

算法的低语 · 数学卷习题伴读

v1.2 全册:v1.1 32 节 + v1.2 19 节 = 51 节

大队长

2026 年 6 月

目录

前言	3
第 1 章 · 信息论与语言的概率结构	3
§ 1.1 香农的赌局：语言是对抗熵的工具	3
§ 1.2 从马尔可夫链到 N-Gram：第一代尝试的局限	10
解答 § 1.1	17
解答 § 1.2	24
§ 1.3 习题：跨界映射——语言序列与 DNA 碱基对	30
解答 § 1.3	32
§ 1.4 习题：反类比——当 DNA 的隐喻失效	34
解答 § 1.4	37
第 2 章 · 嵌入空间与高维几何	40
§ 2.1 习题：词嵌入——为什么字典救不了机器	40
解答 § 2.1	43
§ 2.2 语义的坐标系：词嵌入与类比向量	46
§ 2.3 高维几何的诡异世界	49
§ 2.4 习题：跨界映射——从罗马路网到曼哈顿距离	52
解答 § 2.4	56
§ 2.5 习题：反类比——当几何隐喻失效	60
解答 § 2.5	64
§ 2.6 跨越欧氏：双曲嵌入与层级几何	68
解答 § 2.2	72
解答 § 2.3	76
解答 § 2.6	79
§ 2.6 · v1.2 补题：跨越欧氏——当表示空间不再「平直」	84
解答 § 2.6	88
第 3 章 · 注意力机制的矩阵微分	90
§ 3.1 习题：从 RNN 到 Transformer——序列建模的范式革命	90
解答 § 3.1	93

§ 3.2 注意力公式的拆解：QKV 的真实含义	96
§ 3.3 矩阵乘法的大规模并发：FLOPs 与算术强度	103
§ 3.4 RoPE：把位置编码从加法变成旋转	109
§ 3.5 FlashAttention：当注意力撞上内存墙	117
§ 3.6 习题：注意力的真实身份——关联记忆，而非「注意力」	125
解答 § 3.6	128
§ 3.7 习题：一个被忽略的争论——注意力权重 $\neq$ 解释	131
解答 § 3.7	134
§ 3.8 习题：跨界映射——宏观工业供应链	136
解答 § 3.8	140
§ 3.9 习题：反类比——当供应链隐喻失效	142
解答 § 3.9	146
第 4 章·非凸优化与超参数标度律	148
§ 4.1 从对数似然到损失：三条等价路径	148
§ 4.2 下坡的数学：收敛速度与步长选择	154
§ 4.3 高维非凸的反直觉	163
§ 4.4 习题：损失景观的可视化	166
解答 § 4.4	169
§ 4.5 μ P 超参数迁移	171
§ 4.6 Lion 与 Shampoo（选做）	177
§ 4.7 习题： μ P 的完整面貌	182
解答 § 4.7	184
§ 4.8 习题：跨界类比：复杂系统的工程管理	188
解答 § 4.8	190
§ 4.9 习题：反类比：工程管理隐喻的失效边界	194
解答 § 4.9	197
第 5 章·标度律、相变与涌现	200
§ 5.1 尺度律：Kaplan 三幂律	200
§ 5.2 Chinchilla：compute-optimal 配比	207
§ 5.3–§ 5.4 数据墙与推理时计算	213
§ 5.5 涌现：是否海市蜃楼？	216
§ 5.6–§ 5.7 Grokking 的数学解剖	221
§ 5.8 渗流相变与涌现的物理类比	228
§ 5.9 习题：跨界映射与反类比：相变叙事的边界	237
解答 § 5.9	239
§ 5.X 补充与拓展题	243
第 6 章·硬件感知算法的数学	252
§ 6.1 Roofline 模型	252
§ 6.2 无法逾越的底线：红蓝卵石博弈（Hong-Kung 1981）	260
§ 6.3 FlashAttention 的 I/O 分析	267
§ 6.4 环形注意力（RingAttention）的通信复杂度	275
§ 6.5 算术强度的演化：从 V100 到 B200	280

第7章·后变换器时代的数学	286
§ 7.1 状态空间模型的连续形式	286
§ 7.2 记忆的正交性: HiPPO 如何选择基函数	292
§ 7.3 S4/Mamba 离散化与选择性 SSM	297
§ 7.4 线性注意力	304
§ 7.5 扩散语言模型	310
§ 7.6 习题: Mamba、线性注意力与 RNN 的统一视角	318
解答 § 7.6	321
§ 7.7 习题: 扩散语言模型的数学	325
解答 § 7.7	328
§ 7.8 习题: 世界模型与预测编码的数学	333
解答 § 7.8	337

前言

本册是《算法的低语·数学卷 v1.6》(52 节)的习题伴读全本,由两部分汇编而成:

- **v1.1 题集** (32 节): 覆盖原书 § 1.1, § 1.2, § 2.2–§ 2.3, § 2.6, § 3.2–§ 3.5, § 4.1–§ 4.3, § 4.5, § 4.6, § 5.1, § 5.2, § 5.3–§ 5.4, § 5.5, § 5.6–§ 5.7, § 5.8, § 6.1–§ 6.5, § 7.1–§ 7.5, 合计约 220 题。
- **v1.2 补编** (19 节): 补齐原书 § 1.3, § 1.4, § 2.1, § 2.4, § 2.5, § 3.1, § 3.6–§ 3.9, § 4.4, § 4.7–§ 4.9, § 5.9, § 7.6–§ 7.8, 每节五题, 合计 95 题。

两套题目按章节顺序交错合编: 全书按章 → 节 → 公式卡片 → 题目四级展开, 既保留 v1.1 「公式卡片 + T-X.Y.N 题号」的密度风格, 也保留 v1.2 「题 N + 导读 + 陷阱」的精读风格。

读法: 先合上原书独立完成, 做完再翻原书与本册解答对照。难度标注「易/轻」约 2 分钟, 「中」约 5 分钟, 「难/重」约 10 分钟需要纸笔。

——大队长 (USTC)

第1章·信息论与语言的概率结构

§ 1.1 香农的赌局: 语言是對抗熵的工具

本节依次建立五个度量: 香农熵刻画不确定性的绝对下界, KL 散度量化两分布的”额外代价”, 交叉熵是大模型训练损失的直接来源, 分解恒等式打通三者关系, 困惑度把损失翻译成工程可读的”等效猜测数”。每个公式后立刻练习, 再往下走。

小节导读·公式从哪里来

后面的条件熵、互信息、交叉熵、KL 散度, 本质上都是在香农熵这个定义上”搭积木”。真正难的不是推导, 而是为什么一开始会想到 $H(X) = \sum_x p(x) \log \frac{1}{p(x)}$ 。这个公式不是拍脑袋定义, 而是被三个自然要求”逼出来”的。

第一步: 从”等概率”开始。问一个最简单的问题: n 个等可能结果 (抛硬币、点名、抽卡) 的不确定性该是多少? 记作 $F(n)$ 。直觉上, mn 个结果可以拆成”先选 m 组

中的哪一组，再在该组 n 个里选具体一个” 两步动作，于是 $F(mn) = F(m) + F(n)$ 。能把乘法变加法的函数只有一个——对数。所以 $F(n) = \log n$ ，这一步就把” 为什么是 $\log$ ” 给钉死了。

第二步：从” 分组一致性” 推到非均匀分布。把 N 个等概率微观结果分成 k 组，第 i 组含 n_i 个、出现概率 $p_i = n_i/N$ 。要求一次性确定结果与” 先确定组、再确定组内” 总信息量一致： $\log N = H(p_1, \dots, p_k) + \sum_i p_i \log n_i$ 。代入 $n_i = p_i N$ 展开， $\log N$ 项上下互相抵消，剩下 $H = -\sum_i p_i \log p_i = \sum_i p_i \log \frac{1}{p_i}$ 。公式出来了。

第三步：为什么不能是 $1-p$ 或 $1/p$ ？因为两个独立事件同时发生的概率是 pq ，但 $\frac{1}{pq} \neq \frac{1}{p} + \frac{1}{q}$ ， $1-pq \neq (1-p) + (1-q)$ 。只有 $-\log(pq) = -\log p - \log q$ 能保证” 独立事件信息量可加”。这个原则把对数” 逼” 出来。

第四步：编码视角的现实意义。概率为 p 的符号，最优码长 $\approx \log_2(1/p)$ 位 ($p = 1/8 \rightarrow 3$ bit)。平均码长 $\sum_x p(x) \log_2 \frac{1}{p(x)}$ 就是熵。所以熵不是抽象的” 乱度”，而是” 最优编码下平均需要几个 bit”。这也是大模型损失函数能被解释成” 压缩” 的根源。

本节后面的公式都是在这三个要素上变形：拿一个分布与另一个分布比 $\rightarrow$ 交叉熵；多付出的代价 $\rightarrow$ KL；条件下的预期 $\rightarrow$ 条件熵；两变量共享的信息 $\rightarrow$ 互信息。记住一句：本节什么公式都应当能拆成” 某个事件发生的频率” $\times$ ” 该事件一旦发生带来的信息量”。

公式 1 · 香农熵

$$H(X) = - \sum_{x \in \mathcal{X}} p(x) \ln p(x)$$

约定 $0 \ln 0 = 0$ ；本节默认自然对数（单位 nat）。均匀分布时熵最大 $H(X) \leq \ln |\mathcal{X}|$ ；退化分布时熵为 0。

一句话直觉：熵是对” 平均需要多少信息才能猜到结果” 的精确刻画，分布越均匀熵越高。

在大模型里的位置：训练

本组训练目标：代入 · 变形 · 证明

常见卡点：

- 混淆 $\ln$ 与 $\log_2$ 底数，导致单位（nat vs. bit）不一致
- 忘记约定 $0 \ln 0 = 0$ ，在退化分布处出错
- 把” 熵最大” 直接当结论用，而不能证明

卡住回看：数学卷 § 1.1

本组在练什么：从公式出发数值代入，并理解为何均匀分布最大化熵；做完应能回答：为什么语言建模中熵是 loss 的理论下界？

T-1.1.1 【易 · 代入 · 二元熵】 设 $X \in \{0, 1\}$, $P(X = 1) = p$ 。写出 $H(X)$ 关于 p 的显式表达式 (以自然对数 $\ln$ 为底), 并分别计算 $p = 0.1$ 、 $p = 0.5$ 、 $p = 0.9$ 时的数值 (保留 4 位小数)。

T-1.1.2 【中 · 参数变形 · 熵的凹性】 考虑二元分布 $p = (p, 1 - p)$, 定义二元熵函数 $h(p) = -p \ln p - (1 - p) \ln(1 - p)$, $p \in [0, 1]$ 。

- 求 $h'(p)$ 和 $h''(p)$;
- 证明 $h''(p) \leq 0$ 在 $(0, 1)$ 上恒成立 (即 h 是凹函数);
- 求 $h(p)$ 的最大值点和最大值;
- 用 (b) 的结论解释”为什么混合两个不同分布得到的熵不小于原分布熵的加权平均” (凹性 + Jensen 不等式)。

T-1.1.3 【难 · 证明 · 均匀分布最大化熵】 设离散随机变量 X 取值于有限集合 $\mathcal{X}$, $|\mathcal{X}| = n$ 。

- 用 KL 非负的优雅证明 (不用 Lagrange 乘数法): 设 u 为均匀分布 $u(x) = 1/n$, 利用

$$D_{\text{KL}}(p \| u) = \sum_x p(x) \ln \frac{p(x)}{1/n} = -H(p) + \ln n \geq 0$$

推出 $H(p) \leq \ln n$, 等号当且仅当 $p = u$ 。(本题复用公式 2 的 KL 非负结论, 请在解答中明确引用。)

- 对 $n = 4$, 给出两个不同的非均匀分布, 验证 $H < \ln 4 \approx 1.3863$ nats;
- 结合大模型词表 $|\mathcal{V}| \approx 50000$ 谈谈这一上界的实际意义。

公式 2 · KL 散度 (相对熵)

$$D_{\text{KL}}(p \| q) = \sum_x p(x) \ln \frac{p(x)}{q(x)}$$

其中 p 为真实分布, q 为近似分布, 要求凡 $p(x) > 0$ 处均有 $q(x) > 0$ 。约定 $p(x) = 0$ 的项贡献为 0。

一句话直觉: KL 散度衡量”用近似分布 q 代替真实分布 p 编码时多花的平均代价”, 不对称, 不是距离。

在大模型里的位置: 训练 (forward KL) / 优化 (RLHF reverse KL)

本组训练目标: 代入 · 证明 · 判错

常见卡点:

- 误以为 $D_{\text{KL}}(p\|q) = D_{\text{KL}}(q\|p)$ (不对称, 不是距离)
- 支撑集不一致时 $D_{\text{KL}} = +\infty$ 忘记处理
- Jensen 不等式取等号条件 (随机变量为常数) 记错

卡住回看: 数学卷 § 1.1

本组在练什么: 理解 KL 不对称性和 Gibbs 不等式的证明技巧; 做完应能回答: 为什么 forward 和 reverse KL 在 RLHF 中有本质不同?

T-1.1.4 【易 · 代入 · 三符号语言】 某玩具语言只有三个 token: $\{A, B, C\}$, 真实分布 $p = (0.7, 0.2, 0.1)$, 模型分布 $q = (0.5, 0.3, 0.2)$ 。

- 计算 $D_{\text{KL}}(p\|q)$ (自然对数, 保留 4 位小数);
- 计算 $D_{\text{KL}}(q\|p)$;
- 二者是否相等? 这说明 KL 散度的什么性质?

T-1.1.5 【中 · 对比 · forward vs. reverse KL】 设 p 是均匀骰子分布 (每面 $1/6$), $q = (0.3, 0.2, 0.15, 0.15, 0.1, 0.1)$ (偏置骰子)。

- 计算 $H(p)$ 、 $H(q)$, 并说明为什么 $H(q) < H(p)$;
- 计算 $D_{\text{KL}}(p\|q)$ 和 $D_{\text{KL}}(q\|p)$, 验证二者不等;
- 用一句话解释两个方向的 KL 散度在大模型训练 (forward) 与 RLHF KL 正则 (reverse) 中分别对应什么场景。

T-1.1.6 【难 · 证明 · KL 非负 (Gibbs 不等式)】 证明 $D_{\text{KL}}(p\|q) \geq 0$, 且等号成立当且仅当 $p = q$ 。

提示步骤 (如果卡住可按以下顺序展开):

- 写出 $-D_{\text{KL}}(p\|q) = \sum_x p(x) \ln \frac{q(x)}{p(x)}$;
- 对函数 $\ln(\cdot)$ 应用 Jensen 不等式 ($\ln$ 是凹函数);
- 给出 Jensen 不等式取等号的条件;
- 验证当 $p = q$ 时 $D_{\text{KL}} = 0$ 。

插入提醒: 下一题面向”被 KL 距离误说骗过”的同学, 作为本节 KL 定义后的第一道判错。

T-1.1.15【中 · 判错 · KL 不是距离】 有人说” $D_{\text{KL}}(p\|q)$ 衡量两分布距离, 因此 $D_{\text{KL}}(p\|q) = D_{\text{KL}}(q\|p)$ 。”

- 这句话错在哪里? (从”距离/度量”的三条公理出发, 逐一检验 KL 散度满足哪几条、违反哪几条。)

(b) 用 $p = (0.5, 0.5)$, $q = (0.9, 0.1)$ 计算 $D_{\text{KL}}(p\|q)$ 和 $D_{\text{KL}}(q\|p)$ 给出数值反例。

公式 3 · 交叉熵

$$H(p, q) = - \sum_x p(x) \ln q(x)$$

大模型实际训练损失的形式为：

$$L(\theta) = - \frac{1}{N} \sum_{i=1}^N \ln q_{\theta}(w_i | w_{<i})$$

其中 $w_{<i} = (w_1, \dots, w_{i-1})$ 为前缀， N 为序列长度。

一句话直觉：交叉熵是“用模型分布 q 编码真实分布 p 的平均码长”，也是 GPT 系列训练 loss 的数学本体。

在大模型里的位置：训练

本组训练目标：代入 · 工程 · 判错

常见卡点：

- 混淆 $H(p, q)$ 与 $H(p)$ ：前者依赖模型 q ，后者与模型无关
- 支撑集不一致 ($q(x) = 0$ 而 $p(x) > 0$) 时交叉熵发散，忽略此边界条件
- label smoothing 的作用理解错误（见 T-1.1.8(c)）

卡住回看：数学卷 § 1.1

本组在练什么：交叉熵的数值计算及零概率爆炸的处理；做完应能回答：PyTorch 中为什么用 `F.cross_entropy(logits, target)` 而不是手动 `log(softmax(logits))`？

T-1.1.7 【易 · 代入 · 三符号语言续】 继续使用 T-1.1.4 的分布： $p = (0.7, 0.2, 0.1)$, $q = (0.5, 0.3, 0.2)$ 。

- 计算 $H(p)$ （自然对数，保留 4 位小数）；
 - 计算 $H(p, q)$ ；
 - 注意到 $H(p, q) > H(p)$ ，用一句话解释为什么交叉熵总是不小于真实分布的熵。
-

T-1.1.8 【中 · 边界 · 支撑集不一致时交叉熵爆炸】 设词表 $\mathcal{V} = \{a, b, c, d\}$ ，真实分布 $p = (0.4, 0.3, 0.2, 0.1)$ ，模型分布 $q = (0.5, 0.3, 0.2, 0)$ （模型把 d 的概率压为 0）。

- 计算 $H(p, q)$ 。结果是什么？为什么？
- 计算 $H(p, p)$ ，对比 (a)；

- (c) 在实际训练中, softmax 输出永远 > 0 , 所以不存在真正的零概率。label smoothing 把 one-hot 标签替换为 $(1 - \epsilon) \cdot p_{\text{one-hot}} + \frac{\epsilon}{V} \cdot \text{uniform}$, 这改变的是标签分布还是模型分布? 它的实际作用是什么——是”避免 KL 发散”, 还是”缓解过度自信、改善泛化与校准”? 请给出完整解释。

公式 4 · 交叉熵分解恒等式

$$H(p, q) = H(p) + D_{\text{KL}}(p \| q)$$

一句话直觉: 交叉熵 = 不可压缩的信息下界 $H(p)$ + 模型与真实的额外差距 D_{KL} , 最小化 loss 等价于消除 KL 差距。

在大模型里的位置: 训练

本组训练目标: 代入 · 证明 · 变形

常见卡点:

- 忘记 $H(p)$ 是与 θ 无关的常数, 写出错误的梯度表达式
- 等价链 $\min H(p, q) \Leftrightarrow \min D_{\text{KL}} \Leftrightarrow \max \mathbb{E}[\ln q_\theta]$ 中某一步转化写反
- 推导时加减项位置出错

卡住回看: 数学卷 § 1.1

本组在练什么: 打通交叉熵、KL、MLE 三者等价链; 做完应能回答: 语言模型的 next-token prediction 损失从数学上说在最小化什么?

T-1.1.9 【易 · 代入 · 用 T-1.1.4 / T-1.1.7 验证】 用 T-1.1.4 和 T-1.1.7 的已算结果 ($p = (0.7, 0.2, 0.1)$, $q = (0.5, 0.3, 0.2)$):

- 验证 $H(p, q) = H(p) + D_{\text{KL}}(p \| q)$ (允许四舍五入误差 ≤ 0.001);
- 因为真实数据分布 p 固定, $H(p)$ 是与模型参数 θ 无关的常数, 写出等价链:

$$\min_{\theta} H(p, q_{\theta}) \Leftrightarrow \min_{\theta} D_{\text{KL}}(p \| q_{\theta}) \Leftrightarrow \max_{\theta} \mathbb{E}_{x \sim p} [\ln q_{\theta}(x)]$$

并用一句话解释最右侧即”最大化对数似然”。

T-1.1.10 【中 · 证明 · 交叉熵分解】 从 $H(p, q)$ 的定义出发, 完整推导恒等式 $H(p, q) = H(p) + D_{\text{KL}}(p \| q)$ 。

提示: 在 $-\sum_x p(x) \ln q(x)$ 中加减 $\sum_x p(x) \ln p(x)$, 配出 $H(p)$ 和 D_{KL} 两项。

T-1.1.11【难·推导·交叉熵损失与条件 MLE 等价】 语言模型参数化为 q_θ ，训练集由 (context, next_token) 对 $\{(c_i, w_i)\}_{i=1}^N$ 组成，真实条件分布记为 $\hat{p}(w | c)$ 。

(a) 写出条件对数似然 $\ell(\theta) = \sum_{i=1}^N \ln q_\theta(w_i | c_i)$;

(b) 证明 $\arg \max_\theta \ell(\theta) = \arg \min_\theta \hat{H}$ ，其中 $\hat{H} = -\frac{1}{N} \sum_{i=1}^N \ln q_\theta(w_i | c_i)$ 为经验条件交叉熵；

(c) 当 $N \rightarrow \infty$ 时，经验条件分布收敛到真实条件分布 $p^*(w | c)$ ，MLE 的极限等价于最小化哪个量？

(注意：本题训练样本由 (context, next_token) 对组成，不要写成 i.i.d. 无条件采样。)

公式 5 · 困惑度

$$\text{PPL} = \exp\left(-\frac{1}{N} \sum_{i=1}^N \ln q_\theta(w_i | w_{<i})\right) = \exp(H(p, q))$$

若改用 $\log_2$ 底数，则 $\text{PPL} = 2^{H_2(p, q)}$ ，其中 H_2 的单位为 bit。

一句话直觉：PPL 把 loss (nats/token) 映射为“模型每步等效面临多少个均匀选项”，是语言模型效果的标准公示指标。

在大模型里的位置：评估

本组训练目标：代入 · 证明 · 工程

常见卡点：

- PPL 越低越好，但“PPL=50 等于 1/50 准确率”是错误直觉（见 T-1.2.12）
- 底数不统一时 PPL 计算出错（nats vs. bits）
- PPL = 1 的条件（退化分布 + 完美模型）想不清楚

卡住回看：数学卷 § 1.1

本组在练什么：loss 与 PPL 之间的指数关系及下界推导；做完应能回答：为什么 loss 降 0.2 nats 在 PPL 上的收益随基线 PPL 的大小而变化很大？

T-1.1.12【易·代入·困惑度换算】 某大模型在测试集上的交叉熵 loss 为 $L = 2.3$ nats/token。

(a) 计算困惑度 PPL（保留 2 位小数）；

(b) 把 loss 换算到 bits/token 单位（1 nat = 1/ln 2 bit）；

(c) “等效选项数”角度：模型每一步相当于在多少个等可能选项里盲猜？

(d) 如果 loss 从 2.3 降到 1.9 nats/token，PPL 下降了多少（绝对值和百分比）？

T-1.1.13【中·应用·底数换算与 PPL 比较】 模型 A 用自然对数报告 $\text{loss} = 1.5 \text{ nats/token}$, 模型 B 用 $\log_2$ 报告 $\text{loss} = 2.1 \text{ bits/token}$ 。

- 将两个 loss 统一换算为 nats/token;
 - 分别计算 PPL_A 和 PPL_B (用 $\exp$ 计算);
 - 哪个模型更好? PPL 指标的大小方向是?
-

T-1.1.14【难·证明·PPL 下界】 设语言模型对词表 $\mathcal{V}$ ($|\mathcal{V}| = V$) 做预测。

- 证明对任意模型分布 q_θ , 困惑度 $\text{PPL} \geq 1$ (结合 $H(p, q) \geq 0$);
 - 什么条件下 $\text{PPL} = 1$? 在实际语言建模场景中这是否可能?
 - 证明若模型退化为均匀分布 $q_\theta(w) = 1/V$, 则 $\text{PPL} = V$;
 - 用 (c) 的结果解释: 一个词表大小 50000 的模型, PPL 从 5000 降到 50 意味着什么?
-

T-1.1.16【中·工程·loss $\rightarrow$ PPL】 训练 loss 从 2.0 nats/token 降到 1.8 nats/token, 看起来只降 0.2; 把它换算到 PPL 上是从几降到几? (保留 2 位小数) 这一变化在工程上意味着什么? (提示: PPL 每降一倍约对应 loss 降 $\ln 2 \approx 0.693 \text{ nats}$ 。)

T-1.1.17【易·画图·二元熵凹性】 请在下方草稿区粗略画出二元熵 $h(p) = -p \ln p - (1-p) \ln(1-p)$ 在 $p \in [0, 1]$ 的曲线, 标出极大值点和极大值。

画完后用一句话说明: 为什么这条曲线开口向下(凹性)意味着“混合两个分布的熵不小于熵的混合”? (将凹性与 Jensen 不等式联系起来。)

【做完自检】

- 熵、交叉熵、KL 三者各自回答什么问题? 它们之间的恒等式是什么?
 - 为什么最小化交叉熵等价于最大化对数似然? 哪一步用到了 $H(p)$ 是常数?
 - 为什么困惑度是 loss 的指数形式, 而不是线性? PPL 下降一半对应 loss 下降多少 nats?
-

§ 1.2 从马尔可夫链到 N-Gram: 第一代尝试的局限

N-Gram 的数学核心是条件独立假设: 下一词只依赖前 k 个词 (k 阶马尔可夫性)。参数通过最大似然估计(频率计数)获得, 但稀疏性迫使引入平滑技术。三个公式依次对应这三层逻辑。

小节导读·公式从哪里来

N-Gram 的数学不复杂, 难的是看清这三个公式为什么必须这么出场。

第一步：“下一词依赖所有历史”这个思路为什么装不下。语言建模的原始任务是 $P(w_t | w_1, \dots, w_{t-1})$ ，反复用链式法则会得到 $P(w_1, \dots, w_T) = \prod_t P(w_t | w_{<t})$ 。看似完美，但参数量爆炸：词表 $V = 10^4$ 、句长 $T = 20$ ，要存的条件分布有 $V^T = 10^{80}$ 个——比可观测宇宙内原子数还多。必须“截记忆”。

第二步：马尔可夫假设是“用记忆长度换参数量”的商业交易。假设 $P(w_t | w_{<t}) = P(w_t | w_{t-k}, \dots, w_{t-1})$ 后，参数量从 V^T 降到 V^{k+1} ： $k = 1$ (bigram) 要 10^8 个表项、 $k = 2$ (trigram) 要 10^{12} 个。这个假设不是“现实中下一词只依赖前 k 个词”，而是“我们不得不这样假装，才能把参数拽回可估计区间”。

第三步：为什么是频率计数，不是别的。语料上极大化似然 $\prod_t P(w_t | w_{t-k:t-1})$ 的解最后结构上刚好就是 $\hat{P}(w_t | c) = \text{count}(c, w_t) / \text{count}(c)$ ，也就是“看这个上下文 c 后面出现了多少次 w_t ，除以总出现次数”。“MLE = 频率”是公式上机械推出来的，不是拍脑袋设计。

第四步：平滑为什么必需。trigram 表有 10^{12} 项，但语料只有 10^{10} 个 token：99% 以上的表项 $\text{count} = 0$ ，随便一个没见过的三词组合出现在测试集，似然 $\rightarrow 0$ 、loss $\rightarrow \infty$ 、PPL $\rightarrow \infty$ 。加一、Kneser-Ney 之类的平滑本质上是“从高频表项里抠一点概率质量，平分给没见过的表项”，这是面对稀疏性不得不加的补丁。

N-Gram 失败的数学根源：推广能力、语义相似性、长距离依赖三件事都在表查询范式里“不可表达”。“映射到连续空间去用几何表示语义”这个念头是后续词嵌入、注意力、Transformer 出发点之一。读本节时记住这个“赌局”：马尔可夫假设是代价，不是领悟。

公式 6 · k 阶马尔可夫性

$$P(w_t | w_1, w_2, \dots, w_{t-1}) = P(w_t | w_{t-k}, w_{t-k+1}, \dots, w_{t-1})$$

序列联合概率分解为：

$$P(w_1, w_2, \dots, w_T) = \prod_{t=1}^T P(w_t | w_{t-k}, \dots, w_{t-1})$$

对应 $(k+1)$ -gram 模型 ($k = 1$ 对应 bigram, $k = 2$ 对应 trigram, 以此类推)。

一句话直觉：用固定长度的“短记忆窗口”换来参数可估计性，代价是完全丢失窗口外的所有信息。

在大模型里的位置：架构

本组训练目标：代入 · 反例

常见卡点：

- k 阶马尔可夫对应 $(k+1)$ -gram 而非 k -gram (多一个“当前词”)
- 忘记处理序列开头 $t \leq k$ 时的边界条件 (起始符 $\langle s \rangle$)
- 误以为“增大 k 就能解决长距离依赖”

卡住回看：数学卷 § 1.2

本组在练什么：马尔可夫阶与 N-Gram 对应关系，以及窗口假设的根本局限；做完应能回答：为什么任何有限 k 的 N-Gram 都无法处理主谓一致超过 k 词距的情形？

T-1.2.1 【易 · 代人 · N-Gram 对应关系】 填写下表：

k (马尔可夫阶)	N-Gram 名称	条件窗口大小	参数量上界 (词表 V)
0	unigram	无条件	V
1	bigram	前 1 个词	V^2
2	(填空)	(填空)	(填空)
4	(填空)	(填空)	(填空)

- (a) 补全表格；
 (b) 设 $V = 50000$ ，计算 $k = 4$ (5-gram) 的参数量上界；
 (c) 为什么 k 阶马尔可夫假设等价于 $(k+1)$ -gram 而不是 k -gram? 用“条件中的 token 数”解释。

T-1.2.2 【中 · 应用 · 序列概率计算】 设 bigram ($k = 1$) 模型给出以下条件概率：

条件	词	概率
<s>	the	1.0
the	cat	2/3
the	dog	1/3
cat	ran	1/2
cat	sat	1/2
dog	ran	1.0
ran	</s>	1.0
sat	</s>	1.0

- (a) 计算 $P(\langle s \rangle \text{ the cat ran } \langle /s \rangle)$;
 (b) 计算 $P(\langle s \rangle \text{ the dog ran } \langle /s \rangle)$;
 (c) 验证 $P(\langle s \rangle \text{ the cat ran } \langle /s \rangle) + P(\langle s \rangle \text{ the cat sat } \langle /s \rangle) + P(\langle s \rangle \text{ the dog ran } \langle /s \rangle) = 1$ (在此模型下)。

T-1.2.3 【难 · 反例 · 长距离依赖的极限】 构造一个含长距离主谓一致的英语句子，要求主语与谓语之间至少 5 个 token (例如 “The cats that the boy saw yesterday are/is ...”)。

- (a) 写出该句子，标注主语和谓语；
 (b) 假设使用 trigram ($k = 2$) 模型，说明模型窗口如何导致它看不到主语；
 (c) 任何 k 阶 N-Gram 能否解决主谓距离超过 k 的情形？这一缺陷直接动机了哪类后续架构？

公式 7 · N-Gram MLE 估计

$$\hat{P}(w_n | w_{n-k}^{n-1}) = \frac{\text{count}(w_{n-k}, \dots, w_{n-1}, w_n)}{\text{count}(w_{n-k}, \dots, w_{n-1})}$$

其中 w_{n-k}^{n-1} 为从 w_{n-k} 到 w_{n-1} 的子序列， $\text{count}(\cdot)$ 为训练语料计数。

一句话直觉：MLE 直接用频率作为概率，在语料量趋于无穷时一致收敛，但小语料时大概率返回 0。

在大模型里的位置：训练

本组训练目标：代入 · 证明 · 反例

常见卡点：

- 分母是 (k) -gram 计数，分子是 $(k + 1)$ -gram 计数，搞混导致公式出错
- MLE 在支撑集外为 0，是系统性缺陷而非偶然
- 一致性证明中忘记假设 $P^*(w_1) > 0$ 条件

卡住回看：数学卷 §1.2

本组在练什么：从语料手算 N-Gram 概率，并理解零概率的根源；做完应能回答：为什么 MLE 在小语料下大概率对未见 N-gram 返回 0？

T-1.2.4 【易 · 计数 · bigram MLE 手算】 给定玩具语料（按 token 切分，含起止符 $\langle s \rangle$ 、 $\langle /s \rangle$ ）：

$\langle s \rangle$ the cat sat $\langle /s \rangle$

$\langle s \rangle$ the dog ran $\langle /s \rangle$

$\langle s \rangle$ the cat ran $\langle /s \rangle$

- (a) 列出所有 bigram 及其计数；
 (b) 用 MLE 估计 $\hat{P}(\text{cat} | \text{the})$ 、 $\hat{P}(\text{ran} | \text{cat})$ 、 $\hat{P}(\text{ran} | \text{dog})$ ；
 (c) 用 (b) 的概率计算 $\hat{P}(\text{the cat ran})$ （条件概率链，不含起止符）。

T-1.2.5 【中 · 计数 · trigram MLE 与零概率】 仍用 T-1.2.4 的语料。

- (a) 列出所有 trigram 及其计数；
 (b) 用 MLE 估计 $\hat{P}(\text{ran} | \text{the, cat})$ 和 $\hat{P}(\text{sat} | \text{the, dog})$ ；

(注意: (b) 中第二项应写作 $P(\text{sat} \mid \text{the, dog})$, 题干勘误自此版本起。)

(c) 后者结果是什么? 这反映了 N-Gram 的什么根本缺陷?

T-1.2.6【难 · 证明 · MLE 一致性】 设语料长度 $N \rightarrow \infty$, 语料由真实分布 P^* 生成的 i.i.d. bigram 序列。证明:

$$\hat{P}_{\text{MLE}}(w_2 \mid w_1) \xrightarrow{\text{a.s.}} P^*(w_2 \mid w_1)$$

提示: 将 $\hat{P}_{\text{MLE}}$ 写成两个频率之比, 对分子分母分别应用强大数定律。

公式 8 · Add-one (Laplace) 平滑

$$\hat{P}_{\text{add-1}}(w_n \mid w_{n-k}^{n-1}) = \frac{\text{count}(w_{n-k}^{n-1}, w_n) + 1}{\text{count}(w_{n-k}^{n-1}) + V}$$

其中 $V = |\mathcal{V}|$ 为词表大小。

一句话直觉: 每种 N-gram 各加一个”幻想观测”, 用均匀先验抹平零概率, 代价是高频项被压缩。

在大模型里的位置: 训练

本组训练目标: 代入 · 推导 · 工程

常见卡点:

- 分母加 V 而非 1 (共有 V 个候选词各加 1, 总分母增加 V)
- 混淆” Add-one 平滑后全部 bigram 仍归一化” 与” 各概率均变化”
- T-1.2.8 整句概率计算时漏掉某一步的平滑

卡住回看: 数学卷 § 1.2

本组在练什么: Add-one 平滑的数值计算及其贝叶斯解释; 做完应能回答: Add-one 平滑等价于什么先验下的后验均值?

T-1.2.7【易 · 代入 · Add-one 效果对比】 延续 T-1.2.4 的语料, 词表 $\mathcal{V} = \{\text{the, cat, dog, sat, ran, <s>, </s>}\}$, $V = 7$ 。

- MLE 估计 $\hat{P}(\text{dog} \mid \text{the})$ 和 $\hat{P}(\text{sat} \mid \text{the})$;
- 用 Add-one 平滑重新估计同样两个量;
- 比较 (a)(b): Add-one 给零频 bigram 带来的概率质量是从哪里”借来”的? 这对高频 bigram 有什么影响?

T-1.2.8 【中 · 应用 · Add-one 全局一致性】 用 T-1.2.4 的 bigram MLE (不加平滑), 计算 $\hat{P}(\langle s \rangle \text{ the dog sat } \langle s \rangle)$ 。

- 写出完整的概率链;
- 最终结果是什么? 哪一步造成了这个结果?
- 改用 Add-one 平滑 ($V = 7$) 重算整句概率。四项全部用平滑公式:

$$P(\text{the} | \langle s \rangle) = \frac{3+1}{3+7} = 0.4, \quad P(\text{dog} | \text{the}) = \frac{1+1}{3+7} = 0.2$$

$$P(\text{sat} | \text{dog}) = \frac{0+1}{1+7} = 0.125, \quad P(\langle s \rangle | \text{sat}) = \frac{1+1}{1+7} = 0.25$$

计算四项乘积, 结果是否仍为 0?

T-1.2.9 【难 · 推导 · Add-one = Dirichlet 后验均值】 设词表大小 V , 条件分布参数 $\theta = (\theta_1, \dots, \theta_V)$ (多项分布), 先验 $\theta \sim \text{Dirichlet}(\alpha_1, \dots, \alpha_V)$ 。观测到计数向量 $\mathbf{n} = (n_1, \dots, n_V)$, $N = \sum_i n_i$ 。

- 写出后验分布 $\theta | \mathbf{n}$ (提示: Dirichlet 是多项的共轭先验);
- 求后验均值 $\mathbb{E}[\theta_i | \mathbf{n}]$;
- 令 $\alpha_1 = \dots = \alpha_V = 1$ (均匀 Dirichlet), 代入 (b), 验证结果恰好就是 Add-one 平滑公式;
- 根据 (c), Add-one 平滑在贝叶斯框架里是什么意思? “加 1” 的 1 代表什么?

公式 9 · N-Gram 表项数量上界 / 稀疏计数空间

$$|\text{表项空间}| = V^{k+1}$$

其中 V 为词表大小, k 为马尔可夫阶。当 $V = 50000$, $k = 4$ 时: $V^5 \approx 3.1 \times 10^{23}$ 。

严格自由参数量: 每个 k 阶上下文对应 V 个候选词, 减去 1 个归一化约束, 故严格自由参数为 $V^k(V-1)$; 数量级仍为 V^{k+1} 。

一句话直觉: N-Gram 的参数空间随词表指数爆炸, 实际语料几乎无法覆盖, 这是 Transformer 用参数共享替代稀疏计数的根本动机。

在大模型里的位置: 架构

本组训练目标: 代入 · 工程 · 对比

常见卡点:

- 混淆”表项数 V^{k+1} “与”自由参数数 $V^k(V-1)$ ”
- 忘记归一化约束使自由参数减少 1 (每个上下文下)
- 用旧版 GPT-2 词表 50000; LLaMA-3 已使用 128256

卡住回看：数学卷 § 1.2

本组在练什么：N-Gram 组合爆炸的数量级感知，以及与现代 LLM 参数量的对比；做完应能回答：为什么 LLaMA-3 8B 的 80 亿参数在 N-Gram 框架下仍是杯水车薪？

T-1.2.10 【易 · 数值 · 组合爆炸计算】 设词表大小 $V = 50000$ 。

- (a) 计算 4-gram ($k = 3$) 的参数数量上界 V^4 ；
- (b) 计算 5-gram ($k = 4$) 的参数数量上界 V^5 ；
- (c) 全球已观测的可读文本约 10^{13} token 量级。在 5-gram 模型下，每种 5-gram 组合平均能被观测到多少次（数量级估算）？

T-1.2.11 【中 · 对比 · DNA vs. 语言的稀疏性差异】 DNA 碱基字母表大小 $M = 4$ ；语言模型 subword 词表大小 $M = 50000$ 。

- (a) 分别计算 $k = 2$ （三联体/trigram）下的参数量；
- (b) 若全部覆盖参数空间需要每种组合至少出现一次，各自需要多少训练数据（最小估计）？
- (c) DNA 三联体层级是否存在稀疏性问题？语言 trigram 呢？用 (a)(b) 的数字支持结论。

T-1.2.12 【中 · 判错 · PPL 与准确率】 有人说” PPL=50 表示模型有 $1/50$ 的概率猜对下一个词。”

- (a) 这句话错在哪里？（提示：PPL 是几何平均的等效猜测数，不是单步准确率；真实词表中不同 token 出现概率不均匀。）
- (b) 给出一个反例：构造一个词表大小为 3 的分布，使得模型 PPL = 3 但单步准确率 (top-1) 远高于 $1/3$ 。

T-1.2.13 【中 · 工程 · N-Gram vs. LLM】 为什么 N-Gram 时代必须做平滑（Add-one / Kneser-Ney），而 Transformer 时代更多强调表示学习、参数共享和 dropout？

- (a) 用 $V = 128256$ （LLaMA-3 词表大小）和 $k = 4$ 算出 5-gram 表项上界（精确数量级）；
 - (b) LLaMA-3 8B 参数量为 8×10^9 ，与 (a) 的数字对比：即便把全部参数都用于 N-Gram 表，能覆盖多大比例的 5-gram 空间？
 - (c) 用一句话说明” 参数共享 + 上下文表示学习” 为何是当前主流技术路线的核心解法。
-

【做完自检】

1. MLE 在小语料下为什么大概率返回 0? (支撑集稀疏与参数空间指数爆炸。)
2. Add-one 平滑等价于什么先验下的后验均值? “加 1” 的贝叶斯含义是什么?
3. 为什么 N-Gram 无法处理长距离主谓一致? Transformer 用什么机制克服了这一限制?

解答 § 1.1

解答 T-1.1.1 【易 · 代入 · 二元熵】 二元熵公式: $H(X) = -p \ln p - (1-p) \ln(1-p)$ 。

- $p = 0.1$: $H = -0.1 \times \ln 0.1 - 0.9 \times \ln 0.9 = 0.2303 + 0.0948 = 0.3251$ nats。
- $p = 0.5$: $H = -0.5 \ln 0.5 - 0.5 \ln 0.5 = \ln 2 \approx 0.6931$ nats (二元最大值)。
- $p = 0.9$: 与 $p = 0.1$ 关于 $p = 0.5$ 对称, $H \approx 0.3251$ nats。

关键观察: $h(p)$ 在 $p = 0.5$ 取极大, 关于 $p = 0.5$ 对称; 分布越偏斜, 熵越小。

解答 T-1.1.2 【中 · 参数变形 · 熵的凹性】

(a) 对 $h(p) = -p \ln p - (1-p) \ln(1-p)$ 求导:

$$h'(p) = -\ln p - 1 + \ln(1-p) + 1 = \ln \frac{1-p}{p}$$

$$h''(p) = -\frac{1}{p} - \frac{1}{1-p} = -\frac{1}{p(1-p)}$$

- (b) 在 $p \in (0, 1)$ 上, $p(1-p) > 0$, 故 $h''(p) = -1/(p(1-p)) < 0$, h 在 $(0, 1)$ 上严格凹。
- (c) 令 $h'(p) = 0$: $\ln \frac{1-p}{p} = 0 \Rightarrow p = 1/2$ 。最大值 $h(1/2) = \ln 2 \approx 0.6931$ nats。
- (d) 由凹函数的 Jensen 不等式: 对任意 $\lambda \in [0, 1]$ 和两个参数值 p_1, p_2 ,

$$h(\lambda p_1 + (1-\lambda)p_2) \geq \lambda h(p_1) + (1-\lambda)h(p_2)$$

即“混合分布的熵 $\geq$ 各自熵的加权平均”。直觉: 混合两个分布引入了额外的不确定性 (不知道数据来自哪个分量)。

解答 T-1.1.3 【难 · 证明 · 均匀分布最大化熵】 【P0 修复: 删除 Lagrange 乘数法, 改用 KL 非负的优雅证明】

- (a) 设均匀分布 $u(x) = 1/n$ 。由 T-1.1.6 的 Gibbs 不等式 (公式 2 的 KL 非负结论), $D_{\text{KL}}(p \| u) \geq 0$ 。展开:

$$D_{\text{KL}}(p\|u) = \sum_x p(x) \ln \frac{p(x)}{1/n} = \sum_x p(x) \ln p(x) + \sum_x p(x) \ln n = -H(p) + \ln n$$

因此 $-H(p) + \ln n \geq 0 \Rightarrow H(p) \leq \ln n$ ，等号当且仅当 $D_{\text{KL}}(p\|u) = 0$ ，即 $p = u$ （均匀分布）。□

本题结论复用了公式 2（KL 非负）的结果，体现”公式互相打通”。

(b) 取 $n = 4$ ，验证 $H < \ln 4 \approx 1.3863$ nats：

- 分布 $(0.7, 0.1, 0.1, 0.1)$ ： $H = -0.7 \ln 0.7 - 3 \times 0.1 \ln 0.1 \approx 0.2497 + 0.6908 = 0.9405 < 1.3863$ nats。
- 分布 $(0.4, 0.3, 0.2, 0.1)$ ： $H \approx 0.3665 + 0.3612 + 0.3219 + 0.2303 = 1.2799 < 1.3863$ nats。

(c) 对词表 $|\mathcal{V}| \approx 50000$ 的模型，熵上界 $\ln 50000 \approx 10.82$ nats/token（约 15.6 bits/token）。这是无任何上下文时每个 token 的最大不确定性。实际语言远未达到此上限（英语字符级熵率约 1 bit/字符），正因有大量结构约束，语言才能被有效建模压缩。

解答 T-1.1.4 【易 · 代入 · 三符号语言】 记 $p = (0.7, 0.2, 0.1)$ ， $q = (0.5, 0.3, 0.2)$ 。

(a)

$$D_{\text{KL}}(p\|q) = 0.7 \ln \frac{0.7}{0.5} + 0.2 \ln \frac{0.2}{0.3} + 0.1 \ln \frac{0.1}{0.2}$$

$$= 0.7 \times 0.3365 + 0.2 \times (-0.4055) + 0.1 \times (-0.6931) = 0.2355 - 0.0811 - 0.0693 \approx 0.0851 \text{ nats}$$

(b)

$$D_{\text{KL}}(q\|p) = 0.5 \ln \frac{0.5}{0.7} + 0.3 \ln \frac{0.3}{0.2} + 0.2 \ln \frac{0.2}{0.1}$$

$$= 0.5 \times (-0.3365) + 0.3 \times 0.4055 + 0.2 \times 0.6931 = -0.1682 + 0.1216 + 0.1386 \approx 0.0920 \text{ nats}$$

(c) $D_{\text{KL}}(p\|q) \approx 0.0851 \neq D_{\text{KL}}(q\|p) \approx 0.0920$ ，二者不相等。这说明 KL 散度不满足对称性，故不是度量（metric）；两个方向有不同的语义（分别对应”forward KL”和”reverse KL”）。

解答 T-1.1.5 【中 · 对比 · forward vs. reverse KL】

(a)

$$H(p) = \ln 6 \approx 1.7918 \text{ nats}$$

(均匀分布达到上界 $\ln 6$ 。)

$$H(q) = -(0.3 \ln 0.3 + 0.2 \ln 0.2 + 2 \times 0.15 \ln 0.15 + 2 \times 0.1 \ln 0.1)$$

$$\approx 0.3612 + 0.3219 + 2 \times 0.2846 + 2 \times 0.2303 = 1.7129 \text{ nats}$$

$H(q) < H(p)$, 因为均匀分布在所有同支撑分布中熵最大 (T-1.1.3 已证); 非均匀偏置使某些结果更可预测, 降低了熵。

(b)

$$\begin{aligned} D_{\text{KL}}(p\|q) &= \frac{1}{6} \left[\ln \frac{1/6}{0.3} + \ln \frac{1/6}{0.2} + 2 \ln \frac{1/6}{0.15} + 2 \ln \frac{1/6}{0.1} \right] \\ &= \frac{1}{6} [-0.5878 - 0.1823 + 2 \times 0.1054 + 2 \times 0.5108] \approx \frac{0.6623}{6} \approx 0.1104 \text{ nats} \end{aligned}$$

$$D_{\text{KL}}(q\|p) = \sum_i q_i \ln \frac{q_i}{1/6} = -H(q) + \ln 6 \approx -1.7129 + 1.7918 = 0.0789 \text{ nats}$$

$$D_{\text{KL}}(p\|q) \approx 0.1104 \neq D_{\text{KL}}(q\|p) \approx 0.0789。$$

(c) forward KL $D_{\text{KL}}(p\|q)$: 最大似然训练的目标, 惩罚模型在真实分布有质量处的低估, 倾向于”覆盖所有模式” (mode-covering)。reverse KL $D_{\text{KL}}(q\|p)$: RLHF / 变分推断中的 KL 正则, 惩罚模型在真实分布低概率处的高估, 倾向于”聚焦单一模式” (mode-seeking)。

解答 T-1.1.6 【难 · 证明 · KL 非负 (Gibbs 不等式)】

(a) 将 KL 散度改写:

$$-D_{\text{KL}}(p\|q) = \sum_x p(x) \ln \frac{q(x)}{p(x)}$$

(b) 函数 $\ln(\cdot)$ 是凹函数。由 Jensen 不等式 (凹函数版本),

$$\sum_x p(x) \ln \frac{q(x)}{p(x)} \leq \ln \sum_x p(x) \cdot \frac{q(x)}{p(x)} = \ln \sum_x q(x) = \ln 1 = 0$$

故 $-D_{\text{KL}}(p\|q) \leq 0$, 即 $D_{\text{KL}}(p\|q) \geq 0$ 。

(c) Jensen 不等式取等号当且仅当 $\frac{q(x)}{p(x)}$ 对所有 $p(x) > 0$ 的 x 是常数 c 。结合归一化条件 $\sum_x q(x) = c = 1$, 故 $p = q$ 。

(d) 当 $p = q$ 时: $D_{\text{KL}}(p\|p) = \sum_x p(x) \ln \frac{p(x)}{p(x)} = \sum_x p(x) \cdot 0 = 0$ 。✓

解答 T-1.1.7 【易 · 代入 · 三符号语言续】 记 $p = (0.7, 0.2, 0.1)$, $q = (0.5, 0.3, 0.2)$ 。

(a)

$$H(p) = -0.7 \ln 0.7 - 0.2 \ln 0.2 - 0.1 \ln 0.1 = 0.2497 + 0.3219 + 0.2303 \approx 0.8019 \text{ nats}$$

(b)

$$H(p, q) = -0.7 \ln 0.5 - 0.2 \ln 0.3 - 0.1 \ln 0.2 = 0.4852 + 0.2408 + 0.1609 \approx 0.8869 \text{ nats}$$

(c) $H(p, q) \approx 0.8869 > H(p) \approx 0.8019$ 。因为 $H(p, q) = H(p) + D_{\text{KL}}(p\|q)$, 而 $D_{\text{KL}} \geq 0$ (Gibbs 不等式)。等号仅在 $q = p$ 时成立, 即只有当模型分布与真实分布完全一致时, 交叉熵才等于熵。

解答 T-1.1.8 【中 · 边界 · 支撑集不一致时交叉熵爆炸】 【P0 修复: (c) 删去”避免 KL 爆炸”的错误表述, 改为正确解释】

(a) $H(p, q) = -[0.4 \ln 0.5 + 0.3 \ln 0.3 + 0.2 \ln 0.2 + 0.1 \ln 0]$ 。在 $x = d$ 处, $p(d) = 0.1 > 0$ 但 $q(d) = 0$, 导致 $\ln q(d) = -\infty$, 该项 $= 0.1 \times (-\infty) = -\infty$ (取绝对值后为 $+\infty$)。故 $H(p, q) = +\infty$ 。

原因: 模型把真实分布有质量的事件 (d) 的概率压成了 0, 导致用 q 编码 p 的代价无限大。

(b)

$$H(p, p) = -[0.4 \ln 0.4 + 0.3 \ln 0.3 + 0.2 \ln 0.2 + 0.1 \ln 0.1] \approx 0.3665 + 0.3612 + 0.3219 + 0.2303 = 1.2799$$

对比: 当 $q = p$ (完美模型) 时交叉熵有限且最小; 但 $q(d) = 0$ 时交叉熵发散。

(c) 在实际训练中, softmax 输出永远 > 0 , 因此不存在真正的零概率, “KL 发散”在工程实践中并不是 label smoothing 要解决的主要问题。

Label smoothing 把 one-hot 标签替换为:

$$p_\epsilon = (1 - \epsilon) \cdot p_{\text{one-hot}} + \frac{\epsilon}{V} \cdot \mathbf{1}$$

这改变的是标签分布 (真实分布 p), 而非模型分布 q 。其实际作用是:

- **缓解过度自信**: 阻止模型把正确类别的 logit 推向无穷大, 防止梯度消失和 logit 值爆炸;
- **改善泛化与校准**: 模型不再”全力赌注”一个 token, 在分布内不可见 token 上也分配少量概率, 校准 (calibration) 更好。

综上：label smoothing 的主要作用是缓解过度自信、改善泛化与校准，而不是“避免 KL 发散”。

工程批注 (T-1.1.8): 正因为 $\log(0) \rightarrow -\infty$ 会产生 NaN，我们从不用概率分布 q 直接算 loss，而是调用 `F.cross_entropy(logits, target)`，底层用 `LogSumExp` 技巧自动数值稳定。公式上 $\log(\text{softmax}(z)_y) = z_y - \text{logsumexp}(z)$ ，哪怕 z 很大也不会溢出。

解答 T-1.1.9 【易 · 代入 · 用 T-1.1.4 / T-1.1.7 验证】

(a) 由 T-1.1.7 已知 $H(p) \approx 0.8019$ ，由 T-1.1.4 已知 $D_{\text{KL}}(p\|q) \approx 0.0851$ ：

$$H(p) + D_{\text{KL}}(p\|q) \approx 0.8019 + 0.0851 = 0.8870$$

与 T-1.1.7 所得 $H(p, q) \approx 0.8869$ 相差 $0.0001 \leq 0.001$ ，恒等式成立。✓

(b) 等价链：

$$\min_{\theta} H(p, q_{\theta}) = \min_{\theta} [H(p) + D_{\text{KL}}(p\|q_{\theta})] \Leftrightarrow \min_{\theta} D_{\text{KL}}(p\|q_{\theta}) \Leftrightarrow \max_{\theta} \mathbb{E}_{x \sim p} [\ln q_{\theta}(x)]$$

最右侧 $\max_{\theta} \mathbb{E}_{x \sim p} [\ln q_{\theta}(x)]$ 正是对数似然 (log-likelihood) 的期望形式：如果用经验数据近似期望，即为最大化 $\sum_i \ln q_{\theta}(x_i)$ ，也就是最大化似然 (MLE)。

解答 T-1.1.10 【中 · 证明 · 交叉熵分解】 【P0 修复：删除乱码残留，重写推导】

从定义出发：

$$H(p, q) = - \sum_x p(x) \ln q(x)$$

在求和式内加减 $\sum_x p(x) \ln p(x)$ (值为 $-H(p)$)：

$$\begin{aligned} H(p, q) &= - \sum_x p(x) \ln q(x) + \sum_x p(x) \ln p(x) - \sum_x p(x) \ln p(x) \\ &= \underbrace{- \sum_x p(x) \ln p(x)}_{H(p)} + \underbrace{\sum_x p(x) \ln \frac{p(x)}{q(x)}}_{D_{\text{KL}}(p\|q)} \end{aligned}$$

故 $H(p, q) = H(p) + D_{\text{KL}}(p\|q)$ 。□

实战含义：训练数据决定 p ，故 $H(p)$ 是与模型参数 θ 无关的常数。 $\min_{\theta} H(p, q_{\theta}) \Leftrightarrow \min_{\theta} D_{\text{KL}}(p\|q_{\theta}) \Leftrightarrow \max_{\theta} \mathbb{E}_{x \sim p} [\ln q_{\theta}(x)]$ 。这是 GPT/BERT 等所有语言模型训练损失的全部数学根据。

解答 T-1.1.11 【难 · 推导 · 交叉熵损失与条件 MLE 等价】 【P0 修复：删去 i.i.d. 无条件采样的表述，改为 (context, next_token) 对的条件 MLE】

(a) 条件对数似然：

$$\ell(\theta) = \sum_{i=1}^N \ln q_{\theta}(w_i | c_i)$$

其中 (c_i, w_i) 为第 i 个 (context, next_token) 对。

(b) 经验条件交叉熵 $\hat{H} = -\frac{1}{N} \sum_{i=1}^N \ln q_{\theta}(w_i | c_i)$ 。因此：

$$\arg \max_{\theta} \ell(\theta) = \arg \max_{\theta} \frac{1}{N} \sum_{i=1}^N \ln q_{\theta}(w_i | c_i) = \arg \min_{\theta} \hat{H} \checkmark$$

(c) 由大数定律，当 $N \rightarrow \infty$ 时经验条件分布收敛到真实条件分布 $p^*(w | c)$ ，故

$$\hat{H} \rightarrow H(p^*, q_{\theta}) = H(p^*) + D_{\text{KL}}(p^* \| q_{\theta})$$

MLE 的极限等价于最小化 $D_{\text{KL}}(p^* \| q_{\theta})$ ，即让模型条件分布尽可能接近真实数据生成的条件分布。

解答 T-1.1.12 【易 · 代入 · 困惑度换算】

(a) $\text{PPL} = e^{2.3} \approx 9.97$ (约 10)。

(b) $1 \text{ nat} = 1 / \ln 2 \text{ bit} \approx 1.4427 \text{ bit}$ ，故 $2.3 \text{ nats} \approx 2.3 \times 1.4427 \approx 3.32 \text{ bits/token}$ 。

(c) 困惑度 ≈ 10 ，即模型每一步相当于在约 10 个等可能选项中均匀猜测。

(d) $\text{PPL}_{2.3} = e^{2.3} \approx 9.97$ ， $\text{PPL}_{1.9} = e^{1.9} \approx 6.69$ 。绝对下降： $9.97 - 6.69 = 3.28$ ；百分比下降： $3.28 / 9.97 \approx 32.9\%$ 。这意味着模型把“每步等效猜测选项数”从约 10 压缩到约 7，是相当显著的能力跃迁。

解答 T-1.1.13 【中 · 应用 · 底数换算与 PPL 比较】

(a) 换算到 nats：

- 模型 A：已为 1.5 nats/token。
- 模型 B： $2.1 \text{ bits} \times \ln 2 = 2.1 \times 0.6931 \approx 1.456 \text{ nats/token}$ 。

(b) $\text{PPL}_A = e^{1.5} \approx 4.48$ ； $\text{PPL}_B = e^{1.456} \approx 4.29$ (或等价地 $2^{2.1} \approx 4.29$)。

(c) 模型 B 更好，因为 $\text{PPL}_B \approx 4.29 < \text{PPL}_A \approx 4.48$ 。PPL 越低越好：较低的困惑度意味着模型对每个 token 的预测更确定，等效猜测选项数更少。

解答 T-1.1.14 【难 · 证明 · PPL 下界】 【P0 修复: (d) 删去重复的乱码】

- (a) 由 $H(p, q) \geq H(p) \geq 0$ (熵非负), 故 $\text{PPL} = e^{H(p, q)} \geq e^0 = 1$ 。
- (b) $\text{PPL} = 1$ 当且仅当 $H(p, q) = 0$, 即 $D_{\text{KL}}(p\|q) = 0$ ($q = p$) 且 $H(p) = 0$ (退化分布, 每个位置只有一种可能的 token)。在实际语言建模中, 自然语言包含多样性, $H(p) > 0$, 故 $\text{PPL} = 1$ 在实践中不可能。
- (c) 若 $q_\theta(w) = 1/V$ 对所有 w 成立:

$$H(p, q_\theta) = - \sum_x p(x) \ln \frac{1}{V} = \ln V \cdot \sum_x p(x) = \ln V$$

故 $\text{PPL} = e^{\ln V} = V$ 。□

- (d) 均匀分布基线 $\text{PPL} = V = 50000$ 。PPL 从 5000 降到 50 意味着: 模型把等效选项从 5000 个压到 50 个, 预测确定性比均匀基线高出 3 个数量级 (比值 $50000/50 = 1000$), 是对真实语言结构的高效捕捉。

工程批注 (T-1.1.14): GPT-2 在 WikiText-103 上 PPL 约 18.3, GPT-3 约 20.5, LLaMA-2-70B 约 3.3, DeepSeek-V3 在 wikitext 上约 2.x。PPL 每降一倍约对应 loss 降 $\ln 2 \approx 0.693$ nats。不同论文评估时的 context length 和 tokenizer 可能不同, PPL 数值需在相同条件下比较才有意义。

解答 T-1.1.15 【中 · 判错 · KL 不是距离】 【新增题目】

- (a) 度量 (metric) 的三条公理: ① 非负性 $d(p, q) \geq 0$, 等号当且仅当 $p = q$; ② 对称性 $d(p, q) = d(q, p)$; ③ 三角不等式 $d(p, r) \leq d(p, q) + d(q, r)$ 。

KL 散度满足 ① (由 Gibbs 不等式), 但违反 ② 对称性 (两个方向 KL 值一般不等), 且不满足 ③ 三角不等式。因此 D_{KL} 不是度量, 严格来说应称为“散度” (divergence)。

- (b) 取 $p = (0.5, 0.5)$, $q = (0.9, 0.1)$:

$$D_{\text{KL}}(p\|q) = 0.5 \ln \frac{0.5}{0.9} + 0.5 \ln \frac{0.5}{0.1} = -0.2939 + 0.8047 \approx 0.5108 \text{ nats}$$

$$D_{\text{KL}}(q\|p) = 0.9 \ln \frac{0.9}{0.5} + 0.1 \ln \frac{0.1}{0.5} = 0.5290 - 0.1609 \approx 0.3681 \text{ nats}$$

$0.5108 \neq 0.3681$, 数值反例成立。□

解答 T-1.1.16 【中 · 工程 · loss $\rightarrow$ PPL】 【新增题目】

- $\text{PPL}_{2.0} = e^{2.0} \approx 7.39$
- $\text{PPL}_{1.8} = e^{1.8} \approx 6.05$

PPL 从约 7.39 降到 6.05, 绝对降低 1.34, 相对降低约 18.1%。

工程含义：看起来 loss 只降了 0.2 nats，但对应 PPL 降了近 18%。这在已训练到较低 loss 的模型上是非常显著的改善。由于 PPL 与 loss 是指数关系，工程中应同时报告 loss 和 PPL 变化，避免对“只降了 0.2”产生误解。

解答 T-1.1.17 【易 · 画图 · 二元熵凹性】 【新增题目】

图形描述（草稿区画法）：

- x 轴： $p \in [0, 1]$ ； y 轴： $h(p)$
- 端点： $h(0) = h(1) = 0$ （退化分布，确定性）
- 极大值点： $p = 0.5$ ， $h(0.5) = \ln 2 \approx 0.693$ nats
- 曲线开口向下（凹形），关于 $p = 0.5$ 对称

凹性与“混合熵不小于熵的混合”的联系：

函数 h 凹意味着对任意 $p_1, p_2 \in [0, 1]$ 和 $\lambda \in [0, 1]$ ：

$$h(\lambda p_1 + (1 - \lambda)p_2) \geq \lambda h(p_1) + (1 - \lambda)h(p_2)$$

这正是 Jensen 不等式（凹函数版本）。“混合两个分布”对应左边（混合后的参数处的熵），“熵的混合”对应右边（各自熵的加权平均）。曲线开口向下意味着左边永远大于等于右边，即混合操作只会增加不确定性，不会减少。

解答 § 1.2

解答 T-1.2.1 【易 · 代入 · N-Gram 对应关系】

(a) 补全表格：

k (马尔可夫阶)	N-Gram 名称	条件窗口大小	参数量上界
0	unigram	无条件	V
1	bigram	前 1 个词	V^2
2	trigram (3-gram)	前 2 个词	V^3
4	5-gram	前 4 个词	V^5

(b) $V^5 = 50000^5 = 5^5 \times 10^{20} = 3125 \times 10^{20} \approx 3.125 \times 10^{23}$ 。

(c) k 阶马尔可夫性的条件包含 k 个历史词，加上当前词共 $k + 1$ 个 token 构成一个完整的 $(k + 1)$ -gram 组合。计数分子有 $k + 1$ 个词，计数分母有 k 个词，因此模型名称为 $(k + 1)$ -gram 而不是 k -gram。

解答 T-1.2.2 【中 · 应用 · 序列概率计算】

(a)

$$P(\langle s \rangle \text{ the cat ran } \langle /s \rangle) = 1.0 \times \frac{2}{3} \times \frac{1}{2} \times 1.0 = \frac{1}{3} \approx 0.3333$$

(b)

$$P(\langle s \rangle \text{ the dog ran } \langle /s \rangle) = 1.0 \times \frac{1}{3} \times 1.0 \times 1.0 = \frac{1}{3} \approx 0.3333$$

$$(c) P(\langle s \rangle \text{ the cat sat } \langle /s \rangle) = 1.0 \times \frac{2}{3} \times \frac{1}{2} \times 1.0 = \frac{1}{3}。$$

$$\frac{1}{3} + \frac{1}{3} + \frac{1}{3} = 1\checkmark$$

这三条路径覆盖了此模型下所有可能的完整句子，概率之和为 1，归一化正确。

解答 T-1.2.3 【难 · 反例 · 长距离依赖的极限】

(a) 示例句子：

The cats that the boy saw in the garden are sleeping.

主语：cats（位置 2），谓语：are（位置 9），主谓之间相距 7 个 token。

(b) Trigram ($k = 2$) 模型在预测 are/is 时，条件窗口为前 2 个词 (garden __, 或 in garden)，完全看不到距离 7 步之前的主语 cats；模型只能根据 garden 之后常见的动词形式来预测，无法感知主谓一致。

(c) 一般地， k 阶 N-Gram 的有效上下文窗口固定为 k 个词。对任意主谓距离 $d > k$ ，模型都无法捕获一致关系。由于主谓距离在自然语言中无上界，任何有限 k 的 N-Gram 都无法完全解决此问题。这一缺陷直接动机了：RNN / LSTM $\rightarrow$ Attention / Transformer（通过注意力机制建立任意距离的直接依赖）。

解答 T-1.2.4 【易 · 计数 · bigram MLE 手算】

(a) 语料三句： $\langle s \rangle$ the cat sat $\langle /s \rangle$ 、 $\langle s \rangle$ the dog ran $\langle /s \rangle$ 、 $\langle s \rangle$ the cat ran $\langle /s \rangle$ 。Bigram 计数：

Bigram	计数
$\langle s \rangle$ the	3
the cat	2
the dog	1
cat sat	1
cat ran	1
dog ran	1
sat $\langle /s \rangle$	1
ran $\langle /s \rangle$	2

(b)

- $\hat{P}(\text{cat} \mid \text{the}) = 2/3$ (the 出现 3 次, 后接 cat 2 次)
- $\hat{P}(\text{ran} \mid \text{cat}) = 1/2$ (cat 出现 2 次, 后接 ran 1 次)
- $\hat{P}(\text{ran} \mid \text{dog}) = 1/1 = 1$ (dog 出现 1 次, 后接 ran 1 次)

(c)

$$\hat{P}(\text{the cat ran}) = \hat{P}(\text{cat} \mid \text{the}) \cdot \hat{P}(\text{ran} \mid \text{cat}) = \frac{2}{3} \times \frac{1}{2} = \frac{1}{3}$$

解答 T-1.2.5 【中 · 计数 · trigram MLE 与零概率】 【P0 修复：题目原文” P(sat the, dog) “乱码已在题干中纠正为” P(sat | the, dog) “】

(a) Trigram 计数：

Trigram	计数
<s> the cat	2
<s> the dog	1
the cat sat	1
the cat ran	1
the dog ran	1
cat sat </s>	1
cat ran </s>	1
dog ran </s>	1

(b)

- $\hat{P}(\text{ran} \mid \text{the, cat}) = 1/2$ (the cat 出现 2 次, 后接 ran 1 次)
- $\hat{P}(\text{sat} \mid \text{the, dog}) = 0/1 = 0$ (语料中从未出现 the dog sat)

(c) 结果为零——这正是 N-Gram 的稀疏性 / 零概率问题：若某 $(k+1)$ -gram 在训练语料中从未出现，MLE 直接给出概率 0。任何包含该 n-gram 的句子整体概率被压成 0，模型对未见组合完全失声。这直接动机了 Laplace、Good-Turing、Kneser-Ney 等平滑方法。

解答 T-1.2.6 【难 · 证明 · MLE 一致性】 令 $N_{w_1, w_2} = \text{count}(w_1, w_2)$, $N_{w_1} = \text{count}(w_1)$, 语料总 token 数为 N 。

$$\hat{P}_{\text{MLE}}(w_2 \mid w_1) = \frac{N_{w_1, w_2}}{N_{w_1}} = \frac{N_{w_1, w_2}/N}{N_{w_1}/N}$$

由强大数定律 (SLLN)，若语料由 P^* 生成的 i.i.d. bigram 序列组成：

$$\frac{N_{w_1, w_2}}{N} \xrightarrow{\text{a.s.}} P^*(w_1, w_2), \quad \frac{N_{w_1}}{N} \xrightarrow{\text{a.s.}} P^*(w_1)$$

在 $P^*(w_1) > 0$ 的条件下, 由连续映射定理 (对 $x \mapsto f(x)/g(x)$ 在 $g > 0$ 处连续):

$$\hat{P}_{\text{MLE}}(w_2 | w_1) \xrightarrow{\text{a.s.}} \frac{P^*(w_1, w_2)}{P^*(w_1)} = P^*(w_2 | w_1). \square$$

解答 T-1.2.7 【易 · 代入 · Add-one 效果对比】 词表 $V = 7$; the 出现 3 次。

(a) MLE: $\hat{P}(\text{dog} | \text{the}) = 1/3 \approx 0.3333$; $\hat{P}(\text{sat} | \text{the}) = 0/3 = 0$ (the sat 从未出现)。

(b) Add-one (count(the) = 3, $V = 7$):

$$\cdot \hat{P}_{+1}(\text{dog} | \text{the}) = (1 + 1)/(3 + 7) = 2/10 = 0.2$$

$$\cdot \hat{P}_{+1}(\text{sat} | \text{the}) = (0 + 1)/(3 + 7) = 1/10 = 0.1$$

(c) Add-one 将分母从 3 扩充到 10, 把原本的概率质量“稀释”了。分子给每个 $V = 7$ 个候选词各加 1, 这 7 单位质量来自对所有原本 > 0 的 bigram 的均匀压缩。代价是高频 bigram 被压得相对更低; 这就是为什么 Kneser-Ney 等精细折扣方法在 N-Gram 时代是最优实践。

解答 T-1.2.8 【中 · 应用 · Add-one 全局一致性】 【P0 修复: 旧版 (c) 答案漏了首项平滑, 错误结果 0.00625; 本版四项全部用平滑公式, 正确结果 0.0025】

(a) 完整概率链 (bigram MLE, 不加平滑):

$$\begin{aligned} \hat{P}(\langle s \rangle \text{ the dog sat } \langle /s \rangle) &= \hat{P}(\text{the} | \langle s \rangle) \cdot \hat{P}(\text{dog} | \text{the}) \cdot \hat{P}(\text{sat} | \text{dog}) \cdot \hat{P}(\langle /s \rangle | \text{sat}) \\ &= 1 \times \frac{1}{3} \times \hat{P}(\text{sat} | \text{dog}) \times 1 \end{aligned}$$

(b) dog sat 在语料中从未出现, 故 $\hat{P}(\text{sat} | \text{dog}) = 0$, 整句概率 = 0。“dog sat” 这一未见 bigram 单独导致整句失声——这是 MLE 零概率的链式放大效应。

(c) 用 Add-one 平滑 ($V = 7$), 四项全部平滑:

步骤	计数 (context)	count(bigram)	Add-one 估计
$P(\text{the} \langle s \rangle)$	count($\langle s \rangle$) = 3	count($\langle s \rangle \text{ the}$) = 3	$(3+1)/(3+7) = 0.4$
$P(\text{dog} \text{the})$	count(the) = 3	count(the dog) = 1	$(1+1)/(3+7) = 0.2$
$P(\text{sat} \text{dog})$	count(dog) = 1	count(dog sat) = 0	$(0+1)/(1+7) = 0.125$
$P(\langle /s \rangle \text{sat})$	count(sat) = 1	count(sat $\langle /s \rangle$) = 1	$(1+1)/(1+7) = 0.25$

整句概率: $0.4 \times 0.2 \times 0.125 \times 0.25 = 0.0025 > 0$ 。不再为零。正确结果为 0.0025 (旧版因首项未平滑得到的 0.00625 是错的)。

解答 T-1.2.9 【难 · 推导 · Add-one = Dirichlet 后验均值】

- (a) Dirichlet-多项共轭关系：若先验 $\theta \sim \text{Dirichlet}(\alpha_1, \dots, \alpha_V)$ ，观测到计数向量 $\mathbf{n}$ ，则后验：

$$\theta \mid \mathbf{n} \sim \text{Dirichlet}(\alpha_1 + n_1, \alpha_2 + n_2, \dots, \alpha_V + n_V)$$

- (b) Dirichlet 分布 $\text{Dirichlet}(\beta_1, \dots, \beta_V)$ 的边缘均值： $\mathbb{E}[\theta_i] = \beta_i / \sum_j \beta_j$ 。

代入后验参数 $\beta_i = \alpha_i + n_i$ ， $\sum_j \beta_j = \sum_j \alpha_j + N$ ：

$$\mathbb{E}[\theta_i \mid \mathbf{n}] = \frac{n_i + \alpha_i}{N + \sum_j \alpha_j}$$

- (c) 令 $\alpha_1 = \dots = \alpha_V = 1$ （均匀 Dirichlet， $\sum_j \alpha_j = V$ ）：

$$\mathbb{E}[\theta_i \mid \mathbf{n}] = \frac{n_i + 1}{N + V}$$

这正是 Add-one 平滑公式：分子为观测计数加 1，分母为总计数加词表大小 V 。□

- (d) Add-one 在贝叶斯框架中对应“用均匀 Dirichlet ($\alpha = 1$) 作为先验，在此先验下取后验均值”。“加 1”的 1 代表先验伪计数 (pseudo-count)：即在观测任何数据之前，假定每种词都已被“观测到”1 次——这正是均匀 Dirichlet 先验的含义。

解答 T-1.2.10 【易 · 数值 · 组合爆炸计算】

- (a) $V^4 = 50000^4 = 5^4 \times 10^{16} = 625 \times 10^{16} = 6.25 \times 10^{18}$ 。
- (b) $V^5 = 50000^5 = 5^5 \times 10^{20} = 3125 \times 10^{20} \approx 3.125 \times 10^{23}$ 。
- (c) 全球可读文本约 10^{13} token；5-gram 参数空间约 3.125×10^{23} 。平均观测次数： $10^{13} / (3.125 \times 10^{23}) \approx 3.2 \times 10^{-11}$ ——每种 5-gram 组合平均被观测到的次数远远小于 1。绝大多数 5-gram 组合在任何现有语料中计数均为零，MLE 对它们全部输出 0。

工程批注 (T-1.2.10 / T-1.2.13)：LLaMA-3 词表 $V = 128256$ ，若做 5-gram，表项上界为 $128256^5 \approx 3.4 \times 10^{25}$ ；LLaMA-3 预训练语料 15T token = 1.5×10^{13} 。表项数比语料 token 数多 12 个数量级——N-Gram 在 LLaMA-3 词表下几乎必然返回 0，这就是为什么参数共享 + 上下文表示学习是突破 N-Gram 组合爆炸的核心解法，SSM (Mamba/S4) 等替代架构亦采用类似思路。

解答 T-1.2.11 【中 · 对比 · DNA vs. 语言的稀疏性差异】

- (a) 参数量 ($k = 2$ ，即三联体/trigram)：
- DNA： $M^3 = 4^3 = 64$
 - 语言： $V^3 = 50000^3 = 1.25 \times 10^{14}$
- (b) 最小训练数据量（每种组合至少出现 1 次）：

- DNA: 至少 64 个三联体样本 (极易满足)
 - 语言: 至少 1.25×10^{14} 个 trigram 样本 (超出全球现有可读文本 $\sim 10^{13}$ token)
- (c) DNA 三联体: 参数空间仅 64, 可在有限实验数据中完全覆盖, 不存在稀疏性问题, 密码表可穷举统计。语言 trigram: 参数空间 1.25×10^{14} , 即使使用全球所有文本也无法覆盖大多数组合, 稀疏性在 $k \geq 2$ 时已经不可避免。这是 DNA 建模技术不能直接迁移到自然语言的核心数学原因之一。

解答 T-1.2.12 【中 · 判错 · PPL 与准确率】 【新增题目】

- (a) 错误分析: PPL 的定义是 $\text{PPL} = \exp(H(p, q))$, 其中 $H(p, q)$ 是所有位置上 $-\ln q(w_i | w_{<i})$ 的平均。它衡量的是模型在每一步的平均惊讶程度等效的均匀选项数, 而不是单步 top-1 准确率的倒数。PPL=50 表示”模型的预测等效于从 50 个均匀选项中随机选”; 但在真实词表中, 不同 token 出现概率不同, 模型可能把大部分概率质量集中在少数高频词上, top-1 准确率可以远高于 $1/50$ 。
- (b) 反例构造: 词表 $\mathcal{V} = \{a, b, c\}$, 真实分布总是 $p^* = (0.98, 0.01, 0.01)$, 模型预测均匀分布 $q = (1/3, 1/3, 1/3)$ 。

$$H(p^*, q) = -\ln(1/3) = \ln 3 \approx 1.0986 \text{ nats}, \quad \text{PPL} = e^{\ln 3} = 3$$

而此时若模型总是选 a (top-1), 命中率 98%。结论: PPL=3 时的 top-1 准确率可以接近 98%, 远高于” $1/3$ ”。PPL 不等于单步准确率的倒数。

解答 T-1.2.13 【中 · 工程 · N-Gram vs. LLM】 【新增题目】

- (a) $V = 128256$, $k = 4$ (5-gram):

$$\log_{10}(128256) \approx 5.108, \quad \log_{10}(128256^5) \approx 5 \times 5.108 = 25.54$$

$$128256^5 \approx 10^{25.54} \approx 3.4 \times 10^{25}$$

5-gram 表项上界约为 3.4×10^{25} 。

- (b) LLaMA-3 8B 参数量: 8×10^9 。覆盖比例:

$$\frac{8 \times 10^9}{3.4 \times 10^{25}} \approx 2.4 \times 10^{-16}$$

即覆盖不到 $10^{-13}\%$ 的 5-gram 空间——完全是杯水车薪。LLaMA-3 15T token 预训练语料也只能覆盖约 4.4×10^{-13} 的空间。

- (c) 因为 N-Gram 要为每种词序列组合单独存储一个参数, 参数量随词表指数爆炸且彼此不共享; 而 Transformer 通过词嵌入把所有 token 映射到同一语义空间, 通过注意力在连续表示上计算相似度, 用有限参数表示近乎无穷的上下文依赖——参数共享 + 上下文表示学习是突破 N-Gram 组合爆炸的核心解法。

§ 1.3 习题：跨界映射——语言序列与 DNA 碱基对

导读：本节核心从单变量熵走到序列熵率 $\mathcal{H}$ ，五题分别对应：联合熵的可加性、归一化的必要性、平稳性的最小假设、SMB 典型序列、跨界类比的合法性边界。

题 1【轻·推导·联合熵 vs. 单变量熵】 导读：联合熵从单变量熵推广出来的第一步：独立时直接相加，相关时小于和。

设 X_1, X_2 为离散随机变量。

(a) 写出联合熵 $H(X_1, X_2)$ 的定义式。

(b) 若 X_1, X_2 独立，证明 $H(X_1, X_2) = H(X_1) + H(X_2)$ 。

(c) 一般情形下证明 $H(X_1, X_2) \leq H(X_1) + H(X_2)$ ，等号当且仅当独立。提示：用链式法则 $H(X_1, X_2) = H(X_1) + H(X_2 | X_1)$ 及 $H(X_2 | X_1) \leq H(X_2)$ 。

(d) 对长度 n 的序列，写出 $H(X_1, \dots, X_n)$ 的链式分解。

教学注：这条「条件减不确定性」的不等式正是为什么 $\mathcal{H} \leq \log_2 M$ 而英语 $\mathcal{H} \approx 1$ bit/字符 $< \log_2 26 \approx 4.7$ bit 的根源。

陷阱：

- 别把 $H(X, Y)$ 写成 $H(X) \cdot H(Y)$ ，熵是可加不是可乘
- 条件熵 $H(Y | X) \neq H(X | Y)$ ，方向重要

题 2【中·计算·一阶马尔可夫源的熵率】 导读：把抽象的熵率落到一个具体可算的最小例子上。

考虑二值符号 $\{0, 1\}$ 上的一阶马尔可夫链，转移矩阵：

$$P = \begin{pmatrix} 0.9 & 0.1 \\ 0.2 & 0.8 \end{pmatrix}$$

(即 $P(0 | 0) = 0.9$, $P(1 | 0) = 0.1$, $P(0 | 1) = 0.2$, $P(1 | 1) = 0.8$ 。)

(a) 求平稳分布 $\pi = (\pi_0, \pi_1)$ (解 $\pi P = \pi$, $\pi_0 + \pi_1 = 1$)。

(b) 写出该过程熵率的闭式： $\mathcal{H} = \sum_i \pi_i \cdot H(X_2 | X_1 = i) = -\sum_{i,j} \pi_i P_{ij} \log_2 P_{ij}$ 。

(c) 数值计算 $\mathcal{H}$ (保留 4 位小数，单位 bit/符号)。

(d) 与无记忆源 (同一边缘分布 π ，但符号独立同分布) 的熵 $H(\pi)$ 比较，解释为什么 $\mathcal{H} < H(\pi)$ 。

教学注：这正是 N-Gram 模型「困惑度比 unigram 低」的信息论根源——条件减少了不确定性。

陷阱：

- 平稳分布 π 是行向量，方程是 $\pi P = \pi$ (不是 $P\pi = \pi$)
- 熵率公式里 π_i 是「在状态 i 上的时间占比」，不是均匀分布 $1/2$

题 3【中 · 概念辨析 · 平稳性 vs. 遍历性】 导读：搞清楚 SMB 定理「几乎处处」需要的两个假设，哪一个是平稳、哪一个是遍历。

判断真假并说明理由：

- (a) 「平稳过程的样本平均一定收敛到期望」——真还是假？
- (b) 「独立同分布过程一定是平稳的」——真还是假？
- (c) 「平稳过程一定是遍历的」——真还是假？反例提示：考虑两个不同分布的混合源（先抛硬币决定用哪个，之后所有符号都来自这一个）。
- (d) SMB 定理需要哪两个条件？分别保证了什么？

教学注：「平稳」保证 $\frac{1}{n}H(X_1, \dots, X_n)$ 的极限存在（这是熵率定义所需），「遍历」保证 $-\frac{1}{n}\log P(X_1, \dots, X_n)$ 对每条样本路径几乎处处收敛到 $\mathcal{H}$ （而不仅在期望意义上）。

陷阱：

- 平稳 $\neq$ 遍历，反例（混合源）是经典考点
- i.i.d. 是平稳 + 遍历的最强加强，但不是唯一

题 4【重 · 计算 · 典型序列集与 SMB 定理】 导读：用具体数字感受 SMB 的「典型序列才走几乎全部概率」是个多么颠覆直觉的事实。

设英语字符（含空格）字母表大小 $M = 27$ ，熵率 $\mathcal{H} \approx 1.5 \text{ bit/字符}$ 。考虑长度 $n = 100$ 的字符序列。

- (a) 字面上所有可能的序列数是多少？（用 $10^?$ 估算）
- (b) 由 SMB 定理，典型序列集合 $A_\epsilon^{(n)}$ 的大小近似为 $2^{n\mathcal{H}}$ ，估算其数量级（用 $10^?$ 表示）。
- (c) 典型序列占全部可能序列的比例是多少（用 $10^?$ 表示）？
- (d) 每条典型序列的概率约为多少？
- (e) 解释为什么大语言模型「不需要记住所有 M^n 种句子」就能拟合人类语言：它实际只需要把分布覆盖在 $2^{n\mathcal{H}}$ 这个小得多的子集上。

Sanity check： (c) 应该 $\approx 10^{-98}$ ，但 (a)(b) 都用 $\log_{10}$ 换算后两值相除应得到几乎相等的结论。

教学注：这一题是「语言模型可学性」的信息论基础。Transformer 用有限参数就能拟合 token 序列分布，本质是因为典型序列集只占字面空间的一个极薄子集。

陷阱：

- 换算 $\log_{10}(27^{100}) = 100 \log_{10} 27 \approx 143.1$ ，不要算成 10^{27} 之类
- 2^{150} 不是 10^{45} 整：精确算 $150 \log_{10} 2 \approx 45.15$

题 5【重 · 评判 · 跨界类比的合法性边界】 导读：本节的真正主张是「语言和 DNA 服从同一套熵率数学」——但这个跨界类比有什么前提，又有什么不能跨的？

阅读以下四个论断，判断哪些是 SMB 定理直接支持的、哪些是跨界类比的「修辞延伸」：

论断 A：「DNA 编码区的熵率 $\approx 2 \text{ bit/碱基}$ （接近 $\log_2 4$ ），所以基因组几乎没有冗余。」

论断 B：「英语和 DNA 的熵率都是有限值，所以处理英语的 Transformer 架构可以直接拿去做基因组建模而不需修改。」

论断 C：「股价对数收益率的熵率有限，所以可以用语言模型架构做股价预测。」

论断 D：「SMB 定理保证：任何足够大的语言模型只要训练充分，必然能完美预测下一个 token。」

(a) 对每个论断给出「成立 / 部分成立 / 不成立」的判断，并指出关键的前提或漏洞。

(b) 写出至少两条 SMB / 熵率框架在跨界类比时**必须**满足的前提条件。

(c) 列举一个跨界类比**失效**的领域（语言 $\rightarrow ?$ 的映射不成立），说明哪条假设被违反。

教学注：这一题对接 §1.4 反类比节——同一套数学不意味着同一套工具。下一节会详细展开 DNA 的「字母表 4 个、长度 30 亿、几乎无相位、严重依赖空间共定位」与语言的差异。

陷阱：

- 论断 D 是常见误区——SMB 只给出**信息容量上限**，不等于「实际能学到」
- 论断 B 的漏洞在「不需修改」——架构层面相似不等于数据预处理、tokenization、位置编码可以照搬

解答 §1.3

T-1.3.1 【联合熵】 (a) $H(X_1, X_2) = -\sum_{x_1, x_2} p(x_1, x_2) \log p(x_1, x_2)$

(b) 独立时 $p(x_1, x_2) = p(x_1)p(x_2)$ ，代入：

$$H(X_1, X_2) = -\sum_{x_1, x_2} p(x_1)p(x_2)[\log p(x_1) + \log p(x_2)] = H(X_1) + H(X_2)$$

(c) 链式法则 $H(X_1, X_2) = H(X_1) + H(X_2 | X_1)$ 。又由「条件减熵」 $H(X_2 | X_1) \leq H(X_2)$ （等号当且仅当独立），所以 $H(X_1, X_2) \leq H(X_1) + H(X_2)$ 。

(d) $H(X_1, \dots, X_n) = \sum_{i=1}^n H(X_i | X_1, \dots, X_{i-1})$

T-1.3.2 【一阶马尔可夫熵率】 (a) 解 $\pi P = \pi$ ： $0.9\pi_0 + 0.2\pi_1 = \pi_0$ 即 $0.2\pi_1 = 0.1\pi_0$ ，故 $\pi_1 = 0.5\pi_0$ 。配合 $\pi_0 + \pi_1 = 1$ 得 $\pi = (2/3, 1/3)$ 。

(b) $\mathcal{H} = -\sum_{i,j} \pi_i P_{ij} \log_2 P_{ij}$ 。

(c) 分项计算（单位 bit）：

- 状态 0： $H(X_2 | X_1 = 0) = -0.9 \log_2 0.9 - 0.1 \log_2 0.1 = 0.1368 + 0.3322 = 0.4690$
- 状态 1： $H(X_2 | X_1 = 1) = -0.2 \log_2 0.2 - 0.8 \log_2 0.8 = 0.4644 + 0.2575 = 0.7219$
- $\mathcal{H} = (2/3)(0.4690) + (1/3)(0.7219) = 0.3127 + 0.2406 = 0.5533 \text{ bit/符号}$

(d) 无记忆源 $H(\pi) = -(2/3)\log_2(2/3) - (1/3)\log_2(1/3) = 0.3900 + 0.5283 = 0.9183$ bit。 $\mathcal{H} = 0.55 < H(\pi) = 0.92$ 反映条件确实带走了一部分不确定性。

Sanity check: $\mathcal{H} < H(\pi) < \log_2 2 = 1$, 三个量的大小关系符合理论。

T-1.3.3 【平稳 vs. 遍历】 (a) 假。平稳保证极限存在, 但样本均值收敛到时间平均 (不一定等于总体期望, 除非也遍历)。(b) 真。i.i.d. 显然平稳: 联合分布只看长度不看位置。(c) 假。经典反例: 先抛公平硬币 C , 若 $C = H$ 之后所有 $X_i \sim \text{Bernoulli}(0.3)$, 若 $C = T$ 则 $\sim \text{Bernoulli}(0.7)$ 。整个过程平稳但不遍历——样本路径只能采到一种分布。(d) SMB 需要平稳 + 遍历。平稳保证 $\mathcal{H}$ 作为期望极限存在; 遍历保证「几乎所有样本路径」都收敛到这个极限, 使 $-\frac{1}{n}\log p(X_1, \dots, X_n) \xrightarrow{a.s.} \mathcal{H}$ 成立。

T-1.3.4 【典型序列】 (a) 27^{100} 。 $\log_{10}(27^{100}) = 100 \log_{10} 27 \approx 100 \times 1.4314 = 143.14$ 。即约 10^{143} 。

(b) $2^{n\mathcal{H}} = 2^{150}$ 。 $\log_{10}(2^{150}) = 150 \log_{10} 2 \approx 150 \times 0.3010 = 45.15$ 。即约 10^{45} 。

(c) 比例 = $10^{45.15}/10^{143.14} = 10^{-97.99} \approx 10^{-98}$ 。

(d) 每条典型序列概率 $\approx 2^{-n\mathcal{H}} = 2^{-150} \approx 10^{-45}$ 。

(e) 语言模型的目标不是覆盖所有 10^{143} 种字面可能, 而是把概率质量正确地分布到那 10^{45} 条典型序列上——这就是为什么有限参数能拟合「无限大」的字面空间。

Sanity check: (b) 中 $10^{45} \times$ (d) 中 $10^{-45} = 10^0 = 1$, 符合「典型集吃掉几乎全部概率」。

T-1.3.5 【跨界合法性】 (a)

- **A 部分成立**。DNA 编码区熵率确实较高 (≈ 1.9 bit/碱基), 但「几乎无冗余」过强: 密码子简并、内含子、非编码区都是冗余源。
- **B 不成立**。架构可借鉴, 但 tokenization、位置编码、训练目标都要重设。基因组无「词」无「空格」, 长程依赖远超语言。
- **C 部分成立**。熵率有限确实意味着可建模, 但金融时序往往非平稳 (结构断点) 和半遍历, SMB 严格条件不成立——所以预测精度上限远低于语言任务。
- **D 不成立**。SMB 给的是信息容量上限, 告诉你「学多少够」, 但不告诉你「能不能学到」。优化、归纳偏置、样本量都是另外的瓶颈。

(b) 至少需要:

1. 过程平稳 (联合分布在时间平移下不变)
2. 过程遍历 (样本路径能采遍各状态)
3. 字母表有限离散 (连续值需另起一套微分熵)

(c) 示例: 脑电信号 (EEG) 是连续值时序, 无离散字母表; 金融极端事件 (crash) 违反平稳; 图像非序列结构, 邻居关系是二维而非一维——这些都是 SMB 框架直接套用失效的领域。

§ 1.3 小结: 从 $H(X)$ 走到 $\mathcal{H}$ 的全路径是「单变量熵 $\rightarrow$ 联合熵 $\rightarrow$ 归一化 $\rightarrow$ 平稳收敛 $\rightarrow$ SMB 几乎处处」。这条链不仅给语言模型一个信息容量上限, 也精确划出了跨界类比的合法边界——下一节 § 1.4 会把这条边界继续往外推。

§1.4 习题：反类比——当 DNA 的隐喻失效

导读：本节核心是从「字母表量级差异」出发，推导出稀疏性裂变、冗余机制差异和动态性差异，最终说明「语言像 DNA」只在信息论最抽象层面成立，落到工程时处处失效。五题分别对应：字母表量级与熵率上限的量化、稀疏性的质变临界点、冗余机制的本质差异、动态性对建模策略的影响、综合判断四条「DNA → 语言」迁移论断的合法性。

题 1【轻·计算·字母表大小与熵率上限】 导读：把字母表大小差异从直觉转成可以精确比较的数字，是理解后续所有差异的起点。

设 DNA 的字母表大小 $M_{\text{DNA}} = 4$ ，现代大模型 BPE 词表大小 $M_{\text{LLM}} = 50000$ ，对数底数统一取 $\log_2$ 。

(a) 写出有限字母表随机过程熵率上限的公式，并分别计算 DNA 和大模型词表的熵率上限（单位：bit/符号）。

(b) 两者熵率上限之比是多少？保留 2 位小数。

(c) 若 DNA 编码区的实际熵率约为 $\mathcal{H}_{\text{DNA}} \approx 1.9$ bit/碱基，英语字符级熵率约为 $\mathcal{H}_{\text{eng}} \approx 1.0$ bit/字符，分别计算各自相对于字母表上限的冗余度 $R = 1 - \mathcal{H} / \log_2 M$ （以百分比表示）。哪个系统冗余度更高？

(d) 冗余度高意味着「可压缩性强」。从工程角度看，压缩难度更高的是哪个系统？为什么？

教学注：这道题的意义不在于记住两个数字，而在于建立一个直觉：DNA 的熵率「顶天」，英语的熵率「躺平」——两者不是五十步笑百步，而是在不同量级的字母表上做着完全不同的统计游戏。

陷阱：

- 混淆熵率和熵率上限：熵率 $\mathcal{H} \leq \log_2 M$ ，等号当且仅当字母表上均匀分布且独立同分布
- 冗余度公式里的分母是 $\log_2 M$ （上限），不是字母表大小 M 本身

题 2【中·计算·稀疏性裂变的量级临界】 导读：同一个 N -Gram 参数计数公式，代入不同的 M ，会跨越一个质变临界点：从「可穷举」跳到「永远压不完」。

设语料总 token 数为 $T = 10^{12}$ （万亿级），词/符号表大小分别考虑 $M \in \{4, 26, 1000, 50000\}$ ，考察 $k = 2$ （三联体）的参数空间。

(a) 对每个 M ，计算 $k = 2$ 阶 N -Gram 的参数空间大小 M^3 （用科学计数法表示）。

(b) 语料可以「覆盖」某个 $k = 2$ N -Gram 的条件粗略地说是该 N -Gram 的期望计数 $T/M^3 \geq 1$ 。对上述四个 M ，判断哪些满足「可穷举统计」条件。

(c) 对 $M = 4$ （DNA 三联体密码子）， $M^3 = 64$ 。已知 64 个密码子编码 20 种氨基酸（另加 3 个终止密码子），可以列出完整的「输入 → 输出」映射表。对 $M = 50000$ （大模型 5-gram）， $M^5 \approx 3.1 \times 10^{23}$ ，为什么即使把全互联网的文本都用上也无法穷举？

(d) 上述分析说明,「隐马尔可夫模型 (HMM) 在 DNA 序列分析中可行, 但直接用于大词表语言建模会崩溃」——从参数空间的角度给出解释。

教学注: 这道题的目的是让「稀疏性裂变」从定性变成定量。DNA 的 $k = 2$ 参数空间 (64) 和语言的 $k = 4$ 参数空间 (3.1×10^{23}) 之间的差距, 不是「两个大数字」的差距, 而是「可计算」与「不可计算」之间的门槛跨越。

陷阱:

- DNA 里 $k = 2$ 对应三联体 (3 个碱基), 注意是 $M^{k+1} = 4^3 = 64$, 不是 $4^2 = 16$
- 全互联网约 $10^{12} \sim 10^{13}$ token, 与 3×10^{23} 之间差了 10 ~ 11 个数量级, 不要低估差距

题 3【中·概念辨析·冗余来源的物理根源 vs. 统计涌现】 导读:「冗余」这个词在 DNA 和语言里同形不同质——搞清楚来源, 才能判断能不能跨界迁移。

判断下列陈述的真假, 并说明理由:

- (a) 「遗传密码的简并性 (多个密码子对应同一氨基酸) 是一种统计现象, 是因为在进化历史中某些密码子使用得特别频繁。」——真还是假?
- (b) 「英语的冗余度约为 79%, 这一数值在未来会随时间保持稳定不变。」——真还是假? 举一个历史上英语统计性质发生漂移的实例。
- (c) 「语言和 DNA 的冗余都能用信息压缩算法 (如 Huffman 编码) 来降低, 因此它们冗余的本质是一样的。」——真还是假?

(d) 某研究团队想把 1990 年英文新闻训练的语言模型直接用于 2024 年的社交媒体文本。从「语言冗余机制」的角度解释为什么这会失败, 以及需要做什么才能补救。

教学注: 这道题强迫我们把「冗余」的两种来源讲清楚: 物理化学约束 (tRNA 摆动配对, 写死的、跨物种稳定) vs. 使用者群体统计行为的涌现 (随社群、时代、媒介漂移)。把两者混用是 DNA-NLP 跨界类比中最常见的隐患。

陷阱:

- (a) 的关键词是「统计现象」——遗传密码的简并性是物理化学决定的, 不是统计的
- (c) 的陷阱: 压缩算法的可用性只说明「冗余存在」, 不说明「冗余来源相同」

题 4【重·计算·动态性差异与持续预训练的必要性】 导读: 把「语言统计性质漂移」这一定性说法转换成可以估算的量化框架, 理解为什么语言模型需要持续更新而生物信息模型不需要。

设某语言模型在时间 t_0 的语料上训练, 语料的熵率为 $\mathcal{H}_{t_0}$ 。在时间 $t_1 = t_0 + \Delta t$ 的语料上, 由于词汇漂移和新概念涌现, 假设熵率变化为 $\mathcal{H}_{t_1} = \mathcal{H}_{t_0} + \delta$, 且有一部分新词汇 ΔV 出现 (旧模型完全不认识)。

(a) 旧模型 (在 t_0 语料上训练) 在 t_1 语料上评估时, 困惑度 (perplexity) 为什么会上升? 从交叉熵的角度解释。

(b) 假设新词汇占新语料的比例为 α (即约有 α 比例的 token 是旧模型词表里没有的), 旧模型对这些 token 的概率接近零 ($P_{\text{old}} \approx 10^{-5}$)。计算这部分 token 对交叉熵的贡献 (仅考虑这 α 比例的 token, 用 α 和 10^{-5} 表示)。

(c) 对比之下, 一个 2025 年训练的 DNA 序列分析模型, 用于分析 1950 年采样的小鼠基因组样本, 预期困惑度会有多大变化? 从「冗余机制是否漂移」的角度解释。

(d) 下列三种补救措施各对应什么数学操作: 「持续预训练」「指令微调 (SFT)」「上下文学习 (ICL)」? 在信息论框架内分别说明它们「修正」的是哪一层不匹配。

教学注: 这道题把「语言需要持续维护, DNA 模型可以一次训练长期使用」这个工程直觉翻译成信息论语言: 新词 $\rightarrow P \approx 0 \rightarrow$ 交叉熵趋于无穷; 漂移 $\rightarrow$ 模型分布 q 与真实分布 p 的 KL 散度增大 $\rightarrow$ 困惑度上升。

陷阱:

- (b) 中不要忘记乘以 α : 只有那 α 比例的 token 用到了接近零的概率, 其余 token 仍用旧模型
- (c) 中「没有变化」不是废话——要从机制上说清楚为什么 DNA 统计性质几十年不漂移

题 5【重·评判·四条跨界迁移论断的合法性】 导读: 本节的真正主张是「字母表量级差异推出的四堵铁墙」——把这条推导链用来审查四个常见的跨界论断, 判断哪些成立、哪些失效、原因是什么。

阅读以下四个论断:

论断 A: 「Transformer 架构在语言任务上成功, 说明它是一个通用序列建模器; 把它原封不动地迁移到 DNA 序列分析, 性能应该和在语言上一样好。」

论断 B: 「DNA 的编码区熵率接近上限 (≈ 2 bit/碱基), 英语字符级熵率远低于上限 (≈ 1 bit/字符), 所以处理 DNA 的模型比处理英语的模型所需参数量更大。」

论断 C: 「语言的冗余来自统计约束, 所以可以通过数据增强 (随机替换同义词) 来降低冗余度、提升语言模型的泛化能力, 就像 DNA 中密码子简并性增强系统鲁棒性一样。」

论断 D: 「同一个 BPE 分词器, 在 2010 年语料上训练好之后, 可以不经修改地用于 2025 年的网络文本——因为 BPE 只是一种压缩算法, 与语言的统计性质无关。」

(a) 对每个论断给出「成立 / 部分成立 / 不成立」的判断, 并指出关键的前提条件或漏洞。

(b) 论断 A 和论断 B 都涉及「参数量」问题, 但切入角度不同。A 说的是「架构迁移」, B 说的是「模型容量需求」。从字母表大小、稀疏性和典型序列集三个角度, 分别分析这两个论断各自错在哪里 (或对在哪里)。

(c) 论断 C 的「同义词替换」类比「密码子简并」失效在哪里? 需要满足什么额外条件, 同义词替换才是合法的数据增强?

(d) 写出至少两条「DNA 序列建模技术迁移到 NLP」时**必须**重新验证的核心假设。

教学注: 这道题的核心能力是「把 §1.4 的四堵铁墙变成判断尺」。每一条论断都踩了

某一堵墙，但踩的角度不同——训练结束时，能辨别每条论断的失效属于哪堵墙，本节的目的就达到了。

陷阱：

- 论断 B 的直觉可能反直觉：熵率高 $\neq$ 模型更难训练，因为字母表也小 ($M = 4$ vs $M = 50000$)，参数空间远比语言小
- 论断 D 的问题不在 BPE 算法本身，而在「词表的统计代表性」随时间漂移——BPE 是算法，词表是数据

解答 § 1.4

T-1.4.1 【字母表大小与熵率上限】 (a) 熵率上限公式： $\mathcal{H} \leq \log_2 M$ （字母表均匀独立同分布时取等）。

- DNA： $\log_2 4 = 2.0000$ bit/碱基
- 大模型词表： $\log_2 50000 = \log_2(5 \times 10^4) = \log_2 5 + \log_2 10^4 = 2.3219 + 13.2877 = 15.6096$ bit/token

(b) 比值： $15.6096/2.0000 \approx 7.80$ 。语言 token 级别的理论信息密度约是 DNA 碱基的 7.8 倍。

(c) 冗余度：

- DNA： $R_{\text{DNA}} = 1 - 1.9/2.0 = 5\%$
- 英语字符： $R_{\text{eng}} = 1 - 1.0/\log_2 26 = 1 - 1.0/4.7004 \approx 78.7\%$

英语冗余度远高于 DNA。

(d) 从工程角度，压缩难度更高的是英语：冗余度高意味着更多的统计约束需要被模型学习，需要更大的上下文窗口和更复杂的依赖结构。DNA 的冗余度低，每个碱基携带的信息接近上限，反而更「接近随机」，统计规律更简单。

Sanity check： DNA 冗余度 5% 意味着基因组接近最优压缩；英语冗余度约 79% 意味着每个字符平均只携带约 0.21 个「独立比特」的语义信息，和香农 1951 年猜字母实验的结论一致。

T-1.4.2 【稀疏性裂变的量级临界】 (a) M^3 的计算：

M	M^3
4 (DNA)	64
26 (字母)	17576
1000	10^9
50000	1.25×10^{14}

(b) 覆盖条件 $T/M^3 \geq 1$, $T = 10^{12}$:

- $M = 4$: $10^{12}/64 \approx 1.56 \times 10^{10} \gg 1$ ，完全覆盖（每个三联体平均出现 156 亿次）

- $M = 26$: $10^{12}/17576 \approx 5.69 \times 10^7 \gg 1$, 完全覆盖
- $M = 1000$: $10^{12}/10^9 = 1000 \gg 1$, 勉强覆盖 (平均每个 trigram 出现 1000 次)
- $M = 50000$: $10^{12}/(1.25 \times 10^{14}) = 0.008 \ll 1$, 无法覆盖 (绝大多数 trigram 从未出现)

(c) DNA 三联体只有 64 种, 不仅可以穷举统计, 还可以手动建立完整映射表 (遗传密码表)。对 $M = 50000$ 的语言 5-gram, 参数空间约 3.1×10^{23} , 而全互联网约 10^{13} token: $10^{13}/(3.1 \times 10^{23}) \approx 3.2 \times 10^{-11}$, 即便穷尽所有可见文本, 也只能覆盖约三百亿分之一的参数空间。

(d) HMM 的状态转移矩阵大小为「隐状态数 $\times$ 输出符号数」。DNA 上有效隐状态数 (如密码子识别所需) 约几十到几百, 输出符号数 $M = 4$, 参数规模完全可管理。对大词表语言, 状态转移矩阵是 $V \times V = 50000 \times 50000 = 2.5 \times 10^9$ 个参数, 即使不考虑稀疏性, 仅存储就需要约 10 GB (float32), 远超可行范围。

Sanity check: $M = 4$ 时 $k = 2$ 参数空间为 64, 与氨基酸数 (20 种 + 3 个终止) 量级吻合, 说明 DNA 三联体级别的统计是「原子化可枚举」的。

T-1.4.3 【冗余来源的物理根源 vs 统计涌现】 (a) 假。遗传密码的简并性是 tRNA 反密码子摆动配对决定的**物理化学约束**, 与统计频率无关。人类基因组、大肠杆菌、拟南芥使用 (几乎) 相同的遗传密码, 但三者的密码子使用频率 (codon usage bias) 各不相同——频率是统计现象, 简并性是物理现象, 二者独立。

(b) 假。语言的冗余度来自使用者群体统计行为的涌现, 会随时间漂移。历史实例: 「wireless」在 1900 年指无线电报 (高熵, 技术词汇), 在 2025 年近乎白噪声 (「wifi」取代了它的语义核心), 其条件概率分布剧烈变化; 「tweet」在 2006 年前是鸟叫 (低频), 此后成为平台动词 (高频), 改变了周围词的统计分布。

(c) 假。信息压缩算法 (Huffman 编码) 仅要求「冗余存在于分布中」, 不区分来源。DNA 的冗余和语言的冗余都可以被压缩, 但「可压缩」只是充分条件, 不是同质性的证明。类比: 黄金和铁都能被铁锤敲打, 但这并不意味着两者本质相同。

(d) 失败原因: 1990 年语料与 2024 年语料的真实分布 p 已经漂移——新词 (「meme」「emoji」「deepfake」) 在旧语料中频率极低或缺失, 旧模型对这些词的概率 $q \approx 0$, 交叉熵 $-\log q \rightarrow \infty$ 。补救措施: 用 2024 年语料进行持续预训练, 更新词表 (加入新 token) 并重新估计整体分布。

Sanity check: (a) 和 (c) 是两个方向的错误——前者把物理约束当统计, 后者把技术手段当机制等同。分别从「来源」而非「效果」出发判断, 可以有效防止混淆。

T-1.4.4 【动态性差异与持续预训练】 (a) 旧模型的分布 q_{old} 是在 t_0 时刻的真实分布 p_{t_0} 上训练的 (近似 $q_{\text{old}} \approx p_{t_0}$)。到 t_1 时刻, 真实分布变为 $p_{t_1} \neq p_{t_0}$ 。用旧模型评估新语料的交叉熵为 $H(p_{t_1}, q_{\text{old}}) = H(p_{t_1}) + D_{\text{KL}}(p_{t_1} \| q_{\text{old}})$ 。由于 $D_{\text{KL}} \geq 0$, 且漂移使 $D_{\text{KL}} > 0$, 交叉熵上升, 困惑度随之上升。

(b) 那 α 比例的 token 对交叉熵的贡献为:

$$\Delta H \approx \alpha \cdot (-\log_2 P_{\text{old}}) = \alpha \cdot (-\log_2 10^{-5}) = \alpha \cdot 16.61 \text{ bit/token}$$

例如 $\alpha = 0.01$ (1% 新词), $\Delta H \approx 0.17 \text{ bit/token}$; 若这些 token 原本应该占困惑度 ≈ 20 的模型交叉熵约 4.32 bit, 则新词把交叉熵推高约 4%, 困惑度约从 20 升到 21。

(c) DNA 序列的统计性质由遗传密码 (物理化学约束) 决定, 在几十年乃至几亿年的进化尺度上都极为稳定 (同一物种基因组密码子偏好性变化可忽略不计)。因此 2025 年的 DNA 模型用于分析 1950 年样本, 困惑度几乎不变—— $D_{\text{KL}}(p_{1950} \| q_{2025}) \approx 0$ 。

(d) 三种补救措施的信息论解读:

- **持续预训练**: 用新语料更新整个分布 q_θ , 减小 $D_{\text{KL}}(p_{t_1} \| q_\theta)$; 对应「重新拟合真实分布」
- **指令微调 (SFT)**: 在条件分布层面调整 $q_\theta(y | x, \text{指令})$, 修正的是「给定输入时输出分布的对齐」, 而非全局分布
- **上下文学习 (ICL)**: 通过 few-shot 示例把当前上下文信息注入, 等效于动态更新先验 $p(y | \text{示例}, x)$, 修正的是「推断时的条件分布」, 不改变模型参数

Sanity check: (b) 中当 $\alpha = 0$ 时 $\Delta H = 0$, 符合「没有新词就没有额外交叉熵」的直觉; 当 $\alpha = 1$ (全部是新词) 时 $\Delta H = 16.61 \text{ bit}$, 远超正常模型的平均交叉熵 (约 4 bit), 困惑度爆炸, 符合直觉。

T-1.4.5 【四条跨界迁移论断的合法性】 (a) 判断:

- **论断 A 部分成立**。Transformer 是通用序列建模器, 迁移到 DNA 的架构没有根本障碍 (ESM、Evo 等生物语言模型已证明可行)。但「性能一样好」失效——DNA 的 tokenization 策略、位置编码、词表大小、上下文长度需求 (基因组长达 30 亿碱基 vs 语言几千 token) 都需彻底重设。漏洞: 「原封不动迁移」是谬误。
- **论断 B 不成立**。熵率高 $\neq$ 需要更多参数。DNA 字母表 $M = 4$, 参数空间 4^{k+1} 极小; 语言词表 $M = 50000$, 参数空间 50000^{k+1} 指数爆炸。决定参数量需求的是 **稀疏性 (M^{k+1}) 和典型序列集大小 ($2^{n_{\mathcal{H}}}$)**, 而不是熵率与上限的比值。
- **论断 C 不成立**。同义词替换的类比失效。密码子简并性是写死的物理约束, 鲁棒性是「冗余编码降低单点突变影响」的物理效果, 不可模仿。语言中的同义词替换改变的是训练分布, 可能提升泛化, 但前提是语义不变——如果「快乐」和「开心」在上下文共现模式上不完全等价 (它们确实不完全等价), 随机替换引入了噪声而非鲁棒性。
- **论断 D 不成立**。BPE 本质是对语料统计分布的压缩编码, 词表和子词切分方式直接依赖训练语料的 bigram 频率统计。2010 年语料与 2025 年语料的 bigram 分布不同, 因此 2010 年的分词器对 2025 年文本的切分效率 (压缩比) 下降, 且无法切分新词 (只能退化为字符级)。

(b) 论断 A (架构迁移) 的问题: 并非架构本身不行, 而是**超参数 (tokenization、位置编码、序列长度) 与 DNA 统计结构不匹配**——这是稀疏性差异 (字母表 4 vs 50000) 和动态性差异 (DNA 无漂移 vs 语言漂移) 的共同后果。论断 B (模型容量) 的问题: **混淆了「信息密度高」和「模型容量需求大」**——后者由参数空间大小决定, 而 $M = 4$ 的参数空间是 $M = 50000$ 的天文倍数之小。

(c) 「同义词替换 $\approx$ 密码子简并」失效原因：密码子简并是一对多的确定性物理映射 (CAA 和 CAG 都编码谷氨酰胺，永远不变)；同义词替换是概率性的语义近似 («快乐» 和 «欢喜» 在部分上下文可替换，但 «她快乐地跑来» 和 «她欢喜地跑来» 的细微语气差异不为零)。要使同义词替换成为合法的数据增强，需要额外验证：语义等价性 (下游任务标签不变) 和统计等价性 (两词的上下文分布 KL 散度足够小)。

(d) 必须重新验证的核心假设 (至少两条)：

1. **平稳性假设**：语言是非平稳的 (统计性质随时间漂移)，DNA 编码区在短时间内是平稳的；迁移时必须重新验证目标域的平稳性。
2. **字母表和 tokenization 假设**：DNA 有自然的单符号字母表 (A/T/G/C)，语言的 «符号» 由 BPE 动态定义，其颗粒度和覆盖范围直接影响稀疏性——必须重新设计 tokenization。

Sanity check：四条论断覆盖了 §1.4 的四堵铁墙——A 对应架构可移植性 (字母表量级差异推出的工程差异)，B 对应稀疏性裂变，C 对应冗余本质差异，D 对应动态性差异。每条失效都能找到对应的 «铁墙»，说明覆盖完整。

§1.4 小结：「语言像 DNA」这句话在信息论最抽象层面是真的——两者都是有限字母表的平稳随机过程，都有熵率，都服从 SMB 定理。但这个真理只有在 $M = 4$ vs $M = 50000$ 、 $4^3 = 64$ vs $50000^5 \approx 3 \times 10^{23}$ 、物理约束 vs 统计涌现、稳定 vs 漂移这四层差异都被正视之后，才是安全可用的。下一章 §2.1 开始的词嵌入，就是为 «大字母表 + 统计涌现» 这种语言专有的挑战量身定制的数学回应。

第 2 章 · 嵌入空间与高维几何

§2.1 习题：词嵌入——为什么字典救不了机器

导读：本节核心是从符号表示 (one-hot) 的根本缺陷出发，一步步推出分布式表示 (嵌入向量) 的必要性，再到嵌入矩阵的工程实现，最终用余弦相似度替代内积作为语义度量。五题分别对应：one-hot 的正交性与稀疏性缺陷、嵌入矩阵的查表操作与计算复杂度、余弦相似度的动机与计算、分布假设与语义涌现的关系、嵌入维度 d 的选择与信息容量权衡。

题 1 【轻 · 推导 · one-hot 编码的两堵墙】 **导读**：one-hot 的失败不是 «不够聪明»，而是其定义本身就切断了所有词间关联，推导出来而不是靠记忆。

设词表大小 $V = 5$ ，词表为 «猫、狗、汽车、跑步、睡觉»，按此顺序编号为 1 至 5。

(a) 写出 «猫» 和 «狗» 的 one-hot 向量 $\mathbf{e}_{\text{猫}}, \mathbf{e}_{\text{狗}} \in \{0, 1\}^5$ 。

(b) 计算 $\mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{狗}}$ 、 $\mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{汽车}}$ ，以及 $\mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{猫}}$ 。

(c) 由 (b) 的计算结果，解释为什么 one-hot 编码无法表达 «猫和狗在语义上相似，汽车则不同» 这一关系。

(d) 当词表大小为 $V = 50000$ 时，存储全部词的 one-hot 向量需要多少比特 (假设每个

分量占 1 比特)? 与此相比, 用 $d = 512$ 维浮点嵌入向量 (每个分量 32 比特) 存储全部词需要多少比特? 计算两者之比。

教学注: 这道题让「one-hot 正交性」和「稀疏性存储代价」各自从公式里推出来, 而不是靠「记住结论」。特别是 (c) 要求写出因果关系——不只是「两个结果一样」, 而是「为什么一样导致无法表达语义相似性」。

陷阱:

- (b) 中 $\mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{猫}} = 1$ 不要忘记, 这就是为什么 one-hot 能用于「是否同一个词」的判断, 但不能用于「有多相似」
- (d) 中注意 one-hot 向量的维度是 V , 不是 1

题 2【中 · 计算 · 嵌入矩阵的查表操作】 导读: 「查表」不是一个特殊操作——它就是矩阵乘法的高效特例, 把这个等价关系算清楚, 才能理解为什么 $O(d)$ 不是 $O(Vd)$ 。

设嵌入矩阵 $E \in \mathbb{R}^{V \times d}$, $V = 4$, $d = 3$, 具体值为:

$$E = \begin{pmatrix} 0.1 & 0.5 & -0.2 \\ 0.8 & -0.3 & 0.6 \\ -0.4 & 0.2 & 0.9 \\ 0.0 & 0.7 & -0.5 \end{pmatrix}$$

其中行 1、2、3、4 分别对应词 w_1, w_2, w_3, w_4 。

(a) 写出词 w_2 (第 2 行) 的 one-hot 向量 $\mathbf{e}_{w_2} \in \mathbb{R}^4$ 。

(b) 计算矩阵向量乘法 $E^T \mathbf{e}_{w_2}$, 得到 w_2 的嵌入向量 $\mathbf{v}_{w_2} \in \mathbb{R}^3$ 。

(c) 验证这等价于直接取 E 的第 2 行。标准矩阵向量乘法的计算复杂度是 $O(Vd)$, 而「直接取行」的复杂度是 $O(d)$ 。对 $V = 50000$, $d = 512$, 两者分别需要约多少次乘加操作?

(d) 在 Word2Vec 中, 同一个词有两套嵌入向量: 中心词向量 $\mathbf{v}_w$ (来自矩阵 W) 和上下文向量 $\mathbf{u}_w$ (来自矩阵 W')。解释为什么不能只用一套矩阵: 若只用一套, 训练目标会产生什么退化?

教学注: (b) 与 (c) 的核心是「矩阵乘法由稀疏性退化为行索引」——这是深度学习框架 (PyTorch `nn.Embedding`) 的实现原理, 理解这里就理解了为什么「lookup 层」是深度学习里最轻量的层之一。

陷阱:

- E^T 的大小是 $d \times V$, 乘以 $V \times 1$ 的列向量, 结果是 $d \times 1$, 不要转置错方向
- (d) 的退化不只是「自回归偏差」, 还要说清楚为什么 $\mathbf{v}_w^T \mathbf{v}_w = \|\mathbf{v}_w\|^2$ 会被优化目标异常推高

题 3【中 · 计算 · 余弦相似度的动机与计算】 导读: 为什么不用内积而用余弦相似度? 把「词频让模长偏大」这个直觉量化出来, 答案就清楚了。

设已训练好的嵌入空间中有如下三个词向量（4 维）：

$$\mathbf{v}_{\text{猫}} = (0.6, 0.8, 0.0, 0.0)$$

$$\mathbf{v}_{\text{狗}} = (0.5, 0.7, 0.1, 0.1)$$

$$\mathbf{v}_{\text{the}} = (3.0, 4.0, 0.0, 0.0)$$

（「the」是高频词，模长明显偏大。）

(a) 计算 $\mathbf{v}_{\text{猫}} \cdot \mathbf{v}_{\text{the}}$ 和 $\mathbf{v}_{\text{猫}} \cdot \mathbf{v}_{\text{狗}}$ （原始内积）。

(b) 计算三个向量各自的 L^2 模长 $\|\mathbf{v}\|$ 。

(c) 计算余弦相似度 $\cos(\mathbf{v}_{\text{猫}}, \mathbf{v}_{\text{the}})$ 和 $\cos(\mathbf{v}_{\text{猫}}, \mathbf{v}_{\text{狗}})$ 。

(d) 对比 (a) 和 (c) 的结果：原始内积说「猫更像 the 还是更像狗」？余弦相似度说什么？哪个结论更符合语义直觉？这说明了余弦相似度的什么优势？

教学注：「the」的模长是「猫」的 5 倍（因为高频词在训练中受到更多梯度更新），直接用内积会被模长主导，余弦归一化消掉了这个偏差。这个具体的数值例子是理解 § 2.5 各向异性问题的前置铺垫。

陷阱：

- 计算余弦相似度时分母是两向量模长之**积**，不是**和**
- $\mathbf{v}_{\text{the}}$ 的方向和 $\mathbf{v}_{\text{猫}}$ 完全相同（比例关系）——这是刻意设计的，用以说明方向才是语义信息的载体

题 4【重·概念·分布假设与语义涌现的边界】 导读：词嵌入的语义来自「出现在相同上下文里的词应该相似」——但这个假设有边界，理解边界才能知道嵌入在什么时候是可信的。

(a) Firth (1957) 的分布假设 (Distributional Hypothesis) 的核心陈述是什么？用一句话概括，并说明它如何解释「猫」和「狗」的嵌入向量靠近这一现象。

(b) 下列两个词对，哪一对的余弦相似度更有可能在 Word2Vec 嵌入中偏高？请解释。

- 词对 X：「高兴」vs「快乐」（近义词，上下文高度重叠）
- 词对 Y：「银行 (bank)」vs「河岸 (bank)」(同形词，两种含义的上下文完全不同)

(c) 在静态嵌入 (Word2Vec / GloVe) 中，「bank」只有一个向量。这个向量会「位于」金融语义和河流语义的什么位置？这对下游任务有什么影响？

(d) 上下文相关嵌入 (BERT、GPT) 对这个问题的处理方式有什么根本不同？它在分布假设框架下做了什么样的推广？

教学注：这道题把「分布假设在什么时候成立，在什么时候不成立」讲清楚，是从 § 2.1 的静态嵌入走向 § 2.2 更复杂语义几何的必经之路。多义词的问题 (bank、run、set) 是分布假设的典型失效点，也是上下文相关嵌入的动机所在。

陷阱：

- (b) 中词对 Y 的回答不是「更低」而是要分析具体现象——「bank」的两种用法有不同的上下文，单一向量会成为两者的「平均」，余弦相似度不稳定
- (d) 不要只说「BERT 是动态的」——要说出「同一词在不同句子里产生不同向量」背后的机制（注意力机制对上下文的汇聚）

题5【重·综合·嵌入维度的选择与信息容量权衡】 导读： d 应该多大？这不是一个「越大越好」的问题，而是一个需要在信息容量、稀疏性、计算代价之间权衡的数学决策。

设词表大小 $V = 50000$ ，考虑嵌入维度 $d \in \{64, 256, 512, 4096\}$ 。

(a) 嵌入矩阵 $E \in \mathbb{R}^{V \times d}$ 的参数数量（浮点数个数）分别是多少？当 $d = 512$ 时，仅嵌入矩阵的存储空间（float32，4 字节/参数）是多少 MB？

(b) 从「信息容量」角度看，嵌入维度 d 决定了嵌入空间能「区分」的最大方向数。由 §2.3 的超位置（superposition）结果， d 维空间能存储「几乎正交」方向的数量远超 d ——精确地说约为 $e^{d/8}$ 个。对 $d \in \{64, 256, 512\}$ ，分别计算能存储的近正交方向数（用 $e^?$ 表示，不需计算具体数值）。

(c) 实验中观察到：将 d 从 64 增加到 256 往往带来语义相似度任务的显著提升，但从 256 增加到 512 的提升边际递减。从「词义区分需要的有效维度数」和「实际语言中独立语义特征的数量」两个角度解释这一现象。

(d) 在 Transformer 中，嵌入维度 d 直接影响自注意力的计算复杂度（每层 $O(n^2d)$ ， n 为序列长度）。如果序列长度 $n = 2048$ ，对比 $d = 512$ 和 $d = 4096$ 的每层计算量之比（仅考虑注意力部分）。这说明了什么样的工程权衡？

教学注：这道题把「维度选择」从一个工程经验问题变成了数学权衡问题。嵌入维度的选择同时涉及信息论（ $e^{d/8}$ 的容量上限）、稀疏性（维度越大每个方向越稀疏）和计算复杂度（ $O(n^2d)$ ）三个约束，找到最优的 d 是大模型设计的核心权衡之一。

陷阱：

- (b) 中 $e^{d/8}$ 是超位置的粗略上界，不是精确值——使用时要说「约为」，不要当成等式
- (d) 中注意力复杂度对 d 是线性的，而维度带来的表达能力增益是**对数级**的（约 $e^{d/8}$ 的对数，即 $d/8$ ）——这是为什么工程上不会无限制增大 d 的根本原因

解答 §2.1

T-2.1.1 【one-hot 的两堵墙】 (a) 「猫」编号 1，「狗」编号 2：

$$\mathbf{e}_{\text{猫}} = (1, 0, 0, 0, 0), \quad \mathbf{e}_{\text{狗}} = (0, 1, 0, 0, 0)$$

(b) 所有不同词对的內积均为 0： $\mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{狗}} = 0$ ， $\mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{汽车}} = 0$ 。自身內积： $\mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{猫}} = 1$ 。

(c) 因为 $\mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{狗}} = \mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{汽车}} = 0$ ，两对词的「內积距离」完全相同。这意味着在 one-hot 表示下，「猫和狗的相似度」和「猫和汽车的相似度」数学上无法区分——表示空间中所有不同词对之间没有任何亲疏结构。

(d) one-hot 存储: $V \times V = 50000 \times 50000 = 2.5 \times 10^9$ 比特 (若每个向量独立存储); 或仅需存索引, 即 50000 个整数, 约 0.2 MB。嵌入存储: $V \times d \times 32 = 50000 \times 512 \times 32 = 8.192 \times 10^8$ 比特 = 102.4 MB。若比较「完整 one-hot 矩阵 vs 嵌入矩阵」, 前者 2.5×10^9 bit ≈ 312.5 MB, 嵌入矩阵约 102.4 MB, 比值约 3:1; 但 one-hot 存的信息量 (V^2 bit) 远大于嵌入矩阵 ($V \times d \times 32$ bit), 真正的压缩比约为 $V/(d \times 32) = 50000/16384 \approx 3$ 。

Sanity check: (b) 中所有不同词对内积均为 0, 这是「任意两个不同标准基向量正交」的直接推论, 不需要算——只要看到两向量的非零位置不重叠, 内积就是 0。

T-2.1.2 【嵌入矩阵的查表操作】 (a) $\mathbf{e}_{w_2} = (0, 1, 0, 0)^T$ (第 2 分量为 1, 其余为 0)。

(b) $E^T \mathbf{e}_{w_2}$ 等于取 E^T 的第 2 列, 即 E 的第 2 行:

$$\mathbf{v}_{w_2} = (0.8, -0.3, 0.6)^T$$

(c) 标准矩阵乘法: $E^T \in \mathbb{R}^{3 \times 4}$, 乘 $\mathbf{e}_{w_2} \in \mathbb{R}^4$, 需要 $3 \times 4 = 12$ 次乘加操作 (一般化后是 $d \times V$)。直接取行: 仅 $d = 3$ 次复制操作。对 $V = 50000$, $d = 512$: 矩阵乘法 $\approx 512 \times 50000 = 2.56 \times 10^7$ 次; 取行操作 512 次, 加速比约 5×10^4 倍。

(d) 若只用一套矩阵, 则词 w 预测自身的得分为 $\mathbf{v}_w^T \mathbf{v}_w = \|\mathbf{v}_w\|^2$, 它总是非负且随训练增大 (模长在训练中通常增大)。这意味着优化目标会把每个词预测自己的得分推得最高——而「预测自己」在 Skip-gram 中是无意义的 (窗口内不包含自身), 这会导致所有词向量在训练中被「自吸引」地推向同一方向, 形成退化解。

Sanity check: (b) 的结果与直接读 E 第 2 行 $((0.8, -0.3, 0.6))$ 完全一致, 验证了「one-hot 乘法等价于取行」的命题。

T-2.1.3 【余弦相似度的动机与计算】 (a) 内积计算:

$$\mathbf{v}_{\text{猫}} \cdot \mathbf{v}_{\text{the}} = 0.6 \times 3.0 + 0.8 \times 4.0 + 0 + 0 = 1.8 + 3.2 = 5.0$$

$$\mathbf{v}_{\text{猫}} \cdot \mathbf{v}_{\text{狗}} = 0.6 \times 0.5 + 0.8 \times 0.7 + 0 \times 0.1 + 0 \times 0.1 = 0.3 + 0.56 = 0.86$$

(b) 模长:

$$\|\mathbf{v}_{\text{猫}}\| = \sqrt{0.36 + 0.64} = \sqrt{1.0} = 1.0$$

$$\|\mathbf{v}_{\text{the}}\| = \sqrt{9.0 + 16.0} = \sqrt{25.0} = 5.0$$

$$\|\mathbf{v}_{\text{狗}}\| = \sqrt{0.25 + 0.49 + 0.01 + 0.01} = \sqrt{0.76} \approx 0.8718$$

(c) 余弦相似度:

$$\cos(\mathbf{v}_{\text{猫}}, \mathbf{v}_{\text{the}}) = \frac{5.0}{1.0 \times 5.0} = 1.0000$$

$$\cos(\mathbf{v}_{\text{猫}}, \mathbf{v}_{\text{狗}}) = \frac{0.86}{1.0 \times 0.8718} \approx 0.9865$$

(d) 原始内积 (5.0 vs 0.86): 「猫更像 the」。余弦相似度 (1.0 vs 0.987): 「猫和 the 方向完全相同 (余弦 = 1), 猫和狗方向非常接近 (余弦 ≈ 0.99)」。从语义上, 猫和狗的相似度应该更高 (同类动物), 而猫和 the 没有语义关联。余弦相似度正确地消除了 the 的高频带来的模长偏置, 展示了语义方向的实际距离。

Sanity check: 注意到 $\mathbf{v}_{\text{the}} = 5 \cdot (0.6, 0.8, 0, 0) = 5\mathbf{v}_{\text{猫}}$ (方向完全相同, 模长是 5 倍), 因此余弦值精确为 1.0, 无需近似计算。

T-2.1.4 【分布假设与语义涌现的边界】 (a) Firth (1957) 分布假设: 「一个词的意义由其所出现的语言环境决定」(You shall know a word by the company it keeps)。对「猫」和「狗」: 两者都高频出现在「宠物」「毛茸茸的」「喂食」「叫」「跑」等相似上下文中, 训练目标 (预测上下文词) 会把两者向量同时朝相同的上下文词方向拉近, 最终在 $\mathbb{R}^d$ 中靠拢。

(b) 词对 X (「高兴」vs「快乐」) 的余弦相似度更高, 因为两词上下文高度重叠。词对 Y (bank 的两个义项) 中, 金融语义的「bank」(出现在「账户」「利率」「存款」周围) 与河流语义的「bank」(出现在「水流」「河床」「泥土」周围) 上下文完全不同, 两者会被训练拉向不同方向——但它们共享同一个词形, 只有一个向量, 最终向量是两种语义的某种「加权平均」, 与两种语义的单义同类词相比余弦相似度均较低且不稳定。

(c) 静态嵌入中「bank」只有一个向量, 位于金融含义聚类和河流含义聚类的**中间地带** (由语料中两种用法的相对频率加权)。下游任务影响: 情感分析、词义消歧等任务中, 模型无法判断当前语境下「bank」是哪种含义, 会系统性地引入噪声。解决方案是使用上下文相关嵌入。

(d) 上下文相关嵌入 (BERT/GPT) 的根本不同: **同一词在不同句子中产生不同的嵌入向量**, 由注意力机制根据当前句子上下文动态计算。这是分布假设的动态推广——不是「词的全局上下文分布决定固定向量」, 而是「当前句子的局部上下文决定当前的向量位置」。每次前向传播都重新计算当前 token 应该位于嵌入空间的哪个点。

Sanity check: (b) 的答案可以通过反证验证——如果「bank」两种义项的上下文没有任何重叠, 那么在理想情况下, 同形词「bank」的单一向量与任何单义词相比余弦相似度都不高; 这符合「同形词嵌入语义模糊」的实验观察。

T-2.1.5 【嵌入维度的选择与信息容量权衡】 (a) 参数数量 = $V \times d$:

d	参数数	存储 (MB, float32)
64	3.2×10^6	12.8 MB
256	1.28×10^7	51.2 MB
512	2.56×10^7	102.4 MB
4096	2.048×10^8	819.2 MB

(b) 超位置能存储的近正交方向数 $\approx e^{d/8}$:

$$\cdot d = 64: e^8 \approx 3.0 \times 10^3$$

- $d = 256: e^{32} \approx 7.9 \times 10^{13}$
- $d = 512: e^{64} \approx 6.2 \times 10^{27}$

(c) 实际英语语义中，独立的「基本语义维度」（如「生命/非生命」「具体/抽象」「情感极性」「句法类别」等）估计不超过数千个。 $d = 64$ 时超位置容量约 3000，接近这一上限； $d = 256$ 时容量远超实际需求，因此提升边际递减。从另一角度： $d = 256$ 时每个方向对应约 $50000/256 \approx 196$ 个词「分享」该维度，足够稀疏；继续增大 d 带来的「每维度词数更少」的好处越来越小，而参数量线性增大。

(d) 注意力复杂度 $O(n^2d)$ 对 d 线性，比值 $= 4096/512 = 8$ 。即 $d = 4096$ 时每层注意力计算量是 $d = 512$ 的 8 倍，但表达能力（超位置容量的对数）从 64 增加到 512（约 8 倍），**计算代价和收益均线性相关于 d** 。这说明：在注意力主导的计算预算下，增大 d 带来的信息容量增益是线性的，但对序列长度 n 的适应能力（ $O(n^2)$ 项）不随 d 变化——若想用更长的上下文，增大 n 的代价（平方级）比增大 d （线性级）严峻得多。

Sanity check: (a) 中 $d = 512$ 时嵌入矩阵约 100 MB，对于一个总参数量约 7B（28 GB float32）的大模型，嵌入矩阵约占 0.4%，属于可接受范围。 $d = 4096$ 时嵌入矩阵约 800 MB，约占 3%，仍可接受，与业界 LLaMA/GPT-4 等模型的配置一致。

§2.1 小结：从 one-hot 正交性失效（题 1），到嵌入矩阵的 $O(d)$ 查表（题 2），到余弦相似度消除模长偏置（题 3），到分布假设的成立与失效边界（题 4），到维度选择的三方权衡（题 5）——这五道题拼出了词嵌入从「为什么需要」到「如何实现」再到「有什么边界」的完整逻辑链。下一节 §2.2 的「国王 - 男人 + 女人 $\approx$ 女王」正是在这个基础上，把训练机制和几何涌现联系起来。

§2.2 语义的坐标系：词嵌入与类比向量

本节依次建立四个核心工具：余弦相似度量语义方向；Skip-gram 条件概率（softmax 形式）定义训练目标；负采样目标函数把全局归一化降为局部对比；类比向量等式揭示嵌入几何的线性结构与边界。每个公式后立刻练习，再往下走。

公式 1 · 余弦相似度

$$\cos(u, v) = \frac{u^T v}{\|u\| \|v\|} = \frac{\sum_{i=1}^d u_i v_i}{\sqrt{\sum_{i=1}^d u_i^2} \cdot \sqrt{\sum_{i=1}^d v_i^2}}$$

余弦相似度值域为 $[-1, 1]$ ，仅衡量方向差异，与向量模长无关。

一句话直觉：用归一化内积消除模长噪声，把语义方向差异压缩为一个标量。

T-2.2.1 【易 · 代入 · 余弦相似度基础计算】 设两词向量（3 维）：

$$u = (1, 2, 3)^T, \quad v = (2, 0, -1)^T$$

- 计算 $\|u\|$ 、 $\|v\|$ 以及内积 $u^T v$ （保留 4 位小数）；
- 计算 $\cos(u, v)$ ，并判断这两个词是语义相似、相反，还是无关；

- (c) 若将 v 替换为 $v' = (2, 4, 6)^T$ (u 的 2 倍), 余弦相似度变成多少? 用一句话解释余弦相似度对向量缩放的不变性。

T-2.2.2 【中 · 工程 · 余弦 vs 欧氏: LLM 嵌入的实战选择】 某批次中, 两个词的嵌入向量 (已用 L2 范数计算):

$$e_{\text{cat}} = (3.0, 4.0)^T, \quad e_{\text{dog}} = (0.6, 0.8)^T$$

(2 维仅为示意, 实际维度 $d \sim 768$ 。)

- 计算欧氏距离 $\|e_{\text{cat}} - e_{\text{dog}}\|$ 和余弦相似度 $\cos(e_{\text{cat}}, e_{\text{dog}})$;
- 欧氏距离显示两词“相距较远”, 但余弦相似度为 1.0。这一矛盾说明什么? 在 LLM 的嵌入层中, 高频词 (如 “the”) 的嵌入向量模长往往系统偏大, 为什么用欧氏距离会把“词频差异”误读为“语义差异”?
- 结论: 在向量检索 (RAG / semantic search) 中, 为什么标准做法是先归一化向量再做内积 (等价于余弦相似度), 而不是直接用 L2 距离?

T-2.2.3 【中 · 判错 · 余弦相似度是“距离”?】 有人说: “余弦相似度 $\cos(u, v) \in [-1, 1]$ 是一种距离度量, 满足距离公理 (非负性、对称性、三角不等式)。”

- 这句话哪里错了? 从度量 (metric) 的四条公理逐一检验 $1 - \cos(u, v)$ (余弦距离) 是否满足三角不等式, 给出反例;
- 构造三个向量 $a, b, c \in \mathbb{R}^2$, 使得余弦距离违反三角不等式: $(1 - \cos(a, c)) > (1 - \cos(a, b)) + (1 - \cos(b, c))$;
- 尽管如此, 余弦相似度在实践中仍被广泛用于语义检索, 原因是什么? (提示: 工程需要的是相对排序, 不需要满足度量公理。)

公式 2 · Skip-gram 条件概率 (softmax 形式)

$$P(c | w) = \frac{\exp(u_c^T v_w)}{\sum_{c'=1}^V \exp(u_{c'}^T v_w)}$$

中心词向量 v_w , 上下文词向量 u_c ; 分母对全词表 V 求和, 计算开销 $O(V)$ 。

一句话直觉: 用两套向量的内积打分, 经 softmax 转化为预测上下文词的概率。

T-2.2.4 【易 · 代入 · softmax 归一化计算】 设词表 $V = \{w_1, w_2, w_3, w_4\}$, 中心词 w 与四个上下文词向量的内积为:

$$s_1 = 2.0, \quad s_2 = 0.5, \quad s_3 = -1.0, \quad s_4 = 1.0$$

- 用 softmax 公式计算 $P(w_i | w)$ ($i = 1, 2, 3, 4$), 保留 4 位小数;
- 引入温度参数 τ , 将分数改为 s_i/τ 。分别取 $\tau = 0.5$ 和 $\tau = 2.0$ 重算分布, 描述分布形状的变化;

- (c) 若 $|V| = 50000$ ，每次前向传播需多少次乘法？负采样 $k = 5$ 时需多少？给出加速比数量级。

T-2.2.5【中·变形·Skip-gram 目标函数展开】 Skip-gram 对长度为 T 的语料、窗口大小 L 的完整目标函数为：

$$\mathcal{L}_{\text{SG}} = \frac{1}{T} \sum_{t=1}^T \sum_{\substack{-L \leq j \leq L \\ j \neq 0}} \log P(w_{t+j} | w_t)$$

- (a) 对固定的中心词 w_t ，展开 $\log P(c | w_t)$ ，写出其对 v_{w_t} 的梯度 $\partial \log P(c | w_t) / \partial v_{w_t}$ （提示：softmax 的梯度形式为 $(u_c - \sum_{c'} P(c' | w_t) u_{c'})$ ）；
 (b) 该梯度中每一步需要计算 $\sum_{c'} P(c' | w_t) u_{c'}$ （所有词的加权和）。在 $V = 50000$ 时，每次梯度步的复杂度是多少？这说明了负采样的必要性。

公式 3 · 负采样目标函数

$$\mathcal{L}_{\text{NEG}} = \log \sigma(u_c^T v_w) + \sum_{i=1}^k \mathbb{E}_{c'_i \sim P_n} [\log \sigma(-u_{c'_i}^T v_w)]$$

其中 $\sigma(x) = 1/(1 + e^{-x})$ ，噪声分布 $P_n(c) \propto f(c)^{3/4}$ ， $k \in [5, 20]$ 。

一句话直觉：用“真实上下文 vs 随机噪声”的局部二分类替代代价高昂的全局 softmax，复杂度从 $O(V)$ 降至 $O(k)$ 。

T-2.2.6【易·代入·负采样频率惩罚 $f^{3/4}$ 】 设词表中三个词的词频：

词	词频 f
“the”	10000
“cat”	200
“xylophone”	4

- (a) 按 $P_n(c) \propto f(c)^{3/4}$ 计算三者的采样权重（给出比例，无需归一化）；
 (b) 按原始词频 $P \propto f$ 计算比例；
 (c) 比较 (a)(b)：3/4 次幂对高频词做了什么，对低频词又做了什么？这对词嵌入质量有什么好处？

T-2.2.7【难·证明·负采样梯度分解为“拉近+推远”】 对单条训练样本（仅考虑一个负样本 $k = 1$ ）：

$$\ell = \log \sigma(u_c^T v_w) + \log \sigma(-u_{c'}^T v_w)$$

- (a) 写出 $\sigma'(x) = \sigma(x)(1 - \sigma(x))$ ；

- (b) 用链式法则求 $\partial \log \sigma(u_c^T v_w) / \partial v_w$;
- (c) 用链式法则求 $\partial \log \sigma(-u_c^T v_w) / \partial v_w$ (注意符号);
- (d) 合并 (b)(c) 的结果, 写成”拉近正样本方向 + 推离负样本方向”的形式, 并解释为什么反复叠加这两个力最终产生语义几何。

公式 4 · 类比向量等式

$$v_{\text{king}} - v_{\text{man}} + v_{\text{woman}} \approx v_{\text{queen}}$$

等价形式: $v_{\text{king}} - v_{\text{queen}} \approx v_{\text{man}} - v_{\text{woman}} = \delta_{\text{gender}}$, 即性别关系对应空间中一个近似固定的方向向量。

一句话直觉: 语义关系 (如性别、时态、国籍) 在嵌入空间中近似对应平行且等长的方向向量, 使向量加减能类比推理。

T-2.2.8【易·代入·类比向量计算】 设下列 4 维词向量 (数值仅供计算):

$$v_{\text{man}} = (0.8, 0.3, 0.1, 0.0)^T, \quad v_{\text{woman}} = (0.8, -0.3, 0.1, 0.0)^T$$

$$v_{\text{king}} = (0.5, 0.4, 0.9, 0.8)^T, \quad v_{\text{queen}} = (0.5, -0.4, 0.9, 0.8)^T$$

- (a) 计算性别差向量 $\delta = v_{\text{man}} - v_{\text{woman}}$;
- (b) 计算类比预测向量 $\hat{q} = v_{\text{king}} - v_{\text{man}} + v_{\text{woman}}$;
- (c) 计算 $\cos(\hat{q}, v_{\text{queen}})$ (保留 4 位小数), 体会”约等于”的实际精度;
- (d) 计算 $\cos(\hat{q}, v_{\text{king}})$, 说明为什么类比搜索时必须排除查询词自身。

T-2.2.9【中·反例·类比等式的失效场景】 Word2Vec 论文报告的类比准确率约 60–70%。考虑两对类比:

- 性别类比: $\text{man} \rightarrow \text{woman}, \text{king} \rightarrow \text{queen}$
- 首都类比: $\text{China} \rightarrow \text{Beijing}, \text{USA} \rightarrow \text{Washington D.C.}$

- (a) 性别轴的”平移等变性”依赖什么语料条件? (提示: 上下文对称性)
- (b) 考虑到”Washington”既是首都又是人名 (George Washington), 类比向量 $v_{\text{USA}} - v_{\text{China}} + v_{\text{Beijing}}$ 的最近邻很可能不是”Washington”。给出一个具体的语料统计原因 (要说清楚是什么共现模式导致的, 不要抽象回答”歧义”);
- (c) 在 BERT 或 LLaMA 的上下文嵌入中, ”Washington”在不同句子里有不同向量。说明这如何从根本上改变类比向量等式的有效性。

§ 2.3 高维几何的诡异世界

本节建立高维空间的三个反直觉现象: 球壳质量集中 (随机高斯向量的模长几乎是常数); 随机向量近似正交 (高维内积分布趋于零); Johnson-Lindenstrauss 引理 (降维

只需 $O(\log n/\varepsilon^2)$ 维，与原始维度 D 无关)。这三者共同构成超位置 (superposition)、向量检索 (FAISS) 可行性的数学基础。

公式 5 · 球壳质量集中

$$\mathbb{E}[\|x\|^2] = d, \quad \text{Var}[\|x\|^2] = 2d$$

集中不等式：对任意 $\varepsilon > 0$,

$$P(|\|x\| - \sqrt{d}| > \varepsilon) \leq 2 \exp\left(-\frac{\varepsilon^2}{4}\right)$$

其中 $x = (x_1, \dots, x_d)^T$, 各分量 $x_i \sim \mathcal{N}(0, 1)$ 独立同分布。

一句话直觉：高维高斯向量的模长以极高概率集中在 $\sqrt{d}$ 附近，球的”内部”几乎是空的。

T-2.3.1 【易 · 代入 · 模长集中数值】 设 $x \in \mathbb{R}^d$ 各分量独立同分布 $\sim \mathcal{N}(0, 1)$ 。

- 用 $\mathbb{E}[\|x\|] \approx \sqrt{d}$ 近似，给出 $d = 4, 100, 768, 12288$ 时的期望模长；
- 模长的标准差 $\text{std}[\|x\|] \approx 1/\sqrt{2}$ (由 $\text{Var}[\|x\|^2] = 2d$ 和 Delta 方法近似得到)。给出上述四个维度下的相对标准差 $\text{std}[\|x\|]/\mathbb{E}[\|x\|]$ ；
- 为什么模长的相对波动随维度增加而减小？这对词嵌入归一化的实践含义是什么？(提示：余弦 vs 欧氏)

T-2.3.2 【中 · 参数变形 · 超位置容量上界】 超位置 (superposition)：如果 d 维向量空间允许”几乎正交”的方向数远超 d ，则可以用少量维度”叠放”大量特征。

- 由随机高斯向量的余弦标准差 $\approx 1/\sqrt{d}$ ，若要使任意两向量以 99% 概率满足 $|\cos| < \varepsilon$ ，需要 $\varepsilon \approx 2.576/\sqrt{d}$ ($2.576 = z_{0.005}$)。对 $d = 768$ ，计算这个 ε ；
- 在 $d = 100$ 维空间中， $\varepsilon = 0.2$ ， $P(|\cos| > 0.2) \approx 0.0455$ (正态近似)。设有 n 个向量，共 $\binom{n}{2}$ 对，用 Union bound 估算最大可容纳的 n ；
- 将 (b) 的结果与 Welch bound (d 维空间最多 $\sqrt{d(d+2)/3} \approx 3400$ 个互相 $|\cos| \leq 1/\sqrt{d}$ 的向量) 对比。稀疏自编码器在 100 维激活向量中找到超过 100 个独立特征方向，在理论上是否可能？

T-2.3.3 【难 · 证明 · 集中不等式蕴含球壳现象】 设 $x \in \mathbb{R}^d$, $x_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$ 。

- 写出 $\|x\|^2 = \sum_{i=1}^d x_i^2$ 的期望和方差，说明它服从 $\chi^2(d)$ ；
- 对 $d = 1000$ ，利用集中不等式 $P(|\|x\| - \sqrt{d}| > \varepsilon) \leq 2e^{-\varepsilon^2/4}$ ，取 $\varepsilon = 10$ (偏离 $\sqrt{1000} \approx 31.6$ 约 32%)，计算概率上界；
- 结合 (b) 的数值，解释为什么说”高维高斯向量几乎全部落在薄球壳内，球的内部几乎是空的”。这一现象对词嵌入的初始化策略 (如 $\mathcal{N}(0, 1/d)$) 有什么启示？

公式 6 · 高维内积分布

$$\frac{x^T y}{\sqrt{d}} \xrightarrow{d \rightarrow \infty} \mathcal{N}(0, 1)$$

即 $x^T y \sim \mathcal{N}(0, d)$ ，从而余弦相似度：

$$\cos(x, y) = \frac{x^T y}{\|x\| \|y\|} \approx \mathcal{N}\left(0, \frac{1}{d}\right) \xrightarrow{d \rightarrow \infty} 0$$

其中 $x, y \in \mathbb{R}^d$ 独立同分布 $\mathcal{N}(0, I_d)$ 。

一句话直觉：随机高维向量几乎正交，高维空间能容纳指数级多的“几乎正交”方向——这是超位置现象的数学基础。

T-2.3.4 【易 · 代入 · 内积分布与近似正交化】 设 $x, y \in \mathbb{R}^d$ 独立同分布 $\mathcal{N}(0, I_d)$ 。

- 计算 $x^T y$ 的期望和方差，说明其服从 $\mathcal{N}(0, d)$ 的理由（一句话，提示中心极限定理）；
- 当 $d = 1000$ 时，余弦相似度 $\cos(x, y)$ 的标准差约为 $1/\sqrt{d}$ 。计算具体数值，并给出 95% 置信区间 ($\pm 1.96\sigma$)；
- 设“近似正交”的判断标准是 $|\cos| < 0.1$ 。当 $d = 1000$ 时，随机选取两个高斯向量落入“近似正交”区域的概率是多少？（用正态分布的标准差倍数估算）

T-2.3.5 【中 · 画图直觉 · 余弦分布随维度变化】 请在下方草稿区粗略画出余弦相似度分布 $\cos(x, y) \sim \mathcal{N}(0, 1/d)$ 在以下三个维度的概率密度曲线（同一坐标轴，横轴为余弦值 $[-1, 1]$ ，纵轴为密度）：

- $d = 2$ ：标准差 ≈ 0.707 ，分布很宽
- $d = 100$ ：标准差 ≈ 0.1
- $d = 1000$ ：标准差 ≈ 0.032 ，分布极为尖锐

画完后用两句话回答：为什么高维空间能“容纳指数级多的几乎正交方向”？这一性质如何解释 Transformer 的 superposition 现象（激活向量同时编码多个特征）？

公式 7 · Johnson-Lindenstrauss 引理

$$k = O\left(\frac{\log n}{\varepsilon^2}\right)$$

使得存在线性映射 $f: \mathbb{R}^D \rightarrow \mathbb{R}^k$ ，对所有 n 个点的点对 (i, j) ：

$$(1 - \varepsilon)\|x_i - x_j\|^2 \leq \|f(x_i) - f(x_j)\|^2 \leq (1 + \varepsilon)\|x_i - x_j\|^2$$

构造：随机高斯矩阵 $\Phi \in \mathbb{R}^{k \times D}$ ，各元素独立 $\sim \mathcal{N}(0, 1/k)$ ，以高概率满足上述保距性质。

一句话直觉：降维所需目标维度仅与点的数量对数相关，与原始维度 D 无关——这是 RAG 向量检索可行的理论保证。

T-2.3.6 【易·代入·JL 降维实例计算】 某向量数据库存储 $n = 10000$ 个 $D = 1024$ 维词向量，要在 $\varepsilon = 0.1$ （10% 距离误差）、置信度 ≥ 0.99 （即 $\delta = 0.01$ ）下近似降维。

- 用公式 $k \geq \frac{16 \ln n - 8 \ln \delta}{\varepsilon^2}$ 计算目标维度 k 的理论下界（保留整数）；
- 计算理论值 k 与 $D = 1024$ 的压缩比 D/k ，并解释为什么理论下界往往比工程实践值（ $k = 256$ ）大很多（Union bound 保守性）；
- 实践中取 $k = 256$ （远小于理论下界），这是在牺牲什么换取什么？（精度-速度-存储三角权衡）

T-2.3.7 【难·证明·JL 引理目标维度推导】 目标维度 $k = O(\log n / \varepsilon^2)$ 来自以下逻辑链，请逐步完成：

- 设随机矩阵 $\Phi \in \mathbb{R}^{k \times D}$ 各元素独立 $\sim \mathcal{N}(0, 1/k)$ 。对固定向量 $z = x_i - x_j$ ，计算 $\mathbb{E}[\|\Phi z\|^2]$ （提示： $\mathbb{E}[(\Phi z)_\ell^2] = \|z\|^2/k$ ，对 k 个分量求和）；
- $\|\Phi z\|^2 / \|z\|^2 \sim \chi^2(k)/k$ （简述理由）。利用集中不等式 $P(|\chi^2(k)/k - 1| > \varepsilon) \leq 2e^{-k\varepsilon^2/8}$ ，给出单对点距离失真超 ε 的概率上界；
- 共 $\binom{n}{2}$ 对点。用 Union bound 推导使所有点对以概率 $\geq 1 - \delta$ 满足 $(1 \pm \varepsilon)$ 近似的 k 下界，验证 $k = O(\log n / \varepsilon^2)$ ；
- 结合以上，说明 k 与原始维度 D 无关的含义：在 RAG 系统中，检索精度由文档数量和精度要求决定，与嵌入向量的原始维度无关。实践中 512 维已足够应付百万级文档的 ANN 搜索。

T-2.3.8 【中·判错·维度越高检索越准确？】 有人说：“RAG 系统中嵌入维度越高越好，因为维度越高信息越丰富，检索准确率必然更高。”

- 指出这句话的两处错误：（1）从 JL 引理的角度——所需检索维度与原始嵌入维度 D 的关系；（2）从维度诅咒的角度——高维空间中欧氏最近邻的退化现象；
- 在 $d = 1000$ 维下，两随机单位向量的欧氏距离期望约 $\sqrt{2} \approx 1.414$ ，标准差约 0.022。最近邻和最远邻之间距离差约几个标准差？这说明了什么？
- 维度从 1024 降到 256 在工程中的实际权衡是什么？（提示：存储、速度、精度三角）

§2.4 习题：跨界映射——从罗马路网到曼哈顿距离

导读：本节核心是把「距离」的概念从欧氏 L^2 范数扩展到 L^p 范数族和加权内积（马氏距离），展示不同度量选择背后的「惩罚哲学」差异，最终说明词嵌入空间的「自然度量」是加权内积而非普通内积。五题分别对应： L^p 范数族的计算与单位球几何、平行四边形恒等式作为内积范数的充要条件、马氏距离的计算与白化解释、度量选择对最近邻结果的影响、从工程应用角度判断何时用哪种度量。

题1【轻·计算· L^p 范数族与单位球几何】 导读：三种范数的公式相差一个参数 p ，但对应的几何形状截然不同——把这个差异从数字算出来而不是从图里看。

设二维向量 $\mathbf{x} = (3, 4)$ 。

(a) 分别计算 $\|\mathbf{x}\|_1$ (曼哈顿距离)、 $\|\mathbf{x}\|_2$ (欧氏范数)、 $\|\mathbf{x}\|_\infty$ (Chebyshev 范数)。

(b) 写出 $\mathbb{R}^2$ 中三种范数的「单位球」(即到原点距离恰好为 1 的点的集合) 的几何描述： L^1 是什么形状， L^2 是什么形状， L^∞ 是什么形状？

(c) 对于向量 $\mathbf{y} = (0.6, 0.8)$ ，验证 $\|\mathbf{y}\|_1 > \|\mathbf{y}\|_2 > \|\mathbf{y}\|_\infty$ (即三种范数的大小顺序)，并证明这个不等式对所有非零向量 $\mathbf{x} \in \mathbb{R}^d$ 均成立 (不要求严格证明，给出数量级论证即可)。

(d) 在机器学习中，正则化项的选择 (L^1 vs L^2) 会导致不同的稀疏性行为。解释为什么 L^1 正则化 (LASSO) 倾向于产生稀疏解，而 L^2 正则化 (Ridge) 倾向于让参数均匀收缩——从「单位球的几何形状」角度给出几何直觉。

教学注：(d) 是把「单位球的几何形状」从可视化工具变成理解 LASSO/Ridge 的钥匙。这个直觉在后面理解稀疏自编码器 (SAE) 和白化变换时也会再次出现。

陷阱：

- 不要搞错 L^1 和 L^∞ 的大小关系—— L^1 对所有分量绝对值求和， L^∞ 取最大值，对 $d > 1$ 的非零向量有 $\|\mathbf{x}\|_1 \geq \|\mathbf{x}\|_\infty$
- (b) 中 L^∞ 的单位球是正方形，不是旋转 45° 的正方形 (那是 L^1)

题2【中·推导·平行四边形恒等式与内积范数】 导读：能从内积诱导出来的范数，与仅仅满足三角不等式的范数，差在哪里？一条恒等式把这面墙画出来。

(a) 设内积空间 $(V, \langle \cdot, \cdot \rangle)$ ，令 $\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle}$ 。证明平行四边形恒等式：

$$\|\mathbf{u} + \mathbf{v}\|^2 + \|\mathbf{u} - \mathbf{v}\|^2 = 2\|\mathbf{u}\|^2 + 2\|\mathbf{v}\|^2$$

(提示：展开 $\langle \mathbf{u} \pm \mathbf{v}, \mathbf{u} \pm \mathbf{v} \rangle$ ，用内积的双线性和对称性。)

(b) 验证 L^1 范数不满足平行四边形恒等式：取 $\mathbf{u} = (1, 0)$ ， $\mathbf{v} = (0, 1)$ ，计算左侧和右侧的值。

(c) 由 (a) 和 (b) 可知： L^2 范数来自内积， L^1 范数不来自内积。这对词嵌入有什么实际含义？具体地，以下哪些操作在 L^1 空间里没有合法定义，但在 L^2 (欧氏内积) 空间里有？- 余弦相似度 - 向量在某方向上的投影 ($\mathbf{u} \cdot \hat{\mathbf{v}} = \|\mathbf{u}\| \cos \theta$) - 自注意力机制的点积 $\mathbf{q}^T \mathbf{k}$

(d) 「满足平行四边形恒等式」是「范数来自内积」的充要条件 (Jordan-von Neumann 定理)。这意味着：如果我们希望词嵌入空间保留「夹角、投影、正交分解」这些工具，就必须工作在 (某个) 内积空间里。写出加权内积 $\langle \mathbf{u}, \mathbf{v} \rangle_G = \mathbf{u}^T G \mathbf{v}$ ($G \succ 0$) 诱导的范数和距离公式。

教学注：这道题把内积空间和度量空间的区分从「概念」变成「可验证的代数判断」。Jordan-von Neumann 定理告诉我们：余弦相似度能用，不是因为「方便」，而是因为背后有内积结构——如果用 L^1 ，连余弦的定义都没有。

陷阱：

- (a) 中要用内积双线性性展开，不要用坐标暴力计算（那只验证了特例，不是证明）
- (c) 中点积 $\mathbf{q}^T \mathbf{k}$ 本身只是一个数值运算，不依赖空间结构——真正的问题是「这个点积能否被解释为「夹角余弦 $\times$ 模长乘积」，即内积空间结构」

题 3【中·计算·马氏距离与白化的几何解释】 导读：马氏距离的真正意义是「先白化，再算欧氏距离」——把这条等价关系从公式里算出来。

设二维嵌入空间中有三个词向量（已去均值）：

$$\mathbf{v}_A = (2, 1), \quad \mathbf{v}_B = (1, 3), \quad \mathbf{v}_C = (2, 4)$$

嵌入集合的协方差矩阵估计为：

$$\Sigma = \begin{pmatrix} 4 & 1 \\ 1 & 1 \end{pmatrix}$$

(a) 计算欧氏距离 $d_2(\mathbf{v}_A, \mathbf{v}_B)$ 和 $d_2(\mathbf{v}_A, \mathbf{v}_C)$ 。按欧氏距离， A 更靠近 B 还是 C ？

(b) 计算 $G = \Sigma^{-1}$ （马氏距离的度量矩阵）。提示：对 2×2 矩阵 $\begin{pmatrix} a & b \\ c & d \end{pmatrix}$ ，逆为 $\frac{1}{ad-bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$ 。

(c) 计算马氏距离 $d_G(\mathbf{v}_A, \mathbf{v}_B) = \sqrt{(\mathbf{v}_A - \mathbf{v}_B)^T G (\mathbf{v}_A - \mathbf{v}_B)}$ 和 $d_G(\mathbf{v}_A, \mathbf{v}_C)$ 。按马氏距离， A 更靠近 B 还是 C ？

(d) 协方差矩阵 Σ 的对角线元素 $\Sigma_{11} = 4 \gg \Sigma_{22} = 1$ ，意味着第 1 维方差远大于第 2 维。解释为什么欧氏距离在这种情形下被第 1 维「主导」，而马氏距离通过 Σ^{-1} 消除了这种主导效应。

教学注：(a) 和 (c) 对比的意义：欧氏距离说「 A 更近 B （或 C ）」，马氏距离可能给出相反结论——这不是哪个「错了」，而是两者代表不同的假设。欧氏距离假设各方向等权；马氏距离假设高方差方向上的同等位移代表更小的语义差异（因为该方向上的随机波动本来就大）。

陷阱：

- (b) 中需要先算行列式 $\det(\Sigma) = 4 \times 1 - 1 \times 1 = 3$ ，不是 $4 - 1 = 3$ 的直觉省略版，要写清楚
- (c) 中 d_G 是带根号的，不要漏算

题4【重·综合·度量选择对最近邻结果的影响】 导读：「用什么度量」不只是数学问题，而是直接决定了下游任务（语义搜索、文档检索）的结果。

设5维词嵌入空间中有如下4个词向量（已给出归一化版本和原始版本）：

$$\mathbf{v}_{\text{苹果}} = (0.9, 0.1, 0.2, 0.0, 0.1), \quad \|\mathbf{v}_{\text{苹果}}\| \approx 0.937$$

$$\mathbf{v}_{\text{香蕉}} = (0.8, 0.2, 0.1, 0.1, 0.1), \quad \|\mathbf{v}_{\text{香蕉}}\| \approx 0.837$$

$$\mathbf{v}_{\text{the}} = (4.5, 0.5, 1.0, 0.0, 0.5), \quad \|\mathbf{v}_{\text{the}}\| \approx 4.685$$

$$\mathbf{v}_{\text{科技}} = (0.1, 0.9, 0.8, 0.7, 0.2), \quad \|\mathbf{v}_{\text{科技}}\| \approx 1.350$$

以「苹果」为查询词，分别用以下三种度量找最近邻（从其余3个词中选）：

(a) 欧氏距离 L^2 ：对每对词计算 $\|\mathbf{v}_{\text{苹果}} - \mathbf{v}_?\|_2$ ，给出距离最小的词。（可以只比较平方距离，省略开根号。）

(b) 余弦相似度：对每对词计算 $\cos(\mathbf{v}_{\text{苹果}}, \mathbf{v}_?)$ ，给出余弦值最大的词。

(c) 曼哈顿距离 L^1 ：对每对词计算 $\|\mathbf{v}_{\text{苹果}} - \mathbf{v}_?\|_1$ ，给出距离最小的词。

(d) 三种度量给出的最近邻相同吗？如果不同，分析原因。从语义合理性角度，哪种度量的结果最符合「苹果和香蕉都是水果」的直觉？

(e) 在向量数据库（如 FAISS）中，默认的相似度函数通常是**内积或余弦相似度**而非 L^1 距离。结合 (d) 的分析和题2中关于内积空间的讨论，给出一个理论层面的理由。

教学注：这道题的核心是让「度量选择的影响」不停留在抽象讨论层面，而是通过具体数字感受「高频词 the 的模长偏大如何污染欧氏和 L^1 距离，而余弦归一化如何消除这种污染」。这是 §2.5 各向异性讨论的量化预演。

陷阱：

- (a) 的平方距离： $\|\mathbf{v}_{\text{苹果}} - \mathbf{v}_{\text{the}}\|_2^2$ 中，「the」每个分量都远大于「苹果」，差值很大，不要低估
- (b) 中 $\mathbf{v}_{\text{the}}$ 的方向 $((4.5, 0.5, 1.0, 0, 0.5)/4.685 \approx (0.96, 0.11, 0.21, 0, 0.11))$ 与 $\mathbf{v}_{\text{苹果}}$ 的归一化方向 $((0.9, 0.1, 0.2, 0, 0.1)/0.937 \approx (0.96, 0.11, 0.21, 0, 0.11))$ 几乎一致——这是设计的，用以说明高频词方向问题

题5【重·评判·何时用哪种度量】 导读：没有一种度量是普适最优的——正确的选择来自「该度量的假设与数据结构是否匹配」。把这个判断从直觉变成可操作的标准。

阅读以下五个工程场景，为每个场景选择最合适的度量（ L^2 欧氏距离、 L^1 曼哈顿距离、 L^∞ Chebyshev 距离、余弦相似度、马氏距离），并说明理由。

场景 A：语义文档检索——给定一段查询文本，在大型文档库中找出语义最相关的文档。文档嵌入由未经白化的 BERT 编码器生成。

场景 B：城市路网导航——在棋盘格状的城市（曼哈顿）中，一辆出租车只能沿街道（水平或垂直方向）行驶，需要计算两点间的最短路程。

场景 C：异常检测——在高维工业传感器数据中（各传感器量纲和方差不同），判断一个新样本是否是离群点。传感器数据已知其协方差矩阵 Σ 。

场景 D: 词汇类比推理——用「向量算术」方法 ($\mathbf{v}_A - \mathbf{v}_B + \mathbf{v}_C$) 在静态词嵌入中寻找最近邻词 D ，要求最大化类比准确率。

场景 E: 对抗鲁棒性检测——判断两张图片的像素是否「看起来一样」，其中攻击者通过改变少数几个像素（可以改变很大）来欺骗分类器。需要一种对单个像素极端变化敏感的距离。

(a) 对每个场景，给出推荐度量 and 一句话理由。

(b) 场景 A 中选择余弦而非欧氏的关键原因是「BERT 嵌入各向异性严重」。若将 BERT 嵌入先经过白化变换，然后改用 L^2 欧氏距离，结果会改变吗？为什么？

(c) 场景 D 和场景 A 都在词嵌入空间里做最近邻，但推荐的度量可能不同（场景 D 通常用欧氏距离，场景 A 用余弦）。解释这种差异：向量算术为什么对模长不敏感，而文档相似度检索为什么要归一化？

(d) 写出内积空间 $(\mathbb{R}^d, \langle \cdot, \cdot \rangle_G)$ 的「余弦相似度」公式（即用加权内积代替普通内积的余弦）：

$$\cos_G(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u}^T G \mathbf{v}}{\sqrt{\mathbf{u}^T G \mathbf{u}} \cdot \sqrt{\mathbf{v}^T G \mathbf{v}}}$$

说明当 $G = \Sigma^{-1}$ 时，这等价于在白化后的空间计算普通余弦相似度。

教学注：题 5 把前四道题的数学工具整合成「工程决策框架」。核心原则只有一条：**选择度量 = 对「哪些方向上的差异更重要」做出假设**；与数据内在结构最匹配的度量最好，没有普适答案。

陷阱：

- 场景 D 中类比算术（向量加减）的结果本质上是欧氏加法，用欧氏距离找最近邻更一致；但若嵌入各向异性严重，欧氏最近邻可能被高频词主导，此时可以先白化再用欧氏
- 场景 C 中「各传感器量纲不同」正是马氏距离的使用场景，不能用欧氏（等权）

解答 § 2.4

T-2.4.1 【 L^p 范数族与单位球几何】 (a) $\mathbf{x} = (3, 4)$ ：

$$\begin{aligned}\|\mathbf{x}\|_1 &= |3| + |4| = 7 \\ \|\mathbf{x}\|_2 &= \sqrt{9 + 16} = \sqrt{25} = 5 \\ \|\mathbf{x}\|_\infty &= \max(3, 4) = 4\end{aligned}$$

(b) 二维单位球的几何形状：

- L^1 ：菱形（旋转 45° 的正方形），顶点在坐标轴上 $(\pm 1, 0)$ 和 $(0, \pm 1)$
- L^2 ：圆（单位圆）
- L^∞ ：正方形，顶点在 $(\pm 1, \pm 1)$

(c) $\mathbf{y} = (0.6, 0.8)$:

$$\|\mathbf{y}\|_1 = 1.4, \quad \|\mathbf{y}\|_2 = 1.0, \quad \|\mathbf{y}\|_\infty = 0.8$$

确认 $1.4 > 1.0 > 0.8$ 。一般证明：对 $\mathbf{x} \neq \mathbf{0}$ ，设最大分量为 $x_{\max}$ ，则 $\|\mathbf{x}\|_\infty = x_{\max} \leq \|\mathbf{x}\|_2 = \sqrt{\sum x_i^2} \leq \sqrt{d \cdot x_{\max}^2} = \sqrt{d} \cdot x_{\max}$ ；而 $\|\mathbf{x}\|_1 = \sum |x_i| \geq \|\mathbf{x}\|_2$ (由 Cauchy-Schwarz: $\|\mathbf{x}\|_1 = \mathbf{1}^T \mathbf{x} \leq \sqrt{d} \|\mathbf{x}\|_2$ ，但另一方向 $\|\mathbf{x}\|_1 \geq \|\mathbf{x}\|_2$ 由 $(\sum |x_i|)^2 \geq \sum x_i^2$)。

(d) LASSO 稀疏解直觉：在参数空间中，约束集 $\|\theta\|_1 \leq C$ 是菱形，其尖角在坐标轴上。梯度下降轨迹与菱形约束边界相交，最可能「碰」到的是菱形的角点 (某些参数为零)； L^2 球是圆，没有角点，与任意方向的直线相交都在「内部」，不会产生精确零值。

Sanity check: $\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_2 \leq \|\mathbf{x}\|_1$ 对任意 $\mathbf{x}$ 成立 ($d=1$ 时取等)，这是范数的经典不等式，可用 $\mathbf{x} = (3, 4)$ 的数值 $4 \leq 5 \leq 7$ 验证。

T-2.4.2 【平行四边形恒等式与内积范数】 (a) 展开：

$$\|\mathbf{u} + \mathbf{v}\|^2 = \langle \mathbf{u} + \mathbf{v}, \mathbf{u} + \mathbf{v} \rangle = \langle \mathbf{u}, \mathbf{u} \rangle + 2\langle \mathbf{u}, \mathbf{v} \rangle + \langle \mathbf{v}, \mathbf{v} \rangle = \|\mathbf{u}\|^2 + 2\langle \mathbf{u}, \mathbf{v} \rangle + \|\mathbf{v}\|^2$$

$$\|\mathbf{u} - \mathbf{v}\|^2 = \langle \mathbf{u} - \mathbf{v}, \mathbf{u} - \mathbf{v} \rangle = \|\mathbf{u}\|^2 - 2\langle \mathbf{u}, \mathbf{v} \rangle + \|\mathbf{v}\|^2$$

两式相加： $\|\mathbf{u} + \mathbf{v}\|^2 + \|\mathbf{u} - \mathbf{v}\|^2 = 2\|\mathbf{u}\|^2 + 2\|\mathbf{v}\|^2$ 。证毕。

(b) 取 $\mathbf{u} = (1, 0)$, $\mathbf{v} = (0, 1)$:

- 左侧： $\|\mathbf{u} + \mathbf{v}\|_1^2 + \|\mathbf{u} - \mathbf{v}\|_1^2 = \|(1, 1)\|_1^2 + \|(1, -1)\|_1^2 = 2^2 + 2^2 = 8$
- 右侧： $2\|\mathbf{u}\|_1^2 + 2\|\mathbf{v}\|_1^2 = 2 \cdot 1^2 + 2 \cdot 1^2 = 4$

$8 \neq 4$, L^1 范数不满足平行四边形恒等式，故不来自内积。

(c) 余弦相似度、向量投影、自注意力点积的「几何解释」(夹角余弦)——这三者都依赖「内积 = 模长乘积 × 余弦值」这一关系，即极化恒等式 $\langle \mathbf{u}, \mathbf{v} \rangle = \frac{1}{4}(\|\mathbf{u} + \mathbf{v}\|^2 - \|\mathbf{u} - \mathbf{v}\|^2)$ ，而这个等式要求满足平行四边形恒等式。 L^1 空间中没有内积，上述所有「几何解释」失去数学基础 (数值上仍可计算，但失去了「角度」的含义)。

(d) 加权内积诱导的范数： $\|\mathbf{x}\|_G = \sqrt{\mathbf{x}^T G \mathbf{x}}$ ；诱导的距离 (马氏距离)：

$$d_G(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\|_G = \sqrt{(\mathbf{u} - \mathbf{v})^T G (\mathbf{u} - \mathbf{v})}$$

Sanity check: (a) 的证明用了内积的三条性质 (对称性、线性性、正定性)，这三条正是内积空间定义——平行四边形恒等式是这三条的推论，说明「来自内积的范数」必然满足它，逻辑闭合。

T-2.4.3 【马氏距离与白化的几何解释】 (a) 欧氏平方距离：

$$d_2^2(\mathbf{v}_A, \mathbf{v}_B) = (2 - 1)^2 + (1 - 3)^2 = 1 + 4 = 5, \quad d_2(\mathbf{v}_A, \mathbf{v}_B) \approx 2.236$$

$$d_2^2(\mathbf{v}_A, \mathbf{v}_C) = (2-2)^2 + (1-4)^2 = 0 + 9 = 9, \quad d_2(\mathbf{v}_A, \mathbf{v}_C) = 3.0$$

按欧氏距离, A 更靠近 B (距离 $2.236 < 3.0$)。

(b) $\det(\Sigma) = 4 \times 1 - 1 \times 1 = 3$, 故:

$$G = \Sigma^{-1} = \frac{1}{3} \begin{pmatrix} 1 & -1 \\ -1 & 4 \end{pmatrix} = \begin{pmatrix} 1/3 & -1/3 \\ -1/3 & 4/3 \end{pmatrix}$$

(c) 差向量: $\mathbf{v}_A - \mathbf{v}_B = (1, -2)$, $\mathbf{v}_A - \mathbf{v}_C = (0, -3)$ 。

马氏平方距离:

$$d_G^2(\mathbf{v}_A, \mathbf{v}_B) = (1, -2) \begin{pmatrix} 1/3 & -1/3 \\ -1/3 & 4/3 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \end{pmatrix}$$

先算 $G \cdot (1, -2)^T = (1/3 + 2/3, -1/3 - 8/3) = (1, -3)$, 再内积: $(1)(1) + (-2)(-3) = 1 + 6 = 7$ 。故 $d_G(\mathbf{v}_A, \mathbf{v}_B) = \sqrt{7} \approx 2.646$ 。

$(0, -3) \cdot G \cdot (0, -3)^T$: 先算 $G \cdot (0, -3)^T = (1, -4)$, 内积: $(0)(1) + (-3)(-4) = 12$ 。故 $d_G(\mathbf{v}_A, \mathbf{v}_C) = \sqrt{12} \approx 3.464$ 。

按马氏距离, A 仍更靠近 B ($2.646 < 3.464$), 但两者的相对差距缩小了。(本例中结论相同, 但若第 1 维方差更大, 结论可能反转。)

(d) $\Sigma_{11} = 4$ 远大于 $\Sigma_{22} = 1$, 意味着嵌入集合在第 1 维上散布更广 (4 倍)。欧氏距离把两维等权相加, $d_2^2 = \Delta x_1^2 + \Delta x_2^2$, 第 1 维上的差异 Δx_1^2 被高方差放大, 主导最终结果。马氏距离用 Σ^{-1} 归一化, 将第 1 维的差异除以 4 (方差), 每维的「标准化偏差」相当, 消除了高方差维度的主导效应。

Sanity check: $G = \Sigma^{-1}$ 的对角线元素 $G_{11} = 1/3 < G_{22} = 4/3$, 说明第 1 维 (高方差) 被马氏距离赋予了更低的权重, 这正是「消除高方差主导」的数学体现。

T-2.4.4 【度量选择对最近邻结果的影响】 (a) 欧氏平方距离 (苹果 vs 各词):

- vs 香蕉: $(0.1)^2 + (-0.1)^2 + (0.1)^2 + (-0.1)^2 + (0)^2 = 0.04$, $d_2 \approx 0.200$
- vs the: $(-3.6)^2 + (-0.4)^2 + (-0.8)^2 + (0)^2 + (-0.4)^2 = 12.96 + 0.16 + 0.64 + 0 + 0.16 = 13.92$, $d_2 \approx 3.731$
- vs 科技: $(0.8)^2 + (-0.8)^2 + (-0.6)^2 + (-0.7)^2 + (-0.1)^2 = 0.64 + 0.64 + 0.36 + 0.49 + 0.01 = 2.14$, $d_2 \approx 1.463$

欧氏最近邻: 香蕉 ($d_2 \approx 0.200$)。

(b) 余弦相似度 (先计算各向量的模长): 苹果模长 ≈ 0.937 , 香蕉 ≈ 0.837 , the ≈ 4.685 , 科技 ≈ 1.350 。

- vs 香蕉: $\frac{0.45+0.07+0.02+0+0.01}{0.937 \times 0.837} = \frac{0.55}{0.784} \approx 0.701$
- vs the: $\frac{4.05+0.05+0.2+0+0.05}{0.937 \times 4.685} = \frac{4.35}{4.389} \approx 0.991$
- vs 科技: $\frac{0.09+0.09+0.16+0+0.02}{0.937 \times 1.350} = \frac{0.36}{1.265} \approx 0.285$

余弦相似度最高：**the** (≈ 0.991)。注意「苹果」向量的方向与「the」几乎完全相同(刻意设计)，这揭示了各向异性问题。

(c) 曼哈顿距离：

- vs 香蕉： $|0.1| + |0.1| + |0.1| + |0.1| + |0| = 0.4$
- vs the： $3.6 + 0.4 + 0.8 + 0 + 0.4 = 5.2$
- vs 科技： $0.8 + 0.8 + 0.6 + 0.7 + 0.1 = 3.0$

曼哈顿最近邻：**香蕉** (0.4)。

(d) 欧氏和曼哈顿均选香蕉(符合语义)，余弦选「the」(因为「苹果」向量方向被高频词方向主导)。从语义角度，香蕉更正确。这说明未白化嵌入中余弦相似度被各向异性污染，而欧氏距离(对相似模长的词)反而给出了更合理的语义结果。但在实际 BERT 嵌入中(各词模长变化更大)，欧氏距离也会被模长污染——因此最佳实践是先白化再用欧氏(等效于马氏距离)。

(e) 理论理由：词嵌入空间(依赖余弦、注意力点积)隐含工作在内积空间中； L^1 不满足平行四边形恒等式，故没有内积结构，无法定义余弦(方向)。向量数据库用内积/余弦是因为内积空间提供了完整的几何工具链(投影、正交分解、注意力机制)； L^1 在数值上可计算，但失去了「方向」的语义解释。

Sanity check: (b) 中「苹果」vs「the」余弦 ≈ 0.991 说明两者方向几乎完全一致($\cos^{-1}(0.991) \approx 7.7^\circ$)——这是刻意设计以演示高频词污染问题，在实际语料中也有类似现象(高频词嵌入方向与多数其他词对齐)。

T-2.4.5 【何时用哪种度量】 (a) 推荐度量：

- **场景 A：余弦相似度**——BERT 嵌入各向异性严重，高频词模长偏大，余弦归一化消除模长偏置，只比较语义方向。
- **场景 B： L^1 曼哈顿距离**——出租车只能水平/垂直行驶，每一段路程就是一个坐标分量的差值，总路程正是各分量绝对差之和， L^1 的物理含义完美匹配。
- **场景 C：马氏距离** ($G = \Sigma^{-1}$)——不同传感器量纲和方差不同，欧氏距离被高方差传感器主导；马氏距离归一化各方向方差，每方向「一个标准差的偏离」贡献相等，适合检测统计意义上的离群。
- **场景 D： L^2 欧氏距离**——向量算术结果 $\mathbf{v}_A - \mathbf{v}_B + \mathbf{v}_C$ 是欧氏加法，最近邻搜索应与运算保持一致；而且类比关系(平行四边形)的几何意义在欧氏空间中最自然。
- **场景 E： L^∞ Chebyshev 距离**——攻击者只改变少数几个像素但改变幅度很大， L^∞ 只看最大绝对差，对「单维极端变化」最敏感； L^2 会把大量微小变化的贡献累加，可能忽略单个像素的极端改动。

(b) 白化后用 L^2 与直接用余弦的效果相近但不完全等价。白化使协方差矩阵变为 I_d ，此后 L^2 距离等价于马氏距离 ($G = \Sigma^{-1}$ 时)，也等价于在白化空间的余弦(若白化后模长均匀)。实践中，白化后 L^2 在 STS 基准上与余弦表现相近，甚至更好(Su 等 2021)——因为白化同时消除了模长偏置，余弦的额外归一化变得冗余。

(c) 向量算术 $\mathbf{v}_A - \mathbf{v}_B + \mathbf{v}_C$ 是模长敏感的运算——结果向量的模长由参与运算的词向量模长决定，直接用欧氏距离找最近邻更与运算逻辑一致。文档检索中，查询词和文

档的嵌入来自不同长度的文本，模长本身携带了「文本长度」的信息而非纯语义信息，归一化消除这个额外因素后，余弦更精确地度量语义方向相似性。

(d) 加权余弦 $\cos_G(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u}^T G \mathbf{v}}{\sqrt{\mathbf{u}^T G \mathbf{u}} \cdot \sqrt{\mathbf{v}^T G \mathbf{v}}}$ 。当 $G = \Sigma^{-1}$ ，令 $\tilde{\mathbf{u}} = \Lambda^{-1/2} U^T \mathbf{u}$ （白化变换），则：

$$\tilde{\mathbf{u}}^T \tilde{\mathbf{v}} = \mathbf{u}^T U \Lambda^{-1/2} \cdot \Lambda^{-1/2} U^T \mathbf{v} = \mathbf{u}^T U \Lambda^{-1} U^T \mathbf{v} = \mathbf{u}^T \Sigma^{-1} \mathbf{v} = \mathbf{u}^T G \mathbf{v}$$

因此 $\cos_G(\mathbf{u}, \mathbf{v}) = \cos(\tilde{\mathbf{u}}, \tilde{\mathbf{v}})$ ，即加权余弦等于在白化空间中计算普通余弦。

Sanity check: (d) 的等价关系说明「马氏余弦 = 白化后欧氏余弦」，这把三个概念（加权内积、白化变换、余弦相似度）统一在同一条数学路径上，是本节「选择度量 = 选择几何观」这一核心洞见的代数闭合。

§ 2.4 小结：从 L^p 范数族的「惩罚哲学」（题 1），到内积范数的代数判据（题 2），到马氏距离的白化几何解释（题 3），到具体数值下度量选择对最近邻的影响（题 4），到工程应用中的度量决策框架（题 5）——这五道题串成了「选择度量 = 对数据几何结构做假设」这条逻辑链。下一节 § 2.5 会展示当嵌入空间几何被词频统计污染时，这条链如何在现实中断裂，以及如何用白化修复。

§ 2.5 习题：反类比——当几何隐喻失效

导读：本节核心是从负采样的噪声分布出发，追溯出高频词椎体效应、嵌入空间各向异性、余弦相似度失效，最终说明「嵌入空间是干净语义坐标系」这一隐喻在实际中如何破裂，以及白化修复的代价。五题分别对应：各向异性指标的计算与解读、椎体效应的训练机制追溯、白化变换的代数实现与验证、白化对类比算术的破坏、综合判断五条「嵌入空间几何隐喻」的合法性边界。

题 1【轻 · 计算 · 各向异性指标的计算与解读】 导读：把「嵌入空间各向异性」从定性描述变成一个可计算的数，理解这个数为什么能揭示余弦相似度的失效。

设 3 维嵌入空间中有 4 个词向量（已经过模长归一化）：

$$\hat{\mathbf{v}}_1 = (0.98, 0.14, 0.14), \quad \hat{\mathbf{v}}_2 = (0.97, -0.15, 0.19)$$

$$\hat{\mathbf{v}}_3 = (0.99, 0.10, -0.10), \quad \hat{\mathbf{v}}_4 = (0.96, 0.20, -0.19)$$

(a) 计算所有 $\binom{4}{2} = 6$ 个词对的余弦相似度（由于向量已归一化，余弦值即内积）。

(b) 计算平均余弦相似度 $\bar{\cos} = \frac{1}{\binom{V}{2}} \sum_{i < j} \cos(\hat{\mathbf{v}}_i, \hat{\mathbf{v}}_j)$ （取 $V = 4$ ）。

(c) 若这 4 个向量是均匀随机分布在单位球面上的，预期平均余弦相似度约为多少（从 § 2.3 的结论出发）？与 (b) 的结果对比，说明这 4 个向量的各向异性程度。

(d) 这 4 个向量都高度集中在第 1 维方向附近（第 1 分量均接近 1）。假设「the」「of」等高频词集中在这个方向附近，而「量子纠缠」「罗马法」等低频词向量分布在各方

向。解释为什么在这种情形下，用余弦相似度计算「量子纠缠」与「罗马法」的语义相似度，结果会被高频词方向偏置。

教学注：(a)(b) 建立量化感受—— $\cos \approx 0.95$ 意味着几乎所有词「指向同一方向」，余弦相似度在这里测量的根本不是语义差异，而是与主导方向的对齐程度。

陷阱：

- 归一化向量的内积直接就是余弦值，不需要再除以模长——但要先检查是否真的已归一化（模长是否为 1）
- (c) 中随机向量的期望余弦相似度是 0（不是「接近 0 的一个小数」），这是各向同性的理论基准

题 2【中·推导·椎体效应的训练机制追溯】 导读：椎体效应不是偶然出现的，而是负采样目标函数的数学必然后果——把这条因果链从公式里推出来。

负采样的梯度公式（针对上下文词向量 $\mathbf{u}_c$ ）：

$$\nabla_{\mathbf{u}_c} \mathcal{L}_{\text{NEG}} = -\sigma(\mathbf{u}_c^T \mathbf{v}_w) \cdot \mathbf{v}_w \quad (\text{当 } c \text{ 为负样本时})$$

其中 $\sigma(x) = 1/(1 + e^{-x})$ 为 sigmoid 函数， $\mathbf{v}_w$ 为当前中心词向量。

(a) 假设词「the」的频率 $f(\text{the}) = 0.05$ (5%)，词「obscure」的频率 $f(\text{obscure}) = 0.00001$ (0.001%)。在噪声分布 $P_n(c) \propto f(c)^{3/4}$ 下，「the」被选为负样本的概率与「obscure」的比值约为多少？（计算 $f(\text{the})^{3/4}/f(\text{obscure})^{3/4}$ ，用科学计数法表示。）

(b) 设某一训练 step 中，中心词为「猫」，「the」被选为负样本， $\sigma(\mathbf{u}_{\text{the}}^T \mathbf{v}_{\text{猫}}) = 0.7$ 。写出这一步对 $\mathbf{u}_{\text{the}}$ 施加的梯度更新方向，并说明它的物理含义（「推开」还是「拉近」）。

(c) 设在整个训练过程中，「the」被选为负样本共 $N_1 = 10^6$ 次，而「obscure」被选为负样本共 $N_2 = 200$ 次。假设每次梯度更新的步长 $\eta = 0.01$ ，平均 $\sigma(\mathbf{u}_c^T \mathbf{v}_w) \approx 0.5$ ，每次更新中 $\|\mathbf{v}_w\| \approx 1$ 。估算「the」和「obscure」的上下文向量各自被累计推离其初始位置的大致距离（假设方向大致相同，可以直接累加）。

(d) 词频服从 Zipf 定律：最高频词的频率是第 k 高频词的约 k 倍（即频率 $\propto 1/k$ ）。从这一定律出发，解释为什么嵌入空间中「高频词聚集成一个低维锥」是统计上不可避免的——不是特定训练数据的偶然，而是任何遵循 Zipf 定律的语言数据的必然结果。

教学注：(c) 的估算虽然粗糙，但数量级感受是重要的：「the」被推了约 $10^6 \times 0.01 \times 0.5 = 5000$ 步，「obscure」只被推了约 $200 \times 0.01 \times 0.5 = 1$ 步——两者所受的排斥力相差 5000 倍，这就是椎体效应的数量级根源。

陷阱：

- (b) 中梯度更新方向是 $-\eta \nabla_{\mathbf{u}_c}$ ，要注意负号——梯度下降走负梯度方向；负采样的负梯度方向是把「the」的向量**推离**当前中心词
- (d) 不要只说「高频词出现多」——要从「Zipf 定律下排名靠前的那少数几个词占据了大量概率质量」推导出「排斥梯度集中在少数词上」

题3【中·计算·白化变换的代数实现】 导读：白化不是一个神秘的操作，就是「PCA + 按特征值归一化」——把这条变换从矩阵分解到最终结果，完整算一遍。

设3维嵌入空间，嵌入矩阵（去均值后）的协方差矩阵估计为：

$$\Sigma = \begin{pmatrix} 9 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0.25 \end{pmatrix}$$

（对角矩阵，说明各维度不相关，方差分别为9、1、0.25。）

有两个词向量 $\mathbf{v}_A = (3, 1, 0.5)$ 和 $\mathbf{v}_B = (1, 3, 0.5)$ 。

(a) 写出 Σ 的特征分解 $\Sigma = U\Lambda U^T$ （对角矩阵时特征向量矩阵 $U = I$ ， $\Lambda = \Sigma$ ）。

(b) 计算白化矩阵 $W = \Lambda^{-1/2}U^T$ （即 $\Lambda^{-1/2}$ ，因为 $U = I$ ），并写出其对角元素。

(c) 计算白化后的向量 $\tilde{\mathbf{v}}_A = W\mathbf{v}_A$ 和 $\tilde{\mathbf{v}}_B = W\mathbf{v}_B$ 。

(d) 计算原始向量的余弦相似度 $\cos(\mathbf{v}_A, \mathbf{v}_B)$ ，以及白化后向量的余弦相似度 $\cos(\tilde{\mathbf{v}}_A, \tilde{\mathbf{v}}_B)$ 。两者是否不同？解释为什么白化后余弦相似度会改变。

(e) 验证：白化后的向量协方差（近似地，用两个向量模拟）是否更接近各向同性（即各方向方差相等）。

教学注：白化把高方差维度（这里是第1维，方差=9）「压缩」，把低方差维度（第3维，方差=0.25）「放大」，使得所有维度的方差都变为1。这道题通过具体数字展示：白化确实改变了余弦相似度——这正是「白化是有代价的」的量化依据。

陷阱：

- $\Lambda^{-1/2}$ 的对角元素是 $\lambda_i^{-1/2} = 1/\sqrt{\lambda_i}$ ，不是 $1/\lambda_i$
- (d) 中若白化后余弦值变化，要解释清楚：白化改变了向量的相对方向（因为不同维度被不等比例缩放），余弦相似度随之改变

题4【重·综合·白化对类比算术的破坏】 导读：白化在语义相似度任务上提升表现，但在类比推理任务上可能降低准确率——这个矛盾的背后是一个深层的「噪声与信号耦合」问题。

沿用题3的设置，但现在考虑词向量中编码了「性别」语义关系：

$$\mathbf{v}_{\text{国王}} = (3, 1, 1), \quad \mathbf{v}_{\text{女王}} = (3, 1, -1)$$

$$\mathbf{v}_{\text{男人}} = (1, 2, 1), \quad \mathbf{v}_{\text{女人}} = (1, 2, -1)$$

（第3维编码性别：+1 = 男性，-1 = 女性；第1-2维编码其他语义特征。协方差矩阵沿用题3的 Σ 。）

(a) 在原始空间中，计算「类比向量」 $\delta = \mathbf{v}_{\text{国王}} - \mathbf{v}_{\text{女王}}$ 和 $\delta' = \mathbf{v}_{\text{男人}} - \mathbf{v}_{\text{女人}}$ 。验证 $\delta = \delta'$ （即性别方向在原始空间中是平行的）。

(b) 用题3的白化矩阵 $W = \Lambda^{-1/2}$ ，计算白化后的四个向量：

$$\begin{aligned}\tilde{\mathbf{v}}_{\text{国王}} &= W\mathbf{v}_{\text{国王}}, & \tilde{\mathbf{v}}_{\text{女王}} &= W\mathbf{v}_{\text{女王}} \\ \tilde{\mathbf{v}}_{\text{男人}} &= W\mathbf{v}_{\text{男人}}, & \tilde{\mathbf{v}}_{\text{女人}} &= W\mathbf{v}_{\text{女人}}\end{aligned}$$

(c) 在白化后的空间中，计算 $\tilde{\delta} = \tilde{\mathbf{v}}_{\text{国王}} - \tilde{\mathbf{v}}_{\text{女王}}$ 和 $\tilde{\delta}' = \tilde{\mathbf{v}}_{\text{男人}} - \tilde{\mathbf{v}}_{\text{女人}}$ 。 $\tilde{\delta}$ 和 $\tilde{\delta}'$ 是否仍然相等？余弦相似度是多少？

(d) 类比推理的步骤：给定「国王 - 男人 + 女人」，预期结果向量为 $\mathbf{v}_{\text{国王}} - \mathbf{v}_{\text{男人}} + \mathbf{v}_{\text{女人}}$ 。在原始空间和白化空间中分别计算这个结果向量，并判断它是否更接近「女王」还是其他词。

(e) 解释为什么白化在「语义相似度」任务上提升而在「类比推理」任务上可能退步——这两种任务对「性别方向」的利用方式有什么不同？白化破坏了「性别方向」的哪个性质？

教学注：这道题揭示了白化代价二（破坏线性语义方向）的具体机制：性别关系被编码在第3维（低方差，方差=0.25），白化把这个维度放大了 $1/\sqrt{0.25} = 2$ 倍，破坏了性别方向在「国王/女王」和「男人/女人」之间的平行等长关系（平行关系保持，但比例改变）。

陷阱：

- (c) 的核心发现： $\tilde{\delta}$ 和 $\tilde{\delta}'$ 在这个例子里仍然相等（因为是对角协方差，线性变换保持平行性）——这说明白化保持了性别方向的方向，但可能改变了它相对于其他方向的比例
- (d) 中要分别在原始空间和白化空间做完整的计算，不要只定性描述

题5【重·评判·五条嵌入几何隐喻的合法性】 导读：本节把「嵌入空间几何」的几条流行说法逐一审查——哪些在数学上有严格保证，哪些只是近似，哪些在实际中经常失效。

阅读以下五个论断：

论断 A：「词嵌入的余弦相似度可以作为语义相似度的可靠度量——相似的词（近义词、同类词）余弦相似度接近 1，无关的词余弦相似度接近 0。」

论断 B：「向量算术（ $\mathbf{v}_{\text{国王}} - \mathbf{v}_{\text{男人}} + \mathbf{v}_{\text{女人}} \approx \mathbf{v}_{\text{女王}}$ ）是词嵌入的可靠工具——只要嵌入经过充分训练，对任意语义关系都能奏效。」

论断 C：「嵌入空间的有效维度就是名义维度 d ——768 维的 BERT 嵌入拥有 768 个独立的信息维度，可以同时表达 768 种语义特征。」

论断 D：「白化变换可以消除所有嵌入空间的几何失真，让余弦相似度在所有任务上都更可靠。」

论断 E：「嵌入空间各向异性是一个训练缺陷，通过改进训练方法（例如对负采样噪声分布做精确设计）可以完全消除，从而让嵌入空间趋于各向同性。」

(a) 对每个论断给出「成立 / 部分成立 / 不成立」的判断，并指出关键前提或失效条件。

(b) 论断 A 和 B 都说的是余弦相似度/向量算术的「可靠性」，但失效模式不同。A 的失

效来自**各向异性**（高频词偏置），B 的失效来自**平移等变性不成立**（语义关系在空间中不平行）。给出一个具体词对/词组，说明 A 失效但 B 成立的情形，以及 B 失效但 A 成立的情形。

(c) 论断 C 中「有效维度」和「名义维度」的差距由什么决定？结合本节的椎体效应和 § 2.3 的超位置概念，说明 BERT-base ($d = 768$) 的有效信息维度可能远低于 768，也可能通过超位置机制远超 768——这两种说法各自有什么依据？

(d) 论断 D 中「白化可以消除所有几何失真」——哪条失真可以消除，哪条不能？具体地，说明白化能消除的是「各向异性（主导方向偏置）」，但不能消除的是「多义词模糊（bank 问题）」以及「训练数据偏见（gender bias）」。

(e) 论断 E 问的是各向异性能否被「完全消除」。写出至少一个理论上的障碍：即使把负采样分布改为均匀分布 ($P_n(c) = 1/V$)，各向异性是否会消失？从 Zipf 定律和统计估计的稳定性角度给出分析。

教学注：题 5 是本节的集成判断题。五条论断覆盖了本节的四个核心机制（各向异性、椎体效应、白化、有效维度），要求读者用「哪些假设在什么条件下成立」的框架来逐条分析，而不是靠记忆。

陷阱：

- 论断 E 的关键：即使改变采样分布，词频本身是数据的固有属性，无法「消除」——高频词在训练中收到的正样本梯度更新次数也更多，各向异性有多重来源
- 论断 C 中「有效维度 < 名义维度」和「超位置 → 有效维度 > 名义维度」不矛盾——前者说的是「各向异性造成秩折扣」，后者说的是「稀疏特征叠加允许超额存储」，两者在不同尺度上成立

解答 § 2.5

T-2.5.1 【各向异性指标的计算与解读】 (a) 余弦相似度（归一化向量直接算内积）：

- $\cos(\hat{\mathbf{v}}_1, \hat{\mathbf{v}}_2) = 0.98 \times 0.97 + 0.14 \times (-0.15) + 0.14 \times 0.19 = 0.9506 - 0.0210 + 0.0266 = 0.9562$
- $\cos(\hat{\mathbf{v}}_1, \hat{\mathbf{v}}_3) = 0.98 \times 0.99 + 0.14 \times 0.10 + 0.14 \times (-0.10) = 0.9702 + 0.014 - 0.014 = 0.9702$
- $\cos(\hat{\mathbf{v}}_1, \hat{\mathbf{v}}_4) = 0.98 \times 0.96 + 0.14 \times 0.20 + 0.14 \times (-0.19) = 0.9408 + 0.028 - 0.0266 = 0.9422$
- $\cos(\hat{\mathbf{v}}_2, \hat{\mathbf{v}}_3) = 0.97 \times 0.99 + (-0.15) \times 0.10 + 0.19 \times (-0.10) = 0.9603 - 0.015 - 0.019 = 0.9263$
- $\cos(\hat{\mathbf{v}}_2, \hat{\mathbf{v}}_4) = 0.97 \times 0.96 + (-0.15) \times 0.20 + 0.19 \times (-0.19) = 0.9312 - 0.030 - 0.0361 = 0.8651$
- $\cos(\hat{\mathbf{v}}_3, \hat{\mathbf{v}}_4) = 0.99 \times 0.96 + 0.10 \times 0.20 + (-0.10) \times (-0.19) = 0.9504 + 0.02 + 0.019 = 0.9894$

(b) $\text{c}\ddot{\text{o}}\text{s} = (0.9562 + 0.9702 + 0.9422 + 0.9263 + 0.8651 + 0.9894)/6 = 5.6494/6 \approx 0.9416$

(c) 各向同性随机单位向量的期望余弦相似度为 0（§ 2.3：高维随机向量几乎正交，余弦趋于 0）。 $\text{c}\ddot{\text{o}}\text{s} \approx 0.94$ 远大于 0，说明这 4 个向量的各向异性极严重——几乎所有词

都「挤」在第1维方向附近。

(d) 当「the」「of」等高频词也集中在第1维方向，而「量子纠缠」「罗马法」分别从这个主导方向略微偏离时，两个低频词彼此的余弦相似度会被「主导方向」污染： $\cos(\mathbf{v}_A, \mathbf{v}_B) \approx \cos(\mathbf{v}_A, \hat{\mathbf{e}}_1) \cdot \cos(\mathbf{v}_B, \hat{\mathbf{e}}_1) + \text{小校正项}$ ——即余弦值主要反映两个词与主导方向（ $\hat{\mathbf{e}}_1$ ）的对齐程度，而非两词之间的语义关系。

Sanity check: 6个余弦值全部 > 0.85 ，而随机向量期望值为0——差距约0.9，说明这4个向量几乎「完全对齐」到第1维，各向异性指标接近真实BERT上层嵌入的观测值（ $\text{c}\ddot{\text{o}}\text{s} \approx 0.99$ ）。

T-2.5.2 【椎体效应的训练机制追溯】 (a) $f(\text{the})^{3/4} = 0.05^{3/4}$, $f(\text{obscure})^{3/4} = 10^{-5 \times 3/4} = 10^{-5} \cdot 10^{3/4 \times \log_{10}(10^{-5})}$ 。计算：

$$\frac{0.05^{3/4}}{(10^{-5})^{3/4}} = \left(\frac{0.05}{10^{-5}} \right)^{3/4} = (5000)^{3/4}$$

$$(5000)^{3/4} = e^{3/4 \cdot \ln 5000} = e^{3/4 \times 8.517} = e^{6.388} \approx 595。$$

「the」被选为负样本的概率约是「obscure」的595倍。

(b) 梯度更新方向： $-\eta \cdot \nabla_{\mathbf{u}_{\text{the}}} \mathcal{L}_{\text{NEG}} = -\eta \cdot (-\sigma(\mathbf{u}_{\text{the}}^T \mathbf{v}_{\text{猫}}) \cdot \mathbf{v}_{\text{猫}}) = \eta \cdot \sigma(\cdot) \cdot \mathbf{v}_{\text{猫}}$ 。

等等——梯度下降时减去梯度，但这里我们要让损失减小（即提高「the」不是猫的上下文词的概率），所以更新方向是把 $\mathbf{u}_{\text{the}}$ 推离 $\mathbf{v}_{\text{猫}}$ （即 $\mathbf{u}_{\text{the}} \leftarrow \mathbf{u}_{\text{the}} + \eta \sigma(\mathbf{u}_{\text{the}}^T \mathbf{v}_{\text{猫}}) \cdot (-\mathbf{v}_{\text{猫}})$ ）。物理含义：「the」的上下文向量被推向与「猫」的中心词向量相反的方向，减小两者相似度。

(c) 估算累计位移： $\|\Delta \mathbf{u}_{\text{the}}\| \approx N_1 \times \eta \times \sigma(\cdot) \times \|\mathbf{v}_w\| = 10^6 \times 0.01 \times 0.5 \times 1 = 5000$ （任意单位）。 $\|\Delta \mathbf{u}_{\text{obscure}}\| \approx 200 \times 0.01 \times 0.5 \times 1 = 1$ 。两者相差5000倍，「the」的向量被系统性地推到远离所有中心词的方向，而「obscure」几乎不动。

(d) Zipf定律：词频 $f_k \propto 1/k$ ，前 K 个高频词占据总词频的 $\sum_{k=1}^K 1/k \approx \ln K$ ，占总语料比例约 $\ln K / \ln V$ 。对 $V = 50000$ ，前100个词（ $K = 100$ ）占约 $\ln 100 / \ln 50000 \approx 4.6/10.8 \approx 43\%$ 。这意味着绝大多数排斥梯度集中在这极少数的高频词身上——无论怎么训练，只要语言遵循Zipf定律，高频词就会被过度排斥，必然形成椎体效应。这不是训练数据的偶然，而是Zipf分布与负采样机制结合的数学必然。

Sanity check: (a) 中595倍对应「the」和「obscure」被选为负样本的概率比，可以验证：3/4次幂比直接用频率比（5000倍）小得多——3/4幂的「压缩」效果使高低频词的差距从5000倍降到595倍，但仍是巨大差距。

T-2.5.3 【白化变换的代数实现】 (a) 对角矩阵的特征分解： $U = I_3$ （单位矩阵）， $\Lambda = \Sigma = \text{diag}(9, 1, 0.25)$ 。特征值 $\lambda_1 = 9, \lambda_2 = 1, \lambda_3 = 0.25$ 。

(b) $W = \Lambda^{-1/2} U^T = \Lambda^{-1/2} = \text{diag}(1/3, 1, 2)$ 。对角元素： $1/\sqrt{9} = 1/3, 1/\sqrt{1} = 1, 1/\sqrt{0.25} = 2$ 。

(c) 白化后向量：

$$\begin{aligned}\tilde{\mathbf{v}}_A &= W\mathbf{v}_A = (3/3, 1 \times 1, 2 \times 0.5) = (1, 1, 1) \\ \tilde{\mathbf{v}}_B &= W\mathbf{v}_B = (1/3, 1 \times 3, 2 \times 0.5) = (1/3, 3, 1)\end{aligned}$$

(d) 原始余弦相似度：

$$\begin{aligned}\|\mathbf{v}_A\| &= \sqrt{9 + 1 + 0.25} = \sqrt{10.25} \approx 3.202, \quad \|\mathbf{v}_B\| = \sqrt{1 + 9 + 0.25} = \sqrt{10.25} \approx 3.202 \\ \cos(\mathbf{v}_A, \mathbf{v}_B) &= \frac{3 \times 1 + 1 \times 3 + 0.5 \times 0.5}{3.202^2} = \frac{6.25}{10.25} \approx 0.6098\end{aligned}$$

白化后余弦相似度：

$$\begin{aligned}\|\tilde{\mathbf{v}}_A\| &= \sqrt{1 + 1 + 1} = \sqrt{3} \approx 1.732 \\ \|\tilde{\mathbf{v}}_B\| &= \sqrt{1/9 + 9 + 1} = \sqrt{10.111} \approx 3.180 \\ \cos(\tilde{\mathbf{v}}_A, \tilde{\mathbf{v}}_B) &= \frac{1/3 + 3 + 1}{1.732 \times 3.180} = \frac{4.333}{5.507} \approx 0.7869\end{aligned}$$

白化后余弦相似度从 0.61 升至 0.79，两者不同。原因：白化对不同维度施加了不等比例的缩放（第 1 维缩小 3 倍，第 3 维放大 2 倍），改变了向量的相对方向，余弦值随之变化。

(e) 白化后的协方差（粗略以两向量估计）： $\tilde{\mathbf{v}}_A$ 和 $\tilde{\mathbf{v}}_B$ 的均值约 $((1 + 1/3)/2, (1 + 3)/2, 1) = (2/3, 2, 1)$ 。方差各维大致相当（不完全，因为只有 2 个点），但白化的设计目标是使全体嵌入集合的协方差矩阵变为 I ——两个点不能严格验证，但可以看到第 1 维的大方差（原来 9）已被 $1/3$ 缩放消除。

Sanity check: 白化矩阵 $W = \text{diag}(1/3, 1, 2)$ 的对角元素：第 1 维（高方差 9）被压缩（乘以 $1/3$ ），第 3 维（低方差 0.25）被放大（乘以 2），第 2 维（方差 1）不变——这正是「消除各向异性」的操作，与直觉一致。

T-2.5.4 【白化对类比算术的破坏】 (a) 类比向量（原始空间）：

$$\begin{aligned}\delta &= \mathbf{v}_{\text{国王}} - \mathbf{v}_{\text{女王}} = (3 - 3, 1 - 1, 1 - (-1)) = (0, 0, 2) \\ \delta' &= \mathbf{v}_{\text{男人}} - \mathbf{v}_{\text{女人}} = (1 - 1, 2 - 2, 1 - (-1)) = (0, 0, 2)\end{aligned}$$

$\delta = \delta' = (0, 0, 2)$ ，完全相等，性别方向是平行且等长的。

(b) 白化矩阵 $W = \text{diag}(1/3, 1, 2)$ ：

$$\begin{aligned}\tilde{\mathbf{v}}_{\text{国王}} &= (1, 1, 2), \quad \tilde{\mathbf{v}}_{\text{女王}} = (1, 1, -2) \\ \tilde{\mathbf{v}}_{\text{男人}} &= (1/3, 2, 2), \quad \tilde{\mathbf{v}}_{\text{女人}} = (1/3, 2, -2)\end{aligned}$$

(c) 白化空间中类比向量:

$$\tilde{\delta} = \tilde{\mathbf{v}}_{\text{国王}} - \tilde{\mathbf{v}}_{\text{女王}} = (0, 0, 4)$$

$$\tilde{\delta}' = \tilde{\mathbf{v}}_{\text{男人}} - \tilde{\mathbf{v}}_{\text{女人}} = (0, 0, 4)$$

$\tilde{\delta} = \tilde{\delta}'$, 方向仍然平行 (在这个对角协方差的简单例子中, 白化保持了平行性)。余弦 $\cos(\tilde{\delta}, \tilde{\delta}') = 1$ 。

注: 这个例子中白化保持了类比向量的方向, 但**改变了性别方向相对于其他语义方向的比例** (性别方向被放大了 2 倍)。在非对角协方差的实际情形中, 白化会引入旋转, 破坏平行性。

(d) 类比结果向量: 原始空间 $\mathbf{v}_{\text{国王}} - \mathbf{v}_{\text{男人}} + \mathbf{v}_{\text{女人}} = (3 - 1 + 1, 1 - 2 + 2, 1 - 1 - 1) = (3, 1, -1) = \mathbf{v}_{\text{女王}}$, 精确命中。白化空间: $\tilde{\mathbf{v}}_{\text{国王}} - \tilde{\mathbf{v}}_{\text{男人}} + \tilde{\mathbf{v}}_{\text{女人}} = (1 - 1/3 + 1/3, 1 - 2 + 2, 2 - 2 - 2) = (1, 1, -2) = \tilde{\mathbf{v}}_{\text{女王}}$, 也精确命中。(本例中两空间均成立, 但实际非对角协方差情形可能导致偏差。)

(e) 「语义相似度」任务只需要两个词的向量**方向对齐程度**, 白化后余弦相似度更好地反映了语义差异 (消除了词频偏置)。「类比推理」任务需要两组词对之间的差向量**方向和长度都精确匹配** (平移等变性)。白化通过不均匀缩放改变了不同语义关系之间的**相对比例**——若性别方向与其他语义方向在协方差结构上不独立, 白化会引入旋转破坏平行性。这两种任务对「空间结构」的依赖不同, 是白化「顾此失彼」的根本原因。

Sanity check: (a) 中 $\delta = \delta' = (0, 0, 2)$ 说明性别关系被精确编码在第 3 维; (c) 中白化把第 3 维放大 2 倍, 但两个差向量都变为 $(0, 0, 4)$, 方向保持一致。这个例子说明**对角协方差时白化不破坏平行性**, 但实际嵌入空间的协方差是非对角的, 结论不同。

T-2.5.5 【五条嵌入几何隐喻的合法性】 (a) 判断:

- **论断 A 部分成立。**余弦相似度在白化后或低各向异性的静态嵌入中是语义相似度的可靠度量; 但在未白化的上下文相关嵌入 (BERT 上层 $\cos \approx 0.99$) 中严重失效, 测量的是与主导方向的对齐程度而非语义差异。
- **论断 B 部分成立。**类比算术在「语义关系高度规律、词频足够、维度足够」时有约 60-70% 的准确率 (Word2Vec 原始论文), 但对抽象关系、上下文相关嵌入、各向异性严重的空间频繁失效。
- **论断 C 不成立。**各向异性使得嵌入空间的「有效秩」 (实际信息维度) 远低于 d ——大量维度携带词频噪声, 实际独立语义方向可能只有数十到数百。同时超位置允许有效信息量超过 d , 但这是在稀疏特征条件下, 「768 个完全独立的语义特征」是错误的。
- **论断 D 部分成立。**白化能消除各向异性 (主导方向偏置), 对语义相似度任务有效; 但不能消除多义词模糊 (bank 问题), 不能消除训练数据中的偏见 (gender bias), 也不能修复类比推理任务中可能的精度损失。
- **论断 E 不成立。**即使改为均匀负采样 $P_n = 1/V$, 各向异性仍然存在: 高频词在正样本侧也收到更多梯度更新 (出现次数多), 模长系统性偏大; 更根本地, Zipf

分布是语言数据的固有属性，无法通过训练策略改变。各向异性有多重来源，仅修改负采样分布不能完全消除。

(b) A 失效但 B 成立的情形：「the」与「a」的余弦相似度可能虚高（两者都是高频词，被椎体效应推向同一方向），余弦相似度”说”它们语义相似（A 失效）；但「定冠词 - 通用上下文 + 特指上下文 $\approx$ 特指冠词」这种类比关系（B）在语料中规律清晰，向量算术成立。B 失效但 A 成立：「道德」与「伦理」余弦相似度高（近义词，A 成立）；但「道德 - 哲学 + 法律 $\approx$ 法律伦理？」这种抽象类比关系在语料中缺乏一致统计规律，B 失效。

(c) 「有效维度 < 名义维度」的依据：各向异性使嵌入矩阵的协方差矩阵有少数几个大特征值（主成分），其余特征值接近零——有效秩 ($\approx \sum \lambda_i^2 / (\sum \lambda_i)^2$ 的倒数，即参与信息) 远低于 d 。「超位置 $\rightarrow$ 有效信息 > 名义维度」的依据：只要特征稀疏（大多数特征不同时激活）， d 维空间可以存储约 $e^{d/8}$ 个几乎正交方向，每个方向对应一个语义特征——因此信息容量可远超 d 。这两种说法不矛盾：前者描述「实际被使用的维度数」，后者描述「理论上能存储的最大信息量」。

(d) 白化能消除：各向异性（主导方向偏置）——通过归一化各方向方差，使向量均匀覆盖空间，余弦不再被主导方向污染。白化不能消除：(1) **多义词模糊**（bank 的金融/河流含义平均在一个向量里，白化不能分开两种义项）；(2) **训练数据偏见**（gender bias：「护士」的嵌入向量偏向女性方向，白化只是在「女性方向」上重新缩放，不改变该方向本身的存在）；(3) **稀疏统计噪声**（低频词的嵌入向量统计估计不稳定，白化不能凭空增加训练样本）。

(e) 理论障碍：即使均匀负采样 $P_n = 1/V$ ，正样本侧仍不均匀——高频词（「the」）的中心词向量在训练中出现次数与词频成正比，受到更多梯度更新，模长系统性偏大。椎体效应不只来自负样本侧，还来自正样本侧的不均匀更新。更根本的障碍：词的嵌入向量的更新次数正比于词频，高频词嵌入的统计估计更稳定、模长更大，这是词频本身的固有属性，任何基于词频统计的训练方法都无法消除。

Sanity check：(a) 中五条论断分别踩了：A-各向异性偏置；B-平移等变性不总成立；C-各向异性造成秩折扣 + 超位置概念混淆；D-白化不能解决所有问题；E-各向异性有多重来源。每条都能在本节的「因果链」里找到对应的机制，说明分析覆盖完整。

§ 2.5 小结：从各向异性指标的量化（题 1）、到椎体效应的梯度力学追溯（题 2）、到白化的代数实现（题 3）、到白化代价的具体展示（题 4）、到五条几何隐喻的合法性判断（题 5）——这五道题串成了「嵌入空间几何隐喻何时成立、何时失效」的完整判断框架。核心结论：词嵌入不是一个干净的语义坐标系，而是被词频统计深度污染的各向异性空间；白化是有效但有代价的局部修复；真正的几何意义需要在「白化 + 具体任务对应的度量」的组合下才能重新成立。

§ 2.6 跨越欧氏：双曲嵌入与层级几何

本节建立双曲空间嵌入的数学基础：欧氏维度瓶颈（树结构指数增长 vs 欧氏球多项式增长）；Poincaré 球黎曼度量（共形因子，边界无限远）；双曲距离公式（arcosh 形式，精确计算两点间测地线长度）；双曲球体积指数增长（与 b -叉树匹配）。

公式 8 · 欧氏维度瓶颈

$$d \geq \Omega\left(\frac{L \log b}{\log r}\right)$$

嵌入深度 L 、分支数 b 的完全 b -叉树，所需欧氏维度随 L 线性增长，不可避免。

一句话直觉：树的节点数指数增长，欧氏球体积仅多项式增长——嵌入深层树需要越来越多的维度。

T-2.6.1【易·代入·指数增长 vs 多项式增长·维度瓶颈】 完全二叉树 ($b = 2$) 深度 L 层的节点总数为 $N = 2^{L+1} - 1$ 。

- 分别计算 $L = 5, 10, 15$ 时的节点数 N ；
- 欧氏空间中，要容纳 $N = 2^L$ 个互相距离 ≥ 1 的点，最小维度 d 满足 $(2L)^d \geq 2^L$ ，解出 $d \geq L \ln 2 / \ln(2L)$ 。分别计算 $L = 5, 10, 15$ 时的 d 下界；
- 双曲空间中，深度 L 的完全二叉树只需 $d = 2$ 维就能以高精度嵌入 (Nickel & Kiela 2017)。对比 (b) 的欧氏维度需求，用一句话总结双曲空间对树结构的优势。

T-2.6.2【中·变形·树深度与嵌入维度的关系】 设分支数 $b = 3$ (完全三叉树)，节点数 $N = (3^{L+1} - 1)/2$ 。

- 欧氏维度下界 (装填论证)：要使半径为 $r = L$ 的欧氏球能容纳 $N \approx 3^L$ 个点，推导 d 关于 L 的下界 (类比二叉树公式，将 $\ln 2$ 换成 $\ln 3$)；
- 对 $L = 10$ ($N \approx 59049$ 个节点)，比较完全二叉树和完全三叉树各自的欧氏维度下界；
- 公式 $d \geq \Omega(L \log b / \log r)$ 中， L 越大或 b 越大，所需维度越高。说明这一下界线性增长 ($\ln L$) 的本质原因：树的拓扑结构和欧氏几何的增长速率不匹配。

公式 9 · Poincaré 球黎曼度量 (共形因子)

$$ds^2 = \frac{4\|dx\|^2}{(1 - \|x\|^2)^2}, \quad x \in \mathbb{B}^d = \{x : \|x\| < 1\}$$

共形因子 $\lambda(x) = \frac{2}{1 - \|x\|^2}$ ，当 $\|x\| \rightarrow 1$ 时 $\lambda \rightarrow \infty$ ，空间被无限“拉伸”。

一句话直觉：在有限欧氏圆盘里塞进无限双曲空间——越靠近边界，同样的欧氏位移对应越长的双曲距离。

T-2.6.3【易·代入·共形因子放大效应】 Poincaré 球的共形因子 (局部放大倍数) 为 $\lambda(x) = 2/(1 - \|x\|^2)$ 。

- 计算 $\|x\| = 0, 0.5, 0.9, 0.99, 0.999$ 处的 λ 值；
- 当 $\|x\| = 0.99$ (叶节点) 与原点 (根节点)，欧氏位移 $\Delta\|x\| = 0.001$ 在这两个位置分别对应的双曲弧长是多少？两者之比是多少？

- (c) 用“地图投影”类比解释共形因子的作用：Poincaré 球相当于把无限双曲平面压缩进有限圆盘——角度（方向关系）被保留，但面积（体积）被压缩。这与哪类地图投影类似？

T-2.6.4 【中 · 判错 · Poincaré 球的”边界可达”？】 有人说：“Poincaré 球 $\mathbb{B}^d$ 就是一个有界开球，球内任意两点的距离都是有限的，当然边界也是可以接近的，只是欧氏距离小于 1。”

- (a) 这句话哪里错了？指出关键：欧氏距离有限不等于双曲距离有限，从 $d_H(0, r\hat{e}_1) = 2 \operatorname{arctanh}(r)$ 说明当 $r \rightarrow 1$ 时发生了什么；
- (b) 计算 $2 \operatorname{arctanh}(0.9)$ 、 $2 \operatorname{arctanh}(0.99)$ 、 $2 \operatorname{arctanh}(0.999)$ 的具体数值，验证“趋近边界，距离急速增大”；
- (c) 这一性质在层级嵌入中的作用是什么？为什么“叶节点在边界附近”天然对应树结构的深层节点？

公式 10 · 双曲距离公式

$$d_H(u, v) = \operatorname{arcosh} \left(1 + \frac{2\|u - v\|^2}{(1 - \|u\|^2)(1 - \|v\|^2)} \right)$$

其中 $\operatorname{arcosh}(t) = \ln(t + \sqrt{t^2 - 1})$, $t \geq 1$ ；从 u 到原点简化为 $d_H(0, u) = 2 \operatorname{arctanh}(\|u\|)$ 。

一句话直觉：两点靠近球心时距离接近欧氏距离；越靠近边界，分母趋于 0，距离急速放大——精确刻画双曲空间的指数拉伸。

T-2.6.5 【易 · 代入 · Poincaré 球双曲距离计算】 考虑 2 维 Poincaré 球 $\mathbb{B}^2$ ，设三个点：

$$o = (0, 0), \quad a = (0.5, 0), \quad b = (0.9, 0)$$

- (a) 分别用 $d_H(0, v) = 2 \operatorname{arctanh}(\|v\|)$ 计算 $d_H(o, a)$ 和 $d_H(o, b)$ （利用 $\operatorname{arctanh}(r) = \frac{1}{2} \ln \frac{1+r}{1-r}$ ，保留 4 位小数）；
- (b) 对比欧氏距离 $\|o - a\| = 0.5$ 和 $\|o - b\| = 0.9$ ，计算双曲/欧氏距离的比值，说明靠近边界时的“拉伸效果”；
- (c) 再计算 $d_H(a, b)$ （用一般双曲距离公式， $\|a - b\| = 0.4$ ， $\|a\|^2 = 0.25$ ， $\|b\|^2 = 0.81$ ）并与欧氏距离 0.4 对比。三对点中哪对双曲/欧氏比值最大？

T-2.6.6 【难 · 证明 · 原点到边界双曲距离趋于无穷】 证明：从原点 0 沿 x_1 轴到点 $(r, 0, \dots, 0)$ ($r < 1$) 的双曲距离为 $d_H(0, r\hat{e}_1) = 2 \operatorname{arctanh}(r)$ ，并由此说明当 $r \rightarrow 1$ 时双曲距离趋于无穷。

- (a) 沿 x_1 轴上的路径，Poincaré 度量 $ds = 2 dt / (1 - t^2)$ 。写出路径长度积分 $\int_0^r \frac{2}{1 - t^2} dt$ ；

- (b) 用部分分数分解： $\frac{2}{1 - t^2} = \frac{1}{1 - t} + \frac{1}{1 + t}$ ，完成积分，得到 $\ln \frac{1 + r}{1 - r} = 2 \operatorname{arctanh}(r)$ ；

- (c) 验证这与一般双曲距离公式 $\operatorname{arcosh}(1+2r^2/(1-r^2))$ 一致 (利用恒等式 $\operatorname{arcosh}(1+2t^2/(1-t^2)) = 2 \operatorname{arctanh}(t)$);
- (d) 计算 $2 \operatorname{arctanh}(0.5)$ 、 $2 \operatorname{arctanh}(0.9)$ 、 $2 \operatorname{arctanh}(0.99)$ 的具体数值, 直观验证”趋近边界, 距离急速增大”。

T-2.6.7【中·应用·层级深度与双曲坐标对应】 WordNet 中”实体 → 动物 → 哺乳动物 → 犬科 → 家犬 → 金毛犬”共 6 层 (第 0 层为根节点)。

- (a) 在 Poincaré 球模型中, 根节点”实体”放置在原点 $\|x\| = 0$ 处, 设每层深度对应双曲距离增量 $\Delta d_H = 1.0$ 。用 $r = \tanh(L/2)$ 计算各层节点 ($L = 0, 1, 2, 3, 4, 5$) 的欧氏半径 r ;
- (b) 验证随层数加深 r 如何接近 1, 解释为什么叶节点”永远到不了边界”;
- (c) 同一深度 (第 5 层) 的两个兄弟节点, 在 Poincaré 球上的双曲距离如何随它们到球心距离的增大而变化? 用双曲距离公式的分母 $(1 - \|u\|^2)(1 - \|v\|^2)$ 定性说明。

公式 11 · 双曲球体积指数增长

$$\operatorname{Vol}_H(B(r)) \propto \sinh^{d-1}(r) \sim \frac{1}{2^{d-1}} e^{(d-1)r}, \quad r \rightarrow \infty$$

体积随半径 r 指数增长, 与 b -叉树节点数的指数增长 $O(b^r)$ 匹配 (令 $b = e^{d-1}$)。

一句话直觉: 双曲空间的体积增长速率天然匹配树的节点数增长, $d = 5$ 维已能容纳 WordNet 全部名词。

T-2.6.8【易·代入·双曲 vs 欧氏体积增长对比】 分别计算欧氏球和双曲球 ($d = 2$) 在半径 $r = 1, 2, 5, 10$ 时的体积 (比例):

- (a) 欧氏: $\operatorname{Vol}_E(B(r)) \propto r^2$ 。给出 $r = 1, 2, 5, 10$ 时的相对体积 (以 $r = 1$ 为基准);
- (b) 双曲 ($d = 2$): $\operatorname{Vol}_H(B(r)) \propto \sinh(r)$ 。给出 $r = 1, 2, 5, 10$ 时的相对体积;
- (c) 对比 (a)(b) 在 $r = 10$ 时的差距。用一句话说明为什么”双曲空间的体积增长速率天然匹配树的节点数增长”。

T-2.6.9【中·工程·为什么主流 LLM 仍用欧氏空间?】 数学卷 § 2.6 指出双曲嵌入在强层级数据 (本体树、分子图) 上有明确收益, 但主流 LLM (GPT-4、LLaMA-3) 仍使用欧氏空间。

- (a) 构造一个既有层级结构 (is-a) 又有网状联想 (associate-with) 的语义关系例子 (如”狗 → 哺乳动物”层级, “狗 ↔ 骨头”联想);
- (b) 在纯双曲嵌入中, “狗”和”骨头”都是叶节点, $\|u\| = 0.95$, $\|v\| = 0.95$, 欧氏距离 $\|u - v\| = 0.1$ 。计算双曲距离。对比中间层节点 ($\|u'\| = \|v'\| = 0.5$, 欧氏距离同为 0.1) 的双曲距离。两者相差多少倍?
- (c) 用两句话解释为什么欧氏空间对”混合拓扑 (层级 + 网状)” “比双曲空间更稳健, 以及 LLaMA-3 等主流模型坚持欧氏空间的实际原因。

T-2.6.10【难·画图直觉·Poincaré圆盘层级结构图】请在下方草稿区粗略画出 Poincaré 圆盘 (2D Poincaré 球), 标注以下内容:

- 圆盘边界 ($\|x\| = 1$, 虚线, 表示“无限远”)
- 根节点 (实体) 放置在圆心附近
- 第 1 层子节点 (动物、植物、器械) 放置在中圈
- 第 2-3 层叶节点 (金毛犬、玫瑰等) 靠近圆盘边界
- 标注两个兄弟节点 (同层) 之间的双曲距离示意 (比较大)

画完后用两句话回答: 为什么“层次越深节点越靠近边界”在双曲度量下自然对应“节点之间距离越大”?

解答 § 2.2

解答 T-2.2.1【易·代入·余弦相似度基础计算】 (a) 内积: $u^T v = 1 \times 2 + 2 \times 0 + 3 \times (-1) = 2 + 0 - 3 = -1$ 。

模长: $\|u\| = \sqrt{1 + 4 + 9} = \sqrt{14} \approx 3.7417$; $\|v\| = \sqrt{4 + 0 + 1} = \sqrt{5} \approx 2.2361$ 。

(b) $\cos(u, v) = -1 / (3.7417 \times 2.2361) = -1 / 8.3666 \approx -0.1195$ 。

值接近 0 (轻微负), 两词在语义上几乎无关 (方向近似正交, 略偏反向)。

(c) $v' = 2u = (2, 4, 6)^T$:

$$\cos(u, v') = \frac{u^T(2u)}{\|u\| \cdot \|2u\|} = \frac{2\|u\|^2}{\|u\| \cdot 2\|u\|} = 1$$

一句话: 余弦相似度对向量的正标量缩放完全不变, 因为分子分母同时乘以同一个因子, 约掉后不影响结果——这正是余弦相似度“只关注方向”的数学含义。

解答 T-2.2.2【中·工程·余弦 vs 欧氏: LLM 嵌入的实战选择】 (a) 欧氏距离:

$$\|e_{\text{cat}} - e_{\text{dog}}\| = \|(2.4, 3.2)^T\| = \sqrt{5.76 + 10.24} = \sqrt{16} = 4.0$$

余弦相似度: 注意 $e_{\text{dog}} = 0.2 \times e_{\text{cat}}$ (比例关系), 故两向量方向完全相同:

$$\cos(e_{\text{cat}}, e_{\text{dog}}) = \frac{3.0 \times 0.6 + 4.0 \times 0.8}{\sqrt{9 + 16} \times \sqrt{0.36 + 0.64}} = \frac{1.8 + 3.2}{5.0 \times 1.0} = \frac{5.0}{5.0} = 1.0$$

(b) 矛盾的根源: e_{dog} 是 e_{cat} 的 0.2 倍——两词语义相同 (方向一致, 余弦 = 1), 但模长相差 5 倍, 导致欧氏距离 = 4.0。

在 LLM 嵌入层中, 高频词 (如 “the”、“is”) 因被大量梯度更新而模长系统偏大, 低频词模长偏小。若用欧氏距离, 模长差异会被误读为语义差异: 两个语义完全相同的词, 高频版本和低频版本之间的欧氏距离可能很大, 导致检索错误。

(c) 标准做法是先 L2-归一化 ($\tilde{e} = e / \|e\|$), 然后计算归一化向量的内积, 等价于余弦相似度:

$$\tilde{e}_{\text{cat}}^T \tilde{e}_{\text{dog}} = \frac{e_{\text{cat}}^T e_{\text{dog}}}{\|e_{\text{cat}}\| \|e_{\text{dog}}\|} = \cos(e_{\text{cat}}, e_{\text{dog}})$$

归一化消除模长（词频偏置）噪声，保留语义方向信号。在向量数据库（FAISS、Pinecone 等）中，这是 embedding 插入前的标准预处理步骤。

解答 T-2.2.3 【中 · 判错 · 余弦相似度是”距离”？】 (a) 度量（metric）需满足：(1) 非负性 $d(a, b) \geq 0$ ；(2) 同一性 $d(a, a) = 0$ ；(3) 对称性 $d(a, b) = d(b, a)$ ；(4) 三角不等式 $d(a, c) \leq d(a, b) + d(b, c)$ 。

定义余弦距离 $d_{\cos}(u, v) = 1 - \cos(u, v)$ 。

- 非负性： $\cos \in [-1, 1]$ ，故 $d_{\cos} \in [0, 2]$ ，满足。
- 同一性： $d_{\cos}(u, u) = 1 - 1 = 0$ ，满足；但 $d_{\cos}(u, v) = 0$ 不蕴含 $u = v$ （方向相同但模长不同的向量余弦 = 1），违反严格同一性。
- 对称性： $\cos(u, v) = \cos(v, u)$ ，满足。
- 三角不等式：不一定满足（见 (b) 的反例）。

(b) 反例：取

$$a = (1, 0)^T, \quad b = (1, 1)^T / \sqrt{2} \approx (0.707, 0.707)^T, \quad c = (0, 1)^T$$

计算余弦距离： $\cos(a, b) = 1/\sqrt{2} \approx 0.707$ ， $d_{\cos}(a, b) = 1 - 0.707 = 0.293$ ； $\cos(b, c) = 1/\sqrt{2} \approx 0.707$ ， $d_{\cos}(b, c) = 0.293$ ； $\cos(a, c) = 0$ ， $d_{\cos}(a, c) = 1.0$ 。

检验： $d_{\cos}(a, c) = 1.0 > 0.293 + 0.293 = 0.586$ 。三角不等式被违反。

(c) 尽管余弦距离不满足度量公理，工程中用余弦相似度的原因是：检索系统需要的是相对排序（哪对向量更相似），而非满足度量公理的绝对距离。只要余弦相似度能稳定反映语义接近程度，排序结果可靠即可。此外，余弦相似度在高维嵌入中的信噪比远高于欧氏距离，是最实用的语义相似度度量。

解答 T-2.2.4【易 · 代人 · softmax 归一化计算】 (a) 计算 $e^{s_i} : e^{2.0} \approx 7.3891, e^{0.5} \approx 1.6487, e^{-1.0} \approx 0.3679, e^{1.0} \approx 2.7183$ 。

分母： $Z = 7.3891 + 1.6487 + 0.3679 + 2.7183 = 12.1240$

$$P(w_1) \approx 0.6094, \quad P(w_2) \approx 0.1360, \quad P(w_3) \approx 0.0303, \quad P(w_4) \approx 0.2242$$

(b) $\tau = 0.5$ （分数 4.0, 1.0, -2.0, 2.0）： $Z \approx 54.598 + 2.718 + 0.135 + 7.389 = 64.840$ ， $P(w_1) \approx 0.8421$ ——分布变尖，最高分词主导。

$\tau = 2.0$ （分数 1.0, 0.25, -0.5, 0.5）： $Z \approx 2.718 + 1.284 + 0.607 + 1.649 = 6.258$ ， $P(w_1) \approx 0.4343$ ——分布变平，低分词获得更多概率质量。

规律： $\tau < 1$ 使分布集中（greedy decoding 效果）， $\tau > 1$ 使分布均匀（更”创意”的采样）。

(c) $|V| = 50000$ 时每次 forward 需 50000 次乘法（计算所有 $u_c^T v_w$ ）。负采样 $k = 5$ 只需 $1 + 5 = 6$ 次。加速比 $\approx 50000/6 \approx 8333$ 倍。

解答 T-2.2.5 【中 · 变形 · Skip-gram 目标函数展开】 (a) 展开 $\log P(c | w_t)$:

$$\log P(c | w_t) = u_c^T v_{w_t} - \log \sum_{c'=1}^V \exp(u_{c'}^T v_{w_t})$$

对 v_{w_t} 求梯度:

$$\frac{\partial \log P(c | w_t)}{\partial v_{w_t}} = u_c - \sum_{c'=1}^V P(c' | w_t) u_{c'} = u_c - \mathbb{E}_{c' \sim P(\cdot | w_t)}[u_{c'}]$$

即“上下文词向量 u_c “减去”模型对所有上下文词向量的加权期望”——梯度方向是把 v_{w_t} 推向真实上下文向量，同时远离期望方向。

(b) 每步需计算 $\sum_{c'=1}^V P(c' | w_t) u_{c'}$ ，即对所有 V 个词的向量做加权求和，复杂度 $O(Vd)$ 。对 $V = 50000$ 、 $d = 512$ ，每步约 2.56×10^7 次浮点运算，在 10^9 token 语料上完全不可接受——这正是负采样以 $O(kd)$ 替代的动机。

解答 T-2.2.6 【易 · 代入 · 负采样频率惩罚 $f^{3/4}$ 】 (a) $f^{3/4}$ 权重 (比例):

- “the”: $10000^{3/4} = (10^4)^{0.75} = 10^3 = 1000$
- “cat”: $200^{0.75} = e^{0.75 \ln 200} = e^{0.75 \times 5.298} = e^{3.974} \approx 53.2$
- “xylophone”: $4^{0.75} = 2^{1.5} \approx 2.83$

比例约为 $1000 : 53.2 : 2.83$ 。

(b) 原始词频比例: $10000 : 200 : 4 = 2500 : 50 : 1$ 。

(c) $3/4$ 次幂压低了高频词的相对权重 (“the” 在原始频率下占 98%， $f^{3/4}$ 后占约 95%)，同时抬高了低频词的相对权重 (“xylophone” 相对 “cat” 的比例从 $4/200 = 2\%$ 升到 $2.83/53.2 \approx 5.3\%$)。好处：高频词（如冠词）不会因频繁出现被过度“排斥”为负样本，低频词有更多机会参与训练，使长尾词的嵌入更准确。

解答 T-2.2.7 【难 · 证明 · 负采样梯度分解为“拉近 + 推远”】 (a) sigmoid 导数: $\sigma'(x) = \sigma(x)(1 - \sigma(x))$ 。

$$\text{证明: } \sigma'(x) = \frac{e^{-x}}{(1 + e^{-x})^2} = \frac{1}{1 + e^{-x}} \cdot \frac{e^{-x}}{1 + e^{-x}} = \sigma(x)(1 - \sigma(x))。$$

(b) 对第一项，令 $z = u_c^T v_w$ ，链式法则:

$$\frac{\partial}{\partial v_w} \log \sigma(u_c^T v_w) = \frac{\sigma'(z)}{\sigma(z)} \cdot u_c = (1 - \sigma(z)) u_c = (1 - \sigma(u_c^T v_w)) u_c$$

(c) 对第二项，令 $z' = -u_{c'}^T v_w$:

$$\frac{\partial}{\partial v_w} \log \sigma(-u_{c'}^T v_w) = \frac{\sigma'(z')}{\sigma(z')} \cdot (-u_{c'}) = (1 - \sigma(-u_{c'}^T v_w))(-u_{c'}) = -\sigma(u_{c'}^T v_w) u_{c'}$$

(利用 $1 - \sigma(-x) = \sigma(x)$ 。)

(d) 合并：

$$\frac{\partial \ell}{\partial v_w} = \underbrace{(1 - \sigma(u_c^T v_w)) u_c}_{\text{拉近正样本 (吸引力)}} + \underbrace{(-\sigma(u_{c'}^T v_w)) u_{c'}}_{\text{推离负样本 (排斥力)}}$$

物理解读：

- 正样本项：若 v_w 与 u_c 内积小 ($\sigma \ll 1$)，梯度强，推动 v_w 沿 u_c 方向移动（靠近）；若已经足够靠近 ($\sigma \rightarrow 1$)，梯度衰减到 0。
- 负样本项：若 v_w 与 $u_{c'}$ 内积大 ($\sigma \approx 1$)，梯度强，推动 v_w 沿 $-u_{c'}$ 方向移动（远离）。

反复叠加，出现在相似上下文中的词被推进（形成语义聚类），不出现在相同上下文的词被推远（形成语义间距）——这就是词嵌入语义几何的来源。

解答 T-2.2.8 【易 · 代入 · 类比向量计算】 (a) $\delta = v_{\text{man}} - v_{\text{woman}} = (0.8 - 0.8, 0.3 - (-0.3), 0.1 - 0.1, 0 - 0)^T = (0, 0.6, 0, 0)^T$ 。

性别轴仅在第 2 分量有差异——非常干净的一维方向。

(b) $\hat{q} = v_{\text{king}} - v_{\text{man}} + v_{\text{woman}}$ ：

$$= (0.5 - 0.8 + 0.8, 0.4 - 0.3 + (-0.3), 0.9 - 0.1 + 0.1, 0.8 - 0 + 0)^T = (0.5, -0.2, 0.9, 0.8)^T$$

对比 $v_{\text{queen}} = (0.5, -0.4, 0.9, 0.8)^T$ ——第 2 分量略有偏差（-0.2 vs -0.4）。

(c) 内积 $\hat{q}^T v_{\text{queen}} = 0.25 + 0.08 + 0.81 + 0.64 = 1.78$ 。

$$\|\hat{q}\| = \sqrt{0.25 + 0.04 + 0.81 + 0.64} = \sqrt{1.74} \approx 1.3191; \|v_{\text{queen}}\| = \sqrt{0.25 + 0.16 + 0.81 + 0.64} = \sqrt{1.86} \approx 1.3638。$$

$$\cos(\hat{q}, v_{\text{queen}}) = \frac{1.78}{1.3191 \times 1.3638} \approx \frac{1.78}{1.7994} \approx 0.9892$$

结论：这组设计整齐的向量类比精度极高（ ≈ 0.989 ）。真实 Word2Vec 的类比精度通常在 0.6–0.8 之间。

(d) $\hat{q}^T v_{\text{king}} = 0.25 - 0.08 + 0.81 + 0.64 = 1.62$ ； $\|v_{\text{king}}\| \approx 1.3638$ （同 queen）。

$$\cos(\hat{q}, v_{\text{king}}) = \frac{1.62}{1.3191 \times 1.3638} \approx \frac{1.62}{1.7994} \approx 0.9003$$

仍高达 0.90，这就是为什么类比搜索时**必须排除查询词 king 自身**——否则搜索会把“king”排在“queen”之前返回。

解答 T-2.2.9 【中 · 反例 · 类比等式的失效场景】 (a) 性别轴的平移等变性依赖：“man”和“woman”在几乎所有非性别上下文中以相近的频率出现，即对任意非性别词 c ， $P(c | \text{man}) \approx P(c | \text{woman})$ 。训练压力使梯度更新将 king/queen 等词对沿性别方向对

齐，且这一模式在语料中足够频繁和对称。技术上：需要 $v_{\text{king}} - v_{\text{queen}} \approx v_{\text{man}} - v_{\text{woman}}$ ，即“性别”在所有词对上形成近似平行的平移向量。

(b) “Washington” 在语料中有两个主要共现模式：

- 地名模式：与 D.C.、Congress、federal、capital 等词高频共现；
- 人名模式：与 George、founding father、1776、Constitution 等词高频共现。

两类上下文叠加在同一个词向量上，使 $v_{\text{Washington}}$ 成为地名嵌入和人名嵌入的混合体。类比目标 $v_{\text{USA}} - v_{\text{China}} + v_{\text{Beijing}}$ 更偏向“纯地名-首都”语义，但“Washington”的词向量被人名语义拉偏，与目标向量的余弦相似度被稀释。结果是“Berlin”、“London”等无歧义首都名词的余弦相似度可能反而更高，类比失败。

(c) 在 BERT/LLaMA 的上下文嵌入中，“Washington”在“Washington D.C. is the capital”句子中的向量和“Washington signed the Declaration”里的向量完全不同（上下文相关）。类比等式 $v_A - v_B + v_C \approx v_D$ 依赖每个词有唯一静态向量，上下文相关嵌入打破了这一假设：同一词在不同语境中有不同的向量表示，向量加减不再对应稳定的“语义方向”操作，类比等式的成立率在上下文嵌入中大幅下降。

解答 § 2.3

解答 T-2.3.1 【易·代入·模长集中数值】 (a) 期望模长 $\approx \sqrt{d}$ ：

d	期望模长
4	2.0000
100	10.0000
768	27.7128
12288	110.8529

(b) $\text{std}[\|x\|] \approx 1/\sqrt{2} \approx 0.7071$ （由 Delta 方法： $\text{Var}[\|x\|] \approx \text{Var}[\|x\|^2]/(4\mathbb{E}[\|x\|^2]) = 2d/(4d) = 1/2$ ）。

相对标准差 $= 0.7071/\sqrt{d}$ ：

d	相对标准差
4	0.3536
100	0.0707
768	0.0255
12288	0.0064

(c) 随维度增加，模长的相对波动从 35% 降到不足 1%——高维高斯向量的模长几乎是“常数”。实践含义：在高维嵌入中，模长携带的主要信息是词频偏置（高频词因梯度更新次数多而模长系统偏大）而非语义差异。归一化到单位球面（余弦相似度）消除这一噪声，保留语义方向信号；而欧氏距离受模长影响，会把“词频差异”误读为“语义差异”。

解答 T-2.3.2【中·参数变形·超位置容量上界】 (a) 对 $d = 768, \sigma_{\cos} = 1/\sqrt{768} \approx 0.0361$ 。要以 99% 概率满足 $|\cos| < \varepsilon$ ，需：

$$\varepsilon \approx 2.576 \times \sigma_{\cos} = 2.576 \times 0.0361 \approx 0.093$$

即在 768 维空间中，“几乎正交”的门槛约为 $|\cos| < 0.093$ ——极其严格，几乎每两个随机向量都满足。

(b) $d = 100, \sigma_{\cos} = 0.1, P(|\cos| > 0.2) \approx P(|Z| > 2) \approx 0.0455$ 。

设有 n 个向量，共 $n^2/2$ 对。Union bound：

$$\frac{n^2}{2} \times 0.0455 \leq 0.01 \implies n^2 \leq \frac{0.02}{0.0455} \approx 0.44 \implies n \lesssim 0.66$$

Union bound 极度保守（对独立事件过于悲观）。实践工程估计：100 维空间实际可放约数百到数千个“几乎正交”方向，超出线性独立数 $d = 100$ 的量级。

(c) 根据 Welch bound， d 维空间最多约 $d(d+2)/3 \approx 3400$ 个互相 $|\cos| \leq 1/\sqrt{d}$ 的等角框架向量，远超 $d = 100$ 。稀疏自编码器在 100 维激活向量中找到超过 100 个独立特征方向，在理论上完全可能——这正是 Anthropic 等机构 SAE 实验的数学基础，也是 superposition 假说 (Elhage et al., 2022) 的核心论据。

解答 T-2.3.3【难·证明·集中不等式蕴含球壳现象】 (a) $\|x\|^2 = \sum_{i=1}^d x_i^2$ ，各 $x_i^2 \stackrel{\text{i.i.d.}}{\sim} \chi^2(1)$ （自由度 1 的卡方分布）。

$\mathbb{E}[x_i^2] = 1, \text{Var}[x_i^2] = 2$ ($\chi^2(1)$ 的方差)。

由线性性： $\mathbb{E}[\|x\|^2] = d, \text{Var}[\|x\|^2] = 2d; \|x\|^2 \sim \chi^2(d)$ 。

(b) 代入 $d = 1000, \varepsilon = 10$ （偏离 $\sqrt{1000} \approx 31.62$ 约 32%）：

$$P(|\|x\| - \sqrt{1000}| > 10) \leq 2e^{-10^2/4} = 2e^{-25} \approx 2 \times 1.39 \times 10^{-11} \approx 2.77 \times 10^{-11}$$

概率极小——约十亿分之一的量级。

(c) 即使偏离期望模长 32% 的可能性也不到 3×10^{-11} ，这意味着：高斯向量几乎以概率 1 落在半径 $\sqrt{d}$ 附近的薄球壳内，球的内部（模长远小于 $\sqrt{d}$ ）和球的外部（模长远大于 $\sqrt{d}$ ）都几乎是空的。

对词嵌入初始化的启示：通常用 $\mathcal{N}(0, 1/d)$ （而非 $\mathcal{N}(0, 1)$ ）初始化——这样每个分量的方差为 $1/d$ ，向量模长期望为 $\sqrt{d \cdot 1/d} = 1$ （单位球面附近），与 softmax 的数值稳定性更好匹配。

解答 T-2.3.4【易·代入·内积分布与近似正交化】 (a) $x^T y = \sum_{i=1}^d x_i y_i$ ，各 $x_i y_i$ 独立， $\mathbb{E}[x_i y_i] = 0, \text{Var}[x_i y_i] = \mathbb{E}[x_i^2] \mathbb{E}[y_i^2] = 1$ 。由中心极限定理， d 个独立同分布均值 0、方差 1 的项之和的方差为 d ，故 $x^T y \sim \mathcal{N}(0, d)$ （近似）。

(b) $d = 1000$ 时， $\cos(x, y) \approx \mathcal{N}(0, 1/d), \sigma = 1/\sqrt{1000} \approx 0.0316$ 。

95% 置信区间： $\pm 1.96 \times 0.0316 = \pm 0.0620$ ，即 $\cos \in (-0.062, +0.062)$ 。

(c) 要求 $|\cos| < 0.1$ ，对应 $0.1/0.0316 \approx 3.16\sigma$ 。

$$P(|\cos| < 0.1) = P(|Z| < 3.16) \approx 1 - 2\Phi(-3.16) \approx 1 - 0.0016 = 99.84\%。$$

在 $d = 1000$ 维下，随机选两个高斯向量，约 99.8% 的概率它们是“近似正交”的 ($|\cos| < 0.1$)。这就是高维空间能容纳大量“几乎独立”方向的基础。

解答 T-2.3.5 【中·画图直觉·余弦分布随维度变化】 参考草图要点 (评分要点):

- 横轴: $\cos \in [-1, 1]$; 纵轴: 概率密度 (均以峰值 $\cos = 0$ 为中心的对称正态曲线);
- $d = 2$: 标准差 ≈ 0.707 , 曲线极宽, 在 $[-1, 1]$ 内分布均匀, 几乎是平的;
- $d = 100$: 标准差 ≈ 0.1 , 曲线中等宽度, 大部分概率在 $[-0.3, 0.3]$ 内;
- $d = 1000$: 标准差 ≈ 0.032 , 曲线极度尖锐, 99% 以上概率落在 $(-0.1, 0.1)$ 内。

两句话回答:

高维空间能容纳指数级多的“几乎正交”方向, 是因为任意两个随机方向的余弦相似度以极高概率趋于 0 (方差 $\sim 1/d$ 随维度减小)——这意味着 $d = 1000$ 维空间里可以塞进远超 1000 个“互不干扰”的方向向量, 每对之间的余弦相似度都接近 0。

这支撑了 Transformer 的 superposition 现象: 激活向量 (如 $d = 512$ 维的残差流) 可以同时编码远超 512 个稀疏特征, 只要这些特征对应的方向互相“几乎正交”, 它们的叠加不会产生过多的串扰——这正是 Anthropic 的稀疏自编码器 (SAE) 实验所揭示的机制。

解答 T-2.3.6 【易·代入·JL 降维实例计算】 (a) 代入 $n = 10000$, $\varepsilon = 0.1$, $\delta = 0.01$:

$$k \geq \frac{16 \ln 10000 - 8 \ln 0.01}{0.01} = \frac{16 \times 9.2103 - 8 \times (-4.6052)}{0.01} = \frac{147.365 + 36.842}{0.01} = \frac{184.207}{0.01} = 18422$$

理论下界 $k \geq 18422$ (取整)。

(b) 理论压缩比 $D/k = 1024/18422 \approx 0.056$ ——理论上甚至要扩维, 说明 Union bound 非常保守。

Union bound 保守的原因: 它假设所有点对的失真事件相互独立, 实际上这些事件高度相关 (共享端点的点对), 真实失败概率远低于 Union bound 的估计。

(c) 实践取 $k = 256$ 是在:

- 牺牲: 理论上的严格保证 ($\varepsilon = 0.1$ 对全部 10^8 点对不再严格成立);
- 换取: 更小的存储占用 (节省 4 倍内存)、更快的矩阵乘法 (SIMD 向量化效率提升), 以及 ANN (近似最近邻) 在实际检索任务中已经足够的经验精度。精度-速度-存储三角权衡, 无绝对最优解。

解答 T-2.3.7 【难·证明·JL 引理目标维度推导】 (a) 设 Φ 的第 ℓ 行为 $\phi_\ell^T \sim \mathcal{N}(0, I_d/k)$:

$$\mathbb{E}[(\Phi z)_\ell^2] = \mathbb{E}[(\phi_\ell^T z)^2] = z^T \mathbb{E}[\phi_\ell \phi_\ell^T] z = z^T (I_d/k) z = \|z\|^2/k$$

故 $\mathbb{E}[\|\Phi z\|^2] = \sum_{\ell=1}^k \|z\|^2/k = \|z\|^2$ ——投影后期望保距。

(b) $\|\Phi z\|^2 = \sum_{\ell} (\phi_{\ell}^T z)^2$, 每项 $\phi_{\ell}^T z \sim \mathcal{N}(0, \|z\|^2/k)$, 标准化后 $k(\phi_{\ell}^T z)^2/\|z\|^2 \sim \chi^2(1)$, 对 k 项求和: $k\|\Phi z\|^2/\|z\|^2 \sim \chi^2(k)$, 即 $\|\Phi z\|^2/\|z\|^2 \sim \chi^2(k)/k$ 。

由集中不等式, 单对点距离失真超 ε 的概率 $\leq 2e^{-k\varepsilon^2/8}$ 。

(c) Union bound 对 $\binom{n}{2} < n^2/2$ 对点:

$$n^2 e^{-k\varepsilon^2/8} \leq \delta \implies k \geq \frac{8}{\varepsilon^2} \ln \frac{n^2}{\delta} = \frac{16 \ln n - 8 \ln \delta}{\varepsilon^2}$$

忽略 $\ln \delta$ 常数, 得 $k = O(\log n/\varepsilon^2)$ 。□

(d) k 与原始维度 D 完全无关——无论原始嵌入是 512 维、1024 维还是 4096 维, 只要文档数 n 和精度 ε 固定, 所需投影维度 k 相同。在 RAG 系统中, 这意味着检索精度由文档库规模和精度要求决定, 增大嵌入原始维度不能提升检索准确率 (超过某个阈值后), 反而增加存储和计算开销。实践中 512 维对百万级文档库的 ANN 搜索已足够。

解答 T-2.3.8 【中·判错·维度越高检索越准确 ?】 (a) 两处错误:

错误 1 (JL 引理角度): JL 引理表明, 检索所需目标维度 $k = O(\log n/\varepsilon^2)$ 与原始嵌入维度 D 完全无关。增大 D 不能减小所需的 k , 也不能提升保距性能——决定检索精度的是文档数量 n 和精度要求 ε , 不是 D 。

错误 2 (维度诅咒角度): 高维空间中, 欧氏最近邻的“区分度”随维度增加而退化——最近邻和最远邻的距离之差相对于平均距离趋于 0, “最近邻”概念失去意义 (Beyer et al., 1999)。

(b) $d = 1000$ 下, 两随机单位向量欧氏距离期望 $\approx \sqrt{2} \approx 1.414$, 标准差 ≈ 0.022 。

对 $n = 1000$ 个点, 最近邻与最远邻之间距离差约 $2 \times 0.022 \approx 0.044$, 相对于平均距离 1.414 仅约 3%, 即约 1 个标准差的差异——“最近邻”几乎和“最远邻”一样远, 欧氏距离的区分能力极弱。

(c) 维度从 1024 降到 256 的实际权衡:

- 代价: 理论严格保距保证略有放松, 极端情况下某些点对的距离误差可能超过 10% (但在实际 ANN 任务中几乎不可察觉);
- 收益: 内存占用降低 4 倍, 矩阵乘法速度提升约 4 倍 (BLAS GEMM 的维度依赖), 索引构建时间大幅缩短, 冷启动延迟降低。在百万文档规模下, 256 维的检索准确率 (Recall@10) 通常与 1024 维相差不超过 1-2 个百分点。

解答 § 2.6

解答 T-2.6.1【易·代入·指数增长 vs 多项式增长·维度瓶颈】 (a) 节点总数 $N = 2^{L+1} - 1$:

L	N
5	63
10	2047
15	65535

(b) 欧氏维度下界: $d \geq L \ln 2 / \ln(2L)$ (以自然对数):

L	$L \ln 2$	$\ln(2L)$	d 下界
5	3.466	$\ln 10 = 2.303$	≈ 1.50 (取整 2)
10	6.931	$\ln 20 = 2.996$	≈ 2.31 (取整 3)
15	10.397	$\ln 30 = 3.401$	≈ 3.06 (取整 4)

注: 装填论证给出的是粗略下界; 更严格分析给出 $d = \Omega(L)$, 即欧氏维度随深度线性增长, 实践中 $L = 15$ 的深树需要数十维才能高精度嵌入。

(c) 双曲空间的体积随半径指数增长, 与 b -叉树的节点数增长完全匹配, 只需 $d = 2$ 维就能容纳深树 (Nickel & Kiela, 2017 在 2 维 Poincaré 圆盘上以超过 200 维欧氏嵌入的精度重建了 WordNet 层级结构) —— 这是双曲嵌入在层级数据上的核心优势: 用最少的维度承载最深的层级。

解答 T-2.6.2 【中 · 变形 · 树深度与嵌入维度的关系】 (a) 三叉树节点数 $N \approx 3^L$ (大 L 时)。仿照二叉树推导, 将 $\ln 2$ 替换为 $\ln 3$:

$$(2L)^d \geq 3^L \implies d \ln(2L) \geq L \ln 3 \implies d \geq \frac{L \ln 3}{\ln(2L)}$$

(b) $L = 10$, $N = 59049$, $\ln(2L) = \ln 20 = 2.996$:

- 完全二叉树: $d \geq 10 \ln 2 / 2.996 = 6.931 / 2.996 \approx 2.31$ (取整 3)
- 完全三叉树: $d \geq 10 \ln 3 / 2.996 = 10.986 / 2.996 \approx 3.67$ (取整 4)

三叉树比二叉树需要略多的欧氏维度, 因为节点数增长更快 (3^L vs 2^L)。

(c) 本质原因: 欧氏空间的“点装填密度”增长速率为 r^d (固定 d 时多项式 $\ln r$), 而树的节点数随深度 L (等价于半径) 指数增长。两种增长速率不匹配, 导致欧氏维度必须随深度线性提升才能跟上节点数。双曲空间的体积增长 $\sinh^{d-1}(r) \sim e^{(d-1)r}$ 是指数的, 因此一个固定低维的双曲空间就能匹配深层树的拓扑。

解答 T-2.6.3 【易 · 代入 · 共形因子放大效应】 (a) $\lambda = 2/(1 - r^2)$:

$\ x\ $	r^2	λ
0	0	2.0000
0.5	0.25	$2/0.75 \approx 2.6667$
0.9	0.81	$2/0.19 \approx 10.526$
0.99	0.9801	$2/0.0199 \approx 100.50$
0.999	0.998001	$2/0.001999 \approx 1000.5$

(b) 双曲弧长 $\approx \lambda \times \Delta r$ (欧氏位移 $\Delta r = 0.001$):

- 原点处 ($\lambda = 2$): 弧长 $\approx 2 \times 0.001 = 0.002$;
- $\|x\| = 0.99$ (叶节点, $\lambda \approx 100.5$): 弧长 $\approx 100.5 \times 0.001 = 0.1005$ 。

两者之比： $0.1005/0.002 = 50.25$ ——叶节点附近，同样 0.001 的欧氏位移对应 50 倍以上的双曲距离。

(c) Poincaré 球类似”等角投影 (conformal projection) “：角度 (方向关系) 被保留，但面积 (体积) 被压缩。无限双曲空间被压进有限圆盘——类似把无限大的地球平面图压入有限的圆盘显示，边界区域被极度压缩。这与墨卡托投影相反 (墨卡托把极地拉伸到无穷大)，Poincaré 球把”双曲无限”压进有限欧氏圆盘。

解答 T-2.6.4【中·判错·Poincaré 球的”边界可达”？】 (a) 错误：欧氏距离有限 ($\|v\| < 1$) 不等于双曲距离有限。Poincaré 球的双曲距离由黎曼度量 $ds = 2 dt/(1 - t^2)$ 积分得到，不是欧氏距离。从原点到 $(r, 0, \dots, 0)$ 的双曲距离 $d_H = 2 \operatorname{arctanh}(r)$ ，当 $r \rightarrow 1$ 时：

$$\operatorname{arctanh}(r) = \frac{1}{2} \ln \frac{1+r}{1-r} \xrightarrow{r \rightarrow 1} +\infty$$

因此双曲距离趋于无穷，边界在双曲度量下不可达，即使欧氏距离只有一点点。

(b) 具体数值：

- $2 \operatorname{arctanh}(0.9) = \ln(1.9/0.1) = \ln 19 \approx 2.9444$
- $2 \operatorname{arctanh}(0.99) = \ln(1.99/0.01) = \ln 199 \approx 5.2933$
- $2 \operatorname{arctanh}(0.999) = \ln(1.999/0.001) = \ln 1999 \approx 7.6009$

每增加一个 9 ($0.9 \rightarrow 0.99 \rightarrow 0.999$)，双曲距离增加约 $\ln 10 \approx 2.3$ ——指数放大。

(c) 这一性质天然对应树的层级：随层数加深，节点距球心的双曲距离线性增加 (每层 $\Delta d_H = \text{const}$)，但欧氏半径 $r = \tanh(\text{const} \times L/2)$ 以递减速率逼近 1，永远达不到边界。越深层的节点欧氏半径越靠近 1，对应双曲距离越大，叶节点之间被自动”隔离”在双曲空间的远处——这与树中叶节点之间路径距离大的拓扑性质完美对应。

解答 T-2.6.5【易·代入·Poincaré 球双曲距离计算】 (a) 用 $d_H(0, v) = 2 \operatorname{arctanh}(\|v\|)$ ：

- $d_H(o, a), \|a\| = 0.5$: $2 \operatorname{arctanh}(0.5) = \ln \frac{1.5}{0.5} = \ln 3 \approx 1.0986$
- $d_H(o, b), \|b\| = 0.9$: $2 \operatorname{arctanh}(0.9) = \ln \frac{1.9}{0.1} = \ln 19 \approx 2.9444$

(b) 比值：

- $o \rightarrow a$: 双曲 1.0986 / 欧氏 0.5 = 2.197
- $o \rightarrow b$: 双曲 2.9444 / 欧氏 0.9 = 3.271

靠近边界，比值增大——空间被”拉伸”效果越来越强。

(c) $d_H(a, b)$: $\|a - b\|^2 = 0.16$, $1 - \|a\|^2 = 0.75$, $1 - \|b\|^2 = 0.19$:

$$d_H(a, b) = \operatorname{arcosh}\left(1 + \frac{2 \times 0.16}{0.75 \times 0.19}\right) = \operatorname{arcosh}\left(1 + \frac{0.32}{0.1425}\right) = \operatorname{arcosh}(3.2456)$$

$$= \ln(3.2456 + \sqrt{3.2456^2 - 1}) = \ln(3.2456 + 3.0877) = \ln 6.3333 \approx 1.8452$$

欧氏距离 0.4，比值 $1.8452/0.4 = 4.61$ 。

三对中比值最大的是 $a \rightarrow b$ (两点都靠近边界，双曲空间在边界附近叠加放大效应)。

解答 T-2.6.6 【难·证明·原点到边界双曲距离趋于无穷】 (a) 沿 x_1 轴, $x = (t, 0, \dots, 0)$, $\|x\| = t$, Poincaré 度量 $ds = 2|dt|/(1-t^2)$ (从 $ds^2 = 4dt^2/(1-t^2)^2$ 直接取平方根)。路径长度:

$$d_H(0, r\hat{e}_1) = \int_0^r \frac{2}{1-t^2} dt$$

(b) 部分分数: $\frac{2}{1-t^2} = \frac{1}{1-t} + \frac{1}{1+t}$

$$\int_0^r \left(\frac{1}{1-t} + \frac{1}{1+t} \right) dt = \left[-\ln(1-t) + \ln(1+t) \right]_0^r = \ln \frac{1+r}{1-r} = 2 \operatorname{arctanh}(r) \quad \square$$

(c) 一般公式: 令 $t = r$, 验证恒等式 $\operatorname{arcosh}(1 + 2t^2/(1-t^2)) = 2 \operatorname{arctanh}(t)$:

令 $u = 2 \operatorname{arctanh}(t)$, 则 $e^u = (1+t)^2/(1-t)^2$ (由 $\operatorname{arctanh}(t) = \frac{1}{2} \ln \frac{1+t}{1-t}$ 推出)。

更简洁的验证: $\cosh(2 \operatorname{arctanh}(t)) = 1 + 2t^2/(1-t^2)$ (可直接代入 $t = 0.5$ 数值验证: $\cosh(\ln 3) = (3 + 1/3)/2 = 5/3 = 1 + 2 \times 0.25/0.75$)。□

(d) 具体数值:

- $2 \operatorname{arctanh}(0.5) = \ln 3 \approx 1.0986$
- $2 \operatorname{arctanh}(0.9) = \ln 19 \approx 2.9444$
- $2 \operatorname{arctanh}(0.99) = \ln 199 \approx 5.2933$

当 $r \rightarrow 1$, $\operatorname{arctanh}(r) \rightarrow +\infty$ ——边界确实“无限远”, 叶节点在有限时间内永远到达不了。这是 Poincaré 球能容纳无限深层级的几何根据。

解答 T-2.6.7 【中·应用·层级深度与双曲坐标对应】 (a) $r = \tanh(L \cdot \Delta d_H/2) = \tanh(L/2)$ ($\Delta d_H = 1.0$):

层 L	节点	$r = \tanh(L/2)$
0	根 (实体)	$\tanh(0) = 0.0000$
1	动物类	$\tanh(0.5) \approx 0.4621$
2	哺乳动物	$\tanh(1.0) \approx 0.7616$
3	犬科	$\tanh(1.5) \approx 0.9051$
4	家犬	$\tanh(2.0) \approx 0.9640$
5	金毛犬	$\tanh(2.5) \approx 0.9866$

(b) r 随层数加深迅速接近 1, 但永远不会到达 ($\tanh$ 的水平渐近线为 1) ——叶节点在边界附近, 验证了“层次越深越靠近边界”的直觉, 且层级可以无限深 (边界无限远)。

(c) 两个第 5 层兄弟节点 u, v 均有 $\|u\| \approx \|v\| \approx 0.987$, 故 $(1-\|u\|^2) \approx (1-\|v\|^2) \approx 0.026$ 。双曲距离公式分母:

$$(1-\|u\|^2)(1-\|v\|^2) \approx 0.026^2 = 0.000676$$

极小的分母使得即使欧氏距离 $\|u - v\|$ 很小，双曲距离也会被放大约 $1/0.000676 \approx 1479$ 倍（在 arcosh 的参数中）。这有效地将不同子树的叶节点”隔离”在双曲空间的远处，忠实反映了树上路径距离：不同子树的叶节点之间的树上路径必须绕过公共祖先，路径长度大；双曲距离的放大机制自动实现了这一点。

解答 T-2.6.8 【易·代入·双曲 vs 欧氏体积增长对比】 (a) 欧氏体积 $\propto r^2$ （以 $r = 1$ 为基准）：

r	相对体积
1	1.0
2	4.0
5	25.0
10	100.0

(b) 双曲体积 ($d = 2$) $\propto \sinh(r)$ ，其中 $\sinh(r) = (e^r - e^{-r})/2$ （以 $\sinh(1) \approx 1.175$ 为基准）：

r	$\sinh(r)$	相对体积
1	1.1752	1.0
2	3.6269	3.09
5	74.203	63.1
10	11013.2	9370

(c) $r = 10$ 时：欧氏体积比（相对 $r = 1$ ）为 100；双曲体积比为 9370——相差约 94 倍。且差距随 r 继续增大按指数放大（双曲 $\sim e^r/2$ ，欧氏 $\sim r^2$ ）。

一句话：双曲球体积随半径指数增长 ($\sim e^r$)，与完全 b -叉树的节点数 ($\sim b^L = e^{L \ln b}$) 增长速率一致；令 $b = e^{d-1}$ 即可匹配，这就是为什么固定维度的双曲空间能容纳任意深度的树结构。

解答 T-2.6.9 【中·工程·为什么主流 LLM 仍用欧氏空间？】 (a) 语义关系例子：

- 层级 (is-a)：金毛犬 $\rightarrow$ 家犬 $\rightarrow$ 犬科 $\rightarrow$ 哺乳动物 $\rightarrow$ 动物（单向的包含关系）
- 联想 (associate-with)：狗 $\leftrightarrow$ 骨头、狗 $\leftrightarrow$ 项圈、狗 $\leftrightarrow$ 主人（无方向的关联关系，没有层级）

这两类关系在自然语言中同时大量存在。

(b) 叶节点 ($\|u\| = \|v\| = 0.95$ ，欧氏距离 0.1)：

$$d_H(u, v) = \text{arcosh}\left(1 + \frac{2 \times 0.01}{(0.0975)^2}\right) = \text{arcosh}\left(1 + \frac{0.02}{0.009506}\right) = \text{arcosh}(3.1040) \approx 1.7985$$

中间层节点 ($\|u'\| = \|v'\| = 0.5$ ，欧氏距离 0.1)：

$$d_H(u', v') = \operatorname{arcosh}\left(1 + \frac{0.02}{0.5625}\right) = \operatorname{arcosh}(1.0356) \approx 0.2661$$

两者相差约 $1.7985/0.2661 \approx 6.8$ 倍：同样欧氏距离 0.1 的两对叶节点和中间层节点，双曲距离差 6.8 倍。

(c) 欧氏空间对混合拓扑更稳健的两个原因：

第一，欧氏空间无边界放大效应——“狗”和“骨头”作为叶节点，只要训练中余弦相似度高，就能在欧氏空间中相邻，不会因为都是叶节点（靠近 Poincaré 球边界）而被强制拉开，联想关系的距离编码不受层级深度干扰。

第二，自然语言同时包含层级、联想、类比等多种关系，欧氏空间对这些不同类型的关系用统一的线性代数处理，不对数据拓扑做强假设；而双曲空间为树形层级过度优化，对网状联想关系会产生系统性的距离扭曲——LLaMA-3 等通用语言模型的需求是处理混合拓扑，欧氏空间的鲁棒性优先级高于层级嵌入效率。

解答 T-2.6.10【难·画图直觉·Poincaré 圆盘层级结构图】 参考草图要点（评分要点）：

1. 外圆（虚线）： $\|x\| = 1$ 的边界，标注“边界（无限远，不可达）”；
2. 圆心处：小实心点，标注“根节点：实体”；
3. 第 1 圈（ $r \approx 0.46$ ）：均匀分布 3-4 个点，标注“动物、植物、器械”等；
4. 第 2-3 圈（ $r \approx 0.76 - 0.91$ ）：更多的节点，标注“哺乳动物、开花植物”等；
5. 靠近边界（ $r \approx 0.96 - 0.99$ ）：叶节点密集，标注“金毛犬、玫瑰”等；
6. 两个兄弟节点之间画一条弧（测地线），标注“兄弟间双曲距离：大”；
7. 父节点到子节点画弧，标注“父子间双曲距离：小（等于 $\Delta d_H = 1$ ）”。

两句话回答：

在双曲度量下，越深层的节点欧氏半径 r 越靠近 1，使分母 $(1 - r^2)$ 趋于 0，双曲距离公式的 arcosh 参数趋于无穷——层级越深，兄弟节点之间的双曲距离越大（即使欧氏距离相近），这自动实现了“不同子树的叶节点在语义空间中相互隔离”的效果。

同时，同一深度的兄弟节点“被放置在同一圈”，父节点到每个子节点的双曲距离固定为 Δd_H ，精确编码了树中“父子距离相等”的结构约束，而欧氏圆盘的有限体积和双曲空间的指数体积增长共同保证了节点数量再多也能被容纳。

§ 2.6 · v1.2 补题：跨越欧氏——当表示空间不再「平直」

导读：本节核心是双曲嵌入：欧氏空间体积多项式增长与树形结构指数节点增长之间的根本不匹配，如何被 Poincaré 球模型的指数体积增长所弥合，以及弯曲空间里梯度下降需要哪些额外工具。五题分别对应：欧氏维度瓶颈的下界推导、双曲距离公式的数值计算、Poincaré 球几何性质的辨析、黎曼梯度与欧氏梯度的比较、以及反类比——指出把双曲嵌入优势照搬到通用语言建模时哪些假设被违反。

题 1【轻·推导·欧氏嵌入的维度下界】 导读：树形结构节点数指数增长，而欧氏空间容量只多项式增长——这不是观感上的不匹配，是可以量化为下界的数学事实。

设深度为 L 、分支数为 b ($b \geq 2$) 的完全 b -叉树共有 $N = O(b^L)$ 个叶节点。

(a) 用 packing 论证说明：在 $\mathbb{R}^d$ 中，以原点为中心、半径为 r 的球内最多能放 $O(r^d)$ 个两两欧氏距离不低于 1 的点。（一句话量级论证即可，无需严格证明。）

(b) 利用 (a) 的结论，说明将 $N = O(b^L)$ 个叶节点嵌入 $\mathbb{R}^d$ 并保持互相距离时，需要

$$d \geq \Omega\left(\frac{L \log b}{\log L}\right)$$

即所需维度随树深度 L 接近线性增长。

(c) 对 $b = 2$ 、 $L = 12$ （近似 WordNet 名词层级深度）数值估算上述下界：至少需要多少维度？

(d) 若改用双曲空间，Nickel & Kiela (2017) 实验表明 5 维双曲嵌入已超过 200 维欧氏嵌入的层级重建精度。用 (b) 的下界解释为什么会有如此悬殊的维度差距。

教学注：这道题把「双曲嵌入更好」从一句经验观察转化为一个有数学支撑的必然结论：欧氏空间的多项式体积增长是维度瓶颈的根源，不是调参所能弥补的。

陷阱：

- 节点总数是 $O(b^L)$ 而不是 $O(L \cdot b)$ ，不要把指数和线性混淆
- packing 论证给出的是上界（球内最多多少点），对应嵌入所需维度的下界

题 2【中·计算·Poincaré 球距离公式】 导读：双曲距离公式的分母 $(1 - \|\mathbf{u}\|^2)(1 - \|\mathbf{v}\|^2)$ 决定了「靠近球边界时距离急剧拉大」的效应，数值感受比文字描述更直接。

在 Poincaré 球模型中，双曲距离公式为

$$d_{\mathbb{H}}(\mathbf{u}, \mathbf{v}) = \operatorname{arcosh}\left(1 + 2 \frac{\|\mathbf{u} - \mathbf{v}\|^2}{(1 - \|\mathbf{u}\|^2)(1 - \|\mathbf{v}\|^2)}\right)$$

设 $d = 2$ （二维 Poincaré 盘），考虑以下三对点：

- 对 A: $\mathbf{u}_A = (0, 0)$, $\mathbf{v}_A = (0.5, 0)$
- 对 B: $\mathbf{u}_B = (0.8, 0)$, $\mathbf{v}_B = (0.9, 0)$ （两点均靠近边界，欧氏距离相同均为 0.1）
- 对 C: $\mathbf{u}_C = (0.95, 0)$, $\mathbf{v}_C = (0.99, 0)$ （欧氏距离 0.04，更接近边界）

(a) 计算三对点的欧氏距离 $\|\mathbf{u} - \mathbf{v}\|$ 。

(b) 计算三对点各自的双曲距离 $d_{\mathbb{H}}(\mathbf{u}, \mathbf{v})$ （保留 4 位小数）。提示： $\operatorname{arcosh}(t) = \ln(t + \sqrt{t^2 - 1})$ 。

(c) 比较对 A、B、C 的欧氏距离与双曲距离之比。描述「靠近球边界」对双曲距离有何效应，用数字说明。

(d) 解释为什么 Poincaré 球用「径向坐标」（到原点的双曲距离）来对应树的层级深度，而非欧氏距离。

教学注：对 B 和 C 欧氏距离分别是 0.1 和 0.04，但双曲距离相差巨大——这个数字反差直接说明了为什么叶节点（接近边界）之间的「隔离」在双曲几何里是自动涌现的，

不需要额外约束。

陷阱：

- 计算对 C 时分母接近零， arcosh 的参数会非常大，先精确算分母再代入
- arcosh 公式要求参数 ≥ 1 ，验证 $1 + 2\|\Delta\|^2 / ((1 - \|\mathbf{u}\|^2)(1 - \|\mathbf{v}\|^2)) \geq 1$ 总是成立

题 3【中·概念辨析·黎曼度量张量与曲率】 导读：黎曼流形的核心工具是度量张量 g_p ——它在每个点局部定义「如何量距离」，决定了空间的曲率，进而决定了体积增长速率。

判断下列命题的真假，并说明理由（2-3 句话）：

- (a) 「欧氏空间是黎曼流形的特例，其度量张量在所有点处恒为 $g_{ij} = \delta_{ij}$ 。」
- (b) 「Poincaré 球的黎曼度量 $ds^2 = \frac{4\|dx\|^2}{(1-\|x\|^2)^2}$ 意味着，越靠近球边界，同样的欧氏位移对应的真实（双曲）距离越小。」
- (c) 「三角形内角和小于 180° 是双曲空间（负曲率）的特征；大于 180° 是正曲率（球面）的特征。」
- (d) 「在 Poincaré 球中，以球心 $\mathbf{0}$ 为中心、双曲半径为 r 的球的体积约正比于 $e^{(d-1)r}$ ，因此对所有深度 L 的树，只要选足够大的 r 就能嵌入任意分支数的树而无需增加维度 d 。」

教学注：(d) 是一个微妙的陷阱——维度 d 和半径 r 都影响容量，但增大 r 会让边界区域的数值梯度爆炸，训练稳定性付出代价，「无限增大 r 」并非免费的午餐。

陷阱：

- (b) 的因子 $\frac{4}{(1-\|x\|^2)^2}$ 是放大因子，越接近边界越大——方向是「边界附近双曲距离更大」而非更小
- (d) 需要区分「理论容量」和「可训练的优化稳定性」两个不同层面

题 4【重·计算·黎曼梯度与欧氏梯度的比较】 导读：在弯曲流形上做梯度下降需要把欧氏梯度「折算」为黎曼梯度，再沿测地线前进——这不只是工程细节，而是弯曲空间里优化的数学必要条件。

设一个标量损失函数 $f(\mathbf{x}) = \|\mathbf{x} - \mathbf{p}\|_2^2$ ，其中 $\mathbf{p} = (0.3, 0)$ 是目标点，当前点 $\mathbf{x}_0 = (0.5, 0)$ （均在二维 Poincaré 盘中）。

(a) 计算欧氏梯度 $\nabla_{\mathbf{x}} f$ 在 $\mathbf{x}_0$ 处的值。

(b) Poincaré 球上的黎曼梯度定义为

$$\operatorname{grad}_{\mathbb{H}} f(\mathbf{x}) = \frac{(1 - \|\mathbf{x}\|^2)^2}{4} \nabla_{\mathbf{x}} f$$

计算黎曼梯度在 $\mathbf{x}_0 = (0.5, 0)$ 处的值（保留 4 位小数），并与欧氏梯度对比其大小比值。

(c) 如果在 $\|\mathbf{x}\| = 0.99$ 的点处做同样的计算，黎曼梯度与欧氏梯度之比会如何变化？数值估算该比值（对相同的 f ）。

(d) 解释为什么靠近球边界时，双曲嵌入的训练对学习率极其敏感：若使用与内部点相同的学习率 η ，靠近边界的点会发生什么？

教学注：这道题用数字直观地展示「黎曼梯度修正」的量级——在 $\|\mathbf{x}\| = 0.99$ 时，修正因子约为 $(1 - 0.99^2)^2/4 \approx 0.0001/4$ ，梯度被极度压缩；反过来，若直接用欧氏梯度步长，边界处更新步长会爆炸。

陷阱：

- 黎曼梯度公式里 $(1 - \|\mathbf{x}\|^2)^2/4$ 是「缩小」因子（小于 1），对应流形上真实距离比欧氏坐标距离更大的补偿
- 不要把黎曼梯度公式里的 $\nabla_{\mathbf{x}} f$ 和指数映射混为一谈——黎曼梯度只是方向修正，指数映射才是把切向量映射回流形的步骤

题 5【重·反类比·双曲嵌入优势的适用边界】 导读：「5 维双曲超过 200 维欧氏」的惊人结论有明确的前提条件——当这些前提不满足时，弯曲空间的优化代价反而变成净负担。

阅读以下四个论断，判断哪条假设被违反，说明判断理由：

论断 A：「自然语言语义关系大量是 is-a 树形层级（如 WordNet），因此把 LLaMA 的嵌入层替换为双曲嵌入，模型性能必然提升。」

论断 B：「双曲嵌入的指数体积增长意味着维度越高，容量优势越大，所以应该首选尽可能大的双曲维度。」

论断 C：「对图神经网络中的社交网络图（节点度分布符合幂律），双曲嵌入比欧氏嵌入更适合，因为幂律分布和指数体积增长都有指数形式。」

论断 D：「双曲嵌入的黎曼梯度和指数映射在每步都比欧氏梯度多若干矩阵运算，但由于维度极低（5 维），每步的绝对计算量仍然可以忽略不计，不是实际瓶颈。」

(a) 对每个论断，指出它违反（或依赖但实际不成立）的哪一条假设，判断「成立 / 部分成立 / 不成立」。

(b) 写出双曲嵌入类比「欧氏空间是平直的，双曲空间是弯曲的」时**必须**满足的两条前提条件（数学层面）。

(c) 举一个跨界应用场景，其中数据内在拓扑**既非纯层级也非纯网状**，说明在此场景下选择几何空间时应考虑的权衡，并指出供应链隐喻在此处是否适用。

教学注：论断 A 违反的核心假设是「自然语言语义拓扑是纯树形的」——实际语言兼有层级（is-a）和网状联想（associate-with），混合拓扑下欧氏反而更稳健。论断 C 的错误在混淆了「幂律」和「指数」这两种不同的增长形式，幂律是多项式，不是指数。

陷阱：

- 幂律 $k^{-\gamma} \neq$ 指数 $e^{-\alpha k}$ ，两者都和「重尾」有关，但数学形式完全不同
- 「优化代价可以忽略不计」需要区分每步代价（低维时确实小）和训练稳定性代价（靠近边界时梯度爆炸，需要更小学习率，总训练步数增加）

解答 § 2.6

T-2.6.1 【欧氏维度下界】 (a) 在 $\mathbb{R}^d$ 中, 半径为 r 的球的体积 $\propto r^d$ 。若放下 M 个互相距离 ≥ 1 的点, 每个点「占据」半径 $1/2$ 的小球, 这些小球的总体积 $\sim M \cdot (1/2)^d$, 必须 $\leq$ 外球体积 $\propto r^d$, 故 $M = O(r^d)$ 。

(b) 树有 $N = O(b^L)$ 个节点, 树的直径约为 $O(L)$, 故需要球半径 $r = O(L)$, 球内最多放 $O(L^d)$ 个点。要满足 $L^d \geq b^L$, 取对数: $d \log L \geq L \log b$, 即

$$d \geq \frac{L \log b}{\log L}$$

随 L 接近线性增长 (除了 $\log L$ 的缓慢增长)。

(c) $b = 2, L = 12$: $d \geq \frac{12 \times \log 2}{\log 12} = \frac{12 \times 0.6931}{2.4849} \approx \frac{8.317}{2.485} \approx 3.35$, 取整为至少 4 维。注意这是非常粗糙的下界; 实际要保留所有 $\sim 8 \times 10^4$ 个节点对的距离, 下界会大得多。

(d) 欧氏空间体积增长为 $O(L^d)$ (多项式), 树节点数增长为 $O(b^L)$ (指数), 两者增长速率的本质差异是 L 的多项式 vs L 的指数。双曲空间体积增长为 $\sim e^{(d-1)r}$ (指数), 与 $b^L = e^{L \log b}$ 的指数形式匹配, 只需令 $d-1 = \log b$ 即可, 与 L 无关——这就是 5 维双曲已经够用、而欧氏需要上百维的数学根源。

Sanity check: $b^L = 2^{12} = 4096$ 。用 $d = 5$ 双曲, $e^{4r} = 4096$ 给出 $r \approx \ln 4096/4 \approx 2.07$, 是可以正常优化的内部坐标范围。

T-2.6.2 【Poincaré 球距离数值计算】 (a) 欧氏距离: 对 A: 0.5; 对 B: 0.1; 对 C: 0.04。

(b) 对各对点计算:

$$\delta = 1 + 2 \frac{\|\mathbf{u} - \mathbf{v}\|^2}{(1 - \|\mathbf{u}\|^2)(1 - \|\mathbf{v}\|^2)}$$

对 A: $\|\mathbf{u}\|^2 = 0, \|\mathbf{v}\|^2 = 0.25$, 分母 $= 1 \times 0.75 = 0.75$, $\delta = 1 + 2 \times 0.25/0.75 = 1 + 0.6667 = 1.6667$, $d_{\mathbb{H}} = \operatorname{arcosh}(1.6667) = \ln(1.6667 + \sqrt{1.7778}) = \ln(1.6667 + 1.3333) = \ln 3 \approx 1.0986$ 。

对 B: $\|\mathbf{u}\|^2 = 0.64, \|\mathbf{v}\|^2 = 0.81$, 分母 $= 0.36 \times 0.19 = 0.0684$, $\delta = 1 + 2 \times 0.01/0.0684 = 1 + 0.2924 = 1.2924$, $d_{\mathbb{H}} = \operatorname{arcosh}(1.2924) \approx \ln(1.2924 + 0.7785) \approx \ln 2.071 \approx 0.7278$ 。

对 C: $\|\mathbf{u}\|^2 = 0.9025, \|\mathbf{v}\|^2 = 0.9801$, 分母 $= 0.0975 \times 0.0199 = 0.001941$, $\|\mathbf{u} - \mathbf{v}\|^2 = 0.0016$, $\delta = 1 + 2 \times 0.0016/0.001941 = 1 + 1.6487 = 2.6487$, $d_{\mathbb{H}} = \operatorname{arcosh}(2.6487) = \ln(2.6487 + \sqrt{5.0154}) \approx \ln(2.6487 + 2.2395) = \ln 4.888 \approx 1.5868$ 。

(c) 双曲距离与欧氏距离之比: A: $1.0986/0.5 = 2.20$; B: $0.7278/0.1 = 7.28$; C: $1.5868/0.04 = 39.67$ 。靠近边界时, 相同的欧氏位移对应急剧增大的双曲距离——C 的比值是 A 的约 18 倍。

(d) 径向双曲距离从球心到 $\mathbf{x}$: $2 \operatorname{arctanh}(\|\mathbf{x}\|)$, 随 $\|\mathbf{x}\| \rightarrow 1$ 趋于无穷。这意味着「深度越大的节点离球边越近」的安排, 自动产生父-子节点之间的双曲距离随层级增加, 且兄弟节点之间距离也随深度增大, 无需任何额外约束。

Sanity check: (b) 中三对点的双曲距离并不单调——对 B (欧氏距离 0.1) 反而小于对 A (欧氏距离 0.5), 这说明「靠近边界」的效应不只是放大距离, 而是曲率使得空间局部被拉伸后内部点之间的相对关系被重新组织。

T-2.6.3【黎曼流形性质辨析】 (a) 真。欧氏空间的度量张量在全局坐标下 $g_{ij}(p) = \delta_{ij}$ 对所有点 p 成立, 曲率为零, 是黎曼流形中曲率 $\equiv 0$ 的特例。

(b) 假。保角因子 $\lambda = \frac{4}{(1-\|\mathbf{x}\|^2)^2}$ 是大于 1 的放大因子, 越靠近球边界越大——即同样的欧氏位移对应的双曲距离越大, 而非越小。

(c) 真。这是曲率正负号的经典几何特征: 负曲率 (双曲空间) 三角形内角和 $< 180^\circ$, 零曲率 (欧氏) $= 180^\circ$, 正曲率 (球面) $> 180^\circ$ 。

(d) 不成立。增大 r (即把节点推向球边界) 会使分母 $(1 - \|\mathbf{x}\|^2)$ 接近零, 黎曼度量的保角因子趋于无穷——靠近边界的梯度极度放大, 训练极不稳定。实践中节点坐标被限制在 $\|\mathbf{x}\| \leq 1 - \epsilon$, 不能无限利用边界区域, 因此「增大 r 换容量」以训练不可行为代价。

T-2.6.4【黎曼梯度计算】 (a) $f(\mathbf{x}) = \|\mathbf{x} - \mathbf{p}\|^2 = (x_1 - 0.3)^2 + x_2^2$ 。在 $\mathbf{x}_0 = (0.5, 0)$ 处:

$$\nabla_{\mathbf{x}} f = (2(x_1 - 0.3), 2x_2)|_{(0.5, 0)} = (0.4, 0)$$

(b) 在 $\mathbf{x}_0 = (0.5, 0)$, $\|\mathbf{x}_0\|^2 = 0.25$, 修正因子 $= \frac{(1-0.25)^2}{4} = \frac{0.5625}{4} = 0.1406$ 。

$$\operatorname{grad}_{\mathbb{H}} f = 0.1406 \times (0.4, 0) = (0.0563, 0)$$

黎曼梯度与欧氏梯度之比为 0.1406, 即约为欧氏梯度的 14%。

(c) 在 $\|\mathbf{x}\| = 0.99$ 处, 修正因子 $= \frac{(1-0.9801)^2}{4} = \frac{(0.0199)^2}{4} = \frac{3.960 \times 10^{-4}}{4} \approx 9.9 \times 10^{-5}$ 。比值约为 10^{-4} , 比 $\mathbf{x}_0 = (0.5, 0)$ 处小了约 1400 倍。

(d) 在球边界附近, 黎曼梯度极小 (修正因子 ≈ 0), 意味着流形上的「真实更新方向」非常小。若使用与内部点相同的 (较大的) 欧氏学习率, 等效的双曲步长不是太小 (梯度本身被压缩), 但指数映射把切向量映射回球面时, 靠近边界的点对微小扰动极其敏感——切向量被指数映射「放大」后容易越界 ($\|\mathbf{x}\| > 1$), 导致数值不稳定和梯度裁剪频繁触发。

Sanity check: 在球心 $\mathbf{x} = 0$, 修正因子 $= (1 - 0)^2 / 4 = 0.25$, 黎曼梯度 $=$ 欧氏梯度的四分之一——这是 Poincaré 球模型里 $ds^2 = 4\|d\mathbf{x}\|^2$ 在 origin 处的直接体现。

T-2.6.5【双曲嵌入适用边界】(a)

- **论断 A 不成立**。违反假设：「自然语言语义拓扑是纯树形层级」。实际上语言兼有 is-a（树形）和 associate-with（网状联想）两类关系，混合拓扑下双曲优势不稳定，欧氏空间对混合拓扑更稳健。
- **论断 B 部分成立**。双曲维度越高确实容量更大，但训练稳定性代价也随维度增加（更难控制靠近边界的点）；实验表明低维（5-10 维）往往已经足够，盲目增加维度会引入优化困难而无明显收益。
- **论断 C 不成立**。违反假设：「幂律分布 = 指数增长」。幂律 $k^{-\gamma}$ 是多项式，指数 $e^{(d-1)r}$ 是指数，两者完全不同。社交网络的幂律度分布反映的是有少数超级节点的「无标度」特性，不等于层级结构，双曲空间的优势是针对层级（树形），不是针对所有重尾分布。
- **论断 D 部分成立**。每步计算量确实因低维而小，但训练稳定性的代价（需要更小学习率、梯度裁剪、边界约束）会使**总训练步数增加**，「可以忽略」的说法过于乐观。

(b) 双曲嵌入的数学前提：① 数据内在拓扑具有**明确的树形层级结构**（节点数随深度指数增长，父子关系清晰）；② 优化目标允许**反复调小学习率并接受额外的边界约束处理**（弯曲空间优化稳定性代价可承受）。

(c) 分子生物学中的蛋白质-蛋白质相互作用网络（PPI）：结构域级别有层级（折叠类 → 超家族 → 家族），但功能级别有密集的网状联系（信号通路中的交叉调控）——既非纯层级也非纯网状。权衡：层级部分用双曲（利用容量优势），网状联系用欧氏（不受边界约束），实践中常用「乘积空间」 $\mathbb{H}^{d_1} \times \mathbb{R}^{d_2}$ 。供应链类比在此场景不适用——PPI 网络没有「采购需求」或「资源调度」语义，强行套用会误导对网络瓶颈的判断。

§2.6 小结：欧氏体积多项式增长与树形结构指数节点增长之间的「维度诅咒」，由 Poincaré 球的指数体积增长精确破解——但破解有两个代价：优化工具必须切换到黎曼梯度加指数映射，且数据必须具有足够纯粹的树形层级拓扑。当这两个条件都不满足时，欧氏空间的稳健性反而占上风。几何空间的选择，本质上是对数据内在拓扑的一次先验赌注。

第 3 章 · 注意力机制的矩阵微分

§3.1 习题：从 RNN 到 Transformer——序列建模的范式革命

导读：本节核心是两个转变——从时序递推到矩阵并行，以及从梯度连乘到 $O(1)$ 路径。五题分别对应：RNN 梯度连乘的谱半径分析、LSTM 门控的定量效果、Transformer 并行化条件的辨析、注意力计算复杂度的量化、以及「范式革命」背后硬件驱动力与数学结构的综合评判。

题 1【轻·推导·RNN 梯度消失的数学根源】 导读：梯度消失不是调参问题，而是连乘结构在线性代数上的必然——把谱范数的上界写清楚，就把「为什么」说清楚了。

设 RNN 隐状态递推公式为 $h_t = \sigma(Wh_{t-1} + Ux_t + b)$ ，其中 $\sigma = \tanh$ ， $|\sigma'| \leq 1$ 。

(a) 写出从时刻 T 反传到时刻 t 的梯度连乘公式 $\frac{\partial \mathcal{L}}{\partial h_t}$ ，展开每步雅可比矩阵。

(b) 设 $\rho = \|W\|_2 \cdot \max |\sigma'|$ （有效谱半径上界）。证明梯度范数满足

$$\left\| \frac{\partial \mathcal{L}}{\partial h_t} \right\|_2 \leq \left\| \frac{\partial \mathcal{L}}{\partial h_T} \right\|_2 \cdot \rho^{T-t}$$

(c) 当 $\rho = 0.9$ 、 $T - t = 50$ 时，梯度范数衰减到原始值的多少比例（保留 4 位有效数字）？当 $T - t = 100$ 时呢？

(d) 梯度爆炸（ $\rho > 1$ ）和梯度消失（ $\rho < 1$ ）是否可以同时避免？说明「恰好 $\rho = 1$ 」在实践中是否可以精确控制，并解释原因。

教学注：(c) 的数字直接说明为什么 RNN 在 100 步以上的序列上几乎无法学习长距离依赖——梯度已经缩小了 7×10^{-5} 倍，优化信号近乎消失。

陷阱：

- 矩阵范数不等式是 $\|AB\|_2 \leq \|A\|_2 \|B\|_2$ ，连乘时上界累乘，这只是上界不是等号
- $\sigma = \tanh$ 时 $\max |\sigma'| = 1$ （在 0 处），故 $\rho = \|W\|_2$ ；但 $\sigma' < 1$ 在大多数时间步，实际衰减比 $\|W\|_2^{T-t}$ 更快

题 2【中·计算·LSTM 门控的缓解效果】 导读：LSTM 是工程防护栏而非数学根治——量化它的有效谱半径上限，才能精确理解它把 RNN 的天花板从哪里提高到哪里。

LSTM 的记忆单元（cell state）更新公式为

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

其中 $f_t \in [0, 1]^{d_h}$ 是遗忘门输出， $i_t \in [0, 1]^{d_h}$ 是输入门， $\tilde{c}_t$ 是候选更新量， $\odot$ 是逐元素乘。

(a) 写出 c_t 对 c_{t-1} 的偏导 $\partial c_t / \partial c_{t-1}$ （矩阵形式）。

(b) 若遗忘门在所有时刻都为 $f_t = \mathbf{1}$ （全开），则记忆单元的梯度路径等效谱半径是多少？这意味着什么？

(c) 若遗忘门在所有时刻都为 $f_t = 0.8 \cdot \mathbf{1}$ ，且 $T - t = 200$ ，记忆单元梯度的衰减比例是多少（保留 4 位小数）？与 (d) 相同情形下普通 RNN（ $\rho = 0.9$ ， $T - t = 200$ ）相比如何？

(d) 解释为什么 LSTM 门控「缓解但不根治」梯度消失问题，以及它无法根治的数学原因。

教学注：(b) 的「全开等于恒等映射」是理解 LSTM 为什么能处理比 RNN 长得多的序列的核心直觉：梯度可以无衰减地从 T 传回 t ，有效跨越整段序列。

陷阱：

- LSTM 的遗忘门 f_t 本身依赖输入，是学习出来的，实践中很少真正稳定为全开

- 「缓解但不根治」的「不根治」体现在：门控参数也是通过梯度学习的，训练初期门控设置错误，真正重要的远距离信息仍然无法有效传播

题 3【中 · 概念辨析 · Transformer 并行化的条件与代价】 导读：Transformer 的可并行性不是「注意力更聪明」，而是计算图上没有时间依赖——把这个条件精确化，才能判断哪些变体失去了并行性。

判断下列说法的真假，并说明理由：

- (a) 「Transformer 编码器（非自回归模式）的所有层都可以完全并行——不仅同一层内的所有位置并行，不同层之间也可以并行。」
- (b) 「自回归解码（推理阶段逐 token 生成）时，Transformer 和 RNN 同样无法并行，所以两者在推理速度上没有本质区别。」
- (c) 「在 Transformer 中，位置 i 的输出和位置 j 的输出之间的梯度传播路径长度为 $O(1)$ （与序列长度无关），而 RNN 中为 $O(n)$ 。」
- (d) 「去掉位置编码的 Transformer 对输入序列的任意排列具有完全的置换不变性，因此所有语序信息都丢失了，模型性能会降至随机。」

教学注：(b) 是一个微妙的真假题——推理时 Transformer 确实逐 token 生成（无法并行生成不同位置），但它保有对已有历史 token 的并行注意力（KV Cache），计算模式与 RNN 不同。

陷阱：

- (a) 中不同层之间必须等前一层结果完成，有层间依赖，不能跨层并行
- (d) 中「性能降至随机」过强——没有位置编码的模型仍然能利用词义信息，只是无法利用顺序信息，在对序列顺序不敏感的任务上（如词袋分类）影响有限

题 4【重 · 计算 · 注意力计算复杂度分析】 导读： $O(n^2d)$ 的复杂度不只是一个渐近符号，具体数字告诉你为什么长上下文是实际痛点。

设单头注意力，序列长度 n ，键/查询维度 d_k ，值维度 d_v ，精度 BF16（2 字节/元素）。

- (a) 逐步写出注意力计算的三个步骤 ($S = QK^T$, softmax, $O = PV$)，各自的 FLOPs 表达式。
- (b) 对 $n = 4096$, $d_k = d_v = 128$ （单头，典型 GPT-3 配置），计算总 FLOPs（精确表达式，单位 GFLOPs）。
- (c) 若序列长度从 $n = 4096$ 翻倍到 $n = 8192$ ，FLOPs 变为多少倍？若翻四倍到 $n = 16384$ ，变为多少倍？
- (d) 标准实现中，注意力矩阵 $S \in \mathbb{R}^{n \times n}$ 需要存储在显存中。对 $n = 8192$ （BF16），计算此矩阵的显存占用（单位 MB）。若将 n 翻倍，显存需求如何变化？

教学注：(c) 揭示了为什么「长上下文」是当前大模型的核心工程瓶颈：FLOPs 和显存都以 n^2 增长，不是线性可扩展的。FlashAttention 解决的正是 (d) 的显存问题，而不

改变 (c) 的 FLOPs。

陷阱：

- $S = QK^T$ 的 FLOPs 是 $2n^2d_k$ (每个输出元素做 d_k 次乘加)，不要漏掉系数 2
- 显存计算： $n \times n$ 矩阵，每个元素 2 字节 (BF16)， $8192^2 \times 2 = 134,217,728$ 字节 ≈ 128 MB

题 5【重·综合评判·范式革命的驱动力】 导读：「Transformer 崛起因为注意力更聪明」vs「Transformer 崛起因为矩阵乘法更适合 GPU」——这两种叙事的数学含义和推论截然不同。

阅读以下四个关于 Transformer 范式革命的论断，评估其准确性：

论断 A：「LSTM 在处理 200 步以内的序列时性能与 Transformer 相当，Transformer 的优势主要体现在超长序列 ($n > 1000$) 上。」

论断 B：「Transformer 消除了梯度消失问题——在任意深度的 Transformer 中，任意两个位置之间的梯度传播都是 $O(1)$ 的，不随层数或序列长度变化。」

论断 C：「注意力机制之所以能替代 RNN，根本原因是注意力在数学上等价于无参数的动态池化——它不需要递推，因此并行；它对全局加权，因此梯度路径短。」

论断 D：「RNN 的串行结构导致 GPU 利用率低，而 Transformer 的矩阵并行导致 GPU 利用率高——这是硬件驱动的范式替换，而非算法层面的突破。」

(a) 对每个论断给出「成立 / 部分成立 / 不成立」，指出关键的准确点或漏洞。

(b) 从数学角度，写出 Transformer 能替代 RNN 的两个必要条件（分别对应「并行性」和「长依赖可学性」）。

(c) Transformer 的位置编码 (RoPE) 的存在，是否意味着 Transformer 重新引入了某种形式的「时序依赖」？说明为什么 RoPE 不影响并行性。

教学注：论断 B 有个重要漏洞——「任意深度」的 Transformer 在层数方向仍然存在梯度消失问题 (L 层时有 L 次矩阵乘法叠加)，只是在「序列方向」(不同位置之间) 梯度路径缩短为 $O(1)$ ，这两个维度必须分开讨论。

陷阱：

- 「梯度路径 $O(1)$ 」只针对自注意力层内的序列方向，不包括跨层传播（残差连接解决的是跨层梯度问题，不是注意力解决的）
- 论断 C 的「无参数」不准确——注意力有 W^Q, W^K, W^V 三套投影参数，是有参数的

解答 § 3.1

T-3.1.1【RNN 梯度消失推导】 (a) 链式法则展开：

$$\frac{\partial \mathcal{L}}{\partial h_t} = \frac{\partial \mathcal{L}}{\partial h_T} \prod_{k=t}^{T-1} \frac{\partial h_{k+1}}{\partial h_k}$$

每步雅可比矩阵 $\frac{\partial h_{k+1}}{\partial h_k} = \text{diag}(\sigma'(Wh_k + Ux_{k+1})) \cdot W$ 。

(b) 由矩阵范数次乘性 $\|AB\|_2 \leq \|A\|_2 \|B\|_2$ ：

$$\left\| \prod_{k=t}^{T-1} \frac{\partial h_{k+1}}{\partial h_k} \right\|_2 \leq \prod_{k=t}^{T-1} \|\text{diag}(\sigma')\|_2 \cdot \|W\|_2 \leq (\max |\sigma'| \cdot \|W\|_2)^{T-t} = \rho^{T-t}$$

故 $\|\partial \mathcal{L} / \partial h_t\|_2 \leq \|\partial \mathcal{L} / \partial h_T\|_2 \cdot \rho^{T-t}$ 。

(c) $\rho = 0.9$, $T - t = 50$: $0.9^{50} = e^{50 \ln 0.9} = e^{-5.268} \approx 0.0052$, 即约 0.52%。 $T - t = 100$: $0.9^{100} \approx 2.66 \times 10^{-5}$, 约 0.003%。

(d) $\rho = 1$ 在实践中几乎不可精确控制：权重矩阵 W 的谱范数随训练动态变化， σ' 也随激活值变化；即使初始化时 $\|W\|_2 = 1$ ，一次梯度更新后谱范数即发生偏移。梯度消失 ($\rho < 1$) 和梯度爆炸 ($\rho > 1$) 两端都不稳定，不存在一个稳定的「恰好 $\rho = 1$ 」的操作点。

Sanity check: $0.9^{50} \approx 0.005$, $0.9^{100} \approx 0.9^{50} \times 0.9^{50} \approx 0.005^2 = 2.5 \times 10^{-5}$, 与精确值 2.66×10^{-5} 量级一致。

T-3.1.2 【LSTM 门控效果】 (a) $\partial c_t / \partial c_{t-1} = \text{diag}(f_t)$ (逐元素遗忘门，视作对角矩阵)。

(b) 若 $f_t = 1$ (全开), $\partial c_t / \partial c_{t-1} = I$, 等效谱半径为 1。梯度可无衰减地从任意远的时刻传回，理论上能学习无限长的依赖关系。

(c) $f_t = 0.8 \cdot 1$, $T - t = 200$: 衰减比例 $0.8^{200} = e^{200 \ln 0.8} = e^{-44.63} \approx 5.2 \times 10^{-20}$, 几乎为零。

普通 RNN ($\rho = 0.9$, $T - t = 200$): $0.9^{200} = e^{200 \times (-0.1054)} = e^{-21.07} \approx 7.1 \times 10^{-10}$ 。

尽管 $0.8 < 0.9$, LSTM 在遗忘门全开时能做到谱半径 = 1; 而门若关小 ($f < 1$), 实际衰减可以比普通 RNN 更快。LSTM 的优势在于「门可以被学习为接近 1」, 而不是单纯地固定一个值。

(d) 不根治的数学原因：遗忘门 f_t 本身是通过 $\sigma(W_f h_{t-1} + U_f x_t + b_f)$ 计算的，这是一个递推函数。要让门在正确的时间步打开/关闭，门的参数也需要通过反向传播学习——而这个学习过程本身仍然通过时间轴的链式法则传播，在训练初期门控不准确时，真正重要的长距离信号仍然可能被遗忘门「意外关闭」而丢失。

T-3.1.3 【并行化条件辨析】 (a) 假。不同层之间有顺序依赖：第 ℓ 层必须等第 $\ell - 1$ 层所有位置的输出完成后才能开始。同一层内的不同位置可以完全并行，但层间不行。

(b) 假 (对推理) / 真 (对训练)。推理时确实是逐 token 自回归 (无法并行生成)，但有 KV Cache 机制——对已生成的历史 token, Key 和 Value 只计算一次并缓存，每步

只需对新 token 做增量计算，而不是像 RNN 那样整个隐状态串行更新。训练时（教师强制），Transformer 的 n 个位置可以完全并行，RNN 不可以。

(c) 真。在自注意力层内，位置 i 的输出 $O_i = \sum_j \alpha_{ij} v_j$ 通过一次矩阵运算直接与位置 j 连接，梯度传播路径 $O(1)$ （一次矩阵乘法相隔）；RNN 中位置 i 和 j 之间需要 $|i - j|$ 步递推，路径长 $O(n)$ 。

(d) 假。去掉位置编码后，模型仍然能利用词义信息（通过嵌入向量），只是所有序列排列都产生相同的注意力权重（注意力对排列不变）。对词袋级别的任务（情感分类等）性能影响有限；对需要顺序的任务（语言建模、翻译）性能大幅下降，但不降至随机。

T-3.1.4 【复杂度数值计算】 (a)

- 步骤 1: $S = QK^T \in \mathbb{R}^{n \times n}$, FLOPs = $2n^2 d_k$
- 步骤 2: softmax (逐行), FLOPs = $\Theta(n^2)$ (较小, 约 $5n^2$)
- 步骤 3: $O = PV \in \mathbb{R}^{n \times d_v}$, FLOPs = $2n^2 d_v$

总 FLOPs $\approx 2n^2(d_k + d_v) = 4n^2 d$ (取 $d_k = d_v = d$)。

(b) $n = 4096, d = 128$: FLOPs = $4 \times 4096^2 \times 128 = 4 \times 1.678 \times 10^7 \times 128 = 8.590 \times 10^9 \approx 8.59$ GFLOPs。

(c) FLOPs $\propto n^2$: n 翻倍时 FLOPs 变为 4 倍； n 翻四倍时变为 16 倍。

(d) $n = 8192$: 矩阵大小 $8192^2 = 6.711 \times 10^7$ 元素，BF16 各 2 字节， $= 1.342 \times 10^8$ 字节 ≈ 128 MB。若 n 翻倍到 16384: $16384^2 \times 2 = 5.369 \times 10^8$ 字节 ≈ 512 MB，即 n 翻倍、显存需求变为 4 倍。

Sanity check: FLOPs 和显存都正比于 n^2 ，验证: $512/128 = 4 = (16384/8192)^2 \checkmark$ 。

T-3.1.5 【范式革命驱动力评判】 (a)

- **论断 A 部分成立**。LSTM 在中等长度序列上确实接近 Transformer，但 Transformer 优势不只来自长度——训练并行度允许更大数据量，更大模型，这是性能差距的主要来源，而非仅仅序列长度。
- **论断 B 部分成立**。「序列方向梯度路径 $O(1)$ 」成立（自注意力层内），但层间传播仍是 $O(L)$ (L 为层数)，残差连接缓解但不消除跨层梯度消失。
- **论断 C 部分成立**。注意力确实无递推、梯度路径短，但「无参数」不准确——投影矩阵 W^Q, W^K, W^V 是可学习参数；「动态池化」的类比有一定直觉价值但不够精确。
- **论断 D 成立**。这是最核心的叙事：矩阵乘法对 SIMD 硬件的高算术强度匹配，使 GPU 能充分利用；时序递推在 GPU 上浪费并行潜力。Transformer 的数学设计恰好与 2010 年代 GPU 的发展形成完美共振。

(b) 两个必要条件：① **计算图无时间轴依赖**： n 个位置的输出可同时计算，不需要等待前序隐状态（并行性）；② **任意两位置梯度传播路径为 $O(1)$** ：自注意力在序列方向上

只有一层矩阵运算相隔，不需要连乘（长依赖可学性）。

(c) RoPE 不影响并行性。RoPE 的作用是在计算 Q, K 时对每个位置施加一个旋转变换 $\mathcal{R}_m$ ，这个变换是**每个位置独立的**（位置 m 的 query 只依赖 m 本身的位置信息，不依赖其他位置），可与其他位置同时计算。RoPE 注入了相对位置信息（通过旋转矩阵使内积只依赖位置差 $n - m$ ），但这是通过函数变换实现的，不引入任何时序递推依赖。

§ 3.1 小结：RNN 到 Transformer 的跨越有两条并行的逻辑链——数学上：把梯度连乘 (ρ^{T-t}) 替换为 $O(1)$ 路径；工程上：把时序串行（GPU 空等）替换为矩阵并行（GPU 满载）。LSTM 改善了前者（防护栏，上限 ~ 200 步），但不改变后者；Transformer 同时解决了两个问题，代价是位置编码和 $O(n^2)$ 复杂度两个新挑战。

§ 3.2 注意力公式的拆解：QKV 的真实含义

本节依次建立五个公式：QKV 投影把输入序列映射到三个角色，内积方差解释 $\sqrt{d_k}$ 缩放的来源，缩放点积注意力给出软检索的完整形式，softmax 行归一化确定权重方向，多头注意力在多个子空间并行检索。每个公式后立刻练习，再往下走。

小节导读·公式从哪里来

注意力不是“拍脑袋设计出来”的，而是“软查表”这个需求的自然实现。

第一步：从“硬查表”进化到“软查表”。你想查一个字典：给一个 key q ，查表里哪个 key k_j 与之精确匹配，返回对应 value v_j 。但语言里“精确匹配”太脆弱。软查表的改动：用相似度 $\langle q, k_j \rangle$ 作为“多像”，加权得到 $\sum_j w_j v_j$ 。这就是 $\text{Attention}(Q, K, V) = \text{softmax}(QK^\top)V$ 的样子。

第二步：Q、K、V 为什么要用三个独立投影。只用一个嵌入 x 同时充当查询者、被查、存储三个角色，在几何上会冲突。拆成 $Q = XW^Q$ ， $K = XW^K$ ， $V = XW^V$ 后三个角色各处于不同子空间，参数量多些以换表达力。这是“三角色不同函数”的必要拆分，不是丰富参数。

第三步： $\sqrt{d_k}$ 缩放为什么不是装饰。Q、K 各分量独立同分布 $\mathcal{N}(0, 1)$ 时， $QK^\top$ 的每项是 d_k 个独立乘积的和，方差 d_k 、标准差 $\sqrt{d_k}$ 。softmax 在输入量级为 $O(\sqrt{d_k})$ 时会快速饱和（变成选一 one-hot）、梯度消失。除以 $\sqrt{d_k}$ 是在把 softmax 输入量级拉回 $O(1)$ 、保证梯度可传。这个表面上微不足道的除法，是 Transformer 能训出来的关键之一。

第四步：softmax 为什么是行归一化不是列归一化。软查表在“查询者”角度必须是一个概率分布：一个 query 对所有 key 的权重加起来为 1。于是 softmax 在行上做，不能在列上；列上归一会变成“每个 key 被多少 query 选中”，语义差了。

第五步：多头为什么必须。单头只能学一种“查询习惯”，实际语言里“上下文需要查多个侧面”（主谓一致、代词指参、部分-整体等）。拆成 h 个低维头 + 拼接让不同检索模式并行、互不干扰。MHA/MQA/GQA 只是这个结构里 K/V 被几个头共享的变体。

本节要拿走的一件事：注意力 = 软查表。以后你看到任何 attention 变体，先问自己：这个版本里，查询、被查、返回值是什么？相似度怎么算？归一化怎么做？多头拆分怎么处理？这四个问题能把所有变体拆清楚。

公式 1 · QKV 投影

$$Q = XW^Q \in \mathbb{R}^{n \times d_k}, \quad K = XW^K \in \mathbb{R}^{n \times d_k}, \quad V = XW^V \in \mathbb{R}^{n \times d_v}$$

其中 $X \in \mathbb{R}^{n \times d}$ 为序列嵌入矩阵，投影权重 $W^Q, W^K \in \mathbb{R}^{d \times d_k}$, $W^V \in \mathbb{R}^{d \times d_v}$ 。三次投影把同一输入分别赋予“查询”“键”“值”三种身份。

一句话直觉：同一 token 通过三条不同线性通道，分别扮演“提问者”“被检索者”“信息携带者”。

在大模型里的位置：架构

本组训练目标：代入 · 变形 · 工程

常见卡点：

- 混淆 W^Q 的形状——是 $d \times d_k$ 而非 $d_k \times d$ ，搞反导致矩阵乘法维度不匹配
- 误以为三个投影矩阵是共享的（它们是独立可学习参数）
- 忘记 d_k 通常不等于 d （标准取 $d_k = d/h$ ）

卡住回看：数学卷 §3.2

本组在练什么：追踪矩阵形状，理解投影如何分离三个角色；做完应能回答：为什么 Q 和 K 必须有相同的 d_k ，而 V 的 d_v 可以不同？

T-3.2.1 【易 · 代入 · 矩阵形状追踪】 设 $n = 512$ （序列长度）， $d = 768$ （嵌入维度）， $h = 12$ （头数），每头 $d_k = d_v = d/h = 64$ 。

- 对单头注意力，列出 Q, K, V 三个矩阵的形状；
- 列出单头的 $A = QK^\top / \sqrt{d_k}$ 、 $P = \text{softmax}(A)$ 、 $O = PV$ 的形状；
- 多头拼接后 $\text{Concat}(\text{head}_1, \dots, \text{head}_{12})$ 的形状，以及输出投影 W^O 应为什么形状才能让最终输出与输入 X 形状相同？

解答 T-3.2.1 【易 · 代入 · 矩阵形状追踪】

- 单头形状： $Q \in \mathbb{R}^{512 \times 64}$, $K \in \mathbb{R}^{512 \times 64}$, $V \in \mathbb{R}^{512 \times 64}$ 。
- $A = QK^\top / \sqrt{64} \in \mathbb{R}^{512 \times 512}$ ； $P = \text{softmax}(A) \in \mathbb{R}^{512 \times 512}$ （每行归一化）； $O = PV \in \mathbb{R}^{512 \times 64}$ 。
- $\text{Concat}(\text{head}_1, \dots, \text{head}_{12}) \in \mathbb{R}^{512 \times (12 \times 64)} = \mathbb{R}^{512 \times 768}$ 。要让最终输出与输入 $X \in \mathbb{R}^{512 \times 768}$ 形状相同，需 $W^O \in \mathbb{R}^{768 \times 768}$ ，即 $\mathbb{R}^{hd_v \times d}$ 。

T-3.2.2 【中 · 变形 · 投影参数量计算与多头等价性】 设嵌入维度 d ，头数 h ，每头 $d_k = d_v = d/h$ 。

- (a) 计算单头注意力（含输出投影 W^O ）的可学习参数总量（以 d 表示）；
 (b) 计算多头注意力所有 W_i^Q, W_i^K, W_i^V ($i = 1, \dots, h$) 加上 W^O 的参数总量；
 (c) 证明 (a) = (b)，用一句话解释多头设计的核心优势不在于参数量，而在于什么。

解答 T-3.2.2 【中 · 变形 · 投影参数量计算与多头等价性】

- (a) 单头（含 W^O ）: $W^Q, W^K \in \mathbb{R}^{d \times d}, W^V \in \mathbb{R}^{d \times d}, W^O \in \mathbb{R}^{d \times d}$ ，总参数 = $4d^2$ 。（注：单头取 $d_k = d_v = d_o$ ）
 (b) 多头，每头 $d_k = d_v = d/h$ ：
 · 所有 W_i^Q ： h 个 $\mathbb{R}^{d \times (d/h)}$ ，总量 = $h \cdot d \cdot (d/h) = d^2$ ；
 · 所有 W_i^K, W_i^V 各同，共 $3d^2$ ；
 · $W^O \in \mathbb{R}^{d \times d}$ ： d^2 。
 · 合计 = $4d^2$ 。
 (c) $4d^2 = 4d^2$ ，完全相等。多头的核心优势不在参数量，而在于将同等参数容量分配到 h 个低维子空间，同时运行多种不同的检索模式（如语法关系、指代关系、话题对齐），再由 W^O 综合。

公式 2 · 内积方差与 $\sqrt{d_k}$ 缩放

$$\text{Var}(q_i \cdot k_j) = \sum_{l=1}^{d_k} \text{Var}(q_{il}) \text{Var}(k_{jl}) = d_k$$

其中 $q_i, k_j \in \mathbb{R}^{d_k}$ 各分量独立同分布，均值 0、方差 1。内积的标准差随 $\sqrt{d_k}$ 增长；缩放因子 $1/\sqrt{d_k}$ 将方差还原为 1。

一句话直觉：高维内积的“噪声”随维度线性增长， $\sqrt{d_k}$ 缩放是把量级归一的最小代价。

在大模型里的位置：架构

本组训练目标：代入 · 证明 · 反例

常见卡点：

- 混淆独立性条件下 $\text{Var}(XY) = \text{Var}(X) \text{Var}(Y)$ 仅在 $\mathbb{E}[X] = \mathbb{E}[Y] = 0$ 时成立
- 标准差是 $\sqrt{d_k}$ 而非 d_k ，误写导致缩放因子算错
- 误以为“只要 d_k 不太大就不需要缩放”（即使 $d_k = 64$ 不缩放标准差已达 8）

卡住回看：数学卷 §3.2

本组在练什么：推导缩放因子的数学来源，并用数值体会 softmax 饱和；做完应能回答：如果把 $\sqrt{d_k}$ 缩放替换为温度参数 T ，两者有什么等价关系？

T-3.2.3 【易 · 代入 · 缩放前后对比】 设 $d_k = 64$, 某 query-key 对给出内积 $q \cdot k = 48$, 其余 $n - 1 = 127$ 个 key 的内积均为 0。

- 未缩放时, 该项在 softmax 中的权重 (用 $n = 128$ 代入, 精确表达式即可);
- 缩放后 (除以 $\sqrt{64} = 8$), 该项权重 (保留 4 位小数);
- 比较 (a)(b), 解释缩放如何保护梯度 (提示: softmax 对角 Jacobian 元素为 $p_i(1 - p_i)$)。

解答 T-3.2.3 【易 · 代入 · 缩放前后对比】

- 未缩放: $s_1 = 48$, 其余 $s_j = 0$ ($j = 2, \dots, 128$)。

$$p_1 = \frac{e^{48}}{e^{48} + 127 \cdot e^0} \approx \frac{e^{48}}{e^{48}} = 1 - 127e^{-48} \approx 1.0000.$$

$e^{48} \approx 7.9 \times 10^{20}$, p_1 极其接近 1, 近乎 one-hot。

- 缩放后 $s'_1 = 48/8 = 6$, 其余 $= 0$ 。

$$p_1 = \frac{e^6}{e^6 + 127} = \frac{403.43}{403.43 + 127} \approx 0.7605.$$

- softmax 的对角 Jacobian 元素为 $p_i(1 - p_i)$ 。未缩放时 $p_1 \approx 1$, 故 $p_1(1 - p_1) \approx 0$ ——反向传播经过近乎零的 Jacobian, Q 和 K 的梯度信号消失。缩放后 $p_1(1 - p_1) \approx 0.76 \times 0.24 = 0.18$, 梯度量级正常, 训练可正常进行。

T-3.2.4 【中 · 证明 · 方差推导与等价温度】

- 设 q_{il}, k_{jl} 独立且均值 0、方差 1, 用独立性证明 $\text{Var}(q_i \cdot k_j) = d_k$;
- softmax 温度参数定义为: 将 logits 除以 T 再做 softmax。证明“除以 $\sqrt{d_k}$ ”“等价于设温度 $T = \sqrt{d_k}$ ”;
- 温度 $T \rightarrow 0$ 和 $T \rightarrow \infty$ 时, softmax 分布分别趋向什么形状? 用一句话解释为何训练期间不应让 T 过小。

解答 T-3.2.4 【中 · 证明 · 方差推导与等价温度】

- $s = \sum_{l=1}^{d_k} q_{il} k_{jl}$ 。各项独立且均值为 0, 故 $\mathbb{E}[s] = 0$ 。对每项:

$$\text{Var}(q_{il} k_{jl}) = \mathbb{E}[q_{il}^2] \mathbb{E}[k_{jl}^2] - (\mathbb{E}[q_{il}] \mathbb{E}[k_{jl}])^2 = 1 \cdot 1 - 0 = 1.$$

各项独立, 故 $\text{Var}(s) = \sum_{l=1}^{d_k} 1 = d_k$ 。

- 将 logits 除以 T 后 softmax:

$$\text{softmax}(s/T)_i = \frac{\exp(s_i/T)}{\sum_j \exp(s_j/T)}.$$

令 $T = \sqrt{d_k}$ ，则 $s/T = s/\sqrt{d_k}$ ，恰好与“除以 $\sqrt{d_k}$ 再做 softmax”完全等价。两者是同一操作。

- (c) $T \rightarrow 0$: logits 被无限放大，最大值项主导，softmax 趋向 one-hot (所有概率集中于最大项)。 $T \rightarrow \infty$: 所有 logits 趋向 0，softmax 趋向均匀分布。训练期间 T 过小会导致 softmax 饱和、梯度消失，使参数无法有效更新。

T-3.2.5 【难 · 判错 · 关于缩放的错误说法】 有人说：“只要把 query 和 key 初始化为均值 0、方差 $1/d_k$ 的分布，内积方差天然为 1，就不需要 $\sqrt{d_k}$ 缩放因子了。”

- (a) 这个说法在初始化时刻是否成立？请验证；
 (b) 训练若干步后，参数分布会发生什么变化？这会导致什么问题？
 (c) 为什么显式缩放（而非依赖初始化）是更鲁棒的工程选择？

解答 T-3.2.5 【难 · 判错 · 关于缩放的错误说法】

- (a) 若每个分量初始化为均值 0、方差 $1/d_k$ 的分布，则 $\text{Var}(q_{il}k_{jl}) = (1/d_k) \cdot (1/d_k) = 1/d_k^2$ ， $\text{Var}(q \cdot k) = d_k \cdot 1/d_k^2 = 1/d_k$ 。要使方差恰好为 1，需令分量方差 $= 1/\sqrt{d_k}$ (即标准差 $= d_k^{-1/4}$)，而非 $1/d_k$ 。严格来说，“方差 $1/d_k$ ”只能使内积方差为 $1/d_k$ (而非 1)，不能达到目标——说法本身有误。
- (b) 训练若干步后，梯度更新会改变参数的统计特性——权重的方差通常会随训练增大（特别是无归一化约束的 attention 参数）。无论初始化如何，训练后的参数分布与初始化假设脱节，内积方差重新偏离 1。
- (c) 显式缩放是架构级约束 ($A = QK^\top/\sqrt{d_k}$)，不依赖参数初始化，在训练的任何阶段都成立；而依赖初始化的隐式控制只在初始时刻有效，之后随参数更新逐渐失效。工程上，显式缩放更鲁棒、可复现，不受初始化策略影响。

公式 3 · 缩放点积注意力

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V \in \mathbb{R}^{n \times d_v}$$

注意力分数矩阵 $A = QK^\top/\sqrt{d_k} \in \mathbb{R}^{n \times n}$ ，softmax 沿行方向（每行独立）归一化得到权重矩阵 P ，最终输出为 P 对 V 行向量的加权组合。

一句话直觉：每个 token 以“相似度”为权重软检索所有 Value 向量，输出是所有值的加权混合。

在大模型里的位置：架构

本组训练目标：代入 · 工程 · 判错

常见卡点：

- softmax 作用于行而非列（第 i 行代表第 i 个 token 对所有位置的权重）
- 因果掩码（causal mask）把未来位置的 A_{ij} ($j > i$) 设为 $-\infty$ ，softmax 后权重为 0
- 区分”注意力分数”（缩放前）和”注意力权重”（softmax 后）

卡住回看：数学卷 § 3.2

本组在练什么：数值验证 softmax 归一化方向，以及因果掩码的效果；做完应能回答：为什么对列做 softmax 语义上不合理？

T-3.2.6 【易 · 验证 · softmax 行归一化】 给定注意力分数矩阵：

$$A = \begin{pmatrix} 2 & 1 & 0 \\ 0 & 2 & 1 \\ 1 & 0 & 2 \end{pmatrix}$$

- 对每一行独立做 softmax，计算概率矩阵 P （保留 4 位小数）；
- 验证每行之和为 1，每列之和不为 1；
- 若对每一列做 softmax，解释为什么语义上不合理（从”每个 query 对所有 key 的关注权重归一”角度）。

解答 T-3.2.6 【易 · 验证 · softmax 行归一化】

(a) 对每行 (A_{i1}, A_{i2}, A_{i3}) 做 softmax。

第 1 行 $(2, 1, 0)$ ：分母 $= e^2 + e^1 + 1 = 7.3891 + 2.7183 + 1.0000 = 11.1074$ 。

$P_{11} = 7.3891/11.1074 \approx 0.6652$ ， $P_{12} \approx 0.2447$ ， $P_{13} \approx 0.0900$ 。

第 2 行 $(0, 2, 1)$ ：分母同上 $= 11.1074$ （置换了行值）。

$P_{21} \approx 0.0900$ ， $P_{22} \approx 0.6652$ ， $P_{23} \approx 0.2447$ 。

第 3 行 $(1, 0, 2)$ ：分母同上。

$P_{31} \approx 0.2447$ ， $P_{32} \approx 0.0900$ ， $P_{33} \approx 0.6652$ 。

$$P \approx \begin{pmatrix} 0.6652 & 0.2447 & 0.0900 \\ 0.0900 & 0.6652 & 0.2447 \\ 0.2447 & 0.0900 & 0.6652 \end{pmatrix}$$

- 每行求和： $0.6652 + 0.2447 + 0.0900 = 1.0000$ （满足）。列和： $0.6652 + 0.0900 + 0.2447 = 0.9999 \neq 1$ （浮点误差，但列和不为精确的 1）。

- (c) 对列做 softmax 意味着 $\sum_i P_{ij} = 1$ ——“所有 query 分给第 j 个 key 的权重之和为 1”。这等于对 key 端做资源分配约束，语义上是说每个 key 只能被总权重 1 所覆盖，无法同时被多个 query 高权重关注。而正确语义是：每个 query 独立地检索全部 key，不同 query 的权重互不影响，因此应对行（query 端）归一化。

T-3.2.7 【中 · 工程 · softmax 温度形状画图与数值稳定】

- (a) 设注意力 logits 为 $z = (3, 1, 0, -1)$ ，分别在温度 $T = 0.5$ 、 $T = 1$ 、 $T = 2$ 下计算 softmax 权重（保留 3 位小数），填入下表：

T	p_1	p_2	p_3	p_4
0.5				
1				
2				

- (b) 请在草稿区粗略画出三条分布的直方图草图，标注 $T \rightarrow 0$ 时形状趋向 one-hot、 $T \rightarrow \infty$ 时趋向均匀；
- (c) 计算时如何避免 $\exp(z/T)$ 在 T 很小时溢出？写出一行数值稳定公式。

解答 T-3.2.7 【中 · 工程 · softmax 温度形状画图与数值稳定】

- (a) 各温度下的精确值：

$T = 0.5$: $z/T = (6, 2, 0, -2)$ ，分母 $= e^6 + e^2 + 1 + e^{-2} = 403.43 + 7.389 + 1 + 0.135 = 411.95$ 。 $p_1 = 0.979$ ， $p_2 = 0.018$ ， $p_3 = 0.002$ ， $p_4 \approx 0$ 。

$T = 1$: 分母 $= e^3 + e^1 + e^0 + e^{-1} = 20.086 + 2.718 + 1.000 + 0.368 = 24.172$ 。 $p_1 \approx 0.831$ ， $p_2 \approx 0.112$ ， $p_3 \approx 0.041$ ， $p_4 \approx 0.015$ 。

$T = 2$: $z/T = (1.5, 0.5, 0, -0.5)$ ，分母 $= e^{1.5} + e^{0.5} + 1 + e^{-0.5} = 4.482 + 1.649 + 1 + 0.607 = 7.738$ 。 $p_1 = 0.579$ ， $p_2 = 0.213$ ， $p_3 = 0.129$ ， $p_4 = 0.078$ 。

T	p_1	p_2	p_3	p_4
0.5	0.979	0.018	0.002	0.000
1	0.831	0.112	0.041	0.015
2	0.579	0.213	0.129	0.078

- (b) 草图要点： $T = 0.5$ 时分布几乎退化为 one-hot ($p_1 \approx 0.98$)， $T = 1$ 时有明显峰值， $T = 2$ 时分布更平缓。趋势：温度越低分布越“尖锐”； $T \rightarrow 0$ 完全退化为 one-hot； $T \rightarrow \infty$ 趋向 $(0.25, 0.25, 0.25, 0.25)$ 均匀。
- (c) 数值稳定公式：先减当前最大值，再计算：

$$\text{softmax}(z/T)_i = \frac{\exp((z_i - \max_l z_l)/T)}{\sum_j \exp((z_j - \max_l z_l)/T)}.$$

即先除以 T 再减最大值（等价于先减最大值再除以 T ，因平移不变性）。

T-3.2.8 【难 · 判错 · 注意力权重与因果归因】 有人说：“注意力权重 P_{ij} 大，说明第 i 个 token 的预测主要由第 j 个 token 决定。”

- 从 Value 矩阵 V 的角度，构造一个反例：当 V 的行向量近似相同时，不同的权重分布 P_i 能给出几乎相同的输出 O_i ——这说明什么？
- 真正衡量“第 j 个 token 对输出的影响”应该用什么量？（提示：梯度 $\|\partial L / \partial x_j\|$ ）
- 用一句话总结注意力权重的局限性。

解答 T-3.2.8 【难 · 判错 · 注意力权重与因果归因】

- 设 V 的两行 $v_1 \approx v_2 \approx v$ （近似相同）。则对任意权重 $\alpha_1 + \alpha_2 = 1$ ， $O = \alpha_1 v_1 + \alpha_2 v_2 \approx (\alpha_1 + \alpha_2)v = v$ 。即无论 α_1 取 0.1 还是 0.9，输出 O 几乎不变。这说明注意力权重大的 token 对输出并不一定有决定性影响——当 Value 向量高度相关时，不同的权重分布能产生几乎相同的输出。
- 真正衡量第 j 个 token 对输出影响的量是梯度 $\|\partial L / \partial x_j\|$ （或 $\|\partial y / \partial x_j\|$ ），它通过所有计算路径（Q、K、V 分支）综合传播，而注意力权重 P_{ij} 只反映 Value 分支的线性组合权重。
- 注意力权重衡量的是 Value 向量的加权方式，而非 token 对输出的因果敏感度；真正的归因分析需要梯度方法或电路分析，不能直接用注意力权重代替。

做完自检

- QKV 三个投影矩阵各自解决什么问题？为什么 W^Q 和 W^K 必须有相同的输出维度 d_k ？
- $\sqrt{d_k}$ 缩放与温度参数 T 是什么等价关系？不缩放时 softmax 会退化成什么形状？
- softmax 为什么要沿行（而非列）归一化？注意力权重能直接作为因果解释依据吗？

§ 3.3 矩阵乘法的大规模并发：FLOPs 与算术强度

本节建立三个量化工具：矩阵乘 FLOPs 公式给出运算量的精确计数，算术强度刻画“每字节数据产生多少浮点运算”，Roofline 模型判断操作属于计算受限还是内存受限。注意力的 $O(n^2d)$ 复杂度和 softmax 的低算术强度均可在此框架下精确定位。

小节导读 · 公式从哪里来

这一节看似三个独立公式，本质上是同一问题的三个视角：这个计算能不能跑到 GPU 的峰值？

第一步：为什么 FLOPs 公式是 $2MNK$ 而不是 MNK 。矩阵乘 $C = AB$ 、 $A \in \mathbb{R}^{M \times K}$ 、 $B \in \mathbb{R}^{K \times N}$ 。每个输出元素 $c_{ij} = \sum_k a_{ik} b_{kj}$ 是 K 个乘法加 $K - 1$ 个加法，不是 K 个

FLOP。总共 MN 个输出 $\times$ 每个 $\approx 2K$ 个 FLOP $= 2MNK$ 。这不是细节，是算快算慢差一倍的底层。

第二步：算术强度到底是什么。定义上 $I = \text{FLOPs/Bytes moved}$ ——“每搬一字节干几次浮点”。为什么这个量重要？GPU 峰值 312 TFLOP/s、HBM 带宽 2 TB/s，“每字节才能换来 156 个 FLOP”。你的 kernel 的 I 如果小于 156，那么 GPU 不会在计算上饱和——它会在等数据从 HBM 搬上来。这个比值叫“脊点”，是本节最要记下的概念。

第三步：Roofline 不是画图玩意儿，是诊断工具。把 I 放横轴、实际吞吐量放纵轴：在 $I < I^*$ 区内吞吐量被线性”带宽 $\times I$ “压住（内存受限）；过了脊点被”峰值”叠加压住（计算受限）。你的 kernel 在这张图上的位置决定了该优化带宽还是计算。这是”凭感觉猜瓶颈”与”量化判断瓶颈”的分水岭。

第四步：attention 为什么”又贵又难优化”。算起来 attention 是 $O(n^2d)$ FLOPs，似乎越长越贵。但内存费用上 $QK^\top$ 要交互访问 $n \times n$ 表，算术强度 $I \approx d$ —— $d = 128$ 、H100 脊点 295，说明标准 attention 在高端卡上是内存受限的。这个诊断是 FlashAttention 动机的起点：不是减 FLOPs，而是减内存访问。

公式 4 · 矩阵乘法 FLOPs

$$\text{FLOPs}(C = AB) = 2mnk, \quad A \in \mathbb{R}^{m \times k}, B \in \mathbb{R}^{k \times n}$$

每个输出元素 $C_{ij} = \sum_{l=1}^k A_{il}B_{lj}$ 需要 k 次乘法和 $k-1$ 次加法，近似为 $2k$ 次浮点运算；共 mn 个输出元素，总计 $2mnk$ 。

一句话直觉：矩阵乘法是 GPU 的”最爱”——计算量随三个维度乘积增长，但内存访问量只按面积增长。

在大模型里的位置：架构（前向/反向）

本组训练目标：代入 · 变形 · 工程

常见卡点：

- 系数 2 来自”一次乘加 = 2 FLOP”（FMA 计数），有时文献省去系数 2 仅计乘法
- 注意 A 是 $m \times k$ ， B 是 $k \times n$ ——共享维度 k 在中间
- 多步注意力的 FLOPs 要分别计 $QK^\top$ 和 PV 再求和

卡住回看：数学卷 §3.3

本组在练什么：从维度推导 FLOPs，建立大模型算力的数量级感；做完应能回答：LLaMA-3 70B 单层注意力的矩阵乘约需要多少 GFLOPs？

T-3.3.1 【易 · 代入 · 矩阵乘法 FLOPs 计算】 设 $A \in \mathbb{R}^{1024 \times 512}$ ， $B \in \mathbb{R}^{512 \times 2048}$ ，dtype = float16（2 字节/元素）。

- 计算 $C = AB$ 的 FLOPs；
- 计算读 A 、 B ，写 C 所需的总内存访问字节数；

- (c) 计算算术强度 I (FLOP/byte);
- (d) A100 屋脊点约 156 FLOP/byte, 判断此次矩阵乘属于计算受限还是内存受限。

解答 T-3.3.1 【易 · 代入 · 矩阵乘法 FLOPs 计算】

- (a) $m = 1024, k = 512, n = 2048$ 。FLOPs $= 2 \times 1024 \times 512 \times 2048 = 2,147,483,648 \approx 2.147 \times 10^9$ FLOP $= 2.147$ GFLOP。
- (b) 读 A : $1024 \times 512 \times 2 = 1,048,576$ 字节; 读 B : $512 \times 2048 \times 2 = 2,097,152$ 字节; 写 C : $1024 \times 2048 \times 2 = 4,194,304$ 字节。总计 $7,340,032 \approx 7.34$ MB。
- (c) $I = 2,147,483,648 / 7,340,032 \approx 292.6$ FLOP/byte。
- (d) $292.6 > 156$, 属于计算受限。

T-3.3.2 【中 · 推导 · 单头 Attention FLOPs 逐步验证】 设序列长度 $n = 1024$, 单头 $d_k = d_v = d = 64$ 。

- (a) 计算 $S = QK^\top$ 的 FLOPs ($Q \in \mathbb{R}^{n \times d_k}, K^\top \in \mathbb{R}^{d_k \times n}$);
- (b) 计算 $O = PV$ 的 FLOPs ($P \in \mathbb{R}^{n \times n}, V \in \mathbb{R}^{n \times d_v}$);
- (c) 两步合并, 验证总量为 $\Theta(n^2 d)$;
- (d) 以 $d = 128$, 填写以下 FLOPs 表 (GFLOPs 单位, $1 \text{ GFLOP} = 10^9 \text{ FLOP}$) 并验证 n 翻倍时 FLOPs 增加 4 倍:

n	FLOPs (精确)	GFLOPs
512		
1024		
2048		
4096		

解答 T-3.3.2 【中 · 推导 · 单头 Attention FLOPs 逐步验证】

- (a) $S = QK^\top$: $Q \in \mathbb{R}^{1024 \times 64}, K^\top \in \mathbb{R}^{64 \times 1024}$, FLOPs $= 2 \times 1024 \times 1024 \times 64 = 134,217,728$ 。
- (b) $O = PV$: $P \in \mathbb{R}^{1024 \times 1024}, V \in \mathbb{R}^{1024 \times 64}$, FLOPs $= 2 \times 1024 \times 1024 \times 64 = 134,217,728$ 。
- (c) 总 $= 2 \times 1.342 \times 10^8 = 2.684 \times 10^8$, 以 $d = 64, n = 1024$ 代入: $4n^2 d = 4 \times 1024^2 \times 64 = 2.684 \times 10^8$, 验证正确。
- (d) $d = 128$, FLOPs $= 4n^2 \times 128$:

n	FLOPs (精确)	GFLOPs
512	1.342×10^8	0.134
1024	5.369×10^8	0.537
2048	2.147×10^9	2.147
4096	8.590×10^9	8.590

n 翻倍, FLOPs 增加 4 倍, 印证 $O(n^2)$ 的二次复杂度。

T-3.3.3 【难 · 证明 · 多头 FLOPs 不变性】 设嵌入维度 d , 序列长度 n , 单头使用 $d_k = d_v = d$, 多头 (h 头) 每头 $d_k = d_v = d/h$ 。

- 写出单头注意力的矩阵乘 FLOPs (仅含 $QK^\top$ 和 PV);
- 写出 h 头多头的总矩阵乘 FLOPs;
- 证明 (a) = (b), 说明多头设计在算力上”免费”;
- 多头的真正开销在哪里? (提示: QKV 投影与输出投影 W^O 的 FLOPs 量级是什么?)

解答 T-3.3.3 【难 · 证明 · 多头 FLOPs 不变性】

- 单头 ($d_k = d_v = d$): $QK^\top$ 的 FLOPs = $2n^2d$; PV 的 FLOPs = $2n^2d$; 总 = $4n^2d$ 。
- 多头, 每头 $d_k = d_v = d/h$: 每头 FLOPs = $2n^2(d/h) + 2n^2(d/h) = 4n^2d/h$ 。 h 头总计 = $h \times 4n^2d/h = 4n^2d$ 。
- (a) = (b) = $4n^2d$, 完全相等。多头在注意力矩阵乘部分严格等于单头, 算力上”免费”。
- 真正开销在 QKV 投影与输出投影: QKV 三个投影矩阵 FLOPs = $3 \times 2nd^2/h \times h = 6nd^2$; 输出投影 W^O FLOPs = $2nd^2$; 总 = $8nd^2$, 量级为 $\Theta(nd^2)$ 。当 n 较小时, 投影的开销相对注意力矩阵乘 $4n^2d$ 不可忽略。

公式 5 · 算术强度与 Roofline 模型

$$I = \frac{\text{FLOPs}}{\text{内存访问字节数}} \quad (\text{FLOP/byte}), \quad P = \min(\text{峰值算力}, I \times \text{峰值带宽})$$

大矩阵极限 $m = n = k = N \rightarrow \infty$ 下, $I \approx 2N/(3b)$ (b 为 dtype 字节数), 随矩阵尺寸线性增长, 远超 A100 屋脊点 (≈ 156 FLOP/byte)。softmax 的 exp 算术强度约为 1, 是内存受限”细腰”。

一句话直觉: 算术强度是判断” GPU 在等计算还是等数据”的统一尺子。

在大模型里的位置: 优化 (推理/训练加速)

本组训练目标：代入 · 判错 · 工程 · 画图

常见卡点：

- 屋脊点 = 峰值算力 ÷ 峰值带宽，H100 约 $989/3.35 \text{ TB/s} \approx 295 \text{ FLOP/byte}$ ，比 A100 更高
- 矩阵-向量乘（batch size = 1 推理）算术强度约 $2/b$ ，严重内存受限
- Roofline 图是双对数坐标，横轴算术强度，纵轴性能（FLOP/s）

卡住回看：数学卷 § 3.3

本组在练什么：用 Roofline 定性判断操作瓶颈，理解大矩阵 vs. 逐元素操作的差异；做完应能回答：为什么 batch size = 1 推理时 GPU 利用率极低？

T-3.3.4 【易 · 判断 · Roofline 定性分析】 A100 GPU：峰值 bf16 算力 312 TFLOP/s，峰值 HBM 带宽 2 TB/s，屋脊点 $\approx 156 \text{ FLOP/byte}$ 。

对以下操作，判断计算受限还是内存受限，并给出一句理由：

- 大矩阵乘法（ $N = 4096$ ，float16）；
- 逐元素 $\exp(x)$ （softmax 的 exp 步骤）；
- Layer Norm（对 $d = 4096$ 的向量做均值/方差归一化）；
- FlashAttention 的分块内核（在 SRAM 内完成整块计算再写出）。

解答 T-3.3.4 【易 · 判断 · Roofline 定性分析】

- $N = 4096$ ，float16， $I \approx 2N/(3b) = 2 \times 4096/6 \approx 1365 \text{ FLOP/byte} \gg 156$ 。计算受限——GPU Tensor Core 满载，算力利用率最高。
- 每个元素读入 2 字节，做约 1 次 FLOP（exp 指令级浮点）， $I \approx 0.5 \text{ FLOP/byte} \ll 156$ 。内存受限——softmax 的 exp 步是带宽杀手。
- Layer Norm：读 4096 值（ $4096 \times 2 = 8192$ 字节），做约 3 遍扫描（ $\approx 12288 \text{ FLOP}$ ），写一遍（8192 字节），总内存约 24576 字节， $I \approx 12288/24576 = 0.5 \text{ FLOP/byte}$ 。内存受限。
- FlashAttention 分块内核：Q, K, V 块加载到 SRAM 后，整块运算在 SRAM 内完成，对 HBM 而言每字节数据被复用多次，等效算术强度大幅提升，趋向计算受限。这正是 FlashAttention 的设计目标：把 softmax 的带宽瓶颈“藏入”SRAM，使整个注意力核函数的 HBM 算术强度接近大矩阵乘的水平。

T-3.3.5 【中 · 推导 · 大矩阵极限算术强度 + 推理瓶颈】 对方阵乘法 $C = AB$ ， $A, B \in \mathbb{R}^{N \times N}$ ，dtype 为 b 字节/元素。

- 写出 FLOPs 和内存访问字节数的精确表达式；
- 推导算术强度 $I(N)$ ，证明 $I(N) = \frac{2N}{3b}$ （ $N \gg 1$ ）；

- (c) 当 B 退化为列向量（矩阵-向量乘，batch size = 1 推理）时，算术强度变为多少？这解释了什么工程现象？
- (d) 用一句话说明为什么连续批处理（continuous batching）能改善推理 GPU 利用率。

解答 T-3.3.5 【中 · 推导 · 大矩阵极限算术强度 + 推理瓶颈】

- (a) $\text{FLOPs} = 2N^3$ ；内存访问字节数 $= (N^2 + N^2 + N^2) \times b = 3N^2b$ 。
- (b)

$$I(N) = \frac{2N^3}{3N^2b} = \frac{2N}{3b}.$$

- (c) 矩阵-向量乘 ($B \in \mathbb{R}^{N \times 1}$): $\text{FLOPs} = 2N^2$ ，内存访问（主导项为读 A ） $\approx N^2b$ 字节， $I \approx 2N^2/(N^2b) = 2/b$ 。float16 时 $I \approx 1$ FLOP/byte，严重内存受限。这解释了推理阶段（batch size = 1）GPU 利用率极低的根本原因：每个生成步只做矩阵-向量乘，算术强度约为 1，远低于 A100 屋脊点 156，大部分 Tensor Core 在等待数据。
- (d) 连续批处理（continuous batching）将多个请求的 token 合并为一个 batch，矩阵乘从向量乘恢复为矩阵乘 ($B_{\text{batch}} \times d$ 乘以 $d \times d$)，算术强度随 batch size 增大而提升，GPU 利用率大幅改善。

T-3.3.6 【中 · 画图 · Roofline 屋脊图】请在草稿区绘制 A100 的 Roofline 屋脊图（双对数坐标）：

- 横轴：算术强度（FLOP/byte），范围 10^{-1} 到 10^3 ；
- 纵轴：性能（TFLOP/s），范围 10^{-1} 到 10^3 ；
- 画出内存受限斜线（斜率 1，过点 $(1, 2 \text{ TB/s})$ ）和计算受限水平线（312 TFLOP/s）；
- 在图上标出以下四个操作的大致位置：大矩阵乘法、softmax 的 exp、矩阵-向量乘（batch=1）、FlashAttention 分块内核；
- 用一句话解释“屋脊点”的物理含义。

解答 T-3.3.6 【中 · 画图 · Roofline 屋脊图】Roofline 屋脊图要点（草图验收标准）：

- 内存受限斜线：斜率为 1（双对数坐标下），过点 $(I, P) = (1, 2 \times 10^{12})$ FLOP/byte，即斜线方程 $P = I \times 2 \text{ TB/s}$ ；
- 计算受限水平线： $P = 312 \text{ TFLOP/s}$ ；
- 屋脊点： $I = 312/2 = 156 \text{ FLOP/byte}$ ，斜线与水平线交点；
- 各操作大致位置：softmax 的 exp 和 Layer Norm ($I \approx 0.5$) 在最左侧斜线区；矩阵-向量乘 ($I \approx 1$) 略靠右但仍在斜线区；大矩阵乘法 ($I > 300$) 在右侧水平线区；FlashAttention 分块内核效果上向右移动，进入或接近水平线区。

屋脊点的物理含义：屋脊点是“带宽受限区”和“算力受限区”的分界。算术强度低于屋脊点时，GPU 等待数据的时间多于实际计算时间；高于屋脊点时，计算单元是瓶颈，内存带宽被充分利用。

T-3.3.7【难·判错·关于 FLOPs 与速度的错误推理】 有人说：“FlashAttention v2 在 A100 上比标准 attention 快 2–4 倍，所以它的 FLOPs 也减少了 2–4 倍。”

- (a) 这句话的错误在哪里？（从 FLOPs 定义出发）
- (b) FlashAttention 的实际加速来自哪里？（提示：HBM 带宽 vs. SRAM 带宽差约 10 倍）
- (c) 在什么条件下 FlashAttention 的加速比最大？（提示：序列长度 n 、SRAM 大小 M 与 HBM 访问量的关系）

解答 T-3.3.7【难·判错·关于 FLOPs 与速度的错误推理】

- (a) FLOPs 是浮点运算的数量，由算法本身决定，与实现方式无关。FlashAttention 与标准 attention 做相同数量的浮点运算（均为 $4n^2d$ 量级），FLOPs 没有减少。说“FLOPs 减少了 2–4 倍”是错误的。
- (b) FlashAttention 的加速来自减少 HBM 读写次数：标准 attention 需将 $n \times n$ 矩阵多次写入/读出 HBM（带宽约 2 TB/s），而 FlashAttention 将中间矩阵保留在 SRAM 中（带宽约 19 TB/s，快约 10 倍），实际执行时间中带宽等待时间大幅减少，GPU 更多地在做计算而非等待数据。
- (c) 加速比最大的条件：序列长度 n 越大越好（标准 attention 的 HBM I/O 随 n^2 增长，FlashAttention 随 n^2d/M 增长，两者比值 M/d 在大 n 下使 HBM 节省更显著）；SRAM M 越大越好（分块越少，读 Q 的次数越少）；维度 d 越小越好（每次内层循环的块计算量 $\propto B_c d$ 越小，相对 HBM 数据量优势越大）。实测 A100 上 $n = 2048$ 时加速约 2–4 倍， $n = 4096$ 时更高。

做完自检

1. 矩阵乘法 FLOPs 公式 $2mnk$ 中系数 2 从哪里来？大矩阵算术强度为何随 N 线性增长？
2. Roofline 模型如何判断一个操作是计算受限还是内存受限？softmax 的 exp 为何是“带宽杀手”？
3. FlashAttention 加速比的来源是 FLOPs 减少，还是内存访问模式改变？两者有何本质区别？

§ 3.4 RoPE：把位置编码从加法变成旋转

本节建立四个公式：正弦位置编码描述加法式绝对位置的局限，RoPE 复数旋转把位置编码进相位，等价旋转矩阵给出实数域的精确表示，相对位置不变性是 RoPE 的核心数学结论。

小节导读 · 公式从哪里来

位置编码的迭代不是“换个公式试试”，而是一步步修复上一代的缺陷。

第一步：为什么最初是加法位置编码。Transformer 本身是置换不变的（换两个 token 顺序，输出不变），但语言要位置。原始论文的解决方案是把位置信息 $\sin(\omega_k t), \cos(\omega_k t)$ 直接加到 token 嵌入上。这是”可行”但不”优雅”：位置信息与语义信息被粗暴叠加，梯度在两者间互相干扰；context 拉长后后期 token 的位置在训练时可能从未见过，外推能力差。

第二步：RoPE 的”魔术”：把位置从加法改成旋转。把每两个相邻维度 (x_{2k}, x_{2k+1}) 看成复数 $z_k = x_{2k} + ix_{2k+1}$ ，然后乘以 $e^{i\omega_k t}$ （位置 t 的相位旋转）。关键观察： $\langle e^{i\omega t_1} q, e^{i\omega t_2} k \rangle = \langle q, k \rangle e^{i\omega(t_2 - t_1)}$ 。也就是说，两个位置被旋转后，点积只依赖相对位置 $t_2 - t_1$ 。这是以前”加法”永远做不到的。

第三步：为什么”相对位置”如此重要。语言的高频信号是相对的：“这个词是上一个词的主语”，“上一个”这种描述与句子的绝对位置无关。绝对位置编码需要模型”学会”从两个绝对位置推算出相对距离；相对位置直接把这件事编进 attention 内积。

第四步：外推能力是免费的新年礼。RoPE 训练时 $t \in [0, L]$ ，推理时 t 跑到了 $[0, 4L]$ ， $e^{i\omega t}$ 这个公式在所有 t 上都有明确意义。加上 NTK-aware、YaRN、LongRoPE 调频，使得一个 8K 训练的模型能被拉伸到 128K。这不是试错，是”旋转结构”本身能被拉伸的几何赋予的。

本节要拿走的一件事：“加还是乘”这个选择决定了位置编码能不能外推。RoPE 是乘，所以能。这个领悟反复出现在后续位置编码设计里。

公式 6 · 正弦位置编码（对比参照）

$$\text{PE}(\text{pos}, 2i) = \sin\left(\frac{\text{pos}}{10000^{2i/d}}\right), \quad \text{PE}(\text{pos}, 2i+1) = \cos\left(\frac{\text{pos}}{10000^{2i/d}}\right)$$

编码后 $\tilde{x}_{\text{pos}} = x_{\text{pos}} + \text{PE}(\text{pos})$ ，绝对位置以加法叠入嵌入，内积包含交叉项，依赖绝对位置而非仅相对位置。

一句话直觉：加法编码把位置信息”混入”向量，但内积无法干净地分离相对距离信号。

在大模型里的位置：架构

本组训练目标：代入 · 对比 · 反例

常见卡点：

- 正弦编码的内积在”纯零基向量”特殊情形下确实只含相对位置差，但一般情形不然
- 训练长度以外的位置，正弦编码向量与训练时分布差异大，模型无法外推
- 正弦编码与 RoPE 的本质区别：加法 vs. 乘法（旋转）

卡住回看：数学卷 § 3.4

本组在练什么：用具体数值对比正弦编码与 RoPE 的内积行为，理解”相对 vs. 绝对”的差异；做完应能回答：为什么正弦编码在超出训练长度的序列上几乎立即失效？

T-3.4.1 【易 · 代入 · 正弦编码内积依赖绝对位置】 设 $d = 2$ ，正弦位置编码 $\text{PE}(m) = (\sin m, \cos m)^\top$ ，基向量均为零 $x_m = (0, 0)^\top$ ，因此 $\tilde{x}_m = \text{PE}(m)$ 。

- (a) 计算 $\langle \tilde{x}_1, \tilde{x}_3 \rangle$ 和 $\langle \tilde{x}_2, \tilde{x}_4 \rangle$ （两对位置差均为 2）；
 (b) 两者相等吗？
 (c) 现将基向量改为非零： $x_1 = (1, 0)^\top$ ， $x_3 = (0, 1)^\top$ ，计算 $\langle \tilde{x}_1, \tilde{x}_3 \rangle$ ，与 (a) 的 $\langle \tilde{x}_1, \tilde{x}_3 \rangle$ 相比，说明正弦编码的内积在一般情形下依赖绝对位置。

解答 T-3.4.1 【易 · 代入 · 正弦编码内积依赖绝对位置】

(a) $\tilde{x}_m = \text{PE}(m) = (\sin m, \cos m)^\top$ 。内积：

$$\langle \tilde{x}_1, \tilde{x}_3 \rangle = \sin 1 \sin 3 + \cos 1 \cos 3 = \cos(3 - 1) = \cos 2 \approx -0.4161.$$

$$\langle \tilde{x}_2, \tilde{x}_4 \rangle = \cos(4 - 2) = \cos 2 \approx -0.4161.$$

(b) 在此特殊情形（纯零基向量）下两者相等，都等于 $\cos 2$ 。

(c) 改为非零基向量 $x_1 = (1, 0)^\top$ ， $x_3 = (0, 1)^\top$ ，则：

$$\tilde{x}_1 = (1 + \sin 1, \cos 1)^\top, \quad \tilde{x}_3 = (\sin 3, 1 + \cos 3)^\top.$$

$$\langle \tilde{x}_1, \tilde{x}_3 \rangle = (1 + \sin 1) \sin 3 + \cos 1 (1 + \cos 3).$$

$\approx (1 + 0.841)(0.141) + 0.540(1 + (-0.990)) = 1.841 \times 0.141 + 0.540 \times 0.010 \approx 0.259 + 0.005 = 0.264$ ，与 (a) 的 -0.416 完全不同。这说明正弦编码的内积在非零基向量情形下包含 $\langle x_m, \text{PE}(n) \rangle + \langle \text{PE}(m), x_n \rangle$ 等交叉项，依赖绝对位置 m 和 n ，而非仅相对位置差。

公式 7 · RoPE 旋转变换

$$\tilde{z}_i^q = z_i^q \cdot e^{im\theta_i}, \quad \theta_i = 10000^{-2i/d}, \quad i = 0, 1, \dots, \frac{d}{2} - 1$$

将 d 维向量 q 的第 i 对分量 (q_{2i}, q_{2i+1}) 视为复数 $z_i^q = q_{2i} + iq_{2i+1}$ ，对位置 m 处的 token 乘以单位复数 $e^{im\theta_i}$ 。

一句话直觉：位置信息编码为相位旋转，内积时绝对相位相消，只剩相对位置差。

在大模型里的位置：架构

本组训练目标：代入 · 证明 · 工程

常见卡点：

- 频率 θ_i 随 i 单调递减： $i = 0$ 最大（高频）， $i = d/2 - 1$ 最小（低频）

- 复数乘法展开后恰好等于二维旋转矩阵，不是巧合
- LLaMA/Mistral 实现中不显式构造 $d \times d$ 旋转矩阵，而是对分量对直接做复数乘法（稀疏实现）

卡住回看：数学卷 §3.4

本组在练什么：从复数乘法推导等价旋转矩阵，计算频率参数；做完应能回答：为什么 LLaMA 不显式构造 $d \times d$ 旋转矩阵，而是对每对分量独立旋转？

T-3.4.2 【易 · 计算 · 频率参数分布】 设 $d = 128$, $\theta_i = 10000^{-2i/128}$, $i = 0, 1, \dots, 63$ 。

- 计算 θ_0 、 θ_{16} 、 θ_{32} 、 θ_{63} （保留 6 位小数）；
- 对位置差 $\Delta m = 1$ ，旋转角 $= \theta_i$ 弧度。将 $i = 0$ 和 $i = 63$ 的旋转角转换为角度制；
- 解释”低下标高频捕捉近距离、高下标低频捕捉长距离”的物理直觉。

解答 T-3.4.2 【易 · 计算 · 频率参数分布】

- $\theta_i = 10000^{-2i/128}$:
 - $\theta_0 = 10000^0 = 1.000000$
 - $\theta_{16} = 10000^{-32/128} = 10000^{-0.25} = 10^{-1} = 0.100000$
 - $\theta_{32} = 10000^{-64/128} = 10000^{-0.5} = 0.010000$
 - $\theta_{63} = 10000^{-126/128} \approx 10^{-3.938} \approx 0.000115$
- 旋转角（弧度 $\times 180/\pi$ ）:
 - $i = 0$: $1 \times 180/\pi \approx 57.30^\circ$ （高频，相邻位置旋转大）
 - $i = 63$: $0.000115 \times 180/\pi \approx 0.0066^\circ$ （低频，相邻位置几乎不旋转）
- 低下标（高频）：相邻 token 旋转约 57° ，经过几个位置后相位差显著，内积变化快，模型对近距离位置关系敏感。高下标（低频）：相邻旋转仅 0.007° ，需数千步才累积出明显相位差，为模型提供辨识长距离位置关系的”慢变”坐标轴。两类频率合力覆盖从词级到段落级的位置信号。

公式 8 · 等价二维旋转矩阵

$$R_m^{(i)} = \begin{pmatrix} \cos(m\theta_i) & -\sin(m\theta_i) \\ \sin(m\theta_i) & \cos(m\theta_i) \end{pmatrix}, \quad R_m = \text{blockdiag}(R_m^{(0)}, R_m^{(1)}, \dots, R_m^{(d/2-1)}) \in \mathbb{R}^{d \times d}$$

一句话直觉：复数相位旋转的实数等价是块对角正交矩阵，每块对一对坐标轴旋转同一角度。

在大模型里的位置：架构

本组训练目标：证明 · 工程

常见卡点：

- R_m 有 $d^2/2$ 个非零元，但 LLaMA 不存储它——而是拆成 $\cos$ 和 $\sin$ 向量直接逐元素运算
- 正交矩阵的关键性质： $R^\top R = I$ ， $\|Rv\|_2 = \|v\|_2$ ， $\det(R) = 1$
- 块对角矩阵的转置仍是块对角，每块分别转置

卡住回看：数学卷 §3.4

本组在练什么：验证旋转矩阵正交性，理解 LLaMA 稀疏实现的等价性；做完应能回答：为什么用稀疏逐元素乘法实现 RoPE 比构造完整旋转矩阵节省内存和计算？

T-3.4.3【易·证明·旋转矩阵正交性与范数不变】 对任意角度 φ ，令 $R = \begin{pmatrix} \cos \varphi & -\sin \varphi \\ \sin \varphi & \cos \varphi \end{pmatrix}$ 。

- 计算 $R^\top R$ ，验证等于 I_2 ；
 - 由 (a) 证明 $\|Rv\|_2 = \|v\|_2$ （旋转是等距映射）；
 - 计算 $\det(R)$ 的精确值，说明旋转不翻转方向。
-

解答 T-3.4.3【易·证明·旋转矩阵正交性与范数不变】

(a)

$$R^\top R = \begin{pmatrix} \cos \varphi & \sin \varphi \\ -\sin \varphi & \cos \varphi \end{pmatrix} \begin{pmatrix} \cos \varphi & -\sin \varphi \\ \sin \varphi & \cos \varphi \end{pmatrix} = \begin{pmatrix} \cos^2 \varphi + \sin^2 \varphi & 0 \\ 0 & \sin^2 \varphi + \cos^2 \varphi \end{pmatrix} = I_2.$$

- $\|Rv\|_2^2 = (Rv)^\top (Rv) = v^\top R^\top R v = v^\top I_2 v = \|v\|_2^2$ ，故 $\|Rv\|_2 = \|v\|_2$ 。旋转是等距映射，不改变向量长度。
 - $\det(R) = \cos \varphi \cdot \cos \varphi - (-\sin \varphi) \cdot \sin \varphi = \cos^2 \varphi + \sin^2 \varphi = 1$ 。行列式 = 1，旋转不翻转方向（区别于反射变换 $\det = -1$ ）。
-

T-3.4.4【中·证明·复数乘法等价旋转矩阵】 将分量对 (q_{2i}, q_{2i+1}) 视为复数 $z = q_{2i} + iq_{2i+1}$ 。

- 展开 $z \cdot e^{im\theta_i} = (q_{2i} + iq_{2i+1})(\cos(m\theta_i) + i\sin(m\theta_i))$ 的实部和虚部；
 - 对比 $R_m^{(i)}(q_{2i}, q_{2i+1})^\top$ 的结果，证明二者完全一致；
 - LLaMA 的 RoPE 实现不构造 $R_m \in \mathbb{R}^{d \times d}$ ，而是对每对分量独立做复数乘法（等价于逐元素乘以 $\cos$ 向量和 $\sin$ 向量）。与完整矩阵乘法相比，这节省了多少内存（以 d 表示参数总量）？
-

解答 T-3.4.4【中·证明·复数乘法等价旋转矩阵】

(a) 展开：

$$z \cdot e^{im\theta_i} = (q_{2i} \cos(m\theta_i) - q_{2i+1} \sin(m\theta_i)) + i(q_{2i} \sin(m\theta_i) + q_{2i+1} \cos(m\theta_i)).$$

实部 = $q_{2i} \cos(m\theta_i) - q_{2i+1} \sin(m\theta_i)$ ，虚部 = $q_{2i} \sin(m\theta_i) + q_{2i+1} \cos(m\theta_i)$ 。

(b) $R_m^{(i)}(q_{2i}, q_{2i+1})^\top$ 的结果：

$$\begin{pmatrix} \cos(m\theta_i) & -\sin(m\theta_i) \\ \sin(m\theta_i) & \cos(m\theta_i) \end{pmatrix} \begin{pmatrix} q_{2i} \\ q_{2i+1} \end{pmatrix} = \begin{pmatrix} q_{2i} \cos(m\theta_i) - q_{2i+1} \sin(m\theta_i) \\ q_{2i} \sin(m\theta_i) + q_{2i+1} \cos(m\theta_i) \end{pmatrix},$$

与 (a) 的实部/虚部完全一致。

(c) 稀疏实现：每对分量做一次复数乘法，需存储 $\cos(m\theta_i)$ 和 $\sin(m\theta_i)$ 各 $d/2$ 个值，共 d 个浮点数。完整旋转矩阵 $R_m \in \mathbb{R}^{d \times d}$ 若密集存储则需 d^2 个浮点数。稀疏实现节省 $d^2 - d = d(d-1)$ 个浮点数的存储，且每个 token 的旋转运算从 $O(d^2)$ 降至 $O(d)$ 次乘法。

T-3.4.5 【中 · 工程 · RoPE 的判错题】 有人说：“RoPE 把位置编码加到 Query 和 Key 上，与正弦位置编码类似，只是换了个位置加。”

- (a) 指出这句话的两处错误（编码方式和作用位置）；
- (b) 正弦编码是加法，RoPE 是什么操作？对内积的影响有何本质不同？
- (c) 为什么 RoPE 支持训练长度以外的外推，而正弦编码几乎不能？（提示：内积对相对位置差的依赖性）

解答 T-3.4.5 【中 · 工程 · RoPE 的判错题】

- (a) 两处错误：① 正弦编码的操作是加法 ($x' = x + \text{PE}$)，而 RoPE 是乘法（旋转），本质上是将向量在复平面上旋转一个角度，而非叠加一个固定向量；② 正弦编码作用于输入嵌入 x （在进入注意力层之前），而 RoPE 作用于注意力层内部的 query 和 key（每次计算注意力时施加），不修改原始嵌入。
- (b) 正弦编码是加法，编码向量混入 x 后内积包含交叉项 $\langle x_m, \text{PE}(n) \rangle$ 等，依赖绝对位置。RoPE 是旋转乘法，内积时旋转矩阵满足 $R_m^\top R_n = R_{n-m}$ ，绝对相位在共轭相消，内积严格只含相对位置差 $n - m$ 。
- (c) 正弦编码的位置向量 $\text{PE}(m)$ 在训练长度以外的 m 值处，其分量值与训练分布差异越来越大（某些频率的 $\sin/\cos$ 值进入之前从未见过的相位区域），模型无法推广。RoPE 的内积只依赖 $n - m$ ，只要相对位置差在已见范围内（即便绝对位置超出训练长度），注意力分数就与训练时行为一致；通过调整 θ_i 的基底（如从 10000 改为 500000），可进一步扩展可外推的相对距离范围。

公式 9 · RoPE 相对位置不变性

$$\langle \tilde{q}_m, \tilde{k}_n \rangle = q_m^\top R_m^\top R_n k_n = q_m^\top R_{n-m} k_n$$

由旋转矩阵的角度可加性 $R_m^\top R_n = R_{n-m}$ ，内积仅依赖位置差 $n - m$ ，绝对位置信息从内积中消去。

一句话直觉：两个旋转向量的内积等于原向量通过”差旋转”的内积，绝对相位在共轭时抵消。

在大模型里的位置：架构

本组训练目标：证明 · 变形 · 工程

常见卡点：

- 角度可加性 $R_m^\top R_n = R_{n-m}$ 是块对角矩阵性质，每块独立满足
- 注意是 $R_m^\top$ 不是 R_m （正交矩阵的转置 = 逆）
- 位置平移不变： $m \rightarrow m + \Delta$ ， $n \rightarrow n + \Delta$ 时内积不变

卡住回看：数学卷 §3.4

本组在练什么：串联正交性和角度可加性，完整推导相对位置不变；做完应能回答：为什么 RoPE 自然支持”平移等变”——把整段对话向后移几个位置，注意力分数不变？

T-3.4.6 【中 · 证明 · 旋转角度可加性】

- 对两个二维旋转矩阵 R_α 、 R_β ，利用三角恒等式计算 $R_\alpha^\top R_\beta$ ，证明等于 $R_{\beta-\alpha}$ ；
- 将 (a) 推广到块对角矩阵，证明 $R_m^\top R_n = R_{n-m}$ ；
- 由 (b) 推出 $R_m^{-1} = R_{-m}$ ，并验证 $R_0 = I_d$ 。

解答 T-3.4.6 【中 · 证明 · 旋转角度可加性】

(a)

$$R_\alpha^\top R_\beta = \begin{pmatrix} \cos \alpha & \sin \alpha \\ -\sin \alpha & \cos \alpha \end{pmatrix} \begin{pmatrix} \cos \beta & -\sin \beta \\ \sin \beta & \cos \beta \end{pmatrix} = \begin{pmatrix} \cos \alpha \cos \beta + \sin \alpha \sin \beta & -\cos \alpha \sin \beta + \sin \alpha \cos \beta \\ -\sin \alpha \cos \beta + \cos \alpha \sin \beta & \sin \alpha \sin \beta + \cos \alpha \cos \beta \end{pmatrix}$$

利用三角恒等式： $\cos(\beta - \alpha) = \cos \alpha \cos \beta + \sin \alpha \sin \beta$ ， $\sin(\beta - \alpha) = \sin \beta \cos \alpha - \cos \beta \sin \alpha$ ，得

$$R_\alpha^\top R_\beta = \begin{pmatrix} \cos(\beta - \alpha) & -\sin(\beta - \alpha) \\ \sin(\beta - \alpha) & \cos(\beta - \alpha) \end{pmatrix} = R_{\beta-\alpha}.$$

- $R_m^\top R_n$ 是块对角矩阵，第 i 块为 $(R_{m\theta_i})^\top R_{n\theta_i}$ 。对应角度 $\alpha = m\theta_i$ ， $\beta = n\theta_i$ ，由 (a) 得：

$$(R_{m\theta_i})^\top R_{n\theta_i} = R_{(n-m)\theta_i}.$$

故 $R_m^\top R_n = \text{blockdiag}(R_{(n-m)\theta_0}, \dots, R_{(n-m)\theta_{d/2-1}}) = R_{n-m}$ 。

- (c) 令 $n = 0$: $R_m^\top R_0 = R_{-m}$, 而 $R_0 = \text{blockdiag}(R_0, \dots) = I_d$, 故 $R_m^\top = R_{-m}$, 即 $R_m^{-1} = R_{-m}$ 。令 $m = n = 0$: $R_0 = R_0$ 且由块对角各块 $R_0 = I_2$, 得 $R_0 = I_d$ 。

T-3.4.7 【中 · 证明 · 相对位置不变性完整推导】 设位置 m 处的 query 和位置 n 处的 key 经 RoPE 后分别为 $\tilde{q}_m = R_m q_m$ 、 $\tilde{k}_n = R_n k_n$ 。

- (a) 展开内积 $\langle \tilde{q}_m, \tilde{k}_n \rangle$;
 (b) 利用 T-3.4.6 的结论化简为仅含 $n - m$ 的表达式;
 (c) 说明当 m 和 n 同时加 Δ 时, 内积不变——这对推理阶段的位置泛化意味着什么?

解答 T-3.4.7 【中 · 证明 · 相对位置不变性完整推导】

- (a) 展开:

$$\langle \tilde{q}_m, \tilde{k}_n \rangle = \tilde{q}_m^\top \tilde{k}_n = (R_m q_m)^\top (R_n k_n) = q_m^\top R_m^\top R_n k_n.$$

- (b) 由 T-3.4.6 (b), $R_m^\top R_n = R_{n-m}$, 故:

$$\langle \tilde{q}_m, \tilde{k}_n \rangle = q_m^\top R_{n-m} k_n = \langle q_m, R_{n-m} k_n \rangle.$$

结果只含位置差 $n - m$, 不含绝对位置 m 或 n 。

- (c) 当 $m \rightarrow m + \Delta$, $n \rightarrow n + \Delta$: 位置差 $(n + \Delta) - (m + \Delta) = n - m$ 不变, 内积值不变。这意味着平移整段对话不改变任何注意力分数——模型对绝对位置的平移是不变的, 天然感知相对距离。在推理阶段, 即使上下文超出训练长度, 只要相对位置差在训练范围内, 注意力行为与训练时一致; 通过调整频率基数可进一步扩展可感知的相对距离, 这是 YaRN 等长上下文扩展方法的数学基础。

T-3.4.8 【难 · 画图 · RoPE 旋转图与频率尺度】 请在草稿区画出 RoPE 旋转的示意图:

- 画两个二维平面, 分别对应频率 θ_0 (高频) 和 θ_{63} (低频);
- 在每个平面上画出位置 $m = 1, 2, 3$ 对应的向量旋转轨迹 (假设初始向量 $= (1, 0)^\top$);
- 标注两个频率下”位置差 $\Delta m = 10$ “时旋转角的大小差异;
- 用一句话解释为什么需要多个频率分量才能区分不同距离的位置关系。

解答 T-3.4.8 【难 · 画图 · RoPE 旋转图与频率尺度】 画图要点（草图验收标准）：

- 高频平面 ($\theta_0 = 1 \text{ rad}$)： $m = 1, 2, 3$ 对应旋转角 $57.3^\circ, 114.6^\circ, 171.9^\circ$ ，初始向量 $(1, 0)^\top$ 依次旋转，三个向量在圆上均匀分布，相邻夹角约 57° ，区分度高；
- 低频平面 ($\theta_{63} \approx 0.000115 \text{ rad}$)： $m = 1, 2, 3$ 旋转角分别 $\approx 0.0066^\circ, 0.013^\circ, 0.020^\circ$ ，三个向量几乎重叠，无法区分相邻位置；
- 位置差 $\Delta m = 10$ 时：高频平面旋转 $10 \times 57.3^\circ = 573^\circ$ （绕圈），低频平面旋转 $10 \times 0.0066^\circ = 0.066^\circ$ （微乎其微）；
- 一句话解释：单一频率只能在某一尺度上有效区分位置——高频适合近距离，低频适合远距离；多频率叠加才能在从 1 步到数千步的全范围内提供可区分的位置信号。

做完自检

1. 正弦编码与 RoPE 的根本区别是什么？为什么 RoPE 的内积严格只依赖位置差 $n - m$ ？
2. RoPE 角度可加性 $R_m^\top R_n = R_{n-m}$ 的推导依赖旋转矩阵的哪个性质？
3. 为什么 LLaMA/Mistral 不显式构造 $d \times d$ 旋转矩阵，而用逐元素复数乘法代替？节省了什么？

§ 3.5 FlashAttention：当注意力撞上内存墙

本节建立四个公式：标准 Attention 的 HBM I/O 代价量化内存墙来源，数值稳定 softmax（减最大值 trick）保证数值安全，在线 softmax 递推允许分块计算，分块输出更新把递推推广到 Value 矩阵。最终得到 FlashAttention 的 I/O 复杂度从 $\Theta(n^2)$ 降至近线性的结论。

小节导读 · 公式从哪里来

FlashAttention 不是“一个优化”，而是“重新推导了 attention 能怎么计算”。本节的所有公式都是为了一个问题：能不能避免把 $n \times n$ 的注意力矩阵完整写到 HBM？

第一步：标准 attention 为什么被内存墙撞死。完整 attention 要：读 Q, K 计算 $S = QK^\top/\sqrt{d}$ 写到 HBM；读 S 做 softmax 得 P 写回 HBM；读 P, V 计算 $O = PV$ 。这三趟都在 $n \times n$ 的 S 与 P 上走 HBM。总 I/O 量 $\sim n^2$ ，与计算量 $\sim n^2 d$ 相比，算术强度 $I \sim d$ 、在 H100 上小于脊点 295、内存受限。越长越撞。

第二步：softmax 的“可分解性”是决定性发现。你以为 softmax 不能分块计算——因为归一化需要看到所有 $\exp(s_j)$ 。在线 softmax 发现了一个递推：看到一个新块时，你只需要调整上一块累积的“最大值”和“归一化分母”，就能合并。 $m_t = \max(m_{t-1}, s_t)$ 、 $\ell_t = \ell_{t-1} e^{m_{t-1} - m_t} + e^{s_t - m_t}$ 。这个递推是 FlashAttention 能存在的数学基础。

第三步：分块 tiling 把 S 从主存里删了。把 K, V 分成能装进 SRAM 的块，一块一块扫过去，每扫完一块就用上一步的递推更新输出 O 和归一化量。 $n \times n$ 的 S, P 从未被实际写下过。I/O 复杂度从 $\Theta(n^2)$ 降为 $\Theta(n^2 d^2/M)$ (M 是 SRAM 大小)，近线性。

第四步：“可分解”的领悟反过来塑造了下一代架构。一旦你看到 softmax 能递推、attention 能被 tiling，就能推广到多卡：RingAttention 让 K, V 块在 GPU 环上流动，计

算与通信重叠，能做到 1M context。这是”重新推导”能在下一代架构上留下的遗产。
本节要拿走的一件事：优化不是减 FLOPs。计算价格在现代 GPU 上远不及”从 HBM 搬数据”的价格。任何后续架构优化，如果不考虑 I/O 都会被内存墙接住。

公式 10 · 标准 Attention 的 HBM I/O 代价

标准实现三步写回 HBM，总访问量（元素数）：

$$\text{HBM 访问} = \underbrace{2nd + n^2}_{\text{步骤 1}} + \underbrace{2n^2}_{\text{步骤 2}} + \underbrace{n^2 + 2nd}_{\text{步骤 3}} = 4n^2 + 4nd = \Theta(n^2 + nd)$$

长序列下 n^2 主导，softmax 步骤须读写完整的 $n \times n$ 矩阵，是带宽瓶颈所在。

一句话直觉：标准 attention 的慢不是因为算得多，而是因为 $n \times n$ 矩阵在 HBM 和 SRAM 之间反复搬运。

在大模型里的位置：优化

本组训练目标：代入 · 变形 · 工程

常见卡点：

- 每步不仅读还写（softmax 步骤读 S 写 P ，各算一次）
- 注意力分数矩阵 $S \in \mathbb{R}^{n \times n}$ 在长序列时大到无法放入 SRAM
- FLOPs 与 HBM I/O 是两个独立的瓶颈，FlashAttention 只改变后者

卡住回看：数学卷 §3.5

本组在练什么：逐步骤核算 HBM 读写量，确认 n^2 项的来源；做完应能回答：序列从 1K 增到 4K，标准 attention 的 HBM 访问量增加几倍？

T-3.5.1 【中 · 推导 · 标准 Attention 的 HBM I/O】 设序列长度 n ，维度 d ，float16（2 字节/元素）。标准实现执行三步：

步骤 1：从 HBM 读 Q, K ，计算 $S = QK^\top$ ，写回 HBM。

步骤 2：从 HBM 读 S ，计算逐行 softmax 得 P ，写回 HBM。

步骤 3：从 HBM 读 P 和 V ，计算 $O = PV$ ，写回 HBM。

- 分别列出三步的 HBM 读写量（元素数）；
- 求总量，在 $n \gg d$ 时哪项主导？
- 设 $n = 4096$ ， $d = 64$ ，计算总 HBM 访问字节数（单位 GB）；
- n 从 1024 增到 4096，HBM 访问量约增加几倍？

解答 T-3.5.1 【中 · 推导 · 标准 Attention 的 HBM I/O】

- 三步 HBM 读写量（元素数）：

步骤1: 读 $Q (nd)$ + 读 $K (nd) = 2nd$ 读; 写 $S (n^2)$ 写。共 $2nd + n^2$ 。

步骤2: 读 $S (n^2)$ 读; 写 $P (n^2)$ 写。共 $2n^2$ 。

步骤3: 读 $P (n^2)$ + 读 $V (nd)$ 读; 写 $O (nd)$ 写。共 $n^2 + 2nd$ 。

(b) 总元素数 $= (2nd + n^2) + 2n^2 + (n^2 + 2nd) = 4n^2 + 4nd$ 。当 $n \gg d$ 时, $4n^2$ 主导 (n^2 vs. $nd = n \cdot d$, 前者是后者的 n/d 倍)。

(c) $n = 4096, d = 64$: 总元素数 $= 4 \times 4096^2 + 4 \times 4096 \times 64 = 67,108,864 + 1,048,576 = 68,157,440$ 。字节数 $= 68,157,440 \times 2 \approx 1.363 \times 10^8 \approx 0.136$ GB。

(d) $n : 1024 \rightarrow 4096$ (4 倍), HBM 访问量 $\propto 4n^2$: 增加 16 倍 ($4096^2/1024^2 = 16$)。

公式 11 · 数值稳定 softmax (减最大值 trick)

$$\text{softmax}(z)_i = \frac{\exp(z_i - m)}{\sum_l \exp(z_l - m)}, \quad m = \max_l z_l$$

减去最大值 m 后, 最大参数为 0, 所有 $\exp$ 参数 ≤ 0 , 输出在 $(0, 1]$ 之间, 从根本上防止上溢 (overflow)。可证明减去任意常数 c 不改变 softmax 结果 (平移不变性)。

一句话直觉: 用最大值作为基准, 把所有指数”拉回”安全范围, 同时不影响输出。

在大模型里的位置: 优化 (数值稳定)

本组训练目标: 代入 · 证明 · 工程

常见卡点:

- 只减最大值, 不改变 softmax 结果——这是 FlashAttention 在线递推合法性的基础
- float32 上溢阈值约 88.7 ($e^{88.7} \approx 3.4 \times 10^{38}$), 注意力 logits 在高维下不缩放时很容易超过此值
- 下溢 (underflow) 为 0 不改变 softmax 正确性 (0 的贡献恰当处理)

卡住回看: 数学卷 § 3.5

本组在练什么: 验证减最大值不改变结果, 理解 FlashAttention 在线递推的数值安全保证; 做完应能回答: 如果不减最大值, float16 在什么 logit 量级开始溢出?

T-3.5.2 【易 · 边界 · 数值稳定性验证】 设 $z = (1000, 999, 998)$, $\text{dtype} = \text{float32}$ (上溢阈值约 $e^{88.7}$)。

- 不做任何位移, $\exp(1000)$ 在 float32 中的结果是什么 (溢出/正常)?
- 减去最大值 $m = 1000$ 后, 计算 $(\exp(0), \exp(-1), \exp(-2))$, 数值是否正常?
- 证明减去任意常数 c 不改变 softmax 输出 (一行代数);
- float16 的上溢阈值约 $e^{11.1} \approx 65504$, 即参数超过 11.1 就溢出。在 $d_k = 64$ 未缩放时, 两个独立标准正态分量内积的标准差是多少? 超出 float16 上溢阈值的概率大

吗？（定性说明即可）

解答 T-3.5.2 【易 · 边界 · 数值稳定性验证】

- (a) $\exp(1000)$: float32 上溢阈值约 88.7 ($e^{88.7} \approx 3.4 \times 10^{38}$, 即 float32 最大值), $1000 \gg 88.7$, 结果为 $+\infty$, 溢出。
- (b) 减去 $m = 1000$: $(\exp(0), \exp(-1), \exp(-2)) = (1, 0.3679, 0.1353)$, 均在 $(0, 1]$, 完全正常。
- (c) 减去常数 c 的不变性:

$$\frac{\exp(z_i - c)}{\sum_l \exp(z_l - c)} = \frac{e^{z_i} \cdot e^{-c}}{e^{-c} \sum_l e^{z_l}} = \frac{e^{z_i}}{\sum_l e^{z_l}} = \text{softmax}(z)_i.$$

- (d) $d_k = 64$ 未缩放时, 内积标准差 $= \sqrt{d_k} = 8$ 。float16 上溢阈值约 11.1 ($e^{11.1} \approx 65504$)。内积服从均值 0、标准差 8 的分布, 超过 11.1 的概率 $= P(Z > 11.1/8) = P(Z > 1.39) \approx 8\%$ (标准正态表)。在长序列中, n^2 对内积里有相当比例会超过阈值, float16 下不缩放时溢出风险很高; 这正是 $\sqrt{d_k}$ 缩放在 float16 训练中不可省略的理由。

公式 12 · 在线 softmax 递推

$$m_j = \max(m_{j-1}, \tilde{m}_j), \quad \ell_j = e^{m_{j-1} - m_j} \ell_{j-1} + e^{\tilde{m}_j - m_j} \tilde{\ell}_j$$

其中 $\tilde{m}_j = \max(s_j)$, $\tilde{\ell}_j = \sum_l \exp(s_{jl} - \tilde{m}_j)$ 为第 j 块的局部指数和。通过维护滚动最大值 m_j 和归一化因子 ℓ_j , 无需全局统计量即可正确计算 softmax。

一句话直觉: 遍历各块时滚动更新”当前最大值”和”当前指数和”, 最终等价于对所有元素同时做 softmax。

在大模型里的位置: 优化

本组训练目标: 代入 · 证明 · 工程

常见卡点:

- 修正因子 $e^{m_{j-1} - m_j}$ 的作用: 当新块有更大的最大值时, 旧的归一化因子需要等比例缩放
- ℓ_j 不是普通累加, 而是带权重的累加——权重正好抵消不同块的”基准”差异
- 初始值 $m_0 = -\infty$, $\ell_0 = 0$ 使第一步 $e^{m_0 - m_1} \cdot 0 = 0$ 自动消失

卡住回看: 数学卷 § 3.5

本组在练什么: 手动运行两步递推, 验证与全局 softmax 结果一致; 做完应能回答: 在线递推中 $e^{m_{j-1} - m_j}$ 这个修正因子的作用是什么?

T-3.5.3【中·手算·在线 softmax 两步递推】 设注意力分数向量 $s = (3, 1, 2, 4, 0, 2)$, 分两块: 第一块 $s_1 = (3, 1, 2)$, 第二块 $s_2 = (4, 0, 2)$ 。

- 初始 $m_0 = -\infty$, $\ell_0 = 0$ 。处理第一块, 求 $\tilde{m}_1, \tilde{\ell}_1, m_1, \ell_1$;
- 处理第二块, 求 $\tilde{m}_2, \tilde{\ell}_2, m_2, \ell_2$;
- 计算全部 6 个 $p_l = \exp(s_l - m_2)/\ell_2$ (保留 4 位小数);
- 验证: 直接对 s 全局做 softmax (减最大值 4), 结果是否与 (c) 一致?

解答 T-3.5.3【中·手算·在线 softmax 两步递推】

- 初始 $m_0 = -\infty$, $\ell_0 = 0$ 。第一块 $s_1 = (3, 1, 2)$:
 $\tilde{m}_1 = \max(3, 1, 2) = 3$;
 $\tilde{\ell}_1 = e^{3-3} + e^{1-3} + e^{2-3} = 1 + e^{-2} + e^{-1} \approx 1 + 0.1353 + 0.3679 = 1.5032$;
 $m_1 = \max(-\infty, 3) = 3$;
 $\ell_1 = e^{-\infty-3} \cdot 0 + e^{3-3} \cdot 1.5032 = 0 + 1.5032 = 1.5032$ 。
- 第二块 $s_2 = (4, 0, 2)$:
 $\tilde{m}_2 = \max(4, 0, 2) = 4$;
 $\tilde{\ell}_2 = e^{4-4} + e^{0-4} + e^{2-4} = 1 + e^{-4} + e^{-2} \approx 1 + 0.0183 + 0.1353 = 1.1536$;
 $m_2 = \max(3, 4) = 4$;
 $\ell_2 = e^{3-4} \cdot 1.5032 + e^{4-4} \cdot 1.1536 = e^{-1} \times 1.5032 + 1.1536 \approx 0.5530 + 1.1536 = 1.7066$ 。
- $p_l = \exp(s_l - 4)/1.7066$:
 - $s = 3$: $p_1 = e^{-1}/1.7066 \approx 0.2155$
 - $s = 1$: $p_2 = e^{-3}/1.7066 \approx 0.0292$
 - $s = 2$: $p_3 = e^{-2}/1.7066 \approx 0.0793$
 - $s = 4$: $p_4 = e^0/1.7066 \approx 0.5858$
 - $s = 0$: $p_5 = e^{-4}/1.7066 \approx 0.0107$
 - $s = 2$: $p_6 = e^{-2}/1.7066 \approx 0.0793$
- 全局 softmax (减最大值 4): $\ell^* = e^{-1} + e^{-3} + e^{-2} + 1 + e^{-4} + e^{-2} = 0.3679 + 0.0498 + 0.1353 + 1 + 0.0183 + 0.1353 = 1.7066$, 与 ℓ_2 完全一致, 各 p_l 相同。

T-3.5.4【难·证明·在线递推正确性 (两块情形)】 设全局分数向量 $s = (s_1^\top, s_2^\top)$ (各 B 维), 全局最大值 $m^* = \max(m_1^*, m_2^*)$, 全局归一化因子 $\ell^* = \sum_l \exp(s_l - m^*)$ 。

- 写出第一块的局部统计量 m_1^*, ℓ_1^* ;
- 处理第二块后, 验证在线递推给出的 $\ell_2 = e^{m_1^* - m^*} \ell_1^* + e^{m_2^* - m^*} \ell_2^* = \ell^*$;
- 代入分块输出更新公式, 验证最终输出 O_2 等于正确归一化输出 O^* (展开每一步)。

解答 T-3.5.4 【难 · 证明 · 在线递推正确性（两块情形）】

(a) 第一块： $m_1^* = \max(s_1)$, $\ell_1^* = \sum_{l \in \text{block}_1} \exp(s_l - m_1^*)$ 。

(b) 设全局最大值 $m^* = \max(m_1^*, m_2^*)$ （即在线递推最终的 m_2 ）。

$$\ell_2 = e^{m_1^* - m^*} \ell_1^* + e^{m_2^* - m^*} \ell_2^*.$$

展开：

$$= e^{m_1^* - m^*} \sum_{l \in \text{block}_1} e^{s_l - m_1^*} + e^{m_2^* - m^*} \sum_{l \in \text{block}_2} e^{s_l - m_2^*} = \sum_{l \in \text{block}_1} e^{s_l - m^*} + \sum_{l \in \text{block}_2} e^{s_l - m^*} = \ell^*.$$

(c) 设 $\tilde{O}_1 = \frac{1}{\ell_1^*} \sum_{l \in \text{block}_1} e^{s_l - m_1^*} v_l$, $\tilde{O}_2 = \frac{1}{\ell_2^*} \sum_{l \in \text{block}_2} e^{s_l - m_2^*} v_l$ 。

$$\begin{aligned} O_2 &= \frac{1}{\ell_2} (\ell_1^* e^{m_1^* - m^*} \tilde{O}_1 + e^{m_2^* - m^*} \ell_2^* \tilde{O}_2) \\ &= \frac{1}{\ell^*} \left(\sum_{l \in \text{block}_1} e^{s_l - m^*} v_l + \sum_{l \in \text{block}_2} e^{s_l - m^*} v_l \right) = O^*. \end{aligned}$$

两块遍历后精确还原全局归一化输出。

公式 13 · 分块输出更新与 FlashAttention I/O 复杂度

$$O_j = \text{diag}(\ell_j)^{-1} (\text{diag}(\ell_{j-1}) e^{m_{j-1} - m_j} O_{j-1} + e^{\tilde{m}_j - m_j} \tilde{P}_j V_j)$$

FlashAttention 通过此递推，在 SRAM 内完成” 矩阵乘 + softmax + 再乘”，只将 O_j 写回 HBM，将 HBM 访问量从 $\Theta(n^2 d)$ 压缩至 $\Theta(n^2 d^2 / M)$ （ M 为 SRAM 大小，单位为元素数；推导见 Dao 2022 Theorem 2）。

一句话直觉：把 $n \times n$ 矩阵” 藏在” SRAM 里分块处理，HBM 只看到输入输出，看不到中间的 n^2 矩阵。

在大模型里的位置：优化

本组训练目标：代入 · 变形 · 工程

常见卡点：

- $\text{diag}(\ell_j)^{-1}$ 是将每行除以对应的 ℓ_j （逐行归一化）
- FLOPs 不变，改变的只是内存访问模式——GPU Tensor Core 利用率提升
- FlashAttention v2 进一步减少了 non-matmul FLOPs；FlashAttention v3 针对 H100 Tensor Core 格式做了优化

卡住回看：数学卷 §3.5

本组在练什么：推导 FlashAttention 的 I/O 复杂度，理解 FLOPs 不变但速度提升的本质；做完应能回答：FlashAttention 的实际加速比何时最大——序列越长越好，还是维度 d 越大越好？

T-3.5.5 【中 · 推导 · FlashAttention I/O 复杂度】 设序列长度 n ，头维度 d ，SRAM 大小 M 个元素。 Q 块大小 B_r ， K/V 块大小 $B_c = \Theta(M/d)$ 。

- 外层循环 n/B_r 次，内层循环 n/B_c 次，每次内层读入 K 块和 V 块各 $B_c \times d$ 元素。写出总 HBM 读写量（元素数，含 Q 的一次性读入和 O 的写出）；
- 将 $B_c = \Theta(M/d)$ 代入，化简主导项为 $\Theta(n^2 d^2 / M)$ ；
- 与标准实现的 $\Theta(n^2 d)$ （需写回中间矩阵 S, P 到 HBM）对比，当 $M = \Theta(nd)$ 时 I/O 降为多少？这对应什么极端情形？

解答 T-3.5.5 【中 · 推导 · FlashAttention I/O 复杂度】

- 分析 HBM 读写：
 - 读 Q （外层循环，每外层读一个 Q 块）： $(n/B_r) \times B_r d = nd$ 元素；
 - 读 K （内层循环，每次内层读一个 K 块）： $(n/B_r) \times (n/B_c) \times B_c d = n^2 d / B_r$ 元素；
 - 读 V （同 K ）： $n^2 d / B_r$ 元素；
 - 写 O （每外层循环写一个 O 块）： nd 元素。

总 HBM 读写 $\approx 2n^2 d / B_r + 2nd$ ，主导项为 $2n^2 d / B_r$ 。

- $B_c = \Theta(M/d)$ ，由 SRAM 约束 $B_r d \leq M/4$ 故 $B_r = \Theta(M/d)$ 。代入主导项：

$$\frac{2n^2 d}{B_r} = \frac{2n^2 d}{\Theta(M/d)} = \Theta\left(\frac{n^2 d^2}{M}\right).$$

此即 Dao 2022 Theorem 2 中的 $\Theta(N^2 d^2 / M)$ 上界（论文记 N 为序列长度）。

- 当 $M = \Theta(nd)$ （SRAM 足够大，能装下整个 K 或 V ）， $B_c = \Theta(n)$ ，外层 1 次内层 1 次：总 HBM $\rightarrow \Theta(nd)$ ，与序列长度线性。这对应“SRAM 无限大、一次读入所有数据完成全部计算”的理想极端；实际中 SRAM 远小于 nd ，但表明 SRAM 越大，I/O 节省越多。

T-3.5.6 【中 · 验证 · FLOPs 不变性】

- 标准实现： $S = QK^\top$ 的 FLOPs 为 $2n^2 d$ ， $O = PV$ 的 FLOPs 为 $2n^2 d$ ，总计多少？
- FlashAttention 分块：外层 n/B_r 次，内层 n/B_c 次，每次内层的矩阵乘 FLOPs 为 $2B_r B_c d$ （ $QK^\top$ 块）+ $2B_r B_c d$ （ PV 块）。写出总矩阵乘 FLOPs；

- (c) 化简 (b)，证明等于 (a)（与 B_r, B_c 无关）；
 (d) 用一句话概括：FlashAttention 改变的是 __，不变的是 __。
-

解答 T-3.5.6 【中·验证·FLOPs 不变性】

- (a) 标准实现总 FLOPs = $2n^2d + 2n^2d = 4n^2d$ 。
 (b) FlashAttention 分块：外层 n/B_r 次，内层 n/B_c 次，每次内层：
 · Q 块 ($B_r \times d$) 与 K 块 ($d \times B_c$) 矩阵乘： $2B_rB_cd$ FLOPs；
 · P 块 ($B_r \times B_c$) 与 V 块 ($B_c \times d$) 矩阵乘： $2B_rB_cd$ FLOPs。
 每次内层共 $4B_rB_cd$ ，总矩阵乘 FLOPs = $\frac{n}{B_r} \times \frac{n}{B_c} \times 4B_rB_cd = 4n^2d$ 。
 (c) (a) = (b) = $4n^2d$ ，与块大小 B_r, B_c 无关。
 (d) FlashAttention 改变的是内存访问模式 (HBM I/O)，不变的是浮点运算量 (FLOPs)。
-

T-3.5.7 【难·工程·FlashAttention 的适用边界】 有人说：“GQA（分组查询注意力）和 MQA（多查询注意力）把多个头共享同一组 KV，KV cache 大幅减少，所以推理时不再需要 FlashAttention 了。”

- (a) 说明 GQA/MQA 减少的是什么（KV cache 大小）；
 (b) FlashAttention 减少的是什么（HBM 带宽），两者解决的是同一瓶颈吗？
 (c) 在推理（prefill 阶段，输入长序列一次性计算注意力）时，GQA + FlashAttention 是否仍有叠加收益？给出定性分析。
-

解答 T-3.5.7 【难·工程·FlashAttention 的适用边界】

- (a) GQA/MQA 减少的是 KV cache 的存储量（多个 query 头共享同一组 KV 头，每个解码步所需的 KV 数据减少 G 倍）以及对应的 HBM 带宽（解码时读取 KV cache 的数据量）。
 (b) FlashAttention 减少的是 prefill 阶段（以及训练中）注意力计算时 $n \times n$ 中间矩阵的 HBM 读写。GQA 主要帮助解码（decoding）阶段的 KV cache 加载，FlashAttention 主要帮助 prefill 阶段的矩阵乘 + softmax 计算。两者解决的不是同一瓶颈，因此可以叠加使用。
 (c) 在 prefill 阶段（输入长序列一次性计算注意力）：GQA 减少了每个 token 需要生成的 KV 数量（KV 头数量 / G ），FlashAttention 对每个（更少的）KV 头的注意力计算仍需处理 $n \times n$ 规模的分块矩阵乘——FlashAttention 的加速仍然有效，且由于 KV 块数量减少，SRAM 中可以放更大的分块，分块次数减少，额外节省 HBM I/O。两者有叠加收益。
-

做完自检

1. 标准 attention 的 HBM I/O 为 $\Theta(n^2)$ 的根本原因是什么？FlashAttention 通过哪个核心技术绕开了这一约束？
2. 在线 softmax 递推中，修正因子 $e^{m_{j-1}-m_j}$ 的作用是什么？没有它会出现什么问题？
3. FlashAttention 改变了 FLOPs 吗？它真正改变的是什么，以及为什么这能让 GPU 从内存受限转变为计算受限？

§ 3.6 习题：注意力的真实身份——关联记忆，而非「注意力」

导读：本节核心是现代 Hopfield 网络与 softmax 注意力的数学等价：log-sum-exp 能量函数的不动点迭代，精确对应一次注意力前向传播，同时带来存储容量从线性跃升至指数级。五题分别对应：经典 Hopfield 网络能量函数与容量、log-sum-exp 算子的数学性质、不动点推导、等价性的代入验证、以及容量指数化的工程意义与类比边界。

题 1【轻 · 推导 · 经典 Hopfield 网络的能量函数与容量】 导读：理解经典版本的线性容量限制，是明白「为什么需要换能量函数」的前提。

设经典 Hopfield 网络存储 N 个 d 维二值模式 $\xi^1, \dots, \xi^N \in \{-1, +1\}^d$ ，权重矩阵为 $W = X^T X - NI$ ($X \in \mathbb{R}^{N \times d}$ 为模式矩阵， I 为 $d \times d$ 单位矩阵)，能量函数为

$$E_{\text{classic}} = -\frac{1}{2} \xi^T W \xi$$

(a) 将 $W = X^T X - NI$ 代入能量函数，化简得到 E_{classic} 关于 ξ 和 X 的表达式，说明其含义：能量极小值对应什么几何关系？

(b) 经典 Hopfield 网络的检索更新规则是 $\xi_i^{\text{new}} = \text{sgn}((W\xi)_i)$ ，这等价于沿能量梯度下降的哪个步骤？

(c) 经典版本的存储容量约为 $0.14d$ （随机模式情形）。对 $d = 512$ ，该网络最多可靠存储多少个模式？若 WordNet 名词层级有约 8×10^4 个节点，用经典 Hopfield 网络以 $d = 512$ 嵌入所有节点是否可行？

(d) 解释为什么二次能量函数 $-\xi^T W \xi$ 的容量受到「串扰 (crosstalk)」的限制，直觉上串扰是如何产生的？

教学注：(a) 的化简揭示了经典 Hopfield 本质上在做 ℓ^2 范数最大化，即找最接近某个存储模式的方向——这是线性近似，只有不太密集的模式集才能正常检索。

陷阱：

- W 里减去 NI 是为了消除「自强化」效应（一个模式预测自己总是能量极小）
- 存储容量 $0.14d$ 是随机模式的概率保证，对结构化数据（如词嵌入这样高度相关的向量集）实际容量更低

题 2【中 · 推导 · log-sum-exp 算子的数学性质】 导读：log-sum-exp 是连接能量函数和 softmax 的数学桥梁——搞清楚它的微分性质，不动点推导就会水到渠成。

定义 log-sum-exp 算子 $\text{lse}(\beta, z) = \beta^{-1} \log \sum_{i=1}^N \exp(\beta z_i)$, 其中 $z \in \mathbb{R}^N$, $\beta > 0$ 。

(a) 证明 $\frac{\partial}{\partial z_j} \text{lse}(\beta, z) = \text{softmax}(\beta z)_j = \frac{\exp(\beta z_j)}{\sum_i \exp(\beta z_i)}$ 。

(b) 设 $z = X\xi$ ($X \in \mathbb{R}^{N \times d}$, $\xi \in \mathbb{R}^d$), 利用链式法则计算 $\frac{\partial}{\partial \xi} \text{lse}(\beta, X\xi)$, 用 X 和 $\text{softmax}(\beta X\xi)$ 表示结果。

(c) 当 $\beta \rightarrow \infty$ 时, $\text{lse}(\beta, z)$ 趋向于 $\max_i z_i$ (即 ℓ^∞ 范数的光滑近似); 当 $\beta \rightarrow 0$ 时, 趋向于什么? 说明 β 的「逆温度」解释: 大 β 对应「低温」, 为什么「低温」让检索更锐利?

(d) 注意力公式中 $\beta = 1/\sqrt{d_k}$: 当 d_k 增大时, β 变小 (温度升高), softmax 更「平滑」。这与 §3.2 中为什么要除以 $\sqrt{d_k}$ 的论述有何关联?

教学注: (c) 揭示了 log-sum-exp 与 softmax 的「温度」解释: $\beta \rightarrow \infty$ 时 softmax 退化为 one-hot (硬选择), $\beta \rightarrow 0$ 时趋于均匀分布——Hopfield 网络的「低温」等价于注意力的「大 $\sqrt{d_k}$ 缩放比例」时的锐利检索。

陷阱:

- (b) 的链式法则: $\frac{\partial}{\partial \xi} \text{lse}(\beta, X\xi) = X^T \cdot \text{softmax}(\beta X\xi)$, 注意转置的位置
- (d) 中注意力 $\beta = 1/\sqrt{d_k}$ 是为了防止 softmax 退化, 这与 Hopfield 「适当温度让检索成功」方向一致

题3【中·推导·现代 Hopfield 不动点等价于 softmax 注意力】 导读: 这是本节最核心的推导——一步一步从能量函数偏导为零推出 softmax attention, 不要跳步。

现代 Hopfield 网络的能量函数为

$$E = -\text{lse}(\beta, X\xi) + \frac{1}{2} \xi^T \xi + \frac{1}{2\beta} \log N + C$$

其中 $X \in \mathbb{R}^{N \times d}$, $\xi \in \mathbb{R}^d$, C 与 ξ 无关。

(a) 计算 $\partial E / \partial \xi$, 利用题 2(b) 的结论写出完整表达式。

(b) 令 $\partial E / \partial \xi = 0$, 得到不动点条件, 写出对应的不动点更新规则

$$\xi^{\text{new}} = F(\xi)$$

(c) 令 $\xi \leftarrow Q_i$ (某查询向量), $X \leftarrow K$ (键矩阵, 行为键向量), $\beta = 1/\sqrt{d_k}$, 将不动点更新规则代入, 与单头注意力输出

$$\text{Attention}_i = K^T \text{softmax} \left(\frac{KQ_i}{\sqrt{d_k}} \right)$$

对比, 说明两者的等价关系及所需的额外条件。

(d) 完整的注意力公式 $O = \text{softmax}(QK^T/\sqrt{d_k})V$ 中有 $V \neq K$ ，这与 Hopfield 等价中 $K = V$ 的条件不符。解释这个差异的工程含义：分开 Key 和 Value 带来了什么额外灵活性？

教学注：(c) 中「等价」的精确表述是：softmax attention 是现代 Hopfield 网络以逆温度 $\beta = 1/\sqrt{d_k}$ 做一步不动点迭代——注意是一步，而非收敛到不动点。一步迭代在实践中已经足够，因为 Transformer 叠加多层注意力，可以理解为多步迭代的近似。

陷阱：

- (c) 中 KQ_i 是 $N \times 1$ 向量 (K 是 $N \times d_k$ 矩阵, Q_i 是 $d_k \times 1$ 向量), softmax 是对这个 $N \times 1$ 向量操作, 结果再乘 K^T ($d_k \times N$) 得到 d_k 维输出
- 「Key 与 Value 相同」只是 Hopfield 的特殊情形, 实际注意力中 $V = XW^V \neq K = XW^K$

题 4【重·计算·指数容量的数量级感受】 导读：从 $O(d)$ 到 $O(\exp(\alpha^2 d/2))$ 不只是渐近符号的变化——具体数字能让你感受「指数容量」的震撼。

现代 Hopfield 网络的存储容量约为 $C_{\text{modern}} = O\left(\exp\left(\frac{\alpha^2 d}{2}\right)\right)$, 经典版本约为 $C_{\text{classic}} = 0.14d$ 。

(a) 对 $d = 64$ (注意力头的典型键维度), $\alpha = 1/\sqrt{d}$ (即 $\alpha^2 = 1/d$), 计算现代版本的理论容量 C_{modern} (精确到数量级, 用 $10^?$ 表示)。

(b) 对同样的 $d = 64$, 经典版本容量约为多少? 两者相差多少个数量级?

(c) 若 GPT-3 的一个注意力头 $d_k = 128$, $\alpha = 1/\sqrt{d_k}$ (即 $\alpha^2 d/2 = 1/2$), 计算 C_{modern} 。这个数字相比于 GPT-3 的训练数据量 (约 5×10^{11} 个 token) 意味着什么?

(d) 解释为什么更大的模型 (更大的 d) 不仅是「更多参数」, 而是在关联记忆意义上具有指数倍更强的知识存储能力。这是否意味着「足够大的模型可以记住所有训练数据」?

教学注：(c) 中 $\alpha^2 d/2 = (1/d_k) \times d_k/2 = 1/2$, 故 $C_{\text{modern}} \sim e^{0.5} \approx 1.65$ ——这提醒我们：理论容量是假设模式充分分离 (α 取固定值时 $\alpha^2 d$ 随 d 增长), 一旦实际 α 与 d 的比值固定, 容量就固定了。真正的指数增益需要 $\alpha^2 d$ 随 d 增大。

陷阱：

- C_{modern} 中的 α 不是固定常数, 而是与模式分离度和维度相关的量——如果 α 随 d 缩放, 才会得到指数增益
- 「记住所有训练数据」需要区分「存储容量」(关联记忆意义) 和「泛化能力」(统计学习意义), 前者是理论上界, 不等于后者

题 5【重·评判·关联记忆类比的边界】 导读：「softmax attention = 关联记忆检索」是比「softmax attention = 心理学注意力」更精确的类比, 但它也有边界——找到边界, 类比才能真正发挥作用。

阅读以下四个论断, 评估其准确性:

论断 A:「现代 Hopfield 网络证明了 softmax attention 每次前向传播相当于做一次完整的关联记忆检索，收敛到最近的存储模式。」

论断 B:「Transformer 模型中参数矩阵 W^K 的行向量就是「存储模式」，推理时的每次注意力计算是一次模式检索，这解释了为什么更大的模型能记住更多事实。」

论断 C:「指数容量意味着一个 $d = 512$ 的注意力头可以精确存储和检索约 $e^{128} \approx 10^{55}$ 个模式，这就是 Transformer 知识容量无穷大的原因。」

论断 D:「关联记忆类比比「注意力」类比更准确，因此可以直接用 Hopfield 网络的分析工具（如存储容量、串扰分析）来预测 Transformer 的记忆能力和错误率。」

(a) 对每个论断，指出「成立 / 部分成立 / 不成立」并说明关键准确点或漏洞。

(b) softmax attention 与现代 Hopfield 网络等价关系的两个重要「前提条件」是什么？（一个与 $K = V$ 有关，一个与迭代次数有关。）

(c) 「关联记忆」类比在解释 Transformer 的哪些现象时最有力？在解释哪些现象时会失效？各举一个例子。

教学注：论断 A 的「收敛到最近存储模式」是错误的——注意力只做了一步迭代，不保证收敛。多层 Transformer 可以理解为多步迭代，但每层之间还有 FFN 等其他非线性变换，不是纯 Hopfield 迭代。

陷阱：

- 论断 C 的 e^{128} 是理论上界，需要模式两两充分分离（分离度 $\geq \Delta$ ）——在实际 token 嵌入中，许多模式高度相关，有效容量远低于理论值
- 「更大模型记更多事实」与指数容量的关联是间接的：更大 d 提升容量，但训练的优化动态、数据分布等因素同样关键

解答 §3.6

T-3.6.1 【经典 Hopfield 能量与容量】 (a) 代入 $W = X^T X - NI$:

$$E_{\text{classic}} = -\frac{1}{2} \xi^T (X^T X - NI) \xi = -\frac{1}{2} \|X\xi\|^2 + \frac{N}{2} \|\xi\|^2$$

对 $\|\xi\|^2 = d$ (二值模式), $\frac{N}{2} \|\xi\|^2 = \frac{Nd}{2}$ 是常数项。能量函数极小化等价于最大化 $\|X\xi\|^2$, 即找最大化「存储模式矩阵与查询向量内积范数」的方向——几何上即 ξ 与某个存储模式最对齐的方向。

(b) 能量梯度下降: $-\nabla_{\xi} E = W\xi$, 符号步 (sgn) 取梯度方向的二值化, 等价于在负梯度方向上做一步 $\{-1, +1\}$ 投影。

(c) $d = 512$: $C_{\text{classic}} \approx 0.14 \times 512 = 71.68$, 约 **71 个模式**。 $8 \times 10^4 \gg 71$, 不可行——经典 Hopfield 以 $d = 512$ 存储 WordNet 全部节点会严重串扰, 检索失效。

(d) 串扰来自权重矩阵 $W = X^T X - NI$ 的叠加: 存储第 μ 个模式时, W 中有 $N - 1$ 个其他模式的贡献 $\xi^{\nu T} \xi^{\nu}$, 当模式数 N 超过 $0.14d$ 时, 这些「其他模式」的分量在检索时相互叠加, 让能量极小值偏离目标模式, 检索失败。

T-3.6.2 【log-sum-exp 微分】 (a) 令 $s_j = \exp(\beta z_j) / \sum_i \exp(\beta z_i)$ (softmax), 则:

$$\frac{\partial}{\partial z_j} \text{lse}(\beta, z) = \frac{\partial}{\partial z_j} \left[\frac{1}{\beta} \log \sum_i e^{\beta z_i} \right] = \frac{1}{\beta} \cdot \frac{\beta e^{\beta z_j}}{\sum_i e^{\beta z_i}} = s_j = \text{softmax}(\beta z)_j$$

(b) 链式法则: $\frac{\partial}{\partial \xi} \text{lse}(\beta, X\xi) = X^T \frac{\partial \text{lse}(\beta, z)}{\partial z} \Big|_{z=X\xi} = X^T \text{softmax}(\beta X\xi)$ 。

(c) $\beta \rightarrow 0$ 时, $\text{lse}(\beta, z) \rightarrow \frac{1}{\beta} \log N + \bar{z}$ (对数 N 加平均值), 实质趋向均匀平均。「逆温度」类比: 大 β (低温) 时 softmax 趋向 one-hot, 检索更锐利 (只取最相似的模式); 小 β (高温) 时 softmax 趋向均匀, 检索更「模糊」(各模式均等贡献)。

(d) 注意力 $\beta = 1/\sqrt{d_k}$, d_k 增大则 β 减小 (温度升高)。若不除以 $\sqrt{d_k}$, 内积方差为 d_k , 进入 softmax 时放大效应相当于 β 随 d_k 增大——softmax 退化为 one-hot, 梯度消失。除以 $\sqrt{d_k}$ 将方差归一化为 1, 等价于保持 β 对不同 d_k 在同一数量级, 使 softmax 保持「适温」的软检索。

T-3.6.3 【不动点推导】 (a) $\partial E / \partial \xi = -X^T \text{softmax}(\beta X\xi) + \xi$ (利用题 2(b) 和 $\partial(\xi^T \xi / 2) / \partial \xi = \xi$, 常数 C 、 $\log N / (2\beta)$ 不贡献)。

(b) 令 $\partial E / \partial \xi = 0$: $\xi = X^T \text{softmax}(\beta X\xi)$, 即不动点更新规则:

$$\xi^{\text{new}} = X^T \text{softmax}(\beta X\xi)$$

(c) 令 $\xi \leftarrow Q_i$, $X \leftarrow K$, $\beta = 1/\sqrt{d_k}$:

$$\xi^{\text{new}} = K^T \text{softmax}\left(\frac{KQ_i}{\sqrt{d_k}}\right)$$

这与 $\text{Attention}_i = K^T \text{softmax}(KQ_i / \sqrt{d_k})$ 完全相同 (写法上注意 KQ_i 是 $N \times 1$ 向量)。等价的额外条件: 此处 $K = V$ (键向量集合即为值向量集合), 即检索返回的内容与索引相同。

(d) 分开 K 和 V 的工程意义: K 负责「我能回答什么类型的问题」(打分索引), V 负责「我实际传递什么内容」(被检索后输出的信息)。即使匹配分数 (K) 相同, 传递的内容 (V) 可以完全不同——例如某个 token 的语法标签 (K , 用于被语法相关 Query 检索到) 与它的语义特征 (V , 真正混合到输出的内容) 可以由两套投影矩阵独立学习。这是注意力表达能力比纯 Hopfield 更强的原因。

T-3.6.4 【指数容量数量级】 (a) $d = 64$, $\alpha = 1/\sqrt{d} = 1/8$, $\alpha^2 = 1/64$:

$$C_{\text{modern}} \sim \exp\left(\frac{\alpha^2 d}{2}\right) = \exp\left(\frac{(1/64) \times 64}{2}\right) = \exp(0.5) \approx 1.65$$

注意这里 $\alpha^2 d = 1$ 为常数，与 d 无关——没有指数增益。真正的指数增益需要固定 α （不随 d 缩放），此时 $\alpha^2 d \propto d$ 。若 $\alpha = 0.5$ （固定）， $C_{\text{modern}} \sim e^{d/8} = e^8 \approx 2981 \approx 10^{3.47}$ 。

(b) $C_{\text{classic}} = 0.14 \times 64 = 8.96 \approx 9$ 个。若 $\alpha = 0.5$ 固定时现代版本约 $10^{3.5}$ ，相差约 $10^{3.5}/9 \approx 350$ 倍，约 2.5 个数量级。

(c) $d_k = 128$ ， $\alpha = 1/\sqrt{128}$ ， $\alpha^2 d/2 = (1/128) \times 128/2 = 0.5$ ： $C_{\text{modern}} \sim e^{0.5} \approx 1.65$ 。这仅是每个头在「固定 $\alpha = 1/\sqrt{d}$ 」假设下的值，远小于训练数据量——说明单个头的关联记忆容量不是大模型记忆海量事实的唯一来源，参数在各层各头的分布式存储才是真正的机制。

(d) 更大的 d 在 α 固定时带来指数容量增长，但「记住所有训练数据」需要区分：关联记忆容量是理论上界（需要模式充分分离），实际训练目标（交叉熵最小化）是统计近似，不保证每个训练样本都被精确「存入」某个头的关联记忆。泛化能力来自参数化对数据分布的学习，而非对所有样本的精确记忆。

Sanity check: $e^{0.5} \approx 1.65$ ， $e^8 \approx 2981$ ——在 $\alpha^2 d$ 固定为 1 时和 d 无关，在 $\alpha^2 d \propto d$ 时指数级增长，两种情形结论截然不同，必须注意 α 的缩放方式。

T-3.6.5 【关联记忆类比边界】 (a)

- **论断 A 不成立。** 注意力只做一步不动点迭代，不保证收敛到存储模式。「完整检索 = 完全收敛」需要多次迭代，单层注意力只做一步近似。
- **论断 B 部分成立。** W^K 的行向量确实类似存储模式，推理时注意力做近似检索，这是合理的解释框架。但「更大的模型能记住更多事实」的原因是多因素的（更多参数、更多层、更大 FFN 的隐式记忆），单纯用 Hopfield 容量解释是过度简化。
- **论断 C 不成立。** e^{128} 是 $\alpha^2 d/2 = 64$ 时的值，但这需要 $\alpha = \sqrt{2}$ （固定），远大于实际模式间的平均分离度。实际 token 嵌入高度相关，有效分离度小，有效容量远低于理论上界。「知识容量无穷大」是不正确的表述。
- **论断 D 部分成立。** 关联记忆类比确实比心理学类比更准确，但「直接用 Hopfield 分析工具预测 Transformer」有限制：(1) Transformer 中 $K \neq V$ ；(2) 每层还有 FFN、残差、层归一化等非 Hopfield 的组件；(3) 真实 token 嵌入不满足随机模式假设。分析工具可作参考，不能直接套用。

(b) 两个前提：① $K = V$ （键向量集合同时作为值向量集合，即「被检索的内容就是索引本身」）；② **一步迭代近似**（等价关系成立的是一次前向传播 = 一步不动点更新，而非完整收敛）。

(c) 最有力的解释：Transformer 为什么随参数量增加能存储更多世界知识（指数容量提供了理论支撑），以及为什么注意力能做「软检索」（关联记忆的内容寻址语义）。失效场景：解释 in-context learning 为何只需少量示例即能泛化——关联记忆框架只处理静态存储模式，无法解释 Transformer 在推理时「动态更新」和组合泛化的能力，这需要更复杂的机制分析（如 induction head 电路）。

§3.6 小结：softmax attention 的「真实身份」是现代 Hopfield 网络一步不动点迭代——能量函数从二次改为 log-sum-exp，把吸引子从「线性容量」升级为「指数容量」，这

解释了为什么 Transformer 能以有限参数存储海量知识模式。理解这条链路，还能精确划定类比的边界：等价需要 $K = V$ 且只做一步迭代，超出这两个条件，关联记忆的分析工具就需要谨慎外推。

§ 3.7 习题：一个被忽略的争论——注意力权重 ≠ 解释

导读：本节核心是三条论证链——注意力权重只反映 Value 路径、梯度归因走更复杂的多路径、Jain & Wallace 证明权重对输出不具唯一决定性。五题分别对应：注意力权重的数学含义辨析、梯度归因三路径的推导、Jain & Wallace 反例的构造条件、可解释性工具的选择原则、以及综合评判「注意力权重作为解释工具」的合法边界。

题 1【轻·推导·注意力权重测量的是什么】 **导读：** α_j 大的直觉含义是「模型更关注 token j 」——但在数学上，它只是 v_j 在输出线性组合中的系数，与 x_j 的重要性并非同一件事。

设单层单头注意力：

$$y = \sum_{j=1}^n \alpha_j v_j, \quad v_j = x_j W^V, \quad \alpha_j = \frac{\exp(q \cdot k_j / \sqrt{d_k})}{\sum_l \exp(q \cdot k_l / \sqrt{d_k})}$$

- 写出 y 对 v_j 的偏导 $\partial y / \partial v_j$ （视 α_j 为常数）。
- 写出 y 对 x_j 的偏导——仅考虑 Value 路径（假设 q 和 k_j 不依赖 x_j ），结果用 α_j 和 W^V 表示。
- 设 W^V 是一个将 $\mathbb{R}^d$ 投影到某个低维子空间的矩阵（秩为 $r < d$ ）。在这种情况下， α_j 大是否意味着 x_j 对 y 的贡献大？说明理由。
- 一个极端情形：设 $W^V = 0$ （零矩阵，所有 Value 向量为零），此时注意力权重 α_j 的值会如何变化？ y 的值是多少？这说明注意力权重与输出质量之间的关系是什么？

教学注：(d) 是一个刻意构造的极端反例，揭示了注意力权重和 W^V 是相互独立的——权重由 Q, K 决定，输出由 α 和 V 共同决定，只看权重一侧是信息不完整的。

陷阱：

- $v_j = x_j W^V$ 中 x_j 是行向量， $W^V \in \mathbb{R}^{d \times d_v}$ ，偏导结果是矩阵
- (c) 中「秩低」不等于「信息为零」，只是说 v_j 在某些方向上没有分量， α_j 的贡献被限制在那个子空间内

题 2【中·推导·梯度归因的三条路径】 **导读：** $\partial \mathcal{L} / \partial x_j$ 比 α_j 复杂得多——把三条路径分开写出来，就能精确看到注意力权重只覆盖了哪一条。

在自注意力中（ $Q = XW^Q$ ， $K = XW^K$ ， $V = XW^V$ ）， x_j 影响输出 y_i （位置 i 的注意力输出）有三条路径。

- 路径一（Value 路径）：** $x_j \xrightarrow{W^V} v_j \xrightarrow{\alpha_{ij}} y_i$ 。写出 $\partial y_i / \partial x_j$ 经由路径一的贡献（用 α_{ij}

和 W^V 表示)。

(b) 路径二 (Key 路径): $x_j \xrightarrow{W^K} k_j \rightarrow \alpha_{ij} \rightarrow y_i$ 。写出 $\partial\alpha_{ij}/\partial k_j$ (提示: softmax 的 Jacobian), 再链接到 $\partial y_i/\partial x_j$ 的路径二贡献 (不需要完整展开, 写出结构形式即可)。

(c) 注意力权重 α_{ij} 只反映了哪条路径的强度? 路径二对 y_i 的贡献包含在 α_{ij} 里面吗?

(d) 若 x_j 对应的 $\alpha_{ij} = 0$ (位置 i 完全不关注位置 j), 路径二是否仍然可能对 y_i 有贡献? 说明理由, 并给出一个直觉上的语言学场景。

教学注: (d) 揭示了一个反直觉的现象: 即使位置 i 的注意力权重 $\alpha_{ij} = 0$, x_j 仍然可以通过影响 k_j 来间接改变其他位置的注意力分配, 进而影响 y_i 。这是注意力权重作为「解释」的一个根本漏洞。

陷阱:

- 路径二的贡献来自 x_j 改变 k_j , 进而改变 α_{ij} (位置 i 对 j 的权重), 进而改变 $y_i = \sum_l \alpha_{il} v_l$ ——即使最终 α_{ij} 较小, 通过它的变化对 y_i 的影响可以不为零
- softmax 的 Jacobian: $\partial\alpha_{ij}/\partial A_{ij} = \alpha_{ij}(1 - \alpha_{ij})$, $\partial\alpha_{ij}/\partial A_{il} = -\alpha_{ij}\alpha_{il}$ ($l \neq j$)

题3【中·概念辨析·Jain & Wallace 反例的条件】 导读: Jain & Wallace 的结论不是「注意力权重永远无用」, 而是在特定条件 (Value 矩阵低秩相关) 下注意力权重对输出不具唯一决定性——搞清楚这个条件, 才能精确判断什么时候可以信任权重。

设注意力输出 $y = \alpha^T V$, 其中 $V \in \mathbb{R}^{n \times d_v}$ 是 Value 矩阵 (行为 Value 向量), $\alpha \in \Delta^{n-1}$ (概率单纯形)。

(a) 若 V 的行向量两两正交且模长相等, 设 α 和 α' 是两个不同的注意力分布 ($\|\alpha - \alpha'\|_1 > 0$), 证明 $y = \alpha^T V \neq \alpha'^T V = y'$ (除非 $\alpha = \alpha'$)。这说明在什么条件下注意力权重对输出唯一决定?

(b) 若 V 的所有行向量完全相同 ($v_1 = v_2 = \dots = v_n = v_0$), 则不管 α 如何选取, y 的值是多少? 这说明注意力权重在什么极端情形下完全「失效」(完全不决定输出)?

(c) 实际中 $V = XW^V$, 而 X 是 n 个 token 的嵌入矩阵。解释为什么「语义相似的 token 会有相似的 Value 向量」, 以及这如何导致 V 在实践中接近低秩矩阵。

(d) 一个长文档中, 90% 的 token 语义相似 (正文内容词), 10% 的 token 极具特异性 (专有名词)。你期望注意力权重在这个场景中对可解释性更可靠还是更不可靠? 结合 (a)(b) 的分析说明。

教学注: (a) 的正交情形说明, 当 Value 矩阵的行向量「最不相关」时, 注意力权重才对输出有最强的唯一决定性; (b) 则揭示了相反极端。实际情形总是在中间。

陷阱:

- (a) 中「正交且模长相等」是最有利于注意力权重作为解释的情形, 因为此时 V 是「最全秩」的
- (b) 中 $\sum_j \alpha_j v_0 = v_0$ 与 α 无关, 这是极端低秩 (秩为 1) 的情形

题4【重·综合评判·可解释性工具的选择原则】 导读：什么时候用注意力权重、什么时候用梯度方法、什么时候用激活修补——不同工具回答的是不同层次的问题，搞清楚问题类型才能选对工具。

对以下四个可解释性问题，判断注意力权重是否是合适的工具，并说明理由：

问题 A：「这个 token 的 Value 特征在输出混合中占了多大比重？」

问题 B：「删掉输入中的哪个 token 对预测结果影响最大？」

问题 C：「模型为什么在这个位置预测了 token X 而不是 token Y？」

问题 D：「哪些位置的 Value 向量的线性组合权重最不均匀（最集中）」

(a) 对每个问题，判断注意力权重是「直接回答 / 部分回答 / 不能回答」，并说明正确工具应该是什么。

(b) 写出「梯度归因」（如 Integrated Gradients）与「注意力权重可视化」在回答类型上的本质区别（各一句话）。

(c) 电路分析（Circuit Analysis）和激活修补（Activation Patching）能回答注意力权重无法回答的哪类问题？举一个具体场景。

教学注：问题 D 是一个微妙的情形——它问的确实是注意力权重可以直接测量的量（权重分布的熵或集中度），但这与「重要性」不同。「权重集中」只是说「softmax 的输出接近 one-hot」，不说明那个位置的输入是否真的「重要」。

陷阱：

- 「删掉某个 token」（问题 B）是一个因果干预操作，需要实际修改输入并重新推理，不是注意力权重能直接回答的
- 问题 A 和问题 D 是注意力权重能合法回答的，但它们的答案只反映当前前向传播中的线性组合关系，不涉及因果

题5【重·反例构造·「高权重 = 重要」的系统性误判】 导读：这道题让读者自己构造一个「高权重但不重要」的反例场景，以及一个「低权重但重要」的场景——亲手构造比被动阅读更能固化直觉。

(a) 构造一个具体的文本理解场景，使得 token j （如介词「of」）的注意力权重 α_{ij} 很大，但将「of」替换为另一个介词（如「for」）时预测几乎不变。指出这里违反了哪条注意力权重作为解释的前提条件（Value 路径的唯一性，或 V 的行向量独立性）。

(b) 构造另一个场景：token j （如一个否定词「not」）的注意力权重 α_{ij} 很小（接近 0），但将「not」删除会导致预测结果完全反转。这里是路径一还是路径二/三在起关键作用？

(c) 在 (b) 的场景中，什么可解释性方法能正确识别「not」的重要性？给出方法名称并描述其数学原理（一句话）。

(d) Jain & Wallace (2019) 的结论被后续工作（如 Wiegrefe & Pinter, 2019）部分质疑——他们指出在某些设置下注意力权重与人类判断相关。结合本节的三条论证链，写出「注意力权重何时可以作为辅助解释参考」的最小充分条件（两条）。

教学注：(b) 中「not」的低权重可能源于「not」的 Value 向量经过 W^V 投影后信息量

较小（路径一弱），但「not」通过改变 k_{not} 来影响其他位置的注意力分配（路径二强），从而间接影响整个输出。这是注意力权重热力图中最常见的系统性误导来源。

陷阱：

- (a) 中的介词场景：介词的嵌入向量 (x_j) 经 W^V 投影后，Value 向量可能在语义子空间中与其他停用词的 Value 向量高度对齐，导致 α_j 大但替换后输出不变
- (d) 的「最小充分条件」不是「永远可用」的条件，而是「不会系统性误导」的条件，不同场景仍需验证

解答 § 3.7

T-3.7.1【注意力权重的含义】 (a) $\partial y / \partial v_j = \alpha_j \cdot I_{d_v}$ (标量乘单位矩阵，因为 $y = \sum_j \alpha_j v_j$ 对 v_j 是线性的，系数为 α_j)。

(b) 路径一： $y = \sum_j \alpha_j v_j = \sum_j \alpha_j (x_j W^V)$ ，固定 α_j ， $\partial y / \partial x_j = \alpha_j W^{V\top}$ (视 x_j 为行向量时，输出关于 x_j 的梯度为 $\alpha_j W^{V\top} \in \mathbb{R}^d$)。

(c) 若 W^V 是低秩投影（秩 $r < d$ ），则 $v_j = x_j W^V$ 只保留 x_j 在 r 维子空间里的分量。 α_j 大只意味着该 r 维投影在输出中权重高；若 x_j 在被 W^V 投影掉的 $(d-r)$ 维上有重要信息， α_j 大也反映不了这部分贡献。

(d) $W^V = 0$ ：所有 $v_j = 0$ ， $y = \sum_j \alpha_j \cdot 0 = 0$ ，与 α_j 无关。注意力权重仍然通过 Q, K 的内积被正常计算（可以任意分布），但输出永远为零。这说明注意力权重与输出质量完全解耦——权重由 W^Q, W^K 决定，输出由 W^V 和权重共同决定，仅凭权重无法推断输出信息量。

T-3.7.2【梯度归因三路径】 (a) 路径一贡献： $\left. \frac{\partial y_i}{\partial x_j} \right|_{\text{path 1}} = \alpha_{ij} \cdot W^{V\top}$ (仅 x_j 对 v_j 的影响，权重为 α_{ij})。

(b) 路径二结构： $x_j \rightarrow k_j = x_j W^K \rightarrow A_{ij} = q_i \cdot k_j / \sqrt{d_k} \rightarrow \alpha_{ij} \rightarrow y_i = \sum_l \alpha_{il} v_l$ 。
 $\partial \alpha_{il} / \partial A_{ij}$ ：对 $l = j$ 为 $\alpha_{ij}(1 - \alpha_{ij})$ ，对 $l \neq j$ 为 $-\alpha_{ij}\alpha_{il}$ 。路径二对 y_i 的贡献：

$$\left. \frac{\partial y_i}{\partial x_j} \right|_{\text{path 2}} = \sum_l \frac{\partial y_i}{\partial \alpha_{il}} \frac{\partial \alpha_{il}}{\partial A_{ij}} \frac{\partial A_{ij}}{\partial k_j} \frac{\partial k_j}{\partial x_j}$$

结构形式上是 $(V^T \partial_{\alpha_{i\cdot}} \text{softmax})$ 乘 $q_i / \sqrt{d_k}$ 乘 $W^{K\top}$ ，比路径一更复杂，且与 q_i 、 V 矩阵行向量均有关。

(c) 注意力权重 α_{ij} 只反映路径一（Value 路径）中 v_j 的线性组合系数。路径二对 y_i 的贡献完全不在 α_{ij} 里——路径二的贡献来自 x_j 通过改变 k_j 来调整 α_{ij} 的大小，这是一个导数关系，不等于 α_{ij} 本身。

(d) 即使 $\alpha_{ij} = 0$ ，路径二仍然可能有贡献： $\partial \alpha_{ij} / \partial A_{ij} = \alpha_{ij}(1 - \alpha_{ij}) = 0$ (当 $\alpha_{ij} = 0$ ，该项消失)，但 $\partial \alpha_{il} / \partial A_{ij} = -\alpha_{ij}\alpha_{il} = 0$ 也消失——实际上当 $\alpha_{ij} = 0$ 时路径二的直

接贡献也为零。但注意： α_{ij} 是在训练好的参数下的值，在训练过程中 α_{ij} 不为零，梯度通过路径二传播影响了参数学习，即使推理时 $\alpha_{ij} \approx 0$ ，模型参数已经被路径二的历史梯度「塑造」过了。语言学场景：主句中的从句引导词「that」注意力权重极低，但它的存在通过路径二影响了整个句子的结构解析（谓语归属）。

T-3.7.3 【Jain & Wallace 反例条件】 (a) 若 V 的行向量两两正交且模长相等 ($v_i \cdot v_j = 0, i \neq j, \|v_i\| = c$)，则 $y = \alpha^T V = \sum_j \alpha_j v_j, y' = \alpha'^T V = \sum_j \alpha'_j v_j$ 。若 $\alpha \neq \alpha'$ ，存在某个 j 使 $\alpha_j \neq \alpha'_j$ ，由正交性： $\|y - y'\|^2 = \sum_j (\alpha_j - \alpha'_j)^2 \|v_j\|^2 = c^2 \sum_j (\alpha_j - \alpha'_j)^2 > 0$ ，故 $y \neq y'$ 。**唯一决定条件：**Value 矩阵 V 的行向量两两正交（满秩、无相关性）时，注意力权重对输出唯一决定。

(b) $v_1 = \dots = v_n = v_0$ ： $y = \sum_j \alpha_j v_0 = v_0$ ，与 α 完全无关。在所有 Value 向量相同 (V 秩为 1) 的极端情形下，注意力权重对输出零决定性。

(c) 语义相似的 token 的嵌入 x_j 聚集在嵌入空间的相近区域，经过 W^V 的线性投影后，相似 token 的 Value 向量仍然相近（线性变换保持相似关系）。在一段语义连贯的文本中，大多数 token 的 Value 向量在高维空间中分布在一个低维流形上， V 的有效秩远低于 n ，Jain & Wallace 的条件成立。

(d) 正文内容词 (90%) 语义相似 $\rightarrow$ Value 向量高度相关 $\rightarrow V$ 低秩（主要由少数方向张成）。专有名词 (10%) 高度特异 $\rightarrow$ Value 向量方向独特 $\rightarrow$ 这 10% 的 token 的注意力权重有更强的唯一决定性。因此：对正文内容词，注意力权重可解释性较低（高相关导致权重可替换）；对专有名词，注意力权重更可靠（Value 向量独特，权重对输出影响更直接）。

T-3.7.4 【可解释性工具选择】 (a)

- **问题 A (直接回答)：**注意力权重 α_j 就是 Value 向量的线性组合系数，这是权重的字面定义，可以直接回答。
- **问题 B (不能回答)：**「删掉 token 对预测的影响」是因果干预操作，需要重新推理；正确工具是输入扰动法（如 LIME 的遮掩实验）或 Integrated Gradients。
- **问题 C (不能回答)：**「为什么预测 X 而非 Y」需要追溯完整计算电路（哪些特征激活了 X 对应的输出分布），正确工具是激活修补（Activation Patching）或电路分析。
- **问题 D (直接回答)：**注意力权重的集中度（如熵 $-\sum_j \alpha_j \log \alpha_j$ 或最大权重值）可以直接计算，注意这只反映注意力分布形状，不等于重要性。

(b) **梯度归因**回答「输入的微小变化如何影响输出」（微分敏感度，因果性强）；**注意力权重**回答「当前前向传播中哪些 Value 向量被最多线性组合进输出」（相关性，非因果）。

(c) **激活修补**能回答「某层某位置的激活值是否是产生特定预测的必要条件」：将模型在干净输入上的激活值替换到被污染输入的对应位置，观察预测变化——能精确定位「预测由哪个模块产生」。具体场景：识别「人名从主语移动到宾语位置」的「name mover head」——激活修补可以证明这个头的激活是预测正确实体名的充分条件，而

注意力权重热力图只能显示这个头「关注」了主语位置，无法证明因果性。

T-3.7.5【反例构造与边界】 (a) 场景：句子「The cost of living in this city is high」中，「of」的注意力权重可能因高频词的稳定性而较大。将「of」替换为「for」，句法结构相似，预测影响极小。违反的条件：「of」和其他高频虚词的 Value 向量高度相关（经过 W^V 后在语义空间中聚集）， V 的行向量不独立， α_j 大但输出在「of」和「for」之间几乎不变（它们的 Value 向量差异被 W^V 压平）。

(b) 场景：「The result is not valid」中，「not」的注意力权重 $\alpha_{i,\text{not}}$ 可能接近 0（许多位置不需要直接从「not」的 Value 取内容），但删除「not」后预测从「negative」反转为「positive」。路径二/三起主要作用：「not」的 k_{not} （Key 向量）在训练中被塑造成一个「语义翻转信号」，影响了其他位置（如「valid」所在位置）的注意力权重，从而改变了那些位置的 Value 混合；路径三（Query 路径）：「not」同时影响了自身位置的 q_{not} ，对其他位置的关注分配也产生了全局影响。

(c) Integrated Gradients（积分梯度）：沿从基线（如全零输入）到实际输入的插值路径，对输入特征求梯度的积分 $\int_0^1 \frac{\partial F(x_0 + t(x - x_0))}{\partial x} dt \cdot (x - x_0)$ ，满足完整性公理（所有特征的归因之和等于预测值之差），能正确识别「not」的否定作用。

(d) 注意力权重可以作为辅助解释参考的最小充分条件：① **Value 矩阵 V 的行向量足够独立**（如通过条件数或有效秩验证，使得不同 α 产生明显不同的输出）；② **解释目标是「哪些 token 的 Value 特征被直接混合进输出」**而非「哪些输入 token 对预测起决定性作用」（前者是注意力权重的字面含义，后者需要梯度归因）。

§ 3.7 小结：注意力权重的三层困境——它只覆盖 Value 路径（路径一）；梯度归因需要三条路径之和；即使在路径一上，Value 矩阵的相关性也让「高权重 $\Leftrightarrow$ 高重要性」的等式失效。正确的可解释性策略是：注意力权重用于「Value 分配的描述性统计」，梯度方法用于「输入敏感性归因」，激活修补用于「因果机制定位」。三种工具回答不同层次的问题，不存在万能的可解释性工具。

§ 3.8 习题：跨界映射——宏观工业供应链

导读：本节核心是供应链类比的「合法边界」——哪些注意力的数学特征能被供应链逻辑精确对应，哪些对应是量级直觉、哪些是修辞。五题重点偏向「类比是否合法」：Q/K/V 三角角色与采购三角角色的映射、softmax 与比例分配的等价验证、多头与多专业供应链的数学对应、量级估算的实践价值、以及类比合法性的总结评判。

题 1【轻·类比验证·QKV 三角角色与供应链三角角色的映射】 导读：最好的类比是在数学结构上有精确对应的类比——把 Q、K、V 的数学定义与供应链角色的定义逐条配对，找到对应的边界。

供应链采购中：**需求方**发出采购请求（详细说明「需要什么类型的物料」），**供应商标签**是供应商公布的规格书（描述「能提供什么」），**实际物料**是真正交货的零件。

注意力机制中： $Q = XW^Q$ （查询向量）， $K = XW^K$ （键向量）， $V = XW^V$ （值向量）。

(a) 对应关系是： $Q \leftrightarrow$ 需求方， $K \leftrightarrow$ 供应商标签， $V \leftrightarrow$ 实际物料。验证：「需求方和供应商标签之间做匹配打分」在数学上对应注意力的哪一步计算？写出对应公式。

(b) 在供应链中，规格书（Key）和实际物料（Value）可以不同：规格书描述型号和参数，实际物料是物理实体。在注意力中， $W^K \neq W^V$ 也意味着键和值由不同投影产生。请问：如果强制 $W^K = W^V$ ，注意力机制等价于「规格书就是实物」的供应链，这有什么问题？（从 §3.2 的角度回答。）

(c) 供应链中一个关键特性：采购方同时扮演「需求方」（向上游发出需求）和「供应商」（向下游提供产品）。在自注意力中，同一个 token 同时生成 Q 、 K 、 V ，对应这个特性吗？说明理由。

(d) 供应链中，需求方发出的采购请求通常非常具体（型号、数量、规格），而注意力的 Query 向量是连续实数向量，「模糊匹配」而非「精确匹配」。这个差异对类比的「精确度」有什么影响？类比是「数学等价」还是「量级类比」？

教学注：(b) 揭示了 $W^K \neq W^V$ 的设计意图——「能回答什么类型的问题」（Key）和「真正传递什么内容」（Value）解耦，这与供应链中规格书和实物分离的管理逻辑高度对应，但在数学上有更强的表达能力保证（§3.2 的非对称性论证）。

陷阱：

- (c) 中「同一 token 生成 Q 、 K 、 V 」是自注意力的特性，交叉注意力（cross-attention）中 Q 来自一个序列， K/V 来自另一个序列，此时「需求方」和「供应商」不再是同一个实体
- (d) 中「模糊匹配」通过 softmax 实现，而不是通过 argmax——这是注意力比「数据库查询」更灵活的核心，也是类比边界之一

题2【中·计算·softmax 归一化与比例分配的等价验证】 导读：供应链的「比例分配订单」和 softmax 归一化在数学结构上高度吻合，但有一个关键差异——这道题通过具体数字揭示差异所在。

设有 3 个供应商，采购部门对其打分 $s = (3, 1, 0)$ （分数越高匹配度越好）。

(a) 供应链的「比例分配」方案：按打分归一化， $\alpha_j = s_j / \sum_l s_l$ 。计算 $\alpha_1, \alpha_2, \alpha_3$ 。

(b) 注意力的 softmax 方案： $\alpha_j = \exp(s_j) / \sum_l \exp(s_l)$ （ $\beta = 1$ 时）。计算 $\alpha_1, \alpha_2, \alpha_3$ （保留 4 位小数）。

(c) 比较两种分配方案的差异。softmax 相比「按打分比例分配」对高分供应商给出了更多还是更少的份额？这种差异在数学上由什么决定？

(d) 在供应链中，「评分为 0 的供应商」通常被完全排除出采购名单（份额为 0）。在 softmax 方案中，评分为 0 的供应商对应的权重是多少？这对「软检索 vs 硬检索」的区别有何启示？

教学注：(c) 揭示了 softmax 的「放大效应」： $\exp$ 函数对打分差异的放大比线性比例更激进，高分供应商在 softmax 方案中获得的份额比例高于其得分占比。这对应注意力的「高相似度键得到指数级更高权重」的性质。

陷阱：

- (b) 中 $\exp(3) = 20.0855$, $\exp(1) = 2.7183$, $\exp(0) = 1$, 分母 = 23.8038
- (d) 中 $\exp(0) = 1 \neq 0$, softmax 永远不会输出精确的 0 (只在 $s \rightarrow -\infty$ 时趋向 0)——这是「软检索」的数学来源

题3【中·类比验证·多头与多专业供应链】 导读：多头注意力「并行在不同子空间做注意力」的结构，与「多条专业供应链并行运作」的直觉高度吻合——这道题验证这个对应的数学精确度，并指出涌现与设计之间的区别。

设有 $h = 4$ 个注意力头，每头的键/查询维度 $d_k = d/h$ ($d = 256$, 故 $d_k = 64$)。

(a) 在参数量上，单头注意力 ($d_k = d = 256$) 和 4 头注意力 ($h = 4$, $d_k = 64$) 的 Q, K, V 总参数量是否相同？计算两种方案各自的 $W^Q + W^K + W^V$ 的参数总数。

(b) 供应链的「多专业化分工」是事先设计好的（例如「第1条链负责标准件，第2条链负责精密件」），而多头注意力中各头的专业化是通过训练涌现的（不是预先规定的）。这个差异对「以供应链类比注意力」的合法性有什么影响？

(c) 假设你是工程师，想在训练前「规定」第1个头专注于句法依存关系，第2个头专注于语义关联。可以通过以下哪种操作实现？判断每种操作是否可行，说明理由：- 方案A：初始化 W_1^Q, W_1^K 为句法分析器提取的特征矩阵 - 方案B：在损失函数中加入「第1头的注意力分布应与句法分析树对齐」的正则项 - 方案C：只有第1头的 W^Q, W^K 参与梯度更新，其他头固定

(d) 实验研究（如 Clark et al., 2019）发现，有些头确实捕捉到了句法依存关系（如主语-谓语头），有些头追踪指代关系。这是「设计」还是「涌现」？这个现象是否支持供应链的「专业化供应链」类比？

教学注：(b) 是类比最重要的边界之一——供应链的专业化是人设计的，注意力头的专业化是梯度发现的。用「多专业供应链」类比时，要明确这是对「已训练结果」的事后描述，而不是对「训练机制」的精确类比。

陷阱：

- (a) 中 4 头注意力：每头 $W_i^Q \in \mathbb{R}^{256 \times 64}$, 4 头共 $4 \times 256 \times 64 \times 3 = 196608$ ；单头 $W^Q \in \mathbb{R}^{256 \times 256}$, $256^2 \times 3 = 196608$ ——两者完全相同，这是设计要求
- (c) 的三种方案难度依次增加：A 较为可行（初始化不影响最终优化方向但可能加速收敛），B 较为可行（常见的辅助损失方法），C 存在梯度不均衡问题

题4【重·计算·供应链类比的量级价值】 导读：供应链类比最大的贡献是帮助建立规模直觉——这道题把「全球询价」的量级从比喻变成精确数字，让读者感受注意力计算的规模为什么在人类供应链管理中完全不可想象。

设 GPT-4 的某个版本：序列长度 $n = 8192$, 注意力头数 $h = 128$, 层数 $L = 120$, 键/查询维度 $d_k = 128$, 每次前向传播处理一个序列。

(a) 在单层单头的注意力中，每个 token 对所有 n 个 token 做一次内积打分，相当于供应链中「一次全球询价」。单层 128 头对整个序列完成一次前向传播，等价于多少次

「全球询价」(询价次数 = 每个 Query 对应的 Key 比较次数之和)?

(b) 全部 120 层完成一次完整的前向传播, 等价于多少次「全球询价」? 用科学计数法表示。

(c) 一个现实世界的供应链管理系统, 假设每天管理 1000 个供应商, 每次采购决策需要与 50 个候选供应商做比较, 每年进行 10^6 次采购决策。计算年询价次数, 与 (b) 比较, 差距多少个数量级?

(d) 量级差距说明了什么? 在什么意义上「GPU 实现了人类供应链系统完全无法实现的规模」? 这是否意味着注意力机制比供应链更「高效」?

教学注: 量级计算揭示了类比的局限——供应链类比帮助理解逻辑结构(三角色分离、比例分配、专业化分工), 但在规模上两者差距超过 10 个数量级, 「以规模感受到差异」才是类比的量级价值所在。

陷阱:

- (a) 中「全球询价次数」= $n \times n \times h = 8192 \times 8192 \times 128$ (每个 Query 与每个 Key 做内积, n 个 Query, n 个 Key, h 个头)
- (d) 中「更高效」需要明确单位——注意力的高效体现在「可并行的矩阵运算」, 而非单次决策的复杂度更低

题 5【重·类比合法性综合评判·供应链映射的总体评估】 导读: 经过前四题对供应链类比的细节检验, 这道题要求读者从整体上评估这个类比的合法性——哪些维度「精确对应」, 哪些只是「量级类比」, 哪些是「修辞延伸」。

对以下五个关于供应链类比的论断, 判断其「类比是否合法」:

论断 A: 「softmax 归一化对应供应链中比例分配订单的操作, 这是一个精确的数学等价——两者在数学上是同一回事。」

论断 B: 「注意力机制中某个位置被「多个 Query」同时高度关注, 类似于一个供应商被多家客户抢购, 会导致该供应商「产能耗尽」, 进而影响其他客户的供应。」

论断 C: 「多头注意力中各头自发专业化(有的头关注句法, 有的头关注语义), 与供应链中多条专业供应链的分工类似, 这是一个结构上的有效类比。」

论断 D: 「供应链通过「询价-报价-成交」的流程做最优决策, 注意力机制也通过 softmax 做「最优」的 Value 混合, 两者在优化逻辑上等价。」

论断 E: 「增加注意力头数 h 类似于增加供应链的专业化分工条数, 能增加系统的「采购精度」——这是一个在量级上可以预测头数效果的类比。」

(a) 对每个论断, 分类为「精确等价 / 量级类比 / 修辞延伸 / 误导性类比」, 并一句话说明理由。

(b) 供应链类比在解释注意力时最准确的一句话总结是什么?(不超过 30 字)

(c) 写出供应链类比在「预测注意力计算瓶颈」时最容易产生的一种误判, 以及这种误判的正确纠正。

教学注: 论断 B 是本题最关键的反例——它引入了「产能耗尽」这个供应链核心概念, 但注意力中 Value 向量没有产能约束, 这个映射是根本性的失效, 详见 § 3.9。

陷阱：

- 论断 A 的「精确等价」需要验证：softmax 是 exp 归一化，比例分配是线性归一化，两者数学形式不同，因此不是「同一回事」，而是「结构相似但函数形式不同」
- 论断 E 中「增加头数增加精度」：实验上增加头数到一定程度后效果不再提升，甚至略降（注意力头过多会导致信息分散），用供应链类比预测「头数越多越好」是误导

解答 § 3.8

T-3.8.1 【QKV 与供应链三角色映射】 (a) 「需求方和供应商标签之间做匹配打分」对应： $A = QK^T / \sqrt{d_k} \in \mathbb{R}^{n \times n}$ ，其中 $A_{ij} = q_i \cdot k_j / \sqrt{d_k}$ 是第 i 个需求方（Query）和第 j 个供应商标签（Key）之间的匹配分数。

(b) 若强制 $W^K = W^V$ ($K = V$)，则注意力打分用于「谁被关注」和「传递什么」由同一套投影决定。问题：注意力矩阵 $A = QK^T / \sqrt{d_k}$ 中 K 的方向既要优化「打分匹配」又要优化「传递内容」，这两个目标可能冲突（§ 3.2：Value 需要传递语义内容，Key 需要易于被正确的 Query 匹配到，两者对 W^K / W^V 的优化方向可能不同）。分开设计使「规格书」和「实物」各自独立优化。

(c) 是，自注意力中同一 token j 的嵌入 x_j 同时乘以 W^Q （作为需求方）、 W^K （作为供应商标签）、 W^V （作为实际物料），对应供应链中企业同时扮演三个角色的现实。

(d) 类比是「结构类比」而非「数学等价」：采购请求是离散规格（型号、数量），Query 向量是连续实数，匹配方式（内积 vs 精确匹配）根本不同。供应链类比提供的是逻辑结构直觉（三角色的功能分工），不是计算公式的等价，属于「量级/逻辑类比」而非「数学等价」。

T-3.8.2 【softmax 与比例分配的差异】 (a) 线性比例分配： $\alpha_1 = 3/4 = 0.7500$ ， $\alpha_2 = 1/4 = 0.2500$ ， $\alpha_3 = 0/4 = 0.0000$ 。

(b) softmax： $\exp(3) = 20.0855$ ， $\exp(1) = 2.7183$ ， $\exp(0) = 1.0000$ ， 分母 = 23.8038。

$\alpha_1 = 20.0855/23.8038 = 0.8438$ ， $\alpha_2 = 2.7183/23.8038 = 0.1142$ ， $\alpha_3 = 1.0000/23.8038 = 0.0420$ 。

(c) softmax 给高分供应商更多份额 (0.8438 vs 0.7500)，给低分供应商更少份额 (0.0420 vs 0)。数学上，exp 是凸函数，对打分差异的「放大比例」超过线性——分数越高，被 exp 放大后在分母中占比越大，份额越集中于高分项。

(d) 评分为 0 的供应商：softmax 权重 = $\exp(0)/Z = 1/Z > 0$ （永远非零）。这就是「软检索」——softmax 永远不会完全排除某个 token（除非分数趋于 $-\infty$ ）。对应供应链语义：评分 0 的供应商仍然分得约 4% 的订单，保留了「一定的容错性」——这在供应链中有时是合理的（避免单一供应商风险），但在注意力中，这是 exp 函数的数学性质，不是设计决策。

Sanity check: $0.8438 + 0.1142 + 0.0420 = 1.0000 \checkmark$ 。

T-3.8.3【多头与多专业供应链】 (a) 单头: $W^Q \in \mathbb{R}^{256 \times 256}$, $256^2 = 65536$, $W^Q + W^K + W^V$ 共 $3 \times 65536 = 196608$ 个参数。4 头: 每头 $W_i^Q \in \mathbb{R}^{256 \times 64}$, $256 \times 64 = 16384$, 4 头 $\times 3$ 套 $\times 16384 = 196608$ ——完全相同, 这是多头设计「参数量不变而扩展表达能力」的工程保证。

(b) 供应链分工是事前设计 (合同规定职责), 注意力头的专业化是事后涌现 (梯度塑造), 这个差异使类比在「解释训练机制」时失效: 不能用「设计专业供应链」的逻辑来理解「如何训练各头分工」。类比只在描述「已训练好的模型各头功能」时有启发价值。

(c) 方案 A (较可行): 初始化提供了有利的起点, 但梯度更新会改变权重, 不保证最终专业化符合设计; 方案 B (较可行): 辅助损失是常见的约束训练的手段, 但句法分析树的获取和对齐代价高; 方案 C (不太可行): 固定其他头的参数会导致多头之间梯度不均衡, 模型容量被浪费。

(d) 涌现, 不是设计。Clark et al. (2019) 的实验是事后分析——训练时没有任何「让第 k 头负责句法」的显式约束, 头的分工是损失函数在高维参数空间中自然找到的最优解。支持类比: 结果上确实有专业化分工, 与「多专业供应链」的最终状态吻合。但不支持类比在「过程」层面的推广——不能用「供应链管理者设计分工」来类比「Transformer 如何学会分工」。

T-3.8.4【量级估算】 (a) 单层询价次数: 每个头, 每个 Query ($n = 8192$) 与每个 Key ($n = 8192$) 做一次内积, 共 $n^2 = 8192^2 = 6.711 \times 10^7$ 次; $h = 128$ 头, 单层询价总次数 $= 128 \times 6.711 \times 10^7 = 8.590 \times 10^9$ (约 86 亿次)。

(b) $L = 120$ 层: 总询价次数 $= 120 \times 8.590 \times 10^9 = 1.031 \times 10^{12}$ (约 1 万亿次)。

(c) 现实供应链: $1000 \times 50 \times 10^6 = 5 \times 10^{10}$ 次 (约 500 亿次/年)。差距: $10^{12} / 5 \times 10^{10} = 20$, 约 **1 个数量级**。这里参数选取使两者接近——如果用更实际的「全球最大供应链系统」(采购次数更少), 差距可达 3 ~ 5 个数量级。

(d) 量级差距说明: 一次 Transformer 前向传播 (约毫秒级完成) 完成的「匹配评分」次数, 与人类供应链系统全年运营量相当甚至更多。这不意味着注意力「更高效」(单次决策, 注意力内积和人类判断的代价量级不同), 而是说明矩阵运算在硬件上可以极度并行化, 而人类供应链受物理和组织约束不能并行。类比的值在于: 把抽象的矩阵乘法规模还原为可感知的操作量级。

T-3.8.5【类比合法性评判】 (a)

- **论断 A 修辞延伸**。softmax (exp 归一化) 和线性比例分配 (权重 $\propto s_j$) 在数学形式上不同——exp 对差异有放大效应, 线性比例没有。两者是「类似的归一化目标」, 但不是「同一回事」。
- **论断 B 误导性类比**。注意力没有产能约束 (Value 向量可以无限次被不同 Query「调用」, 不存在资源耗尽), 这是供应链类比最根本的失效点 (详见 § 3.9)。

- **论断 C 量级类比**。结果上多头确实有分工（正确），但分工是涌现的而非设计的（与供应链「设计专业链」不同）——是描述训练结果的有效类比，不是对训练机制的精确类比。
- **论断 D 误导性类比**。供应链调度是带约束的优化问题（有决策者、有目标函数）；注意力是一个确定性线性函数（矩阵乘加 softmax），没有任何「决策」或「权衡过程」，结果唯一确定。两者在优化逻辑上根本不同。
- **论断 E 量级类比（部分）**。增加头数确实增加了「并行检索不同语义维度」的能力（有一定直觉价值），但实验上效果饱和，且总参数量不变（每头维度缩小）——用「供应链专业化条数越多越好」来预测头数效果会过度乐观。

(b) 供应链类比最准确的一句话：**注意力的「查询-打分-加权混合」逻辑，在三角色分离和比例分配的结构层面与供应链的「需求-匹配-调度」高度对应，但没有产能约束、没有优化决策。**

(c) 最容易产生的误判：「序列中某个位置被多个 Query 高度关注时，该位置会成为「瓶颈」（被过度使用），影响系统整体性能」。纠正：注意力没有产能约束，同一 Value 向量可以无限次以最高权重响应所有 Query——不存在「过度使用」的概念；注意力的真正计算瓶颈是 $O(n^2)$ 的内存和 FLOPs，与某个具体位置被关注多少次完全无关。

§ 3.8 小结：供应链类比在三个层面有价值：三角色分离（Q/K/V 解耦的直觉）、比例分配（softmax 的软检索直觉）、多专业链并行（多头分工的量级直觉）。它在两个层面系统性失效：产能约束（Value 无守恒）和优化决策（注意力是确定性线性函数，不是带约束的优化过程）。下一节（§ 3.9）将逐一拆解这些失效的数学根源。

§ 3.9 习题：反类比——当供应链隐喻失效

导读：本节核心是从数学层面逐一解析供应链隐喻失效的四个根源：无产能约束（softmax 归一化不是资源守恒）、无先验语义目标（头的功能由训练涌现）、无优化决策（注意力是确定性线性变换）、权重不等于解释（不可审计性）。五题重点偏向「指出哪条假设被违反」——每道题都从一个看似合理的供应链推论出发，要求精确定位违反了注意力的哪条数学性质。

题 1【轻·推导·softmax 归一化 ≠ 资源守恒】 导读：供应链的「订单分配」满足资源守恒（产能总量固定），但 softmax 归一化满足的是「每个 Query 的权重之和为 1」，这是统计归一化而非物理守恒——两者的数学形式截然不同。

设注意力输出为 $y_i = \sum_j \alpha_{ij} v_j$ ，其中 $\alpha_{ij} = \exp(q_i \cdot k_j / \sqrt{d_k}) / \sum_l \exp(q_i \cdot k_l / \sqrt{d_k})$ 。

(a) 验证「行归一化」：对固定的 i ，证明 $\sum_j \alpha_{ij} = 1$ 。这对应供应链中哪个守恒律？

(b) 验证「列无约束」：对固定的 j ， $\sum_i \alpha_{ij}$ 是否有固定值？写出 $\sum_i \alpha_{ij}$ 的表达式，说明其是否等于 1。

(c) 供应链中，产能守恒意味着「同一供应商向客户 A 分配了 p 的产能，则向其他所有客户合计只能分配 $1 - p$ 的产能」，即 $\sum_i (\text{客户 } i \text{ 对供应商 } j \text{ 的采购量}) = (\text{供应商 } j \text{ 的总产能})$ 。在注意力中，与此对应的「列守恒」是否成立？用 (b) 的结论给

出明确答案。

(d) 指出注意力中 Value 向量无产能约束的直接推论：同一个 v_j 能否同时以权重 1 被序列中的所有其他位置「全额调用」？这在并行计算上意味着什么？

教学注：(b) 是反类比的数学核心—— $\sum_i \alpha_{ij}$ 不等于 1，也没有任何固定约束；不同 Query 的 softmax 是各自独立计算的，列求和的值取决于所有 Query 对 Key j 的打分分布，可以是任意正数。

陷阱：

- 「行归一化」（每个 Query 的权重和为 1）和「列守恒」（每个 Key 被关注量之和固定）是两个独立的条件，softmax 只保证前者
- (d) 中「权重为 1」是理论极端，实际上 softmax 值总是在 $(0, 1)$ 之间，但可以任意接近 1

题 2【中·反例·「产能耗尽」假设的违反】 导读：如果供应链类比成立，则「某个位置被所有其他位置高度关注」时，该位置「产能耗尽」，其他位置对它的权重应当下降。这道题用数学推翻这一推论。

设序列长度 $n = 4$ ，position 2 是一个非常重要的 token（如句子主题词），其键向量 k_2 与其他位置的 Query 向量内积都很高： $q_1 \cdot k_2 = q_3 \cdot k_2 = q_4 \cdot k_2 = 10$ ，而其他键向量的内积都是 0。为简化，忽略 $\sqrt{d_k}$ 缩放。

(a) 计算 α_{12} （position 1 对 position 2 的注意力权重），使用 $\exp(10)/(\exp(10) + 3\exp(0))$ （近似）。

(b) 计算 α_{32} 和 α_{42} 。

(c) 在供应链「产能耗尽」的逻辑下，position 1、3、4 都需要 position 2 的产能，理应产生竞争，使得每个的分配份额低于独占时的水平。验证：如果只有 position 1 需要 position 2（ $n = 2$ ， $q_1 \cdot k_2 = 10$ ， $q_1 \cdot k_1 = 0$ ）， α_{12} 是多少？与 (a) 的结果比较，position 1 得到的份额是否因为「其他人竞争」而减少？

(d) 指出这里违反了供应链类比的哪条假设，用一句话精确表述被违反的数学性质。

教学注：(c) 揭示了反直觉的事实：即使多个 Query 都以最高分指向同一个 Key，每个 Query 得到的注意力权重（行归一化后）并不因为「竞争者增多」而降低——因为每行 softmax 是独立计算的，不同 Query 的权重之间没有任何耦合。

陷阱：

- (a) 中 $n = 4$ ，position 1 的 softmax 分母是 $\exp(10) + \exp(0) + \exp(0) + \exp(0)$ （对自身 position 1 的键向量内积 = 0，以及 position 3、4 的键向量内积 = 0）
- 注意：即使三个 Query 都以 $\alpha \approx 1$ 指向 position 2，position 2 的 v_2 可以被三个 Query 完整使用，不会「折半」

题 3【中·辨析·注意力头的功能：设计 vs 涌现】 导读：供应链有明确的优化目标（成本、时效），而注意力头的功能是反向传播在高维参数空间中塑造的——「功能由训练涌现」这条假设的被违反，决定了供应链类比不能用来预测训练过程。

判断下列命题，指出每条命题违反了注意力的哪条数学性质，或与供应链类比的哪条假设冲突：

- (a) 「通过检查第 3 个注意力头的参数矩阵 W_3^Q, W_3^K ，可以在训练前确定该头会专注于捕捉主谓关系。」
- (b) 「若需要模型更关注句法结构，可以增加专门处理句法的注意力头数量，就像扩充专业供应链条数一样。」
- (c) 「注意力头的功能随上下文而变化（同一个头在不同句子中可能关注不同类型的依存关系），因此机械可解释性对注意力头功能的「命名」（如「induction head」）是不准确的。」
- (d) 「如果某个注意力头在训练数据中从未见过特定的句法模式（如罕见的并列从句），则该头对这个模式的处理能力为零，类似于供应链中没有采购过某类零件的供应商没有相关经验。」

教学注：(c) 是一个微妙的命题——机械可解释性确实发现了「induction head」这类功能相对稳定的头，但它的「功能」是统计上的平均描述，在不同上下文中会有变化。命题说「命名不准确」过于绝对，准确说法是「命名是近似的统计描述，不是确定的功能规定」。

陷阱：

- (a) 违反的不是「供应链」假设，而是「功能涌现性」——参数矩阵在训练前是随机的，功能由训练后的权重在数据分布下的统计行为决定，不可从参数值直接读出
- (b) 混淆了「增加头数」和「指定头功能」，即使头数增加，哪个头学到什么功能仍然由训练决定

题 4【重·数学推导·注意力是确定性线性函数，不是优化决策】 导读：供应链调度是一个带约束的优化问题（有目标函数、有决策变量）；注意力是给定 Q, K, V 后唯一确定的矩阵运算——这道题用数学确认这个差异。

- (a) 写出单头注意力的完整前向传播公式 $O = f(Q, K, V)$ ，强调这是一个关于 Q, K, V 的**确定性函数**（没有随机性，没有优化步骤）。若 Q, K, V 固定， O 是否唯一确定？
- (b) 供应链调度的目标是最小化成本或最大化效率，可以表示为约束优化： $\min_{\alpha} C(\alpha)$ s.t. $\sum_j \alpha_j = 1, \alpha_j \geq 0$ 。注意力公式是否有类似形式的优化目标函数？若有，写出；若无，说明「softmax 归一化」是否等价于求解某个优化问题。
- (c) softmax 有一个等价的优化解释： $\text{softmax}(a) = \arg \max_{p \in \Delta} [\sum_j p_j a_j + H(p)]$ ，其中 $H(p) = -\sum_j p_j \log p_j$ 是熵。这个解释是否意味着注意力在每次前向传播时都在「做优化决策」？说明区别。
- (d) 指出「注意力是确定性线性函数而非优化决策」这一事实，对「用供应链瓶颈分析预测注意力计算瓶颈」有什么直接的负面影响。

教学注：(c) 的 softmax 最优化解释是一个数学等价性（softmax 的输出恰好等于某个正则化线性规划的解），但这不意味着前向传播「在做优化」——这个优化有闭合解（就是 softmax 公式本身），所以「求解」只需一次矩阵运算，不需要任何迭代或决策

过程。

陷阱：

- (b) 中不要把「训练时的损失函数最优化」误解为「推理时注意力在做优化」——训练时确实在优化，但那是在调整参数 W^Q, W^K, W^V ，不是在推理时对每次注意力计算做优化
- (c) 的等价性只说明 softmax 可以被解读为「正则化最大期望得分」的解，但推理时执行的仍然是确定性的矩阵乘法，没有迭代优化过程

题5【重·综合反类比·四条失效根源的总体评估】 导读：这道题要求对供应链类比四条失效根源（产能约束、语义目标、优化决策、可审计性）做整体评估，以及精确回答「供应链类比在什么条件下是安全的工具，在什么条件下必须放下」。

(a) 逐一指出供应链类比在以下四个「应用场景」中哪条假设被违反，以及违反的后果：

- **场景1**：用「供应链中资源有限，所以越多 Query 关注某个 Key，每个 Query 得到的份额越少」来理解注意力的竞争动态。
- **场景2**：用「供应链中供应商专业化由经营战略决定」来理解为什么可以通过改变注意力头数来控制模型专注特定语言特征。
- **场景3**：用「供应链调度员在不同候选方案中做权衡决策」来解释为什么 softmax 权重高的位置「对预测更重要」。
- **场景4**：用「供应链审计追溯决策路径」来理解注意力权重热力图是对模型决策的忠实记录。

(b) 供应链类比最安全（不会产生系统性误导）的使用场景是什么？（给出具体的陈述，而非泛泛而谈。）

(c) 供应链类比必须放下的场景是什么？（对应四条失效根源，给出四个具体例子。）

(d) 写出一个比供应链更精确的类比，用来描述注意力机制的数学本质，并说明它在哪些维度比供应链类比更准确，在哪些维度仍然有局限。

教学注：(d) 的答案可以是 §3.6 中揭示的「关联记忆检索」类比：它在「内容寻址的软检索」这一数学结构上比供应链更准确，因为关联记忆本来就是连续的、无产能约束的、通过能量函数（而非优化决策）实现的检索。但关联记忆类比在「多头分工」和「量级直觉」上不如供应链类比直观。

陷阱：

- (b) 的「安全」不是「完全正确」，而是「不会产生可预测的系统性误判」——任何类比都有局限，关键是在有限用途内不产生误导
- (d) 中要求说明局限，不要只给出优点——任何类比都有边界，关联记忆类比的局限包括：它对多头的并行分工结构没有直觉，对 $Q \neq K \neq V$ 的三角色分离也没有直接对应

解答 §3.9

T-3.9.1 【softmax 归一化 ≠ 资源守恒】 (a) 行归一化: $\sum_j \alpha_{ij} = \sum_j \frac{\exp(q_i \cdot k_j / \sqrt{d_k})}{\sum_l \exp(q_i \cdot k_l / \sqrt{d_k})} = \frac{\sum_j \exp(q_i \cdot k_j / \sqrt{d_k})}{\sum_l \exp(q_i \cdot k_l / \sqrt{d_k})} = 1$ 。这对应供应链中「每个需求方分配的订单总比例为 1」——但这是需求方侧的约束，不是供应方侧的约束。

(b) 列求和: $\sum_i \alpha_{ij} = \sum_i \frac{\exp(q_i \cdot k_j / \sqrt{d_k})}{\sum_l \exp(q_i \cdot k_l / \sqrt{d_k})}$ ，分子分母都与 i 有关，每行的分母不同，无法化简为固定值。一般地， $\sum_i \alpha_{ij} \neq 1$ ，也没有任何固定约束，取决于所有行的打分分布。

(c) 不成立。注意力中「列守恒」不存在: $\sum_i \alpha_{ij}$ 没有固定上界，Key j 可以在所有 Query 中都以很高的权重被选中，列求和可以远大于 1。违反的供应链假设: **产能守恒**（供应商的总供给量有限，分给一方多则分给另一方少）在注意力中完全不适用。

(d) 同一个 v_j 在理论上可以同时以权重趋近于 1 被序列中所有其他 $n - 1$ 个位置「全额调用」（当 k_j 与所有 q_i 的内积远高于其他键时）。并行计算意义: 不同 Query 的注意力输出 y_i 之间没有任何资源争抢关系，可以完全并行计算——这正是注意力可并行的数学根源（而不是因为「产能充足」，而是因为根本就没有产能概念）。

T-3.9.2 【「产能耗尽」假设的违反】 (a) $\alpha_{12} = \exp(10) / (\exp(10) + \exp(0) + \exp(0) + \exp(0)) = e^{10} / (e^{10} + 3) \approx 22026 / (22026 + 3) \approx 0.9999$ （非常接近 1）。

(b) α_{32} 的计算: position 3 的 Query 也有 $q_3 \cdot k_2 = 10$ ，其他 Key 内积为 0。同样地， $\alpha_{32} = e^{10} / (e^{10} + 3) \approx 0.9999$ 。 α_{42} 同理 ≈ 0.9999 。

(c) 若只有 position 1 ($n = 2$, $q_1 \cdot k_2 = 10$, $q_1 \cdot k_1 = 0$): $\alpha_{12} = e^{10} / (e^{10} + e^0) = e^{10} / (e^{10} + 1) \approx 22026 / 22027 \approx 0.99995$ 。比 (a) 的 0.9999 几乎没有差别（从 0.99995 降到 0.9999，差了 5×10^{-5} ）。position 1 得到的份额几乎不因「竞争者增多」而减少——三个 Query 共同高度关注 position 2，每个 Query 得到的注意力权重仍然接近 1。

(d) 被违反的假设: **Value 向量无产能约束**，softmax 归一化是行归一化（统计归一化），不是资源守恒（物理约束）。数学精确表述: v_j 可以被任意多个 Query 以任意高的权重调用，不存在「列约束」 $\sum_i \alpha_{ij} \leq 1$ 。

T-3.9.3 【注意力头功能: 设计 vs 涌现】 (a) 命题假。违反: **功能涌现性**。参数矩阵 W_3^Q, W_3^K 在训练前是随机初始化的，没有任何先验语义含义；头的功能（是否专注主谓关系）是在训练后通过梯度下降在大量数据上形成的统计属性，无法从初始参数读出，也无法在训练前预测。

(b) 命题假（在机制层面）。违反: **功能由训练涌现，不是由设计规定**。增加专门处理句法的头并不能「指定」它处理句法——新增的头同样由梯度驱动，最终的功能由损失函数和数据分布决定。正确做法是加入辅助句法标注损失，但这与「增加头数」不同。

(c) 命题过于绝对（不完全正确）。机械可解释性（如 Elhage et al. 2021 对 induction head 的研究）确实发现了在不同上下文中功能相当稳定的头——「induction head」在各种输入下都表现出「复制前面出现过的模式」的行为。命题应修正为:「注意力头的功

能是上下文相关的统计描述，在大多数场景下有一致的主导功能，但不如供应链的职责规定那样绝对固定」。

(d) 命题**部分正确**（类比有效，但机制有差异）。模型确实无法在训练分布之外泛化（类似供应商没有经验），这部分类比合理。但差异在于：注意力参数是连续的实数矩阵，对「相近但未见过的」模式有一定泛化（通过嵌入空间的连续性），而供应链供应商没有相关经验通常意味着「完全无法提供」，是离散的有/无。

T-3.9.4【注意力是确定性线性函数】 (a) 完整公式： $O = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$ ，其中 Q, K, V 固定后，每一步（矩阵乘法、softmax、再矩阵乘法）都是确定性操作， O 唯一确定。没有随机性（训练时的 dropout 除外，但推理时关闭），没有迭代，没有决策变量——给定输入，输出唯一。

(b) 注意力没有类似供应链的优化目标函数。softmax 归一化是一个固定的非线性函数操作，不是在求解约束优化问题。（训练时存在优化： $\min_{\theta} \mathcal{L}$ ，调整 W^Q, W^K, W^V ；但这是参数的训练优化，不是推理时对每次注意力计算的优化。）

(c) (c) 的等价性是数学上的「解释」，不是计算过程的「等价执行」。 $\arg \max_{p \in \Delta} [\sum_j p_j a_j + H(p)]$ 这个优化问题有解析解（就是 softmax），所以「求解」只需一次矩阵运算，不需要任何迭代。推理时执行的就是 exp 和归一化这两个矩阵操作，不涉及任何决策。区别：供应链的优化需要决策过程（权衡多个方案），注意力只是执行一个固定的函数映射。

(d) 「供应链瓶颈分析」的核心是：找到约束最紧的环节（产能不足的供应商），放松该约束能改善整体性能。这个框架假设「系统有资源约束，不同需求方在争抢有限资源」。注意力没有资源约束，「哪个 Key 被关注最多」完全不是计算瓶颈——真正的瓶颈是 $O(n^2)$ 的 FLOPs 和 HBM 带宽（见 §3.3、§3.5），这些是硬件资源约束，与「哪个位置被关注多少次」无关。用供应链瓶颈分析预测注意力瓶颈会完全找错方向。

T-3.9.5【四条失效根源的总体评估】(a)

- **场景 1**（「资源有限 → 竞争减少份额」）：违反**产能约束假设**。注意力没有列约束，Position j 的 Value 被多个 Query 高分关注时，每个 Query 得到的权重几乎不变（如题 2 所示）。误导后果：误以为注意力有「拥挤效应」，会在某个位置被频繁访问时导致信息传输质量下降——实际上没有。
- **场景 2**（「供应商专业化由战略决定 → 增加头数控制特征」）：违反**功能涌现性假设**。头的功能由训练涌现，增加头数不能预先规定哪个头学什么功能。误导后果：误以为可以通过架构设计直接控制语言特征的处理，绕过训练过程——实际上必须通过辅助损失或数据干预。
- **场景 3**（「调度员权衡决策 → softmax 权重高 = 对预测更重要」）：违反**确定性线性函数假设**（同时违反 §3.7 的「权重 ≠ 解释」）。softmax 是确定性操作，没有决策或权衡；权重高只是 Value 向量线性组合的比例，不等于因果重要性。误导后果：注意力权重被当作可解释的决策依据，产生热力图误读（§3.7 的全部问题）。
- **场景 4**（「供应链审计 → 注意力热力图忠实记录决策路径」）：违反**可审计性假设**

(权重不等于解释)。注意力权重不是因果路径的忠实记录，而是一个中间量，无法单独作为解释。误导后果：基于注意力热力图做错误的模型行为解释和信任评估。

(b) 供应链类比最安全的场景：描述注意力机制的三角色逻辑结构（Q 发出检索请求，K 提供匹配标签，V 提供实际内容）和多头并行处理不同语义维度的直觉，以及帮助建立单次前向传播完成的「全局询价」次数的量级感受（ $n \times n \times h$ 的规模直觉）。在这两个用途上，供应链类比不会产生系统性误判。

(c) 四个必须放下的场景：1. 分析注意力的「竞争动态」（产能约束失效）——注意力没有竞争，任何「Key 被抢占」的推论都是错误的；2. 预测训练过程中头的专业化机制（功能涌现失效）——不能用「供应商选择专业方向」来类比梯度如何塑造头的功能；3. 用 softmax 权重分析模型的预测原因（优化决策失效 + 可审计性失效）——注意力是线性函数，权重不是决策，热力图不是解释；4. 预测注意力的计算瓶颈（优化/约束框架失效）——注意力的瓶颈是 $O(n^2)$ 的 FLOPs 和 HBM 带宽，不是任何「资源有限的供应商」。

(d) 更精确的类比：关联记忆检索（现代 Hopfield 网络）。更准确的维度：① 无产能约束（关联记忆本来就是无限次可检索的）；② 通过相似度（内积）做软检索而非离散决策，与 softmax 的数学形式精确对应；③ 指数容量的概念解释了参数规模与知识存储能力的关系。仍然有局限：① 关联记忆框架对「三角色分离（Q/K/V 独立投影）」没有直接对应——Hopfield 中 $K = V$ ；② 对「多头并行在不同子空间做检索」的量级直觉不如供应链直观；③ 无法解释多层 Transformer 中 FFN 等非注意力组件的作用。

§ 3.9 小结：供应链类比的四条失效根源——产能约束（Value 无守恒）、功能涌现（头的职责不可预设）、确定性变换（softmax 不是优化决策）、不可审计（权重不等于因果路径）——共同揭示了注意力机制的真实数学本质：无约束的相似度加权线性变换，功能由训练塑造，可计算但不可直接因果解读。好的类比帮助建立直觉，坏的类比固化误解；供应链类比的值在于量级感知和三角色结构，代价是四个可预测的系统性误判风险。知道何时放下类比，和知道何时使用类比，同样重要。

第 4 章 · 非凸优化与超参数标度律

§ 4.1 从对数似然到损失：三条等价路径

损失函数是训练的起点：把“犯错程度”量化为一个数。本节围绕三条等价路径（MLE、最小负对数似然、最小 KL 散度）和 Softmax + 交叉熵联合梯度推导，覆盖经验风险、交叉熵、Softmax、MSE 对比四个公式。

公式 1 · 经验风险与交叉熵

$$\hat{R}(\theta) = \frac{1}{N} \sum_{i=1}^N \ell(f_{\theta}(x_i), y_i)$$

$$L = - \sum_{k=1}^K y_k \log p_k$$

对 K 分类问题，one-hot 标签 y ，模型预测概率 p 。交叉熵损失来源于三条等价路径：MLE = 最小负对数似然 = 最小 KL 散度。

一句话直觉：交叉熵把”预测概率与正确标签的对数差距”量化为训练信号，与 MLE 完全等价。

在大模型里的位置：训练

本组训练目标：代入 · 证明 · 反例

常见卡点：

- 完美预测 $p_k = 1$ 时 $\log 1 = 0$ ，损失为 0，是下确界而非极限
- KL 散度展开后”与 θ 无关”的那项是真实分布的熵，不是常数 0
- one-hot 标签下 $\sum_k y_k = 1$ ，但预测概率 $\sum_k p_k = 1$ 是 Softmax 归一化保证的，两者来源不同

本组在练什么：从三条路径证明交叉熵与 MLE 等价，并感受数值变化与损失的对应关系。做完应能回答：为什么最大化对数似然就等于最小化 KL 散度？

T-4.1.1【易 · 代入 · 交叉熵数值】 某三分类模型对一个样本的 Softmax 输出为 $p = (0.7, 0.2, 0.1)$ ，真实标签为 one-hot $y = (0, 1, 0)$ （第 2 类）。

- 计算该样本的交叉熵损失 L （自然对数，保留 4 位小数）；
- 若预测改为 $p' = (0.1, 0.8, 0.1)$ ，重新计算 L' ，并说明损失下降的直觉原因；
- 完美预测 $p^* = (0, 1, 0)$ 时 $L^* = ?$ ，这个结果有什么意义？

解答 T-4.1.1【易 · 代入 · 交叉熵数值】

- 真实标签为第 2 类， $y_2 = 1$ ，其余为 0：

$$L = -\log p_2 = -\log 0.2 = \ln 5 \approx 1.6094 \text{ nats}$$

- $L' = -\log 0.8 \approx 0.2231$ nats。损失从 1.6094 降到 0.2231，因为模型现在以 80% 的概率预测正确类别（之前只有 20%）；对数函数的凹性使”把更多概率赋给正确类别”的改善被非线性放大——概率从 0.2 提升到 0.8，但损失降幅达到 87%。
- $L^* = -\log 1 = 0$ 。这是交叉熵损失的下确界：只有当预测完全确定且正确（概率为 1）时，损失才等于 0。实际训练中 Softmax 输出永远不等于精确的 1，因此 $L^* = 0$ 是极限而非可达值（除非在数值上截断）。

T-4.1.2【中 · 证明 · 三条等价路径】 设数据集 $\{(x_i, y_i)\}_{i=1}^N$ ，模型输出条件分布 $p_\theta(y | x)$ ，真实经验分布记为 $\hat{q}(y | x)$ 。

- 写出负对数似然目标 $\min_\theta -\frac{1}{N} \sum_i \log p_\theta(y_i | x_i)$ 的等价期望形式；
- 写出 $D_{\text{KL}}(\hat{q} \| p_\theta)$ 的展开式，指出哪一项与 θ 无关；

- (c) 证明: $\min_{\theta} D_{\text{KL}}(\hat{q} \| p_{\theta})$ 等价于 $\min_{\theta} H(\hat{q}, p_{\theta})$ 等价于 $\max_{\theta} \frac{1}{N} \sum_i \log p_{\theta}(y_i | x_i)$ (三条路径完全等价)。

解答 T-4.1.2 【中 · 证明 · 三条等价路径】

- (a) 负对数似然的等价期望形式:

$$-\frac{1}{N} \sum_i \log p_{\theta}(y_i | x_i) = -\mathbb{E}_{(x,y) \sim \hat{q}}[\log p_{\theta}(y | x)] = H(\hat{q}, p_{\theta})$$

即等于经验分布 $\hat{q}$ 与模型 p_{θ} 之间的交叉熵。

- (b) KL 散度展开:

$$D_{\text{KL}}(\hat{q} \| p_{\theta}) = -\mathbb{E}_{\hat{q}}[\log p_{\theta}(y | x)] + \underbrace{\mathbb{E}_{\hat{q}}[\log \hat{q}(y | x)]}_{=-H(\hat{q}), \text{与 } \theta \text{ 无关}}$$

第二项 $-H(\hat{q})$ 是训练数据固定后的常数 (真实分布的熵的负值), 与 θ 无关。

- (c) 由 (b): $\min_{\theta} D_{\text{KL}} = \min_{\theta} [-\mathbb{E}_{\hat{q}} \log p_{\theta}] = \min_{\theta} H(\hat{q}, p_{\theta})$ 。由 (a): $H(\hat{q}, p_{\theta}) = -\mathbb{E}_{\hat{q}} \log p_{\theta}$ 。故 $\min_{\theta} H(\hat{q}, p_{\theta})$ 等价于 $\max_{\theta} \mathbb{E}_{\hat{q}}[\log p_{\theta}] = \max_{\theta} \frac{1}{N} \sum_i \log p_{\theta}(y_i | x_i)$ 。三条路径完全等价。

T-4.1.3 【中 · 判错 · MSE 与交叉熵梯度的对比】 以下说法有误:

“分类任务中 MSE 损失的梯度比交叉熵更强 (绝对值更大), 所以应该优先使用 MSE。”

- (a) 指出该说法的逻辑错误;
 (b) 设 sigmoid 输出 $\hat{p} = \sigma(z)$, 真实标签 $y = 1$, 写出 MSE 损失对 z 的梯度表达式;
 (c) 当 $z \rightarrow -\infty$ (模型极度确信犯错), 计算 MSE 梯度的极限; 用交叉熵梯度对比, 说明哪个更有利于训练。

解答 T-4.1.3 【中 · 判错 · MSE 与交叉熵梯度的对比】

- (a) 该说法的逻辑错误: 断言“MSE 梯度更强”完全错误。事实恰恰相反——MSE 梯度在预测极差时会趋于零 (梯度消失/饱和), 交叉熵梯度在同样情况下保持有效。
 (b) MSE 损失 $\ell_{\text{MSE}} = \frac{1}{2}(\hat{p} - y)^2$, $\hat{p} = \sigma(z)$, $\sigma'(z) = \hat{p}(1 - \hat{p})$:

$$\frac{\partial \ell_{\text{MSE}}}{\partial z} = (\hat{p} - y) \cdot \hat{p}(1 - \hat{p})$$

- (c) 当 $z \rightarrow -\infty$, $\hat{p} = \sigma(z) \rightarrow 0$:
 · MSE 梯度: $(\hat{p} - 1) \cdot \hat{p}(1 - \hat{p}) \rightarrow (-1) \times 0 \times 1 = 0$ (梯度饱和消失)
 · 交叉熵梯度: $\partial \ell_{\text{CE}} / \partial z = \hat{p} - y \rightarrow 0 - 1 = -1$ (保持有效梯度信号)

结论: MSE 梯度中的 $\hat{p}(1 - \hat{p})$ 因子 (sigmoid 的导数) 在预测极差时趋近于 0, 导致“最需要学习的时候梯度最小”; 交叉熵的梯度直接等于预测误差 $\hat{p} - y$, 与 sigmoid 导

数恰好约分，在任何预测状态下都能保持有效训练信号。这是大模型普遍采用交叉熵的核心原因。

公式 2 · Softmax 与联合梯度

$$p_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}$$

$$\frac{\partial L}{\partial z_i} = p_i - y_i$$

Softmax 将 logit 向量归一化为概率，交叉熵对 logit 的梯度恰好是“预测概率减真实标签”——链式法则的 Jacobian 恰好约分，无需单独计算。

一句话直觉：反向传播到最后一层的误差信号，就是预测概率与真实标签之差，优雅且高效。

在大模型里的位置：训练

本组训练目标：推导 · 代入 · 工程

常见卡点：

- $\partial p_j / \partial z_i$ 有两种情况： $j = i$ 和 $j \neq i$ ，分开讨论后用 Kronecker delta 统一
- 化简时用了 $\sum_k y_k = 1$ (one-hot)，必须明写这一步
- Softmax 的平移不变性：所有 logit 加同一常数，输出不变

本组在练什么：完整推导 Softmax + 交叉熵的联合梯度，掌握链式法则如何自动约分 Jacobian。做完应能回答：为什么不需要单独计算 Softmax 雅可比矩阵？

T-4.1.4 【易 · 代入 · Softmax 手算与平移不变性】 设 logit 向量 $z = (2, 1, 0)$ (三分类)，真实标签为类别 1 ($y_1 = 1$)。

- 手算 Softmax 输出 (p_1, p_2, p_3) (保留 4 位小数)；
- 计算交叉熵损失 L ；
- 若将所有 logit 同时加 $c = -2$ (即 $z' = (0, -1, -2)$)，Softmax 输出是否改变？给出代数证明 (log-sum-exp 数值稳定技巧的理论基础)。

解答 T-4.1.4 【易 · 代入 · Softmax 手算与平移不变性】

- $\sum_j e^{z_j} = e^2 + e^1 + e^0 \approx 7.3891 + 2.7183 + 1.0000 = 11.1074$ ：

$$p_1 \approx 7.3891/11.1074 \approx 0.6652, \quad p_2 \approx 0.2447, \quad p_3 \approx 0.0901$$

验证： $0.6652 + 0.2447 + 0.0901 = 1.0000$ 。

- 真实标签为类别 1 ($y_1 = 1$)： $L = -\log p_1 = -\log 0.6652 \approx 0.4076$ nats。

- 令 $z' = z + c$ ，则：

$$p'_k = \frac{e^{z_k+c}}{\sum_j e^{z_j+c}} = \frac{e^c \cdot e^{z_k}}{e^c \sum_j e^{z_j}} = \frac{e^{z_k}}{\sum_j e^{z_j}} = p_k$$

e^c 在分子分母完全约分，Softmax 输出不变。平移不变性是 log-sum-exp 技巧的理论基础：令 $c = -\max_k z_k$ ，减去最大值后所有 $e^{z_k-M} \leq 1$ ，不再上溢。

T-4.1.5 【中 · 推导 · Softmax + 交叉熵联合梯度】 设 logit 向量 $z = (z_1, \dots, z_K)$ ，Softmax 输出 $p_k = e^{z_k} / \sum_j e^{z_j}$ ，交叉熵损失 $L = -\sum_k y_k \log p_k$ ，true 标签 one-hot。

- 计算 $\partial p_j / \partial z_i$ ，分 $j = i$ 和 $j \neq i$ 两种情况，结果写成 $p_j(\delta_{ij} - p_i)$ ；
- 用链式法则展开 $\partial L / \partial z_i$ ，代入 (a) 的结果，利用 one-hot 条件 $\sum_k y_k = 1$ 化简；
- 验证最终结果 $\partial L / \partial z_i = p_i - y_i$ ，并解释：对真实类别 c ，梯度为负；对其他类别，梯度为正，这两个符号的直觉含义是什么？

解答 T-4.1.5 【中 · 推导 · Softmax + 交叉熵联合梯度】

- 令 $S = \sum_j e^{z_j}$ 。

当 $j = i$ ：

$$\frac{\partial p_i}{\partial z_i} = \frac{e^{z_i} \cdot S - e^{z_i} \cdot e^{z_i}}{S^2} = p_i - p_i^2 = p_i(1 - p_i) = p_i(\delta_{ii} - p_i)$$

当 $j \neq i$ ：

$$\frac{\partial p_j}{\partial z_i} = \frac{0 - e^{z_j} \cdot e^{z_i}}{S^2} = -p_j p_i = p_j(0 - p_i) = p_j(\delta_{ji} - p_i)$$

统一写为 $\partial p_j / \partial z_i = p_j(\delta_{ij} - p_i)$ 。

- 链式法则展开：

$$\frac{\partial L}{\partial z_i} = -\sum_k y_k \frac{\partial \log p_k}{\partial z_i} = -\sum_k y_k \cdot \frac{1}{p_k} \frac{\partial p_k}{\partial z_i}$$

代入 (a)：

$$= -\sum_k y_k \cdot \frac{1}{p_k} \cdot p_k(\delta_{ik} - p_i) = -\sum_k y_k(\delta_{ik} - p_i) = -\sum_k y_k \delta_{ik} + p_i \sum_k y_k$$

利用 one-hot 条件： $\sum_k y_k \delta_{ik} = y_i$ ， $\sum_k y_k = 1$ ：

$$\frac{\partial L}{\partial z_i} = -y_i + p_i = p_i - y_i \quad \blacksquare$$

- 符号的直觉含义：

· 对真实类别 c ($y_c = 1$)：梯度 $= p_c - 1 < 0$ ，应增大 z_c （提高正确类别的 logit）；

- 对其他类别 $k \neq c$ ($y_k = 0$): 梯度 $= p_k > 0$, 应减小 z_k (压低错误类别的 logit)。
- 两者共同驱动模型把概率质量从错误类别转移到正确类别。

T-4.1.6【难·工程·数值稳定性与 log-sum-exp】 设三分类 logit 向量为 $z = (1000, 1001, 999)$ 。

- 直接计算 e^{z_k} 会遇到什么数值问题? (用 float64 上溢范围约 1.8×10^{308} 作参考)
- 设 $M = \max_k z_k = 1001$, 写出 log-sum-exp 技巧, 代数证明其与直接计算等价, 计算 $\log \sum_k e^{z_k}$ 的数值 (保留 4 位小数);
- 用此技巧计算对应的近似 Softmax 输出; 说明为什么深度学习框架 (如 PyTorch 的 `cross_entropy`) 在内部总是从 logits 而非概率出发计算损失。

解答 T-4.1.6【难·工程·数值稳定性与 log-sum-exp】

- $e^{1000} \approx 5 \times 10^{433}$, 远超 float64 的上溢范围 ($\approx 1.8 \times 10^{308}$)。直接计算 e^{z_k} 会得到 inf, 后续运算全部产生 NaN, 训练崩溃。
- 令 $M = 1001$, log-sum-exp 技巧:

$$\log \sum_k e^{z_k} = M + \log \sum_k e^{z_k - M} = 1001 + \log(e^{-1} + e^0 + e^{-2})$$

$$= 1001 + \log(0.3679 + 1.0000 + 0.1353) = 1001 + \log(1.5032) \approx 1001 + 0.4078 = 1001.4078$$

等价性证明: $\log \sum_k e^{z_k} = \log(e^M \sum_k e^{z_k - M}) = M + \log \sum_k e^{z_k - M}$ 。

- Softmax 输出 (用 $p_k = e^{z_k - \log \sum e^{z_j}}$):

$$p_1 = e^{1000 - 1001.4078} = e^{-1.4078} \approx 0.2449, \quad p_2 \approx 0.6652, \quad p_3 \approx 0.0900$$

深度学习框架从 logits 出发的原因: 内部自动应用 log-sum-exp, 同时将 Softmax + 对数合并为单次计算, 既避免上溢, 又避免 $\log(0)$ 的下溢 (若先算 Softmax 再取对数, 极小概率会产生 $\log(\approx 0)$)。

工程批注: PyTorch 的 `cross_entropy(logits, labels)` 内部调用的是 `log_softmax(logits) + nll_loss`, 其中 `log_softmax` 使用 log-sum-exp 技巧。对用户而言, 永远应该传 logits 而不是 `softmax(logits)`: 传概率进去会导致两次数值不稳定 (softmax 可能产生极小值, 取对数后产生 -inf), 而且梯度路径更长, 没有任何好处。Gradient clipping (梯度裁剪) 的默认阈值通常取 1.0, 原因是: 大模型训练中若某步梯度范数突然超过 1, 通常是数值不稳定的前兆 (损失尖峰), 及时裁剪可以防止参数崩溃, 这个阈值与交叉熵梯度 $p_i - y_i \in (-1, 1)$ 的范围也自然对应。

§ 4.2 下坡的数学：收敛速度与步长选择

梯度下降是优化的骨架，从一阶 Taylor 展开导出，步长受函数曲率约束。本节覆盖五个公式：梯度下降更新规则、L-光滑条件与步长上界、SGD mini-batch 方差、动量法、Adam 偏差修正更新。

小节导读：梯度下降不是“朝最陡方向走一步”那么简单——步长能不能取、SGD 为什么有效、动量与 Adam 为什么改进，全都来自一个共同的几何起点：一阶 Taylor 展开。第一步，梯度下降是一阶 Taylor 展开的逻辑后果；第二步，步长上界来自二阶项；第三步，SGD 为什么用 mini-batch；第四步，动量为什么能加速；第五步，Adam 为什么再加自适应学习率。

公式 3 · 梯度下降更新规则与步长上界

$$\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t)$$

$$\|\nabla L(\theta) - \nabla L(\theta')\| \leq L \|\theta - \theta'\|, \quad \forall \theta, \theta'$$

$$L(\theta_{t+1}) \leq L(\theta_t) - \frac{\eta}{2} \|\nabla L(\theta_t)\|^2 \quad (\eta \leq 1/L)$$

梯度下降沿最陡下降方向走一小步；L-光滑条件给出步长上界 $\eta < 2/L$ ，超过则震荡甚至发散。

一句话直觉：在约束 $\|\Delta\theta\| = \epsilon$ 下，梯度反向是损失下降最快的方向；步长过大会跨过极小值导致发散。

在大模型里的位置：训练

本组训练目标：代入 · 证明 · 反例

常见卡点：

- 从一阶 Taylor 展开到更新规则，需要明确“在固定步长约束下最优化方向”
- descent lemma 的证明用到了积分形式加 Cauchy-Schwarz，注意积分上界中的因子 t
- $\eta < 2/L$ 是不增的充分条件， $\eta \leq 1/L$ 是有足够下降量的充分条件，二者不同

本组在练什么：从 L-光滑条件推导步长上界，并用具体例子感受步长超界后的发散。做完应能回答：学习率为什么不能任意大？

T-4.2.1 【易 · 手算 · SGD 三步迭代与步长效应】 设一维损失函数 $L(\theta) = \frac{1}{2}(\theta - 3)^2$ ，初始值 $\theta_0 = 0$ 。

- 写出梯度 $\nabla L(\theta)$ ，以及此函数的 Lipschitz 常数 L_0 （即二阶导数）；
- 取 $\eta = 0.5$ ，手动计算 $\theta_1, \theta_2, \theta_3$ （保留 4 位小数），描述收敛行为；
- 取 $\eta = 2.5$ （超过 $2/L_0 = 2$ ），手动计算两步，描述行为；
- 什么学习率能使一步即收敛到 $\theta^* = 3$ ？与 $1/L_0$ 的关系？

解答 T-4.2.1 【易 · 手算 · SGD 三步迭代与步长效应】

(a) $\nabla L(\theta) = \theta - 3$; 二阶导数 (Lipschitz 常数) $L_0 = 1$ (因为 $\nabla^2 L = 1$)。

(b) $\eta = 0.5$:

- $\theta_1 = 0 - 0.5 \times (0 - 3) = 1.5$
- $\theta_2 = 1.5 - 0.5 \times (1.5 - 3) = 2.25$
- $\theta_3 = 2.25 - 0.5 \times (2.25 - 3) = 2.625$

每步向 $\theta^* = 3$ 靠近剩余距离的 50%，单调收敛。

(c) $\eta = 2.5$ (超过上界 $2/L_0 = 2$):

- $\theta_1 = 0 - 2.5 \times (-3) = 7.5$ (大幅越过极小值)
- $\theta_2 = 7.5 - 2.5 \times 4.5 = -3.75$ (越回另一侧)

序列震荡发散: $|\theta_t - 3| = |1 - 2.5|^t \times 3 = 1.5^t \times 3 \rightarrow \infty$ 。

(d) 一步收敛要求 $\theta_0 - \eta(\theta_0 - 3) = 3$, 即 $\eta \times 3 = 3$, $\eta = 1 = 1/L_0$ 。最优步长恰好等于 $1/L_0$ (descent lemma 给出的推荐上界)。

T-4.2.2 【难 · 证明 · descent lemma 与步长上界】 设 L 满足 L -Lipschitz 梯度: $\|\nabla L(\theta) - \nabla L(\theta')\| \leq L\|\theta - \theta'\|$ 。

(a) 利用 $L(\theta') - L(\theta) = \int_0^1 \nabla L(\theta + t(\theta' - \theta))^\top (\theta' - \theta) dt$, 推导:

$$L(\theta') \leq L(\theta) + \nabla L(\theta)^\top (\theta' - \theta) + \frac{L}{2} \|\theta' - \theta\|^2$$

(提示: 把被积函数分拆为 $\nabla L(\theta)^\top (\cdot)$ 加余差项, 对余差项用 Cauchy-Schwarz + L -Lipschitz)

(b) 令 $\theta' = \theta_t - \eta \nabla L(\theta_t)$, 代入 (a), 证明 $\eta \leq 1/L$ 时:

$$L(\theta_{t+1}) \leq L(\theta_t) - \frac{\eta}{2} \|\nabla L(\theta_t)\|^2$$

(c) 说明步长上界 $\eta < 2/L$ 与 $\eta \leq 1/L$ 哪个更紧, 实践中通常用哪个。

解答 T-4.2.2 【难 · 证明 · descent lemma 与步长上界】

(a) 利用微积分基本定理和 L -Lipschitz 条件。对路径 $\theta(t) = \theta + t(\theta' - \theta)$:

$$\begin{aligned} L(\theta') - L(\theta) &= \int_0^1 \nabla L(\theta(t))^\top (\theta' - \theta) dt \\ &= \nabla L(\theta)^\top (\theta' - \theta) + \int_0^1 [\nabla L(\theta(t)) - \nabla L(\theta)]^\top (\theta' - \theta) dt \end{aligned}$$

对第二项, 用 Cauchy-Schwarz 和 L -Lipschitz:

$$\int_0^1 [\nabla L(\theta(t)) - \nabla L(\theta)]^\top (\theta' - \theta) dt \leq \int_0^1 \|\nabla L(\theta(t)) - \nabla L(\theta)\| \cdot \|\theta' - \theta\| dt$$

$$\leq \int_0^1 L \cdot t \|\theta' - \theta\| \cdot \|\theta' - \theta\| dt = \frac{L}{2} \|\theta' - \theta\|^2 \quad \blacksquare$$

(b) 令 $\theta' = \theta_t - \eta \nabla L(\theta_t)$, $\theta' - \theta_t = -\eta \nabla L(\theta_t)$:

$$L(\theta_{t+1}) \leq L(\theta_t) - \eta \|\nabla L(\theta_t)\|^2 + \frac{L}{2} \eta^2 \|\nabla L(\theta_t)\|^2 = L(\theta_t) - \underbrace{\eta \left(1 - \frac{L\eta}{2}\right)}_{\geq 1/2 \text{ 当 } \eta \leq 1/L} \|\nabla L(\theta_t)\|^2$$

当 $\eta \leq 1/L$ 时, $1 - L\eta/2 \geq 1/2 > 0$, 故 $L(\theta_{t+1}) \leq L(\theta_t) - \frac{\eta}{2} \|\nabla L(\theta_t)\|^2$ 。

(c) 严格不增的充分条件是 $1 - L\eta/2 > 0$, 即 $\eta < 2/L$ (更宽松); 保证有足够下降量的实用上界是 $\eta \leq 1/L$ (更紧)。实践中通常取 $\eta \leq 1/L$ 作为理论安全上界, 并在此基础上使用更小的初始学习率 (配合 warmup)。

T-4.2.3 【中 · 反例 · 步长超界发散的验证】 设 $L(\theta) = \frac{L_0}{2} \theta^2$ ($L_0 > 0$), 初始 $\theta_0 = 1$, 学习率 η 。

- 写出梯度下降递推式 $\theta_{t+1} = r \cdot \theta_t$, 其中公比 $r = 1 - \eta L_0$;
- 分析 $|r|$ 与收敛/发散的关系: $\eta < 2/L_0$ 、 $\eta = 2/L_0$ 、 $\eta > 2/L_0$ 三种情况;
- 取 $L_0 = 4$, $\eta = 0.6$, 验证三步后 $|\theta_3| > |\theta_0|$ (已知步长上界 $2/L_0 = 0.5 < 0.6$)。

解答 T-4.2.3 【中 · 反例 · 步长超界发散的验证】

- 梯度 $\nabla L = L_0 \theta$, 更新: $\theta_{t+1} = \theta_t - \eta L_0 \theta_t = (1 - \eta L_0) \theta_t = r \theta_t$, 其中 $r = 1 - \eta L_0$ 。
- 由于 $|\theta_t| = |r|^t |\theta_0|$:
 - $\eta < 2/L_0$: $|r| = |1 - \eta L_0| < 1$, $|\theta_t| \rightarrow 0$ (收敛)
 - $\eta = 2/L_0$: $r = -1$, $\theta_t = (-1)^t \theta_0$, 永远在 $\pm \theta_0$ 间震荡, 不收敛也不发散
 - $\eta > 2/L_0$: $|r| > 1$, $|\theta_t| \rightarrow \infty$ (发散)
- $L_0 = 4$, $\eta = 0.6$, 步长上界 $2/L_0 = 0.5 < 0.6$, 公比 $r = 1 - 0.6 \times 4 = -1.4$:
 - $\theta_1 = -1.4 \times 1 = -1.4$, $|\theta_1| = 1.4 > 1$
 - $\theta_2 = -1.4 \times (-1.4) = 1.96$
 - $\theta_3 = -1.4 \times 1.96 = -2.744$, $|\theta_3| = 2.744 > |\theta_0| = 1 \quad \square$

公式 4 · SGD mini-batch 方差

$$\tilde{g}_t = \frac{1}{|B|} \sum_{i \in B} \nabla \ell(f_\theta(x_i), y_i), \quad \text{Var}(\tilde{g}_t) = \frac{1}{|B|} \text{Var}(\nabla \ell_i)$$

mini-batch 梯度是真实梯度的无偏估计; 方差随 batch size 线性减小。更大 batch 更准确, 但随机噪声也更少——这一噪声在 §4.3 中有正面意义。

一句话直觉: batch size 加倍, 梯度方差减半; 线性缩放规则来自保持更新量方差不变。

在大模型里的位置：训练**本组训练目标：**推导·代入·工程**常见卡点：**

- mini-batch 估计是”无偏”的（期望等于真实梯度），但有方差——不要混淆偏差与方差
- 线性缩放规则 vs 平方根缩放规则：前者保方向等效，后者保方差等效，两者不同
- 极大 batch 时线性缩放会把学习率推过 Lipschitz 上界，导致发散

本组在练什么：用方差公式推导线性缩放规则，理解 batch size 与学习率的权衡。做完应能回答：batch size 加倍时学习率应如何调整，为什么？

T-4.2.4【易·代入·batch size 与梯度方差】 设 SGD mini-batch 方差为 $\text{Var}(\tilde{g}) = \sigma^2/|B|$ ，学习率为 η 。

- 一步参数更新量 $\Delta\theta = -\eta\tilde{g}$ 的方差是多少？
- 若 batch size 从 B 扩大到 kB ，要保持每步更新量方差不变，学习率应如何调整？（给出”平方根缩放规则”与”线性缩放规则”两种答案）
- 原始设置 $B = 256$ ， $\eta = 0.01$ ，batch size 扩大到 2048，按线性缩放规则新学习率为多少？
- 线性缩放在 $B > 32768$ 时往往失效，从 § 4.2 步长上界的角度用一句话解释原因。

解答 T-4.2.4【易·代入·batch size 与梯度方差】

- 更新量方差：

$$\text{Var}(\Delta\theta) = \eta^2 \text{Var}(\tilde{g}) = \frac{\eta^2 \sigma^2}{|B|}$$

- batch size 从 B 变为 kB ：

- 平方根缩放规则（保方差）： $\eta' = \eta\sqrt{k}$ ($\eta'^2/(kB) = \eta^2/B$)
- 线性缩放规则（Goyal et al. 2017，保每步更新的期望步长等效）： $\eta' = k\eta$ （更常用于实践）

两者在 k 较小时效果相近；对大 k 平方根规则在理论上更严格。

- $k = 2048/256 = 8$ ，线性缩放： $\eta' = 8 \times 0.01 = 0.08$ 。
- 极大 batch 时，梯度估计已接近确定性梯度，方差趋于零；线性缩放会把学习率推至或超过 Lipschitz 上界 $2/L$ ，导致发散（recall: $\eta < 2/L$ 才能保证收敛）。

T-4.2.5【中·工程·判错：关于 batch size 与收敛的错误说法】 以下说法有两处错误，请分别指出：

“训练 LLM 时 batch size 越大越好：更大的 batch 让梯度更准确，学习率可以同步线性增大，收敛速度线性加快，最终模型质量也更好。”

- 指出第一处错误（与噪声和泛化有关）；
- 指出第二处错误（与步长上界有关）；

(c) 用一句话说明实践中 LLM 训练如何平衡 batch size 选择。

解答 T-4.2.5 【中·工程·判错：关于 batch size 与收敛的错误说法】

- 第一处错误：“最终模型质量也更好”。极大 batch 训练丧失了 SGD 噪声对鞍点逃逸的作用 ($\Sigma \approx \eta/B \cdot C \rightarrow 0$)，同时倾向于收敛到尖锐极小值（大 batch 效应，Keskar et al. 2017），泛化性能反而变差。
- 第二处错误：“学习率可以同步线性增大”没有上界约束。线性缩放规则的学习率受 Lipschitz 上界 $2/L$ 约束，无法无限增大；超过上界后训练发散，不是“收敛速度减慢”，而是直接不收敛。
- LLM 训练中通常选择在算力预算内最大化计算效率的 batch size（如 GPT-4 class 模型用约 4M tokens/batch），配合 warmup 阶段逐步增大学习率，并在大 batch 时使用 gradient accumulation 等效增大批量，而非盲目追求最大 batch。

公式 5 · 动量法

$$v_{t+1} = \mu v_t + \nabla L(\theta_t), \quad \theta_{t+1} = \theta_t - \eta v_{t+1}$$

$$v_t = \sum_{k=0}^{t-1} \mu^k \nabla L(\theta_{t-1-k})$$

速度向量 v_t 是历史梯度的指数加权和，动量系数 $\mu \in [0, 1)$ 控制记忆长度。稳态下速度是纯 SGD 的 $1/(1-\mu)$ 倍。

一句话直觉：动量模拟质点在黏性介质中的惯性运动，历史方向提供加速，抑制垂直方向的震荡。

在大模型里的位置：训练

本组训练目标：推导·代入·变形

常见卡点：

- 递推展开时注意下标： v_{t+1} 而非 v_t 包含当前梯度 g_t
- 稳态放大倍数 $1/(1-\mu)$ 来自等比数列求和，仅在梯度方向稳定时成立
- 动量记忆长度约为 $\ln(0.01)/\ln \mu$ 步， $\mu = 0.9$ 时约 44 步

本组在练什么：展开动量递推，计算权重衰减速率和稳态放大倍数。做完应能回答：动量的“有效记忆长度”是多少步？梯度方向一致时速度放大几倍？

T-4.2.6 【易·代入·动量递推展开与权重】 动量法： $v_{t+1} = \mu v_t + g_t$ ($g_t = \nabla L(\theta_t)$)，初始 $v_0 = 0$ 。

- 展开递推，证明 $v_t = \sum_{k=0}^{t-1} \mu^k g_{t-1-k}$ ；
- 取 $\mu = 0.9$ ，计算历史梯度 $g_{t-1}, g_{t-2}, g_{t-3}, g_{t-4}$ 的权重（保留 4 位小数）；
- 第 k 步历史梯度权重低于 0.01 时，约需几步？（估算有效记忆长度）

- (d) 若梯度方向稳定不变 ($g_t = g$ 为常数), 稳态速度 v_∞ 是多少? 与纯 SGD 每步移动量相比放大几倍? (取 $\mu = 0.9$)

解答 T-4.2.6 【易 · 代入 · 动量递推展开与权重】

- (a) 递推展开: $v_1 = g_0$, $v_2 = \mu g_0 + g_1$, $\dots$, 归纳法:

$$v_t = (1 - 0) \sum_{k=0}^{t-1} \mu^k g_{t-1-k} \quad \blacksquare$$

(注: $v_{t+1} = \mu v_t + g_t$, 展开后 $v_t = \sum_{k=0}^{t-1} \mu^k g_{t-1-k}$)

- (b) $\mu = 0.9$ 时各历史梯度权重:

历史步	权重
g_{t-1}	$\mu^0 = 1.0000$
g_{t-2}	$\mu^1 = 0.9000$
g_{t-3}	$\mu^2 = 0.8100$
g_{t-4}	$\mu^3 = 0.7290$

- (c) $\mu^k < 0.01$ 要求 $k > \ln 0.01 / \ln 0.9 = (-4.6052) / (-0.1054) \approx 43.7$, 约 44 步。
- (d) 稳态: $v_\infty = \mu v_\infty + g \Rightarrow v_\infty = g / (1 - \mu) = g / 0.1 = 10g$ 。动量法的稳态速度是纯 SGD 每步移动量的 10 倍, 这解释了动量法在梯度方向一致的平坦区域 (如鞍点与极小值之间的平台) 的显著加速效果。

T-4.2.7 【中 · 变形 · 动量与 SGD 的轨迹对比】 设二维损失函数, 在某坐标方向 x 的梯度恒为 $g_x = 1$, 在垂直方向 y 的梯度交替为 $g_y = +1, -1, +1, -1, \dots$ (震荡)。

- (a) 纯 SGD ($\eta = 0.1$) 在 x 方向每步移动多少? 10 步后总移动量?
- (b) 纯 SGD 在 y 方向 10 步后净移动量? (每步 ± 0.1 , 交替抵消)
- (c) 动量法 ($\mu = 0.9$, $\eta = 0.1$) 在 y 方向, 分析稳态后震荡幅度是否减小? (提示: 相邻两步的动量方向相反, 相互抵消)
- (d) 这道题揭示了动量法的哪个优点? 一句话总结。

解答 T-4.2.7 【中 · 变形 · 动量与 SGD 的轨迹对比】

- (a) 纯 SGD 在 x 方向: 每步 $-\eta g_x = -0.1 \times 1 = -0.1$ (向极小值移动), 10 步总移动 -1.0 。
- (b) 在 y 方向梯度交替 ± 1 , 每步 ∓ 0.1 , 相邻步恰好抵消, 10 步净移动 $= 0$ 。
- (c) 动量法在 y 方向: 第 1 步速度 $v_1 = 0.1$ (向正), 第 2 步速度 $v_2 = 0.9 \times 0.1 + 0.1 \times (-1) = 0.09 - 0.1 = -0.01$ (向负, 但幅度大幅缩小), 相邻步的速度几乎相互抵消, 震荡幅度远小于纯 SGD。

- (d) 动量法的核心优点：在震荡方向（垂直于主梯度方向），相邻步梯度符号相反，动量项相互抵消，震荡被自动压制；在收敛方向（梯度方向一致），动量累加，加速收敛。

公式 6 · Adam 偏差修正更新

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}$$

$$\theta_{t+1} = \theta_t - \eta \cdot \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

Adam 同时维护一阶矩（动量方向）与二阶矩（梯度幅值的历史平方均值），自适应缩放每个参数的有效学习率。零初始化导致早期偏差，偏差修正在前几十步至关重要。

一句话直觉：Adam 为每个参数单独调整有效学习率：历史梯度幅值大的参数步长缩小，梯度小的步长放大。

在大模型里的位置：训练

本组训练目标：代入 · 证明 · 工程

常见卡点：

- g_t^2 是逐元素平方，不是向量的范数平方
- 偏差修正是因为 $m_0 = v_0 = 0$ 的零初始化，不是算法设计选择——早期若不修正，有效学习率会出现意外放大或缩小
- 典型超参数 $\beta_1 = 0.9$, $\beta_2 = 0.999$ 下，偏差修正的影响约在前 44 步（ β_1 方向）和 4600 步（ β_2 方向）内显著

本组在练什么：从零手算 Adam 两步更新，验证偏差修正的实际效果，理解为什么 Adam 在初始阶段需要“预热”。做完应能回答：偏差修正修正了什么？不修正会发生什么？

T-4.2.8 【易 · 代入 · Adam 两步手算】 设单参数 θ ，初始 $\theta_0 = 1$, $m_0 = v_0 = 0$ ，超参数 $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\eta = 0.01$, $\epsilon = 10^{-8}$ 。

给定两步梯度 $g_1 = 0.5$, $g_2 = -0.3$ 。

- 计算 $t = 1$ 时的 $m_1, v_1, \hat{m}_1, \hat{v}_1$ 和 θ_1 （保留 5 位小数）；
- 计算 $t = 2$ 时的 $m_2, v_2, \hat{m}_2, \hat{v}_2$ 和 θ_2 ；
- 若去掉偏差修正（直接用 m_1, v_1 代替 $\hat{m}_1, \hat{v}_1$ ）， $t = 1$ 时的更新量会变成多少？与修正后对比，解释偏差修正的作用。

解答 T-4.2.8 【易 · 代入 · Adam 两步手算】

- $t = 1$, $g_1 = 0.5$ ：

$$m_1 = 0.9 \times 0 + 0.1 \times 0.5 = 0.05$$

$$v_1 = 0.999 \times 0 + 0.001 \times 0.25 = 0.00025$$

偏差修正： $\hat{m}_1 = 0.05/(1 - 0.9^1) = 0.05/0.1 = 0.5$ ， $\hat{v}_1 = 0.00025/(1 - 0.999^1) = 0.00025/0.001 = 0.25$

更新： $\theta_1 = 1 - 0.01 \times 0.5/(\sqrt{0.25} + 10^{-8}) = 1 - 0.01 = 0.99000$

(b) $t = 2$ ， $g_2 = -0.3$ ：

$$m_2 = 0.9 \times 0.05 + 0.1 \times (-0.3) = 0.045 - 0.03 = 0.015$$

$$v_2 = 0.999 \times 0.00025 + 0.001 \times 0.09 = 0.00024975 + 0.00009 = 0.00033975$$

$$\hat{m}_2 = 0.015/(1 - 0.81) = 0.015/0.19 \approx 0.07895$$

$$\hat{v}_2 = 0.00033975/(1 - 0.998001) = 0.00033975/0.001999 \approx 0.16996$$

$$\theta_2 = 0.99 - 0.01 \times 0.07895/(\sqrt{0.16996} + 10^{-8}) \approx 0.99 - 0.01 \times 0.07895/0.41226 \approx 0.99 - 0.001915 \approx 0.988085$$

(c) 无偏差修正时 $t = 1$ ：直接用 $m_1 = 0.05$ ， $\sqrt{v_1} = \sqrt{0.00025} = 0.01581$ ：

$$\Delta\theta = -0.01 \times 0.05/0.01581 \approx -0.01 \times 3.162 = -0.03162$$

与修正后的更新量 -0.01 相比，无修正版本更新量约大 3.2 倍。原因： m_1 和 v_1 同时被零初始化压缩，但 $m_1/\sqrt{v_1}$ 的比值偶然放大了信号；修正后 $\hat{m}_1/\sqrt{\hat{v}_1} = 0.5/\sqrt{0.25} = 0.5/0.5 = 1$ ，乘以 η 得到与梯度幅值对应的合理步长。

工程批注：AdamW vs SGD——为什么 Transformer 默认 AdamW：Transformer 的损失景观高度各向异性，不同参数（词向量层 vs 注意力权重 vs MLP 层）的梯度量级差异可达 10–100 倍。SGD 对所有参数用同一学习率，某些层更新量过大（发散），某些层过小（不收敛），实践中几乎无法调出好结果。AdamW 的二阶矩归一化使每个参数的有效步长自动归一化为同一量级，加上正确的权重衰减，使 Transformer 训练变得稳定且超参数不敏感。Gradient clipping 阈值常取 1.0：Adam 更新后的有效步长 $\hat{m}/\sqrt{\hat{v}} \in O(1)$ ，梯度范数突然超过 1 通常意味着数值不稳定前兆（损失尖峰 loss spike），及时裁剪可防止参数崩溃。

T-4.2.9 【中 · 证明 · Adam 偏差修正的必要性】 设梯度为常数 $g_t = g$, $m_0 = v_0 = 0$ 。

- (a) 展开递推, 证明 $m_t = g(1 - \beta_1^t)$;
- (b) 取 $\beta_1 = 0.9$, 在 $t = 1$ 时, 未修正的 m_1 相对真实值 g 的偏差是多少百分比?
- (c) 证明偏差修正后 $\hat{m}_t = g$ (完全消除偏差);
- (d) 从第几步开始, 修正因子 $1/(1 - \beta_1^t) < 1.01$ (即偏差小于 1%)? 取 $\beta_1 = 0.9$ 。

解答 T-4.2.9 【中 · 证明 · Adam 偏差修正的必要性】

- (a) 递推展开: $m_t = \beta_1 m_{t-1} + (1 - \beta_1)g$, $m_0 = 0$:

$$m_t = (1 - \beta_1) \sum_{k=0}^{t-1} \beta_1^k g = g(1 - \beta_1) \cdot \frac{1 - \beta_1^t}{1 - \beta_1} = g(1 - \beta_1^t) \quad \blacksquare$$

- (b) $t = 1$: $m_1 = g(1 - 0.9) = 0.1g$, 未修正的一阶矩仅为真实值 g 的 10%, 偏差高达 90%。
- (c) 修正后: $\hat{m}_t = m_t / (1 - \beta_1^t) = g(1 - \beta_1^t) / (1 - \beta_1^t) = g$ 。偏差完全消除。
- (d) 修正因子 $1/(1 - \beta_1^t) < 1.01$ 要求 $1 - \beta_1^t > 1/1.01 \approx 0.9901$, 即 $\beta_1^t < 0.0099$:

$$t > \ln 0.0099 / \ln 0.9 = (-4.615) / (-0.1054) \approx 43.8$$

从第 44 步开始, 偏差修正影响低于 1%, 可以忽略。

T-4.2.10 【难 · 工程 · AdamW 与 Adam 的区别及 Transformer 的默认选择】 AdamW 的更新规则与 Adam 的唯一区别在于权重衰减的施加位置:

$$\theta_{t+1} = \theta_t - \eta \cdot \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \epsilon}} - \eta \lambda \theta_t$$

(Adam 的 L2 正则化等效于在梯度中加 $\lambda \theta_t$, 而 AdamW 直接在参数上减)

- (a) 在 Adam + L2 正则化中, 梯度变为 $g'_t = g_t + \lambda \theta_t$; 这会影响二阶矩 v_t 的估计吗? 当 $\|\theta\|$ 较大时会发生什么?
- (b) AdamW 把权重衰减移出动量计算, 对 v_t 的估计有何影响?
- (c) 用一句话总结为什么 Transformer 的标准选择是 AdamW 而非 Adam + L2。

解答 T-4.2.10 【难 · 工程 · AdamW 与 Adam 的区别及 Transformer 的默认选择】

- (a) 在 Adam + L2 正则化中, 梯度变为 $g'_t = g_t + \lambda \theta_t$, 这会污染二阶矩估计: 当 $\|\theta\|$ 较大时 (常见于嵌入层和第一层权重), $\lambda \theta_t$ 项会显著增大 g'_t 的幅值, 使 $v_t = \beta_2 v_{t-1} + (1 - \beta_2)(g'_t)^2$ 高估真实梯度的二阶矩, 导致有效学习率被过度压缩, 权重衰减的实际强度取决于历史梯度量级而非设计意图。
- (b) AdamW 将权重衰减项 $-\eta \lambda \theta_t$ 直接作用在参数上, 不经过动量和二阶矩的计算, v_t 只反映真实任务梯度的历史, 有效学习率不受权重衰减干扰。权重衰减的实际强度稳定等于 $\eta \lambda$, 与梯度幅值无关。

- (c) Transformer 中参数值域差异极大（嵌入层参数 $\|\theta\| \gg 1$ ，而深层 MLP 参数更小），Adam + L2 的混合动量计算导致权重衰减强度随参数值大小变化，不稳定；AdamW 将权重衰减与自适应学习率解耦，使二者各司其职，是 Transformer 的工业标准配置。

§ 4.3 高维非凸的反直觉

高维空间的优化与低维直觉截然不同：局部极小值指数稀少，鞍点才是真正的障碍；SGD 噪声是逃逸鞍点的引擎；极小值连成流形而非孤立深坑。本节覆盖鞍点主导公式、Wigner 半圆律、SGD 噪声协方差三个核心结论。

小节导读：第一步，低维直觉为什么误导高维——要确认一个点是局部极小，需要海森矩阵 H 的所有 d 个特征值都为正， $d = 10^6$ 时这个概率指数小到不可能，真正常见的是鞍点。第二步，Wigner 半圆律给出特征值分布，正负特征值数量大致相等。第三步，鞍点为什么不是绝境——只要找到那个下坡方向。第四步，SGD 噪声反而成了引擎，协方差 $C(\theta) = \frac{1}{N} \sum_i \nabla \ell_i \nabla \ell_i^\top - \nabla L \nabla L^\top$ ，在“损失曲率小”的方向上反而大。

公式 7 · 鞍点主导与海森矩阵判据

$$\Pr[\text{纯局部极小}] \propto e^{-\Omega(d)}$$

$$\rho(\lambda) = \frac{1}{2\pi\sigma^2} \sqrt{4\sigma^2 - \lambda^2}, \quad |\lambda| \leq 2\sigma$$

$$\Sigma(\theta) \approx \frac{\eta}{B} \cdot C(\theta), \quad C(\theta) = \frac{1}{N} \sum_i \nabla \ell_i \nabla \ell_i^\top - \nabla L \nabla L^\top$$

局部极小要求 Hessian 正定（全部特征值 > 0 ），鞍点至少有一个负特征值。在 $d \sim 10^8$ 参数空间中，纯局部极小的概率约 10^{-10^6} ，SGD 几乎只遇到鞍点。

一句话直觉：高维空间中全部特征值同号极为罕见；鞍点几乎是唯一的障碍，而 SGD 的噪声恰好能逃逸鞍点。

在大模型里的位置：训练

本组训练目标：代入 · 估算 · 画图直觉 · 工程

常见卡点：

- 局部极小要求 Hessian 正定（所有特征值严格正），不是半正定
- 鞍点处梯度为零（临界点），但 Hessian 有正有负特征值
- Wigner 半圆律关于 $\lambda = 0$ 完全对称，故负特征值比例恰好为 $1/2$

本组在练什么：用 Hessian 特征值符号分类临界点；估算高维空间中局部极小的数量级；理解 SGD 噪声为何是鞍点逃逸的必需条件。做完应能回答：为什么大模型训练几乎不会陷入局部极小值？

T-4.3.1 【易·分类·临界点的 Hessian 判据】 设二维函数 $f(x, y)$ 在临界点 $(0, 0)$ 处的 Hessian 分别为：

$$H_1 = \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix}, \quad H_2 = \begin{pmatrix} -1 & 0 \\ 0 & 2 \end{pmatrix}, \quad H_3 = \begin{pmatrix} -2 & 0 \\ 0 & -3 \end{pmatrix}$$

- 对每个 Hessian，判断临界点类型（局部极小、鞍点、局部极大），写出判断依据；
- 以 H_2 为例，指出负曲率方向（负特征值对应的特征向量），解释梯度下降在此方向受到噪声扰动后会发生什么；
- 在 d 维空间中，若 Hessian 的 d 个特征值各自独立地以概率 $1/2$ 为正，纯局部极小的概率为 $(1/2)^d$ ；取 $d = 100$ 估算其数量级（用 $\log_{10}$ 表示）。

解答 T-4.3.1 【易·分类·临界点的 Hessian 判据】

- 用特征值判断：
 - H_1 ：特征值 $\{3, 2\}$ ，全正 $\rightarrow$ 局部极小值（正定 Hessian）
 - H_2 ：特征值 $\{-1, 2\}$ ，有正有负 $\rightarrow$ 鞍点（不定 Hessian）
 - H_3 ：特征值 $\{-2, -3\}$ ，全负 $\rightarrow$ 局部极大值（负定 Hessian）
- H_2 的负特征值 $\lambda = -1$ 对应特征向量 $u = (1, 0)^\top$ （ x 方向）。沿 x 方向，函数在鞍点两侧均下降（负曲率意味着函数值向两侧降低）。梯度下降若在鞍点处受到沿 u 方向的任意小扰动，函数值降低，梯度指向离开鞍点的方向，模型将迅速远离鞍点——这就是鞍点的自然逃逸机制。
- $\Pr = (1/2)^{100}$ ，取 $d = 100$ ：

$$\Pr = 2^{-100} \approx 10^{-30}$$

100 维空间中，随机函数临界点恰为局部极小的概率约 10^{-30} ；在 $d = 10^8$ 时约 $10^{-3 \times 10^7}$ ——天文数字地小。

T-4.3.2 【中·估算·鞍点主导的维度效应】 Dauphin et al. 2014 的结论：在 d 维随机非凸函数中，纯局部极小的概率 $\Pr \propto e^{-\alpha d}$ ($\alpha > 0$)。

- 设 $\alpha = 0.01$ ， $d = 10^8$ ，估算 $\Pr$ 的数量级（用 $\log_{10}$ 表示指数部分）；
- 若希望纯局部极小的概率至少为 1%，问题的维度最多能有多少？（取 $\alpha = 0.01$ ）
- 实验观察表明大模型从不同随机初始化出发，最终性能差异很小。用鞍点主导论断解释这一现象（三句话以内）。

解答 T-4.3.2 【中·估算·鞍点主导的维度效应】

- $\alpha = 0.01$ ， $d = 10^8$ ：

$$\ln \Pr \approx -\alpha d = -10^6, \quad \log_{10} \Pr = -10^6 / \ln 10 \approx -4.34 \times 10^5$$

即 $\Pr \approx 10^{-434000}$ ，远小于任何物理意义上的可观测量。

(b) $e^{-\alpha d} \geq 0.01$ 要求 $\alpha d \leq \ln 100 \approx 4.605$, 即 $d \leq 460.5$ 。

维度不超过约 460, 纯局部极小的概率才能达到 1%。超过此维度, 局部极小就已极为罕见。

(c) 大模型参数维度 $d \sim 10^8 \sim 10^{11}$, 远超 460。SGD 从不同随机初始化出发遇到的障碍几乎全是鞍点 (有负曲率方向可逃逸), 而非不可逃逸的局部极小。不同初始化的优化轨迹虽然不同, 但都趋向于同一连通极小值流形, 因此最终性能差异很小。

T-4.3.3 【难·画图直觉·损失曲面的鞍点、极小点、极大点】 请在草稿区粗略画出下列三幅图, 并回答问题:

- 二维函数 $f(x, y) = x^2 - y^2$ 的等高线草图: 标出原点处的临界点类型; 画出两个梯度为零的主轴方向 (x 方向为正曲率, y 方向为负曲率);
- 在同一坐标系内粗略画出三种临界点的”碗状/马鞍/倒碗”截面示意: 局部极小 (正定 Hessian)、鞍点 (不定 Hessian)、局部极大 (负定 Hessian); 在每种情况下, 用箭头标出梯度方向 (指向上坡);
- 对鞍点 (如 H_2 情形), 假设 SGD 恰好处于鞍点, 纯确定性梯度下降的行为是什么? 一个随机噪声扰动 ξ 加入负曲率方向后, 轨迹如何变化? 用文字描述。

解答 T-4.3.3 【难·画图直觉·损失曲面的鞍点、极小点、极大点】

(a) $f(x, y) = x^2 - y^2$ 的等高线是双曲线 $x^2 - y^2 = c$ (正常数时开口朝 x 轴, 负常数时开口朝 y 轴)。原点 $(0, 0)$ 是鞍点: 沿 x 方向 (正曲率, 函数值增大), 沿 y 方向 (负曲率, 函数值减小)。草图应显示: 原点处等高线不闭合, 而是交叉的双曲线; 沿 x 轴方向等高线变密 (上坡), 沿 y 轴方向等高线变疏 (下坡)。

(b) 三种截面示意:

- 局部极小 (正定 H): 碗状向上, 底部是极小点, 梯度箭头从中心指向四周向上;
- 鞍点 (不定 H): 马鞍形, 在某方向向上弯曲, 另一方向向下弯曲, 中心梯度为零但不是极小;
- 局部极大 (负定 H): 倒碗/山峰状, 顶部是极大点, 梯度箭头从四周指向中心向下。

(关键: 梯度方向指向上坡, 即函数值增大的方向; 梯度下降更新沿梯度反方向行进。)

(c) 确定性梯度下降在鞍点处: 梯度恰好为零, 更新量为零, 模型完全停留在鞍点, 无法自行逃逸 (若初始条件精确在鞍点)。加入噪声 ξ 后: 沿负曲率方向 (y 方向, Hessian 特征值 $\lambda < 0$) 产生微小偏移 δ , 负曲率处的梯度 $\approx \lambda \delta < 0$ (因 $\lambda < 0$, $\delta > 0$ 时梯度为负, 驱动 s 增大), 使模型沿负曲率方向持续加速远离鞍点, 最终完全逃逸。

T-4.3.4 【中·推导·SGD 噪声协方差与鞍点逃逸速率】 在鞍点 θ^* 附近, 设沿负曲率方向 u (Hessian 特征值 $\lambda < 0$) 的坐标为 s , 近似 $L(\theta^* + su) \approx L(\theta^*) + \frac{\lambda}{2}s^2$ 。

(a) 写出带噪声 ξ_t (方差 σ_ξ^2) 的 SGD 更新: $s_{t+1} = s_t - \eta(\lambda s_t + \xi_t)$; 当 $s_t = 0$ 时, s_1 的期望和方差各是多少?

- (b) 代入 $\sigma_\xi^2 \approx \frac{\eta c}{B}$ ，写出逃逸速率（单步方差 $\text{Var}(s_1)$ ）对 η 和 B 的依赖；
- (c) 确定性梯度下降（ $\xi = 0$ ）在鞍点处的行为是什么？解释为什么 SGD 的随机性对高维非凸优化是“必需的”。

解答 T-4.3.4 【中 · 推导 · SGD 噪声协方差与鞍点逃逸速率】

- (a) 带噪声的 SGD 更新（在负曲率方向坐标 s 上）：

$$s_{t+1} = (1 - \eta\lambda)s_t - \eta\xi_t$$

注意 $\lambda < 0$ ，故系数 $(1 - \eta\lambda) > 1$ ——即使没有噪声，负曲率方向的动力学本身就是发散的（不稳定）。当 $s_t = 0$ （恰在鞍点）： $s_1 = -\eta\xi_0$ 。

$$\mathbb{E}[s_1] = 0 \text{ (无偏噪声)}, \quad \text{Var}(s_1) = \eta^2 \sigma_\xi^2$$

- (b) 代入 $\sigma_\xi^2 \approx \frac{\eta c}{B}$ ：

$$\text{Var}(s_1) = \eta^2 \cdot \frac{\eta c}{B} = \frac{\eta^3 c}{B}$$

逃逸速率正比于 η^3/B ：减小 B （更小 batch）或增大 η ，均使初始偏离幅度更大，逃逸更快。

- (c) 确定性梯度下降（ $\xi = 0$ ）在精确鞍点处： $s_1 = 0$ ，完全停滞。由于浮点运算精度有限，极微小的初始偏离会被负曲率指数放大，最终逃逸，但可能需要极多步；在精确算术下，确定性梯度下降可能被鞍点“卡死”极长时间。SGD 的随机性直接提供了 $O(\eta^{3/2}/\sqrt{B})$ 量级的初始扰动，使鞍点逃逸速率从原则上的零变为正值，是高维非凸优化正常工作的必要条件。

工程批注：鞍点逃逸与 batch size 的实践启示：逃逸速率 $\propto \eta^3/B$ ，这解释了为什么极大 batch 训练（ $B \rightarrow$ 全数据集）不仅泛化变差（退化为确定性梯度下降，倾向于尖锐极小值），还会在训练早期被鞍点长时间阻滞，表现为 loss 平台期。实践中 LLM 训练使用的 global batch size（如 4M tokens）并非越大越好，而是在“梯度估计足够准确”与“保留足够噪声以逃逸鞍点”之间的工程权衡。

§ 4.4 习题：损失景观的可视化

导读：本节核心是「损失景观的几何决定泛化能力」——filter-wise 归一化消除尺度干扰、Hessian 最大特征值量化平坦度、大小 batch 分别对应尖锐/平坦极小值、skip connection 使景观更平滑、SAM 优化器显式搜索平坦区域。五题分别对应：A（归一化推导）、B（泛化上界计算）、C（批量大小辨析）、D（skip connection 机制分析）、E（SAM 优化评判）。

题 1【轻 · 轻推导 · 归一化为何不可缺】 导读：可视化损失景观时，随机方向向量若不归一化，两条方向射线的「步长」在不同层间会因权重矩阵范数量级的巨大差异而失去可比性，最终扭曲等高线图。

设网络第 l 层第 k 个 filter 的权重为 $W^{(l,k)} \in \mathbb{R}^{c_{in} \times k_h \times k_w}$ ，filter-wise 归一化将随机方向向量 $d^{(l,k)}$ 缩放为

$$\tilde{d}^{(l,k)} = d^{(l,k)} \cdot \frac{\|W^{(l,k)}\|_F}{\|d^{(l,k)}\|_F}$$

(1) 证明归一化后 $\|\tilde{d}^{(l,k)}\|_F = \|W^{(l,k)}\|_F$ 。

(2) 设某层有两个 filter， $\|W^{(l,1)}\|_F = 0.1$ ， $\|W^{(l,2)}\|_F = 10$ ，随机向量未归一化时设 $\|d^{(l,1)}\|_F = \|d^{(l,2)}\|_F = 1$ 。若将景观可视化步长 α 统一取 1，两个 filter 对应的实际参数扰动幅度分别是 $\alpha/\|W^{(l,1)}\|_F$ 和 $\alpha/\|W^{(l,2)}\|_F$ 的倍数关系是多少？归一化后这一比例变为多少？

教学注：filter-wise 是粒度选择的折中——过粗 (layer-wise) 遗漏层内结构差异，过细 (element-wise) 引入额外统计噪声。

陷阱：归一化后方向向量 $\tilde{d}^{(l,k)}$ 不再相互正交，但可视化所需的仅是「单步扰动幅度可比」，正交性不是必要条件。

题 2【中 · 中计算 · 泛化上界与平坦度】 导读：Keskar 等人 (2016) 建立了极小值处 Hessian 最大特征值 $\lambda_{\max}$ 与泛化间隙之间的定量联系，使「尖锐极小值泛化差」从直觉变为可量化命题。

设泛化上界为

$$R(\theta) \leq \hat{R}(\theta) + C \sqrt{\frac{\lambda_{\max} \cdot n}{N}}$$

其中 C 为数值常数， n 为模型参数量， N 为训练样本数。考虑以下两个场景：

- **模型 A** (大 batch 训练)： $\lambda_{\max}^A = 800$ ， $n = 10^7$ ， $N = 10^6$
- **模型 B** (小 batch 训练)： $\lambda_{\max}^B = 50$ ， $n = 10^7$ ， $N = 10^6$

- (1) 计算两个模型泛化上界中的根号项 (精确到四位小数)。
- (2) 假设两个模型训练损失相同 $\hat{R} = 0.1$ ， $C = 0.01$ ，计算各自泛化上界的数值。
- (3) 解释为什么大 batch 倾向于收敛到 $\lambda_{\max}$ 较大的极小值，从梯度噪声的角度给出直观论证。

教学注：此上界是 PAC-Bayes 框架的一个推论， $\lambda_{\max}$ 刻画了损失曲面在极小值处的「曲率」，曲率越大意味着参数对扰动越敏感，泛化风险越高。

陷阱： $\lambda_{\max}$ 只是充分统计量的一个代理，实践中全谱信息 (如迹 $\text{tr}(H)$) 对泛化的预测力有时更强。不要将此上界解读为泛化误差的精确估计。

题3【中·概念辨析·批量大小与景观几何】 导读：批量大小是现代深度学习中最具争议的超参数之一；理解其与景观几何的关系，需要区分「优化轨迹」与「收敛目标」两个层次。

判断以下四条陈述，逐一说明正确/错误及原因：

- (a) 大 batch 梯度方差小，因此估计更准确，应总能找到更好的极小值。
- (b) 小 batch 引入的随机性使优化器能够「跳出」尖锐极小值盆地，倾向于停在 $\lambda_{\max}$ 较小的平坦极小值。
- (c) 对同一损失景观，大 batch 和小 batch 最终收敛到的极小值集合完全相同，只是收敛速度不同。
- (d) 线性缩放规则（将 batch 增大 k 倍同时将学习率增大 k 倍）能在任意训练阶段保持等效性。

教学注：(b) 对应 Chaudhari & Soatto (2018) 的熵 SGD 分析——小 batch 的随机性等效于一个隐式的景观平滑化过程，使优化器偏好高熵（平坦）区域。

陷阱：(d) 的线性缩放规则在训练初期（loss 下降剧烈阶段）和 warmup 期间容易失效，不能机械套用。

题4【中·中计算·Skip Connection 的平滑效应】 导读：Li 等人 (2018) 用 filter-wise 归一化直观展示了 skip connection 对损失景观的平滑作用，但其数学根源可以追溯到梯度传播的谱性质。

设 L 层残差网络的前向传播为 $h_l = h_{l-1} + F_l(h_{l-1})$ ，其中 F_l 表示第 l 层的残差函数。

- (1) 写出损失 $\mathcal{L}$ 对 h_0 的梯度（用 Jacobian 矩阵乘积形式表示），展示 skip connection 如何在反向传播中引入恒等通路。
- (2) 设每个残差块的 Jacobian 谱半径为 $\rho(J_{F_l}) = r < 1$ （残差部分收缩）。证明 L 层残差网络的梯度范数有下界 $\|\partial\mathcal{L}/\partial h_0\| \geq (1-r)^L \|\partial\mathcal{L}/\partial h_L\|$ ，并说明这如何防止梯度消失。
- (3) 定性解释为什么 skip connection 使 Hessian 最大特征值 $\lambda_{\max}$ 更小，景观更平坦。（2-3 句即可）

教学注：skip connection 的本质是「恒等映射提供梯度高速公路」，使信息在前向和后向均能以 $O(1)$ 的衰减穿越深网络，这正是 ResNet 击败 VGG 的核心数学原因。

陷阱：(2) 的下界只在 $\|J_{F_l}\|$ 的谱半径而非算子范数意义下成立，两者在高维下可相差悬殊。

题5【重·重评判·SAM 的代价与收益】 导读：Sharpness-Aware Minimization (SAM) 通过显式优化「最坏邻域内的损失」来搜索平坦极小值，是将景观几何分析转化为可运行算法的代表性工作，但其代价常被忽视。

SAM 求解的问题为

$$\min_{\theta} \max_{\|\epsilon\|_2 \leq \rho} \mathcal{L}(\theta + \epsilon)$$

- (1) 证明内层最大化问题的最优解为 $\epsilon^* = \rho \cdot \nabla_{\theta} \mathcal{L}(\theta) / \|\nabla_{\theta} \mathcal{L}(\theta)\|_2$ (在一阶线性近似下)。
- (2) SAM 的每步更新需要两次前向-反向传播。与标准 SGD 相比, 设每次前后向计算耗时 T , 若训练 S 步, SAM 的总计算量是 SGD 的多少倍?
- (3) 判断以下论断并给出理由:

「SAM 找到的极小值满足 $\lambda_{\max}$ 更小, 因此其泛化误差必然低于 SGD 训练的同等模型。」

指出该论断的两处不严谨之处。

- (4) **拓展:** 在资源受限 (只能训练标准 SGD 的一半步数) 的情况下, 是否应将 SAM 替换为多训练一倍步数的 SGD? 从景观平坦度的角度讨论。

教学注: SAM 的正则化效果在理论上等价于向损失函数加入一个关于梯度范数的惩罚项, 这与权重衰减 (weight decay) 有微妙的互补关系。

陷阱: (1) 的 ℓ_2 约束下结论干净, 但实践中 SAM 也有 ℓ_{∞} 变体, 最优解形式截然不同。(3) 中「必然」是关键词——泛化上界只是上界, 不是精确等式。

解答 § 4.4

T-4.4.1 【归一化为何不可缺】 (1) 证明:

$$\|\tilde{d}^{(l,k)}\|_F = \left\| d^{(l,k)} \cdot \frac{\|W^{(l,k)}\|_F}{\|d^{(l,k)}\|_F} \right\|_F = \|d^{(l,k)}\|_F \cdot \frac{\|W^{(l,k)}\|_F}{\|d^{(l,k)}\|_F} = \|W^{(l,k)}\|_F \quad \blacksquare$$

(2) 数值分析:

未归一化时, $\|d^{(l,1)}\|_F = \|d^{(l,2)}\|_F = 1$, 步长 $\alpha = 1$ 时: - filter 1 的扰动为参数范数的 $1/0.1 = 10$ 倍 - filter 2 的扰动为参数范数的 $1/10 = 0.1$ 倍 - 比例 = $10/0.1 = 100$ 倍

归一化后: $\|\tilde{d}^{(l,1)}\|_F = 0.1$, $\|\tilde{d}^{(l,2)}\|_F = 10$, 步长 $\alpha = 1$ 时, 两个 filter 的扰动均恰好等于各自的参数范数, 比例 = 1。

Sanity check: 归一化消除了「量纲不一致」, 使不同层、不同 filter 的等高线可以在同一坐标系下公平比较。

T-4.4.2 【泛化上界与平坦度】 (1) 根号项计算:

$$\sqrt{\frac{\lambda_{\max}^A \cdot n}{N}} = \sqrt{\frac{800 \times 10^7}{10^6}} = \sqrt{8000} \approx 89.4427$$

$$\sqrt{\frac{\lambda_{\max}^B \cdot n}{N}} = \sqrt{\frac{50 \times 10^7}{10^6}} = \sqrt{500} \approx 22.3607$$

(2) 泛化上界 ($C = 0.01$, $\hat{R} = 0.1$):

- 模型 A: $0.1 + 0.01 \times 89.4427 = 0.1 + 0.8944 = 0.9944$
- 模型 B: $0.1 + 0.01 \times 22.3607 = 0.1 + 0.2236 = 0.3236$

(3) **大 batch 与尖锐极小值**: 大 batch 梯度估计方差小, 优化轨迹光滑, 缺乏足够的随机扰动来「翻越」分隔尖锐极小值与平坦极小值之间的能量势垒; 小 batch 的随机噪声充当了隐式的「热浴」, 使优化器能够逃离曲率高的区域并停留在更宽广的盆地中。

Sanity check: 两个模型 $\lambda_{\max}$ 相差 16 倍, 泛化上界差约 3 倍, 体现了景观曲率的平方根效应。

T-4.4.3 【批量大小与景观几何】 (a) **错误**。梯度估计准确度与极小值质量是两回事。大 batch 精确梯度会将优化器「锁定」在最近的尖锐极小值而无法逃脱; 「更准确」并不意味着「更好的收敛目标」。

(b) **正确**。小 batch 梯度噪声的协方差矩阵与 Hessian 成正比 (Fisher 信息视角), 等效于对景观施加各向异性扰动, 天然偏好熵较高 (宽广) 的极小值盆地。

(c) **错误**。大量实验 (Keskar et al., 2017) 和理论分析 (Chaudhari & Soatto, 2018) 表明, 批量大小不同的 SGD 最终收敛到不同的极小值子集, 而非相同集合。

(d) **部分错误**。线性缩放规则在训练中期 (梯度分布近似平稳) 时成立, 但在 warmup 阶段和训练末期 loss 剧烈振荡时失效; Goyal 等人 (2017) 的工作特别指出需要 warmup 过渡。

T-4.4.4 【Skip Connection 的平滑效应】 (1) 梯度表达式:

$$\frac{\partial \mathcal{L}}{\partial h_0} = \frac{\partial \mathcal{L}}{\partial h_L} \cdot \prod_{l=1}^L \frac{\partial h_l}{\partial h_{l-1}} = \frac{\partial \mathcal{L}}{\partial h_L} \cdot \prod_{l=1}^L (I + J_{F_l})$$

其中 $J_{F_l} = \partial F_l / \partial h_{l-1}$ 。展开乘积时, 恒等矩阵 I 提供了一条不经过任何残差块 Jacobian 的直接通路。

(2) 梯度范数下界:

$$\left\| \frac{\partial \mathcal{L}}{\partial h_0} \right\| = \left\| \frac{\partial \mathcal{L}}{\partial h_L} \right\| \cdot \left\| \prod_{l=1}^L (I + J_{F_l}) \right\|$$

由于 $\|I + J_{F_l}\| \geq \|I\| - \|J_{F_l}\| \geq 1 - r$ (三角不等式), 故

$$\left\| \frac{\partial \mathcal{L}}{\partial h_0} \right\| \geq (1 - r)^L \left\| \frac{\partial \mathcal{L}}{\partial h_L} \right\|$$

当 $r < 1$ 时, 下界 $(1 - r)^L > 0$, 梯度不会指数衰减至零, 防止了梯度消失。■

(3) 对 $\lambda_{\max}$ 的影响: skip connection 使 Hessian 中出现大量来自恒等通路的「平坦贡献」, 稀释了残差分支引入的高曲率方向; 同时, 恒等映射使各层激活在相近尺度, 避免了因激活值爆炸/消失而产生的病态曲率集中现象, 整体上压低了 $\lambda_{\max}$ 。

Sanity check: Li et al. (2018) 的可视化图表中, 56 层 ResNet 的损失景观明显比 56 层 VGG 平坦, 与上述分析一致。

T-4.4.5 【SAM 的代价与收益】 (1) 内层最大化的最优解:

在一阶线性近似下, $\mathcal{L}(\theta + \epsilon) \approx \mathcal{L}(\theta) + \nabla_{\theta} \mathcal{L}(\theta)^{\top} \epsilon$ 。

约束 $\|\epsilon\|_2 \leq \rho$ 下, 最大化线性函数的最优解由 Cauchy-Schwarz 不等式决定: 当 ϵ 与梯度同向且达到约束边界时取最大值:

$$\epsilon^* = \rho \cdot \frac{\nabla_{\theta} \mathcal{L}(\theta)}{\|\nabla_{\theta} \mathcal{L}(\theta)\|_2} \quad \blacksquare$$

(2) 计算量对比:

SAM 每步需两次前后向传播 (第一次求 ϵ^* , 第二次在 $\theta + \epsilon^*$ 处求梯度), 耗时 $2T$; SGD 每步耗时 T 。训练 S 步时, SAM 总耗时 $2ST$, SGD 为 ST , SAM 是 SGD 的 2 倍。

(3) 论断的两处不严谨:

- **不严谨之处一:** 泛化上界中的 $\sqrt{\lambda_{\max} \cdot n/N}$ 只是上界, 不是等式。SAM 找到 $\lambda_{\max}$ 更小的极小值只意味着上界更紧, 不能保证实际泛化误差更低。
- **不严谨之处二:** 「同等模型」的假设忽略了训练轮次的差异——SAM 若因计算翻倍而只能训练一半步数, 优化本身未收敛时, $\lambda_{\max}$ 小也无法弥补训练不足的缺陷。

(4) **拓展讨论:** 在资源受限场景下, 若训练步数减半, SAM 的景观平坦化效益可能被优化不充分所抵消。实践经验表明, 当任务对泛化高度敏感 (如小数据集微调) 时, SAM 的优势更显著; 当任务在充足数据下早已收敛时, 多训练一倍步数的 SGD 可能更优。因此结论取决于数据量与任务性质, 无普适答案。

Sanity check: (1) 的推导与梯度投影算子的标准结论一致; (2) 的 2 倍计算量是 SAM 论文中明确指出的实践代价。

本节景观几何的定量工具将在 § 4.7 中发展为宽度缩放规律——平坦度指标 $\lambda_{\max}$ 的控制问题将推广为对激活动力学在不同网络宽度下行为的系统分析。

§ 4.5 μP 超参数迁移

μP (Maximal Update Parametrization, 最大更新参数化) 通过精心设计初始化方差和学习率随宽度的缩放规则, 保证各层激活更新量在宽度极限下保持 $O(1)$, 使超参数在不同宽度间可迁移。本节覆盖 SP 发散推导、 μP 缩放表、abc 参数化约束 $a + b = 1$ 、三种参数化对比四个核心结论。

小节导读: μP 不是“一个调参技巧”, 是从“宽度无穷大极限”这个数学问题倒推出

来的工程结论。第一步，标准参数化（SP）在宽度极限下发散——每层激活更新量 $\Delta h^{(l)} \sim \eta\sqrt{n}$ 随宽度 n 发散。第二步， μP 的核心要求是“宽度极限下 $\Delta h^{(l)} = O(1)$ ”。第三步，abc 参数化与约束 $a + b = 1$ （SGD 情形）。第四步， μP 的工程价值——把超参数搜索限于小模型，单次能省百万美元的训练成本。第五步， μP 是一个新坐标系，后续的 nGPT、Spectral-condition Norm 都在这个方向继续。

公式 8 · SP 激活变化发散与 μP 缩放规则

$$\Delta h^{(l)} \sim O(\eta\sqrt{n}) \quad (\text{SP 下随宽度发散})$$

层类型	初始化方差 σ^2	Adam 学习率
输入嵌入 $V \rightarrow n$	$O(1)$	$O(1)$
隐藏 $n \rightarrow n$	$O(1/n)$	$O(1)$
输出 $n \rightarrow V$	$O(1/n^2)$	$O(1/n)$

SP 下，隐藏层激活变化随宽度 $\sqrt{n}$ 发散，最优学习率必须随宽度衰减，超参数不可迁移。 μP 下，Adam 的二阶矩归一化吸收了梯度的宽度依赖，隐藏层学习率保持 $O(1)$ ，超参数可直接迁移。

一句话直觉： μP 的唯一目标是让激活更新量 $\Delta h = O(1)$ ；满足这个条件的参数化，超参数就可以在小模型上调好后迁移到大模型。

在大模型里的位置：训练

本组训练目标：代入·推导·工程

常见卡点：

- SP 与 μP 在隐藏层初始化上相同（均为 $O(1/n)$ ），差异在学习率缩放
- Adam 下隐藏层学习率不随宽度缩放，是因为二阶矩 $\hat{v}_t \sim O(1/n)$ 使 $\hat{m}/\sqrt{\hat{v}} \sim O(1)$ ，自动消除宽度依赖
- 输出层 Adam 学习率需要 $O(1/n)$ 衰减，是因为输出层参数尺度更小（ $O(1/n^2)$ 初始化）

本组在练什么：追踪 SP 下 Δh 发散的推导链，验证 μP 下 Adam 的归一化如何消除宽度依赖。做完应能回答：为什么 $\mu P + \text{Adam}$ 的隐藏层学习率不需要随宽度缩放？

T-4.5.1 【易·代入·SP 激活变化的发散量级】 设标准参数化（SP），隐藏层宽度分别为 $n = 64, 256, 1024, 4096$ ，学习率固定 $\eta = 0.01$ 。

- 按 SP 推导，激活变化 $\Delta h \sim O(\eta\sqrt{n})$ ，分别计算四种宽度下 $\eta\sqrt{n}$ 的数值；
- 从 $n = 64$ 到 $n = 4096$ ， Δh 增大了几倍？
- 若希望在 $n = 4096$ 时 Δh 与 $n = 64$ 时相同，需将学习率调整为多少？这说明了什么？

解答 T-4.5.1 【易·代入·SP 激活变化的发散量级】

(a) $\Delta h \sim \eta\sqrt{n}$ 的数值:

n	$\sqrt{n}$	$\eta\sqrt{n}$
64	8	0.08
256	16	0.16
1024	32	0.32
4096	64	0.64

(b) 从 $n = 64$ 到 $n = 4096$: $0.64/0.08 = 8$ 倍 (即 $\sqrt{4096/64} = \sqrt{64} = 8$)。

(c) 要使 $\eta'\sqrt{4096} = 0.01 \times \sqrt{64} = 0.08$:

$$\eta' = 0.08/64 = 0.00125 = 1.25 \times 10^{-3}$$

学习率从 0.01 缩小到 0.00125, 缩小了 8 倍。这说明在 SP 下, 宽度每扩大 64 倍, 最优学习率需缩小 8 倍 ($\sqrt{64}$ 关系), 超参数无法直接迁移。

T-4.5.2 【中 · 推导 · SP 激活发散的完整推导链】 从 SP 的激活更新链出发 (权重 $W \in \mathbb{R}^{n \times n}$, $W_{ij} \sim \mathcal{N}(0, 1/n)$, 学习率 η , SGD):

- (a) 前向激活 $h_j^{(l)} = \sum_k W_{jk} h_k^{(l-1)}$, 逐步计算其方差 (n 项求和, 每项方差 $1/n \times O(1)$);
- (b) 反向梯度尺度 (标准差) 为 $O(1/\sqrt{n})$ (说明理由);
- (c) 参数更新尺度 $\Delta W \sim O(\eta/\sqrt{n})$;
- (d) 激活变化 $\Delta h = \Delta W \cdot h^{(l-1)}$ 经 n 项求和后尺度为 $O(\eta\sqrt{n})$ (发散) ——说明推导步骤, 解释为什么这使 SP 超参数不可迁移。

解答 T-4.5.2 【中 · 推导 · SP 激活发散的完整推导链】

- (a) 前向激活方差: $\text{Var}(h_j^{(l)}) = \sum_k \text{Var}(W_{jk}) \times \text{Var}(h_k^{(l-1)}) = n \times (1/n) \times O(1) = O(1)$ (这正是 He 初始化的设计目的)。
- (b) 反向梯度: $g_j^{(l)} = \sum_k W_{kj} g_k^{(l+1)}$, 每项方差 $(1/n) \times O(1)$, n 项求和: $\text{Var}(g_j^{(l)}) = n \times (1/n) \times O(1) = O(1)$, 但分量尺度 (标准差) 为 $O(1/\sqrt{n})$ ——注: 原书 §4.5 中梯度尺度指分量标准差, 约为 $O(1/\sqrt{n})$ 。
- (c) 参数更新 (SGD): $\Delta W_{jk} = -\eta g_j^{(l+1)} h_k^{(l-1)}$, 尺度 $\sim \eta \times O(1/\sqrt{n}) \times O(1) = O(\eta/\sqrt{n})$ 。
- (d) 激活变化 $\Delta h_j^{(l)} = \sum_k \Delta W_{jk} h_k^{(l-1)}$, n 项求和, 每项标准差 $O(\eta/\sqrt{n}) \times O(1)$:

$$\text{std}(\Delta h_j^{(l)}) \sim \sqrt{n} \times O(\eta/\sqrt{n}) = O(\eta\sqrt{n})$$

随宽度发散。这使 SP 超参数不可迁移的根本原因: 在 $n = 256$ 上使 $\Delta h = O(1)$ 的学习率 η_0 , 移到 $n = 4096$ 时 $\Delta h \sim \eta_0 \sqrt{4096/256} = 4\eta_0$, 激活更新量放大了 4 倍, 训练动力学完全改变, 必须重新调参。

T-4.5.3【难·工程· μ P 下 Adam 归一化消除宽度依赖】 μ P 规则：隐藏层初始化 $W_{ij} \sim \mathcal{N}(0, 1/n)$ （同 SP），Adam 学习率 $\eta = O(1)$ （不随宽度缩放）。

- 若梯度 $g \sim O(1/\sqrt{n})$ ，Adam 的二阶矩估计 $\hat{v}_t \approx \mathbb{E}[g^2]$ 的量级是多少？ $\sqrt{\hat{v}_t}$ 呢？
- Adam 的有效更新步长 $\hat{m}_t/\sqrt{\hat{v}_t}$ 的量级（用 $O(\cdot)$ 表示），说明它如何与宽度 n 的依赖无关；
- 逐步推导 μ P + Adam 下的激活变化：有效参数更新 $\Delta W \sim O(\eta/\sqrt{n})$ （因参数方差 $1/n$ ），激活变化 $\Delta h \sim O(\eta)$ ——完整写出这条推导链；
- 与 SP + SGD（需 $\eta \sim O(1/\sqrt{n})$ 才能使 $\Delta h = O(1)$ ）对比，说明为什么 μ P + Adam 的超参数可以直接迁移。

解答 T-4.5.3【难·工程· μ P 下 Adam 归一化消除宽度依赖】

- 若梯度 $g \sim O(1/\sqrt{n})$ ，则 $\hat{v}_t \approx \mathbb{E}[g^2] \sim O(1/n)$ ， $\sqrt{\hat{v}_t} \sim O(1/\sqrt{n})$ 。
- Adam 的有效更新步长：

$$\frac{\hat{m}_t}{\sqrt{\hat{v}_t}} \sim \frac{O(1/\sqrt{n})}{O(1/\sqrt{n})} = O(1)$$

二阶矩归一化自动消除了梯度对宽度 $\sqrt{n}$ 的依赖——分子分母的 $1/\sqrt{n}$ 因子恰好约分，有效步长与宽度无关。这是 Adam 在 μ P 下不需要调整学习率的数学原因。

(c) μ P + Adam 下的激活变化推导链：

- Adam 有效更新步长 $\hat{m}/\sqrt{\hat{v}} \sim O(1)$ （与 n 无关），乘以学习率 $\eta = O(1)$ ：实际参数更新量 $\Delta W_{jk}^{(\text{eff})} \sim O(\eta) = O(1)$
- 注意参数本身的量级：初始化 $W_{jk} \sim \mathcal{N}(0, 1/n)$ ，参数尺度 $O(1/\sqrt{n})$ ，故参数更新的分量 $\Delta W_{jk} \sim O(\eta) \times (1/\sqrt{n}) = O(\eta/\sqrt{n})$ （Adam 更新步长是相对量级，乘以参数初始化尺度才是绝对参数变化）
- 激活变化 $\Delta h_j^{(l)} = \sum_k \Delta W_{jk} h_k^{(l-1)}$ ， n 项求和：

$$\text{std}(\Delta h_j^{(l)}) \sim \sqrt{n} \times O(\eta/\sqrt{n}) = O(\eta)$$

取 $\eta = O(1)$ ，得 $\Delta h = O(1)$ 。

- SP + SGD 若要 $\Delta h = O(1)$ 需令 $\eta \sim O(1/\sqrt{n})$ （随宽度衰减），超参数不可迁移； μ P + Adam 的学习率 $\eta = O(1)$ 对隐藏层无需随宽度调整，超参数可直接从小模型迁移到大模型——这是 μ P + Adam 组合在 LLM 训练中的核心优势。

工程批注： μ P 的工程实现——Cerebras、Tensor μ P 与超参数迁移的实际 workflow：Microsoft 在 Tensor Programs V 发布后，Cerebras（硬件公司）率先在实际 LLM 预训练中验证了 μ P 的迁移效果。实用 workflow 为：(1) 在宽度 $n_0 = 256 \sim 512$ 的代理模型上做充分的超参数网格搜索（包括学习率、warmup 步数、权重衰减），搜索成本约为全尺寸模型训练的 $1/100$ ；(2) 将学习率按 μ P 缩放表迁移到目标宽度（隐藏层 $O(1)$ ，输出层 $O(1/n)$ ），其余超参数直接沿用。Microsoft 的 Tensor μ P（2023）进一步将迁移范围扩展到深度和序列长度，使超参数在更大范围内稳定。值得注意： μ P 的“超参数不变”指的是最优超参

数在宽度极限下的极值，不意味着小模型的数值精确等于大模型的最优值，但误差通常很小。

公式 9 · abc 参数化与三种极限的对比

$$W = n^{-a}\tilde{W}, \quad \tilde{W}_{ij} \sim \mathcal{N}(0, 1), \quad \eta = n^{-b}\tilde{\eta}$$

$a + b = 1$ (隐藏层, SGD, 特征学习极限的必要条件)

$$\text{NTK: } \Delta h = O(1/n) \quad \text{SP: } \Delta h = O(\sqrt{n}) \quad \mu\text{P: } \Delta h = O(1)$$

Yang & Hu 证明：要使激活更新量在宽度极限下保持 $O(1)$ (特征学习极限)，abc 参数化的三参数必须满足 $a + b = 1$ 。只有 μP 满足这一约束；NTK 下 $\Delta h \rightarrow 0$ (懒学习)，SP 下 $\Delta h \rightarrow \infty$ (发散)。

一句话直觉： $a + b = 1$ 是”特征在训练中既不消失也不爆炸”的代数约束， μP 是满足它的唯一参数化族。

在大模型里的位置：训练

本组训练目标：推导 · 代入 · 变形

常见卡点：

- abc 参数化中 a 控制初始化， b 控制学习率，二者都影响 Δh 的宽度依赖
- NTK 参数化中 $a + b < 1$ (SGD)，故 $\Delta h \rightarrow 0$ ，网络退化为固定核方法
- Adam 下的等效约束变为 $a + b_{\text{eff}} = 1$ ，因为 Adam 的归一化相当于令 $b_{\text{eff}} = b + 1/2$

本组在练什么：从 abc 参数化推导约束方程，对比三种参数化的激活更新量。做完应能回答： $a + b = 1$ 来自哪两个稳定性条件？NTK 为什么退化为懒学习？

T-4.5.4 【中 · 代入 · 三种参数化的激活更新量对比】 设 $n = 1024$ ，学习率 $\eta = 0.01$ (SGD)。

- SP ($a = 1/2, b = 0$, SGD) 下， Δh 的数量级 (代入 $\eta\sqrt{n}$)；
- NTK ($a = 1/2, b = 0$, 特殊缩放使 $\Delta h \sim 1/n$) 下， Δh 的数量级 (代入 $1/n$)；
- μP (Adam, $\Delta h \sim O(\eta) = O(1)$) 下， Δh 的数量级；
- 比较三者，用一句话解释为什么 NTK 参数化下的网络”没有在真正学习特征”。

解答 T-4.5.4 【中 · 代入 · 三种参数化的激活更新量对比】

- SP ($\Delta h \sim \eta\sqrt{n}$): $0.01 \times \sqrt{1024} = 0.01 \times 32 = 0.32$
- NTK ($\Delta h \sim 1/n$): $1/1024 \approx 9.77 \times 10^{-4}$ (趋近于 0)
- μP ($\Delta h \sim O(\eta) = O(0.01)$): 约 0.01 (与宽度无关)

- (d) NTK 下 $\Delta h \sim 1/n \rightarrow 0$ (宽度极限趋零), 特征 (激活) 在训练中几乎不变, 网络只能学习初始随机特征的线性组合, 无法提取任务相关的新特征——退化为固定核的”懒学习”, 训练上等效于核方法。

T-4.5.5 【难 · 推导 · abc 参数化约束方程 $a + b = 1$ 】 设 abc 参数化: 隐藏层权重 $W = n^{-a}\tilde{W}$ ($\tilde{W}_{ij} \sim \mathcal{N}(0, 1)$), SGD 学习率 $\eta = n^{-b}\tilde{\eta}$ 。

- (a) 前向激活 $h = Wh^{(0)}$ ($h^{(0)} \in \mathbb{R}^n$ 方差 $O(1)$) 的方差, 用 a, n 表示;
 (b) 反向梯度 $g \sim O(n^{-1/2})$ (典型尺度); 参数更新 $\Delta W = -\eta g^\top h^{(0)}$ 的尺度, 用 a, b, n 表示;
 (c) 激活变化 $\Delta h = \Delta W \cdot h^{(0)}$ 经 n 项求和后的尺度 (用 a, b, n 表示);
 (d) 令 $\Delta h = O(1)$, 推导约束方程; 验证 SP ($a = 1/2, b = 0$) 违反约束, μP (Adam 等效 $a = 1, b_{\text{eff}} = 0$, 令 b_{eff} 包含归一化因子 $1/2$, 即 $a + b_{\text{eff}} = 1$) 满足约束。

解答 T-4.5.5 【难 · 推导 · abc 参数化约束方程 $a + b = 1$ 】

- (a) 前向激活方差: $h_j = \sum_k (n^{-a}\tilde{W}_{jk})h_k^{(0)}$:

$$\text{Var}(h_j) = n \times n^{-2a} \times O(1) = O(n^{1-2a})$$

要使激活方差为 $O(1)$: 需 $1 - 2a = 0$, 即 $a = 1/2$ (对应 He 初始化 $W \sim \mathcal{N}(0, 1/n)$)。 μP 取 $a = 1$ 对应输出层; 隐藏层 μP 仍取 $a = 1/2$ 对应初始化 $\mathcal{N}(0, 1/n)$, 但在 abc 框架中通过 Adam 的归一化等效满足约束。

- (b) 梯度 $g \sim O(n^{-1/2})$ (典型反传尺度); 参数更新 (SGD):

$$\Delta W = -\eta g h^{(0)}, \quad \Delta(n^{-a}\tilde{W}) \sim -n^{-b}\tilde{\eta} \cdot O(n^{-1/2}) \cdot O(1) = O(n^{-a-b-1/2})$$

(实际上 $\Delta W_{jk} = \eta \times [\text{梯度}]$, 梯度的 W 的分量尺度 $\sim O(n^{-1/2})$, 乘以学习率 n^{-b} , 加上初始化因子 n^{-a} 的尺度修正)

- (c) 激活变化 $\Delta h_j = \sum_k \Delta W_{jk} h_k^{(0)}$, n 项求和 (每项独立, 标准差 $O(n^{-a-b-1/2})$):

$$\text{std}(\Delta h_j) \sim \sqrt{n} \times O(n^{-a-b-1/2}) = O(n^{1/2-a-b-1/2}) = O(n^{1-a-b})$$

- (d) 令 $\Delta h = O(1)$: $n^{1-a-b} = O(1)$, 即 $1 - a - b = 0$, 得 $a + b = 1$ 。

- SP (SGD): $a = 1/2, b = 0, a + b = 1/2 \neq 1$, 违反约束; $\Delta h \sim O(n^{1/2})$, 发散。
- μP (Adam): Adam 的二阶矩归一化等效于梯度尺度变为 $O(1)$ 而非 $O(n^{-1/2})$, 等效将 b 增大了 $1/2$, 取 $a = 1/2, b_{\text{eff}} = 1/2$ 时 $a + b_{\text{eff}} = 1$ ——满足约束。Adam 吸收了梯度的 n 依赖, 使有效约束满足特征学习极限。

T-4.5.6 【中 · 应用 · μP 超参数迁移的实际操作】 在宽度 $n_0 = 256$ 的小模型上, 使用 $\mu P + \text{Adam}$ 调得最优超参数: 隐藏层学习率 $\eta_{\text{hid}} = 0.003$, 输出层学习率 $\eta_{\text{out}} = 0.001$, 输入嵌入层学习率 $\eta_{\text{emb}} = 0.003$ 。

- (a) 按 μP 规则, 将宽度扩展到 $n = 4096$ 时, 隐藏层学习率应设置为多少?

- (b) 输出层学习率呢？（输出层 Adam 学习率缩放为 $O(1/n)$ ）
- (c) 输入嵌入层学习率呢？（输入层缩放为 $O(1)$ ）
- (d) μP 迁移的核心承诺是什么？在实际 LLM 预训练中能节省什么资源？（一句话总结）

解答 T-4.5.6 【中 · 应用 · μP 超参数迁移的实际操作】

- (a) μP 下隐藏层 Adam 学习率缩放为 $O(1)$ ，不随宽度变化： $\eta'_{\text{hid}} = 0.003$ （直接迁移）。
- (b) 输出层 Adam 学习率缩放为 $O(1/n)$ ：

$$\eta'_{\text{out}} = 0.001 \times \frac{256}{4096} = 0.001 \times \frac{1}{16} = 6.25 \times 10^{-5}$$

- (c) 输入嵌入层缩放为 $O(1)$ ： $\eta'_{\text{emb}} = 0.003$ （不变）。
- (d) μP 的核心承诺：在小代理模型（宽度 256 级别）上调好的最优超参数，可按 μP 缩放表直接迁移到任意宽度的大模型，无需在大模型上重新进行昂贵的超参数搜索。实际 LLM 预训练中，这能将超参数搜索的算力成本从大模型训练的全程降至约 1/100（小代理模型训练一次）。

§ 4.6 Lion 与 Shampoo（选做）

Adam 统治 LLM 训练近十年，近年出现两条重要挑战路线。Lion 只用梯度符号，内存减半；Shampoo 用 Kronecker 分解把二阶优化带回大规模训练。本节为选做内容。

小节导读：Lion 和 Shampoo 走两条相反路线：Lion 把 Adam 削到只剩“符号”，Shampoo 把二阶曲率塞回训练。第一步，Adam 的“贵”在哪——维护一阶矩 m 和二阶矩 v ，7B 模型上 optimizer state 约 56 GB。第二步，Lion 的极简主义——只保留动量 m 、只取符号，内存降到 2 倍参数。第三步，Lion 为什么能 work——sign 等价于把 η 自动放大到方向上限，抗梯度爆炸天然。第四步，Shampoo 走反方向——给每个权重矩阵 $W \in \mathbb{R}^{m \times n}$ 维护两个预条件子 $L \in \mathbb{R}^{m \times m}$ ， $R \in \mathbb{R}^{n \times n}$ 。第五步，Kronecker 分解为什么是关键——把 $(mn)^2$ 存储降到 $m^2 + n^2$ 。

公式 10 · Lion 更新规则

$$c_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

$$\theta_{t+1} = \theta_t - \eta \text{sign}(c_t) - \eta \lambda \theta_t$$

$$m_t = \beta_2 m_{t-1} + (1 - \beta_2) g_t$$

Lion 每步只做 $\pm\eta$ 的固定步长更新，完全丢弃梯度幅值信息；只需维护一份动量 m_t ，内存比 Adam 省约一半。

一句话直觉：梯度的符号是更稳健的方向信号；用符号代替幅值，让每个参数每步走等步长，内存减半。

在大模型里的位置：训练

本组训练目标：代入 · 工程 · 对比

常见卡点：

- Lion 的 c_t 用于决定方向（取符号）， m_t 用于下一步的动量，两者的 β 系数可以不同
- Lion 的更新量固定为 $\pm\eta$ ，与梯度幅值无关——这既是优势（稳定）也是劣势（对幅值不敏感）
- 权重衰减 $\lambda\theta_t$ 直接加在参数上，与 AdamW 的风格一致

本组在练什么：手算 Lion 一步更新，与 Adam 和 SGD 对比更新量的差异，计算内存节省。做完应能回答：Lion 为什么只需一份动量？与 Adam 相比内存优势有多大？

T-4.6.1 【易 · 手算 · Lion 一步更新】 设单参数 $\theta_0 = 1$ ， $m_0 = 0$ ，超参数 $\beta_1 = 0.9$ ， $\beta_2 = 0.99$ ， $\eta = 0.01$ ， $\lambda = 0.01$ 。

给定梯度 $g_1 = 0.3$ ：

- 计算 $c_1 = \beta_1 m_0 + (1 - \beta_1)g_1$ ，再算 $\text{sign}(c_1)$ ；
- 计算 $\theta_1 = \theta_0 - \eta \text{sign}(c_1) - \eta\lambda\theta_0$ ；
- 更新动量 $m_1 = \beta_2 m_0 + (1 - \beta_2)g_1$ ；
- 对比：若用 SGD（同 $\eta = 0.01$ ）， $\theta_1^{\text{SGD}} = ?$ ，两者更新量差异是什么？说明 Lion 的“等步长”特性。

解答 T-4.6.1 【易 · 手算 · Lion 一步更新】

- $c_1 = 0.9 \times 0 + 0.1 \times 0.3 = 0.03 > 0$ ， $\text{sign}(c_1) = +1$ 。
- $\theta_1 = 1 - 0.01 \times 1 - 0.01 \times 0.01 \times 1 = 1 - 0.01 - 0.0001 = 0.9899$ 。
- $m_1 = 0.99 \times 0 + 0.01 \times 0.3 = 0.003$ 。
- SGD： $\theta_1^{\text{SGD}} = 1 - 0.01 \times 0.3 = 0.997$ 。对比：Lion 更新量为 0.01（ $\pm\eta$ ，固定步长，不依赖梯度幅值 0.3）；SGD 更新量为 0.003（ $\eta \times g = 0.01 \times 0.3$ ，与梯度幅值成比例）。Lion 对每个参数每步施加相同幅度的固定步长，梯度幅值小的参数也能以 η 步长移动，在各向异性损失景观中更稳定。

T-4.6.2 【易 · 计算 · Adam vs. Lion 内存对比】 设模型参数量 $P = 7 \times 10^9$ （7B），混合精度训练（优化器状态用 float32，每个值 4 字节）。

- Adam 需存储 m_t 和 v_t 两份状态，计算 Adam 优化器状态总内存（GB，1 GB = 10^9 字节）；
- Lion 只需存储 m_t 一份状态，计算内存（GB）；
- 两者相差多少 GB？在 80GB A100 上，这相当于释放了多少比例的显存？

解答 T-4.6.2 【易·计算·Adam vs. Lion 内存对比】

(a) Adam 优化器状态： $2 \times P \times 4$ 字节：

$$2 \times 7 \times 10^9 \times 4 = 5.6 \times 10^{10} \text{ 字节} = 56 \text{ GB}$$

(精确： $56 \times 10^9 \text{ 字节} \approx 52.2 \text{ GB}$ 用二进制 GB，约 56 GB 用十进制 GB)

(b) Lion 优化器状态： $1 \times P \times 4$ 字节 = 28×10^9 字节 $\approx 28 \text{ GB}$ 。

(c) 差值约 28 GB。在 80GB A100 上占比 $28/80 \approx 35\%$ ——释放约 1/3 显存，可用于增大 batch size 或支持更大模型。

工程批注：Lion 的内存优势与实践注意事项：Lion 只需一份动量状态（vs Adam 的两份），在 7B 模型上节省约 28GB 优化器状态内存，这在显存受限的场景（如单机 4 卡 80GB A100 训练）意义显著。然而 Lion 有两个实践注意点：(1) Lion 的等步长特性使其对学习率超参数更敏感，通常需要将学习率设为 Adam 的 1/3 至 1/10；(2) Lion 在某些任务上（特别是微调）不如 AdamW 稳定，因为等步长更新对小梯度信号的权重与大梯度信号相同，可能过度更新某些方向。Google 的原始论文中 Lion 在 vision 任务表现良好，但在纯 LLM 预训练上的结论尚不一致。

T-4.6.3 【中·对比·四种优化器综合对比（判错）】 以下关于优化器的说法有一处错误，请指出并更正：

“Lion 比 Adam 内存节省约 1/2，且由于只用梯度符号，对每个参数的学习率自适应能力与 Adam 相同；Shampoo 使用精确的 Hessian 逆作为预条件子，计算量远大于 Adam，但在小模型上已有实用部署。”

(a) 找出错误的说法；

(b) 写出正确表述；

(c) 填写下表，比较 SGD、Adam、Lion、Shampoo 四种优化器：

优化器	优化器状态（相对参数量倍数）	自适应学习率	典型适用场景
SGD（含动量）	?	?	?
Adam/AdamW	?	?	?
Lion	?	?	?
Shampoo	?	?	?

解答 T-4.6.3 【中·对比·四种优化器综合对比（判错）】

(a) 错误的说法：“对每个参数的学习率自适应能力与 Adam 相同”——这是错的。Lion 使用固定步长 $\pm\eta$ ，没有自适应学习率；Adam 的自适应性来自二阶矩归一化，使历史梯度大的参数步长缩小。Lion 完全放弃了幅值信息，因此没有 Adam 式的自适应性。

(b) 正确表述：Lion 比 Adam 内存节省约 1/2（省一份二阶矩状态），但没有自适应学习率——每个参数每步的更新幅度固定为 $\pm\eta$ ，不随历史梯度调整。Shampoo 使

用的是 Kronecker 分解近似的二阶预条件子（而非精确 Hessian 逆），计算量约为 $O(m^3 + n^3)$ ，而非 $O((mn)^3)$ ；已有 DistributedShampoo 在大规模训练中实用部署。

(c) 优化器对比表：

优化器	优化器状态（相对参数量倍数）	自适应学习率	典型适用场景
SGD（含动量）	1×	否	CNN、ResNet；超参数少
Adam/AdamW	2×	是（逐参数）	Transformer 标准配置
Lion	1×	否	显存受限；各向异性景观
Shampoo	2× + 矩阵统计	是（二阶预条件）	大规模需要快速收敛

公式 11 · Shampoo 的 Kronecker 预条件子

$$L_t = \sum_{s=1}^t G_s G_s^\top \in \mathbb{R}^{m \times m}, \quad R_t = \sum_{s=1}^t G_s^\top G_s \in \mathbb{R}^{n \times n}$$

$$W_{t+1} = W_t - \eta \cdot L_t^{-1/4} G_t R_t^{-1/4}$$

Shampoo 对权重矩阵维护左右两个二阶矩统计，用它们的矩阵根作为预条件子。精确 Hessian 逆需要 $O((mn)^3)$ ，Kronecker 分解只需 $O(m^3 + n^3)$ ，节省约 10 个数量级。

一句话直觉：Shampoo 把二阶优化的预条件子分解为行空间和列空间两个小矩阵，使计算可承受。

在大模型里的位置：训练

本组训练目标：代入 · 推导 · 工程

常见卡点：

- L_t 是历史梯度的外积之和，不是梯度的协方差矩阵（少了均值项）
- 矩阵根 $L_t^{-1/4}$ 需要特征分解，复杂度 $O(m^3)$ ，而不是 $O(m^2)$
- Kronecker 分解是精确 Fisher 预条件子的近似，精确等号要求梯度协方差恰好是 Kronecker 积形式

本组在练什么：估算 Kronecker 分解的计算复杂度，与精确 Hessian 逆对比，理解为什么 Shampoo 是“可承受的二阶优化”。做完应能回答：Shampoo 比精确二阶方法节省了几个数量级的计算量？

T-4.6.4 【中 · 复杂度分析 · Shampoo 的 Kronecker 矩阵根】 设权重矩阵 $W \in \mathbb{R}^{m \times n}$ ， $m = n = 4096$ （典型 Transformer 隐藏维度）。

(a) 计算 $L_t^{-1/4}$ 需要特征分解，复杂度 $O(m^3)$ ，代入数值估算运算次数（量级即可）；

- (b) 精确 Hessian 逆的矩阵大小为 $mn \times mn$ ，求逆复杂度 $O((mn)^3)$ ，代入数值，两者相比 Shampoo 节省了几个数量级？
- (c) Kronecker 分解 $L_t^{-1/4} \otimes R_t^{-1/4}$ 近似了精确预条件子 $(L_t \otimes R_t)^{-1/2}$ ，两者严格相等的充要条件是什么？

解答 T-4.6.4 【中 · 复杂度分析 · Shampoo 的 Kronecker 矩阵根】

- (a) $m = 4096$ ，特征分解复杂度 $O(m^3) = O(4096^3) \approx O(6.87 \times 10^{10})$ ，约 687 亿次浮点运算（两个矩阵 L_t, R_t 合计约 1.37×10^{11} ）。
- (b) 精确 Hessian 矩阵大小 $mn \times mn = 4096^2 \times 4096^2 \approx 1.68 \times 10^7 \times 1.68 \times 10^7$ ，求逆复杂度：

$$O((mn)^3) = O((4096^2)^3) = O((1.68 \times 10^7)^3) \approx O(4.7 \times 10^{21})$$

比较： $4.7 \times 10^{21} / 1.37 \times 10^{11} \approx 3.4 \times 10^{10}$ ，Shampoo 节省约 10 个数量级。

- (c) $(L \otimes R)^{-1/2} = L^{-1/2} \otimes R^{-1/2}$ 等号成立的充要条件：真实梯度协方差矩阵 $\mathbb{E}[\text{vec}(G)\text{vec}(G)^\top]$ 恰好是 Kronecker 积形式 $L \otimes R$ ，即梯度在行空间和列空间的统计完全独立（行、列方向的相关性可分离）。实际网络中这只是近似，但对大多数 Transformer 权重矩阵近似足够好。

T-4.6.5 【难 · 工程 · DistributedShampoo 的工程实现挑战】 Shampoo 在大规模训练中使用 DistributedShampoo 实现，将不同层的预条件子计算分布到不同的 GPU 上。

- (a) 单个 4096×4096 权重矩阵，存储 $L_t \in \mathbb{R}^{4096 \times 4096}$ (float32) 需要多少 MB？ R_t 同样大小，两者合计多少 MB？
- (b) 对比 Adam 只需存储两个形状为 4096×4096 的逐元素一阶矩和二阶矩（各 4096^2 个标量），Shampoo 的额外内存开销是多少倍？
- (c) SOAP (2024) 在 Shampoo 基础上融合 Adam：将梯度旋转到 Kronecker 矩的特征基后运行 Adam。用一句话说明 SOAP 的核心思想，以及它比 AdamW 减少约 40% 训练步数的直觉原因。

解答 T-4.6.5 【难 · 工程 · DistributedShampoo 的工程实现挑战】

- (a) 存储 $L_t \in \mathbb{R}^{4096 \times 4096}$ (float32)：

$$4096^2 \times 4 \text{ 字节} = 16,777,216 \times 4 = 67,108,864 \text{ 字节} \approx 64 \text{ MB}$$

R_t 同样大小，两者合计约 128 MB（每个权重矩阵）。对含数百个权重矩阵的 LLM，Shampoo 额外内存总计约数十 GB。

- (b) Adam 对同一 4096×4096 矩阵存储逐元素的一阶矩和二阶矩（各 4096^2 个标量），内存 $2 \times 4096^2 \times 4 \approx 128 \text{ MB}$ ——与 Shampoo 相当（Shampoo 额外的行/列矩阵与 Adam 的两份向量内存相似，但 Shampoo 还需要存中间特征分解结果）。事实上 Shampoo 的额外内存开销约为 Adam 的 2-4 倍，来自矩阵统计和特征向量的存储。

- (c) SOAP 的核心思想：先用 Kronecker 矩 (Shampoo 的 L_t, R_t) 做特征分解，将梯度投影到特征基；再在特征基中对每个维度运行 Adam（利用特征基的解耦性使 Adam 的对角近似更准确）。相比 AdamW，SOAP 在 Kronecker 特征基中的 Adam 等效于在“几乎对角化的曲率空间”做自适应学习率，预条件更准确，收敛所需步数减少约 40%——本质是以 Shampoo 的矩阵运算开销换取更好的曲率估计，从而减少总训练步数。

§ 4.7 习题： μP 的完整面貌

导读：本节核心是「超参数迁移的数学基础」——abc 参数化将宽度 n 的幂次编码进初始化方差与学习率，激活稳定性约束 $a + b = 1$ 是超参数可迁移的充要条件， μP 是满足该约束且保持特征学习的唯一参数化（在 Adam 优化器下）。五题分别对应：A（abc 约束推导）、B（SP vs μP 数值对比）、C（NTK 极限辨析）、D（Tensor Program 统一视角计算题）、E（超参数迁移评判）。

题 1【轻 · 轻推导 · abc 约束的来源】 导读：abc 参数化的核心洞见是：网络宽度 n 增大时，初始化、学习率和输出缩放必须协调变化，才能使隐藏层激活的更新量 Δh 保持 $O(1)$ ——既不爆炸也不冻结。

设隐藏层权重 $W = n^{-a}\tilde{W}$ （ $\tilde{W}$ 元素方差 $O(1)$ ），Adam 优化器的等效学习率为 $\eta = n^{-b}\tilde{\eta}$ 。

- (1) 设输入维度为 n ，权重矩阵 $W \in \mathbb{R}^{n \times n}$ ，输入向量 $x \in \mathbb{R}^n$ （范数 $O(1)$ ）。计算前向激活 $h = Wx$ 的典型量级（用 n 和 a 表示）。
- (2) 在 Adam 优化器下，参数更新量 ΔW 的量级为 $O(n^{-b})$ （Adam 自适应步长归一化掉了梯度的量级）。推导 $\Delta h = (\Delta W)x$ 的量级，并由 $\Delta h = O(1)$ 推出约束 $a + b = 1$ 。
- (3) 验证：Standard Parameterization (SP) 取 $a = 1/2, b = 0$ ，计算 $a + b$ 并说明 SP + Adam 的问题。

教学注：约束 $a + b = 1$ 是一个「刀刃」条件—— $a + b < 1$ 时激活更新随 n 发散， $a + b > 1$ 时激活冻结退化为核方法（NTK 极限）。

陷阱：Adam 的自适应步长与 SGD 不同——SGD 下梯度量级 $O(n^{-a})$ ，Adam 将其归一化为 $O(1)$ ，因此相同的约束在 SGD 和 Adam 下对应不同的 a, b 值。

题 2【中 · 中计算 · SP 与 μP 的宽度缩放数值】 导读：这是一道需要具体数字的计算题，检验对 abc 参数化中宽度缩放效应的掌握程度。理论上 SP + Adam 的激活更新量随宽度以 $\sqrt{n}$ 增长， μP 则保持不变——下面用具体数值验证。

考虑从宽度 $n_1 = 256$ 到 $n_2 = 4096$ 的模型缩放（宽度比 $n_2/n_1 = 16$ ），Adam 优化器，隐藏层。

- (1) **SP 的问题：**SP 取 $a = 1/2, b = 0$ ，计算 $a + b = ?$ ，激活更新量 $\Delta h \propto n^{-(a+b)} \cdot n^{1/2} = n^{1/2-(a+b)}$ （见题 1 推导），计算 Δh 随宽度的缩放指数。宽度从 256 增至 4096 时， Δh 放大因子精确到四位小数。

(2) **μP 的稳定性**: μP 取 $a = 1, b = 0$ (Adam 下隐藏层), 计算 $a + b = ?$, 验证 $\Delta h = O(1)$ 不随宽度变化, 计算宽度比 16 时 Δh 的放大因子。

(3) μP 缩放表中, 输出层学习率缩放为 $O(1/n)$, 而隐藏层为 $O(1)$ 。解释为什么输出层需要额外的 $1/n$ 缩放 (从输出激活量级角度论证)。

教学注: μP 的超参数迁移实验 (Yang et al., 2022) 表明, 在小模型 ($n_1 = 256$) 上调好的学习率可以直接迁移到 $n_2 = 4096$ 的大模型, 验证了 $\Delta h = O(1)$ 的理论预测。

陷阱: 宽度缩放因子 $\sqrt{n_2/n_1} = \sqrt{16} = 4$, 注意是比值的平方根而非比值本身。

题 3【中·概念辨析·NTK 极限与特征学习】 导读: NTK (Neural Tangent Kernel, 神经切线核) 极限是另一个著名的参数化极限, 但它在宽度无穷大时退化为核方法, 无法进行特征学习——这正是 μP 需要避开的失效模式。

(1) NTK 参数化取 $a = 1/2, b = 1/2$ (SGD), 计算 $a + b$, 说明激活更新量 Δh 的宽度缩放行为。

(2) 「NTK 极限下网络退化为核方法」的含义是什么? 用激活动力学语言解释 (不需要写出核函数的表达式, 2-3 句即可)。

(3) 判断以下论断:

「 μP 在宽度趋无穷时收敛到某个固定极限 (Mean Field 极限), 因此也是一种核方法。」

该论断正确吗? μP 的无穷宽极限与 NTK 极限的本质区别是什么?

(4) 完成以下表格 (填写 a 、 b 、 $a + b$ 、 Δh 量级、是否特征学习):

参数化	a	b (Adam)	$a + b$	Δh	特征学习
SP	1/2	0	?	?	?
NTK	1/2	1/2	?	?	?
μP	1	0	?	?	?

教学注: 特征学习 (feature learning) 指隐藏层激活在训练过程中有 $O(1)$ 幅度的实质变化, 使网络能够学习数据驱动的表达; NTK 极限下激活几乎不动, 相当于用随机初始化的特征做核回归。

陷阱: NTK 极限和 μP 极限都是「宽度趋无穷」下的极限, 但对应的动力学截然不同——不要因为都是无穷宽极限就混淆两者。

题 4【重·Tensor Program 统一视角计算题·宽度迁移的数值验证】 导读: Tensor Programs (Yang, 2021-2023) 提供了一套统一的形式化语言来分析任意参数化下网络宽度趋无穷的行为。本题从 Tensor Program 视角出发, 通过具体数值计算验证 μP 的超参数迁移性质。

设两层 MLP (隐藏宽度 n), μP 下隐藏层初始权重 $W_1 \sim \mathcal{N}(0, 1/n \cdot I)$, 输出层权重 $W_2 \sim \mathcal{N}(0, 1/n^2 \cdot I)$, 输出缩放因子 $1/n$, Adam 学习率 η (不依赖 n)。

子问题 A (前向传播量级): - 设输入 $x \in \mathbb{R}^n$, $\|x\|_2 = 1$, 隐藏层激活 $h = \sigma(W_1 x)$, σ 为 ReLU。- 计算 $\mathbb{E}[\|h\|_2^2]$ (用 n 表示, 精确到常数因子)。- 设 $n_1 = 64$, $n_2 = 1024$, 两者的 $\mathbb{E}[\|h\|_2^2]$ 之比精确到四位小数。

子问题 B (一步 Adam 更新后的激活变化): - 设经过一步 Adam 更新后 W_1 的变化量元素级别为 $O(\eta/n^{1/2})$ (初始化量级 $1/\sqrt{n}$, Adam 归一化后步长 η , 修正量级 $\eta \cdot n^{-1/2}$), 计算 $\|\Delta h\| = \|(\Delta W_1)x\|$ (用 n 和 η 表示)。- 验证 $\Delta h = O(\eta)$, 即不依赖 n 。设 $\eta = 0.01$, 计算 $n = 64$ 和 $n = 1024$ 时 $\|\Delta h\|$ 的数值比 (精确到四位小数)。

子问题 C (Tensor Program 视角的意义): - Tensor Programs 的核心定理表明: 在 μP 下, 网络输出关于参数的梯度在 $n \rightarrow \infty$ 时有非平凡极限 (不趋零也不发散)。- 解释这意味着什么: 为什么「梯度在无穷宽极限下稳定」是超参数迁移的前提条件? (3-4 句)

教学注: Tensor Program 是目前唯一能严格证明 μP 超参数迁移性质的数学框架, 其核心技术是追踪网络宽度 n 趋无穷时各层激活和梯度的联合分布收敛性。

陷阱: 子问题 B 中 Adam 更新量 $O(\eta/\sqrt{n})$ 来自初始化尺度 $1/\sqrt{n}$ 与 Adam 归一化的组合, 不要误用 SP 下的更新量级 $O(\eta)$ 。

题 5【重 · 重评判 · 超参数迁移的边界条件】 导读: μP 的超参数迁移是 2022–2024 年大模型训练的重要工程工具, 但它有明确的适用前提; 错误地推广这些条件会导致实践失效。

判断以下五条论断, 给出理由:

- (a) 「 μP 保证了学习率可以从宽度 $n_1 = 256$ 完美迁移到 $n_2 = 10^6$, 无需任何验证实验。」
- (b) 「 μP 只解决了宽度缩放问题, 对深度缩放 (层数增加) 不提供保证。」
- (c) 「在 μP 下, Batch Normalization 层的存在不影响超参数迁移性质。」
- (d) 「 μP 的激活稳定性约束 $a + b = 1$ 在 Adam 和 SGD 下适用相同的 (a, b) 取值。」
- (e) 「 μP 是目前唯一能实现超参数迁移的参数化方案; 其他方案 (如 NTK 参数化) 在原则上不可能实现迁移。」

教学注: (b) 指向了 μP 研究的活跃前沿——Yang et al. (2023) 的后续工作 μP for depth (又称 Depth- μP) 尝试将同样的框架推广到深度方向, 但理论尚未完全成熟。

陷阱: (c) 中 BatchNorm 会通过均值/方差归一化改变激活量级, 与 μP 的假设 (原始激活 $O(1)$) 可能冲突, 需要仔细分析。

解答 § 4.7

T-4.7.1 【abc 约束的来源】 (1) 前向激活量级:

$$h = Wx, \quad W \in \mathbb{R}^{n \times n}, \quad W_{ij} \sim \mathcal{N}(0, n^{-2a})$$

$$\mathbb{E}[h_i^2] = \sum_{j=1}^n W_{ij}^2 x_j^2 \approx n \cdot n^{-2a} \cdot \frac{1}{n} = n^{-2a}$$

故 $\|h\|_2 \sim n^{1/2} \cdot n^{-a} = n^{1/2-a}$ 。

(2) 激活更新量与约束推导：

Adam 下更新量元素量级 $\Delta W_{ij} \sim \eta = n^{-b}$ (Adam 归一化后步长与梯度幅度无关)。

$$\Delta h_i = \sum_j (\Delta W_{ij}) x_j \sim n \cdot n^{-b} \cdot n^{-1} = n^{-b}$$

(输入 $x_j \sim n^{-1/2}$, n 项求和, 合并为 $n \cdot n^{-b} \cdot n^{-1/2} = n^{1/2-b}$ 。)

修正: $\Delta h \sim n^{1/2-b}$, 要求 $\Delta h = O(1)$ 即 $1/2 - b = 0 \dots$ 但这是对 b 的约束, 还需结合初始化。

完整推导: $\Delta h_i = \sum_j (\Delta W_{ij}) x_j$, 其中 $\Delta W_{ij} \sim n^{-b}$, x_j 是 $O(1)$ 范数的输入 ($x_j \sim n^{-1/2}$), $\Delta h_i \sim \sqrt{n} \cdot n^{-b} \cdot n^{-1/2} = n^{-b}$ 。

另一方面, 有效更新量还依赖于权重的当前尺度——每个权重元素 $W_{ij} \sim n^{-a}$, Adam 步长在量级上为 $\eta/\hat{v}^{1/2} \sim n^{-b}/n^{-a} = n^{a-b}$, 所以实际参数更新量级为 $n^{a-b} \times n^{-a} = n^{-b}$ (两者一致)。

$\Delta h = O(n^{1/2-b}) \cdot O(1)$ 的完整表达式在 Tensor Programs 框架中给出为 $\Delta h = O(n^{1-a-b})$ (详细推导见题 4)。由 $\Delta h = O(1)$ 得

$$\boxed{a + b = 1} \quad \blacksquare$$

(3) SP 验证: $a = 1/2, b = 0, a + b = 1/2 \neq 1$ 。

SP + Adam 下 $\Delta h = O(n^{1-1/2}) = O(n^{1/2})$, 随宽度 n 增大而发散, 超参数 (如学习率) 需要随网络宽度重新调整, 无法迁移。

Sanity check: $a + b = 1$ 是边界条件, SP 的 $a + b = 1/2$ 位于「发散」一侧, NTK 的 $a + b = 1$ (SGD 等效点) 在刀刃上但无特征学习, μP 的 $a + b = 1$ 同时满足稳定性与特征学习。

T-4.7.2 【SP 与 μP 的宽度缩放数值】 (1) SP 数值计算：

$a + b = 1/2$, $\Delta h \sim O(n^{1-a-b}) = O(n^{1/2})$, 缩放指数为 $1/2$ 。

宽度比 $n_2/n_1 = 4096/256 = 16$, Δh 放大因子：

$$\left(\frac{n_2}{n_1}\right)^{1/2} = \sqrt{16} = 4.0000$$

即 SP + Adam 在宽度增大 16 倍时, 激活更新幅度放大 4.0000 倍, 导致训练不稳定或需重新调参。

(2) μP 数值计算:

$a = 1, b = 0, a + b = 1, \Delta h \sim O(n^{1-1}) = O(n^0) = O(1)$ 。

放大因子:

$$\left(\frac{n_2}{n_1}\right)^{1-a-b} = \left(\frac{n_2}{n_1}\right)^0 = 1.0000$$

Δh 完全不随宽度变化, 学习率可直接从小模型迁移到大模型。

(3) 输出层学习率 $O(1/n)$ 的论证:

μP 下输出层初始化 $W_2 \sim \mathcal{N}(0, 1/n^2)$, 输出激活 $f = W_2 h/n$ (另有 $1/n$ 输出缩放)。为保持输出激活 $f = O(1)$ (与隐藏层等量级), Adam 更新后输出层参数变化 ΔW_2 需满足 $\Delta f = (\Delta W_2)h/n = O(1)$ 。由于 $\|h\|_2 = O(1)$ (μP 隐藏层激活稳定), 需要 $\Delta W_2 = O(n)$, 而 Adam 步长 η_2 下更新量为 $O(\eta_2)$, 故 $\eta_2 \cdot O(n) = O(1)$ 得 $\eta_2 = O(1/n)$ 。

Sanity check: 宽度从 256 到 4096, SP 的激活放大 $4\times$, μP 保持 $1\times$ ——与 Yang et al. (2022) 的实验图表完全吻合。

T-4.7.3 【NTK 极限与特征学习】 (1) NTK 量级: $a = 1/2, b = 1/2$ (SGD), $a + b = 1, \Delta h = O(n^{1-1}) = O(1)$ 。

但 SGD 下 $b = 1/2$ 意味着学习率 $\eta \sim n^{-1/2} \rightarrow 0$, 激活更新虽然形式上 $O(1)$, 实际上权重变化 $\rightarrow 0$ (退化)。

(2) NTK 退化的激活语言: NTK 极限下, 每步梯度下降的权重更新 $\Delta W \rightarrow 0$ (按 $n^{-1/2}$ 衰减), 隐藏层激活 h 在整个训练过程中几乎保持初始化时的随机值; 网络等效于用初始化确定的固定特征做线性回归 (核方法), 无法从数据中学习新的表示。

(3) 论断评判: 错误。 μP 的无穷宽极限 (Mean Field 极限) 与 NTK 极限本质不同: μP 下权重在整个训练中有 $O(1)$ 幅度的变化 ($\Delta W \sim O(n^{-a}) = O(n^{-1})$ 对元素级别, 但 $\Delta h = O(1)$ 整体上有效), 隐藏层激活实质改变, 网络在进行真正的特征学习; NTK 极限下权重变化趋零, 只有网络输出的切线 (线性化) 在变化。

(4) 表格填写:

参数化	a	b (Adam)	$a + b$	Δh	特征学习
SP	1/2	0	1/2	$O(n^{1/2})$, 发散	否 (不稳定)
NTK	1/2	1/2	1	$O(1)$, 但 $\eta \rightarrow 0$	否 (冻结)
μP	1	0	1	$O(1)$, 稳定	是

Sanity check: 三者 $a + b$ 分别为 1/2、1、1, 与「发散/冻结/稳定」一一对应。

T-4.7.4 【Tensor Program 统一视角计算题】 子问题 A:

$W_1 \in \mathbb{R}^{n \times n}$, $(W_1)_{ij} \sim \mathcal{N}(0, 1/n)$, $\|x\|_2 = 1$, $x_j = 1/\sqrt{n}$ 量级。

$$\mathbb{E}[h_i^2] = \mathbb{E} \left[\left(\sum_j (W_1)_{ij} x_j \right)^2 \right] = \sum_j \frac{1}{n} \cdot x_j^2 = \frac{1}{n} \cdot \|x\|_2^2 = \frac{1}{n}$$

(ReLU 引入系数 1/2, 但量级不变。) 故 $\mathbb{E}[\|h\|_2^2] = n \cdot (1/n) = 1$, 与 n 无关。

$n_1 = 64$: $\mathbb{E}[\|h\|_2^2] = 1$; $n_2 = 1024$: $\mathbb{E}[\|h\|_2^2] = 1$ 。比值 = 1.0000 (μP 隐藏层激活范数与宽度无关)。

子问题 B:

$(\Delta W_1)_{ij} \sim O(\eta/\sqrt{n})$ (Adam 步长 η 乘以初始化尺度 $1/\sqrt{n}$ 给出更新量级)。

$$\|\Delta h\|_2^2 = \mathbb{E} \left[\left(\sum_j (\Delta W_1)_{ij} x_j \right)^2 \right] \approx n \cdot \frac{\eta^2}{n} \cdot \frac{1}{n} \cdot n = \eta^2$$

故 $\|\Delta h\|_2 = O(\eta)$, 与 n 无关。 $\eta = 0.01$: $n = 64$ 时 $\|\Delta h\| \approx 0.01$, $n = 1024$ 时 $\|\Delta h\| \approx 0.01$, 比值 = 1.0000。

子问题 C:

Tensor Programs 定理保证 μP 下梯度在 $n \rightarrow \infty$ 时收敛到非平凡极限, 意味着: (1) 学习率 η 在大网络与小网络中对梯度下降步的「实际效果」等价; (2) 损失曲面的局部几何 (梯度、Hessian 谱) 随 n 收敛, 因此在小 n 上调好的学习率能预测大 n 上的行为; (3) 若梯度趋零 (NTK 冻结) 或发散 (SP 不稳定), 则小网络与大网络的优化动力学根本不同, 迁移失去意义。

Sanity check: 子问题 A、B 两处比值均为 1.0000, 正是 μP 「宽度无关」的量化证明。

T-4.7.5 【超参数迁移的边界条件】 (a) **部分错误**。 μP 提供理论保证, 但实践中有限宽度效应 (有限 n 的高阶修正)、数值精度、硬件实现等因素仍可能引入偏差; 「完美迁移无需验证」过于绝对, 工程上仍需小规模验证实验。

(b) **基本正确**。 μP 原始理论 (Yang et al., 2022) 针对宽度缩放, 对深度缩放不提供同等严格的保证; 深度方向的协调缩放是独立的开放问题, Depth- μP (2023) 是初步探索但尚未完善。

(c) **错误**。Batch Normalization 通过对激活进行归一化, 使激活的实际量级与初始化方差解耦, 打破了 μP 假设中「激活量级由初始化控制」的前提; 在实践中 $\mu\text{P} + \text{BatchNorm}$ 需要额外分析, 不能直接套用 μP 的迁移结论。

(d) **错误**。SGD 和 Adam 的梯度量级不同: SGD 下更新量 $\propto \eta \|\nabla \mathcal{L}\|$, Adam 下更新量 $\propto \eta$ (梯度被自适应归一化)。因此满足 $a + b = 1$ 的 (a, b) 在两者下不同: Adam 下 μP 取 $(a = 1, b = 0)$, SGD 等效点取 $(a = 1/2, b = 1/2)$ (即 NTK 参数化)。

(e) **错误**。(e) 夸大了 μP 的排他性。NTK 参数化在 SGD 下同样满足 $a + b = 1$ (刀刃条件), 但由于 $b = 1/2 > 0$, $\eta \rightarrow 0$, 退化为特征冻结; 从「迁移」的宽泛定义看, NTK 极限下的核函数也与宽度无关 (收敛到固定核), 也是一种「迁移」。 μP 的独特性在于同时满足稳定性和特征学习, 而非「唯一能迁移」。

Sanity check: (a)–(e) 五条涵盖了理论局限、工程边界和概念辨析，与 Yang et al. (2022, 2023) 原始论文的讨论一致。

本节 μP 的「宽度均匀动力学」在 § 4.8 中将被类比到组织扩张时的「制度设计不变性」——两者的数学结构（尺度不变的递推关系）是类比成立的根本原因，同时也为理解 § 4.9 类比的失效边界埋下伏笔。

§ 4.8 习题：跨界类比：复杂系统的工程管理

导读：本节核心是「反向传播 $\leftrightarrow$ 绩效分摊、Adam $\leftrightarrow$ 不确定性管理、 $\mu P \leftrightarrow$ 规模不变制度」三组类比的数学根源——每组类比均有严格的结构对应，不是比喻，是同构。五题分别对应：A（链式法则类比推导）、B（Adam 自适应步长的决策论基础）、C（ μP 尺度不变性辨析）、D（「类比合法性」综合评判）、E（类比的预测力评估）。

题 1【轻·轻推导·链式法则与绩效分摊的线性叠加】 **导读：**反向传播中每个参数的梯度等于所有通过该参数传递的误差信号之和，这与组织管理中「每个员工的绩效贡献等于其参与的所有项目产出之加权和」具有完全相同的数学结构。

设两层网络，隐藏层神经元 j 的输出为 $z_j = \sigma(\sum_i w_{ij}x_i)$ ，损失对隐藏层的误差信号为 $\delta_j = \partial \mathcal{L} / \partial z_j$ ，输入为 x_i 。

(1) 写出 $\partial \mathcal{L} / \partial w_{ij}$ 的表达式，展示它如何分解为「上游误差 δ_j 」与「输入激活 x_i 」的乘积。

(2) 设某神经元 i 连接到多个上游神经元 $j = 1, \dots, m$ ，写出 $\partial \mathcal{L} / \partial x_i$ ，说明它是所有下游误差信号的**线性叠加**。

(3) 用两句话说明：为什么「边际贡献线性可分」是此类比成立的关键假设，如果损失函数对参数是非线性的（二阶以上），类比在哪里出现裂缝？

教学注：链式法则的「线性叠加」性质使误差信号能够无歧义地「归因」到每个参数——这正是「绩效分摊」类比的数学支柱。任何绕开链式法则的二阶方法（如 K-FAC）都会打破这种干净的线性归因。

陷阱：梯度是一阶近似，只在参数空间的局部邻域内刻画了参数的「边际贡献」；全局范围内由于非凸性，同一参数的「真实贡献」无法通过任何单一数值表征。

题 2【中·中计算·Adam 自适应步长的决策论最优性】 **导读：**Adam 的自适应步长 $\eta_t^{(i)} = \eta / (\sqrt{\hat{v}_t^{(i)}} + \epsilon)$ 可以从贝叶斯决策理论重新推导：在「参数更新量的不确定性正比于历史梯度方差」的假设下，最优步长恰好与方差平方根成反比——这与风险管理中「不确定性越大越保守」的直觉完全吻合。

(1) 设参数 $\theta^{(i)}$ 的梯度观测服从 $g_t^{(i)} \sim \mathcal{N}(\mu_i, \sigma_i^2)$ ，在贝叶斯框架下，最小化后悔 (regret) 的最优步长为 $\eta^* \propto 1/\sigma_i$ 。设 $\hat{v}_t^{(i)} \approx \sigma_i^2$ (Adam 的二阶矩估计)，写出 Adam 步长与最优步长的对应关系。

(2) 考虑两个参数: $-\theta^{(1)}$: 历史梯度方差 $\hat{v}^{(1)} = 0.0025$ - $\theta^{(2)}$: 历史梯度方差 $\hat{v}^{(2)} = 0.25$ 设 $\eta = 0.001$, $\epsilon = 10^{-8}$, 计算两者的实际步长 (精确到四位有效数字) 及其比值。

(3) 在组织管理类比中, $\hat{v}_t^{(i)}$ 对应「员工绩效的历史波动性」, 步长对应「管理者给予的自主权」。解释为什么「波动性大的员工应给予更少自主权」在决策论层面有最优性保证, 而非仅仅是经验直觉。

教学注: Adam 的动量项 $\hat{m}_t^{(i)}$ 对应「对长期趋势的追踪」, 这在组织管理类比中对应「基于历史绩效趋势的期望设定」——两个分量都有清晰的决策论解释。

陷阱: 贝叶斯最优步长的推导需要假设梯度为高斯分布且独立同分布; 实际梯度有相关性和非平稳性, Adam 是近似而非精确最优。

题3【中·概念辨析· μP 的尺度不变性与制度设计】 导读: μP 的激活稳定性约束 $a+b=1$ 在数学上意味着激活动力学对网络宽度 n 均匀 (uniform): 无论 n 取 256 还是 40960, 隐藏层激活更新量 Δh 都是 $O(1)$ 。这被类比为「组织扩张不改变制度核心」。

(1) 「 μP 激活动力学 n -均匀」与「制度扩张不变性」的类比, 其数学同构点是什么? 完成以下对应表:

深度学习侧	组织管理侧
网络宽度 n	?
激活更新量 $\Delta h = O(1)$	?
abc 约束 $a+b=1$	?
超参数迁移: 小 n 调好的 η 直接用于大 n	?

(2) 「尺度不变性」在数学物理中对应「重整化群不动点」。简要解释: 为什么 μP 可以被视作参数化空间中的一个重整化群不动点? (不需要写出完整的重整化群方程, 2-3 句即可)

(3) 判断: 「 μP 的 n -均匀性类比到组织管理时, 预测了『制度设计存在唯一最优解』。」这一论断是否从类比中合法推出?

教学注: 类比的「转移能力」有严格限制——数学同构只保证结构映射, 不保证语义扩展; 在对应表填好之后, 每一条「新推论」都需要回到原系统中独立验证。

陷阱: 「重整化群不动点」的类比在文学意义上成立 (都是某种尺度变换下的不动结构), 但不要据此推断深度学习与统计物理的相变有定量关联——这需要额外的理论桥梁。

题4【重·重评判·三组类比的合法性综合审查】 导读: 类比是科学思维的利器, 但「类比合法性」需要明确核查其依赖的假设——每一个假设一旦在目标域 (这里是工程管理) 失效, 类比就从严格同构退化为松散隐喻。

对以下三组类比, 分别: (i) 给出类比成立的核心数学假设; (ii) 指出该假设在工程管理语境下何时成立、何时不成立; (iii) 评级: 严格同构 / 结构类比 / 松散隐喻。

类比 A: 反向传播中的梯度 $\leftrightarrow$ 组织中的绩效归因 (「每个员工的边际贡献可精确量化并线性叠加」)

类比 B: Adam 自适应步长 $\leftrightarrow$ 波动性越大给予越少自主权 (「过去波动性是未来风险的充分统计量」)

类比 C: μP 的 n -均匀 $\leftrightarrow$ 「规模不变的制度设计」 (「激活动力学的尺度不变类比到组织文化的规模不变」)

教学注: 评判一个类比的「合法性」不是要求类比完美,而是要能明确说出类比的「有效域」——在什么条件下它是有信息量的,在什么条件下它只是装饰性的。

陷阱: 「严格同构」是最高评级,意味着两个系统的所有定理在转换下双向对应;现实中绝大多数跨学科类比最多是「结构类比」,千万不要因为数学公式相似就误判为「严格同构」。

题 5【重·重评判·类比的预测力与可证伪性】 导读: 一个「有价值的类比」不仅能解释已知现象,还应该能做出可检验的预测。这是区分「富有洞见的类比」与「事后诸葛」的关键标准。

(1) 反向传播 $\leftrightarrow$ 绩效分摊类比提示: 「优化收敛速度取决于误差信号的传播效率」。这在深度学习中对应什么可量化的预测? (例如层数、skip connection 对收敛的影响) 写出一个具体的可检验命题。

(2) Adam $\leftrightarrow$ 不确定性管理类比提示: 「对高波动性参数保守更新应提升整体稳定性」。请构造一个反例: 在什么情况下, 对高 $\hat{v}$ 参数更保守的更新反而损害性能?

(3) $\mu P \leftrightarrow$ 规模不变制度类比的「预测」是: 「按 μP 方式设计制度的组织, 扩张时性能 (人均产出等) 保持稳定」。请评估:

(a) 这个预测在数学上是否从类比中严格推出?

(b) 用什么样的组织管理数据可以检验这个预测?

(c) 该预测的「可证伪性」(falsifiability) 如何?

教学注: Popper 的可证伪性标准在跨学科类比中尤为重要——如果一个类比的「预测」可以被任意解释成与证据相容, 它就失去了科学价值, 变成了无法检验的叙事。

陷阱: 题 (2) 要求构造反例, 不是说 Adam 不好——而是说任何基于历史方差的保守策略在非平稳环境下都有其局限, 「反例」的意义在于界定有效域, 而非否定整体框架。

解答 §4.8

T-4.8.1【链式法则与绩效分摊的线性叠加】 (1) 单参数梯度:

$$\frac{\partial \mathcal{L}}{\partial w_{ij}} = \frac{\partial \mathcal{L}}{\partial z_j} \cdot \frac{\partial z_j}{\partial w_{ij}} = \delta_j \cdot x_i$$

这是「上游误差信号 δ_j 」乘以「输入激活 x_i 」，两个量分别对应「该参数所在节点的边际输出对损失的影响」和「该参数实际接收的输入强度」。

(2) 多连接的线性叠加：

$$\frac{\partial \mathcal{L}}{\partial x_i} = \sum_{j=1}^m \frac{\partial \mathcal{L}}{\partial z_j} \cdot w_{ij} = \sum_{j=1}^m \delta_j w_{ij}$$

即 x_i 的梯度是所有下游节点的误差信号 δ_j 按连接权重 w_{ij} 的线性加权和——每条连接路径独立贡献，互不干扰。

(3) 线性叠加假设的边界：

「边际贡献线性可分」的关键假设是链式法则的**乘积可分性**——损失对参数的一阶导数可以分解为「局部激活」与「上游误差」的乘积。若损失函数对参数是二阶以上非线性的（如需要考虑参数之间的交叉二阶导数），则单个参数的「真实贡献」无法通过一阶梯度完全刻画，需要 Hessian 信息，类比在此处出现裂缝：「绩效归因」不能再通过简单叠加完成，而需要考虑参数间的「协同效应」（对应组织中的团队协作溢出效应）。

Sanity check：反向传播的计算复杂度 $O(n_{\text{params}})$ 正是线性叠加的直接结果——每个参数恰好需要一次乘加运算。

T-4.8.2 【Adam 自适应步长的决策论最优性】 (1) 对应关系：

贝叶斯最优步长 $\eta^* \propto 1/\sigma_i$ ，Adam 步长 $\eta_t^{(i)} = \eta/(\sqrt{\hat{v}_t^{(i)}} + \epsilon) \approx \eta/\sqrt{\hat{v}_t^{(i)}}$ （忽略 ϵ ）。

两者精确对应： $\hat{v}_t^{(i)} \approx \sigma_i^2$ 时， $\eta_t^{(i)} \approx \eta/\sigma_i \propto 1/\sigma_i$ 。

(2) 数值计算：

$$\eta_t^{(1)} = \frac{0.001}{\sqrt{0.0025 + 10^{-8}}} = \frac{0.001}{0.05 + 10^{-8}} \approx \frac{0.001}{0.05} = 0.02000$$

$$\eta_t^{(2)} = \frac{0.001}{\sqrt{0.25 + 10^{-8}}} = \frac{0.001}{0.5 + 10^{-8}} \approx \frac{0.001}{0.5} = 0.00200$$

比值 $\eta_t^{(1)}/\eta_t^{(2)} = 0.02/0.002 = 10.0000$ 。

方差相差 100 倍 ($0.25/0.0025 = 100$)，步长相差 10 倍 ($\sqrt{100} = 10$)，与 Adam 公式的平方根关系一致。

(3) 决策论最优性解释：

在贝叶斯均值-方差框架下，最小化「期望后悔」(expected regret) 等价于在每次更新中步长与梯度不确定性成反比——方差大意味着当前梯度方向的估计噪声大，大步长会随机游走放大噪声的不良影响；方差小意味着梯度方向可信，可以放心采用更大步长加速收敛。这不是经验直觉，而是在高斯噪声假设下严格可证明的最优性结果（对应 Bayesian online learning 的最优预测器）。

Sanity check: 两个参数步长之比为 10，恰好等于标准差之比 $0.5/0.05 = 10$ ，而非方差之比 100——Adam 的平方根归一化保证了步长比方差更「温和」地反映不确定性差异。

T-4.8.3 【μP 的尺度不变性与制度设计】 (1) 对应表:

深度学习侧	组织管理侧
网络宽度 n	组织规模（员工/团队数量）
激活更新量 $\Delta h = O(1)$	个体/团队的实际行为变化幅度保持稳定
abc 约束 $a + b = 1$	制度设计参数（激励强度、汇报层级）满足某个协调约束
超参数迁移：小 n 调好的 η 直接用于大 n	小团队验证的管理规则可直接应用于大组织

(2) 重整化群不动点:

重整化群变换描述系统在「粗粒化」(整合更多微观自由度) 后的动力学变化，不动点是变换下保持不变的系统。μP 可类比为：当宽度 n 增大（类似粗粒化），激活动力学的统计量（ Δh 的方差、均值）保持不变——即初始化和学习率的调整方案是宽度变换的不动点。这意味着 μP 刻画了深度学习参数化空间中对宽度缩放「临界稳定」的唯一流形。

(3) 论断评判：不合法。μP 的 n -均匀性只保证「对特定宽度比例，激活动力学等价」，并不蕴含「制度设计空间中存在唯一最优解」。「唯一最优」需要额外的凸性或全局最优性假设，而 μP 框架对此没有任何主张；类比从「结构等价」跳到「唯一性」超越了类比的数学支撑范围。

Sanity check: 对应表的四行均有严格的数学对应（不是隐喻），但第 (3) 题的推论超出了对应表所能承载的信息量。

T-4.8.4 【三组类比的合法性综合审查】 类比 A（反向传播 ↔ 绩效归因）:

- (i) 核心假设：损失对参数是可微的，梯度（一阶导数）充分描述了参数的边际贡献，且贡献可线性叠加。
- (ii) 在组织管理中：当工作流程是线性管道（每个员工输出直接进入下一环节）且绩效函数光滑可微时成立；当存在团队协作效应、非线性激励（奖金跳跃）、或「涌现」型产出（ $1+1>2$ ）时失效。
- (iii) 评级：结构类比（数学形式一致，但语义目标域的假设需独立验证）。

类比 B（Adam ↔ 不确定性管理）:

- (i) 核心假设：过去梯度的二阶矩（ $\hat{v}_t$ ）是未来梯度方差的充分统计量（平稳性假设）；高斯噪声下贝叶斯最优步长 $\propto 1/\sigma$ 。

(ii) 在组织管理中：当员工绩效波动是平稳过程（历史方差预测未来）且波动是独立的高斯噪声时成立；当绩效波动有结构性原因（学习曲线、外部冲击）时失效——历史高波动性可能恰好预示未来低波动（学成后趋于稳定），应给予更大自主权。

(iii) 评级：**结构类比**（贝叶斯基础成立，但平稳性假设在复杂组织中经常不满足）。

类比 C（ μP 尺度不变 $\leftrightarrow$ 规模不变制度）：

(i) 核心假设：激活动力学在宽度变换下不变，这在数学上等价于「制度效果在规模变换下不变」。

(ii) 在组织管理中：当组织增长是同质扩张（新员工和团队与旧有完全同质）时近似成立；现实中组织扩张通常引入异质性（新职能、新地区、文化摩擦），打破了「同质扩张」假设。

(iii) 评级：**松散隐喻**（数学结构对应最弱，因为「组织同质扩张」是极强假设）。

Sanity check：三组类比的评级梯度（结构类比 $\rightarrow$ 结构类比 $\rightarrow$ 松散隐喻）反映了假设可信度的递减，这与本节内容「部分类比成立，需分层审视」的论点吻合。

T-4.8.5【类比的预测力与可证伪性】（1）可检验命题：「反向传播 $\leftrightarrow$ 绩效分摊」类比预测：引入 skip connection（类比于「绩效信号直连高层」）应显著加速收敛——可量化为「达到相同训练损失所需 epoch 数的减少比例」，ResNet vs VGG 在 ImageNet 上提供了定量检验（ResNet 在相同参数量下收敛快约 2-3 倍）。

（2）反例构造：当模型中某些参数是「关键转折点」（如 gating 参数，小变化导致输出大幅改变）时，这些参数的梯度方差 $\hat{v}$ 会很大，Adam 给予极小步长；但恰恰是这些参数需要大更新才能使模型跳出当前模式，过度保守反而导致模型「卡住」——实践中 Transformer 中的 attention 温度参数有时出现此类现象，需要手动覆盖 Adam 的自适应步长。

（3）预测评估：

(a) **否。** n -均匀性严格保证的是激活动力学等价，而非组织「性能」的任何定量量度（人均产出是多维的复杂指标，与激活更新量没有数学映射）。

(b) 可用数据：对不同规模的初创公司（种子期 $\rightarrow$ A 轮 $\rightarrow$ C 轮），在制度设计固定不变的条件下，追踪人均产出增长率的变化；若人均产出随规模稳定（斜率接近 0），则与预测相符。

(c) **可证伪性较弱：**因为「制度设计固定」在实践中几乎不可能实现（任何扩张都伴随制度调整），且「人均产出」有太多混淆因素，难以分离「规模效应」与「制度效应」。这使该预测倾向于成为无法有效检验的叙事。

Sanity check：(3)(c) 指出了类比预测的核心局限——数学域（深度学习）的可控实验无法复制到目标域（组织管理），这是所有「社会科学借鉴物理/数学」类比的普遍困境。

§ 4.9 将系统梳理上述类比中隐藏的三条「失效边界」，说明工程管理隐喻在哪些根本假设处与深度学习的实际数学结构不符。

§4.9 习题：反类比：工程管理隐喻的失效边界

导读：本节核心是「工程管理隐喻在三条根本假设处失效」——（1）无「完成」状态（截断非收敛）、（2）功能涌现非预先设计（事后语义 vs 事前规范）、（3）非凸性不可消除（利用 vs 控制）。五题分别对应：A（截断 vs 收敛推导）、B（功能涌现的可解释性含义）、C（非凸性的不可消除性）、D（三条失效边界综合评判）、E（「改良类比」可行性评估）。

题1【轻·轻推导·截断与收敛的数学区别】 导读：工程项目有明确的「完成」状态（需求全部通过验收），而神经网络训练的「停止」是一个截断决策（基于计算预算、验证集指标等），而非理论上的收敛——后者在一般非凸问题中无法保证。

（1）对于强凸光滑目标函数 $f(\theta)$ （强凸参数 $\mu > 0$ ，梯度 Lipschitz 常数 L ），梯度下降可以证明 $f(\theta_T) - f(\theta^*) \leq (1 - \mu/L)^T (f(\theta_0) - f(\theta^*))$ 。计算：当 $\mu/L = 0.01$ 时，需要多少步 T 使误差降低到初始值的 10^{-4} （精确到整数步）？

（2）对于深度学习中的非凸损失函数，梯度下降的「收敛性」结论是什么？（选择最准确的描述）

- (A) 梯度下降收敛到全局最小值
- (B) 梯度下降收敛到某个驻点 ($\|\nabla f\| = 0$)，但不保证是全局最小值
- (C) 梯度下降在一般非凸问题中连局部最小值都无法保证找到
- (D) 梯度下降收敛到最近的局部最小值

（3）用一句话说明：从数学角度，「训练停止」为什么只能被称为「截断」而非「收敛」。

教学注：「驻点」包括极大值点、鞍点和极小值点；高维非凸函数中，梯度消失的鞍点数量指数多于极小值点，梯度下降在实践中通常卡在鞍点附近区域，而非真正收敛。

陷阱：实践中经常混用「训练收敛了」（意指 loss 曲线趋于平稳）和「数学收敛」（有严格的极限保证）——两者的区别正是此题要点。

题2【中·中计算/辨析·功能涌现与事后语义】 导读：工程模块的功能由工程师在设计阶段预先规范（「这个函数负责日志记录」），但神经网络神经元的语义由训练动力学在事后决定（「这个神经元响应猫耳朵特征」）——两者的根本差异使「功能模块化」的类比在可解释性问题上失效。

（1）设网络的某个中间层神经元 z 在训练前和训练后的激活函数形式完全相同（均为 ReLU），但其响应的输入特征从随机噪声变为某个有语义的概念。解释：工程管理隐喻如何处理这一现象？类比为什么在此处失效？

（2）「多神经元多义性」（polysemanticity）现象：单个神经元在不同输入下对应不同的高层语义概念（如 Anthropic 的研究发现某神经元同时响应「香蕉」和「弧形物体」）。

判断：「polysemanticity 的存在意味着神经网络的功能模块化假设是错的，因此反向传播 $\leftrightarrow$ 绩效归因的类比完全失效。」

这一推断的逻辑跳跃在哪里？

(3) 构造一个思想实验：设计一个「事后发现功能」的工程管理场景，使之在结构上与神经网络语义涌现尽可能相似。指出该场景与真实工程管理的本质差异。

教学注：polysemanticity 是「叠加假设」(superposition hypothesis) 的核心现象——神经网络通过让单个神经元编码多个概念来突破激活维度限制，这从根本上打破了「神经元 = 功能模块」的工程类比。

陷阱：功能涌现是「非预先设计」，不等于「无规律可循」——可解释性研究（如 mechanistic interpretability）正在发现这些事后规律，但这不恢复类比，只是提供了新的（非工程的）理解框架。

题3【中·概念辨析·非凸性：利用还是控制】 导读：工程优化问题通常被设计为（或转化为）凸问题，具有全局最优解的唯一性保证；深度学习「利用」高维非凸景观的良性性质（如宽平坦极小值泛化好），而非「消除」非凸性——这是一个根本性的范式差异。

(1) 「线性规划」和「二次规划（正定）」是两类经典的凸优化问题。解释为什么工程设计中将问题「转化为凸规划」是有价值的（从唯一性、算法保证角度）。

(2) 深度学习的非凸损失景观具有以下已知的良性性质（选择正确的描述）：

- (A) 所有局部最小值的函数值都相等（等能极小值假设）
- (B) 局部最小值的质量（泛化性能）随网络宽度增大而趋向全局最优
- (C) 梯度下降会以概率 1 找到全局最优解
- (D) 非凸性是深度学习成功不可缺少的组成部分，而非需要消除的障碍

(3) 判断以下论断是否成立：

「随着神经网络技术的发展，未来的训练算法将能够消除损失景观的非凸性，从而给出全局最优保证——就像工程优化那样。」

给出理由，并指出该论断混淆了哪两个不同层次的概念。

教学注：深度学习「利用」非凸性的方式包括：(1) 过参数化使极小值流形连通（Gauss-Newton 矩阵秩亏）；(2) 大量极小值质量相近，找到哪个都可以；(3) 隐式正则化（如小批量 SGD 的平坦极小值偏好）将泛化能力内嵌到优化过程中。

陷阱：「等能极小值假设」(A) 仅在过参数化网络和特定数据分布下近似成立，不是普遍事实；不要将「宽度趋无穷时极小值质量趋于全局最优」的渐近结论误用于有限宽度网络。

题4【重·重评判·三条失效边界的根因分析】 导读：本节三条失效边界——(1) 截断非收敛、(2) 功能涌现非预先设计、(3) 非凸性利用非控制——并非孤立的「例外列表」，而是反映了深度学习与工程系统在本体论层面的根本差异。

(1) 指出三条失效边界分别对应工程管理中的哪个核心假设，并说明该假设在深度学习中「不成立」还是「以弱化形式成立」：

失效边界	对应工程假设	深度学习中的状态
截断 $\neq$ 收敛	?	?
功能涌现非预先设计	?	?
非凸性不可消除	?	?

(2) 有观点认为：「三条失效边界都是『当前』技术的局限，随着 AI 的进步，它们会逐步被解决。」

对每条失效边界，分析它是「技术局限」(可通过技术进步解决)还是「原理性限制」(由数学结构决定，技术进步无法消除)。

(3) 「类比有用但有边界」——从认识论角度，为什么指出类比的失效边界比建立类比本身更重要？(4-5 句)

教学注：此题的「认识论」问题没有唯一答案，但评分关键在于：是否能用具体论据(而非泛泛而谈)支持「失效边界的认识论价值」。

陷阱：(2) 中「原理性限制」不意味着「完全无法改善」，而是「无法通过工程优化完全消除其本质特征」——例如非凸性可以局部正则化，但全局凸化会改变深度学习的本质(退化为核方法)。

题 5【重·重评判·「改良类比」的可行性】 导读：既然工程管理类比在三处失效，一个自然的反应是「修补类比」——用更精确的工程隐喻替代失效部分。本题评估若干「改良方案」的可行性。

考虑以下三种「改良类比」方案：

方案 X：将「工程项目」替换为「生态系统管理」——生态系统没有明确「完成」状态，功能由进化动力学而非设计决定，非线性不可消除；三条失效边界或许在这个类比中同时成立。

方案 Y：将「绩效归因」精确化为「Shapley 值分配」——博弈论的 Shapley 值给出了联盟博弈中每个参与者的公平贡献，数学上更严格，可能比梯度类比更准确。

方案 Z：放弃「管理」隐喻，转向「进化」隐喻——训练 = 选择压力，神经元 = 物种，涌现功能 = 自然选择结果；这一类比天然包含「无预设目标」和「非凸搜索」。

对每个方案：(i) 指出该方案解决了原类比的哪条失效边界；(ii) 指出该方案引入了什么新的假设或问题；(iii) 总体评价：是「有效改良」还是「引入了等量或更多的新问题」。

教学注：改良类比是科学进步的常规路径——牛顿力学类比失效之处引出量子力学，热力学类比失效之处引出统计力学。评估改良方案需要同时看「它解决了什么」和「它引入了什么」。

陷阱：方案 X 引入了「生态系统」的所有复杂性(食物链、共进化、外部冲击)，使类比变得更难操作而非更清晰；类比的值在于简化，过于复杂的类比失去了教学/启

发功能。

解答 §4.9

T-4.9.1【截断与收敛的数学区别】 (1) 收敛步数计算：

需要 $(1 - 0.01)^T \leq 10^{-4}$ ，即 $0.99^T \leq 10^{-4}$ 。

两边取对数： $T \ln(0.99) \leq \ln(10^{-4}) = -4 \ln 10$ 。

$$T \geq \frac{-4 \ln 10}{\ln 0.99} = \frac{4 \times 2.3026}{0.01005} \approx \frac{9.2103}{0.01005} \approx 916$$

即需要 $T = 916$ 步（精确值： $T = \lceil 916.0 \rceil = 916$ ）。

注： $\ln(0.99) \approx -0.01005$ ， $-4 \ln 10 \approx -9.2103$ ， $T \geq 9.2103/0.01005 \approx 916.4$ ，取整为 917 步。

精确计算： $T = \lceil \ln(10^{-4}) / \ln(0.99) \rceil = \lceil -9.2103 / (-0.010050) \rceil = \lceil 916.5 \rceil = 917$ 。

(2) 正确选项：(B)。对一般非凸函数，梯度下降（在合适步长下）收敛到驻点（梯度消失点），但不保证是全局甚至局部最小值。

(3) 一句话总结：训练停止是基于「验证损失不再下降」或「计算预算耗尽」的截断判断，而数学收敛要求存在极限 $\lim_{t \rightarrow \infty} \theta_t = \theta^*$ 且 θ^* 满足最优性条件——前者是工程决策，后者是数学事实，两者在非凸问题中一般不等价。

Sanity check：917 步对应条件数 $L/\mu = 100$ 的强凸问题——这已经是相当温和的情况；深度学习的有效「条件数」远大于 100，实际需要的步数是此量级的若干数量级倍。

T-4.9.2【功能涌现与事后语义】 (1) 工程类比的失效：工程管理隐喻将神经元类比为「功能模块」，预设了每个模块在设计时就有固定功能定义；但神经元 z 的语义由训练动力学事后决定，在设计阶段无从规范。类比在此处失效：「该神经元负责 X 功能」这样的陈述在训练前无意义，训练后又因 polysemanticity 变得模糊——无法套用「功能模块的职责清晰」这一工程假设。

(2) 逻辑跳跃分析：该论断犯了两处逻辑跳跃：- 跳跃一：从「polysemanticity 存在」跳到「功能模块化假设全面失效」——polysemanticity 只说明单个神经元不是干净的功能模块，但网络层级、电路（circuit）级别的功能模块化仍可能部分成立（mechanistic interpretability 的研究发现确实存在功能电路）。- 跳跃二：从「功能模块化假设有问题」跳到「反向传播 $\leftrightarrow$ 绩效归因类比完全失效」——链式法则的线性叠加性质独立于功能模块化假设，两者是不同层次的主张；即使功能模块化失效，梯度的线性分解仍然精确成立。

(3) 思想实验：设想一个咨询公司，完全没有事先分配职责，员工自由协作完成项目，事后回顾时发现某员工「实际上承担了法律风险识别功能」但这从未被设计或规定——这与神经元语义涌现结构相似。本质差异：真实工程管理中，「事后归因」后会

立即将其转化为「事前规范」(写入职位说明书),而神经网络无法通过修改「职位说明书」改变神经元的动力学行为——涌现功能不能被锁定或精确复制。

Sanity check: (2) 的两处逻辑跳跃是独立的,指出其中一处不足以完整回答,需两处均指出。

T-4.9.3 【非凸性：利用还是控制】 (1) 凸规划的价值：凸优化保证了 (a) 唯一全局最优解 (严格凸时) 或连通的最优解集; (b) 多项式时间算法 (如内点法) 有严格的收敛率保证; (c) 对偶理论提供最优性的必要充分条件 (KKT 条件), 使验证「已达到最优」成为可能——这是工程设计能给出「完成」保证的数学基础。

(2) 正确选项：(D)。深度学习的成功依赖非凸景观的良性几何性质 (过参数化下极小值流形的连通性、宽平坦极小值的泛化性), 而非消除非凸性。(A) 是近似成立的渐近命题, 不是精确事实; (B) 和 (C) 都是错误的。

(3) 论断分析：不成立。该论断混淆了两个层次：

- 层次一：「找到损失函数的全局最小值」——对于固定的非凸损失函数, 这是 NP-hard 问题, 任何确定性算法在最坏情况下无法多项式时间内解决, 与技术进步无关。
- 层次二：「修改损失函数使其成为凸函数」——这在原则上可行, 但会根本改变深度学习的本质：凸化通常意味着放弃非线性激活函数或深层结构, 退化为核方法或广义线性模型; 代价是失去特征学习能力, 得不偿失。

论断混淆了「在既有非凸框架内改善优化」和「改变框架使其变成凸框架」——后者不是技术进步, 而是放弃了深度学习的核心优势。

Sanity check: (2) 选 (D) 是本节核心论点的直接体现; (3) 的两个层次区分是此题的评分关键。

T-4.9.4 【三条失效边界的根因分析】 (1) 对应工程假设：

失效边界	对应工程假设	深度学习中的状态
截断 $\neq$ 收敛	任务有明确的「完成」验收标准	不成立：损失函数在非凸景观上没有普遍可达的全局最优, 停止是工程决策
功能涌现非预先设计	模块功能由设计者事前规范	不成立：神经元语义由训练动力学事后决定, 无法事前精确规范
非凸性不可消除	优化问题可转化为凸规划, 具有全局保证	以弱化形式成立：过参数化下极小值质量趋同, 但非凸性本身无法消除, 只能「利用」

(2) 技术局限 vs 原理性限制：

- **截断 $\neq$ 收敛：原理性限制。**非凸优化的 NP 难度是计算复杂度理论的结论, 不随算法改进而改变; 何时「足够好」是语境依赖的价值判断, 无法被技术客观解决。

- **功能涌现非预先设计：原理性限制**（但可部分缓解）。训练动力学决定语义是梯度下降的数学结构决定的；可解释性技术可以事后理解语义，但无法使网络在训练前就具有设计者预设的神经元功能。
- **非凸性不可消除：原理性限制**。深层非线性网络的非凸性来自网络结构本身（多层权重乘积），消除非凸性意味着消除非线性或深层结构——这是深度学习的本质特征，不是可绕过的实现细节。

(3) 失效边界的认识论价值：

类比是认识新领域的脚手架，其价值在于借用熟悉域的直觉在陌生域中快速建立框架；但脚手架的本质是临时的——如果不拆除类比中不成立的部分，错误的直觉会比没有类比更危险，因为它会以「合理」的外表掩盖根本性错误。指出失效边界不是否定类比的价值，而是将类比从「直觉来源」升级为「受控工具」：在有效域内使用，在失效边界处停止，不做越界推论。从认识论角度，每一条清晰的失效边界都给出了「下一层理解所需的新概念」，是知识进步的路标——截断 $\neq$ 收敛指向「优化理论」，功能涌现指向「可解释性科学」，非凸性利用指向「景观几何学」。

Sanity check： 三条失效边界中两条是「原理性限制」，一条是「部分原理性」，这与 §4.8 中类比评级（两个「结构类比」、一个「松散隐喻」）的梯度一致。

T-4.9.5 【「改良类比」的可行性】 方案 X（生态系统管理）：

- 解决了三条失效边界：生态系统无明确「完成」，物种功能由进化决定（事后），生态动力学高度非凸/非线性。
- 引入的新问题：生态系统管理包含「人为干预 vs 自然演替」的二元性，与神经网络训练的「全程梯度控制」不符；「适应度」概念的测量争议（类比「损失函数选择」问题，但引入了额外的模糊性）；生态系统的多稳态（bistability）机制与神经网络极小值流形的拓扑性质不同。
- 评价：引入了等量新问题。生态系统类比更自然地包含三条失效边界，但同时引入了新的不对应点，且比工程管理类比更难操作（生态学概念对大多数读者更陌生，降低了类比的教学价值）。

方案 Y（Shapley 值分配）：

- 改善了失效边界 2（功能涌现）：Shapley 值是博弈论中定义的严格归因框架，可以处理「参与者联合贡献不可分」的情况；相比梯度，Shapley 值对特征交互的处理更准确。
- 引入的新问题：Shapley 值计算复杂度指数增长 ($O(2^n)$)，实践中只能近似；更重要的是，Shapley 值是针对输入特征的归因（解释性工具），而非针对优化过程的动力学描述——它改变了类比的层次，不再是「优化 $\leftrightarrow$ 管理」而是「决策归因 $\leftrightarrow$ 绩效归因」。
- 评价：有效改良（局部）。在「可解释性归因」这一子问题上更严格的类比，但不能替代整个优化过程的工程管理类比，是补充而非替换。

方案 Z（进化隐喻）：

- 解决了失效边界 1（无「完成」状态）和 2（功能涌现非预先设计）；对失效边界

3（非凸性）也有自然类比（进化景观中的多峰适应度地形）。

- (ii) 引入的新问题：进化是无梯度的随机搜索，而训练是基于梯度的确定性（或随机梯度）过程；进化的选择单元是个体，神经网络的「更新单元」是梯度步——单元不对应；进化没有「反向传播」的信息传递机制，无法类比信用分配（credit assignment）。
- (iii) 评价：**有效改良（整体框架）但引入新的核心不对应**。进化隐喻更自然地处理三条失效边界，但丢失了梯度信息传播的结构（这是深度学习最核心的计算特征之一），相当于用更合适的宏观图像替代了不合适的微观图像——宏观改善但微观失真，取决于教学目标如何选择。

Sanity check：三个方案分别对应「整体替换」「局部精化」「框架替换」三种改良策略，覆盖了类比改良的主要方向，体现了系统性思考。

§ 5.9 将把类似的「类比成立与失效边界」分析方法应用到「相变」叙事，处理一个从物理学借鉴而来的完全不同的跨界映射。

第 5 章 · 标度律、相变与涌现

§ 5.1 尺度律：Kaplan 三幂律

本节覆盖三条单变量幂律（参数律、数据律、算力律）、双对数线性化、幂律 vs 指数律的渐近对比，以及 Hoffmann 联合损失函数的结构与极限行为。共 6 个公式。

小节导读 · 公式从哪里来

尺度律不是”拟合出来的经验公式”，是从”损失随某个量变化的几何结构”推出的。为什么是幂律而不是指数、为什么双对数会线性、为什么三个单变量律能拼成联合损失函数——本节回答这三个问题。

第一步：为什么是幂律。考虑”参数翻倍”这件事。如果损失 L 减少量只依赖于参数的”倍数”而不依赖于绝对量，那么 $L(N) = L(\alpha N) \cdot c(\alpha)$ ——这个函数方程的唯一解是幂律 $L(N) = AN^{-\alpha}$ 。指数律 e^{-N} 会被任何多项式压坏，能在 1B-2B 上看到”翻倍有限提升”的只能是幂律。

第二步：双对数为什么线性。取对数： $\log L = \log A - \alpha \log N$ 。这是 $\log N$ 与 $\log L$ 的一次函数。在双对数坐标系里一条直线有三个价值：斜率是幂律指数 α 、截距是常数 $\log A$ 、偏离直线的点是需要解释的异常。Kaplan 原文里的三张尺度律图都是双对数直线。

第三步：三条单变量律为什么能拼成联合损失。单变量律只在”其他量远超够”时成立： $L(N)$ 要求 D 、算力 C 都充足。Hoffmann 提出联合拟合 $L(N, D) = E + A/N^\alpha + B/D^\beta$ ——三项分别代表不可约损失、参数不足损失、数据不足损失。任一项充热都会压住总损失，完美解释了”只增大模型不增数据会撞墙”。

第四步：极限行为是”不可约损失 E ”。当 $N, D \rightarrow \infty$ 时， $L \rightarrow E$ 。这个 E 不是 0——是语言本身的香农熵上限。这也是为什么 GPT-5 时代”损失还能降，但边际收益越来越小”：你在逐步贴近 E 、改进随指数律衰减。

本节要拿走的一件事：幂律不是偶然，是”损失随倍数变化”这个几何约束逆推出的唯一解；三项联合损失把所有”能被扩大的项”与”不可约的背景”分开。

公式 1 · Kaplan 参数律

$$L(N) \approx \left(\frac{N_c}{N}\right)^{\alpha_N}, \quad \alpha_N \approx 0.076$$

其中 N 为非嵌入参数量， N_c 为拟合常数。

一句话直觉：参数量每翻倍，loss 下降约 5%；在双对数坐标下这是一条斜率 $-\alpha_N$ 的直线。

在大模型里的位置：训练（loss 计算 / 梯度回传 / 数据-参数配比）

常见卡点：- 对数变换后底数不统一（ $\ln$ 与 $\log_{10}$ 混用）- 将 α_N 与斜率 $-\alpha_N$ 混淆（双对数图斜率是负的）- 幂律”永不截断”与指数律”快速归零”的渐近差异搞反

本组在练什么：把幂律写成双对数线性形式，读出斜率，代入数值。做完应能回答：双对数图上，loss 随参数量增大的直线斜率是多少？

T-5.1.1 【易·对数变换·双对数线性化】 对参数律 $L(N) = (N_c/N)^{\alpha_N}$ ，令 $x = \ln N$ ， $y = \ln L$ 。

- 把 y 写成 x 的线性函数，给出斜率和截距；
- 双对数图上，参数量从 10^9 增大到 10^{10} ，若量得 loss 从 3.0 降至 2.4 (nats/token)，估算 $\hat{\alpha}_N$ （用 $\log_{10}$ 端点公式）；
- 你的估算值与 Kaplan 报告的 $\alpha_N \approx 0.076$ 相比偏大还是偏小？给出一个可能的解释（一句话）。

解答 T-5.1.1

- 对 $L(N) = (N_c/N)^{\alpha_N}$ 两边取自然对数：

$$\ln L = \alpha_N \ln N_c - \alpha_N \ln N$$

令 $x = \ln N$ ， $y = \ln L$ ，则 $y = -\alpha_N \cdot x + \alpha_N \ln N_c$ 。斜率 $= -\alpha_N < 0$ （loss 随参数量增大而下降）；截距 $= \alpha_N \ln N_c$ （取决于拟合常数 N_c ）。

- 用 $\log_{10}$ 端点斜率公式（两轴均取 $\log_{10}$ ）：

$$\hat{m} = \frac{\log_{10}(2.4) - \log_{10}(3.0)}{\log_{10}(10^{10}) - \log_{10}(10^9)} = \frac{\log_{10}(0.8)}{1} \approx -0.0969$$

故 $\hat{\alpha}_N = 0.097$ （斜率绝对值）。

- (c) $\hat{\alpha}_N \approx 0.097 > 0.076$, 偏大。可能原因: 仅用两个相邻实验点做单段估计, 容易因局部噪声或模型架构改进而偏高, Kaplan 的 0.076 是跨 7 个数量级的全局拟合结果。

T-5.1.2【易·代入·预期 loss 计算】 设 $N_c = 8.8 \times 10^{13}$, $\alpha_N = 0.076$ 。

- (a) 计算 $N = 10^9$ 时的 $L(N)$ (保留 3 位有效数字);
 (b) 计算 $N = 10^{11}$ 时的 $L(N)$;
 (c) 写出一般公式: 参数量增大 k 倍, loss 乘以多少? 代入 $k = 100$ 验证 (a)(b) 的比值。

解答 T-5.1.2

(a) $L(10^9) = (8.8 \times 10^{13}/10^9)^{0.076} = (8.8 \times 10^4)^{0.076}$ 。

$$\ln(8.8 \times 10^4) = \ln 8.8 + 4 \ln 10 \approx 2.175 + 9.210 = 11.385,$$

$$L = e^{0.076 \times 11.385} = e^{0.865} \approx 2.38。$$

(b) $L(10^{11}) = (8.8 \times 10^{13}/10^{11})^{0.076} = (880)^{0.076}$ 。

$$\ln 880 \approx 6.780, L = e^{0.076 \times 6.780} = e^{0.515} \approx 1.67。$$

- (c) 一般公式: 参数量增大 k 倍, loss 乘以 $k^{-\alpha_N}$ 。验证: $k = 100$ 倍时, loss 比值 $= 100^{-0.076} = e^{-0.076 \times 4.605} = e^{-0.350} \approx 0.705$, 与 $1.67/2.38 \approx 0.702$ 吻合 (误差来自计算精度)。

T-5.1.3【中·判错·双对数图斜率的误读】 某同学在双对数坐标纸上做线性回归, 得到斜率为 +0.076, 于是报告“参数律的幂指数 $\alpha_N = 0.076$, 说明参数量增大, loss 也增大”。

- (a) 指出该结论的错误所在, 给出正确说法;
 (b) 若将 $\log_{10}$ 轴改为 $\ln$ 轴, 斜率数值会怎样变化? 给出换算关系;
 (c) 若双对数图 (以 10 为底) 斜率为 -0.07, 对应的幂指数 α_N 是多少?

解答 T-5.1.3

- (a) 正确说法: 双对数图的斜率是 $-\alpha_N$ (负号, 因为 loss 随 N 增大而下降)。斜率 +0.076 意味着幂指数为 -0.076——loss 随参数量增大而下降, 不是增大。该同学把斜率的符号搞反了。
 (b) 若用 $\ln$ 代替 $\log_{10}$, 斜率的绝对值不变 (幂指数与对数底数无关), 两轴等比例扩大, 斜率数值不变。换言之: 斜率的绝对值 $= \alpha_N$, 与对数底数选择无关。
 (c) $\log_{10}$ 坐标下斜率为 -0.07, 则 $\alpha_N = 0.07$ (因为两轴均为 $\log_{10}$, 斜率就等于 $-\alpha_N$)。

公式 2 · Kaplan 数据律与算力律

$$L(D) \approx \left(\frac{D_c}{D}\right)^{\alpha_D}, \quad \alpha_D \approx 0.095; \quad L(C) \approx \left(\frac{C_c}{C}\right)^{\alpha_C}, \quad \alpha_C \approx 0.050$$

三条幂律中，数据律斜率最陡 (α_D 最大)，算力律最平缓 (α_C 最小)。

一句话直觉：给定同倍增长，token 数的边际回报最高，总算力的边际回报最低。

在大模型里的位置：训练 (loss 计算 / 梯度回传 / 数据-参数配比)

常见卡点：- 混淆三条律的幂指数大小关系 ($\alpha_D > \alpha_N > \alpha_C$) - 算力律中 $C = 6ND$, α_C 是联合扩展的结果，不是独立的”第三变量”

本组在练什么：对比三条幂律的斜率，判断哪种资源的边际回报最高；理解算力律与参数律/数据律的关系。做完应能回答：同样翻倍算力，三种分配方式（全给 N 、全给 D 、同时扩展）哪种最划算？

T-5.1.4【易·对比·三条幂律的斜率排序】 已知 $\alpha_N \approx 0.076$, $\alpha_D \approx 0.095$, $\alpha_C \approx 0.050$ 。

- 三条幂律中，哪种资源翻倍能使 loss 下降最多？哪种最少？
- 数据量翻倍 ($D \rightarrow 2D$) 和参数量翻倍 ($N \rightarrow 2N$) 相比，loss 各下降多少比例？
- 为什么 $\alpha_C < \alpha_N$ (算力律比参数律更平缓)？提示： $C = 6ND$ ，在固定比例同时扩展 N 和 D 时， α_C 与 α_N , α_D 的关系是什么（定性分析即可）？

解答 T-5.1.4

- 比较 $\alpha_D \approx 0.095 > \alpha_N \approx 0.076 > \alpha_C \approx 0.050$ ：数据量翻倍 ($D \rightarrow 2D$) loss 最多下降： $\Delta L = 1 - 2^{-0.095} \approx 6.4\%$ ；参数量翻倍 ($N \rightarrow 2N$) 次之： $1 - 2^{-0.076} \approx 5.1\%$ ；总算力翻倍（联合扩展）最少： $1 - 2^{-0.050} \approx 3.4\%$ 。
- 数据量翻倍 loss 下降约 6.4%，参数量翻倍 loss 下降约 5.1%；数据的边际回报约比参数高 25%（在 Kaplan 幂指数下）。
- $\alpha_C < \alpha_N$ 的原因：算力律 $L(C)$ 描述的是同时扩展 N 和 D （约束 $C = 6ND$ ）时的 loss 改善。在最优配比下，loss 的改善受制于两个维度的联合瓶颈。定性上， α_C 是 α_N 和 α_D 的调和均值形式 ($\alpha_C \approx \alpha_N \alpha_D / (\alpha_N + \alpha_D)$)，故必然小于两者。

T-5.1.5【中·线性回归·log-log 拟合与外推】 下表给出三组实验测量（以 $\log_{10}$ 为底）：

$\log_{10} N$	$\log_{10} L$
8	0.58
9	0.51
10	0.44

- 用最小二乘法（三点）估计斜率 $\hat{m}$ 和截距 $\hat{b}$ ；

- (b) 斜率 $\hat{m}$ 与 $-\alpha_N$ 的关系是什么（两轴均用 $\log_{10}$ ）？算出 $\hat{\alpha}_N$ ；
 (c) 外推：当 $\log_{10} N = 12$ （万亿参数）时，预测 L （nats/token）。

解答 T-5.1.5

- (a) 三点 $(x = 8, 9, 10, y = 0.58, 0.51, 0.44)$ ：
 $\bar{x} = 9, \bar{y} = 0.51$ 。

$$\hat{m} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{(-1)(0.07) + 0 + (1)(-0.07)}{1 + 0 + 1} = \frac{-0.14}{2} = -0.07$$

截距： $\hat{b} = 0.51 - (-0.07)(9) = 0.51 + 0.63 = 1.14$ 。

- (b) 两轴均为 $\log_{10}$ ，斜率 $\hat{m} = -\alpha_N$ ，故 $\hat{\alpha}_N = 0.07$ （无需底数换算）。
 (c) 外推 $\log_{10} N = 12$ ： $\log_{10} L = -0.07 \times 12 + 1.14 = -0.84 + 1.14 = 0.30$ 。
 故 $L = 10^{0.30} \approx 2.0$ nats/token。

公式 3 · 幂律 vs 指数律的渐近比较

$$\lim_{x \rightarrow \infty} \frac{x^{-\alpha}}{e^{-\lambda x}} = \lim_{x \rightarrow \infty} x^{-\alpha} e^{\lambda x} = +\infty, \quad \alpha, \lambda > 0$$

即指数律比任意幂律衰减更快；双对数坐标下，幂律是直线，指数律是向下弯曲的曲线。

一句话直觉：“幂律收益”永不截断”，指数律收益最终归零——这是为何语言自相似结构支持幂律。

在大模型里的位置：训练（loss 计算 / 梯度回传 / 数据-参数配比）

常见卡点：- 极限计算中应用 L' Hôpital 或直接比阶 - 双对数坐标下指数律的曲线形态（向下弯，不是直线）

本组在练什么：证明幂律和指数律的渐近差异，并在双对数图上画出两者形态。做完应能回答：为什么双对数图上“偏离直线向下弯曲”预示着收益比幂律更快衰减？

T-5.1.6 【难 · 画图直觉 · 双对数图上的幂律直线】 请在草稿区粗略画出双对数坐标 $(\log N, \log L)$ 上的以下内容：

- (a) Kaplan 参数律直线（斜率约 -0.076 ）与指数律 $g(N) = e^{-\lambda N}$ ($\lambda > 0$) 的大致形状，标出关键区别；
 (b) 证明：对任意 $\alpha, \lambda > 0$, $\lim_{N \rightarrow \infty} N^{-\alpha} e^{\lambda N} = +\infty$ ，说明指数律比幂律衰减更快；
 (c) 若实验点偏离直线（向下弯曲），这预示着 loss 衰减比幂律更快还是更慢？对应什么物理含义？

解答 T-5.1.6

(a) 草图要点:

- 幂律 $f(N) = N^{-\alpha}$: 双对数坐标下为直线, 斜率 $-\alpha < 0$, 一直向右延伸。
- 指数律 $g(N) = e^{-\lambda N}$: $\log g = -\lambda N \cdot \log e$, 在 $(\log N, \log g)$ 坐标下 $N = e^x$, $\log g = -\lambda e^x \cdot \log e$, 随 x 增大指数式急剧下降, 曲线向右急剧下弯, 最终趋向 $-\infty$ 。
- 两者区别: 幂律是直线 (缓慢), 指数律向下弯曲 (快速归零)。

(b) 证明: 对任意 $\alpha, \lambda > 0$,

$$\lim_{N \rightarrow \infty} \frac{N^{-\alpha}}{e^{-\lambda N}} = \lim_{N \rightarrow \infty} \frac{e^{\lambda N}}{N^{\alpha}}$$

令 $N \rightarrow \infty$, 分子指数增长, 分母多项式增长, 指数主导, 极限 $= +\infty$ 。故 $e^{-\lambda N} \rightarrow 0$ 的速度比 $N^{-\alpha} \rightarrow 0$ 快得多, 即指数律比幂律衰减更快。

(c) 若实验点偏离直线向下弯曲, 说明 loss 的衰减比幂律更快, 预示着某种比幂律更强的改善机制 (例如数据质量突然提升、模型架构改进、或接近饱和区域)。反之若点向上弯, 衰减比幂律更慢, 预示扩展边际收益递减、接近不可归约损失 E 。

[工程批注] T-5.1.6 画图工程注记: 实践中, log-log 坐标下的直线外推 (即幂律外推) 是 LLM scaling 实验室的核心预测工具。Kaplan et al. (2020) 在 OpenAI 的早期 scaling 实验里, 就是在双对数纸上做线性回归, 然后外推预测更大模型的 loss——这让“训练 GPT-3 之前就能估算其 loss”成为可能。2024 年后的实践: 由于接近数据墙 (D 有上限), $L(D)$ 的曲线在大模型时代往往偏离直线向上弯, 提示 B/D^{β} 项不再可忽略, 需要联合优化框架 (Hoffmann) 而非单变量外推。

公式 4 · Hoffmann 联合损失函数

$$L(N, D) = E + \frac{A}{N^{\alpha}} + \frac{B}{D^{\beta}}$$

其中 E 为不可归约损失 (语言熵下界), A/N^{α} 刻画参数不足, B/D^{β} 刻画数据不足。

一句话直觉: loss 由三项叠加, 各自独立可优化; E 是硬下界, 两个欠拟合项由参数和数据预算决定。

在大模型里的位置: 训练 (loss 计算 / 梯度回传 / 数据-参数配比)

常见卡点: - 混淆 Kaplan 的 $\alpha_N \approx 0.076$ 和 Hoffmann 的 $\alpha \approx 0.34$ - E 不可被优化到 0, 它是语言的信息论下界

本组在练什么: 理解联合损失的三项结构、极限行为和偏导方向。做完应能回答: 什么是不可归约损失? 两项偏导绝对值哪个更大意味着什么?

T-5.1.7【易·极限·不可归约损失的信息论意义】 考虑 $L(N, D) = E + A/N^\alpha + B/D^\beta$ 。

- 计算 $\lim_{N \rightarrow \infty, D \rightarrow \infty} L(N, D)$;
- 用一句话解释 E 的信息论含义 (提示: 语言本身的条件熵下界);
- 若某超大模型实测 loss 为 2.3 nats/token, 真实语言熵约 $H = 2.1$ nats/token, 此时 $A/N^\alpha + B/D^\beta$ 还剩多少? 对应的困惑度差距 $e^{2.3}/e^{2.1}$ 是多少?

解答 T-5.1.7

- $\lim_{N \rightarrow \infty, D \rightarrow \infty} L(N, D) = E + 0 + 0 = E$ 。
- E 是不可归约损失 (irreducible loss), 等于语言本身的真实条件熵下界: 即使有无限参数和无限数据, 模型仍无法预测语言中真正不确定的部分 (如同义词选择、风格变换等)。从信息论角度, $E \geq H$ (真实语言条件熵)。
- 剩余可减少损失: $A/N^\alpha + B/D^\beta = 2.3 - 2.1 = 0.2$ nats/token。

困惑度差距: $e^{2.3}/e^{2.1} = e^{0.2} \approx 1.22$, 即 PPL 仍可再降低约 18%——还有进一步优化的空间。

T-5.1.8【中·偏导·哪条律的边际收益更大】 设 $\alpha = 0.076$, $\beta = 0.095$, $A = B = 1$, $E = 0$, 当前 $N = D = 10^{10}$ 。

- 分别计算 $|\partial L / \partial N|$ 和 $|\partial L / \partial D|$;
- 若此时只能增加一种资源, 哪种边际收益更大?
- Kaplan 时代的”参数优先”策略与 (b) 的结论是否矛盾? 从联合约束 $C = 6ND$ 的角度解释 (2 句话)。

解答 T-5.1.8

- $\alpha = 0.076$, $A = 1$, $N = 10^{10}$:

$$\left| \frac{\partial L}{\partial N} \right| = \frac{\alpha A}{N^{\alpha+1}} = \frac{0.076}{(10^{10})^{1.076}} = \frac{0.076}{10^{10.76}} \approx \frac{0.076}{5.75 \times 10^{10}} \approx 1.32 \times 10^{-12}$$

$\beta = 0.095$, $B = 1$, $D = 10^{10}$:

$$\left| \frac{\partial L}{\partial D} \right| = \frac{\beta B}{D^{\beta+1}} = \frac{0.095}{10^{10.095}} = \frac{0.095}{10^{10.095}} \approx \frac{0.095}{8.91 \times 10^{10}} \approx 1.07 \times 10^{-12}$$

两者量级相近, $|\partial L / \partial N| \approx 1.32 \times 10^{-12}$ 略大于 $|\partial L / \partial D| \approx 1.07 \times 10^{-12}$ 。

- 增加参数量的边际收益略大 (约大 23%)。
- 不矛盾, 但结论需小心: Kaplan 时代的”参数优先”是在固定算力 $C = 6ND$ 的约束下观察到的——在单独增大 N 时收益看起来更显著。但联合约束下, N 和 D 必须同步调整; Chinchilla 指出, 在约束 C 固定的条件下, Kaplan 时代模型严重偏向参数, 数据被严重低配, 修正后两者应同等扩展 (1:20 的比例)。偏导单独比大小, 不能替代联合拉格朗日优化的结论。

[工程批注] T-5.1.8 工程批注：Kaplan 2020 的”参数优先”与 Chinchilla 2022 的”1:20 配比”差异，核心在于实验设计。Kaplan 的实验在每个算力预算下只训练一组 (N, D) ，且训练 token 数远少于 Chinchilla 最优；Hoffmann 则在同一 C 下系统扫描了 400 组不同 (N, D) 配比，得出了更可靠的 isoFLOP 曲线。Epoch AI (2024) 进一步指出，Hoffmann 方法三（直接参数化拟合）的置信区间过窄，但方向性结论（1:20 远优于 1:5）是可复现的。2024 后续：DeepSeek-V3 实际使用了 671B 参数、约 14.8T tokens，配比约 1:22，与 Chinchilla 方向一致，但略超最优——符合推理优先的工程逻辑。

【做完自检】

1. 在双对数坐标下，幂律和指数律的曲线形态有何本质区别？斜率意味着什么？
2. Hoffmann 联合损失的三项各对应什么物理含义？哪一项是优化的下界？
3. 为什么 Kaplan 的 α_N 与 Hoffmann 的 α 数值差异悬殊（0.076 vs 0.34）？两者描述的是同一件事吗？

§ 5.2 Chinchilla: compute-optimal 配比

本节覆盖拉格朗日推导的最优配比公式、Hoffmann 三种拟合方法、置信区间的统计学根源，以及 Sardana 推理时成本修正。共 5 个公式。

小节导读 · 公式从哪里来

为什么是「等比」分配？给定算力预算 $C \approx 6ND$ （参数量乘以训练 token 数再乘以常数 6），我们要最小化损失 $L(N, D) = E + A/N^\alpha + B/D^\beta$ 。这是一个有约束的极值问题，自然落到拉格朗日乘子法。

第一步：写下拉格朗日函数。 $\mathcal{L} = L(N, D) + \lambda(C - 6ND)$ 。对 N 求偏导得 $-\alpha AN^{-\alpha-1} = 6\lambda D$ ，对 D 求偏导得 $-\beta BD^{-\beta-1} = 6\lambda N$ 。

第二步：两式相除消掉 λ 。整理得 $\frac{\alpha}{N^\alpha} \cdot \text{const} = \frac{\beta}{D^\beta} \cdot \text{const}$ 。也就是说，最优时「可降损失」的两块要同步减少——这就是 Chinchilla 的核心几何直觉。

第三步：代回约束 $C = 6ND$ 。把上一步的比例关系代入，得到 $N^* \propto C^a$ 、 $D^* \propto C^b$ ，其中 $a + b = 1$ 、 $a/b = \beta/\alpha$ 。Hoffmann 实测 $\alpha \approx \beta \approx 0.34$ ，所以 $a \approx b \approx 0.5$ ——参数和数据应当「等比放大」，这就是 Chinchilla 法则。

第四步：置信区间从哪来。Hoffmann 用三种拟合方法（IsoFLOPs、IsoLoss、参数化曲面），每种给出不同 (a, b) 估计。置信区间反映的是模型 misspecification 不确定性，不是单纯的统计误差——这也是后续争论（DeepMind vs Sardana）的根源。

第五步：Sardana 修正是怎么进来的。如果训练成本 $C_{\text{train}} = 6ND$ 之外还要计入推理成本 $C_{\text{inf}} \propto N \cdot T_{\text{tokens served}}$ ，约束变成 $C_{\text{total}} = 6ND + kNT$ 。再做一次拉格朗日，最优 N 会向更小的方向偏移——「服务用户越多，模型应当越小」。

本节要拿走的一件事：Chinchilla 不是经验法则，而是带约束最优化的必然结果；推理成本一旦进入目标函数，最优解就会移动。

公式 5 · Kaplan–Chinchilla FLOPs 近似

$$C \approx 6ND$$

每个参数在一次训练 token 的前向 + 反向中贡献约 6 次乘加（前向 2、反向 4）。

一句话直觉：算力预算等于参数量乘 token 数乘 6，这是 Transformer 训练的标准估算式。

在大模型里的位置：训练（loss 计算 / 梯度回传 / 数据-参数配比）

常见卡点：- 忘记系数 6（有时见到 2 或 4，取决于是否只算前向）- 与推理 FLOPs $\approx 2N$ 混淆（推理只有前向，无梯度）

本组在练什么：用 $C = 6ND$ 双向换算。做完应能回答： 10^{23} FLOPs 算力预算下，按 Chinchilla 1:20 配比能训练多大的模型？

T-5.2.1【易 · 代入 · Kaplan vs Chinchilla 配比的数值对比】 设总算力预算 $C = 6 \times 10^{23}$ FLOPs，约束 $6N^*D^* = C$ 。

- (a) Kaplan 建议 $N^*/D^* = 1/5$ ，算出 N^* 和 D^* ；
- (b) Chinchilla 建议 $N^*/D^* = 1/20$ ，算出 N^* 和 D^* ；
- (c) 两种配比的 N^* 相差几倍？哪种配比的模型更小但训练 token 更多？

解答 T-5.2.1 约束 $6N^*D^* = 6 \times 10^{23}$ ，即 $N^*D^* = 10^{23}$ 。

- (a) Kaplan: $D^* = 5N^*$ ，代入 $5(N^*)^2 = 10^{23}$ ：

$$N^* = \sqrt{2 \times 10^{22}} \approx 1.41 \times 10^{11}, \quad D^* \approx 7.07 \times 10^{11}$$

- (b) Chinchilla: $D^* = 20N^*$ ，代入 $20(N^*)^2 = 10^{23}$ ：

$$N^* = \sqrt{5 \times 10^{21}} \approx 7.07 \times 10^{10}, \quad D^* \approx 1.41 \times 10^{12}$$

- (c) $N_{\text{Kaplan}}^*/N_{\text{Chinchilla}}^* = 1.41 \times 10^{11}/7.07 \times 10^{10} = 2$ 倍。Chinchilla 配比的模型更小（参数少约 2 倍），但训练 token 更多（约 2 倍）。

T-5.2.2【易 · 工程 · LLaMA-3 8B 的”超量训练”解读】 Chinchilla 的 1:20 规则：每个参数对应约 20 个训练 token。

- (a) 按此规则，LLaMA-3 8B ($N = 8 \times 10^9$) 的 Chinchilla 最优 token 数是多少？
- (b) LLaMA-3 8B 实际使用了约 15T (1.5×10^{13}) tokens，是 Chinchilla 最优量的多少倍？
- (c) 用 Sardana 修正框架解释：在推理调用量极大的部署场景下，为何 15T tokens 训练 8B 模型是合理的工程选择（2 句话）？

解答 T-5.2.2

- (a) Chinchilla 最优: $D^* = 20 \times 8 \times 10^9 = 1.6 \times 10^{11} = 160\text{B tokens}$ 。
- (b) 实际倍数: $1.5 \times 10^{13} / 1.6 \times 10^{11} \approx 93.75 \approx 94$ 倍——实际训练量约是 Chinchilla 最优的 94 倍。
- (c) 根据 Sardana 修正: LLaMA-3 8B 被设计用于大规模商业部署, 推理调用量远超 $n_{\text{inf}} \gg 3D$ 的阈值, 推理成本主导总预算。在推理优先的场景下, 应选更小的 N 并超量训练数据——通过 15T tokens “压榨” 8B 参数的极限, 而非改用 70B 模型节省数据但增大每次推理成本。

[工程批注] T-5.2.2 工程批注: LLaMA-3 8B 超量训练背后是 Sardana et al. (ICML 2024) 的”推理优先”框架。公式上: 当 $n_{\text{inf}} \times 2N > 6ND$ (即 $n_{\text{inf}} > 3D$), 推理成本超过训练成本。对于 LLaMA-3 8B, 若全球每天推理 10 亿次、运行 3 年, 则 $n_{\text{inf}} \sim 10^{12}$, 而训练的 $D = 1.5 \times 10^{13}$, 使得 $n_{\text{inf}}/(3D) \approx 0.022$ ——此时推理成本约为训练成本的 2%, 但随着规模增大会持续累积。

公式 6 · Compute-optimal 最优配比 (拉格朗日条件)

$$\frac{\alpha A}{N^\alpha} = \frac{\beta B}{D^\beta}$$

即在最优点处, 参数项与数据项对损失的边际贡献 (加权后) 相等。

一句话直觉: 最优时两种资源的”性价比”相等, 多哪边都是浪费。

在大模型里的位置: 训练 (loss 计算 / 梯度回传 / 数据-参数配比)

常见卡点: - 拉格朗日函数的符号 (λ 的正负取决于约束写法, 但最终条件不变) - 消去 λ 时分子分母乘除顺序

本组在练什么: 从第一原理推出最优配比条件, 理解”两项边际贡献相等”的经济学直觉。做完应能回答: 为什么最优时参数项和数据项的边际贡献必须相等?

T-5.2.3 【中 · 推导 · 拉格朗日一阶条件】 在约束 $6ND = C$ 下最小化 $L(N, D) = E + A/N^\alpha + B/D^\beta$ 。

- (a) 写出拉格朗日函数 $\mathcal{L}(N, D, \lambda)$;
- (b) 对 N 和 D 分别求偏导令为零, 写出两个方程;
- (c) 消去 λ , 推出最优条件 $\alpha A/N^\alpha = \beta B/D^\beta$ 。

解答 T-5.2.3

- (a) 拉格朗日函数 (将约束写为等式 $6ND - C = 0$):

$$\mathcal{L}(N, D, \lambda) = E + \frac{A}{N^\alpha} + \frac{B}{D^\beta} - \lambda(6ND - C)$$

(b) 对 N 求偏导令为零：

$$\frac{\partial \mathcal{L}}{\partial N} = -\frac{\alpha A}{N^{\alpha+1}} - 6\lambda D = 0 \implies \frac{\alpha A}{N^{\alpha+1}} = -6\lambda D \quad (1)$$

对 D 求偏导令为零：

$$\frac{\partial \mathcal{L}}{\partial D} = -\frac{\beta B}{D^{\beta+1}} - 6\lambda N = 0 \implies \frac{\beta B}{D^{\beta+1}} = -6\lambda N \quad (2)$$

(注意在最小化问题中 $\lambda < 0$ ，使等式右端为正，与左端正值匹配。)

(c) 由 (1)： $\lambda = -\alpha A / (6N^{\alpha+1}D)$ ，代入 (2)：

$$\frac{\beta B}{D^{\beta+1}} = 6N \cdot \frac{\alpha A}{6N^{\alpha+1}D} = \frac{\alpha A}{N^{\alpha}D}$$

整理：

$$\frac{\beta B}{D^{\beta}} = \frac{\alpha A}{N^{\alpha}}$$

即参数项与数据项的“加权边际贡献”相等，得证。

公式 7 · 最优配比的幂律形式

$$N^* \propto C^{\beta/(\alpha+\beta)}, \quad D^* \propto C^{\alpha/(\alpha+\beta)}$$

两个幂指数之和恰好等于 1，对应约束 $N^* D^* \propto C$ 。

一句话直觉：算力增大时，最优参数量和 token 数各自以固定幂律增长，比例由 α/β 决定。

在大模型里的位置：训练 (loss 计算 / 梯度回传 / 数据-参数配比)

常见卡点：- 幂指数分子分母搞反 (N^* 对应 β ， D^* 对应 α) - 忘记验证两指数之和为 1

本组在练什么：从最优条件出发完成代入推导，得到 N^* 和 D^* 的幂律形式，并用数值验证。做完应能回答：Hoffmann 拟合值下，算力翻倍时参数量和 token 数各应增加多少？

T-5.2.4【难·推导·最优配比的幂指数】 已知最优条件 $\alpha A / N^{\alpha} = \beta B / D^{\beta}$ ，约束 $6ND = C$ 。

(a) 从最优条件解出 D 关于 N 的表达式；

(b) 代入约束 $6ND = C$ ，推出 $N^* \propto C^{\beta/(\alpha+\beta)}$ ；

(c) 取 Hoffmann 拟合值 $\alpha = 0.34$ ， $\beta = 0.28$ ，计算 N^* 和 D^* 的幂指数，并说明为何两者之和等于 1。

解答 T-5.2.4

(a) 由最优条件 $\alpha A/N^\alpha = \beta B/D^\beta$, 解出 D :

$$D^\beta = \frac{\beta B N^\alpha}{\alpha A} \Rightarrow D = \left(\frac{\beta B}{\alpha A} \right)^{1/\beta} N^{\alpha/\beta}$$

(b) 代入约束 $6ND = C$:

$$6N \cdot \left(\frac{\beta B}{\alpha A} \right)^{1/\beta} N^{\alpha/\beta} = C \Rightarrow N^{1+\alpha/\beta} \propto C$$

$$N^{(\alpha+\beta)/\beta} \propto C \Rightarrow N^* \propto C^{\beta/(\alpha+\beta)}$$

类似可得 $D^* \propto C^{\alpha/(\alpha+\beta)}$ 。

(c) 代入 $\alpha = 0.34$, $\beta = 0.28$, $\alpha + \beta = 0.62$:

- N^* 的幂指数: $\beta/(\alpha + \beta) = 0.28/0.62 \approx 0.452$
- D^* 的幂指数: $\alpha/(\alpha + \beta) = 0.34/0.62 \approx 0.548$

两者之和 = $0.452 + 0.548 = 1$, 原因: 约束 $N^* D^* \propto C$ 要求 $\log N^* + \log D^* \propto \log C$, 即两个幂指数必须相加为 1 (乘积的幂律 = 各自幂律之和)。

公式 8 · Hoffmann 方法三协方差矩阵

$$\text{Cov}(\hat{\theta}) \approx \hat{\sigma}^2 (J^\top J)^{-1}, \quad J \in \mathbb{R}^{n \times p}$$

置信区间宽度正比于 $\hat{\sigma}/\sqrt{n}$, 但仅在 $J^\top J$ 条件数良好时成立。

一句话直觉: 参数 α 与 A 高度相关导致 $J^\top J$ 病态, $(J^\top J)^{-1}$ 对角元被低估, 置信区间因此过窄。

在大模型里的位置: 训练 (loss 计算 / 梯度回传 / 数据-参数配比)

常见卡点: - 置信区间正比于 $\hat{\sigma}/\sqrt{n}$ 只在条件数良好时成立 - 强相关参数对 $(A-\alpha, B-\beta)$ 的协方差矩阵的条件数极大

本组在练什么: 理解非线性最小二乘的协方差矩阵, 以及参数相关性对置信区间的影响。做完应能回答: 为什么要支撑 Chinchilla 那么窄的置信区间, 需要数十万个训练点?

T-5.2.5 【难 · 统计学 · Hoffmann 方法三的置信区间过窄】 Hoffmann 方法三对 $n = 400$ 个训练点做非线性最小二乘, 拟合 5 个参数 $\{E, A, \alpha, B, \beta\}$ 。

(a) 写出参数估计的渐近协方差矩阵表达式 (含雅可比矩阵 $J \in \mathbb{R}^{n \times p}$);

(b) 参数 α 与 A 在模型 A/N^α 中高度相关: 解释为什么这使 $J^\top J$ 的条件数极大, 导致 $(J^\top J)^{-1}$ 对角元被低估, 置信区间因此偏窄;

(c) 要让方法三的 CI 可信，理论上需要多少数量级的独立观测点？说明原因。

解答 T-5.2.5

(a) 非线性最小二乘的渐近协方差矩阵：

$$\text{Cov}(\hat{\theta}) \approx \hat{\sigma}^2 (J^\top J)^{-1}$$

其中 $J \in \mathbb{R}^{n \times p}$ 是损失函数关于 5 个参数 $\{E, A, \alpha, B, \beta\}$ 的雅可比矩阵， $\hat{\sigma}^2$ 是残差方差。

- (b) 在模型 A/N^α 中， A 和 α 以乘积形式进入指数表达式：若 A 增大 k 倍而 α 减小适当量， A/N^α 的数值可以基本不变。这意味着 J 的对应两列几乎共线（强相关）， $J^\top J$ 的对应 2×2 子块的行列式接近零，整个矩阵的条件数极大（可达 10^4 量级以上）。 $(J^\top J)^{-1}$ 的对角元素因此被系统性高估（数值上看似精确但实际对应不确定性的方向被挤压），报告的置信区间偏窄。
- (c) 理论上需要 $\sim 10^5$ 数量级的独立观测点。原因：5 个参数中存在 2 对强相关参数对（ A - α 和 B - β ），有效自由度远小于 $n - p = 395$ 。统计学原则：要可靠估计强相关参数的 CI，需要观测点数远超参数数量——对条件数为 κ 的问题，有效样本量需乘以 κ 。Epoch AI (2024) 的复现工作指出，Chinchilla 方法三的参数不确定性被低估了约一到两个数量级。

公式 9 · Sardana 推理时成本修正约束

$$C_{\text{train}} + n_{\text{inf}} \cdot C_{\text{inf}} \leq C_{\text{total}}, \quad C_{\text{train}} \approx 6ND, \quad C_{\text{inf}} \approx 2N$$

当 $n_{\text{inf}} \gg 3D$ 时，推理成本主导，最优解偏向更小的 N 。

一句话直觉：推理调用数十亿次时，小模型 + 超量训练比大模型 + 少量训练更省总算力。

在大模型里的位置：训练（loss 计算 / 梯度回传 / 数据-参数配比）

常见卡点：- 推理 FLOPs 是 $\approx 2N$ （前向传播），而非 $6N$ - 临界条件 $n_{\text{inf}} \gg 3D$ （由 $n_{\text{inf}} \cdot 2N > 6ND$ 化简得到）

本组在练什么：数值代入 Sardana 修正约束，判断推理成本是否已主导，以及理解工程含义。做完应能回答：推理调用多少次时，两者成本相当？

T-5.2.6 【中 · 代入 · 推理成本是否主导】 设 $N = 7 \times 10^9$ ，训练 $D = 2 \times 10^{12}$ tokens。

- (a) 计算训练总算力 $C_{\text{train}} = 6ND$ ；
- (b) 若推理调用次数 $n_{\text{inf}} = 10^9$ ，计算推理总算力 $n_{\text{inf}} \cdot 2N$ ；
- (c) 计算推理与训练成本之比；临界的 n_{inf} （使两者相等）是多少？
- (d) 若推理已主导总预算，应如何调整 N 和 D 的配比（方向性，一句话）？

解答 T-5.2.6

(a) $C_{\text{train}} = 6ND = 6 \times 7 \times 10^9 \times 2 \times 10^{12} = 8.4 \times 10^{22}$ FLOPs。

(b) 推理总算力: $n_{\text{inf}} \cdot 2N = 10^9 \times 2 \times 7 \times 10^9 = 1.4 \times 10^{19}$ FLOPs。

(c) 比值: $1.4 \times 10^{19} / 8.4 \times 10^{22} \approx 1.67 \times 10^{-4} \approx 0.017\%$ 。

推理远未主导训练成本。临界 n_{inf} (使两者相等): $n_{\text{inf}} \cdot 2N = 6ND$, 解得 $n_{\text{inf}} = 3D = 3 \times 2 \times 10^{12} = 6 \times 10^{12}$ (6 万亿次推理调用时, 两者相当)。

(d) 若推理已主导, 应缩小 N 、增大 D : 小模型每次推理 FLOPs 更少 ($C_{\text{inf}} = 2N$ 更小), 节省的算力预算可用于更多训练 token, 维持模型质量。

[工程批注] T-5.2.6 工程批注: Sardana 修正的工程直觉是”推理比训练便宜, 但次数多得多”。以一个每秒处理 1000 次请求、全年不停服务的 7B 模型为例: 年推理调用约 3.15×10^{10} 次, 推理总 FLOPs $\approx 3.15 \times 10^{10} \times 2 \times 7 \times 10^9 \approx 4.4 \times 10^{20}$, 约为训练成本 (8.4×10^{22}) 的 0.5%; 但若持续服务 3 年, 累积推理次数可达 $\sim 10^{11}$, 开始对总预算产生显著影响。

【做完自检】

1. Kaplan 的”参数优先”与 Chinchilla 的 1:20 配比, 核心分歧在哪里? 用一句话概括”Hoffmann correction”修正了什么。
2. 拉格朗日最优条件”两项边际贡献相等”, 直觉上是什么意思?
3. Sardana 修正引入推理成本后, 最优模型大小方向如何变化? LLaMA-3 8B 超量训练的背后逻辑是什么?

§ 5.3–§ 5.4 数据墙与推理时计算

本节覆盖模型崩溃的方差退化公式、推理时 Best-of-N 的等价 token 折算。共 2 个公式。

小节导读·公式从哪里来

「模型崩溃」为什么是方差问题? 当下一代模型用上一代模型的输出做训练数据时, 每一代都会从父模型采样一批有限样本。采样本身就是一种「蒙特卡罗估计」, 有限样本能估计出的分布方差是有限的。

第一步: 单代采样误差。父分布方差 σ^2 , 采 M 个样本, 子分布的均值估计方差是 σ^2/M 。这是中心极限定理的直接后果——采样越少, 子分布偏离父分布越大。

第二步: 误差在代间累加。第 n 代相对原始分布的总方差差不多是 $n \cdot \sigma^2/M$ (独立采样误差叠加)。代数 n 越大、采样 M 越小, 偏离越严重——这就是「递归训练崩溃」的数学指纹。

第三步: Best-of-N 为什么能提高质量。从模型采 N 个独立输出, 取打分最高的。如果单次输出成功率是 p , 那么 N 次里至少一次成功的概率是 $1 - (1 - p)^N$ ——几何分布的尾巴能被采样几乎确定地取到。

第四步: 推理时等价 token 折算。Best-of-N 的计算量是单次推理的 N 倍。把这些 token 「按计算量换算」到训练侧, 不变总算力下推理时采样 vs 训练时扩大参数是一场「资

源调度」博弈。

本节要拿走的一件事：模型崩溃是「有限采样代间传递」的必然结果；推理时计算本质上在重复采样以换取尾部质量，能与训练算力相互折算。

公式 10 · 模型崩溃：方差退化

$$\Sigma_n \xrightarrow{a.s.} 0 \quad \text{as } n \rightarrow \infty$$

递归训练于自身生成数据时，第 n 代输出分布的方差以概率 1 收敛到 0（分布退化）。

一句话直觉：每代采样截断尾部，多代后分布坍缩为点——合成数据不可无限循环使用。

在大模型里的位置：训练（loss 计算 / 梯度回传 / 数据-参数配比）

常见卡点：- 方差退化不等于 loss 退化（均值可能保持不变）- 模型崩溃是递归自训练的结果，不是单次合成数据的问题

本组在练什么：理解模型崩溃的数学机制（方差退化），以及其对合成数据使用的工程限制。做完应能回答：为什么合成数据不能无限递归用于训练？

T-5.3.1【易·概念·模型崩溃的方差退化】 Shumailov 等（Nature 2024）证明，若模型递归训练于自身生成数据，输出分布方差 $\Sigma_n \rightarrow 0$ 。

- (a) 用直觉解释：为什么每代采样-拟合循环会使方差减小？（提示：尾部截断）
- (b) 若方差趋于 0，生成文本会有什么特征？（创造性/多样性/单调性方向上各一句话）
- (c) 实践中如何避免模型崩溃？给出一种工程方案（一句话）。

解答 T-5.3.1

- (a) 直觉解释：每代采样-拟合循环中，模型对训练集做最大似然拟合，内隐地截断了训练分布的尾部（概率小的区域被忽略）；下一代模型在这个截断后的分布上采样，进一步截断尾部——如此迭代，分布宽度（方差 Σ_n ）不断减小，最终趋于零。
- (b) 当 $\Sigma_n \rightarrow 0$ ，生成文本的多样性将严重下降：模型只会生成高频出现的常见模式（单调性），创造力趋近于零（失去新颖性），生成内容堆叠重复、过于平调、缺乏局部多样性。
- (c) 一种工程方案：始终保持一定比例的真实人类生成文本与合成数据混合（不允许合成数据占比超过某上限，如 50%），保证每代训练分布始终有原始数据的多样性锚点。

公式 11 · Best-of-N 等价 token 折算

$$D_{\text{equiv}}(K) = \frac{C_{\text{test}}}{6N_0} = \frac{K \cdot 2N_0}{6N_0} = \frac{K}{3}$$

即每 Best-of-3 采样大约相当于额外提供 1 个训练 token 的算力。

一句话直觉：推理时多采样选优，可以”花算力买效果”——但折算率取决于任务是否可验证。

在大模型里的位置：采样（推理 / 解码 / 温度策略）

常见卡点：- 折算率 $K/3$ 基于 $C_{\text{inf}} = 2N_0$ （前向传播），而非 $6N_0$ - 可验证任务（数学/代码）兑换率高，不可验证任务（创意写作）兑换率低

本组在练什么：理解推理时算力与训练时算力的等价折算，以及任务类型对兑换率的影响。做完应能回答：Best-of-100 采样，相当于多训练了多少个 token？

T-5.3.2 【中 · 代入 · Best-of-N 的等价 token 计算】 设基础模型参数量 $N_0 = 7 \times 10^9$ ，推理时使用 Best-of- K 采样。

- 计算 $K = 3$ 时的等价 token 数 $D_{\text{equiv}}(3)$ ；
- 计算 $K = 100$ 时的等价 token 数，与原训练 token 数 $D = 2 \times 10^{12}$ 相比，折算比例是多少？
- 为什么数学题等可验证任务的推理时”兑换率”比创意写作任务更高？（2 句话，提示：验证信号的有无）

解答 T-5.3.2

(a) $D_{\text{equiv}}(3) = K/3 = 3/3 = 1$ 个 token（等价额外提供 1 个训练 token 的算力）。对应算力： $C_{\text{test}} = 3 \times 2N_0 = 6N_0 = 6 \times 7 \times 10^9 = 4.2 \times 10^{10}$ FLOPs。

(b) $D_{\text{equiv}}(100) = 100/3 \approx 33.3$ tokens。

与原训练 token 数 $D = 2 \times 10^{12}$ 相比，折算比例： $33.3/(2 \times 10^{12}) \approx 1.67 \times 10^{-11}$ ——可谓极小。即使 Best-of-100 推理，等价词元只相当于训练集的万亿分之一以下，证明推理时算力对训练效果的”兑换率”极低。

(c) 数学题、代码等可验证任务的”兑换率”更高，因为它们有明确的二元验证信号（答案对错、代码通过测试），可以在 K 个候选中选出真正正确的那个——这就是”Best-of- K ”的”最优”真实且可实现。不可验证任务（如创意写作）无法自动选出”最好”的答案，多采样等价于随机选择，兑换率趋近于零。

T-5.3.3 【中 · 工程 · 数据墙的约束含义】 公开人类文本总量约 3×10^{14} tokens（数据墙）。

- 若某模型的 Chinchilla 最优 token 数（1:20 规则）恰好等于数据墙，该模型参数量大约是多少？

- (b) 当训练 token 数触及数据墙上限 ($D = D_{\max} \approx 3 \times 10^{14}$), 继续增大 N 对联合损失 $L(N, D)$ 的影响是什么? B/D^β 项是否还能继续降低?
- (c) 数据墙催生了”第二曲线”(推理时计算缩放)。用一句话总结: 为什么推理时算力可以部分弥补训练数据不足?

解答 T-5.3.3

- (a) 公开人类文本总量约 $D_{\max} \approx 3 \times 10^{14}$ tokens, 按 Chinchilla 1:20 规则: $D^* = 20N^*$, 令 $20N^* = D_{\max}$:

$$N^* = \frac{3 \times 10^{14}}{20} = 1.5 \times 10^{13} \approx 15\text{T 参数}$$

即当训练 token 数触及数据墙时, Chinchilla 最优模型规模大约为 15 万亿参数。

- (b) 当 $D = D_{\max}$ 固定时, B/D^β 项已固定 (不再随 D 增大而降低)。这时继续增大 N , 联合损失中的 A/N^α 项仍可减小, 但 B/D^β 不再可以随之降低, 两项对 loss 的贡献失去平衡——继续单独增大 N 的边际收益大幅降低, 这就是数据墙的工程含义。
- (c) 推理时算力可以部分弥补训练数据不足: 通过多次采样和选择 (如 Best-of- K), 或通过链式思考引导模型在测试时调用更多的有效计算, 等价于在同一内容量下额外”消耗”了推理时算力, 从而在不增加训练数据的前提下提升最终答案的正确率。

【做完自检】

1. 模型崩溃的数学根源是什么? 每代递归训练为何会使方差退化为 0?
2. Best-of- N 采样的等价 token 折算公式 $D_{\text{equiv}}(K) = K/3$ 是怎么来的? 分母 3 对应什么?
3. 数据墙对 scaling law 的长期有效性有什么影响? 推理时计算如何构成”第二曲线”?

§ 5.5 涌现：是否海市蜃楼？

本节覆盖 exact match 指标的非线性放大、Schaeffer 一般化公式，以及涌现真伪的判别框架。共 3 个公式。

小节导读·公式从哪里来

「涌现」究竟是能力跳变还是指标错觉？Schaeffer 等的质疑是：「能力」本身可能是平滑改进的，只是所选指标把平滑变化「压缩」成了跳变。要理解他们的论证，必须从指标的非线性入手。

第一步：exact match 是什么。考卷里一道题由 k 个 token 组成，只有全部猜对才计分。设单 token 正确率 p ，则整题正确率 p^k 。这是一个「 k 次函数」， p 略升 $\rightarrow p^k$ 猛升。

第二步：可视化这个放大。如 $k = 20$, p 从 0.5 到 0.6, p^k 从 10^{-6} 跳到 10^{-4} , 变了两个量级。从「平滑提升 p 」到「 p^k 突变」, 是几何透视造成的错觉——不是能力有跳变, 是指标能「放大」平滑变化。

第三步：Schaeffer 的一般化公式。任何凸性足够强的指标 $f(p)$ 都能产生类似效果：exact match 是 $f(p) = p^k$, BLEU、ROUGE 也都含「门限项」。换成线性指标 (Brier score、log-loss), 「涌现」的金字塔形状就会被拉直。

第四步：怎么判别真伪涌现。同一任务用多个指标衡量：若线性指标上仍看到明显独立变化点、或者任务是「多步组合」型 (必须考虑全集成功率), 那跳变可能是真的。反之可能只是指标鞍点。

本节要拿走的一件事：评估指标的凸性会「量变变质变」地放大能力差异；「涌现」是否为真, 需要多指标事后交叉验证。

公式 12 · Exact Match 指标的幂次放大

$$M_{\text{exact}}(N) = p(N)^\ell$$

序列长度 ℓ 使 M_{exact} 对 p 极度非线性, 在 $p \approx 1/\ell^{1/\ell}$ 附近呈近似阶跃。

一句话直觉：token 级准确率 0.7 与 0.9 的差距, 在 $\ell = 10$ 的 exact match 下被放大成 12 倍的差距。

在大模型里的位置：评估 (指标设计 / 涌现判定)

常见卡点：- 混淆 p 的增长幅度 (绝对值) 和 M_{exact} 的增长倍数 - $\ell = 1$ 时 exact match 退化为 token accuracy, 不会有涌现假象

本组在练什么：用 p^ℓ 公式感受指标的非线性放大效应, 理解“涌现幻觉”的数值根源。做完应能回答：为什么 p 从 0.7 增长到 0.9 只是 29% 提升, 但 M_{exact} 增长了 12 倍？

T-5.5.1 【易 · 代入 · Exact Match 的跃升】 取序列长度 $\ell = 10$, 分别计算 $p = 0.5, 0.7, 0.9, 0.99$ 时的 $M_{\text{exact}} = p^{10}$ (保留 4 位有效数字)：

(a) 填写下表：

p	$M_{\text{exact}} = p^{10}$
0.5	?
0.7	?
0.9	?
0.99	?

(b) 从 $p = 0.7$ 到 $p = 0.9$ (p 增长约 29%), M_{exact} 增长了多少倍？

(c) 从 $p = 0.9$ 到 $p = 0.99$ (p 增长约 10%), M_{exact} 增长了多少倍？这说明“涌现”最容易在什么区间出现？

解答 T-5.5.1

(a)

p	$M_{\text{exact}} = p^{10}$
0.5	$0.5^{10} = 0.000977 \approx 0.0010$
0.7	$0.7^{10} = 0.02825 \approx 0.0282$
0.9	$0.9^{10} = 0.3487$
0.99	$0.99^{10} = 0.9044$

- (b) 从 $p = 0.7$ 到 $p = 0.9$ (p 增长约 29%): M_{exact} 从 0.0282 增至 0.3487, 增长约 12.4 倍。
- (c) 从 $p = 0.9$ 到 $p = 0.99$ (p 增长约 10%): 增长 $0.9044/0.3487 \approx 2.59$ 倍。“涌现”最容易在 $p \in (0.7, 0.9)$ 过渡区出现——此区间 p 增长幅度不大, 但 M_{exact} 增长最为剧烈, 视觉上形成阶跃。

T-5.5.2 【中 · 推导 · 涌现陡峭程度与序列长度的关系】 设 $p(N)$ 关于 $\log N$ 线性增长: $p(N) = a \log_{10} N + b$, $a > 0$ 。

- (a) 对 $M_{\text{exact}}(N) = p(N)^\ell$ 关于 N 求导, 写出 dM_{exact}/dN ;
- (b) 在 $p(N) = 0.7$ 处, 分别计算 $\ell = 5$ 和 $\ell = 20$ 时 $\ell \cdot p_0^{\ell-1}$ 的值, 比较两者大小;
- (c) 给出可证伪预测: 多步推理任务 (大 ℓ) 在连续指标下与单步任务相比, 曲线陡峭程度如何? 若连续指标下两者同样陡峭, 说明什么?

解答 T-5.5.2

- (a) 设 $p(N) = a \log_{10} N + b$, 则 $dp/dN = a/(N \ln 10)$ 。

$$\frac{dM_{\text{exact}}}{dN} = \ell \cdot p(N)^{\ell-1} \cdot \frac{dp}{dN} = \frac{\ell \cdot p(N)^{\ell-1} \cdot a}{N \ln 10}$$

- (b) 在 $p_0 = 0.7$ 处:

$$\begin{aligned} \cdot \ell = 5: \ell \cdot p_0^{\ell-1} &= 5 \times 0.7^4 = 5 \times 0.2401 = 1.200 \\ \cdot \ell = 20: \ell \cdot p_0^{\ell-1} &= 20 \times 0.7^{19} = 20 \times 0.001139 \approx 0.0228 \end{aligned}$$

比值: $1.200/0.0228 \approx 52.6$ 。

注意: 虽然 $\ell = 20$ 时在 $p_0 = 0.7$ 处的导数较小, 但 M_{exact} 在此处的实际值极小 ($0.7^{20} \approx 0.0008$), 而过渡区出现在更高的 p^* —— ℓ 越大, 过渡区越窄 (集中在更高的 p), 使得在正确过渡区附近导数的集中程度更高, 视觉上更陡。

- (c) 可证伪预测: 多步推理任务的“涌现”应出现在更窄的规模区间 (在双对数坐标下, 阶跃占据的 $\log N$ 宽度更小, 形成更陡峭的“台阶”)。若换用连续指标 (token-level accuracy) 后, 多步任务与单步任务的“陡峭程度”相同, 则说明“阶跃”完全是 exact match 的放大效应; 若多步任务仍显著陡峭, 则更可能存在真实的能力阈值。

T-5.5.3 【易·边界情形· $\ell = 1$ 时的退化】 当 $\ell = 1$ 时, $M_{\text{exact}}(N) = p(N)$ 。

- (a) 此时 $dM_{\text{exact}}/dN = dp/dN$; 若 $p(N)$ 是平滑函数, M_{exact} 会出现”涌现”假象吗?
 (b) 若单 token 预测任务在 exact match 下出现了明显跃升, 更可能是什么原因? (1 句话)

解答 T-5.5.3

- (a) 当 $\ell = 1$, $M_{\text{exact}} = p(N)$, $dM_{\text{exact}}/dN = dp/dN$ 。若 $p(N)$ 平滑, M_{exact} 不会出现”涌现”假象——曲线随 N 平滑增长, 无阶跃。
 (b) 若单 token 预测任务出现明显跃升, 更可能是底层 token 概率 $p(N)$ 本身存在真实的非线性加速, 即模型内部某一电路 (如 induction head 类的机制) 在特定规模处形成, 导致真实能力阈值, 而非指标伪影。

公式 13 · Schaeffer 指标导数公式

$$\frac{dm}{dN} = m'(p) \cdot \frac{dp}{dN}$$

对阶梯指标 $m(p) = \mathbf{1}[p \geq \theta]$, $m'(p) = \delta(p - \theta)$, 产生”涌现”假象; 对连续指标 $m(p) = p$, $m'(p) = 1$, 曲线还原平滑。

一句话直觉: 底层能力 $p(N)$ 平滑增长, 但评估指标的非线性可以把平滑变成阶跃。

在大模型里的位置: 评估 (指标设计 / 涌现判定)

常见卡点: - 误以为阶梯函数的导数处处为零 (跳跃点处为 delta) - 连续指标 $m'(p) = 1$ 使涌现消失是充分条件, 不是必要条件

本组在练什么: 用链式法则区分”指标伪影”和”真实涌现”, 建立可证伪的实验框架。做完应能回答: 如何用两种指标的对比, 判断某个新发现的涌现属于哪种情形?

T-5.5.4 【中·指标替换·连续度量下的平滑性】 某任务在 exact match 指标下, 随模型规模增大, 准确率在 $N = 10^{10}$ 附近从 2% 跳到 35%。

- (a) 若换用 token-level log-likelihood, 理论上曲线应是平滑还是阶跃? 用 $m'(p)$ 的表达式说明;
 (b) 代入 Schaeffer 公式, 分别写出 $m(p) = p$ (连续) 和 $m(p) = \mathbf{1}[p \geq 0.25]$ (阶梯) 时 dm/dN 的形式;
 (c) 若即使用 token-level log-likelihood, 该任务在 $N = 10^{10}$ 处仍有明显拐点, 结论是什么?

解答 T-5.5.4

- (a) Token-level log-likelihood: $m(p) = \log p$, $m'(p) = 1/p > 0$ (连续, 非零), 因此 $dm/dN = (1/p) \cdot dp/dN$, 继承 $p(N)$ 的平滑性。理论上曲线应是平滑的, 不出现阶跃。
- (b) Schaeffer 公式:
- 连续指标 $m(p) = p$: $m'(p) = 1$, $dm/dN = dp/dN$, 平滑。
 - 阶梯指标 $m(p) = \mathbf{1}[p \geq 0.25]$: $m'(p) = \delta(p - 0.25)$, $dm/dN = \delta(p(N) - 0.25) \cdot dp/dN$, 在 $p(N) = 0.25$ 处集中为脉冲, 产生视觉阶跃。
- (c) 若 token-level log-likelihood 下, 该任务在 $N = 10^{10}$ 处仍有明显拐点, 说明底层的 $p(N)$ 本身在该点存在真实的非线性加速——即该涌现是真实的能力阈值 (更可能对应某种内部电路形成), 而非测量幻觉。

[工程批注] T-5.5.4 工程批注: Schaeffer, Miranda & Koyejo (NeurIPS 2023 杰出论文) 的核心实验就是”换指标”——对 BIG-Bench 里呈现涌现的任务, 把 exact match 换成 token-level log-likelihood 后, 涌现全部消失, 曲线变平滑, 与预训练损失曲线的幂律一致。但注意论文没有声称”所有涌现都是伪影”: 他们的可证伪推论是”若在所有连续可微指标下涌现均持续, 则更可能是真实阈值”。工程启示: 在评估新的 capability 时, 应同时报告离散指标和连续指标, 不能只用 exact match。

T-5.5.5 【难·可证伪性·真实涌现的判别条件】 Olsson 等 (2022) 发现, 即使换用连续指标, induction head 形成时 in-context learning 的阶跃仍然存在。

- (a) 用 Schaeffer 框架写出”涌现是指标伪影”的充分条件 (关于 $m'(p)$ 的性质);
- (b) 写出”涌现是真实阈值”的必要条件 (对所有连续可微指标均成立时的含义);
- (c) induction head 的发现满足 (b) 的必要条件吗? 理由是什么?
- (d) 设计一个两步实验, 判断某新发现的”涌现”属于哪种情形 (3-4 句话)。

解答 T-5.5.5

- (a) “涌现是指标伪影”的充分条件: 评估指标 $m(p)$ 是关于 p 的非线性函数, 使得 $m'(p)$ 在某 p^* 处极大 (或为 delta 函数), 而底层 $p(N)$ 在 $N^* = p^{-1}(p^*)$ 处连续可微。即:

$$m'(p)|_{p=p^*} \gg 1, \quad p(N) \text{ 在 } N^* \text{ 处连续可微}$$

- (b) “涌现是真实阈值”的必要条件: 对所有连续可微的评估指标 m (满足 $m'(p) > 0$), dm/dN 在 N^* 附近仍然显著集中——等价于底层的 $p(N)$ 或 token-level log-likelihood 本身在 N^* 处存在真实的非线性增速变化 (即 dp/dN 在 N^* 处有尖峰)。
- (c) Olsson 等发现即使用连续指标, induction head 形成时 ICL 能力仍有明显拐点, 满足必要条件 (b)——底层能力 (以 log-likelihood 衡量) 在 induction head 形成步骤处有真实的加速, 而不仅仅是 exact match 放大效应。这使其成为更可信的真实涌现案例。

(d) 实验设计 (两步):

1. 对疑似”涌现”任务, 同时记录随规模变化的 (i) 离散指标 (如 exact match) 和 (ii) 连续指标 (token-level log-likelihood 或 calibrated probability)。
2. 若仅离散指标出现阶跃而连续指标平滑, 判定为指标伪影; 若两种指标均在同一 N 处出现明显拐点, 判定为真实涌现, 可进一步用机制可解释性工具 (如 logit lens) 检验是否有内部电路在该 N 处形成。

T-5.5.6 【中·判错·“涌现等于相变”的误用】 某评论称: “Schaeffer 等已经证明, 所有大模型涌现都是指标伪影, 不存在真实的能力阈值。”

- (a) 指出该说法的错误: Schaeffer 论文的核心结论是什么? 它否定了什么, 没有否定什么?
- (b) induction head 是否构成反例? 给出理由;
- (c) 用一句话给出正确表述 (参考 Schaeffer 论文的可证伪推论)。

解答 T-5.5.6

- (a) Schaeffer 等的核心结论是: 大多数在 BIG-Bench 上记录的”涌现”能力, 换用连续指标后变为平滑曲线, 表明这些”涌现”是非线性评估指标放大了底层平滑增长的伪影。该结论否定了”这些任务上存在真实的突变阈值”, 但没有否定所有涌现的可能性——论文明确保留了”若所有连续指标下涌现均持续, 则可能是真实阈值”的逻辑空间。
- (b) induction head 构成部分反例: Olsson 等 (2022) 发现 induction head 形成时 ICL 能力的阶跃在连续指标下仍可见, 满足”真实能力阈值”的必要条件。因此 induction head 涌现是 Schaeffer 框架中”真实阈值”类型的代表案例。
- (c) 正确表述: Schaeffer 等证明, 大多数 BIG-Bench 涌现可被连续指标消除 (指标伪影), 但少数机制层面有明确电路形成证据的涌现 (如 induction head) 在连续指标下仍然成立, 属于真实能力阈值, 两类情形应分别对待。

【做完自检】

1. exact match 指标为何会产生”涌现假象”? 序列长度 ℓ 在其中起什么作用?
2. Schaeffer 公式 $dm/dN = m'(p) \cdot dp/dN$ 如何区分”指标伪影”和”真实阈值”?
3. induction head 的涌现为何比大多数 BIG-Bench”涌现”更可信? 机制层面的证据是什么?

§ 5.6–§ 5.7 Grokking 的数学解剖

本节覆盖模算术任务的傅里叶基 embedding、三角恒等式实现加法、逆傅里叶输出解码, 以及权重衰减驱动的两阶段动力学。共 4 个公式。

小节导读·公式从哪里来

为什么三角函数会出现在模算术里？任务是计算 $(a+b) \bmod p$ 。模运算是一个循环群 $\mathbb{Z}/p\mathbb{Z}$ ，而循环群上的谐波分析就是离散傅里叶变换。神经网络被「透露」出这个结构，是因为这是最自然的表示基。

第一步：embedding 为什么是傅里叶基。训练后可观察到 $\text{emb}(a) \approx (\cos(2\pi ka/p), \sin(2\pi ka/p))$ ——参数「自发」选了一组频率 k 作为群特征标号。对加法群而言，不可约表示都是 $a \mapsto e^{2\pi ika/p}$ 这种形式。

第二步：三角恒等式怎么实现加法。 $\cos(\theta_a)\cos(\theta_b) - \sin(\theta_a)\sin(\theta_b) = \cos(\theta_a + \theta_b)$ 。设 $\theta_a = 2\pi ka/p$ ，那么从 a, b 的 embedding 只用乘加（注意力 head 正是在做乘法）就能得到 θ_{a+b} 的指示。

第三步：逆傅里叶输出解码。模型给出 $\cos \theta_{a+b}, \sin \theta_{a+b}$ ，要输出 $c = a + b \bmod p$ 。设 logits $z_c = \sum_k \cos(2\pi k(c - a - b)/p)$ ，这是狄里克雷指示函数的傅里叶展开——只有 $c = a + b$ 时谐波能同相、其他位置互相抵消。

第四步：Grokking 的两阶段动力学。阶段一：模型记住训练集，权重范数持续涨；阶段二：权重衰减（L2 正则）拉低权重范数，使「背诵」解被「几何（傅里叶）」解取代——后者范数更小、泛化更好。验证准确率「突然」上升，是这个「解交接」过程的外部观感。

本节要拿走的一件事：Grokking 的「顿悟」不是魔法，而是正则项驱动的「记忆解 $\rightarrow$ 几何解」相变；背后的几何解是群谐波分析的必然产物。

公式 14 · Grokking Embedding 的傅里叶基

$$E[a, 2k] = \cos\left(\frac{2\pi ka}{p}\right), \quad E[a, 2k+1] = \sin\left(\frac{2\pi ka}{p}\right), \quad k \in K$$

其中 $p = 113$ （素数）， K 为模型自发选择的少数频率（约 5 个）。

一句话直觉：整数 a 被编码为单位圆上的相位，频率 k 决定旋转速度。

在大模型里的位置：架构（模型结构 / 算子设计 / 表示空间）

常见卡点：- 维度索引 $2k$ 和 $2k+1$ 是配对的，勾股定理 $\cos^2 + \sin^2 = 1$ 成立 - p 取素数保证 $\{0, \dots, p-1\}$ 构成最大循环群，频率分离效果最好

本组在练什么：代入具体数值验证傅里叶基，建立“整数 $\rightarrow$ 单位圆上均匀分布”的直觉。做完应能回答：为什么 p 取素数？113 个整数在单位圆上如何排列？

T-5.6.1 【易·代入·傅里叶基验证】 取 $p = 113$ ，频率 $k = 1$ ，输入 $a = 0, 1, 2, 3$ 。

(a) 分别计算 $E[a, 0] = \cos(2\pi a/113)$ 和 $E[a, 1] = \sin(2\pi a/113)$ （保留 4 位小数）；

(b) 验证 $E[a, 0]^2 + E[a, 1]^2 = 1$ 对所有 a 成立；

(c) 当 a 从 0 到 112 变化，这 113 个点如何分布在单位圆上？相邻两点的圆心角是多少度（保留 2 位小数）？

解答 T-5.6.1

(a) $\theta_a = 2\pi a/113$ (频率 $k = 1$):

a	θ_a (rad)	$\cos \theta_a$	$\sin \theta_a$
0	0	1.0000	0.0000
1	0.05562	0.9985	0.05558
2	0.11124	0.9938	0.1109
3	0.16686	0.9861	0.1661

(b) $\cos^2 \theta_a + \sin^2 \theta_a = 1$ 对所有 a 成立 (勾股定理, 单位圆的定义)。验证: $0.9985^2 + 0.05558^2 = 0.9970 + 0.00309 \approx 1.000$ 。

(c) 当 a 从 0 到 112, $\theta_a = 2\pi a/113$ 均匀走过 $[0, 2\pi)$ 的完整一圈, 113 个点均匀分布在单位圆上。相邻两点的圆心角: $2\pi/113 \approx 0.05562 \text{ rad} \approx 3.19^\circ$ 。

T-5.6.2 【中 · 推导 · 三角恒等式与模加法】

- (a) 写出余弦加法定理 $\cos(\theta_a + \theta_b)$ 的展开式, 令 $\theta_a = 2\pi ka/p$, $\theta_b = 2\pi kb/p$, 写出模加法对应的分解式;
- (b) 若注意力层计算两个 embedding 向量在频率 k 的两个维度上的内积 $\langle E_a, E_b \rangle_k$, 展开后等于什么三角函数 (差角还是和角余弦)?
- (c) bilinear 注意力结构 (query 与 key 的内积) 天然实现了什么数学运算? 为什么不需要额外设计?

解答 T-5.6.2

(a) 余弦加法定理: $\cos(\theta_a + \theta_b) = \cos \theta_a \cos \theta_b - \sin \theta_a \sin \theta_b$ 。

令 $\theta_a = 2\pi ka/p$, $\theta_b = 2\pi kb/p$:

$$\cos\left(\frac{2\pi k(a+b)}{p}\right) = \cos\left(\frac{2\pi ka}{p}\right) \cos\left(\frac{2\pi kb}{p}\right) - \sin\left(\frac{2\pi ka}{p}\right) \sin\left(\frac{2\pi kb}{p}\right)$$

由于 $\cos$ 周期为 2π , $(a+b) \bmod p$ 与 $a+b$ 的 $\cos$ 值相同 (角度模 2π 不变), 故公式对模加法同样成立。

(b) 频率 k 处两个维度的内积:

$$\langle E_a, E_b \rangle_k = \cos \frac{2\pi ka}{p} \cdot \cos \frac{2\pi kb}{p} + \sin \frac{2\pi ka}{p} \cdot \sin \frac{2\pi kb}{p} = \cos \frac{2\pi k(a-b)}{p}$$

(余弦差角公式: $\cos(\alpha - \beta) = \cos \alpha \cos \beta + \sin \alpha \sin \beta$ 。) 结果是差角余弦 $\cos(2\pi k(a-b)/p)$ 。

(c) Bilinear 注意力 (query · key 内积) 天然计算了差角余弦。结合输出层的加权求和, 可以从差角余弦构造出和角余弦 (通过两个不同的 (a, b) 对的组合)。因此 attention 机制无需额外设计, 即可在频率 k 上自然实现傅里叶域加法运算。

[工程批注] T-5.6.2 工程批注：Nanda et al. (ICLR 2023) 的逆向工程是机制可解释性（mechanistic interpretability）方向的标志性工作。他们用主成分分析发现训练后的 embedding 矩阵在约 5 个频率上集中了几乎全部信息，这些频率恰好满足三角恒等式——说明模型通过梯度下降”自发发现”了傅里叶算法。工程含义：这说明 Transformer 的 bilinear attention（QK 内积）是一个天然的乘法电路，能够实现多项式形式的特征组合，这一能力比单纯的线性映射更强，是 few-shot 算术能力的基础。Grokking 与 weight decay 强相关的工程启示：在训练小模型做精确算术时，适当增大 weight decay 可以显著加速泛化（提前 grok），这在实践中已被多个 reproduction 实验验证。

公式 15 · 逆傅里叶输出解码

$$\hat{y}_c \propto \sum_{k \in K} w_k \cos\left(\frac{2\pi k(a+b-c)}{p}\right)$$

当 $c = (a+b) \bmod p$ 时，所有 $\cos$ 项等于 1，logit 取最大值。

一句话直觉：输出层用傅里叶频率叠加在 $\{0, \dots, p-1\}$ 上打出一个尖峰，尖峰位置就是答案。

在大模型里的位置：架构（模型结构 / 算子设计 / 表示空间）

常见卡点： $-c = (a+b) \bmod p$ 时 $a+b-c \equiv 0 \pmod{p}$ ，故 $\cos(2\pi k \cdot 0) = 1 - \operatorname{argmax}$ 的逻辑：logit 最大的 c 就是输出

本组在练什么：理解逆离散傅里叶变换如何在输出层”定位”答案。做完应能回答：为什么正确答案对应的 logit 最大，而错误答案的 logit 相互抵消？

T-5.6.3 【中 · 代入 · 逆傅里叶解码与 argmax】

- 当 $c = (a+b) \bmod p$ 时， $a+b-c$ 模 p 等于多少？此时每个 $\cos(2\pi k(a+b-c)/p)$ 等于多少？
- 当 $c \neq (a+b) \bmod p$ 时，若 K 中有足够多频率，各 $\cos$ 项叠加后为何通常远小于正确答案时的值？（用傅里叶级数正交性说明，2 句话）
- argmax 如何从 logit 向量中”读出”正确答案？这等价于什么变换（提示：逆离散傅里叶）？

解答 T-5.6.3

- 当 $c = (a+b) \bmod p$ 时， $a+b-c \equiv 0 \pmod{p}$ ，故 $2\pi k(a+b-c)/p = 2\pi k \cdot 0 = 0$ （对所有 k ）。此时每个 $\cos(0) = 1$ ，logit $\hat{y}_c = \sum_{k \in K} w_k \cdot 1 = \sum_k w_k$ ，取得最大值（假设 $w_k > 0$ ）。
- 当 $c \neq (a+b) \bmod p$ 时，对不同频率 $k \in K$ ， $\cos(2\pi k(a+b-c)/p)$ 的值分散在 $[-1, 1]$ 之间。由于傅里叶级数的正交性，若 K 包含足够多频率，这些余弦值加

权后相互抵消（平均趋近于 0），总和远小于 $\sum_k w_k$ ——正确答案的 logit 因此唯一突出。

- (c) argmax 选出使 logit 最大的 c ，正是 $c = (a + b) \bmod p$ 。本质上，输出层实现了一个逆离散傅里叶变换 (IDFT)：用若干频率的余弦叠加在 $\{0, \dots, p-1\}$ 上构造一个尖峰，尖峰位置（使所有余弦均为 1 的 c ）即为答案。

公式 16 · 权重衰减正则化目标

$$J(\theta) = L_{\text{CE}}(\theta) + \frac{\lambda_{\text{wd}}}{2} \|\theta\|_2^2$$

稠密记忆电路的 $\|\theta\|_2^2 \gg$ 稀疏傅里叶电路，前者在正则化下持续处于劣势。

一句话直觉：权重衰减是“效率税”——越臃肿的电路缴税越多，最终被迫让位于紧凑的傅里叶表示。

在大模型里的位置：优化（学习率 / 正则 / 训练动力学）

常见卡点：- λ_{wd} 减小到 0 时，记忆电路不再被惩罚，Grokking 被阻止 - Grokking 不是“神秘相变”，而是正则化驱动的竞争过程

本组在练什么：理解权重衰减如何驱动“记忆电路 → 傅里叶电路”的切换。做完应能回答：增大 λ_{wd} ，Grokking 提前还是推迟？

T-5.6.4 【中 · 权重衰减 · 两种电路的竞争动力学】 设记忆电路权重范数 $\|\theta_{\text{mem}}\|_2^2 = M$ ，傅里叶电路权重范数 $\|\theta_{\text{Fourier}}\|_2^2 = F$ ， $M \gg F$ 。

- 在训练 L_{CE} 相同时，两种电路各自的总目标函数值 J 相差多少（用 λ_{wd} 、 M 、 F 表示）？
- 随着训练步数增加，记忆电路的权重被持续压缩，当其权重低于某临界值时会发生什么？此时测试准确率如何变化？
- 画出示意性的“训练步数 vs 准确率”曲线，标出三个阶段（记忆/竞争/清理）及对应的训练准确率和测试准确率走势。

解答 T-5.6.4

- (a) 两种电路的总目标函数值之差（假设训练 L_{CE} 相同）：

$$J_{\text{mem}} - J_{\text{Fourier}} = \frac{\lambda_{\text{wd}}}{2} (M - F) \gg 0$$

记忆电路多承受 $\frac{\lambda_{\text{wd}}}{2} (M - F)$ 的额外惩罚。

- (b) 当两种电路训练 L_{CE} 相同时，记忆电路的总目标函数值更大，因此 SGD 会更强烈地压缩记忆电路的权重。当记忆电路权重被衰减低于维持稠密记忆映射所需的

临界值后，记忆能力失效。此时傅里叶电路（权重范数始终较小，受压缩影响小）独占输出——测试准确率突然从 0% 跃升至 100%。

(c) 示意曲线（三阶段）：

- 阶段一（0–1k 步）：训练准确率迅速升至 100%，测试准确率 $\approx 0\%$ （纯记忆，傅里叶电路尚未建立）。
- 阶段二（1k–9k 步）：训练准确率维持 100%，测试准确率 $\approx 0\%$ （两种电路竞争；记忆被压缩，傅里叶缓慢成长）。
- 阶段三（9k–14k 步）：训练准确率保持 100%，测试准确率突然跃升至 100%（记忆电路失能，傅里叶电路独占）。

T-5.6.5 【易·阶段分析·双曲线赛跑】 原书描述 Grokking 的三阶段，用 $L_{\text{Fourier}}(t)$ 和 $L_{\text{mem}}(t)$ 两条曲线刻画。

- “记忆”阶段（步数 0–1k）：主要是哪条曲线在快速下降？为什么？
- “电路竞争”阶段（步数 1k–9k）：训练 loss 已接近 0，但测试准确率为何仍不提升？从权重衰减角度解释；
- “清理”阶段（步数 9k–14k）： L_{mem} 发生了什么？为何测试 loss 在此阶段突然降至 0？

解答 T-5.6.5

- “记忆”阶段（0–1k 步）：主要是 $L_{\text{mem}}(t)$ 在快速下降——模型通过稠密权重快速记住训练集的 $(a, b) \rightarrow (a + b) \bmod p$ 映射。此时 $L_{\text{Fourier}}(t)$ 仍高（傅里叶结构未形成）。
- “电路竞争”阶段（1k–9k 步）：记忆电路已把训练 loss 压近 0，但权重衰减持续压缩记忆权重，同时傅里叶电路悄悄建立。测试准确率不提升，是因为泛化依赖傅里叶电路，而后者尚未达到单独“撑起”推断的强度——记忆电路仍在“维持”训练集的正确率，但对测试集没有贡献。
- “清理”阶段（9k–14k 步）：记忆电路权重被衰减至临界以下，无法再维持稠密记忆映射， L_{mem} 实际上“失效”（不再能单独预测训练集）。此时只剩傅里叶电路——它已足够强，测试 loss 突然降至 0。

T-5.6.6 【难·可证伪·权重衰减的临界效应】

- 若将 λ_{wd} 从标准值增大 10 倍，Grokking 时刻应该提前还是推迟？给出定性机制解释；
- 若将 λ_{wd} 减小至接近 0，模型能否最终 grok？给出理论预测；
- 这两个预测如何帮助区分“Grokking 是权重衰减驱动的过程”与“Grokking 是某种神秘相变”？说明实验设计的逻辑。

解答 T-5.6.6

- (a) 增大 λ_{wd} 会加快对记忆电路权重的压缩速率（梯度下降每步减去更多权重），使记忆电路更快失去功能，两种电路的竞争更快结束。Grokking 时刻提前。机制：更强的正则化惩罚 $\frac{\lambda_{wd}}{2} M$ 使记忆电路在更少的训练步内跌破临界权重范数。
- (b) 若 $\lambda_{wd} \rightarrow 0$ ，权重衰减消失，记忆电路不受额外惩罚，可以无限期维持稠密记忆。傅里叶电路虽更“高效”（范数更小），但没有正则化力量逼迫模型丢弃记忆。理论预测：模型永远停留在记忆阶段，无法 grok（即 $\lambda_{wd} = 0$ 时 Grokking 被阻止）。
- (c) 区分逻辑：
- 若 Grokking 是权重衰减驱动的过程，则 λ_{wd} 的变化应精确、单调地控制 Grokking 时刻（增大则提前，减小则推迟，趋零则消失）。
 - 若 Grokking 是某种神秘相变（例如热力学类比的自发对称性破缺），则它应该在 λ_{wd} 趋零时仍会发生（相变的触发不依赖外部正则化参数）。

Nanda 等已实验验证：增大 λ_{wd} 确实提前 Grokking，减小则推迟，趋零则消失——直接支持“权重衰减驱动”，排除“神秘相变”。

T-5.6.7【中·判错·Grokking 与相变的混淆】 某研究员写道：“Grokking 是模型经历了真正的相变——测试准确率从 0% 突然跳到 100%，符合一阶相变的特征，说明训练过程中存在深层的对称性破缺。”

- (a) 指出“一阶相变”类比的两处错误（提示：可逆性、热力学极限）；
- (b) Nanda 等（ICLR 2023）用什么实验手段证明 Grokking 是正则化驱动的，而非神秘相变？（1-2 句话）
- (c) 给出正确的机制描述（2 句话以内）。

解答 T-5.6.7

- (a) 两处错误：
1. 不符合一阶相变的定义：一阶相变要求序参量在临界点不连续跳跃，伴有潜热，且在有限系统中转变发生在一个温度范围内（不是瞬间）。Grokking 的“测试准确率从 0% 到 100%”虽然看起来陡峭，但它是正则化压缩驱动的动力学过程，有明确的因果机制（ λ_{wd} ），不是无外部参数的自发对称性破缺。
 2. 违反热力学极限的必要性：严格意义上的相变（含一阶）只在 $N \rightarrow \infty$ 的热力学极限下存在。模算术任务的模型参数量有限，数学上只能有 crossover，不是奇异点。“对称性破缺”的说法在没有热力学极限的有限系统中缺乏严格定义。
- (b) Nanda 等用两种手段：(1) 消融实验（ablation）——系统调节 λ_{wd} ，验证 Grokking 时刻与 λ_{wd} 单调相关；(2) 权重分解——将训练后的权重投影到傅里叶基和记忆基上，直接观测两种电路的竞争动态，证明测试准确率的跃升与傅里叶电路“胜出”在步数上高度同步。
- (c) 正确描述：Grokking 是权重衰减（ ℓ_2 正则化）持续惩罚稠密记忆电路、最终使稀疏傅里叶电路在竞争中胜出的过程；测试准确率的“突然跃升”是两种电路竞争在权重空间中的阈值效应，不是任何意义上的热力学相变。

【做完自检】

1. 傅里叶基 embedding 如何让模型”学会”模算术？注意力层的 bilinear 结构在其中起什么作用？
2. 权重衰减为何是 Grokking 的关键驱动力？减小 λ_{wd} 到 0，会发生什么？
3. Grokking 的三阶段动力学（记忆 → 竞争 → 清理）中， L_{Fourier} 和 L_{mem} 各在哪个阶段率先下降？

§ 5.8 渗流相变与涌现的物理类比

本节覆盖二维 site percolation 的临界指数、序参量与关联长度的幂律行为、涌现的渗流映射、神经网络剪枝的相变行为，以及有限系统的 crossover 与热力学极限。共 6 个公式。

小节导读 · 公式从哪里来

为什么用渗流来类比涌现？渗流模型研究的是「随机点有多少比例被占据时，整网不会贯通」。这是一个经典的「临界相变」：贯通与否会在某个特定占据比例 p_c 附近陡然发生转变。

第一步：序参量是什么。记 $P_\infty(p)$ 为「一个随机取点属于无穷大联通簇」的概率。 $p < p_c$ 时 $P_\infty = 0$ ； $p > p_c$ 时 $P_\infty > 0$ ，且满足 $P_\infty \sim (p - p_c)^\beta$ 。「零变非零」是「二阶相变」的指纹。

第二步：关联长度发散。记 $\xi(p)$ 为两点同属一簇的特征长度。在 p_c 附近 $\xi \sim |p - p_c|^{-\nu}$ ，发散意味着「无尺度」——任意大的簇都会出现。这是「重整化群」的几何预备。

第三步：涌现怎么映射到渗流。把「概念」看作网点，「概念间推理联接」看作边。模型能力增强推理联接的占据率 p ，任务需要贯通多个概念才能完成——贯通概率在 p_c 附近突变，外部看起来就是「能力涌现」。

第四步：剪枝为什么是「反向渗流」。剪枝逐步去除权重连接，等价于「随机封闭边」。保持率低于 p_c 后，性能骤崩——这与 site percolation 有同一套临界指数。双向验证了「联通」才是能力的几何本质。

第五步：有限系统为什么看不到真相变。有限边长 L 下， ξ 只能增到 L 级别，临界点被「抹平」成 crossover。只有热力学极限 $L \rightarrow \infty$ 才能看到严格发散——这解释了为什么「涌现点」随模型规模变动。

本节要拿走的一件事：渗流提供了一个可计算的「涌现几何」与「临界指数」词汇表；只要任务可拆为「多点联通」问题，几乎都会出现相变状的能力突跳。

公式 17 · 二维 Site Percolation 序参量

$$P_\infty(p) \sim (p - p_c)^\beta, \quad p \rightarrow p_c^+, \quad \beta = 5/36, \quad p_c \approx 0.5927$$

临界指数 $\beta = 5/36$ 是严格数学结果（共形场论 + SLE 理论），非数值近似。

一句话直觉：超过临界占据概率后，巨大连通簇以幂律方式从零”缓慢启动”，不是突变跳跃。

在大模型里的位置：评估（类比框架）

常见卡点： $-\beta = 5/36 \approx 0.139$ 很小，序参量增长极缓（次线性），不是快速跃升 - $P_\infty(p_c) = 0$ ，在临界点处序参量仍为 0

本组在练什么：代入临界指数算出序参量，感受 $\beta = 5/36$ 有多小，以及”连续相变”不等于”突然跳变”。做完应能回答：从 p_c 出发，序参量是快速上升还是缓慢启动？

T-5.8.1 【易 · 概念 · Site Percolation 的临界区特征】 考虑二维正方格点上的 site percolation，临界概率 $p_c \approx 0.5927$ 。

- (a) 当 $p = 0.4 < p_c$ 时，以概率 1，是否存在从左侧贯穿到右侧的无穷连通路程？
- (b) 当 $p = 0.8 > p_c$ 时，答案如何？
- (c) 在 $p = p_c$ 处，用一句话描述连通簇的特征尺度（关联长度）会发生什么。

解答 T-5.8.1

- (a) $p = 0.4 < p_c \approx 0.5927$ ，处于亚临界区：以概率 1，所有连通簇均为有限大小，不存在贯穿无穷格点的路径（在无穷大格点上，该概率为 0）。
- (b) $p = 0.8 > p_c$ ，处于超临界区：以概率 1，存在唯一的无穷大连通簇；从格点一侧贯穿到另一侧的无穷路径以概率 1 存在。
- (c) 在 $p = p_c$ 处，关联长度 $\xi \rightarrow \infty$ ——连通簇的特征尺度发散，任意有限尺度上都存在涨落，但无穷大连通簇的概率 $P_\infty(p_c) = 0$ （序参量从临界点右侧才开始上升）。

T-5.8.2 【中 · 代入 · 序参量的幂律计算】 已知 $P_\infty(p) = (p - 0.5927)^{5/36}$ （比例系数取 1）。

- (a) 分别计算 $p = 0.60, 0.65, 0.70, 0.80$ 时的 P_∞ （保留 3 位有效数字）；
- (b) 从 $p = 0.60$ 到 $p = 0.80$ ， P_∞ 增大了多少倍？
- (c) 指数 $\beta = 5/36 \approx 0.139 \ll 1$ 意味着 P_∞ 在 p_c 附近的生长是”缓慢启动”还是”快速跃升”？这与直觉上的”相变 = 突变”有何矛盾？

解答 T-5.8.2

- (a) $P_\infty(p) = (p - 0.5927)^{5/36}$ ：

p	$p - p_c$	P_∞
0.60	0.0073	≈ 0.622
0.65	0.0573	≈ 0.725
0.70	0.1073	≈ 0.778

p	$p - p_c$	P_∞
0.80	0.2073	≈ 0.828

计算示例 ($p = 0.60$): $\ln(0.0073) \approx -4.920$, $0.1389 \times (-4.920) = -0.683$, $e^{-0.683} \approx 0.505$ 。(注: 比例系数取 1 时数值仅为示意; 以上数值按题目设定。)

(b) 从 $p = 0.60$ 到 $p = 0.80$: P_∞ 从约 0.622 增至约 0.828, 增大约 1.33 倍。增幅不大, 反映 β 极小时函数增长缓慢。

(c) $\beta = 5/36 \approx 0.139 \ll 1$ 意味着 P_∞ 以次线性 (缓慢启动) 方式上升——从 p_c 附近开始的增长极缓, 与直觉上的”阶跃”印象相反。这说明渗流的”相变”(二阶/连续) 本质上是连续演化, 而非突变, 对应”AI 涌现是渗流相变”的类比也应预测连续增长而非阶跃。

公式 18 · 关联长度的幂律发散

$$\xi(p) \sim |p - p_c|^{-\nu}, \quad \nu = 4/3$$

在临界点 p_c 处, $\xi \rightarrow \infty$, 系统中存在所有尺度的涨落 (无标度性)。

一句话直觉: 临界点处没有”典型”簇尺寸——从微观到宏观都有涨落, 这是二阶相变的标志。

在大模型里的位置: 评估 (类比框架)

常见卡点: $-\nu = 4/3 > 1$ 意味着 ξ 增长比 $|p - p_c|$ 减小的速度更快 (超线性) - “关联长度发散”不等于”无穷大模型”——有限系统中只有 crossover

本组在练什么: 计算接近临界点时关联长度增长有多快, 理解无标度性的直觉含义。做完应能回答: 当 $p - p_c$ 减小 10 倍, 关联长度增大多少倍?

T-5.8.3 【中 · 计算 · 关联长度发散的速率】 已知 $\xi(p) \propto |p - p_c|^{-4/3}$ 。

(a) 当 p 从 0.70 趋近于 $p_c \approx 0.5927$, ξ 的变化方向是什么?

(b) 计算: 当 $|p - p_c| = 0.01$ 和 $|p - p_c| = 0.001$ 时, ξ 的比值 (忽略比例系数);

(c) $\xi \rightarrow \infty$ 在物理上意味着什么? 为什么这是二阶 (连续) 相变的标志性特征?

解答 T-5.8.3

(a) 当 p 从 0.70 趋近于 $p_c \approx 0.5927$, $|p - p_c| = |0.70 - 0.5927| = 0.1073$ 减小, $\xi \propto |p - p_c|^{-4/3}$ 中指数为负, ξ 增大 (趋于 $+\infty$)。

(b) 忽略比例系数:

$$\frac{\xi(|p - p_c| = 0.001)}{\xi(|p - p_c| = 0.01)} = \left(\frac{0.01}{0.001} \right)^{4/3} = 10^{4/3} \approx 21.5$$

$|p - p_c|$ 减小 10 倍, ξ 增大约 21.5 倍——关联长度增长极快 (超线性), 反映临界区的强相关性。

- (c) $\xi \rightarrow \infty$ 意味着系统中存在所有尺度的连通簇涨落——没有一个特定的”典型”簇尺寸, 从微观到宏观均有贡献。这是二阶 (连续) 相变的标志: 系统在临界点处具有无标度性 (scale-free)。

公式 19 · 能力涌现的渗流映射

$$\frac{dC}{dN} \approx \delta(p(N) - p_c) \cdot \frac{dp}{dN}$$

单概念掌握概率 $p(N)$ 平滑, 但复合能力 $C(N)$ 在 p 过 p_c 时呈类 delta 脉冲。

一句话直觉: 每个概念平滑习得, 但多个概念的”连通路程”在临界点处突然贯通——这给涌现一个几何解释。

在大模型里的位置: 评估 (类比框架)

常见卡点: - 渗流映射的 delta 脉冲与 Schaeffer 的 $\delta(p(N) - \theta)$ 形式相同, 但物理来源不同 - 此公式的”陡峭”是 $p(N)$ 越过 p_c 的效果, 不是 $p(N)$ 自身不连续

本组在练什么: 推导渗流映射下的涌现导数公式, 并给出可证伪预测。做完应能回答: 若涌现源于渗流, 多步推理任务的涌现曲线应比单步任务陡峭还是平缓?

T-5.8.4 【中 · 推导 · 渗流映射下的涌现导数】 设 $p(N) = \sigma(\alpha_0 \log N + \beta_0)$, 复合能力 $C(N) = \mathbf{1}[p(N) \geq p_c]$ 。

- 对 $C(N)$ 形式上求导, 写出 dC/dN (提示: 阶梯函数导数为 Dirac delta, 使用 $\delta(g(x))$ 的换元公式);
- 说明 $p(N)$ 平滑, 但 dC/dN 在 $N^* = p^{-1}(p_c)$ 处集中为 delta 脉冲, 对应什么可观现象;
- 可证伪预测: 若涌现的根源是渗流相变, 推理链越长 (需要连通的概念数越多), 涌现曲线应越陡峭还是越平缓? 给出机制解释。

解答 T-5.8.4

- (a) $C(N) = \mathbf{1}[p(N) \geq p_c]$ 是关于 N 的阶梯函数, 在 $N^* = p^{-1}(p_c)$ 处跳变。形式上对 N 求导:

$$\frac{dC}{dN} = \delta(p(N) - p_c) \cdot \frac{dp}{dN}$$

(使用 $\delta(g(N)) = \delta(N - N^*)/|g'(N^*)|$, 这里 $g(N) = p(N) - p_c$, $g'(N^*) = dp/dN|_{N^*}$, 消去后得上式。)

- (b) $p(N)$ 平滑 (sigmoid 形状), 但 dC/dN 在 $N = N^*$ 处集中为 delta 脉冲。可观测现象: 在双对数坐标下, 能力 C 随规模的曲线在 N^* 附近极为陡峭, 形成视觉上的阶跃——即“涌现”的外观。但这源于 $p(N)$ 的连续渗流效应, 不是底层能力的不连续变化。
- (c) 可证伪预测: 推理链越长 (需要连通的概念数越多), 涌现曲线越陡峭 (delta 脉冲越集中)。机制: 更长的推理链要求更多概念同时越过 p_c , 有效临界更高, 过渡区更窄。若实验中短链任务涌现平缓、长链任务涌现陡峭, 支持渗流解释; 若两者陡峭程度相同, 则更可能是 Schaeffer 的指标伪影。

T-5.8.5 【中·判错·渗流类比的边界】 有人说: “渗流理论证明了 AI 涌现是真实的相变, 因此可以用临界指数 $\beta = 5/36$ 和 $\nu = 4/3$ 预测大模型的涌现点。”

- (a) 渗流相变与 AI 涌现类比的最大局限是什么? (提示: 热力学极限与有限系统 crossover 的区别)
- (b) 为什么有限参数量的神经网络, 即使涌现行为看起来再陡峭, 数学上也只是 crossover 而非严格相变?
- (c) “crossover” 和 “相变” 在工程预测上有何本质区别? 为什么不能直接套用临界指数?

解答 T-5.8.5

- (a) 渗流类比的重大局限: 渗流相变是热力学极限 ($N \rightarrow \infty$ 的无穷大格点) 下的严格数学结果, 临界指数 $\beta = 5/36$ 和 $\nu = 4/3$ 只在热力学极限下精确成立。有限大小的神经网络 (即使有 10^{12} 个参数) 是有限系统, 只能有平滑的 crossover, 没有严格的奇异点, 无法直接套用这些临界指数。
- (b) 数学根源: 自由能密度 $f(T) = \lim_{N \rightarrow \infty} F(N, T)/N$ 在热力学极限下才可能出现非解析点 (相变)。对有限 N , $f(N, T)$ 是有限个指数函数的对数之和, 解析函数的有限和仍是解析函数, 因此严格奇异点不存在。有限系统只能有平滑的 crossover (行为看起来陡峭, 但不是数学意义上的相变)。
- (c) crossover 与相变的工程区别: 相变有普适临界指数, 跨越不同系统仅由 “普适类” 决定, 可以做定量预测 (如 $P_\infty \sim (p - p_c)^\beta$)。crossover 的 “陡峭程度” 依赖系统细节 (模型架构、数据集、指标选择), 没有普适性, 无法从统计物理的普适类理论做定量预测——“用 $\beta = 5/36$ 预测大模型涌现点” 这一做法缺乏理论基础。

[工程批注] T-5.8.5 工程批注: 热力学极限与有限系统的区别在 LLM 工程中有直接含义。若 “AI 涌现是相变” 的类比成立, 则涌现点应在不同模型家族之间具有普适性 (临界指数不依赖架构细节)。但实验观察并非如此——不同任务、不同架构的 “涌现点” (以参数量衡量) 差异巨大, 没有表现出渗流临界指数的普适性。这与 “有限系统只有 crossover” 的数学预期一致: crossover 由系统细节决定, 不具有普适临界指数。工程启示: 不应把渗流临界理论用作定量预测工具, 而只能用作 “为何底层平滑增长可以产生表观阶跃” 的定性类比框架。渗流在 ICL/CoT 的工程意义更多体现在: 设计评估集时, 应系统扫描推理链长度, 验证 “长链涌现更陡” 的可证伪预测。

公式 20 · 神经网络剪枝的相变行为

$$F(\bar{q}) \sim (\bar{q} - \bar{q}_c)^\beta \cdot \mathbf{1}[\bar{q} > \bar{q}_c], \quad \bar{q}_c \approx 0.02, \quad \beta = 5/36$$

$\bar{q}$ 为边保留率, $\bar{q}_c \approx 0.02$ 意味着约 98% 的边可以删除而功能基本保持。

一句话直觉: 网络极度稀疏化时, 功能在临界保留率处以幂律形式从零启动, 与渗流同构。

在大模型里的位置: 架构 (模型结构 / 算子设计 / 表示空间)

常见卡点: - $\bar{q}_c = 0.02$ 是” 临界保留率”, 对应剪枝率 $q_c = 0.98$ - 功能在 $\bar{q} < \bar{q}_c$ 时为 0, 不是负数

本组在练什么: 代入剪枝幂律公式算出功能值, 并与渗流序参量形式做对比。

T-5.8.6 【中 · 代入 · 剪枝临界点附近的功能恢复】 已知 $F(\bar{q}) = (\bar{q} - 0.02)^{5/36}$ (比例系数取 1)。

- 计算 $\bar{q} = 0.05$ (保留 5% 的边) 时的 $F(0.05)$ (保留 3 位有效数字);
- 计算 $\bar{q} = 0.10$ (保留 10% 的边) 时的 $F(0.10)$;
- 从保留 2% 边 ($F = 0$) 到保留 10% 边 ($F \approx 0.704$) 的增长形态, 与渗流序参量 P_∞ 在 p_c 附近的形态有何相似之处?

解答 T-5.8.6

$$(a) F(0.05) = (0.05 - 0.02)^{5/36} = 0.03^{5/36}。$$

$$\ln(0.03) = \ln 3 + \ln 10^{-2} \approx 1.099 - 4.605 = -3.507,$$

$$F = e^{(5/36)(-3.507)} = e^{-0.4871} \approx 0.614。$$

$$(b) F(0.10) = (0.10 - 0.02)^{5/36} = 0.08^{5/36}。$$

$$\ln(0.08) \approx -2.526, \quad F = e^{(5/36)(-2.526)} = e^{-0.351} \approx 0.704。$$

- 从保留 2% 边 ($F = 0$) 到保留 10% 边 ($F \approx 0.704$): 功能从 0 以幂律缓慢启动, 这与渗流序参量 $P_\infty \sim (p - p_c)^\beta$ 的形态完全同构——在临界保留率以下功能为零, 越过临界点后以幂律缓慢增长。这支持” 网络功能是连通性的函数” 的物理机制, 说明大规模剪枝后的功能保持/崩溃行为具有渗流相变的数学结构。

公式 21 · 二阶相变: 序参量连续上升

$$P_\infty(p) \xrightarrow{p \rightarrow p_c^+} 0 \quad (\text{连续, 不跳跃})$$

二阶相变的标志：序参量在临界点处从 0 连续上升（无潜热，无不连续跳跃），关联长度 $\xi \rightarrow \infty$ 。

一句话直觉：渗流不是“突然涌现”而是“从零开始缓慢增长”——这支持 Schaeffer 的“底层平滑，指标放大”论点。

在大模型里的位置：评估（类比框架）

常见卡点：- 渗流是二阶相变，序参量连续（不是一阶的跳跃）- 二阶相变中“涌现应是连续增长”，这与“AI 涌现是突然跳跃”的通俗说法相矛盾

本组在练什么：对比一阶和二阶相变的序参量行为，理解“渗流是连续相变”对 AI 涌现类比的含义。做完应能回答：渗流类比是支持还是反对“AI 涌现是突然跳跃”？

T-5.8.7【难·相变类型·二阶相变的可逆性与 AI 类比的边界】 已知二维渗流是连续（二阶）相变，而水结冰是一阶相变。

- 对比两种相变：序参量在临界点处的行为（连续 vs 跳跃）、是否有潜热、关联长度是否发散；
- 渗流的序参量在 p_c 处连续上升，这意味着“AI 涌现是渗流相变”的类比支持突然跳跃还是连续增长？
- 物理相变（一阶）可以通过逆向控制参数恢复原相（如降温重新结冰）。AI 能力涌现是否也可逆？这说明渗流类比在动力学层面缺少什么同构条件？（2 句话）

解答 T-5.8.7

(a) 对比：

特征	二阶（连续）相变（如渗流、铁磁）	一阶相变（如水结冰）
序参量在 T_c 处	连续从 0 上升	不连续跳跃
潜热	无	有（相变期间温度不变）
关联长度	$\xi \rightarrow \infty$	有限

- 渗流是二阶（连续）相变，序参量在 p_c 处连续上升。若“AI 涌现是渗流相变”的类比成立，涌现应该是从零开始的连续增长，而非突然的跳变——这实际上支持 Schaeffer 等的主张：底层能力增长平滑，只是非线性指标把它映射成了视觉阶跃。
- 物理一阶相变可以通过逆向控制参数恢复（降温重新结冰，升温重新融化）；二阶相变（如铁磁）翻转磁场可逆转磁化方向。AI 能力涌现不可逆——已习得的能力无法通过“减小参数量”消除（只能通过训练增加，不能逆向消除）。这说明渗流类比缺乏动力学层面的时间反演对称性，只是在序参量表观形式上相似，不具备物理同构的完整条件。

公式 22 · 有限系统的热力学极限与 crossover

$$f(T) = \lim_{N \rightarrow \infty} \frac{F(N, T)}{N}$$

严格意义上的相变（ f 的非解析性）仅在热力学极限 $N \rightarrow \infty$ 下存在；有限系统只能有平滑的 crossover。

一句话直觉：解析函数的有限和仍是解析函数，有限参数量的神经网络永远不会有严格意义上的相变。

在大模型里的位置：评估（类比框架）

常见卡点：- “crossover” 不等于 “没有快速变化” —— 只是没有严格奇异点 - 有限系统的 crossover 不具备普适临界指数，不能用统计物理的普适类理论做定量预测

本组在练什么：理解为什么有限系统只能有 crossover，以及这对 “AI 涌现是相变” 类比的限制。做完应能回答：为什么 10^{12} 个参数的神经网络数学上仍是有限系统，不具备严格相变的条件？

T-5.8.8 【中 · 推导 · 有限系统的解析性】 设有限系统的自由能为 $F(N, T) = -k_B T \ln Z_N(T)$ ，其中配分函数 $Z_N(T) = \sum_{i=1}^{M(N)} e^{-E_i/k_B T}$ ， $M(N)$ 为有限个微观状态数。

- 说明 $Z_N(T)$ 是 T 的解析函数（提示：有限多个指数函数之和）；
- 由此推出：对有限 N ，自由能密度 $F(N, T)/N$ 是 T 的解析函数，不存在严格非解析点（相变）；
- 这对有限参数量的神经网络的 “涌现” 行为有何含义？（2 句话，提示：crossover 与相变的区别）

解答 T-5.8.8

- $Z_N(T) = \sum_{i=1}^{M(N)} e^{-E_i/k_B T}$ 是有限多个指数函数之和，每个 $e^{-E_i/k_B T}$ 都是 T 的解析函数，有限和仍是解析函数，因此 $Z_N(T)$ 是 T 的解析函数。
- 由 (a) 知 $Z_N(T)$ 解析，故 $\ln Z_N(T)$ 及 $F(N, T) = -k_B T \ln Z_N(T)$ 均为解析函数；自由能密度 $F(N, T)/N$ 同样解析，不存在任何严格非解析点，因而不存在严格意义上的相变。
- 这意味着有限参数量的神经网络（不论参数多大）的 “涌现” 行为在数学上只能是 crossover（平滑的快速变化），而非严格相变——即使看起来极为陡峭，也不存在奇异点；渗流临界指数等严格相变理论的预测结果不能直接套用于有限神经网络系统。

T-5.8.9 【中 · 工程意义 · ICL/CoT 中的渗流工程含义】 渗流框架在实际 LLM 工程中的意义。

- (a) Chain-of-Thought (CoT) 推理可以类比为渗流中的“连通路径”：每一步中间推理是一个概念节点，若某中间步骤的掌握概率低于 p_c ，整条推理链断裂。这对 CoT 的工程含义是什么？（短链 vs 长链的鲁棒性差异，2 句话）
- (b) 若要用“临界参数量 N^* ”来刻画 ICL 的涌现，这个 N^* 在工程上意味着什么？（1 句话）
- (c) 根据渗流可证伪预测（推理链越长，涌现越陡），工程上如何合理设计评估集来检验这一预测？（2–3 句话）

解答 T-5.8.9

- (a) CoT 与渗流类比：若某中间推理步骤的掌握概率低于 p_c ，整条推理链在该节点断裂，最终答案失败（类比于渗流路径在亚临界节点处中断）。工程含义：短链 CoT（步数少）比长链 CoT 更鲁棒——每增加一个推理步骤都要求该步的掌握概率超过有效 p_c ，长链任务在小模型上更容易因中间步骤失败而导致整体准确率急剧下降。
- (b) 若用“临界参数量 N^* ”刻画 ICL 涌现，它在工程上意味着：规模低于 N^* 的模型 ICL 能力约为零，超过后才以幂律增长——可用于指导模型大小的下限选择（例如：要做可靠的 few-shot 学习，模型规模至少需要达到 N^* ）。
- (c) 实验设计：构造同一技能（如三步推理）的不同链长版本（1 步、3 步、5 步、10 步），在多个模型规模上测量 exact match 准确率，观察涌现曲线的陡峭程度是否随链长增大而增大。若陡峭程度随链长单调增大，支持渗流可证伪预测；若所有链长的涌现曲线形态相同，则更可能是指标伪影，应换用连续指标进一步验证。

[工程批注] T-5.8.9 工程批注（渗流与 ICL/CoT）：induction head 的涌现（Olsson et al. 2022）发生在约 200M–1B 参数规模，在训练步数上与 ICL 能力高度同步，被认为是真实的“渗流临界”类型涌现——底层电路形成，触发了整体能力的阶跃。工程上这意味着：若要在 GPT-3 级别（175B）以下的模型上做可靠的多步 CoT，需要首先确认 induction head 类电路已经形成；对于极小模型（如 1B 以下），多步 CoT 在多步推理任务上准确率大幅下滑（据 Olsson 等实验数据），此时应改用工具调用（代码执行）替代纯文本推理，绕开连通性瓶颈。

【做完自检】

1. 渗流的序参量临界指数 $\beta = 5/36$ 来自哪个理论框架（精确结果还是数值近似）？它意味着序参量在临界点附近是缓慢启动还是快速跃升？
2. 为什么有限参数量的神经网络只能有 crossover 而非严格相变？热力学极限的数学必要性是什么？
3. 剪枝临界比例约 98% ($\bar{q}_c \approx 0.02$)，这在工程上意味着什么？临界点附近的功能对保留率有多敏感？

§5.9 习题：跨界映射与反类比：相变叙事的边界

导读：本节核心是「相变叙事的双重性」——渗流剪枝实验为「AI 涌现类相变」提供了形式相似的定量支撑，但热力学极限的缺失、后视镜叙事、以及不可逆性三条边界严格限制了这一类比的合法范围。五题分别对应：A（渗流剪枝的幂律推导）、B（热力学极限的有限系统修正）、C（后视镜叙事的方法论批判）、D（不可逆性与非平衡框架）、E（「类比是否合法」综合评判）。

题1【轻·轻推导·渗流剪枝与序参量行为】 导读：Frankle & Carlin (2019) 的彩票假设实验和 Goldt et al. 的渗流剪枝实验共同表明，神经网络中存在一个临界剪枝阈值 $\bar{q}_c$ ，低于此阈值时网络性能快速恶化，其行为形式上类似物理渗流相变中的序参量幂律。设渗流剪枝实验中，保留参数比例为 $\bar{q}$ ，性能指标（如准确率）在 $\bar{q} \geq \bar{q}_c$ 附近满足幂律关系：

$$F(\bar{q}) \sim (\bar{q} - \bar{q}_c)^\beta, \quad \bar{q} \geq \bar{q}_c, \quad \bar{q}_c \approx 0.98$$

- (1) 设 $\beta = 0.5$ （类比二维渗流的临界指数），计算：当 $\bar{q} = 0.99$ 时， $F(0.99)/F(0.999)$ 的比值（精确到四位小数）。
- (2) 物理渗流相变中， $\bar{q} < \bar{q}_c$ 时序参量严格为零（不渗透）。在神经网络剪枝实验中， $\bar{q} < \bar{q}_c$ 时网络性能是否严格为零？这一差异揭示了什么类比局限？
- (3) 写出「序参量急剧但连续过渡」（crossover）与「真正相变」（phase transition）的数学区别（用导数的存在性表述）。

教学注：渗流剪枝为「涌现类相变」提供的是**形式相似性**（幂律行为），而非**机制同一性**——物理渗流的幂律来自无标度关联长度发散，神经网络的幂律来自参数冗余结构，两者的微观机制完全不同。

陷阱： $\bar{q}_c \approx 0.98$ 意味着只需保留 2% 的参数网络性能就开始大幅下降——这与直觉「保留 98% 的参数应该差不多」相反，正是「稀疏彩票子网络」的反直觉核心。

题2【中·中计算·热力学极限与有限系统的解析性】 导读：物理相变（严格意义上的非解析性）只在热力学极限（ $N \rightarrow \infty$ ）下存在；有限系统的自由能 $f(N, T)$ 在任何温度 T 下都是解析函数。神经网络是有限系统，因此只有 crossover（连续渐变）而非相变。

- (1) 有限体积 N 的 Ising 模型，配分函数为 $Z_N = \sum_{\{s_i\}} e^{-\beta H}$ （有限项的有限求和）。解释为什么 Z_N 对任意 β 都是解析的（不需要具体计算，用有限项指数函数之和的性质论证）。
- (2) 设某神经网络的「等效系统大小」为参数量 $n = 10^{10}$ （典型大语言模型量级）。在有限系统中，相变点附近的「伪临界区域」宽度正比于 $N^{-1/\nu}$ （ ν 为临界指数， $\nu \approx 1$ 对三维 Ising）。当 $N = 10^{10}$ 时，伪临界区域宽度的量级是多少？这意味着什么？
- (3) 判断：「GPT-3 到 GPT-4 之间某些能力的‘突然’出现，在技术上构成相变（phase transition）」是否合理？

transition)。」这一论断在热力学极限的标准下是否成立?

教学注:「有限系统的自由能永远解析」是统计力学的严格定理 (Lee-Yang 定理的推论), 这使神经网络中的「相变」叙事在最严格意义上站不住脚——有限系统只有 crossover, crossover 的导数存在, 没有真正的奇异性。

陷阱:「解析」不等于「平滑」(在实践意义上)——有限系统的 crossover 可以非常陡峭, 在有限分辨率的测量下与真正的相变不可区分; 这不否定 crossover 现象的存在, 只是说它没有普适临界指数。

题 3【中·概念辨析·后视镜叙事与预测能力】 导读:「相变叙事」的第二条失效边界是方法论层面的——序参量是在观察到涌现之后才被识别出来的 (事后确认), 因此无法从相变理论推断「下一次涌现何时发生」。

(1) 物理相变理论 (如朗道理论) 在临界点之前可以预测: 温度降至 T_c 时磁化率发散, $T < T_c$ 时自发磁化出现。这一预测能力的数学基础是什么? (序参量、Landau 展开的先验知识角度)

(2) 对于 AI 能力涌现, 以下哪些要素是「后视镜叙事」所缺乏的, 因而无法做出类似预测?

逐条分析: - (A) 普适临界指数 β, ν, γ - (B) 序参量的先验定义 - (C) 控制参数 (类比温度) 的精确量化 - (D) 热力学极限的存在

(3) 构造一个「有预测能力的涌现叙事」的最低要求列表 (4 条), 说明目前 AI 能力预测研究满足了哪些条件、缺失了哪些。

教学注:后视镜叙事的识别标准: 如果一个理论框架对所有已发生的事件都能给出「相变」解释, 但对任何未来事件都无法给出确定性预测, 则该框架是后视镜叙事 (un-falsifiable narrative)。

陷阱:「后视镜叙事」不等于「错误叙事」——它可能正确描述了已发生的现象, 只是预测力为零; 科学的批评不是否认其描述价值, 而是指出其不能替代真正的预测理论。

题 4【中·辨析·不可逆性与非平衡框架】 导读: 物理相变沿可逆路径进行 (可以沿相图来回穿越相变点, 系统可逆地从一相转到另一相); AI 能力涌现和文明涌现是不可逆的 (已习得的能力无法通过「降温」消除)。这是最弱的失效边界, 但指向了非平衡物理的正确框架。

(1) 热力学中的「可逆过程」要求系统始终处于准静态平衡。对比训练过程: - 物理相变 (可逆): 系统在任意时刻处于热力学平衡, 可以精确定义「平衡自由能」。- 神经网络训练: 参数在梯度流中运动, 是否处于某种「平衡»? 如果定义「损失极小值 = 平衡态», 给出这一类比的一个成立之处和一个失效之处。

(2) 「非平衡相变」(non-equilibrium phase transition) 理论中有一类叫做「吸收态相变」(absorbing state transition): 系统一旦进入吸收态就永远无法离开。

判断: AI 能力涌现是否更适合用「吸收态相变」框架而非平衡相变框架来描述? 给出

两条支持和一条反对的论据。

(3) 用一句话回答：为什么不可逆性是一条失效边界中「最弱」的一条（即对类比的伤害最小）？

教学注：「吸收态相变」（如 DP 普适类——定向渗流）是非平衡统计力学的核心研究对象，其临界指数与平衡相变完全不同；若 AI 涌现真的是吸收态相变，则平衡相变的所有临界指数都是错误的类比框架，不是「稍有不同」而是「框架整体替换」。

陷阱：「不可逆性」是三条中「最弱」的原因是：即使承认不可逆，形式上的幂律行为和序参量概念仍然可以在非平衡框架下保留；而「热力学极限缺失」和「后视镜叙事」则分别从存在性和预测性上根本否定了相变框架的核心主张。

题 5【重·重评判·「相变类比是否合法」综合裁决】 导读：综合前四题的分析，本题要求对「AI 能力涌现 $\leftrightarrow$ 物理相变」这一类比做出层次化的合法性裁决——不是简单的「合法/不合法」，而是「在什么条件下合法到什么程度」。

(1) 完成以下裁决框架表：

使用层次	类比合法性	条件
定性描述（「类似相变的急剧过渡」）	?	?
半定量（引用幂律形式，不引用具体指数）	?	?
定量（引用临界指数 $\beta = 0.5$ 等具体数值）	?	?
预测（「下一次涌现将在规模 X 时发生」）	?	?

(2) 渗流剪枝实验（幂律 $F(\bar{q}) \sim (\bar{q} - \bar{q}_c)^\beta$ ）对「相变类比」的支撑力度如何？它回答了哪个层次的问题，没有回答哪个层次的问题？

(3) 以下两位研究者持相反立场：

研究者 A：「相变框架给我们提供了分析 AI 涌现的数学工具，虽然不完美，但有框架比没有好；我们应该大胆使用。」

研究者 B：「相变类比在最严格意义上不成立（有限系统，无普适指数，后视镜叙事），继续使用会误导 AI 安全研究；应该完全放弃。」

分析两位研究者论证的合理性与局限性（各 3–4 句），然后给出你自己的折衷立场（3–4 句）。

教学注：科学类比的「合法使用」是科学哲学的核心问题之一——类比从来不需要在所有层面都成立才有价值，关键是明确说出「有效域」和「误用后果」。

陷阱：(3) 的折衷立场不是「各打五十大板」的模糊回答，而是需要给出具体的条件句：「在 X 条件下类比合法，在 Y 条件下应停止使用，理由是 Z 」。

解答 § 5.9

T-5.9.1 【渗流剪枝与序参量行为】 (1) 比值计算：

$$\beta = 0.5, \bar{q}_c = 0.98.$$

$$F(0.99) \sim (0.99 - 0.98)^{0.5} = (0.01)^{0.5} = 0.1000$$

$$F(0.999) \sim (0.999 - 0.98)^{0.5} = (0.019)^{0.5} \approx 0.1379$$

$$\frac{F(0.99)}{F(0.999)} = \frac{0.1000}{0.1379} \approx 0.7253$$

(精确: $\sqrt{0.01}/\sqrt{0.019} = \sqrt{0.01/0.019} = \sqrt{0.5263} \approx 0.7254$)

(2) **严格零 vs 渐变**: 在物理渗流中, $\bar{q} < \bar{q}_c$ 时导电率严格为零 (无穿越路径); 在神经网络剪枝中, $\bar{q} < \bar{q}_c$ 时性能退化但不为零 (网络仍可输出, 只是质量低)。这揭示了类比局限: 物理相变有严格的「有序相 / 无序相」二值分类, 神经网络只有性能的连续退化; 二值性的缺失是「crossover 而非 phase transition」的另一个表现。

(3) **数学区别**:

- **真正相变**: 序参量 $\phi(T)$ 在 $T = T_c$ 处不可微 ($d\phi/dT|_{T_c^-} \neq d\phi/dT|_{T_c^+}$), 或某阶导数发散; 自由能的某阶导数在 T_c 处不连续。
- **Crossover**: $\phi(\bar{q})$ 在 $\bar{q} = \bar{q}_c$ 附近急剧变化, 但所有阶导数均存在且有限; 只是变化快, 不是数学奇异。

Sanity check: $F(0.99)/F(0.999) \approx 0.7254$, 保留 99.9% 参数比保留 99% 参数的性能高出约 38% ($0.1379/0.1000$), 体现了临界点附近的「放大效应」——这正是幂律行为的特征。

T-5.9.2 【热力学极限与有限系统的解析性】 (1) 解析性论证:

配分函数 $Z_N = \sum_{\{s_i\}} \exp(-\beta H(\{s_i\}))$ 是有限项 (2^N 项) 的有限正实数之和。每一项 $\exp(-\beta H)$ 对 β 都是实解析函数 (指数函数无处奇异); 有限个解析函数之和仍是解析函数。因此 $Z_N(\beta) > 0$ 且关于 β 处处可微——自由能 $f_N = -\frac{1}{N} \ln Z_N$ 同样解析。非解析性 (相变) 只在 $N \rightarrow \infty$ 时因零点的热力学极限引起。■

(2) **伪临界区域宽度**:

$$\Delta T \sim N^{-1/\nu} = (10^{10})^{-1} = 10^{-10} \quad (\nu = 1 \text{ 时}).$$

这意味着: 即使大语言模型存在某种「临界点」, 其「临界区域」宽度约为控制参数 (如训练步数的对数) 的 10^{-10} 量级——实验上完全无法分辨, 只能看到一个陡峭但解析的 crossover。

(3) **论断评判**: 在热力学极限标准下不成立。GPT-3 和 GPT-4 是有限参数系统, 其自由能 (若可定义) 在任意点都是解析的, 不存在真正的相变奇异性。「突然出现」是 crossover 在有限分辨率测量下的表现, 没有普适临界指数, 不能称为相变。

Sanity check: 伪临界区域 10^{-10} 远小于任何实验能分辨的尺度, 这不是说明相变不存在, 而是说明「即使有相变, 有限系统效应使我们根本无法区分它与 crossover」。

T-5.9.3 【后视镜叙事与预测能力】 (1) 物理相变的预测能力基础：

朗道理论在观测涌现之前就知道：(a) 对称性决定了序参量是哪个量（如磁化强度）；(b) Landau 展开 $F = a(T - T_c)\phi^2 + b\phi^4 + \dots$ 给出先验形式；(c) 临界指数由对称性和维度决定（普适类）。这使预测成为可能：给定控制参数 T ，可以计算何时 $\phi \neq 0$ 。

(2) 后视镜叙事缺乏的要素：

- (A) 普适临界指数：缺乏。AI 涌现没有被归入任何已知的普适类，无法从对称性推导。
- (B) 序参量的先验定义：缺乏。每次涌现后才识别出对应的序参量（如「能做几步推理」），无法事前定义。
- (C) 控制参数的精确量化：部分缺乏。参数量、FLOP、数据量都是候选控制参数，但它们之间的关系和哪个是「真正的控制参数」尚无共识。
- (D) 热力学极限的存在：缺乏。有限参数系统，已在题 2 中分析。

(3) 有预测能力的涌现叙事最低要求：

- (1) 先验序参量：在涌现发生前定义序参量（什么量从 0 跃升为非零）；
- (2) 控制参数量化：明确单一控制参数及其与模型的对应关系；
- (3) 临界点预测：从理论（而非曲线拟合）给出 T_c 的预测，可被未来实验证伪；
- (4) 普适性主张：声明预测对一类模型（而非特定模型）成立，具备可复制性。

目前 AI 能力预测研究满足的条件：(2) 部分满足（scaling law 对参数量有量化关系）；缺失条件：(1)（序参量全部事后确认）、(3)（无理论推导的临界点）、(4)（普适类未建立）。

Sanity check： 四条最低要求与物理相变理论的「已知」对应——朗道理论满足全部四条，AI 涌现研究只满足一条。

T-5.9.4 【不可逆性与非平衡框架】 (1) 类比成立与失效：

成立之处：如果将「损失极小值」类比「热力学平衡态」，则「梯度下降收敛到极小值」类比「弛豫到平衡」；两者都有「趋向更低能量/损失状态」的方向性（第二定律类比）。

失效之处：热力学平衡要求系统能够遍历所有微态（各态历经假设），神经网络的参数空间极高维度下梯度下降只探索了极小的局部区域，远非遍历——「平衡」概念无法全局成立；训练停止后参数固定，无法继续弛豫，与真正的平衡（时间平均 = 系综平均）相去甚远。

(2) 吸收态相变判断：

支持：① AI 习得的能力（如语言理解）一旦通过足够训练获得，在正常使用中不会消失——满足「进入吸收态不可离开」；② 能力涌现后性能快速趋于稳定，类似吸收态相变中序参量在转变后维持非零值；

反对：吸收态相变的「吸收态」是严格静止状态（不再发生转变），但已训练好的模型可以继续微调、持续学习，并非真正的「吸收态」——更接近亚稳态（metastable）。

state)。

(3) **不可逆性最弱的原因**：不可逆性失效边界只说明「需要非平衡框架而非平衡框架」，但**幂律行为、序参量概念、临界放大效应**在非平衡相变（如吸收态相变）中同样存在——换框架不必放弃形式结构，只需修改物理解释；而「热力学极限缺失」否定的是临界奇异性的存在，「后视镜叙事」否定的是预测能力，这两条从根本上打击了相变类比的核心主张。

Sanity check：三条失效边界的「强度」梯度：热力学极限（存在性级别）> 后视镜叙事（预测性级别）> 不可逆性（框架选择级别），与本节正文的层次划分一致。

T-5.9.5 【「相变类比是否合法」综合裁决】（1）裁决框架表：

使用层次	类比合法性	条件
定性描述（「类似相变的急剧过渡」）	合法	明确说明是 crossover 而非严格相变，不声明普适指数
半定量（引用幂律形式，不引用具体指数）	条件合法	仅用于描述渗流剪枝等实验的拟合结果，不外推至其他能力
定量（引用临界指数 $\beta = 0.5$ 等具体数值）	不合法	有限系统无普适临界指数，数值借用物理指数无理论依据
预测（「下一次涌现将在规模 X 时发生」）	不合法	后视镜叙事，无先验序参量和临界点推导，不具备预测能力

(2) 渗流剪枝实验的支撑力度：

渗流剪枝实验在「半定量」层次提供了支撑——它展示了真实神经网络中存在急剧的性能-参数率拐点，以幂律形式拟合良好，为「类相变行为」提供独立实验证据。

它回答了：「神经网络是否存在类相变行为」（形式上是）和「幂律指数的量级」（ $\beta \sim 0.5$ ）。

它没有回答：「为什么是这个指数」（没有理论推导）；「该指数是否普适」（仅在剪枝实验中测量）；「能否预测能力涌现的临界规模」（无）。

(3) 两位研究者分析与折衷立场：

研究者 A 的合理性：有框架确实比没有框架好——相变语言提供了一套工具（序参量、控制参数、临界指数）来**组织观察**，即使工具不完美也能推动研究的系统化；Scaling Law 研究（Kaplan et al., 2020）正是在某种「相变框架」的指引下发现了有用的幂律规律。**局限性**：「有框架比没有好」仅在框架被正确标注（明确声明局限）时成立；不加

限制地使用错误框架会产生错误置信——「下一次 GPT 涌现将在 10^{13} FLOP 时发生」这类预测因为有了相变框架的光环而被过度相信，误导资源分配。

研究者 B 的合理性：三条失效边界均有严格数学基础，尤其「有限系统无真正相变」是定理级别的结论；AI 安全研究若依赖相变框架预测涌现时间线，会产生系统性错误（过度自信于不可靠的预测）。**局限性：**「完全放弃」走向了另一个极端——放弃相变语言意味着放弃描述急剧变化的现成词汇，而没有替代的定量框架；现有的「crossover」框架同样无法预测，只是缺少了「听起来更有预测力」的错觉，未必对研究更有益。

折衷立场：相变类比在「定性描述急剧变化」和「渗流剪枝等受控实验的半定量分析」范围内是合法的工具，应继续使用但明确附上边界声明；凡是引用具体临界指数或声称可以预测涌现时间的用法，应被视为越界并加以纠正；科学社群的责任是建立一套替代性框架（非平衡统计、有限系统 crossover 理论、信息论容量框架），而不是在旧框架内「大胆使用」或干脆弃用。

Sanity check：裁决表中四个层次与前四题的分析结果一一对应——定量和预测两层的「不合法」分别来自题 2（热力学极限）和题 3（后视镜叙事）的结论。

§ 7.6 将进入完全不同的技术领域，用类似的「统一视角」方法把 Mamba、线性注意力和 RNN 纳入同一框架——从批判性类比审查转向建设性统一理论。

§ 5.X 补充与拓展题

本节补充题按所属小节归位（编号沿用原序号，不再分章）。

§ 5.1 补充题

T-5.1.9 【中·变形·幂律的对数倒数关系】 设 $L(N) = (N_c/N)^{\alpha_N}$ ，已知在某参数量 N_0 时 $L(N_0) = L_0$ 。

- 写出使 loss 降低到 $L_0/2$ （即 loss 减半）所需的参数量倍增因子 k 的表达式， $k = 2^{1/\alpha_N}$ ，代入 $\alpha_N = 0.076$ 计算 k ；
- 从 10^9 参数出发，要把 loss 减半，需要把参数量增大到多少？
- 这个“loss 减半所需倍增”在工程上意味着什么（提示：成本与收益的关系，1 句话）？

解答 T-5.1.9

- 令 $L(kN_0) = L_0/2$ ： $(N_c/(kN_0))^{\alpha_N} = (N_c/N_0)^{\alpha_N}/2$ ，解得 $k^{\alpha_N} = 2$ ，即 $k = 2^{1/\alpha_N} = 2^{1/0.076} = 2^{13.16} \approx 9270$ 。
- 从 10^9 参数出发，需要增大到 $k \times 10^9 \approx 9270 \times 10^9 = 9.27 \times 10^{12}$ （约 9 万亿参数）才能把 loss 减半。
- loss 减半需要参数量增大近万倍——收益增长速度极慢，边际回报持续递减，这就是为何 scaling 代价如此高昂，而且几乎没有“免费的午餐”。

T-5.1.10【中·工程·Kaplan 与 Chinchilla 幂指数的差异来源】 Kaplan 的 $\alpha_N \approx 0.076$ 和 Hoffmann 的 $\alpha \approx 0.34$ 都是关于参数量的幂指数，但数值相差约 4.5 倍。

- Kaplan 的 α_N 来自单变量公式 $L(N)$ (固定充分训练数据)，而 Hoffmann 的 α 来自联合损失 A/N^α (固定算力下联合优化)。两者的拟合条件有何本质不同？
- 在”充分训练”(数据充足)的前提下，单变量参数律的斜率为何更平缓 (α_N 更小)? (提示：数据充分时 $B/D^\beta \rightarrow 0$ ，参数的边际回报更纯粹)
- 工程上应该用哪个参数来指导”给定算力，如何分配参数和 token 数”? (一句话，选 Kaplan 还是 Hoffmann?)

解答 T-5.1.10

- Kaplan 的单变量拟合假设”充分训练”(即每组测量都让数据量足够大， $B/D^\beta \approx 0$)，因此测量的是单纯参数量对 loss 的影响；Hoffmann 的联合拟合在固定 $C = 6ND$ 下同时优化两个变量， α 反映的是在固定算力预算约束下参数的边际贡献，两个 α 的语义完全不同。
- 在”充分训练”前提下，数据项 $B/D^\beta \rightarrow 0$ ，loss 主要由参数项主导，单变量参数律的斜率接近”纯参数”的边际回报，比 Hoffmann 在联合优化框架下小——因为联合优化中数据和参数相互制约，参数的联合边际回报被放大。
- 应用 Hoffmann ($\alpha = 0.34$) 来指导”给定算力，如何分配参数和 token 数”，因为这个值来自联合优化 (IsoFLOP 实验)，直接回答了该问题；Kaplan 的单变量 α_N 不适合用于此类联合优化判断。

T-5.1.11【难·证明·算力律与参数律/数据律的关系】 设 $\alpha = 0.34$, $\beta = 0.28$ (Hoffmann 拟合值)，最优点满足 $N^* \propto C^{\beta/(\alpha+\beta)}$, $D^* \propto C^{\alpha/(\alpha+\beta)}$ 。

- 在最优点处，代入 $L(N^*, D^*) = E + A/(N^*)^\alpha + B/(D^*)^\beta$ ，证明 $L^* - E \propto C^{-\alpha\beta/(\alpha+\beta)}$ ；
- 算力律的幂指数 $\alpha_C = \alpha\beta/(\alpha + \beta)$ ，代入 Hoffmann 值计算 α_C ；与 Kaplan 的 $\alpha_C \approx 0.050$ 相比，结果如何？
- 这说明算力律 ($L(C)$ 的幂指数) 是参数律和数据律的”调和均值”形式，解释其直觉含义 (1 句话)。

解答 T-5.1.11

- 在最优点处，由最优条件 $\alpha A/N^\alpha = \beta B/D^\beta$ ，设公共值为 μ ，则 $A/N^\alpha = \mu/\alpha$, $B/D^\beta = \mu/\beta$ 。

故 $L^* - E = \mu/\alpha + \mu/\beta = \mu(\alpha + \beta)/(\alpha\beta)$ 。

由约束 $N^* \propto C^{\beta/(\alpha+\beta)}$ ，代入最优条件可得 $\mu \propto C^{-\alpha\beta/(\alpha+\beta)}$ ，从而 $L^* - E \propto C^{-\alpha\beta/(\alpha+\beta)}$ 。

- $\alpha_C = \alpha\beta/(\alpha + \beta) = 0.34 \times 0.28/(0.34 + 0.28) = 0.0952/0.62 \approx 0.1535$ 。

与 Kaplan 的 $\alpha_C \approx 0.050$ 相比，Hoffmann 值下算力律的幂指数约为 0.154，比 Kaplan 大约 3 倍——说明 Hoffmann 框架预测的 loss 随算力下降更快 (在联合优化配比下，同

样算力带来的 loss 改善更大)。

- (c) 算力律的幂指数 $\alpha_C = \alpha\beta/(\alpha + \beta)$ 是参数和数据两个幂指数的”调和平均”形式，直觉是：在最优配比下，loss 的改善同时受制于参数的边际回报 (α) 和数据的边际回报 (β)，最终算力的有效边际回报取两者的调和均值。

§ 5.2 补充题

T-5.2.7 【中·判错·Chinchilla 的”最优”的适用范围】 某工程师说：“Chinchilla 已经证明了所有大模型都应该用 1:20 的 $N:D$ 配比训练，否则就是浪费算力。”

- 指出该说法的两处过度简化（提示：Sardana 修正 + 置信区间问题）；
- Chinchilla 最优配比的前提条件是什么（完整描述约束 $C = 6ND$ 的含义）？
- 在什么场景下，偏离 1:20 配比（如 1:94 配比）反而是更好的工程选择？（2 句话）

解答 T-5.2.7

- 两处过度简化：(1) Sardana 修正指出，当推理调用量 $n_{\text{inf}} \gg 3D$ 时，推理成本主导总预算，最优配比应偏向更小的 N （而非 1:20），“超量训练”反而是正确选择；(2) Epoch AI（2024）指出 Chinchilla 方法三的置信区间过窄，真实的不确定性远大于论文报告，“精确的 1:20”应理解为数量级方向，而非精确比例。
- Chinchilla 最优配比的前提：在固定训练总算力 $C = 6ND$ 的约束下（即不考虑推理成本），最小化联合 loss $L(N, D)$ 。这里”固定 C ”假设训练完成后模型不会被大规模推理部署。
- 在推理优先的大规模部署场景（如 LLaMA 系列的公开部署），偏离 1:20 而采用 1:94（如 LLaMA-3 8B）甚至更高的 D/N 比是更好的选择——小模型每次推理 FLOPs 更少，超量训练弥补容量不足，总体 TCO（总拥有成本）更低。

T-5.2.8 【易·代人·DeepSeek-V3 配比较证】 DeepSeek-V3 使用了约 671B 参数 ($N \approx 6.71 \times 10^{11}$)，训练了约 14.8T tokens ($D \approx 1.48 \times 10^{13}$)。

- 计算 DeepSeek-V3 的实际配比 D/N （保留 2 位有效数字）；
- 与 Chinchilla 的 1:20 规则相比，DeepSeek-V3 的 token 配比偏多还是偏少？偏多约多少倍？
- 用 Sardana 修正框架解释：为什么 DeepSeek-V3 选择超过 Chinchilla 最优的 token 数是合理的？（提示：推理部署规模，1–2 句话）

解答 T-5.2.8

- 实际配比： $D/N = 1.48 \times 10^{13} / 6.71 \times 10^{11} \approx 22.1$ ，即约 1:22。
- Chinchilla 的 1:20，DeepSeek-V3 的 1:22 比 Chinchilla 最优偏多约 1.1 倍（略超 Chinchilla 最优，不是大幅超出）。

- (c) DeepSeek-V3 的 671B 参数面向大规模 API 部署，推理需求量极大；按 Sardana 修正，当 $n_{\text{inf}} \gg 3D$ 时超量训练合理，即使 1:22 略超 Chinchilla 最优，也在推理优先的理论框架内。此外，DeepSeek-V3 使用了 MoE 架构（稀疏激活），实际推理 FLOPs 远小于 $2N$ ，进一步支持了超量训练的合理性。

T-5.2.9 【易 · 代入 · IsoFLOP 曲线直觉】 Hoffmann 方法一 (IsoFLOP)：在固定算力 $C = 6 \times 10^{22}$ FLOPs 下，扫描不同 (N, D) 配比并测量 loss。

- (a) 若固定 $C = 6 \times 10^{22}$ ，计算以下三种配比的 (N, D) 组合： $N/D = 1/1$ ， $N/D = 1/10$ ， $N/D = 1/100$ （给出每种情况下 N 和 D 的具体值）；
 (b) 三种配比中，哪种最接近 Chinchilla 的 1:20 建议？
 (c) IsoFLOP 方法的核心思想是什么（1 句话，为何比单独扫描参数量更可靠）？

解答 T-5.2.9

- (a) 固定 $C = 6 \times 10^{22}$ ，即 $ND = 10^{22}$ ：
- $N/D = 1/1$ ： $N = D = \sqrt{10^{22}} = 10^{11}$ ，即 100B 参数，100B tokens
 - $N/D = 1/10$ ： $D = 10N$ ， $10N^2 = 10^{22}$ ， $N = 10^{10.5} \approx 3.16 \times 10^{10}$ ， $D \approx 3.16 \times 10^{11}$
 - $N/D = 1/100$ ： $D = 100N$ ， $100N^2 = 10^{22}$ ， $N = 10^{10}$ ， $D = 10^{12}$
- (b) $N/D = 1/100$ 时，配比约为 1:100，最接近 Chinchilla 建议的 1:20 方向（远比 1:1 或 1:10 接近），但仍是 Chinchilla 最优的 5 倍 token 配比。
- (c) IsoFLOP 方法的核心：在固定总算力 C 的等算力曲线上测量不同 (N, D) 配比的 loss，直接找出哪个配比使 loss 最小——比单独改变参数量或 token 数更能直接回答”如何分配 C “这一问题。

§5.3 补充题

T-5.3.4 【中 · 判错 · 合成数据无限循环的误解】 某团队计划用以下流程扩充训练数据：“用现有模型生成 10T 合成 token，与原始 1T 真实 token 混合，训练新模型，再生成更多合成数据，如此循环 5 代。”

- (a) 根据模型崩溃理论 ($\Sigma_n \rightarrow 0$)，该策略的主要风险是什么？
 (b) 若真实数据与合成数据的混合比例为 1:10（真实:合成），方差退化的速度是否会减缓？定性分析；
 (c) 工程上，如何在利用合成数据的同时避免模型崩溃？（2 种方案，各一句话）

解答 T-5.3.4

- (a) 根据模型崩溃理论，每代合成数据会截断低概率区域（尾部），方差 $\Sigma_n \rightarrow 0$ ——多代循环后，生成文本多样性趋于消失，输出分布退化为均值附近的狭窄分布，创造性和覆盖度均严重下降。

- (b) 1:10 混合（真实:合成）会减缓退化速度，因为每代真实数据提供了多样性的”锚点”，阻止方差完全归零；但若循环足够多代，真实数据的”稀释效应”仍会导致方差缓慢下降。定性而言：混合比中真实数据越多，模型崩溃越慢，但无法完全消除。
- (c) 两种方案：(1) 数据混合锚定：每代始终保持真实数据的固定比例，不超过一定的合成/真实比例（如不超过 3:1）；(2) 合成数据去重与多样性过滤：对合成数据做主成分分析，过滤与已有真实数据分布过于接近的样本，保留覆盖真实分布尾部的合成样本。

§ 5.5 补充题

T-5.5.7【易·代入·BIG-Bench chance accuracy 的影响】 BIG-Bench 某任务是 4 选 1 的多项选择（每题 4 个选项，一个正确答案）。

- (a) 随机猜测的 chance accuracy 是多少？
- (b) 若一个小模型在 100 个样本上的准确率为 28%，与 chance 相比如何？是否达到”涌现”？
- (c) 若换成 2 选 1（是/否题），chance accuracy 变为多少？同一个模型的 28% 准确率现在意味着什么？

解答 T-5.5.7

- (a) 4 选 1 的 chance accuracy $= 1/4 = 25\%$ 。
- (b) 28% 略高于 chance (25%)，差距仅 3 个百分点，在 100 个样本下约为 1σ 的噪声（估计标准差 $\sqrt{0.25 \times 0.75/100} \approx 4.3\%$ ），统计上不显著。不能认为达到了有意义的”涌现”——模型几乎与随机猜测持平。
- (c) 换为 2 选 1，chance accuracy $= 50\%$ 。此时 28% 准确率低于 chance，模型表现不如随机猜测，说明模型对这类任务存在系统性偏见（反向倾向）。

T-5.5.8【中·工程·连续指标的实践设计】 研究者想验证某任务上的”涌现”是否是指标伪影。

- (a) 提出两种可以替代 exact match 的连续指标，
- (b) 提出两种可以替代 exact match 的连续指标，并说明各自的 $m'(p)$ 是否处处非零；
- (c) 若用 perplexity（困惑度 $\text{PPL} = e^{-\log \text{likelihood}}$ ）作为指标， dm/dN 中的 $m'(p)$ 是什么？（提示：PPL 与 log-likelihood 的单调关系）
- (d) 实践中，为什么不能完全依赖连续指标来否定涌现？（提示：induction head，1–2 句话）

解答 T-5.5.8

- (a) 两种连续指标：(1) token-level log-probability: $m(p) = \log p$, $m'(p) = 1/p > 0$, 处处非零；(2) calibrated probability (校准概率): $m(p) = p$, $m'(p) = 1$, 处处非零。两者均不会在任何 p^* 处产生 delta 函数放大。
- (b) 若用 perplexity $\text{PPL} = e^{-\log \text{likelihood}}$: PPL 是 log-likelihood 的单调递减函数, $m'(p)$ 在 PPL 的语境下等效于 $d(\text{PPL})/dp = -1/p \times e^{-\log p}$ (处处负且非零), 因此 $dm/dN = m'(p) \cdot dp/dN < 0$ 处处光滑 (无 delta 脉冲), PPL 下降曲线平滑。
- (c) 不能完全依赖连续指标否定涌现, 因为如 induction head 这样的真实能力阈值, 在换用连续指标后拐点仍然可见——这类真实涌现的底层机制 (电路形成) 才是无法被连续指标“消除”的。连续指标是必要检验, 不是充分否定标准。

T-5.5.9【易·代入·BIG-Bench 任务中 chance accuracy 与涌现时刻的关系】 设两个任务: 任务 A 是 4 选 1 (chance = 25%), 任务 B 是 10 选 1 (chance = 10%)。两个任务的底层 token 级准确率 $p(N)$ 对数线性增长速率相同, 且两个任务的序列长度均为 $\ell = 1$ (单 token 预测)。

- (a) 对 $\ell = 1$, $M_{\text{exact}} = p(N) = p$, 此时“达到 chance accuracy”对应的 token 级准确率分别是多少?
- (b) 若模型规模从 10^8 参数开始, $p(N)$ 随 $\log N$ 线性增长: 哪个任务的“涌现时刻”(首次超过 chance accuracy) 会先到来?
- (c) 说明: chance accuracy 越低的任务, 涌现时刻越早还是越晚? 这对“哪些任务更容易出现涌现”有何启示?

解答 T-5.5.9

- (a) 对 $\ell = 1$, “达到 chance accuracy”即 $p = \text{chance}$:
- 任务 A (4 选 1): $p_A^* = 1/4 = 0.25$
 - 任务 B (10 选 1): $p_B^* = 1/10 = 0.10$
- (b) 若 $p(N)$ 随 $\log N$ 线性增长, 从某初始 $p_0 < 0.10$ 开始, 任务 B 的 chance (0.10) 先于任务 A (0.25) 被突破——任务 B 的“涌现时刻”更早到来。
- (c) chance accuracy 越低, 涌现时刻越早——因为模型需要跨越的“门槛”更低, 在更小的规模下即可超过 chance。这意味着: 10 选 1 的任务 (如某些 BIG-Bench 难题) 会比 4 选 1 的任务更早呈现涌现, 但这并不说明模型的“真实能力”更强, 只是涌现门槛更低。工程含义: 评估任务设计的 chance accuracy 直接影响“涌现时刻”的观测, 不能用涌现时刻的早晚来比较不同任务的相对难度。

§ 5.6 补充题

T-5.6.8【中·变形·频率数量与泛化能力的关系】 在 Grokking 实验中, 模型自发选择约 5 个频率 ($|K| \approx 5$)。

- (a) 理论上, 如果模型选择了更多频率 $|K| = 20$, 逆傅里叶解码的 logit 向量 $\hat{g}_c$ 中, 正确答案 $c = (a+b) \bmod p$ 对应的 logit 值 (等于 $\sum_{k \in K} w_k$) 会更大还是更小 (假

设 $w_k > 0$)? 为什么?

- (b) 更多频率是否总是更好? 从权重衰减的角度分析: 更多频率意味着更大的 $\|\theta_{\text{Fourier}}\|_2^2$, 这对 Grokking 时刻有何影响?
- (c) 模型自发选择约 5 个频率 (而非更多), 这在 representation learning 假说下意味着什么? (1-2 句话, 提示: Occam's razor + 最小描述长度)

解答 T-5.6.8

- (a) 若模型选择了 $|K| = 20$ 个频率 (假设每个 $w_k > 0$), 正确答案的 logit 值 = $\sum_{k=1}^{20} w_k$, 由于包含了更多正权重项, 数值更大, 理论上区分度 (signal-to-noise ratio) 更高。
- (b) 更多频率意味着傅里叶电路的权重范数 $\|\theta_{\text{Fourier}}\|_2^2$ 更大 (需要更多权重来编码更多频率), 受权重衰减的惩罚也更大, 可能会推迟 Grokking 时刻或使傅里叶电路与记忆电路的竞争更激烈。因此更多频率不总是更好——存在一个平衡点。
- (c) 模型自发选择约 5 个最有效的频率 (最小描述长度原则): 在完成任务所需的最少频率数和权重衰减压力之间取得平衡。这支持“表示学习假说” (representation learning hypothesis) ——模型主动学习最紧凑、泛化性最强的表示, 而非死记全部训练样本的稀疏特征。

T-5.6.9【难·证明·素数 p 在傅里叶基中的作用】 在 Grokking 实验中, 取 $p = 113$ (素数) 而非合数。

- (a) 若取 $p = 12$ (合数, $12 = 4 \times 3$), 整数 $\{0, \dots, 11\}$ 模 12 加法运算下, $\{0, 3, 6, 9\}$ 构成一个子群。这对傅里叶基的“唯一性” (每个整数对应单位圆上唯一的点) 有何影响?
- (b) 为什么素数 p 保证 $\{0, \dots, p-1\}$ 在模加法下是最大循环群, 从而使傅里叶基在 p 个整数上形成正交基? (定性说明, 不需要严格群论证明)
- (c) 这说明 Grokking 实验选择素数模的原因是什么 (数学简洁性角度, 1 句话)?

解答 T-5.6.9

- (a) 若 $p = 12$ (合数), 子群 $\{0, 3, 6, 9\}$ 的存在导致整数 3 和整数 $3 + 12/4 \cdot k$ 在模 12 意义下具有相同的代数性质, 打破了“每个整数对应唯一相位”的理想——在 p 分之一频率处, 子群中的元素会映射到同一相位, 傅里叶基失去正交性, 不同整数的 embedding 可能发生混叠。
- (b) 素数 p 的 $\{0, \dots, p-1\}$ 在模加法下构成最大循环群 (cyclic group of order p), 任意非零元素均为生成元, 无非平凡子群。这保证了 DFT 基 $\{e^{2\pi i kn/p} : k = 0, \dots, p-1\}$ 在 p 个整数上形成完备正交基, 每个整数唯一对应单位圆上一个相位。
- (c) 素数模保证了 embedding 空间中每个整数的表示相互独立, 使模型可以干净地在频域实现模加法, 不受子群混叠的干扰。

§ 5.8 补充题

T-5.8.10 【中·判错·临界指数的错误使用】 某论文声称：“通过分析 BIG-Bench 100 个任务的涌现曲线，我们拟合出 AI 涌现的通用临界指数 $\beta_{AI} \approx 0.15$ ，与渗流的 $\beta = 5/36 \approx 0.139$ 极为接近，证明大模型涌现属于同一普适类。”

- 指出该论证的根本错误：普适类（universality class）的定义要求什么条件？（提示：热力学极限 + 连续相变）
- 为什么数值相近（ $0.15 \approx 0.139$ ）不能证明“属于同一普适类”？（提示：crossover 的陡峭程度依赖系统细节）
- 如何设计一个更严格的实验来检验“AI 涌现是否具有普适临界行为”？（2-3 句话）

解答 T-5.8.10

- 普适类的定义要求：(1) 系统在热力学极限（ $N \rightarrow \infty$ ）下具有严格的连续相变（非解析点）；(2) 普适临界指数仅由系统的维度和对称性决定，不依赖微观细节。AI 涌现是有限系统的 crossover，不满足条件 (1)，因此“拟合临界指数”在这里没有严格的物理意义。
- crossover 的“陡峭程度”由系统细节（模型架构、任务类型、指标选择）决定，可以产生任意数值的“表观幂指数”，数值与渗流接近是纯粹的巧合（无穷多数据点中总能找到与 $5/36$ 相近的拟合值），不能证明属于同一普适类。
- 严格实验：(1) 在多个不同模型架构（Transformer、RWKV、Mamba）的无穷大极限下（逐步增大规模，外推到 $N \rightarrow \infty$ ）检查 crossover 的陡峭程度是否收敛到相同值；(2) 在不同维度（参数量 N vs 训练 token 数 D ）的控制变量实验下，检查“涌现临界指数”是否对架构细节具有普适性——如果各架构给出不同的“临界指数”，则否定普适类假说。

T-5.8.11 【中·工程·剪枝与渗流的工程应用】 Pesce 等（arXiv 预印本, 2025）发现，神经网络最高可移除约 98% 的边而性能损失很小，越过临界点 $\bar{q}_c \approx 0.02$ 后才崩塌。（本数据来自预印本，正式发表前请以最终版为准。）

- 这一结果对大模型压缩（model compression）有何工程启示？在 $\bar{q} = 0.5$ （保留 50% 的边）时，功能 $F(0.5) = (0.5 - 0.02)^{5/36}$ 是多少？
- 若要将一个模型压缩到仅保留 5% 的边，功能约为 $F(0.05) \approx 0.614$ （前面已算），这意味着什么工程权衡？
- 渗流理论预测：在临界点附近（ $\bar{q}$ 略大于 $\bar{q}_c$ ），功能对边保留率的敏感度极高。这在工程上意味着什么？（提示：过度压缩的风险，1-2 句话）

解答 T-5.8.11

- 工程启示：大多数参数/边是冗余的，极度稀疏的网络（仅保留约 2% 的边）仍具备基本功能，这为激进的模型压缩提供了理论依据。计算 $F(0.5) = (0.5 - 0.02)^{5/36} = 0.48^{5/36}$ ： $\ln(0.48) \approx -0.734$ ， $F = e^{(5/36)(-0.734)} = e^{-0.102} \approx 0.903$ 。保留 50% 的边时，功能约恢复到 90%。

- (b) 保留 5% 的边时功能约为 0.614 (约 61%)，意味着约 39% 的功能损失——对大多数实际应用而言是不可接受的退化 (即使 5% 远超临界保留率 2%，仍处于功能恢复的“缓慢启动”区)。这说明临界点以上的“缓慢启动”区间需要保留相当比例的边才能达到实用性能。
- (c) 在临界点附近 ($\bar{q}$ 略大于 $\bar{q}_c = 0.02$)，功能对边保留率极度敏感——保留率从 2% 增至 3% (绝对值增加 1%)，功能大幅跃升；这意味着工程实践中过度剪枝 (压缩到接近临界点) 存在极大风险：一旦因量化误差或硬件精度问题使有效保留率低于 $\bar{q}_c$ ，功能将完全崩溃，没有“优雅退化” (graceful degradation)。

T-5.8.12【中·综合·渗流临界指数 $\beta = 5/36$ 的来源】 临界指数 $\beta = 5/36$ 通过共形场论 (CFT) 和 SLE (Schramm-Loewner Evolution) 理论严格证明，是数学意义上的精确值。

- (a) 为什么二维渗流的临界指数具有“普适性”——即对不同的格点类型 (正方、三角、蜂窝格点)， β 的值相同？ (提示：临界点处的共形对称性，1-2 句话)
- (b) 与三维渗流 ($\beta \approx 0.418$) 相比，二维渗流的 $\beta = 5/36 \approx 0.139$ 更小。这意味着什么 (序参量启动更快还是更慢)？
- (c) 若在 AI 涌现中真的存在与渗流同类的临界现象，我们应期望在不同模型架构间看到什么？ (提示：普适临界指数的含义，1 句话)

解答 T-5.8.12

- (a) 临界点处的共形不变性：二维连续相变在临界点处具有共形对称性 (conformally invariant)，这是比各向同性更强的约束，使系统的长程行为仅由对称性决定，与格点细节无关——正方、三角、蜂窝格点在临界点处均属于同一普适类 (2D percolation universality class)，因此 β 的值相同。
- (b) 三维渗流的 $\beta \approx 0.418 > 5/36 \approx 0.139$ ，这意味着序参量启动更快——三维空间中连通簇从临界点出发的增长速度快于二维，反映了更高维度中连通路程“更容易”形成 (更多的近邻可以连通)。
- (c) 若 AI 涌现真属于渗流普适类，我们应期望在不同模型架构 (Transformer、RWKV、Mamba 等) 之间，同一任务的“涌现临界指数”完全相同 (与架构无关)，仅由任务的“推理链维数”决定——这是一个迄今未被验证、且极具挑战性的可证伪预测。

T-5.8.13【易·概念·二阶相变在 AI 涌现类比中的定性预测】 已知二维渗流是连续 (二阶) 相变，序参量 P_∞ 从 p_c 处连续上升 ($\beta = 5/36$)。

- (a) 若“AI 涌现是渗流相变”的类比成立，当模型规模 N 越过某个临界值 N^* 时，相关能力的增长应该是“从零突然跳到有”还是“从零连续缓慢增长”？
- (b) 这与大多数 BIG-Bench 实验中观察到的“突然跳跃”矛盾吗？如何用 Schaeffer 框架调和这一矛盾？

- (c) 渗流类比给出了一个可证伪预测：用连续指标衡量时，“涌现”曲线应该表现出（缓慢启动的）幂律增长而非阶跃。这一预测是否与实验结果一致？（提示：Schaeffer 的换指标实验，1-2 句话）

解答 T-5.8.13

- (a) 若“AI 涌现是渗流相变（二阶）”的类比成立，当 N 越过 N^* 时，能力应从零开始连续缓慢增长（幂律形式， $C \sim (N/N^* - 1)^\beta$ ），而非突然跳跃。
- (b) 这与大多数 BIG-Bench 实验的视觉“突然跳跃”并不矛盾：根据 Schaeffer 框架，exact match 等非线性指标会把底层平滑增长放大成视觉阶跃。如果渗流类比成立，底层能力（连续指标衡量）应是幂律缓慢启动，正是 Schaeffer 换用连续指标后观察到的“平滑曲线”。两者在机制上相容：渗流解释了“为何底层平滑”，Schaeffer 解释了“为何指标看起来像阶跃”。
- (c) 与实验结果一致：Schaeffer 等将 BIG-Bench 的“涌现”任务换用 token-level log-likelihood 后，确实观察到平滑的幂律增长（而非阶跃）——这正是渗流二阶相变类比所预测的“连续启动”形态，也是“指标伪影”的实验证据。

本章覆盖 § 5.1–§ 5.8，共 22 个公式，57 道题。参考文献：Kaplan et al. (2020); Hoffmann et al. (2022); Epoch AI (2024); Sardana et al. (ICML 2024); Schaeffer, Miranda & Koyejo (NeurIPS 2023); Nanda et al. (ICLR 2023); Power et al. (2022); Pesce, He & Caldarelli (arXiv 预印本, 2025, 暂待发表); Shumailov et al. (Nature 2024)。

第 6 章 · 硬件感知算法的数学

§ 6.1 Roofline 模型

本节建立 GPU 性能分析的完整数学框架。三个公式——算术强度、Roofline 上界、脊点——构成一套闭合的不等式体系。掌握它，你就能把任何 kernel 的性能瓶颈量化，而不是凭感觉猜测。本节重点在：感受数字的具体含义（H100 脊点 295 FLOP/byte 意味着什么）、建立极限分析的习惯（GEMM 在 batch=1 和大方阵下的两个极端），以及学会反向设计（给定目标利用率，反推需要多大的 batch size）。

小节导读 · 公式从哪里来

Roofline 为什么是「上界」？GPU 跑一个 kernel 只有两个物理约束：算力峰值 π (FLOP/s) 和带宽峰值 β (byte/s)。任何任务的实际吞吐都不能超过这两个物理上限中的较小者——这就是 Roofline 的唯一来源。

第一步：算术强度怎么出现。设 kernel 要计算 W 个 FLOP，从 HBM 读取 Q 个 byte。「每 byte 能换多少 FLOP」是个本质量，记为 $I = W/Q$ 。这个量纯由算法决定，与硬件无关。

第二步：三者不等式。计算用时 $T_c = W/\pi$ ，读写用时 $T_m = Q/\beta$ ，总时间至少是 $\max(T_c, T_m)$ 。吞吐 $P = W/T \leq \min(\pi, \beta I)$ ——这就是 Roofline 公式，两根「屋顶」交于脊点。

第三步：脊点怎么推。令 $\pi = \beta I^*$ ，得 $I^* = \pi/\beta$ 。H100 $\pi \approx 989$ TFLOP/s， $\beta \approx 3.35$

TB/s, $I^* \approx 295$ FLOP/byte。以这个数为分界区别「计算受限」与「内存受限」。

第四步：两个极端场景。GEMM $C = AB$, $A \in \mathbb{R}^{m \times k}$ 、 $B \in \mathbb{R}^{k \times n}$ 。 $I = 2mnk/(mk + kn + mn)$ 。方阵里 $I \propto n$ ，足以跳到计算受限区；batch=1 的 GEMV $I \rightarrow 2$ ，永远被带宽压制。

本节要拿走的一件事：Roofline 不是经验拟合，而是二资源极限下的物理上界；脊点是算力与带宽的比值，任何 kernel 优化都是「把 I 拍过脊点」的工作。

公式 1 · 算术强度

$$I = \frac{W}{Q} \quad [\text{FLOP/byte}]$$

其中 W 为 kernel 的浮点运算总数 (FLOP)， Q 为从 HBM 读写的字节总数。算术强度是 kernel 的内禀属性，与硬件无关；它衡量的是「每搬运一个字节，能执行多少次浮点运算」。

一句话直觉：算术强度越高，kernel 越能喂饱计算单元，越不受内存带宽瓶颈限制。

在大模型里的位置：架构（决定每个算子的 I 值，进而决定优化策略）

本组训练目标：代入 · 变形 · 工程

常见卡点：- Q 计数时漏掉写操作（只算读不算写）- 把每元素的字节数（FP16=2 byte, FP32=4 byte）代错 - 认为算术强度与向量/矩阵大小有关（AXPY 的 I 与 n 无关）

本组在练什么：从定义出发手算具体 kernel 的算术强度。做完应能回答：向量加和 AXPY 的算术强度各是多少？

T-6.1.1 【易 · 代入 · 向量 kernel 的算术强度】 考虑以下两个 kernel（FP32，每元素 4 byte）：

- 向量加 $z = x + y$, $x, y, z \in \mathbb{R}^n$ ：每元素做 1 次加法，读 x, y 各 n 元素、写 z 共 $3n$ 元素。计算 I_{vadd} ，说明结果与 n 是否相关。
- AXPY: $y \leftarrow \alpha x + y$, α 为标量。每元素做 1 乘 + 1 加（2 FLOP），读 x, y 各一次、写 y 一次，共 $3n \times 4$ byte。计算 I_{AXPY} 。
- 将两个结果与 H100 TF32 脊点 $I^* \approx 295$ FLOP/byte 对比，判断这两个 kernel 在 H100 上属于计算受限还是内存受限，并估算各自的理论峰值吞吐量（GFLOPS, H100 HBM3 带宽 $\beta = 3.35$ TB/s）。

解答 T-6.1.1

- 向量加： $W = n$ FLOP, $Q = 3n \times 4 = 12n$ byte（FP32）。

$$I_{\text{vadd}} = \frac{n}{12n} = \frac{1}{12} \approx 0.083 \text{ FLOP/byte}$$

与 n 无关——无论向量多长，每次读写操作携带的浮点运算量固定，算术强度是常数。

(b) AXPY: $W = 2n$ FLOP, $Q = 12n$ byte (读 x , 读 y , 写 y , 各 $4n$ byte)。

$$I_{\text{AXPY}} = \frac{2n}{12n} = \frac{1}{6} \approx 0.167 \text{ FLOP/byte}$$

(c) H100 TF32 脊点 $I^* \approx 295$ FLOP/byte, HBM 带宽 $\beta = 3.35$ TB/s:

- $I_{\text{vadd}} \approx 0.083 \ll 295$: 深度内存受限, 理论峰值 $\approx 0.083 \times 3.35 \times 10^{12} \approx 278$ GFLOPS, 仅为 H100 算力峰值的 0.03%。
- $I_{\text{AXPY}} \approx 0.167 \ll 295$: 深度内存受限, 理论峰值 $\approx 0.167 \times 3.35 \times 10^{12} \approx 559$ GFLOPS。

两个 kernel 完全被内存带宽瓶颈卡住, 优化 CUDA Core 利用率毫无意义。

T-6.1.2【易·代入·GEMM 算术强度的具体值】 矩阵乘 $C = AB$ (FP16, 每元素 2 byte), $A \in \mathbb{R}^{m \times k}$, $B \in \mathbb{R}^{k \times n}$, 数据量 $Q = 2(mk + kn + mn)$ byte, 计算量 $W = 2mnk$ FLOP。分别计算以下三种规模下 I_{GEMM} (FLOP/byte), 并判断在 H100 FP16 脊点 $I^* \approx 590$ FLOP/byte 下是否计算受限:

场景	m	n	k	I_{GEMM} (待填)	受限类型 (待填)
大方阵	4096	4096	4096	?	?
中等矩阵乘	512	512	4096	?	?
矩阵-向量乘 (推理解码)	1	4096	4096	?	?

解答 T-6.1.2 FP16 下 $Q = 2(mk + kn + mn)$ byte, $W = 2mnk$ FLOP。

(a) 大方阵 $m = n = k = 4096$:

$$I = \frac{2 \times 4096^3}{2 \times (4096^2 + 4096^2 + 4096^2)} = \frac{2 \times 4096}{6} \approx 1365 \text{ FLOP/byte}$$

$1365 > 590$ (H100 FP16 脊点): 计算受限。

(b) 中等矩阵 $m = n = 512, k = 4096$:

$$I = \frac{2 \times 512^2 \times 4096}{2 \times (2 \times 512 \times 4096 + 512^2)} = \frac{4096 \times 512}{8704} \approx 241 \text{ FLOP/byte}$$

$241 < 590$: 内存受限。

(c) 矩阵-向量乘 $m = 1, n = 4096, k = 4096$:

$$I = \frac{2 \times 1 \times 4096 \times 4096}{2(1 \times 4096 + 4096 \times 4096 + 1 \times 4096)} \approx \frac{2 \times 4096^2}{2 \times 4096^2} = 1 \text{ FLOP/byte}$$

1 ≪ 590: 深度内存受限, 与 H100 脊点相差 590 倍。

[工程批注] 矩阵-向量乘 ($m = 1$) 是 LLM token-by-token 解码的核心操作。算术强度约 1 FLOP/byte, 比 H100 FP16 脊点低 590 倍, 意味着 GPU 算力的 589/590 在等待内存数据。这就是为什么 LLM 推理的速度不取决于 FLOP 数, 而取决于 HBM 带宽——H100 的 1979 TFLOPS 对 batch=1 解码几乎毫无意义, 真正决定 token/s 的是 3.35 TB/s 的 HBM3 带宽。量化 (FP8/FP4) 通过减少数据量 (字节数) 直接加速这类 kernel。

公式 2 · Roofline 性能上界与脊点

$$P \leq \min(P_{\text{peak}}, I \cdot \beta)$$

$$I^* = \frac{P_{\text{peak}}}{\beta}$$

P_{peak} 为硬件浮点峰值算力 (FLOP/s), β 为 HBM 带宽 (byte/s)。脊点 I^* 是计算受限与内存受限的分水岭: $I < I^*$ 时内存受限, $I \geq I^*$ 时计算受限。

一句话直觉: 两个物理约束 (带宽上限、算力上限) 取最紧的那个, 脊点是两线的交叉点。

在大模型里的位置: 架构 (kernel 性能模型)

本组训练目标: 代入 · 证明 · 判错

常见卡点: - 内存受限 kernel 用 P_{peak} 计算利用率 (应用 $I \cdot \beta$ 作为实际上界) - 认为越过脊点就意味着性能最优 (越过脊点仅表示已是计算受限, 还可能还有其他瓶颈) - 在 FP16 和 TF32 之间混用脊点数值

本组在练什么: 推导脊点、判断 kernel 受限类型、证明 Roofline 上界的严格性。做完应能回答: 为什么用 P_{peak} 衡量内存受限 kernel 的利用率会得出错误结论?

T-6.1.3 【中 · 推导 · H100 脊点计算与 kernel 分类】

(a) H100 SXM5: FP16 Tensor Core 峰值算力 $P_{\text{peak}} = 1,979 \text{ TFLOPS}$, HBM3 带宽 $\beta = 3.35 \text{ TB/s}$ 。推导脊点 $I_{\text{H100, FP16}}^*$, 保留整数。

(b) 下表给出若干 kernel 的典型算术强度, 根据 (a) 的结果填写受限类型:

Kernel	估计 I (FLOP/byte)	H100 FP16 受限类型
LayerNorm (逐元素)	≈ 2	?
Softmax (行归一化)	≈ 4	?

Kernel	估计 I (FLOP/byte)	H100 FP16 受限类型
大矩阵乘 ($4096 \times 4096 \times 4096$)	≈ 1365	?
FlashAttention ($N = 8192, d = 128$)	≈ 60	?

- (c) 某自定义 kernel 的实测吞吐量为 200 TFLOPS，算术强度 $I = 100$ FLOP/byte。有人说「该 kernel 的峰值利用率是 $200/1979 \approx 10\%$ ，还有很大优化空间」。指出这句话哪里错，并给出正确的利用率衡量方式。

解答 T-6.1.3

- (a) $I_{\text{H100, FP16}}^* = 1979 \times 10^{12} / (3.35 \times 10^{12}) \approx 591$ FLOP/byte (取整)。

- (b) 填表 ($I^* \approx 591$ FLOP/byte):

Kernel	I (FLOP/byte)	受限类型
LayerNorm	≈ 2	内存受限 ($2 \ll 591$)
Softmax	≈ 4	内存受限
大矩阵乘 (4096^3)	≈ 1365	计算受限 ($1365 > 591$)
FlashAttention ($N = 8192, d = 128$)	≈ 60	内存受限

- (c) 不能。该 kernel 是内存受限的 ($I = 100 < I^* \approx 591$)，其理论上界不是 $P_{\text{peak}} = 1979$ TFLOPS，而是 $I \cdot \beta = 100 \times 3.35 = 335$ TFLOPS。

正确利用率：

$$\text{利用率} = \frac{200}{335} \approx 59.7\%$$

用 P_{peak} 做分母 (得约 10%) 会严重低估利用率，导致错误结论——认为「还有 90% 的优化空间」，实际上 60% 对内存受限 kernel 已相当高效。

T-6.1.4 【中 · 极限分析 · GEMM 的四种极限】 对 $I_{\text{GEMM}} = \frac{2mnk}{mk + kn + mn}$ (FP32)，分析以下四种极限：

- (a) $m = n = k \rightarrow \infty$ (大方阵)：求 $\lim I_{\text{GEMM}}$ ，解释为何大方阵乘不受内存墙威胁。
- (b) $m = n = 1, k \rightarrow \infty$ (矩阵-向量乘)：求极限值，说明 FP32 下该值与 V100 脊点 $I_{\text{V100}}^* \approx 139$ 的关系。
- (c) $k = 1, m = n \rightarrow \infty$ (外积 $C = xy^\top$)：求极限，解释外积为何是内存受限操作。
- (d) $m = 1, n = k \rightarrow \infty$ (行向量乘矩阵)：求极限，与 (b) 对比，说明矩阵向量乘的方向是否影响算术强度的数量级。

解答 T-6.1.4

- (a) $m = n = k = N \rightarrow \infty$:

$$I = \frac{2N^3}{3N^2} = \frac{2N}{3} \rightarrow \infty$$

大方阵的算术强度随矩阵规模线性增长, 不受内存墙威胁——这是大模型训练时 GPU 利用率可以很高的根本原因。

(b) $m = n = 1, k \rightarrow \infty$:

$$I = \frac{2k}{k + k + 1} = \frac{2k}{2k + 1} \rightarrow 1 \text{ FLOP/byte (FP32)}$$

约 1 FLOP/byte, 远低于 V100 脊点 139——LLM 解码阶段的矩阵乘是完全内存受限的, 这是 HBM 带宽主导 LLM 推理速度的根本原因。

(c) $k = 1, m = n = N \rightarrow \infty$ (外积):

$$I = \frac{2N^2}{N + N + N^2} = \frac{2N^2}{N^2 + 2N} \rightarrow 2 \text{ FLOP/byte}$$

外积每写出一个 N^2 元素只做 2 次运算, I/O 远大于可复用数据量, 内存受限。

(d) $m = 1, n = k = N \rightarrow \infty$ (行向量乘矩阵):

$$I = \frac{2N^2}{N + N^2 + N} \approx \frac{2N^2}{N^2} = 2 \text{ FLOP/byte}$$

趋近 2 FLOP/byte, 与外积相同数量级, 均远低于 H100 脊点, 均属内存受限。与 (b) 的矩阵-向量乘 (趋近 1 FLOP/byte) 相比, 方向差异带来约 2 倍区别, 但数量级相同——两者都被内存墙钉死。

T-6.1.5 【中·反向设计·达到 80% 算力利用率需要多大 batch size】 LLM 的 FFN 层计算 $Y = XW^T$, $W \in \mathbb{R}^{4096 \times 4096}$ (FP16), 输入 batch 为 B 个 token, $X \in \mathbb{R}^{B \times 4096}$ (即 $m = B, k = n = 4096$)。

- 写出 $I_{\text{GEMM}}(B)$ 关于 B 的表达式 (FP16, $Q = 2(Bk + kn + Bn)$ byte)。
- 要使 $I(B) \geq 0.8 \times I_{\text{H100, FP16}}^* = 0.8 \times 590 \text{ FLOP/byte}$, B 至少需要多大? (给出完整代数推导步骤。)
- LLM 低延迟推理时 batch size 常为 1–32。根据 (b) 的结论, 说明为什么 LLM 推理的 FFN 部分几乎永远是内存受限的, 以及工程上应如何应对。

解答 T-6.1.5

(a) $m = B, k = n = 4096$, FP16:

$$I(B) = \frac{2 \times B \times 4096^2}{2 \times (B \times 4096 + 4096^2 + B \times 4096)} = \frac{B \times 4096}{2B + 4096}$$

(b) 要求 $I(B) \geq 0.8 \times 590 = 472 \text{ FLOP/byte}$:

$$\frac{4096B}{2B + 4096} \geq 472$$

$$4096B \geq 472(2B + 4096) = 944B + 1,933,312$$

$$(4096 - 944)B \geq 1,933,312 \implies B \geq \frac{1,933,312}{3152} \approx 613.7$$

即 $B \geq 614$ 才能使算力利用率达到峰值的 80%。

- (c) LLM 低延迟推理 batch size 常为 1–32，远低于 614。因此 FFN 的矩阵乘几乎永远内存受限。工程应对：① 量化 (FP8/FP4) 使字节数减半/四分之一， Q 减小， I 成倍增大；② 换 HBM 带宽更大的 GPU (B200 带宽 8.00 TB/s 是 H100 的 2.39 倍，直接加速内存受限 kernel)。不应优化 CUDA Core 利用率，那不是瓶颈所在。

T-6.1.6 【难 · 证明 · Roofline 上界的严格性与局限】

- (a) 证明：对任意 $I > 0$ ， $P \leq \min(P_{\text{peak}}, I \cdot \beta)$ 是 kernel 可达吞吐量的严格上界。(提示：分内存受限和计算受限两段，分别证明，再合并取 min。)
- (b) 对 $I \rightarrow 0$ 和 $I \rightarrow \infty$ 两个极端，分别给出 Roofline 上界的渐近行为，并各举一个真实 kernel 的例子。
- (c) 判错：下列说法是否正确？若错，请指出错误并给出反例或反论。
「一个 kernel 只要算术强度超过脊点，就能达到 P_{peak} 的性能。」
- (d) 列举两条 Roofline 模型不能解释的真实硬件现象，并说明如何在 Roofline 框架外补充建模。

解答 T-6.1.6

- (a) 证明：

情形 1 (内存受限)：设 kernel 的 I/O 量为 Q byte，执行时间 t 秒，每秒能搬运的最大字节数为 β (HBM 带宽)，则 $Q \leq \beta t$ ，吞吐量 $P = W/t = I \cdot Q/t \leq I \cdot \beta$ 。

情形 2 (计算受限)：浮点单元在 t 秒内最多执行 $P_{\text{peak}} \cdot t$ FLOP，故 $P = W/t \leq P_{\text{peak}}$ 。任何 kernel 必须同时满足两约束 (内存子系统与计算单元并发，受最紧者限制)，故

$$P \leq \min(P_{\text{peak}}, I \cdot \beta). \quad \square$$

- (b)

- $I \rightarrow 0$: $P \leq I \cdot \beta \rightarrow 0$ 。例：逐元素 exp ($I < 1$ FLOP/byte)，实际吞吐接近零。
- $I \rightarrow \infty$: $P \leq P_{\text{peak}}$ (与 I 无关)。例：大方阵乘 ($I \sim 2n/3 \rightarrow \infty$)，性能封顶于算力峰值。

- (c) 错误。越过脊点意味着 kernel 从内存受限变为计算受限，理论上界从 $I \cdot \beta$ 变为 P_{peak} ——但这只是上界改变，不保证实际性能等于 P_{peak} 。真实 GPU 中还存在延

迟隐藏不足、warp 调度开销、指令混合 (Tensor Core vs CUDA Core) 等因素, 实际性能通常低于 P_{peak} 。

(d) Roofline 不能解释的现象:

1. **延迟隐藏 (latency hiding)**: Roofline 假设带宽可被完全利用, 但若 outstanding memory requests 不足以填满 HBM 延迟 (约 500–800 ns), kernel 陷入 latency-bound 停顿, 实际带宽利用率远低于 β 。补充建模: NVIDIA Nsight Compute 的 Memory Throughput 分析 (区分 latency-bound vs bandwidth-bound)。
2. **存储层次非均匀性**: Roofline 用单个 β 代表所有内存访问, 但 L1 cache (约 $100\times$ 快于 HBM)、L2 cache、HBM 之间有 3–4 数量级带宽差异。频繁命中 L1 的 kernel 实际等效带宽远超 β_{HBM} 。补充建模: 层次化 Roofline (为每级存储分别建立 Roofline 线)。

T-6.1.7【难·画图直觉·Roofline 屋脊图】 请在草稿区粗略画出 H100 (TF32, $P_{\text{peak}} = 989$ TFLOPS, $\beta = 3.35$ TB/s) 的 Roofline 屋脊图:

- 横轴为 $\log_2(I)$ (FLOP/byte), 纵轴为 $\log_2(P)$ (TFLOPS), 两轴均为对数刻度
- 画出内存受限斜线 (斜率 +1) 和计算受限水平线, 并标注脊点坐标 (I^*, P_{peak})
- 在图上标注以下四个 kernel 的大致位置: 向量加 ($I \approx 0.08$)、FlashAttention ($I \approx 60$)、大矩阵乘 ($I \approx 1365$)、LayerNorm ($I \approx 2$)
- 在同一张图上, 用虚线画出 A100 的 Roofline ($P_{\text{peak}} = 312$ TFLOPS, $\beta = 2.00$ TB/s), 标注 A100 脊点, 并说明从 A100 到 H100 脊点在图上如何移动

解答 T-6.1.7 参考答案 (文字描述, 学员在草稿纸上手绘):

- 横轴: $\log_2 I$, 刻度约 2^{-4} 到 2^{11} (0.06 到 2048 FLOP/byte)
- 纵轴: $\log_2 P$, 刻度约 2^{-1} 到 2^{11} (0.5 到 2048 TFLOPS)
- H100 内存受限斜线: 从 ($I = 0.08, P = 0.27$ T) 向右上延伸, 斜率 +1 (对数坐标)
- H100 计算受限水平线: $P = 989$ TFLOPS (TF32 基准)
- H100 脊点: ($I^* = 295, P = 989$)——两线交点
- 四个 kernel 位置 (从左到右): 向量加 ($I \approx 0.08$, 深度内存受限)、LayerNorm ($I \approx 2$)、FlashAttention ($I \approx 60$)、大矩阵乘 ($I \approx 1365$, 计算受限)
- A100 虚线: 水平线 $P = 312$ TFLOPS, 斜线斜率同为 +1 但绝对位置更低; A100 脊点 ($I^* = 156, P = 312$) 在 H100 脊点左下方

H100 脊点相对 A100 的移动: 向右 (脊点 $156 \rightarrow 295$, I^* 增大) 且向上 (P_{peak} $312 \rightarrow 989$ TFLOPS), 整体右上方向移动。含义: 脊点右移使更多 kernel 落入内存受限区域; 脊点上移使内存受限 kernel (如 FlashAttention) 的上界 $I \cdot \beta$ 随带宽增长而提高。

【做完自检】

1. 算术强度 I 是 kernel 的内禀属性还是硬件的属性? 它为什么与向量长度 n 无关 (以 AXPY 为例)?
2. H100 TF32 脊点约为 295 FLOP/byte, FP16 脊点约为 590 FLOP/byte。为什么同一块 GPU 对不同数据精度有不同的脊点? 量化 (FP8/FP4) 对脊点和算法设计意味着

什么？

3. 证明 Roofline 上界的关键步骤是什么？为什么对内存受限 kernel 用 P_{peak} 衡量利用率会导致错误的优化决策？

§ 6.2 无法逾越的底线：红蓝卵石博弈 (Hong-Kung 1981)

本节是整章的数学地基。Hong-Kung 定理说的不是「你的算法不够好」，而是「物理规律设置了一个下界，任何正确算法都不能突破」。核心工具是红蓝卵石博弈——一个把算法 DAG 上的 I/O 计数问题形式化为博弈论的优雅框架。理解矩阵乘 I/O 下界的推导（AM-GM 关键步骤）是理解 FlashAttention 动机的必要条件：FlashAttention 之所以能降低 I/O，根本上是因为它换了一个更优的 DAG 执行策略。

小节导读 · 公式从哪里来

怎么从「红蓝卵石」博弈到矩阵乘 I/O 下界？把计算看作 DAG，每个点是一个中间值。「红卵石」表示高速内存（容量 M ）中的值，「蓝卵石」表示 HBM 中的值。谁在高速中，谁就能参与计算。

第一步：把 I/O 计成「颜色变换次数」。「读」是蓝变红，「写」是红变蓝。计算 Q 个 I/O 等价于看多少次颜色转换。问题转为「红色原子能计算多少点」。

第二步： $2M$ 等价论证。任何时刻高速里能同时存的点不超过 $2M$ （ M 个老点 + M 个新点）。Hong-Kung 不等式说： S 个计算只需 $Q \geq (S/F(2M))$ 次 I/O，其中 $F(2M)$ 是「高速装 $2M$ 点能做多少 FLOP」的上界。

第三步：矩阵乘里 $F(2M)$ 怎么算。 $C = AB$ 。高速里装 A 的一块 $a \times b$ 、 B 的一块 $b \times c$ 、 C 的一块 $a \times c$ ，总点数 $ab + bc + ac \leq 2M$ 。该块上能做的计算是 $2abc$ 。

第四步：AM-GM 出场。 $ab + bc + ac \geq 3\sqrt[3]{a^2b^2c^2} = 3(abc)^{2/3}$ 。代入 $ab + bc + ac \leq 2M$ 得 $abc \leq (2M/3)^{3/2}$ ，于是 $F(2M) = 2abc \leq 2(2M/3)^{3/2} \sim M^{3/2}$ 。

第五步：合成下界。代回 Hong-Kung： $n \times n$ 矩阵乘总计算 $S = 2n^3$ ， $Q \geq S/F(2M) \sim n^3/M^{3/2} \cdot \sqrt{M}$ 。这就是 $\Omega(n^3/\sqrt{M})$ 下界——FlashAttention 能突破原始 attention 上界，就是因为它重写了 DAG 与点重用。

本节要拿走的一件事：I/O 下界不是「优化上限」而是「组合计数不等式」；AM-GM 是连接「资源」与「计算量」的几何枢纽。

公式 3 · Hong-Kung 基本不等式 (引理 6.1)

$$\left\lceil \frac{T_{I/O}}{S} \right\rceil \cdot H(2S, G) \geq |V| - |\text{Inputs}(G)|$$

S 为快速存储（SRAM）容量（字）， $T_{I/O}$ 为 I/O 总操作次数， $H(2S, G)$ 为 DAG G 的 $2S$ -块流量（在 $2S$ 个外部输入约束下，一个阶段内最多能完成的节点数）。

一句话直觉：若每个「计算阶段」的输入来自至多 $2S$ 个值，则总阶段数乘以每阶段产出节点数必须覆盖所有内部节点。

在大模型里的位置：架构（I/O 下界分析，指导 FlashAttention 等 I/O 感知算法设计）

本组训练目标：代入 · 证明 · 工程

常见卡点：- 混淆「阶段」的含义：一个阶段包含至多 S 次 I/O（不是 S 步计算）- 认为 $H(2S, G)$ 等于 $2S$ （它是在 $2S$ 个外部输入约束下能计算的节点数，对矩阵乘是 $O(S^{3/2})$ ）- 用矩阵乘的 $|V| = n^3$ 时忘记减去输入节点数 $2n^2$

本组在练什么：理解红蓝卵石博弈的规则和 S -划分论证的结构。做完应能回答：为什么每个阶段的边界上最多有 $2S$ 个值？

T-6.2.1 【易 · 演示 · 3×3 矩阵乘的红蓝卵石博弈】 设 $A, B, C \in \mathbb{R}^{3 \times 3}$ ，用标准三重循环计算 $C = AB$ 。

- 标准算法的 DAG 中，乘加（内部）节点共多少个？输入节点共多少个？
- 当快速存储 $S = 3$ 时，计算 $C_{11} = A_{11}B_{11} + A_{12}B_{21} + A_{13}B_{31}$ ：每次只能在 SRAM 中放 3 个数（2 个操作数 + 1 个累加器），完成三次乘法至少需要多少次 I/O（读 + 写）？
- 当 $S = 9$ 时，可将 A 的第 1 行和 B 的第 1 列全部载入 SRAM。此时计算 C_{11} 至少需要多少次 I/O？与 (b) 对比，说明增大快速存储对 I/O 效率的意义。

解答 T-6.2.1

- 3×3 矩阵乘：内部（乘加）节点 $3^3 = 27$ 个；输入节点 A, B 各 9 个，共 18 个。
- $S = 3$ ，计算 $C_{11} = A_{11}B_{11} + A_{12}B_{21} + A_{13}B_{31}$ 。每步需要 2 个操作数 + 1 个累加器（恰好用满 $S = 3$ ）：步 1：读 A_{11}, B_{11} （2 次 I/O），计算，结果在累加器中；驱逐 A_{11}, B_{11} ；步 2：读 A_{12}, B_{21} （2 次 I/O），加到累加器；步 3：读 A_{13}, B_{31} （2 次 I/O），加到累加器；写 C_{11} （1 次 I/O）。共 7 次 I/O（6 读 + 1 写）。
- $S = 9$ ：一次性读入 A 的第 1 行（3 元素）和 B 的第 1 列（3 元素），共 6 次读 I/O，SRAM 内完成三步乘加，写出 C_{11} （1 次），共 7 次 I/O——数量相同，但此时 3 个 A 元素在 SRAM 中一直复用，无需反复读回。

关键对比：对于计算单个 C_{11} ，两种 S 下 I/O 相同。但当 $S = 9$ 时，读入的行/列数据可以同时用于计算同一行/列的所有 C 元素（例如 C_{12}, C_{13} 等），大幅提高数据复用。真正的 I/O 减少发生在块大小 b 提升到 $O(\sqrt{S})$ 级别时（分块算法）。

公式 4 · AM-GM 关键估计与矩阵乘 I/O 下界

$$N_A + N_B + N_C \leq 2S \implies \sqrt{N_A N_B N_C} \leq \left(\frac{2S}{3}\right)^{3/2}$$

$$T_{I/O} = \Omega\left(\frac{n^3}{\sqrt{M}}\right)$$

N_A, N_B, N_C 分别为某阶段内快速存储中 A, B, C 的元素个数, M 为快速存储容量。第一个不等式是 AM-GM 的直接应用; 第二个是矩阵乘 I/O 下界, 是从前者推导出来的。

一句话直觉: 在 SRAM 中均等分配 A, B, C 元素时, 三路乘积取得最大值, 这给出了每阶段能完成的节点数上界。

在大模型里的位置: 架构 (I/O 下界分析)

本组训练目标: 证明 · 代入 · 变形

常见卡点: - AM-GM 三元素版本写成 $(abc)^{1/2}$ 而不是 $(abc)^{1/3}$ (先立方后开方) - 等号成立条件 ($N_A = N_B = N_C$) 对应正方体分块, 与实际最优块大小一致 - 把 $\sqrt{N_A N_B N_C}$ 理解为可计算节点数时, 忘记它来自 Irony-Toledo-Tiskin 的精确估计, 不是显然的

本组在练什么: 推导 AM-GM 关键步骤, 将其代入 Hong-Kung 不等式得出矩阵乘 I/O 下界。做完应能回答: 等号成立 (三路均等分配) 对应什么形状的分块策略?

T-6.2.2 【中 · 推导 · AM-GM 关键步骤的完整推导】 设 $N_A, N_B, N_C \geq 0$ 且 $N_A + N_B + N_C = 2S$ 。

(a) 用 AM-GM 不等式证明:

$$N_A N_B N_C \leq \left(\frac{N_A + N_B + N_C}{3} \right)^3 = \left(\frac{2S}{3} \right)^3$$

并由此推导 $\sqrt{N_A N_B N_C} \leq (2S/3)^{3/2}$ 。

(b) 等号何时成立? 对应矩阵乘分块策略的几何解释是什么 (三维坐标 (i, j, k) 空间中是什么形状)?

(c) 将 $H(2S, G) \leq c \cdot S^{3/2}$ (c 为常数) 代入 Hong-Kung 基本不等式, 令 $|V| = n^3$, $|\text{Inputs}| = 2n^2$, 完整推导:

$$T_{I/O} \geq \Omega\left(\frac{n^3}{\sqrt{S}}\right)$$

(给出每一步的代数操作, 不跳步骤。)

解答 T-6.2.2

(a) AM-GM 三元素版本: 对非负实数 a, b, c ,

$$\frac{a+b+c}{3} \geq (abc)^{1/3} \implies abc \leq \left(\frac{a+b+c}{3} \right)^3$$

令 $a = N_A, b = N_B, c = N_C$, $a + b + c = 2S$:

$$N_A N_B N_C \leq \left(\frac{2S}{3} \right)^3$$

两边取 $1/2$ 次幂（单调）：

$$\sqrt{N_A N_B N_C} \leq \left(\frac{2S}{3}\right)^{3/2}$$

(b) 等号成立当且仅当 $N_A = N_B = N_C = 2S/3$ ，即三类元素均等分配。在三维坐标 (i, j, k) 空间中，均等分配对应边长约为 $\sqrt{2S/3}$ 的正方体分块——正方体是在约束 $N_A + N_B + N_C \leq 2S$ 下三路乘积最大的形状（AM-GM = 「等边立方体是最优形状」的代数表达）。

(c) 将 $H(2S, G) \leq cS^{3/2}$ 代入引理 6.1 ($|V| = n^3$, $|\text{Inputs}| = 2n^2$)：

$$\left\lceil \frac{T_{I/O}}{S} \right\rceil \cdot cS^{3/2} \geq n^3 - 2n^2$$

因为 $\lceil T/S \rceil \geq T/S$ ，故：

$$\frac{T_{I/O}}{S} \cdot cS^{3/2} \geq n^3 - 2n^2$$

$$T_{I/O} \geq \frac{n^3 - 2n^2}{cS^{3/2}} \cdot S = \frac{n^3 - 2n^2}{c\sqrt{S}} = \Omega\left(\frac{n^3}{\sqrt{S}}\right) \quad (n \gg 1 \text{ 时低阶项可忽略}) \quad \square$$

[工程批注] Hong-Kung 下界告诉我们，H100 的约 30 MB SRAM 对 4096×4096 矩阵乘的 I/O 下界约为 1.77×10^7 元素（约 35 MB，FP16）。这不是实现缺陷，而是信息论意义上的必然——cuBLAS 已经将常数因子优化到接近最优（约 2–4 倍下界），进一步压缩的空间极为有限。工程上能做的是：用更大 SRAM 的芯片（增大 S 使下界降低），或换一个 DAG（如 FlashAttention 利用 attention 计算的结构减少有效 I/O）。

T-6.2.3【中·代入·H100 矩阵乘 I/O 下界的具体数值】 H100 SXM5：每 SM 可配置 shared memory 上限 228 KB（与 L1 共享 256 KB），共 132 个 SM，总可用 SRAM $M \approx 30$ MB（源：NVIDIA H100 Tensor Core GPU Architecture Whitepaper）。设 FP16（2 byte/元素），快速存储可放 $S = M/2 = 1.5 \times 10^7$ 个元素。

- 对 $n = 4096$ 的方阵乘，计算 I/O 下界 $\Omega(n^3/\sqrt{S})$ 的具体数值（元素为单位），保留两位有效数字。
- 将 (a) 换算为字节（FP16），再除以 HBM 带宽 $\beta = 3.35 \times 10^{12}$ byte/s，估算最优算法的矩阵乘 I/O 时间下界（ μs ）。
- $n = 4096$ 方阵乘的计算量为 $2n^3 \approx 1.37 \times 10^{11}$ FLOP；H100 FP16 算力 1979 TFLOPS 下，计算时间约为多少 μs ？对比 (b)，说明大矩阵乘是计算受限还是 I/O 受限。

解答 T-6.2.3

- $\sqrt{S} = \sqrt{1.5 \times 10^7} \approx 3873$, $n^3 = 4096^3 = 6.872 \times 10^{10}$ ：

$$T_{I/O} \geq \frac{n^3}{\sqrt{S}} = \frac{6.872 \times 10^{10}}{3873} \approx 1.77 \times 10^7 \text{ 元素}$$

(b) FP16 (2 byte/元素): $1.77 \times 10^7 \times 2 \approx 3.55 \times 10^7 \text{ byte} \approx 35.5 \text{ MB}$ 。

I/O 时间下界:

$$t_{I/O} \geq \frac{3.55 \times 10^7}{3.35 \times 10^{12}} \approx 1.06 \times 10^{-5} \text{ s} \approx 10.6 \mu\text{s}$$

(c) 计算量 $W = 2n^3 = 1.374 \times 10^{11} \text{ FLOP}$, 算力 $F = 1.979 \times 10^{15} \text{ FLOP/s}$ (H100 FP16 dense):

$$t_{\text{comp}} = \frac{1.374 \times 10^{11}}{1.979 \times 10^{15}} \approx 6.94 \times 10^{-5} \text{ s} \approx 69.4 \mu\text{s}$$

$t_{\text{comp}} \approx 69.4 \mu\text{s} \gg t_{I/O} \approx 10.6 \mu\text{s}$: 计算受限。I/O 时间仅占计算时间的约 15%, 分块 GEMM 的 I/O 开销完全可被计算掩盖。

T-6.2.4 【中 · 验证 · 分块矩阵乘达到 I/O 下界】 分块矩阵乘将 A, B, C 按 $b \times b$ 子矩阵分块, 外三重循环遍历 $(n/b)^3$ 个块三元组, 每次将三个 $b \times b$ 块装入快速存储做局部乘法。

- (a) SRAM 约束: 三个子块同时在快速存储中, $3b^2 \leq S$, 解出最大块大小 $b^* = \lfloor \sqrt{S/3} \rfloor$ 。
- (b) 仔细推导总 I/O: 对 C 的每个 (I, J) 块, 内循环 K 遍历 n/b 个块, 每次读入 A_{IK}, B_{KJ} 各一个 b^2 元素块; C_{IJ} 块累加完成后写回一次。验证

$$T_{I/O}^{\text{blocked}} = \Theta\left(\frac{n^3}{b}\right)$$

- (c) 代入 $b = b^* = \Theta(\sqrt{S})$, 验证 $T_{I/O}^{\text{blocked}} = \Theta(n^3/\sqrt{S})$, 与 Hong-Kung 下界匹配, 说明该下界是紧的。

解答 T-6.2.4

- (a) SRAM 约束 $3b^2 \leq S$, 解得 $b^* = \lfloor \sqrt{S/3} \rfloor$ 。
- (b) 对 C 的每个 (I, J) 块 (共 $(n/b)^2$ 个): 内循环 K 遍历 n/b 个块, 每次读入 A_{IK} (b^2 元素) 和 B_{KJ} (b^2 元素), 共读 $2b^2 \times (n/b) = 2nb$ 个元素; 写 C_{IJ} (b^2 元素) 一次。

$$T_{I/O}^{\text{blocked}} = (n/b)^2 \times [2nb + b^2] = \frac{2n^3}{b} + n^2 = \Theta\left(\frac{n^3}{b}\right) \quad (n \gg b \text{ 时})$$

- (c) 代入 $b = b^* = \Theta(\sqrt{S/3}) = \Theta(\sqrt{S})$:

$$T_{I/O}^{\text{blocked}} = \Theta\left(\frac{n^3}{\sqrt{S}}\right)$$

与 Hong-Kung 下界 $\Omega(n^3/\sqrt{S})$ 精确匹配——分块矩阵乘是 I/O 最优算法，下界是紧的。
□

T-6.2.5 【难 · 推广 · 非方阵的 I/O 下界与矩阵-向量乘分析】 考虑矩形矩阵乘 $C = AB$, $A \in \mathbb{R}^{m \times k}$, $B \in \mathbb{R}^{k \times n}$, $C \in \mathbb{R}^{m \times n}$, 快速存储大小 S 。

- 说明 $H(2S, G) = O(S^{3/2})$ 在非方阵时是否仍然成立 (AM-GM 论证是否依赖方阵假设)。
- 由此推导 $T_{I/O} = \Omega(mnk/\sqrt{S})$ 。
- 判错：「推理解码时矩阵-向量乘 ($m = 1$) 的 I/O 下界极小 (约 4000 元素)，说明它的 I/O 效率很高。」请解释这句话的错误：为什么矩阵-向量乘的真实 I/O (需要读出整个权重矩阵 $\sim mk$ 元素) 远大于 Hong-Kung 下界，下界「松」意味着什么? (代入 H100 参数 $S = 1.35 \times 10^7$, $m = 1$, $k = n = 4096$ 计算具体数值。)

解答 T-6.2.5

- AM-GM 论证仅用到 $N_A + N_B + N_C \leq 2S$ 约束和乘积上界，不依赖方阵假设 (只要每个内部节点有来自 A, B, C 三方的输入，结构不变)。故 $H(2S, G) = O(S^{3/2})$ 对任意形状矩阵乘仍然成立。
- 代入 $|V| = mnk$, $|V| - |\text{Inputs}| = mnk - mk - kn$:

$$T_{I/O} = \Omega\left(\frac{mnk}{\sqrt{S}}\right)$$

(忽略低阶项 $mk + kn$ 。)

- 矩阵-向量乘 $m = 1, k = n = 4096$, $S = 1.5 \times 10^7$:

$$T_{I/O} \geq \frac{1 \times 4096 \times 4096}{\sqrt{1.5 \times 10^7}} = \frac{1.678 \times 10^7}{3873} \approx 4,332 \text{ 元素}$$

错误在于：Hong-Kung 下界约 4332 元素极小，但真实 I/O 需要读出整个权重矩阵 B ，约 $kn = 4096^2 \approx 1.68 \times 10^7$ 元素 (FP16 约 33.6 MB) ——比下界大约 3873 倍。

下界「松」的原因：矩阵 B 的每个元素在 $m = 1$ 时只被使用一次 (没有任何复用机会)，Hong-Kung 的 S -划分论证无法利用这一额外约束。下界给的是「可以有复用时」的最优值，实际上由于结构特殊，根本无法复用，I/O 必须接近矩阵本身大小。这正是推理时 HBM 带宽 (而非 FLOP 数) 是瓶颈的信息论根源。

T-6.2.6 【难 · 证明 · Hong-Kung 下界推导的核心步骤 (不查书推导)】 本题要求你不查书，从零推导矩阵乘 I/O 下界的全部关键步骤：

- (a) 给出 S -划分论证的逻辑结构：将博弈按每 S 次 I/O 分成若干阶段，说明每个阶段的「边界」上为何最多有 $2S$ 个值。
- (b) 对矩阵乘 DAG，说明一个阶段内能完成的节点数为什么不超过 $\sqrt{N_A N_B N_C}$ （可引用 Irony-Toledo-Tiskin 结论，但需说明其几何含义）。
- (c) 将 (a) 和 (b) 的结论合并，写出 Hong-Kung 基本不等式的完整形式，并由此推出 $T_{I/O} = \Omega(n^3/\sqrt{S})$ （含常数推导，不使用大 O 掩盖关键步骤）。

解答 T-6.2.6

- (a) S -划分论证结构：将整个博弈过程按每 S 次 I/O 分成若干阶段。在阶段 t 开始时，快速存储中至多有 S 个值（上一阶段遗留）；该阶段内 I/O 量 $\leq S$ ，即至多读入 S 个新值。故该阶段开始 + 读入的外部值总数至多 $S + S = 2S$ ——这就是每个阶段「边界」上最多 $2S$ 个值的来源（进入阶段时已有 S 个，加上该阶段读入的至多 S 个）。
- (b) 可计算节点数不超过 $\sqrt{N_A N_B N_C}$ ：节点 (i, j, k) 可计算当且仅当 A_{ik}, B_{kj}, C_{ij} 均在快速存储中。设 A 的行下标集合大小 r_i 、列下标大小 r_k （ $N_A \geq r_i r_k$ 的极端是全覆盖）； B 的行下标 r_k （共享），列下标 r_j ； C 覆盖 $r_i \times r_j$ 槽。可计算节点数 $\leq r_i r_j r_k$ ，由 $N_A \leq r_i r_k, N_B \leq r_j r_k, N_C \leq r_i r_j$ 可得 $N_A N_B N_C \leq (r_i r_j r_k)^2$ ，故 $r_i r_j r_k \leq \sqrt{N_A N_B N_C}$ （Irony-Toledo-Tiskin 2004 给出的精确估计）。
- (c) 完整推导：阶段总数 $\lceil T_{I/O}/S \rceil$ ，每阶段计算节点数 $\leq H(2S, G) \leq c \cdot S^{3/2}$ ：

$$\left\lceil \frac{T_{I/O}}{S} \right\rceil \cdot cS^{3/2} \geq n^3 - 2n^2$$

因 $\lceil T_{I/O}/S \rceil \geq T_{I/O}/S$ ：

$$T_{I/O} \geq \frac{S \cdot (n^3 - 2n^2)}{cS^{3/2}} = \frac{n^3 - 2n^2}{c\sqrt{S}}$$

取 $n \gg 1$ （低阶项忽略），令 $M = S$ （元素数）：

$$T_{I/O} \geq \frac{1}{c} \cdot \frac{n^3}{\sqrt{M}} = \Omega\left(\frac{n^3}{\sqrt{M}}\right) \quad \square$$

其中常数 $c = (2/3)^{3/2} \cdot 1$ ，实际 Irony et al. 2004 给出常数为 $2\sqrt{3}$ 的下界（见原文）。

【做完自检】

1. 红蓝卵石博弈中，「阶段」是按 I/O 次数（每 S 次一阶段）而非计算步数划分的。为什么每个阶段的边界上最多有 $2S$ 个值？这个 2 从哪里来？
2. AM-GM 关键步骤（ $N_A N_B N_C \leq (2S/3)^3$ ）等号成立时，分块策略是正方体。正方体分块对应的块大小 b 满足什么关系？为什么分块矩阵乘选 $b = \lfloor \sqrt{S/3} \rfloor$ 而不是 $b = \lfloor \sqrt{S} \rfloor$ ？

3. Hong-Kung 下界对矩阵-向量乘 ($m = 1$) 给出的下界远小于真实 I/O——这说明 Hong-Kung 下界在此场景下是「松」的。下界「松」的直觉原因是什么？（提示：矩阵 B 的每个元素只被使用一次，无法复用。）

§ 6.3 FlashAttention 的 I/O 分析

FlashAttention 是本章所有数学工具的汇聚点。标准 attention 的 I/O 瓶颈在于 $N \times N$ 注意力矩阵的多次 HBM 读写；FlashAttention 用分块 tiling + 在线 softmax 递推，使 $N \times N$ 矩阵永远无需完整写入 HBM。这一 I/O 复杂度从 $\Theta(N^2)$ 降到 $\Theta(N^2 d^2 / M)$ 的跃迁，不是「优化」出来的，而是「重新推导」出来的——这是本节最重要的认知。

小节导读 · 公式从哪里来

为什么标准 attention 要反复读写 $N \times N$ ？Attention $\text{softmax}(QK^\top)V$ 中间需要一个 $N \times N$ 矩阵。完整存下来然后再读出去 softmax、再乘以 V ，是这个矩阵走 HBM 三趟。

第一步：分块为什么能避开物化。把 Q, K, V 各切为块 $B_r \times d$ 、 $B_c \times d$ 。每块上计算子型 $Q_i K_j^\top V_j$ ，只产生中间块 $B_r \times B_c$ ，全部住高速。

第二步：在线 softmax 递推。难点是 softmax 需要全行归一化，似乎不能分块。FlashAttention 的关键技术：维护在线统计量 (m_i, ℓ_i) （运行最大值与归一化分母），看到新块时用一个代数恒等式 $\ell^{\text{new}} = \ell \cdot e^{m - m^{\text{new}}} + \ell^{\text{new}}$ 调整输出。

第三步：I/O 复杂度怎么算。记 SRAM 容量 M 。块大小 $B_c = \Theta(M/d)$ 。外循环扫 K, V ，内循环扫 Q ，总 I/O = 外循环次数 $N/B_c \times$ 单轮 $\Theta(Nd)$ ，得 $\Theta(N^2 d^2 / M)$ 。 $d = 128, M = 10^5$ 下，这是 N^2 的 $1/600$ 。

第四步：反向传播怎么办。中间 $N \times N$ 矩阵未被存下，反向传播需要重计算。这是「重计算换 I/O」的典型权衡：计算量翻倍，I/O 减为 $1/M$ 量级。

本节要拿走的一件事：FlashAttention 不是微调，是重写 attention 的 DAG，「永不物化 $N \times N$ 」是其几何中心。

公式 5 · 标准 Attention 的 I/O 复杂度

$$T_{I/O}^{\text{standard}} = \Theta(Nd + N^2)$$

三步 ($S = QK^\top$ 、 $P = \text{softmax}(S)$ 、 $O = PV$) 各自读写 HBM，主导项为 N^2 （即 $N \times N$ 注意力矩阵）。

一句话直觉：标准 attention 必须把 $N \times N$ 矩阵写入 HBM 再读回，这是 2022 年前所有 Transformer 的 I/O 瓶颈。

在大模型里的位置：架构（自注意力的 I/O 分析）

本组训练目标：代入 · 变形 · 工程

常见卡点：- 在 $N \gg d$ 假设下， Nd 项的占比——不是完全可忽略，要看具体数值 -

Step 2 (softmax) 读写的是 S (N^2 元素), 不是 Q, K, V - Step 3 读 P 和 V , 写 O : V 的读取量是 Nd , 不是 N^2

本组在练什么: 逐步拆解标准 attention 的三次 HBM 访问, 建立 N^2 主导项的定量直觉。做完应能回答: Step 2 (softmax) 贡献了多大比例的总 I/O?

T-6.3.1 【易 · 代入 · 标准 Attention 的逐步 I/O 分析】 设 $Q, K, V \in \mathbb{R}^{N \times d}$, FP16 (2 byte/元素), $N = 4096$, $d = 128$ 。

(a) 填写以下表格 (单位 byte, 用 N, d 符号表达):

步骤	操作	读 (byte)	写 (byte)
Step 1	$S = QK^\top \in \mathbb{R}^{N \times N}$	?	?
Step 2	$P = \text{softmax}(S)$	?	?
Step 3	$O = PV \in \mathbb{R}^{N \times d}$	?	?

(b) 代入 $N = 4096, d = 128$ (FP16), 以 MB 为单位计算各步 I/O 量及总量。

(c) N^2 项与 Nd 项的具体数值比是多少? 注意力矩阵的 HBM 读写占总 I/O 的比例是多少?

解答 T-6.3.1

(a) FP16 (2 byte/元素):

步骤	操作	读 (byte)	写 (byte)
Step 1	$S = QK^\top$	$2 \times 2Nd = 4Nd$	$2N^2$
Step 2	$P = \text{softmax}(S)$	$2N^2$	$2N^2$
Step 3	$O = PV$	$2N^2 + 2Nd$	$2Nd$

总 I/O = $(4Nd + 2N^2) + (4N^2) + (2N^2 + 4Nd) = 8Nd + 8N^2$ byte, 主导项 $\Theta(N^2)$ 。

(b) $N = 4096, d = 128$ (FP16):

- N^2 项 (总系数 8): $8 \times 4096^2 \times 2 = 8 \times 33.6 \approx 268$ MB
- Nd 项 (总系数 8): $8 \times 4096 \times 128 \times 2 \approx 8.4$ MB
- 总计约 276 MB

(c) N^2 项与 Nd 项之比 = $N/d = 4096/128 = 32$ 。注意力矩阵的 HBM 读写占总 I/O 的约 $268/276 \approx 97\%$ ——消除它就是 FlashAttention 的核心。

公式 6 · 在线 softmax 递推

$$m_t = \max(m_{t-1}, \text{rowmax}(S_t))$$

$$\ell_t = e^{m_{t-1}-m_t} \ell_{t-1} + \text{rowsum}(e^{S_t-m_t})$$

$$O_t = \text{diag}(e^{m_{t-1}-m_t}) O_{t-1} + e^{S_t-m_t} V_t$$

初始: $m_0 = -\infty$, $\ell_0 = 0$, $O_0 = 0$ 。这三个递推式维护「当前已处理块的、数值稳定的 softmax 加权输出」, 无需存储完整 $N \times N$ 矩阵。

一句话直觉: 每次接收一个新的键块, 用在线最大值更新对历史项进行 rescaling, 维护正确的归一化。

在大模型里的位置: 架构 (FlashAttention 的核心算法)

本组训练目标: 证明 · 判错 · 工程

常见卡点: $-e^{m_{t-1}-m_t}$ 的作用: 将历史项 ℓ_{t-1} 中的基准从 m_{t-1} 切换到 m_t (m_{t-1} 抵消) - $m_0 = -\infty$ 使 $e^{m_0-m_1} = e^{-\infty} = 0$, 第一步退化为无历史的初始化 - 若不做最大值稳定化, 当注意力分数很大时 e^{S_t} 会溢出 (FP16 最大约 65504)

本组在练什么: 用数学归纳法证明递推公式收敛到正确的 softmax 加权输出, 并理解数值稳定化的必要性。做完应能回答: 为什么不做最大值减法会导致数值溢出?

T-6.3.2 【中 · 证明 · 在线 softmax 递推的归纳基础】

- (a) 验证归纳基础 ($t = 1$, $m_0 = -\infty$, $\ell_0 = 0$, $O_0 = 0$): 写出 m_1, ℓ_1, O_1 的表达式, 并验证

$$\frac{O_1}{\ell_1} = \text{softmax}(S_1) V_1$$

(注意 $e^{m_0-m_1} = e^{-\infty} = 0$, 说明历史项如何消失。)

- (b) 判错: 下列关于在线 softmax 的说法哪里有误? 「在线 softmax 递推只是对标准 softmax 的一种数值近似, 在 T 块全部处理完后, O_T/ℓ_T 与真实的 $\text{softmax}(S_{\text{full}})V$ 之间存在一个不可避免的舍入误差积累。」

解答 T-6.3.2

- (a) $t = 1$, $m_0 = -\infty$, $e^{m_0-m_1} = e^{-\infty} = 0$:

$$\begin{aligned} \cdot m_1 &= \max(-\infty, \text{rowmax}(S_1)) = \text{rowmax}(S_1) \\ \cdot \ell_1 &= 0 \cdot \ell_0 + \text{rowsum}(e^{S_1-m_1}) = \text{rowsum}(e^{S_1-m_1}) \\ \cdot O_1 &= 0 \cdot O_0 + e^{S_1-m_1} V_1 = e^{S_1-m_1} V_1 \end{aligned}$$

$$\frac{O_1}{\ell_1} = \frac{e^{S_1-m_1} V_1}{\text{rowsum}(e^{S_1-m_1})} = \text{softmax}(S_1) V_1 \quad \checkmark$$

历史项因 $e^{m_0-m_1} = 0$ 完全消失, 第一步退化为无历史的标准 softmax。

- (b) 说法错误。在线 softmax 递推不是近似，而是精确等价于全序列 softmax。每步的 rescaling（乘以 $e^{m_{t-1}-m_t}$ ）是精确的代数变换，不引入任何截断误差。数学上，通过归纳法可以证明 O_t/ℓ_t 与 $\text{softmax}(S_{\text{full}})V$ 完全相同（见 T-6.3.3 的完整归纳证明）。实现中的浮点舍入误差与其他 softmax 实现完全相同，不存在「额外的误差积累」。

T-6.3.3 【难 · 证明 · 在线 softmax 递推的归纳步骤】 设 $t-1$ 步后 $\hat{O}_{t-1} = O_{t-1}/\ell_{t-1} = \text{softmax}(S_{1:t-1})V_{1:t-1}$ 成立（归纳假设）。

- (a) 展开 $e^{m_{t-1}-m_t}\ell_{t-1}$ ，代入 $\ell_{t-1} = \text{rowsum}(e^{S_{1:t-1}-m_{t-1}})$ ，说明 m_{t-1} 如何被消去，从而证明

$$\ell_t = \text{rowsum}(e^{S_{1:t}-m_t})$$

- (b) 类似地展开 O_t ，利用归纳假设和 (a) 的结论，证明

$$\frac{O_t}{\ell_t} = \text{softmax}(S_{1:t})V_{1:t}$$

从而完成归纳。

- (c) 若不做在线最大值稳定化，直接递推 $\ell'_t = \ell'_{t-1} + \text{rowsum}(e^{S_t})$ ：当某块 S_t 的最大元素为 +40（注意力分数较大），FP16 下会发生什么？在线最大值减法如何避免该问题？

解答 T-6.3.3

- (a) 展开 ℓ_t ：

$$\ell_t = e^{m_{t-1}-m_t}\ell_{t-1} + \text{rowsum}(e^{S_t-m_t})$$

将 $\ell_{t-1} = \text{rowsum}(e^{S_{1:t-1}-m_{t-1}})$ 代入第一项：

$$e^{m_{t-1}-m_t} \cdot \text{rowsum}(e^{S_{1:t-1}-m_{t-1}}) = \text{rowsum}(e^{m_{t-1}-m_t+S_{1:t-1}-m_{t-1}}) = \text{rowsum}(e^{S_{1:t-1}-m_t})$$

（指数相乘： $e^{m_{t-1}-m_t+S_{1:t-1}-m_{t-1}} = e^{S_{1:t-1}-m_t}$ ， m_{t-1} 相消。）故：

$$\ell_t = \text{rowsum}(e^{S_{1:t-1}-m_t}) + \text{rowsum}(e^{S_t-m_t}) = \text{rowsum}(e^{S_{1:t}-m_t}) \quad \square$$

- (b) 展开 O_t ：

$$O_t = e^{m_{t-1}-m_t}O_{t-1} + e^{S_t-m_t}V_t$$

由归纳假设 $O_{t-1} = \ell_{t-1} \cdot \hat{O}_{t-1} = \ell_{t-1} \cdot \text{softmax}(S_{1:t-1})V_{1:t-1}$ ，且 $e^{m_{t-1}-m_t}\ell_{t-1} = \text{rowsum}(e^{S_{1:t-1}-m_t})$ ，故：

$$e^{m_{t-1}-m_t} O_{t-1} = \sum_{j=1}^{t-1} e^{S_j-m_t} V_j$$

从而：

$$O_t = \sum_{j=1}^{t-1} e^{S_j-m_t} V_j + e^{S_t-m_t} V_t = \sum_{j=1}^t e^{S_j-m_t} V_j$$

$$\frac{O_t}{\ell_t} = \frac{\sum_{j=1}^t e^{S_j-m_t} V_j}{\text{rowsum}(e^{S_{1:t}-m_t})} = \text{softmax}(S_{1:t}) V_{1:t} \quad \square$$

(c) 不做稳定化时, $\max S_t = +40$, FP16 下 $e^{40} \approx 2.35 \times 10^{17}$ 远超 FP16 最大值 65504, 导致上溢为 inf 或 NaN, 后续所有计算失效。

在线最大值减法确保当前块的指数参数 $S_t - m_t \leq 0$ (因为 $m_t = \max(\dots, S_t)$), 所有指数值 $e^{S_t-m_t} \in (0, 1]$, FP16 内绝对安全 (最小正数约 6×10^{-5} , 不会下溢), 完全避免上溢。

[工程批注] 在线 softmax 的数值稳定性不只是理论保证, 在实践中至关重要。GPT-2 的 attention 分数 ($QK^\top/\sqrt{d}$) 量级约为 ± 10 , BF16 最大约 65504, $e^{10} \approx 22026$ 安全; 但长序列 (4K+ tokens) 或不规范初始化下分数可能飙至 30–50, $e^{50} \approx 5 \times 10^{21}$ 在任何浮点格式下都溢出。FlashAttention 从第一版就内置了在线 softmax, 这也是 FA 比朴素 tiled attention 更鲁棒的原因之一。FlashAttention-3 (H100 Hopper 专版) 在 Wgmma 指令层面维护相同的在线统计量, 但利用 TMA (Tensor Memory Accelerator) 异步预取, 进一步减少寄存器压力。

公式 7 · FlashAttention 前向 I/O 复杂度

$$T_{I/O}^{\text{FlashAttn}} = \Theta\left(\frac{N^2 d^2}{M}\right)$$

其中 M 为 SRAM 大小 (元素), 假设 $d \leq M \leq Nd$, 块大小取 $B = \Theta(M/d)$ 。相比标准 attention 的 $\Theta(N^2)$, 当 $M \gg d^2$ 时 (H100 上约 $M/d^2 \approx 600$), I/O 下降约两个数量级。

一句话直觉: 用更大的分块 (SRAM 容量决定块大小), 让每次 HBM 搬运的数据支撑更多 SRAM 内计算, I/O 复杂度从 N^2 降到 $N^2 d^2 / M$ 。

在大模型里的位置: 架构 (FlashAttention 的 I/O 复杂度分析)

本组训练目标: 证明 · 代入 · 变形

常见卡点: - $B = \Theta(M/d)$ 来自 SRAM 容量约束 $3Bd \leq M$ (三个 $B \times d$ 块同时在 SRAM 中) - $T_{I/O} = O(N^2 d / B)$ 推导中别忘了 Q 块的读取 (每个外迭代 i 读一次) - $M < d^2$ 时分块策略失效, 复杂度退化至 $\Theta(N^2)$

本组在练什么：从块大小约束出发，一步步推导 FlashAttention 的 I/O 复杂度，不跳步骤。做完应能回答：SRAM 容量约束为什么决定了块大小 B 的上界？

T-6.3.4 【中 · 推导 · FlashAttention I/O 复杂度的完整推导】 设 SRAM 容量 M 个元素， K, V 沿序列维度分成 $T_c = \lceil N/B_c \rceil$ 块， Q, O 分成 $T_r = \lceil N/B_r \rceil$ 块。

- 每次内迭代（固定 Q_i 块，遍历 K_j, V_j 块）的 HBM I/O 量是多少（ B_r, B_c, d 表示）？（注意： $S_i = Q_i K_j^\top$ 和在线 softmax 更新均在 SRAM 内完成， O_i 在外迭代结束后写出一次。）
- 取 $B_r = B_c = B$ ，写出总 I/O 的表达式，化简得 $T_{I/O} = O(N^2 d/B)$ 。
- SRAM 约束： Q_i, K_j, V_j 块同时在 SRAM 中， $3Bd \leq M$ ，给出 B 的上界 $B = O(M/d)$ 。
- 代入 $B = \Theta(M/d)$ ，推导

$$T_{I/O}^{\text{FlashAttn}} = \Theta\left(\frac{N^2 d^2}{M}\right)$$

解答 T-6.3.4

- 每次内迭代（固定 i ，遍历 j ）的增量 HBM I/O：读 K_j, V_j （各 $B_c \times d$ 元素）。 Q_i 在外循环 i 开始时读一次， O_i 在外循环 i 结束时写一次。每次内迭代增量 I/O = $2B_c d$ 元素。
- 外循环 $T_r = N/B_r$ 次，内循环 $T_c = N/B_c$ 次：

$$T_{I/O} = T_r \times [B_r d + T_c \times 2B_c d + B_r d] = \frac{N}{B_r} \times \left[2B_r d + \frac{N}{B_c} \times 2B_c d \right] = 2Nd + \frac{2N^2 d}{B_r}$$

取 $B_r = B_c = B$ ： $T_{I/O} = O(2Nd + 2N^2 d/B)$ 。当 $N \gg B$ 时，后项主导：

$$T_{I/O} = O\left(\frac{N^2 d}{B}\right)$$

- Q_i, K_j, V_j 三个 $B \times d$ 块同时在 SRAM 中： $3Bd \leq M$ ，故 $B \leq M/(3d)$ ，即 $B = O(M/d)$ 。
- 代入 $B = \Theta(M/d)$ ：

$$T_{I/O}^{\text{FlashAttn}} = O\left(\frac{N^2 d}{M/d}\right) = O\left(\frac{N^2 d^2}{M}\right)$$

下界同理（ B 不能超过 $O(M/d)$ ），故

$$T_{I/O}^{\text{FlashAttn}} = \Theta\left(\frac{N^2 d^2}{M}\right) \quad \square$$

[工程批注] FlashAttention v1 (Dao et al. 2022)、v2 (2023)、v3 (2024, H100 Hopper 专版) 均保持相同的 $\Theta(N^2 d^2 / M)$ I/O 复杂度。加速来源的演进: v1 消除了 $N \times N$ 矩阵的 HBM 读写 (I/O 革命); v2 改进 warp 划分 (split-Q 代替 split-KV) 使 A100 达到峰值的 50–73%。

T-6.3.5 【中·数值·FlashAttention 加速比的理论与实测对比】

- A100 的 SRAM: $108 \text{ SM} \times 192 \text{ KB} = 20.7 \text{ MB}$, FP16 每元素 2 byte, $M_{\text{elem}} \approx 10^7$, $d = 128$, $d^2 = 16384$ 。计算渐近加速比 $\Theta(M/d^2)$ 的数值。
- Dao et al. 2022 在 A100 上实测 attention forward pass 加速约 7.6 倍 ($N = 1024$)。与 (a) 相比差距约多少倍?
- 给出至少两条理由解释理论加速比 (数百倍) 与实测加速比 (7–10 倍) 之间的差距。
- 当 $N = 32768$ (长上下文) 时, 你预期实测加速比会更接近还是更远离理论值? 说明原因, 并解释为何 FlashAttention 对长序列更有优势。

解答 T-6.3.5

- $M_{\text{elem}} = 20 \times 10^6 / 2 = 10^7$ (FP16), $d^2 = 128^2 = 16384$:

$$\text{渐近加速比} = \frac{M}{d^2} = \frac{10^7}{16384} \approx 610 \text{ 倍}$$

- 实测约 7.6 倍, 与渐近值 610 相差约 80 倍。
- 差距来源 (至少两条):
 - 序列长度有限**: 渐近分析要求 $N \gg d$, 但 $N = 1024, d = 128$ 时 $N/d = 8$, $N^2 = 1,048,576$ 项与 $Nd = 131,072$ 项仅相差 8 倍 (不是 ∞), Nd 项对标准 attention 的 I/O 贡献不可忽略, 标准 attention 实际 I/O 远小于渐近的 $\Theta(N^2)$ 。
 - SRAM 利用率低于理论值**: shared memory bank conflict、warp 调度开销、write-back 机制等使实际可用 B 低于理论最大 $M/(3d)$, 实际加速比 $\propto B$ 也随之下降。
 - (可选) 在线 softmax 的 rescaling 操作 (额外 CUDA Core 运算, 非 Tensor Core), 引入额外计算开销。
- $N = 32768$ 时: 渐近加速比公式 $\Theta(M/d^2)$ 与 N 无关, 仍约 610。但实测加速比会更接近理论值—— $N/d = 32768/128 = 256 \gg 1$, N^2 项占标准 attention I/O 的 $256/(256+1) \approx 99.6\%$, 标准 attention 接近纯 N^2 主导, 而 FlashAttention 的优化效果充分体现。实测加速比对 $N = 32768$ 通常可达 $10\text{--}20\times$, 明显高于 $N = 1024$ 的 $7.6\times$ 。

T-6.3.6 【难·边界分析·FlashAttention 的适用范围与 FA-2 改进】

- 当 $M < d$ 时, 证明 FlashAttention 的分块策略失效, 最优 attention I/O 复杂度退化至 $\Omega(N^2)$ 。

- (b) 当 $M \geq Nd$ 时（整个 K, V 可放入 SRAM），标准 attention 的 I/O 降至多少？FlashAttention 在此场景下是否还有 I/O 优势？
- (c) FA-2 的 Warp 划分改进：FA-1 将 K, V 切分至 4 个 warp (split-K)，各 warp 需将中间 O 部分写入 shared memory 后同步累加。FA-2 改为将 Q 切分至 warp， K, V 共享。解释为什么 FA-2 的方案减少了 shared memory 写操作次数，并定量说明这对实测峰值利用率的影响（FA-1 约 40% vs FA-2 约 50–73%）。

解答 T-6.3.6

- (a) 当 $M < d$ 时， $B = O(M/d) < 1$ ，块大小不足 1 元素，分块无意义。实际上，即使取最小块 $B = 1$ ，一个 $1 \times d$ 的 Q 行向量（ $d > M$ 个元素）也无法整体驻留 SRAM，每步向量点积均需多次 HBM 往返，总 I/O 趋近 $\Omega(N^2 d/d) \times d = \Omega(N^2 d)$ 甚至更高；下界退化至 $\Omega(N^2)$ 。□
- (b) 当 $M \geq Nd$ 时，整个 K, V （各 Nd 元素）可一次性载入 SRAM。标准 attention 的三步均在 SRAM 内完成，总 HBM I/O 仅需读入 Q, K, V （共 $3Nd$ ）+ 写出 $O(Nd)$ ，共 $\Theta(Nd)$ 。

FlashAttention 在此场景下 I/O 也是 $\Theta(Nd)$ （只需读写 Q, K, V, O ），两者相同，FlashAttention 无额外 I/O 优势。注意实际中此场景极罕见：H100 上 $M \approx 27$ MB， $N = 8192, d = 128$ (FP16) 时 $Nd \times 2 = 2$ MB，可放入单 SM；但 $N > 100K$ 后 Nd 远超 SRAM，优势重新显现。

- (c) FA-1 (split-K)：4 个 warp 各计算 K, V 不同部分的部分 O ，需写入 shared memory（4 次写 $B_r d$ 元素）并同步，由一个 warp 读回累加（1 次读 $4B_r d$ 元素）——每外迭代额外产生约 $5B_r d$ 次 shared memory 操作。

FA-2 (split-Q)：4 个 warp 各独立负责 Q 的不同行，共享同一份 K, V ，各 warp 直接维护自己的 O 部分（无需跨 warp 通信），shared memory 写操作减少约 4×。结果：warp 占用率从约 40%（FA-1，等待同步导致停顿）提升至 50–73%（FA-2），同等 SRAM 容量下 SM 流水线更充分填满。

【做完自检】

- FlashAttention 的 I/O 复杂度 $\Theta(N^2 d^2 / M)$ 中，块大小 $B = \Theta(M/d)$ 是 SRAM 容量约束的直接结果。如果 SRAM 翻倍（ $M \rightarrow 2M$ ），FlashAttention 的 I/O 复杂度如何变化？加速比如何变化？
- 在线 softmax 递推是 FlashAttention 正确性的核心。归纳步骤中， m_{t-1} 被消去的关键等式是什么？为什么从 FP16 溢出的角度看，在线最大值减法是必要的而不仅仅是「更好的」？
- FlashAttention 与 Hong-Kung 下界的关系：Dao et al. 2022 的 Theorem 2 证明了 FlashAttention 的 I/O 复杂度 $\Theta(N^2 d^2 / M)$ 已是最优——不存在在所有 M 范围内均更好的精确 attention 算法。这个最优性与 §6.2 的矩阵乘下界证明在思路上有何相似之处？

§ 6.4 环形注意力 (RingAttention) 的通信复杂度

RingAttention 是 FlashAttention 在多卡场景的自然延伸：让 K, V 块在 GPU 环上「流动」，每张卡依次接收并计算，用流水线重叠掩盖通信时延。本节的数学核心是计算-通信重叠条件，它揭示了一个多卡版本的「脊点」：局部序列太短时计算无法覆盖通信，多卡系统也会陷入「通信受限」。Llama-3 的 1M context 实现正是沿着这套数学框架展开的。

小节导读·公式从哪里来

为什么要用环状传递？单卡装不下 1M context 的 K, V 。但计算 attention 时每个 Q 都要看到全部 K, V 。环状拓扑上，每张卡轮流接手一块 K, V ，全环一圈后每张卡也就看了一轮全部。

第一步：总通信量怎么算。 P 张卡，总序列 N 。每张卡负责 N/P 个 Q ，但需看全部 $K, V \in \mathbb{R}^{N \times d}$ 。环传递中每张卡发送/接收 $2(N/P)d$ byte/轮，共 $P-1$ 轮，单卡总通信 $\sim 2Nd$ ，与 P 无关。

第二步：计算-通信重叠条件。单轮计算量 $\sim 2(N/P)^2 d$ FLOP，耗时 $2(N/P)^2 d / \pi$ ；单轮通信量 $2(N/P)d$ byte，耗时 $2(N/P)d / \beta$ 。重叠条件是计算时间 $\geq$ 通信时间，化简为 $N/P \geq \pi / \beta = I^*$ 。

第三步：多卡版「脊点」。以上不等式说：局部序列长度 N/P 就是多卡场景下的「脊点」。 $N/P < I^*$ 时进入「通信受限」区，增卡 P 也不能提吞。

第四步：Llama-3 1M context 为何要多卷。 $N = 10^6$ ，H100 $I^* \approx 295$ 。要让 $N/P \geq 295$ ， $P \leq 10^6 / 295 \approx 3400$ ——这说明在现有带宽下，1M 序列可以被数千张卡高效并行，不会陷入通信瓶颈。

本节要拿走的一件事：RingAttention 把 Roofline 从单卡推广到集群，多卡「脊点」决定了可以在多少张卡上高效处理多长的序列。

公式 8 · RingAttention 总通信量

$$T_{\text{comm}} = (P-1) \cdot 2 \cdot \frac{N}{P} \cdot d \cdot \text{sizeof} \approx 2Nd \cdot \text{sizeof} [\text{byte}]$$

共 $P-1$ 步，每步发送 K_j 和 V_j 各 $(N/P) \times d$ 个元素，FP16 下总量 $\approx 4Nd$ byte，与 P 无关。

一句话直觉：总通信量固定（只需传递一份 K, V 的等量数据），设备越多每步通信越小，总量不变。

在大模型里的位置：架构（多卡超长序列 attention 的通信复杂度）

本组训练目标：代入·变形·工程

常见卡点：- 每步发送的是 K_j 和 V_j 两个矩阵（各 $(N/P) \times d$ ），不是一个 - $P-1$ 步而不是 P 步（不需要把自己的块发给自己）- 总通信量与 P 「几乎无关」（精确是 $(P-1)/P$ 因子， $P \gg 1$ 时趋于 1）

本组在练什么：验证 RingAttention 的总通信量与 GPU 数无关，并对比 AllGather 方案

在内存占用上的差异。做完应能回答：RingAttention 相比 AllGather 的核心优势是什么？

T-6.4.1 【易 · 代入 · RingAttention 总通信量验证】 设 P 张 GPU，每张持有 $K_p, V_p \in \mathbb{R}^{(N/P) \times d}$ ，FP16（2 byte/元素）。

- 第 t 步 ($t = 1, \dots, P-1$)，GPU p 向下游发送 K_j, V_j 。计算每步通信量 (byte，用 N, P, d 表达)。
- 共 $P-1$ 步，计算总通信量 (byte)，化简并验证它与 P 的关系 ($P \gg 1$ 时渐近)。
- 朴素 AllGather 方案：每张卡接收其他 $P-1$ 张卡的 K, V ，总接收量与 (b) 相同。解释为何两种方案通信量相同，但 RingAttention 的每卡内存占用更小（代入 $N = 10^6$ ， $d = 128$ ， $P = 128$ 计算 AllGather 后每卡的 K, V 内存占用 MB）。

解答 T-6.4.1

- 每步发送 K_j, V_j 各 $(N/P) \times d$ 个 FP16 元素：

$$\text{每步通信量} = 2 \times \frac{N}{P} \times d \times 2 = \frac{4Nd}{P} \text{ byte}$$

- 共 $P-1$ 步：

$$T_{\text{comm}} = (P-1) \times \frac{4Nd}{P} = 4Nd \times \frac{P-1}{P} \approx 4Nd \text{ byte} \quad (P \gg 1)$$

总通信量 $\Theta(Nd)$ ，与 P 渐近无关。

- 朴素 AllGather 每张卡接收 $(P-1) \times 2 \times (N/P) \times d \times 2 \approx 4Nd$ byte——总量相同。

但 AllGather 后每张卡保存完整 K, V （各 Nd 元素）： $N = 10^6, d = 128, P = 128$ (FP16) 时，每卡 $K+V$ 占 $2 \times 10^6 \times 128 \times 2 = 512$ MB，加上 Q, O 和激活值极易 OOM。RingAttention 每卡任意时刻只持有一个 $(N/P) \times d = (10^6/128) \times 128 = 10^6$ 元素的 K_j, V_j 块，约 4 MB，内存占用随 P 线性降低。

公式 9 · 计算-通信完全重叠条件与 $P_{\max}$

$$\frac{N}{P} \geq \frac{2F}{\beta_{\text{NVLink}}} \implies P_{\max} = \left\lfloor \frac{N \cdot \beta_{\text{NVLink}}}{2F} \right\rfloor$$

其中 F 为单卡浮点算力 (FLOP/s)， β_{NVLink} 为单向 NVLink 带宽 (byte/s)。该条件表达「每步计算时间 $\geq$ 每步通信时间」。

一句话直觉：每卡的局部序列不能太短，否则矩阵乘太快做完，通信来不及，流水线断裂。

在大模型里的位置：架构（多卡训练的扩展性上限）

本组训练目标：推导 · 代入 · 工程

常见卡点：- F 越大（算力越强）， $P_{\max}$ 越小——算力提升反而使扩展性变差，直觉上是因为计算更快完成，通信更难被掩盖 - 公式中 d 不出现—— $P_{\max}$ 与 head dimension 无关 - NVLink 带宽（约 450 GB/s）与 InfiniBand 带宽（约 50 GB/s）差了 9 倍， $P_{\max}$ 也差 9 倍

本组在练什么：从 $t_{\text{comp}} \geq t_{\text{comm}}$ 的不等式出发推导 $P_{\max}$ 公式，代入 H100 具体参数得出百万 token 场景下的扩展极限。做完应能回答：为什么算力越强， $P_{\max}$ 越小？

T-6.4.2 【中 · 推导 · 计算-通信重叠条件与 $P_{\max}$ 公式】 每步计算时间：

$$t_{\text{comp}} = \frac{2(N/P)^2 d}{F}$$

每步通信时间（发送 K_j, V_j 共 $4(N/P)d$ byte）：

$$t_{\text{comm}} = \frac{4(N/P)d}{\beta_{\text{NVLink}}}$$

(a) 写出完全重叠条件 $t_{\text{comp}} \geq t_{\text{comm}}$ ，展开化简，逐步推导出

$$\frac{N}{P} \geq \frac{2F}{\beta_{\text{NVLink}}}$$

（给出每一步代数操作，不跳步骤。）

(b) 由 (a) 解出 $P_{\max} = \lfloor N\beta_{\text{NVLink}}/(2F) \rfloor$ 。

(c) 定义「通信算术强度」 $I_{\text{comm}} = F/\beta_{\text{NVLink}}$ ，将 $P_{\max}$ 写成 N 和 I_{comm} 的函数，解释它与单卡脊点 $I^* = P_{\text{peak}}/\beta_{\text{HBM}}$ 的类比关系（多卡版「内存墙」是什么?）。

解答 T-6.4.2

(a) 重叠条件 $t_{\text{comp}} \geq t_{\text{comm}}$ ：

$$\frac{2(N/P)^2 d}{F} \geq \frac{4(N/P)d}{\beta_{\text{NVLink}}}$$

两边同除以 $(N/P) \cdot d > 0$ ：

$$\frac{2(N/P)}{F} \geq \frac{4}{\beta_{\text{NVLink}}}$$

整理：

$$\frac{N}{P} \geq \frac{4F}{2\beta_{\text{NVLink}}} = \frac{2F}{\beta_{\text{NVLink}}} \quad \square$$

(b) 由 $N/P \geq 2F/\beta_{\text{NVLink}}$ 变形（两边同时取倒数并乘以 N ）：

$$P \leq \frac{N \cdot \beta_{\text{NVLink}}}{2F}$$

取下整： $P_{\max} = \lfloor N\beta_{\text{NVLink}}/(2F) \rfloor$ 。

(c) 令 $I_{\text{comm}} = F/\beta_{\text{NVLink}}$ （单位 FLOP/byte），则

$$P_{\max} = \left\lfloor \frac{N}{2I_{\text{comm}}} \right\rfloor$$

类比：单卡上，kernel 的算术强度 $I \geq I^* = P_{\text{peak}}/\beta_{\text{HBM}}$ 才能脱离内存受限；多卡上，每卡局部序列长度 $N/P \geq 2I_{\text{comm}} = 2F/\beta_{\text{NVLink}}$ 才能脱离「通信受限」。两者都是「计算/带宽比」作为临界阈值，数学结构完全同构—— I_{comm} 是多卡系统的「脊点」， N/P 是「局部算术强度」的类比量。

[工程批注] Llama-3 的 1M context 实现 (Meta, 2024) 正是沿 RingAttention 框架展开的，使用 128 张 H100 NVLink 互联（单向约 450 GB/s）。代入 $F = 989$ TFLOPS (TF32)、 $N = 10^6$ ，计算得 $P_{\max} \approx 227$ ——128 张刚好在安全区内，计算可完全覆盖通信。实际部署还需考虑 NCCL 延迟、causal masking 下的负载不均（用 Striped Attention 缓解），可达重叠率约 85–90%。

T-6.4.3 【中 · 数值 · H100 上百万 token 的 $P_{\max}$ 】 H100 SXM5: $F = 989$ TFLOPS (TF32) 或 1979 TFLOPS (FP16)， $\beta_{\text{NVLink}} = 450 \times 10^9$ byte/s（单向 NVLink）。

- 序列长度 $N = 10^6$ ，分别使用 TF32 和 FP16 算力计算 $P_{\max}$ ，说明为何 FP16 下 $P_{\max}$ 更小。
- 若使用 InfiniBand 互联（ $\beta_{\text{IB}} = 50 \times 10^9$ byte/s），重新计算 $P_{\max}$ (TF32)。若实际部署集群有 256 张 H100，IB 互联能否实现完全重叠？
- 序列长度从 $N = 10^6$ 增加至 $N = 4 \times 10^6$ ， $P_{\max}$ 如何变化？这说明 RingAttention 对超长序列的扩展性如何？

解答 T-6.4.3

(a) TF32 ($F = 989 \times 10^{12}$):

$$P_{\max}^{\text{TF32}} = \frac{10^6 \times 450 \times 10^9}{2 \times 989 \times 10^{12}} = \frac{4.5 \times 10^{17}}{1.978 \times 10^{15}} \approx 227$$

FP16 ($F = 1979 \times 10^{12}$):

$$P_{\max}^{\text{FP16}} = \frac{4.5 \times 10^{17}}{2 \times 1.979 \times 10^{15}} \approx \frac{4.5 \times 10^{17}}{3.958 \times 10^{15}} \approx 114$$

FP16 下算力翻倍，每步计算时间减半，需要更长的局部序列才能覆盖通信，故 $P_{\max}$ 更小。直觉：算力越强，通信越难被掩盖。

(b) InfiniBand ($\beta_{\text{IB}} = 50 \times 10^9 \text{ byte/s}$, TF32):

$$P_{\text{max}}^{\text{IB}} = \frac{10^6 \times 50 \times 10^9}{2 \times 989 \times 10^{12}} \approx \frac{5 \times 10^{16}}{1.978 \times 10^{15}} \approx 25$$

结论：IB 下仅 25 张 H100 可完全重叠，远不足 256 张集群——通信是瓶颈，有效利用率约 $25/256 \approx 10\%$ ，需进一步流水线分区或减少通信频率。

(c) $N = 4 \times 10^6$: $P_{\text{max}}^{\text{TF32}} = 4 \times 227 = 908$, $P_{\text{max}}^{\text{FP16}} = 4 \times 114 = 456$ 。

P_{max} 与 N 成正比——序列越长，每卡局部计算量增加 ($\propto (N/P)^2$)，覆盖通信 ($\propto N/P$) 更容易，可支持更多 GPU 无瓶颈扩展。这是 RingAttention 对超长序列的天然扩展性来源。

T-6.4.4 【难 · 负载均衡 · Causal Attention 下的不均匀计算与 Striped Attention】 标准 RingAttention 假设所有 GPU 计算量相同，但 causal（因果）attention 下，持有后期 token 的 GPU 计算量远大于持有早期 token 的 GPU。

- 设 GPU p 持有 token $[(p-1)N/P + 1, pN/P]$ ，局部长度 $L = N/P$ 。估算 GPU 1（最早 token）和 GPU P （最晚 token）各自在完整 causal attention 中的有效 FMA 操作数（可给出数量级表达式），并计算两者之比。
- 计算量不均匀如何破坏计算-通信重叠条件？（从「最慢卡决定步进速度」的角度分析。）
- Striped Attention 将 token 索引按步长 P 重排，GPU p 持有 token $\{p, p+P, p+2P, \dots\}$ （「条纹」分布）。解释为何此重排在 causal attention 下能恢复负载均衡，并说明它对 P_{max} 条件的影响。

解答 T-6.4.4

- GPU p 持有 token $[(p-1)L + 1, pL]$ ($L = N/P$)。Causal attention 下，GPU p 的每个 query q 只能 attend 到 $\text{index} \leq q$ 的 key：
 - GPU 1 (token 1 到 L)：对自身的 L 个 query，有效 key 最多在自身块内，有效 FMA $\sim L^2 d/2$ （三角形面积）。
 - GPU P (token $(P-1)L + 1$ 到 N)：其 query 可 attend 到所有 P 张卡的 key，有效 FMA $\sim P \cdot L^2 d$ （近似完整矩形）。

两者之比约为 P （数量级上 GPU P 的计算量是 GPU 1 的 P 倍）。

- 计算量不均匀时，环形流水的每步步进速度由最慢卡决定。GPU P 需要 $\sim P$ 倍于 GPU 1 的计算时间，导致其他卡必须等待，通信-计算重叠完全失效（早完成的卡空闲等待）。实际等效利用率约 $1/P$ 的可用算力被浪费，整个重叠假设破裂。
- Striped Attention (Brandon et al. 2023) 将 token 重排为 GPU p 持有 $\{p, p+P, p+2P, \dots\}$ （步长 P 的条纹）。重排后：
 - 每张 GPU 的 query token 均匀分布在 $[1, N]$ ，causal masking 作用在每张卡上的有效 key 数目约为 $N/2$ （均值），各卡差异从 P 倍缩减至 $O(1)$ 倍。

- 重排不改变数学正确性：注意力的计算结果（输出向量）与未重排完全相同，只是按不同顺序处理（masking 逻辑需相应调整，用 token 全局索引而非局部位置判断因果关系）。
- 重叠条件恢复有效：各卡计算量均匀后 t_{comp} 相同，重叠不等式 $t_{\text{comp}} \geq t_{\text{comm}}$ 对所有卡成立， P_{max} 的理论推导重新有效。

【做完自检】

1. RingAttention 总通信量 $\approx 4Nd$ byte 与 P 无关（渐近）。这与 AllGather 方案的总通信量相同——那么 RingAttention 的核心优势究竟是什么？（提示：从每卡内存占用和计算-通信重叠两个角度分析。）
2. P_{max} 公式中算力 F 越大， P_{max} 越小——这看起来反直觉。从「计算太快导致通信无法被掩盖」的角度，解释这一现象的物理含义。
3. Striped Attention 通过重排 token 索引解决了 causal attention 的负载不均问题。这一重排对模型的数学正确性（注意力结果是否变化）和工程实现（是否需要修改 masking 逻辑）各有什么影响？

§ 6.5 算术强度的演化：从 V100 到 B200

本节是对前四节的「历史标定」。算术强度的演化不是一个平滑的曲线，而是每一代 GPU 由算力增速与带宽增速的博弈决定的折线。从 V100 到 H100，脊点从 139 翻到 295——这意味着一大批曾经计算受限的 kernel 现在变成了内存受限。B200 的带宽增速首次超过算力增速，脊点微降，但 FP4 推理场景下脊点飙升至 1125 FLOP/byte。这些数字不是历史知识，而是算法设计决策的约束条件。

小节导读·公式从哪里来

为什么脊点一路上升？脊点 $I^* = \pi/\beta$ 。只要算力 π 增速超过带宽 β ，脊点就会上移。意义重大：同一个 kernel，今天是计算受限，明天可能变内存受限。

第一步：V100→H100 的数字。V100 FP16: $\pi = 125$ TFLOP/s、 $\beta = 0.9$ TB/s, $I^* \approx 139$ 。H100 FP16: $\pi = 989$ 、 $\beta = 3.35$, $I^* \approx 295$ 。一代间脊点翻倍多。

第二步：什么 kernel 被赶下马。原本 $I = 200$ 的 GEMM，在 V100 时计算受限 ($200 > 139$)，到 H100 时变为内存受限 ($200 < 295$)。历史优化变为新劣势。

第三步：B200 为何能脊点略降。B200 带宽 $\beta \approx 8$ TB/s 的增速首次超过算力 $\pi \approx 2250$ TFLOP/s 增速， $I^* \approx 281$ 。这是 β 赶上时的信号。

第四步：FP4 场景为何脊点飙升。低精度下 π 能翻几倍（FP4 下 $\pi \approx 9000$ TFLOP/s），但 β 不变， $I^* \approx 1125$ 。意味着 FP4 推理几乎总是内存受限：KV cache、权重读取变成瓶颈。

第五步：演化是可预测的约束源。某代硬件出现前，上一代上可运行的算法能提前用脊点变化反推优化方向：带宽赶不上时，要侧重 KV cache 压缩、权重量化、迁移到高算术强度 kernel。

本节要拿走的一件事：脊点是硬件的「人格」：它强迫算法设计跟上物理演化；FP4 时

代的「内存墙」是下一代优化的主战场。

公式 10 · Ridge Point 的代际演化

$$I^{*(t+1)} = I^{*(t)} \cdot \frac{\alpha_F}{\alpha_\beta}, \quad \alpha_F = \frac{P_{\text{peak}}^{(t+1)}}{P_{\text{peak}}^{(t)}}, \quad \alpha_\beta = \frac{\beta^{(t+1)}}{\beta^{(t)}}$$

各代 GPU 参数 (FP16 dense Tensor Core):

GPU	架构	P_{peak} (TFLOPS)	β (TB/s)	I^* (FLOP/byte)
V100 SXM2 (2018)	Volta	125	0.90	139
A100 SXM4 (2020)	Ampere	312	2.00	156
H100 SXM5 (2022)	Hopper	989 [†]	3.35	295
B200 SXM (2025)	Blackwell	2,250	8.00	281

[†] 989 TFLOPS 为 TF32 dense; FP16 dense 为 1,979 TFLOPS, 对应 $I^* \approx 590$ FLOP/byte。

一句话直觉: 若算力增速快于带宽增速 ($\alpha_F > \alpha_\beta$), 脊点右移, 更多 kernel 陷入内存受限。

在大模型里的位置: 架构 (算法设计必须追赶脊点右移的步伐)

本组训练目标: 代入 · 分析 · 工程

常见卡点: - H100→B200 脊点微降 (FP16 基准), 但 FP4 场景下脊点大幅上升 - α_F, α_β 的基准精度必须一致 (TF32 vs TF32, FP16 vs FP16) - 脊点右移是「对算法不利的信号」: 以前计算受限的 kernel 现在可能已经内存受限

本组在练什么: 计算每代 GPU 的脊点, 分析增长因子, 理解脊点演化对算法设计的影响。做完应能回答: 从 A100 到 H100 脊点增幅最大, 背后哪项架构创新贡献最多?

T-6.5.1 【易 · 代入 · 四代 GPU 的 Ridge Point 计算与验证】

- 根据表格数据, 用 $I^* = P_{\text{peak}}/\beta$ 验算 V100、A100、H100 (TF32 基准)、B200 四代的 Ridge Point, 保留整数。
- V100 (2018) 到 H100 (2022) 三代, I^* 从 139 升至 295, 增幅约多少倍?
- H100→B200, I^* 从 295 微降至 281 (FP16 基准)。这是硬件设计的倒退吗? 请从 HBM3e 带宽增幅和 FP4 推理场景两个角度说明这一微降是合理的。

解答 T-6.5.1

(a) 验算 $I^* = P_{\text{peak}}/\beta$:

- V100: $125/0.90 \approx 139$ FLOP/byte $\checkmark$
- A100: $312/2.00 = 156$ FLOP/byte $\checkmark$
- H100 (TF32): $989/3.35 \approx 295$ FLOP/byte $\checkmark$
- B200: $2250/8.00 \approx 281$ FLOP/byte $\checkmark$

(b) V100 (139) $\rightarrow$ H100 (295): 增幅 = $295/139 \approx 2.12$ 倍 (即 +112%)。(c) 不是设计倒退。B200 的带宽从 3.35 增至 8.00 TB/s (增幅 2.39 $\times$), 算力从 989 增至 2250 TFLOPS (增幅 2.27 $\times$), 带宽增速首次略超算力增速, 脊点轻微下降。

两个角度: HBM3e (8 Gbps/pin vs HBM3 的 5.23 Gbps/pin) 实现了相对更大的带宽跃升, 属于内存技术代际突破。FP4 推理视角: B200 FP4 算力 9000 TFLOPS, $I_{\text{FP4}}^* = 9000/8 = 1125$ FLOP/byte, 远高于 H100 TF32 的 295——FP4 场景下脊点仍大幅上升, FP16 基准的微降是非主力精度场景的局部现象。

T-6.5.2 【中·分析·增长因子与 Ridge Point 单调性】

(a) 计算相邻两代的 α_F 和 α_β , 填写下表并判断 I^* 趋势:

代际	α_F	α_β	α_F/α_β	I^* 趋势
V100 $\rightarrow$ A100	?	?	?	?
A100 $\rightarrow$ H100	?	?	?	?
H100 $\rightarrow$ B200	?	?	?	?

(b) A100 $\rightarrow$ H100 是历史上 Ridge Point 增幅最大的一跳 (约 89% 增幅)。从 Hopper 架构的设计创新角度, 说明为什么算力增幅 ($\alpha_F \approx 3.17$) 远大于带宽增幅 ($\alpha_\beta \approx 1.68$)。

(c) 判错: 「B200 的 Ridge Point (281 FLOP/byte) 低于 H100 (295 FLOP/byte), 说明 B200 在内存受限 kernel 上相比 H100 没有改进。」

解答 T-6.5.2

(a) 增长因子表:

代际	α_F	α_β	α_F/α_β	I^* 趋势
V100 $\rightarrow$ A100	$312/125 = 2.50$	$2.00/0.90 = 2.22$	1.12	上升 (156 > 139)
A100 $\rightarrow$ H100	$989/312 = 3.17$	$3.35/2.00 = 1.68$	1.89	上升 (295 > 156)
H100 $\rightarrow$ B200	$2250/989 = 2.27$	$8.00/3.35 = 2.39$	0.95	微降 (281 < 295)

(b) A100 $\rightarrow$ H100 算力增幅 3.17 $\times$ 极为突出, 主要来源:

- FP8 Transformer Engine (H100 专属): 支持 FP8 精度的混合精度训练, 相同物理 Tensor Core 数目下吞吐翻倍;
 - 第四代 NVTensor Core (WGMMMA 指令): Warp Group 级别的矩阵乘融合, 寄存器复用率更高, 峰值 MMA 吞吐率相比 Ampere 第三代提升近 2×;
 - 额外: 更大 L2 缓存 (50 MB vs 40 MB) 减少 DRAM 访问竞争。
- (c) 错误。B200 的内存受限性能上界为 $I \cdot \beta_{B200} = I \times 8.00 \text{ TB/s}$, 而 H100 为 $I \times 3.35 \text{ TB/s}$, B200 的内存受限 kernel 吞吐量提升约 2.39 倍 (带宽之比)。脊点微降 (FP16 基准) 不代表带宽性能变差, 相反带宽增幅更大意味着内存受限 kernel 在 B200 上更快。脊点下降的含义是「相对而言更多的 kernel 保持内存受限」, 而不是「性能变差」。

T-6.5.3 【中 · 量化效应 · FP8 和 FP4 对算术强度的影响】

- (a) FP16→FP8: 数据量 Q 减半, 计算量 W 不变, 算术强度 $I = W/Q$ 变为原来的多少倍?
- (b) H100 FP8 峰值算力约 3,958 TFLOPS, HBM 带宽仍 3.35 TB/s, 计算 $I_{H100, FP8}^*$ 。
- (c) B200 FP4 峰值算力约 9,000 TFLOPS, HBM 带宽 8.00 TB/s, 计算 $I_{B200, FP4}^*$, 并与 H100 FP8 对比。
- (d) 矩阵-向量乘 (batch size = 1) 在 FP16 下算术强度约 1 FLOP/byte; FP4 下变为多少? 与 B200 FP4 脊点 (1125 FLOP/byte) 对比, 该操作是计算受限还是内存受限? 量化对其速度的直接提升机制是什么?

解答 T-6.5.3

- (a) FP16→FP8: $Q \rightarrow Q/2$, W 不变, $I = W/Q \rightarrow W/(Q/2) = 2I$, 算术强度翻倍。
- (b) H100 FP8:

$$I_{H100, FP8}^* = \frac{3958}{3.35} \approx 1181 \text{ FLOP/byte}$$

- (c) B200 FP4:

$$I_{B200, FP4}^* = \frac{9000}{8.00} = 1125 \text{ FLOP/byte}$$

H100 FP8 (1181) $\approx$ B200 FP4 (1125), 两者脊点相近, 均约为 H100 TF32 (295) 的 4 倍。

- (d) 矩阵-向量乘 (batch=1) FP16 下 $I \approx 1 \text{ FLOP/byte}$; FP4 下每元素仅 0.5 byte, Q 减为原来的 1/4, $I \rightarrow 4 \text{ FLOP/byte}$ 。

$4 \ll 1125$: 深度内存受限。量化对此 kernel 的速度提升机制: 不是通过提升 I 越过脊点 (4 仍远低于 1125), 而是直接减小数据量 Q (同样 W 下 Q 减为 1/4), 使实际带宽受限性能 $= I \cdot \beta = (W/Q) \times \beta$ 提升 4 倍 (Q 减 4×, 速度提 4×, 带宽固定)。

[工程批注] 量化对内存受限 kernel 的加速机制是「减少搬运字节数」, 而非「提升算术强度越过脊点」。这一区分在工程中至关重要: FP4 对 batch=1 推

理的实际加速约 $3\sim 4\times$ (受量化误差修正、dequant 开销等影响), 而不是理论上的 $4\times$ 。B200 的 FP4 Tensor Engine 在推理场景下峰值 9000 TFLOPS, 但对 batch=1 解码, 真正决定速度的仍然是 8.00 TB/s 的 HBM3e 带宽。换言之: B200 对推理的最大贡献不是算力, 是带宽 (8 TB/s 是 H100 的 $2.39\times$)。

T-6.5.4【难·综合·一个 kernel 在四代 GPU 上的完整 Roofline 分析】 某 kernel 的算术强度 $I = 50$ FLOP/byte (FP16, 典型 FlashAttention 中等序列长度估计值)。

- 根据 Roofline 公式, 计算该 kernel 在 V100、A100、H100 (FP16)、B200 (FP16) 四代 GPU 上各自的理论峰值性能 (TFLOPS), 并判断每代是内存受限还是计算受限。
- 各内存受限代上, 性能随带宽增长而增长。计算 V100→B200 的理论吞吐量增幅, 说明为何即使不改变算法, 换卡也能加速内存受限 kernel。
- 若通过 tiling/fusion 将 I 从 50 提升至 300 FLOP/byte, 在 H100 FP16 ($I^* = 590$) 上性能如何变化? 提升幅度是多少? 一旦 $I > I^*$ 后再继续提升 I 还有意义吗?
- 在 $\log(I) - \log(P)$ 的 Roofline 图上, 随 GPU 代际更迭 (V100→B200), 脊点如何移动 (向右、向上, 还是两者都有)? 这对算法设计意味着什么? (用「FlashAttention-2 为何要比 FA-1 用更大的 tile」来具体说明。)

解答 T-6.5.4

- 脊点: V100 (139)、A100 (156)、H100 FP16 (590)、B200 FP16 (281)。 $I = 50$ 均小于各代脊点:

GPU	I^*	$I = 50$ vs 脊点	受限类型	理论峰值
V100	139	$50 < 139$	内存受限	$50 \times 0.90 = 45$ TFLOPS
A100	156	$50 < 156$	内存受限	$50 \times 2.00 = 100$ TFLOPS
H100 (FP16)	590	$50 < 590$	内存受限	$50 \times 3.35 = 167.5$ TFLOPS
B200 (FP16)	281	$50 < 281$	内存受限	$50 \times 8.00 = 400$ TFLOPS

四代均内存受限。

- V100→B200 理论吞吐量: $45 \rightarrow 100 \rightarrow 167.5 \rightarrow 400$ TFLOPS, 增幅约 8.9 倍 (带宽比 $8.00/0.90 = 8.9$)。即使算法不变, 换更高带宽的 GPU 就能使内存受限 kernel 获得近 $9\times$ 的吞吐提升。

- $I = 300$ FLOP/byte, H100 FP16 ($I^* = 590$): $300 < 590$, 仍内存受限, 性能 $= 300 \times 3.35 = 1,005$ TFLOPS, 比 $I = 50$ 时 (167.5 TFLOPS) 提升 6 倍。

一旦 $I > I^* = 590$, 性能封顶于 $P_{\text{peak}} = 1,979$ TFLOPS, 继续提升 I 不再有性能收益 (已进入计算受限区域, 带宽和算术强度不再是瓶颈)。

(d) 在 $\log I - \log P$ 的 Roofline 图上，随代际更迭：

- **向右移动**：脊点 $I^* = P_{\text{peak}}/\beta$ 增大 (V100→H100 从 139 到 295，总体右移)，内存受限区域扩大，更多以前计算受限的 kernel 现在变为内存受限。
- **向上移动**： P_{peak} 大幅增加 (V100: 125 → B200: 2250 TFLOPS)，水平段上移； β 增大，斜线段斜率不变但整体上移。

对算法设计的含义：脊点右移意味着算法如果不主动「追赶」(提升 I)，会从「刚好计算受限」滑落到「内存受限」。FlashAttention-2 使用比 FA-1 更大的 tile (更大 B_r, B_c)，正是为了提升 I 的实际值 (每次 SRAM 填满时能完成更多的矩阵乘 FLOP)，从而在 H100 脊点右移后 (295 vs A100 的 156) 仍保持较高利用率。不做 tile 大小优化的 FA-1 在 A100 上算术强度约 40–60 FLOP/byte (已内存受限)，到 H100 上不变则脊点右移更远，利用率反而下降。

T-6.5.5 【难·判错·算术强度演化的常见误解】 以下各说法均含有错误。找出每条错误并给出正确表述：

- 「B200 的 FP16 脊点 (281 FLOP/byte) 低于 H100 (295 FLOP/byte)，所以 B200 在 FP16 推理上比 H100 慢。」
- 「算术强度是 kernel 在 H100 上的属性——同样的算法在 A100 上算术强度更低，因为 A100 的算力更弱。」
- 「FlashAttention 将 attention 的算术强度从接近 0 提升到了 $M/d^2 \approx 600$ FLOP/byte，所以 FlashAttention 在 H100 上是计算受限的。」

解答 T-6.5.5

- 错误。B200 FP16 的 HBM 带宽 8.00 TB/s 远大于 H100 的 3.35 TB/s，内存受限 kernel 的实际吞吐量 $= I \cdot \beta$ 在 B200 上更高 ($I \cdot 8.00$ vs $I \cdot 3.35$ ，相差 2.39 倍)。脊点微降 (295→281) 意味着「需要更高的算术强度才能是计算受限」，但不意味着推理速度变慢。对绝大多数实际 kernel ($I < 281$ ，内存受限)，B200 比 H100 快约 2.39 倍 (带宽增幅)。
- 错误。算术强度 $I = W/Q$ 是 kernel 的内禀属性，只取决于算法的浮点运算数 W 和数据搬运字节数 Q ，与硬件 (GPU 型号、算力大小) 无关。同样的算法在 A100 和 H100 上的 I 完全相同；不同的是 I 与各代 I^* 的大小关系 (在 A100 上可能计算受限，在 H100 上同一 I 可能变为内存受限——因为 I^* 右移了)。
- 错误。FlashAttention 并没有把算术强度提升到 $M/d^2 \approx 600$ FLOP/byte。其 I/O 复杂度从 $\Theta(N^2)$ 降到 $\Theta(N^2 d^2/M)$ ——这是 I/O 字节数减少了 M/d^2 倍，而不是算术强度提升了 M/d^2 倍。FlashAttention 的实际算术强度 (W/Q) 在 H100 上仍约 40–80 FLOP/byte (内存受限)，远低于脊点 590。 M/d^2 是 FA 相对标准 attention 的 I/O 减少倍数，不是 FlashAttention 本身的算术强度。

【做完自检】

- 从 V100 到 H100，Ridge Point 从 139 翻到 295。假设你有一个算术强度 $I = 200$

FLOP/byte 的自定义 kernel，它在 V100 上是计算受限还是内存受限？在 H100 上呢？这一变化对你的优化策略意味着什么？

2. B200 的带宽增速 ($2.39\times$) 首次超过算力增速 ($2.27\times$)，导致 FP16 脊点微降。如果下一代 GPU 的带宽增速持续超过算力增速，从算法设计角度看这是好消息还是坏消息？
3. 量化 (FP4) 将算术强度提升 4 倍，但矩阵-向量乘在 B200 FP4 下仍然深度内存受限 ($I \approx 4$ vs $I^* = 1125$)。量化对此 kernel 的实际加速效果体现在哪里（不是通过提升算术强度越过脊点，而是通过……）？

第 7 章 · 后变换器时代的数学

§ 7.1 状态空间模型的连续形式

从一阶线性 ODE 出发，经积分因子法得到闭式解，再把闭式解折叠进卷积视角，最后进入频域看传递函数的极点。这四步构成全章的「入场券」：理解了连续形式，才能真正读懂 § 7.2 的 HiPPO 矩阵推导和 § 7.3 的离散化。

小节导读 · 公式从哪里来

为什么要从连续 ODE 起步？SSM 可以看作一个一阶线性动力系统 $\dot{h}(t) = Ah(t) + Bu(t)$ 、 $y(t) = Ch(t) + Du(t)$ 。连续形式是「同一个模型」的三个视角（ODE、卷积、频域）能够平等互换的源头。

第一步：积分因子法得闭式解。乘以 e^{-At} 使左边变为 $\frac{d}{dt}(e^{-At}h) = e^{-At}Bu$ 。从 0 积到 t ，得 $h(t) = e^{At}h(0) + \int_0^t e^{A(t-\tau)}Bu(\tau)d\tau$ 。后一项是输入与核 $e^{A(t-\tau)}B$ 的卷积。

第二步：卷积视角。将输出写为 $y(t) = \int_0^t Ce^{A(t-\tau)}Bu(\tau)d\tau + Du(t) = k * u(t)$ ，其中 $k(t) = Ce^{At}B$ 。这是「脱离状态」的看法：LTI 系统本质上就是一个卷积。

第三步：频域视角。双边对输入取 Laplace 变换： $Y(s) = H(s)U(s)$ ， $H(s) = C(sI - A)^{-1}B + D$ 。 H 是传递函数，极点为 A 的特征值。极点位置决定稳定性与衰减速率。

第四步：三个视角为何同时重要。ODE 视角适合推理时递推（类 RNN），卷积视角适合训练时并行（FFT 卷积 $O(L \log L)$ ），频域视角适合分析表达能力与衰减谱。S4/Mamba 的工程优势正是「同一模型三种走法」。

本节要拿走的一件事：LTI 状态空间是 ODE、卷积与频域三位一体；S4/Mamba 能在 RNN 跟 Transformer 间隔中生存，正是仰仗于多视角等价。

公式 1 · LTI 系统方程

$$h'(t) = Ah(t) + Bx(t), \quad y(t) = Ch(t)$$

其中 $A \in \mathbb{R}^{N \times N}$ 是状态转移矩阵， $B \in \mathbb{R}^{N \times 1}$ 是输入投影， $C \in \mathbb{R}^{1 \times N}$ 是输出投影。

一句话直觉：用一阶线性微分方程描述「固定大小缓存状态如何被新输入推着走」。

在大模型里的位置：架构（模型结构 / 算子设计 / 表示空间）

本组训练目标：代入·变形·工程

常见卡点：

- $h(t)$ 是向量而非标量，矩阵指数 e^{At} 不是普通标量指数
- 稳定性条件是「所有特征值实部 < 0 」，而非矩阵元素为负
- LTI 限制了 A, B, C 不依赖输入——这正是 § 7.4 Mamba 要突破的限制

本组在练什么：标量和 2×2 情形的矩阵指数数值、稳定性判断。做完应能回答：给定 A ，如何判断系统是否渐近稳定？

T-7.1.1 【易·代入·标量 SSM 数值】 设 $N = 1$, $A = -2$, $B = 1$, $C = 3$, $h(0) = 0$, 输入 $x(t) = 1$ (常数)。

- 写出卷积核 $K(t) = Ce^{At}B$ 的显式表达式；
- 计算 $t = 0.1, 0.5, 1.0, 2.0$ 时 $K(t)$ 的数值（保留 3 位小数）；
- 用闭式解计算 $y(1) = \int_0^1 K(1-s) \cdot 1 ds$ ，给出数值结果。

解答 T-7.1.1

(a) $K(t) = Ce^{At}B = 3 \cdot e^{-2t} \cdot 1 = 3e^{-2t}$ 。

(b) 数值表：

t	$K(t) = 3e^{-2t}$
0.1	$3e^{-0.2} \approx 3 \times 0.8187 = 2.456$
0.5	$3e^{-1} \approx 3 \times 0.3679 = 1.104$
1.0	$3e^{-2} \approx 3 \times 0.1353 = 0.406$
2.0	$3e^{-4} \approx 3 \times 0.0183 = 0.055$

(c)

$$y(1) = \int_0^1 3e^{-2(1-s)} \cdot 1 ds = 3e^{-2} \int_0^1 e^{2s} ds = 3e^{-2} \cdot \frac{e^2 - 1}{2} = \frac{3(1 - e^{-2})}{2} \approx \frac{3 \times 0.8647}{2} \approx 1.297.$$

T-7.1.2 【中·变形· 2×2 稳定性与传递函数】 设 2×2 系统：

$$A = \begin{pmatrix} -1 & 0 \\ 0 & -3 \end{pmatrix}, \quad B = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad C = (1 \quad 2).$$

- 计算 $(sI - A)^{-1}$ ，写出 $G(s) = C(sI - A)^{-1}B$ 并化简为有理分式；
- 找出极点和零点，验证极点与 A 的特征值一致；
- 当 $\omega \rightarrow \infty$ 时， $|G(j\omega)|$ 如何衰减？用一句话说明其低通滤波物理含义。

解答 T-7.1.2

(a)

$$sI - A = \begin{pmatrix} s+1 & 0 \\ 0 & s+3 \end{pmatrix}, \quad (sI - A)^{-1} = \begin{pmatrix} \frac{1}{s+1} & 0 \\ 0 & \frac{1}{s+3} \end{pmatrix}.$$

$$G(s) = \frac{1}{s+1} + \frac{2}{s+3} = \frac{(s+3) + 2(s+1)}{(s+1)(s+3)} = \frac{3s+5}{s^2+4s+3}.$$

(b) 极点: $s = -1, s = -3$, 正好是 A 的特征值 $\lambda_1 = -1, \lambda_2 = -3$ 。零点: $3s + 5 = 0 \Rightarrow s = -5/3 \approx -1.667$ 。

(c) 分子次数 1, 分母次数 2, 故 $|G(j\omega)| \sim 1/\omega \rightarrow 0$ (-20 dB/dec)。物理含义: 系统是低通滤波器, 高频快速振荡输入无法传递到输出, 仅保留低频(慢变)历史信息——这正是 HiPPO 矩阵设计的信号处理基础。

T-7.1.3【难·判错·稳定性误判】 甲同学说: “只要状态矩阵 A 的所有元素均为负数, LTI 系统就渐近稳定。”

(a) 用以下矩阵构造一个反例证明甲同学错误:

$$A = \begin{pmatrix} -1 & 2 \\ 0 & 1 \end{pmatrix}$$

(计算特征值, 指出哪里违反了稳定性条件);

(b) 写出正确的渐近稳定充要条件 (用特征值语言表达);

(c) 说明为什么 HiPPO-LegS 矩阵 (对角元全为 $-(n+1)$, $n \geq 0$) 满足此条件。

解答 T-7.1.3

(a) 反例: $A = \begin{pmatrix} -1 & 2 \\ 0 & 1 \end{pmatrix}$ 。特征多项式: $\det(\lambda I - A) = (\lambda + 1)(\lambda - 1) = \lambda^2 - 1 = 0$, 特征值 $\lambda = \pm 1$ 。 $\lambda = 1$ 实部为正, 系统不稳定, 尽管 A 有负元素。(b) 正确的充要条件: A 的所有特征值实部均严格小于 0 (即所有特征值位于左半复平面 $\text{Re}(\lambda_i) < 0$)。

(c) HiPPO-LegS 的对角元全为 $-(n+1) \leq -1$, 严格负数。对角元就是矩阵对角化后的主要特征值; 下三角项可以用 Gershgorin 圆盘定理或 DPLR 分解精确证明特征值全在左半平面。直觉上, 每个 Legendre 系数都在以速率 $(n+1)/t$ 自然衰减, 越高阶系数衰减越快, 状态有界演化。

工程批注: T-7.1.3 揭示了深度学习中的一个常见陷阱: 矩阵元素为负 $\neq$ 矩阵稳定。在实现 S4/Mamba 时, 若用错初始化 (如用某些随机矩阵而非 HiPPO 初始化), 可能得到不稳定系统导致训练发散。S4D 直接用对角矩阵 A 回避

了此问题——对角矩阵的特征值就是对角元本身，只需约束对角元为负实部即可保证稳定，在 PyTorch 中常用 `softplus` 或直接约束为负数参数化。

公式 2 · 闭式解（矩阵指数卷积）

$$h(t) = e^{At}h(0) + \int_0^t e^{A(t-s)}Bx(s)ds$$

一句话直觉：积分因子法的产物——初始状态按 e^{At} 自由演化，历史输入的影响通过卷积叠加。

在大模型里的位置：架构（模型结构 / 算子设计 / 表示空间）

本组训练目标：证明 · 变形

常见卡点：

- 积分因子是左乘 e^{-At} ，展开时用 $\frac{d}{dt}(e^{-At}h(t)) = e^{-At}(h'(t) - Ah(t))$
- 初始时刻的边界条件 $h(0)$ 对应 $e^{At}h(0)$ 项，零初始态才退化为纯卷积
- $e^{A(t-s)}$ 中 $(t-s)$ 是时间差，不是分开的两项

本组在练什么：从 ODE 推导闭式解，再把闭式解折叠为卷积视角。做完应能回答：卷积核 $K(t)$ 是什么，它由哪些参数决定？

T-7.1.4 【中 · 证明 · 积分因子推导闭式解】 从 $h'(t) = Ah(t) + Bx(t)$ 出发：

- 将方程改写为 $h'(t) - Ah(t) = Bx(t)$ ，左乘积分因子 e^{-At} ，展开 $\frac{d}{dt}(e^{-At}h(t))$ ，写出每一步；
- 在 $[0, t]$ 上积分，利用 $h(0)$ 给出闭式解；
- 设 $h(0) = 0$ ，代入 $y(t) = Ch(t)$ ，识别卷积结构，写出卷积核 $K(\tau) = Ce^{A\tau}B$ 。

解答 T-7.1.4

- 将 ODE 改写： $h'(t) - Ah(t) = Bx(t)$ 。左乘 e^{-At} ：

$$\frac{d}{dt}(e^{-At}h(t)) = e^{-At}h'(t) - Ae^{-At}h(t) = e^{-At}Bx(t).$$

- 在 $[0, t]$ 上积分：

$$e^{-At}h(t) - h(0) = \int_0^t e^{-As}Bx(s)ds.$$

两边左乘 e^{At} ：

$$h(t) = e^{At}h(0) + \int_0^t e^{A(t-s)}Bx(s)ds. \quad \square$$

(c) 令 $h(0) = 0$, 代入 $y(t) = Ch(t)$:

$$y(t) = \int_0^t \underbrace{Ce^{A(t-s)}B}_{K(t-s)} x(s) ds, \quad K(\tau) = Ce^{A\tau}B. \quad \square$$

T-7.1.5 【易 · 代入 · 画图直觉 · SSM 脉冲响应】 设 $N = 1$, $A = -1$, $B = 1$, $C = 1$, 输入为单位脉冲 $x(t) = \delta(t)$ (即 $h(0) = 0$, $x(t) = 0$ 对 $t > 0$, 但 $B\delta(t)$ 在 $t = 0$ 注入初始状态 $h(0^+) = B = 1$)。

- 写出 $t > 0$ 时的状态 $h(t)$ 和输出 $y(t)$ 的表达式;
- 在草稿区粗略画出 $y(t)$ 随时间 $t \in [0, 3]$ 的变化曲线 (指数衰减形状), 标注 $t = 0, 1, 2, 3$ 处的数值;
- 若把 A 从 -1 改为 -0.1 (衰减更慢), 曲线形状会怎么变? 从「系统对历史输入的记忆长度」角度解释。

解答 T-7.1.5

(a) 脉冲输入在 $t = 0^+$ 注入 $h(0^+) = B = 1$, 之后 $x(t) = 0$, 故满足齐次方程:

$$h(t) = e^{At}h(0^+) = e^{-t} \cdot 1 = e^{-t}, \quad y(t) = Ch(t) = e^{-t}.$$

- 草图: 指数衰减曲线, 从 $(0, 1)$ 经过 $(1, e^{-1} \approx 0.368)$, $(2, e^{-2} \approx 0.135)$, $(3, e^{-3} \approx 0.050)$, 单调趋零, 无振荡。
- 若 $A = -0.1$ (衰减变慢), $y(t) = e^{-0.1t}$, 曲线从同一起点出发但「更平」, 在 $t = 10$ 时仍有 $e^{-1} \approx 0.368$ 。物理含义: 系统对历史输入的记忆时间常数是 $1/|A|$; $A = -0.1$ 时时间常数为 10, 远长于 $A = -1$ 的时间常数 1。HiPPO 矩阵的设计目标正是选择合适的 A , 使系统在固定维度内尽量长地「记住」历史。

公式 3 · 卷积核与卷积视角

$$y(t) = (K * x)(t) = \int_0^t K(t-s)x(s) ds, \quad K(t) = Ce^{At}B$$

一句话直觉: 零初始态下, 输出是输入与卷积核的卷积——卷积核由 A, B, C 唯一确定。

在大模型里的位置: 架构 (模型结构 / 算子设计 / 表示空间)

本组训练目标: 代入 · 变形 · 工程

常见卡点:

- 卷积是对 s 积分, $K(t-s)$ 是「时差 $t-s$ 」时刻的核值, 不是 $K(t)K(s)$
- 离散化后核变为 $\bar{K}_k = \bar{C}\bar{A}^k\bar{B}$, 是 $\bar{A}$ 的幂次, 而非矩阵指数
- FFT 计算卷积的前提是 LTI (核不依赖时间), 选择性 SSM 破坏了这一前提

本组在练什么：从连续卷积核推到离散卷积核，理解 S4 高效训练的卷积结构。做完应能回答：为什么 LTI 假设使训练复杂度降为 $O(L \log L)$ ？

T-7.1.6 【中 · 变形 · 离散卷积核递推展开】 设离散 SSM 参数 $\bar{A} \in \mathbb{R}^{N \times N}$, $\bar{B} \in \mathbb{R}^{N \times 1}$, $\bar{C} \in \mathbb{R}^{1 \times N}$, 递推 $h_k = \bar{A}h_{k-1} + \bar{B}x_k$, $y_k = \bar{C}h_k$, $h_0 = 0$ 。

- 展开 h_1, h_2, h_3 关于 x_1, x_2, x_3 的表达式；
- 写出 $y_k = \sum_{j=0}^{k-1} \bar{K}_j x_{k-j}$ 中卷积核元素 $\bar{K}_j$ 的一般公式；
- 对 $N = 1$, $\bar{A} = 0.9$, $\bar{B} = 1$, $\bar{C} = 1$, 计算 $\bar{K}_0, \bar{K}_1, \bar{K}_2, \bar{K}_3$ 并说明「指数衰减」的物理含义。

解答 T-7.1.6

- 递推展开 ($h_0 = 0$):

$$h_1 = \bar{B}x_1; \quad h_2 = \bar{A}\bar{B}x_1 + \bar{B}x_2; \quad h_3 = \bar{A}^2\bar{B}x_1 + \bar{A}\bar{B}x_2 + \bar{B}x_3.$$

- 一般公式: $\bar{K}_j = \bar{C}\bar{A}^j\bar{B}$ ($j = 0, 1, 2, \dots$)。

- 代入 $\bar{A} = 0.9$, $\bar{B} = 1$, $\bar{C} = 1$:

$$\bar{K}_0 = 1, \quad \bar{K}_1 = 0.9, \quad \bar{K}_2 = 0.81, \quad \bar{K}_3 = 0.729.$$

$\bar{K}_j = 0.9^j$, 指数衰减。物理含义：更远的历史输入 x_{k-j} 对当前输出的贡献越来越小，体现了「有限记忆」—— $\bar{A} < 1$ 的稳定系统必然产生指数衰减的卷积核。

T-7.1.7 【难 · 工程 · DPLR 的必要性与复杂度】 设 $A \in \mathbb{R}^{N \times N}$, 序列长度 L 。

- 若直接逐步计算 $\bar{K}_k = \bar{C}\bar{A}^k\bar{B}$ (每步 $O(N^2)$)，写出总复杂度；对 $N = L = 4096$ 估计操作数量级；
- 若 $A = \Lambda$ (对角)，证明 $\bar{K}_k = \sum_{i=1}^N c_i \bar{\lambda}_i^k$ (指数多项式)，并解释如何用 FFT 在 $\tilde{O}(N + L)$ 内算出全部核元素；
- HiPPO-LegS 非对角，S4 用 DPLR ($A = \Lambda - PQ^*$) 参数化。写出 Woodbury 恒等式展开 $(zI - \bar{A})^{-1}$ 的公式，说明为什么它把复杂度降回对角情形的量级。

解答 T-7.1.7

- 每步 $\bar{K}_k = \bar{C}\bar{A}^k\bar{B}$ 需 1 次 $N \times N$ 矩阵-向量乘 $O(N^2)$, L 步总计 $O(N^2L)$ 。对 $N = L = 4096$, 约 $4096^2 \times 4096 \approx 6.9 \times 10^{10}$ 次浮点运算，不可接受 (现代 GPU 每秒约 10^{14} FLOP, 但显存带宽不够)。
- 对角矩阵 $\bar{A} = \text{diag}(\bar{\lambda}_1, \dots, \bar{\lambda}_N)$, $\bar{A}^k = \text{diag}(\bar{\lambda}_1^k, \dots, \bar{\lambda}_N^k)$, 故

$$\bar{K}_k = \bar{C} \bar{A}^k \bar{B} = \sum_{i=1}^N \underbrace{c_i}_{=\bar{C}_{:,i}} \bar{\lambda}_i^k.$$

生成函数 $\hat{K}(z) = \sum_{k=0}^{L-1} \bar{K}_k z^k$ 在 L 个单位根 ω^l (FFT 点) 处求值:

$$\hat{K}(\omega^l) = \sum_{i=1}^N \frac{c_i}{1 - \bar{\lambda}_i \omega^l},$$

即 Cauchy 矩阵-向量积, 再用 FFT 类算法降至 $\tilde{O}(N+L)$, 逆 FFT 恢复时域核。

(c) Woodbury 恒等式 (设 $M = zI - \bar{\Lambda}$ 为对角矩阵):

$$(zI - \bar{A})^{-1} = (zI - \bar{\Lambda} + PQ^*)^{-1} = M^{-1} + M^{-1}P(I - Q^*M^{-1}P)^{-1}Q^*M^{-1}.$$

所有操作在对角矩阵 M^{-1} 和低秩矩阵 P, Q 上, 代价 $O(N+r^3)$, 把一般 $N \times N$ 矩阵逆的 $O(N^3)$ 降到线性量级。

工程批注: T-7.1.7 是 S4 工作的核心贡献之一。工程实践中, S4D (Diagonal S4, Gu et al. NeurIPS 2022) 直接把 DPLR 中的 P, Q 设为零, 用纯对角矩阵 $A = \Lambda$, 代码量从数百行降到十几行, 且性能与原 S4 相当。在 PyTorch 中实现时, 对角矩阵的矩阵指数就是逐元素指数 `torch.exp(Delta * Lambda)`, 整个 ZOH 离散化是一行代码, 这正是 S4D 在工程中被广泛使用的原因。

【做完自检】

1. 给定 $A = -2, B = 1, C = 3$, 闭式解的卷积核 $K(t)$ 是什么? 当 $t \rightarrow \infty$ 时它趋向何处?
2. LTI 系统渐近稳定的充要条件是什么? 判断 $A = \begin{pmatrix} -1 & 2 \\ 0 & 1 \end{pmatrix}$ 是否稳定。
3. 为什么 DPLR 参数化能把 S4 的训练复杂度从 $O(N^2L)$ 降至 $\tilde{O}(N+L)$? 关键代数工具是什么?

§ 7.2 记忆的正交性: HiPPO 如何选择基函数

§ 7.2 的核心论证链: 选定测度 $\rightarrow$ 正交多项式基 $\rightarrow$ 对系数 $h_n(t)$ 关于 t 求导 (莱布尼茨法则) $\rightarrow$ 整理出矩阵方程 $\rightarrow$ 矩阵元素就是 HiPPO 矩阵。全节最难的一步是「对时变积分求导并用勒让德导数展开整理系数」, 走通这一步之后, HiPPO 矩阵就不再是神秘的数字, 而是正交多项式的代数结构。

小节导读 · 公式从哪里来

HiPPO 矩阵是怎么「推出来」的? 问题是: 用一个 N 维状态 $h(t)$ 记住输入历史 $u(\tau), \tau \leq t$ 。应该记什么? 「在某个加权意义下, $h(t)$ 能重建 u 的最佳 N 项近似。」这是一个函数逼近问题。

第一步：选定测度。加权 $\mu(\tau)d\tau$ 决定「哪部分历史要记准」。LegT 采用均匀测度重视最近窗口，LegS 采用缩放测度重视所有历史。

第二步：选正交多项式基。在该测度下取勒让德/拉盖尔正交多项式 $\{P_n\}$ ，记 $h_n(t) = \langle u, P_n \rangle_\mu$ 为投影系数。「记住历史」=「保持 $\{h_n\}_{n=0}^{N-1}$ 」。

第三步：对时间求导。 $\dot{h}_n(t) = \frac{d}{dt} \int u(\tau) P_n(\tau, t) \mu(\tau, t) d\tau$ 。莱布尼茨法则展开三项：上下限项、被积函数对时间偏导、测度本身偏导。

第四步：代入正交多项式递推关系。勒让德多项式 P'_n 可用 $P_0, \dots, P_{n-1}$ 线性表示。整理后得 $\dot{h} = Ah + Bu$ ，其中 A 是「多项式递推关系」的矩阵表示——这就是 HiPPO 矩阵 A_{ij} 。

第五步：LegS 为何会带 $1/t$ 项。缩放测度下 $\mu(\tau, t) = \mathbf{1}_{[0,t]}/t$ ，对 t 偏导会产生 $-1/t$ 项。这导致 A 中出现 $-n/t$ 对角项——「全历史记忆」随时间缩放的代价。

本节要拿走的一件事：HiPPO 矩阵不是拼凑出来的数字，而是「最佳 N 项逼近」的多项式递推代数结果；测度决定记忆风格。

公式 4 · Legendre 多项式正交性

$$\int_{-1}^1 P_n(x) P_m(x) dx = \frac{2}{2n+1} \delta_{nm}$$

归一化基 $\tilde{P}_n(x) = \sqrt{\frac{2n+1}{2}} P_n(x)$ ，满足 $\int_{-1}^1 \tilde{P}_n \tilde{P}_m dx = \delta_{nm}$ 。

一句话直觉：正交性是「每个基函数正交于其他所有基函数」，是最优投影系数公式的数学基础。

在大模型里的位置：架构（模型结构 / 算子设计 / 表示空间）

本组训练目标：代入 · 证明

常见卡点：

- $\|P_n\|^2 = \frac{2}{2n+1}$ ，不是 1；归一化后才是单位范数
- 奇函数 $\times$ 偶函数在对称区间 $[-1, 1]$ 上积分为 0——利用此性质可快速验证正交
- $\tilde{P}_n$ 在 $[0, t]$ 上使用时要做变量替换 $u = s/t$

本组在练什么：Legendre 多项式的正交性验证和归一化。做完应能回答：为什么 HiPPO 矩阵里出现 $\sqrt{2n+1}$ 这个系数？

T-7.2.1 【易 · 代入 · 正交性验证】 给定 $P_0(x) = 1$ ， $P_1(x) = x$ ， $P_2(x) = \frac{1}{2}(3x^2 - 1)$ 。

- 利用正交性公式直接写出 $\|P_0\|^2$ ， $\|P_1\|^2$ ， $\|P_2\|^2$ 的值（不需要积分）；
- 手动计算 $\int_{-1}^1 P_1(x) P_2(x) dx$ ，用奇偶性验证结果为 0；
- 写出 $\tilde{P}_0, \tilde{P}_1, \tilde{P}_2$ 的表达式，并验证 $\|\tilde{P}_0\|^2 = \|\tilde{P}_1\|^2 = \|\tilde{P}_2\|^2 = 1$ 。

解答 T-7.2.1

(a) 由 $\|P_n\|^2 = \frac{2}{2n+1}$: $\|P_0\|^2 = 2$, $\|P_1\|^2 = \frac{2}{3}$, $\|P_2\|^2 = \frac{2}{5}$ 。

(b) $\int_{-1}^1 P_1(x)P_2(x) dx = \int_{-1}^1 x \cdot \frac{1}{2}(3x^2 - 1) dx = \frac{1}{2} \int_{-1}^1 (3x^3 - x) dx$ 。

被积函数是奇函数，在对称区间 $[-1, 1]$ 上积分为 0。□

(c)

$$\tilde{P}_0 = \frac{1}{\sqrt{2}}, \quad \tilde{P}_1 = \sqrt{\frac{3}{2}}x, \quad \tilde{P}_2 = \sqrt{\frac{5}{2}} \cdot \frac{1}{2}(3x^2 - 1).$$

验证: $\|\tilde{P}_n\|^2 = \frac{2n+1}{2} \cdot \|P_n\|^2 = \frac{2n+1}{2} \cdot \frac{2}{2n+1} = 1$ 。□

T-7.2.2 【易 · 代入 · LegS 矩阵 N=3 情形】 利用 HiPPO-LegS 矩阵公式，写出 $N = 3$ （行列下标 $n, k \in \{0, 1, 2\}$ ）时的显式矩阵 A_{LegS} 和向量 B_{LegS} （保留精确根号形式）。验证对角元、下三角元、上三角元分别对应公式的哪一支。

解答 T-7.2.2 行列下标 $n, k \in \{0, 1, 2\}$ ，代入公式：

$$A_{\text{LegS}} = - \begin{pmatrix} 1 & 0 & 0 \\ \sqrt{3} & 2 & 0 \\ \sqrt{5} & \sqrt{15} & 3 \end{pmatrix}, \quad B_{\text{LegS}} = \begin{pmatrix} 1 \\ \sqrt{3} \\ \sqrt{5} \end{pmatrix}.$$

验证：对角元 $-(n+1): -1, -2, -3$ ；下三角元 $-\sqrt{(2n+1)(2k+1)}: -\sqrt{3}, -\sqrt{5}, -\sqrt{15}$ ；上三角元全为 0。□

公式 5 · HiPPO-LegS 矩阵

$$(A_{\text{LegS}})_{nk} = \begin{cases} -\sqrt{(2n+1)(2k+1)} & n > k \\ -(n+1) & n = k \\ 0 & n < k \end{cases}, \quad (B_{\text{LegS}})_n = \sqrt{2n+1}$$

一句话直觉：在 $[0, t]$ 均匀测度下，令 Legendre 系数最优压缩历史信号所必须满足的状态矩阵。

在大模型里的位置：架构（模型结构 / 算子设计 / 表示空间）

本组训练目标：证明 · 反例 · 判错

常见卡点：

- 矩阵是严格下三角——上三角全零对应「全局历史均匀压缩，不存在窗口弹出效应」

- $B_n = \sqrt{2n+1}$ 来自 $\tilde{P}_n(1) = \sqrt{2n+1}P_n(1) = \sqrt{2n+1}$ (Legendre 多项式在端点的值)
- LegT 矩阵上三角非零——那是滑动窗口弹出旧信息的数学体现

本组在练什么：手推 HiPPO 矩阵一行，感受莱布尼茨法则 + 勒让德导数展开如何产生矩阵元素。做完应能回答： $A_{2,1} = -\sqrt{15}$ 这个数字从哪里来？

T-7.2.3 【难 · 证明 · 推导 LegS 矩阵第 n=2 行】 推导 A_{LegS} 的 $n=2$ 行（下标从 0 起）。设 $\tilde{P}_2(u) = \sqrt{5} \cdot \frac{1}{2}(3(2u-1)^2 - 1)$ 。

- 写出 $h_2(t) = \frac{1}{t} \int_0^t \tilde{P}_2(s/t)x(s) ds$ 的形式；
- 对 $h_2(t)$ 用莱布尼茨法则关于 t 求导，分离出边界项（含 $x(t)$ ）和积分项；
- 利用 $\tilde{P}'_2(u) = 2\sqrt{5} \cdot \sqrt{3}\tilde{P}_1(u)$ （仅 $k=1$ 贡献， $2-k=1$ 为奇），整理积分项为 h_0, h_1, h_2 的线性组合；
- 读出 $A_{2,0}, A_{2,1}, A_{2,2}$ 和 B_2 ，验证与矩阵公式一致。

解答 T-7.2.3

- $h_2(t) = \frac{1}{t} \int_0^t \tilde{P}_2(s/t)x(s) ds$ ，其中 $\tilde{P}_2(u) = \sqrt{5}(6u^2 - 6u + 1)$ （代入 $u = s/t$ 后展开 $\frac{1}{2}(3(2u-1)^2 - 1)$ ）。
- 莱布尼茨法则求导：

$$h'_2(t) = -\frac{1}{t^2} \int_0^t \tilde{P}_2(s/t)x(s) ds + \frac{1}{t} \tilde{P}_2(1) \cdot x(t) - \frac{1}{t^2} \int_0^t \frac{s}{t} \tilde{P}'_2(s/t)x(s) ds.$$

第一项 $= -\frac{1}{t} h_2(t)$ ；边界项： $\tilde{P}_2(1) = \sqrt{5}(6-6+1) = \sqrt{5}$ ，贡献 $\frac{\sqrt{5}}{t}x(t)$ ，即 $B_2 = \sqrt{5}$ 。
□

- 利用 $\tilde{P}'_2(u) = 2\sqrt{5} \cdot \sqrt{3}\tilde{P}_1(u)$ （仅 $k=1$ 满足 $2-k=1$ 为奇），第三项整理为：

$$-\frac{1}{t^2} \int_0^t \frac{s}{t} \cdot 2\sqrt{15}\tilde{P}_1(s/t)x(s) ds = -\frac{2\sqrt{15}}{t} \cdot h_1(t).$$

又第一项和第三项中含 h_2 的部分合并： $-\frac{1}{t}h_2$ （第一项）和第三项整理后额外的 $-\frac{2}{t}h_2$ 合并得 $-\frac{3}{t}h_2$ （对角元 $A_{2,2} = -3$ ）。

对 $h_0(t)$ 的贡献： $A_{2,0} = -\sqrt{5}$ 直接来自 h_2 对 h_0 的耦合（通过时间变换 $\tau = \log t$ 化为标准 LTI 后完整推导）。

- 汇总：

$$A_{2,0} = -\sqrt{5}, \quad A_{2,1} = -\sqrt{15}, \quad A_{2,2} = -3, \quad B_2 = \sqrt{5}.$$

与矩阵公式一致： $-\sqrt{(2 \cdot 2 + 1)(2 \cdot 0 + 1)} = -\sqrt{5}$, $-\sqrt{(5)(3)} = -\sqrt{15}$, $-(2+1) = -3$, $\sqrt{2 \cdot 2 + 1} = \sqrt{5}$ 。

工程批注：T-7.2.3 的推导过程揭示了 HiPPO 的精妙之处：Legendre 多项式的递推关系和导数展开公式，把对时变积分的微分自动转化为矩阵代数。工程中，Gu et al. “How to Train Your HiPPO” (ICLR 2023) 表明，LegS 矩阵更多起到「良好初始化」的作用，实际训练后 A 矩阵会偏离 LegS 结构——理论最优性与任务最优性之间仍有差距。S4D 直接放弃 HiPPO 初始化，用随机初始化的对角矩阵，在实践中表现更好。

T-7.2.4 【中 · 变形 · LegT 与 LegS 对比】 HiPPO-LegT (窗口 $\theta = 1$) 矩阵的上三角元为 $-(-1)^{n-k}\sqrt{(2n+1)(2k+1)}$ ($n < k$)，下三角元与 LegS 相同，对角元为 $-(2n+1)$ 。

- 写出 $N = 3$ 时的 A_{LegT} (精确根号形式)；
- 对比 A_{LegT} 和 A_{LegS} 的结构：上三角项为何在 LegT 中非零？用「滑动窗口 vs. 全历史」的测度差异解释；
- 判错：乙同学说「LegT 的记忆更长，因为它连上三角也有非零元」。指出这句话的错误，说明上三角非零的实际含义（窗口弹出）。

解答 T-7.2.4

(a) $N = 3$ 时 A_{LegT} ($\theta = 1$):

对角元 ($n = k$): $-(2n+1)$, 即 $-1, -3, -5$ 。

下三角 ($n > k$): 与 LegS 相同 $-\sqrt{(2n+1)(2k+1)}$ 。

上三角 ($n < k$): $-(-1)^{n-k}\sqrt{(2n+1)(2k+1)}$ 。

$$A_{\text{LegT}} = - \begin{pmatrix} 1 & -\sqrt{3} & \sqrt{5} \\ \sqrt{3} & 3 & -\sqrt{15} \\ \sqrt{5} & \sqrt{15} & 5 \end{pmatrix}.$$

- 结构差异的物理含义：LegT 使用滑动窗口测度（最近 θ 时间），窗口边界处旧 token「弹出」、新 token 进入。上三角反号代表「弹出效应」——旧 token 离开窗口时对高阶系数的修正（符号交替反映了勒让德多项式在边界的值）。LegS 使用全历史均匀测度，测度随 t 整体缩放，没有弹出机制，故上三角全零。
- 判错：乙同学的说法错误。上三角非零不代表记忆更长，恰恰相反——LegT 的非零上三角元体现的是遗忘机制（窗口之外的信息被弹出），LegT 的记忆长度被限制在窗口 θ 内，比 LegS 的全历史压缩更短。

T-7.2.5 【中 · 工程 · 最优投影的几何意义与近似误差】 设 $\hat{x}_t(s) = \sum_{n=0}^{N-1} h_n(t) \tilde{P}_n(s/t)$ 是 $x|_{[0,t]}$ 的 N 阶近似。

- 用 Hilbert 空间正交投影定理一句话解释：为什么 $\hat{x}_t$ 是 $L^2([0,t], ds/t)$ 中距 x 最近的 N 阶多项式？
- 若 $x(s) = s^2$, $t = 1$, $N = 3$, 重构误差为 0 吗？说明原因 ($P_2(2u-1)$ 是几次多项式?)；

(c) 若改为 $x(s) = s^3$, $N = 3$, 是否有误差? 误差来自哪一阶 Legendre 系数?

解答 T-7.2.5

- (a) $\hat{x}_t = \text{proj}_{\mathcal{P}_{N-1}}(x)$ 是 x 在子空间 $\mathcal{P}_{N-1}$ 上的正交投影。由 Hilbert 空间基本定理, 正交投影是子空间内的最近点, 故 $\|\hat{x}_t - x\| \leq \|p - x\|$ 对所有 $p \in \mathcal{P}_{N-1}$ 成立。
- (b) $x(s) = s^2 = u^2$ ($u = s/t = s$)。基函数 $\tilde{P}_0, \tilde{P}_1, \tilde{P}_2$ 张成所有次数 ≤ 2 的多项式 (因为 $\tilde{P}_2$ 是 u^2 的线性组合)。 u^2 本身在 $\mathcal{P}_2$ 中, 重构误差为 0。
- (c) $x(s) = s^3$ 是 3 次多项式, $\mathcal{P}_2$ 只能精确表示 ≤ 2 次的多项式, 存在重构误差。误差来自 $\tilde{P}_3$ 方向 (即 $h_3(t)\tilde{P}_3(u)$), 大小等于 $h_3(t)^2$ (u^3 在 $\tilde{P}_3$ 上的投影系数的平方)。

【做完自检】

- HiPPO-LegS 矩阵的上三角为何全零, 而 LegT 的上三角非零? 各自对应什么测度和物理含义?
- $B_n = \sqrt{2n+1}$ 这个系数是怎么来的? (提示: Legendre 多项式在端点 1 处的值)
- HiPPO 的「最优性」是绝对的吗? 若换一种测度, 最优矩阵会变吗? 举例说明。

§ 7.3 S4/Mamba 离散化与选择性 SSM

从连续 ODE 出发, 经零阶保持 (ZOH) 离散化得到 $\bar{A} = e^{A\Delta}$ 的递推, 再展开为卷积, 最后进入 Mamba 的选择性机制——让 Δ_t 依赖输入, 打破 LTI 限制。并行扫描是让选择性 SSM 能在 GPU 上高效训练的关键算法, 其核心是结合律。

小节导读 · 公式从哪里来

为什么要 ZOH 离散化? 连续 ODE 不能直接跑在计算机上, 必须取采样点 $t_k = k\Delta$ 。「零阶保持」假设: 采样间 $u(\tau)$ 是常数, 这让子区间积分有闭式解。

第一步: 代闭式解。从 $h(t_{k+1}) = e^{A\Delta}h(t_k) + \int_{t_k}^{t_{k+1}} e^{A(t_{k+1}-\tau)}Bu(\tau)d\tau$, ZOH 下 $u(\tau) = u_k$, 积分出 $h_{k+1} = \bar{A}h_k + \bar{B}u_k$, $\bar{A} = e^{A\Delta}$ 、 $\bar{B} = A^{-1}(e^{A\Delta} - I)B$ 。

第二步: 递推 vs 卷积二面性。递推同 RNN 一样 $O(L)$; 展开为 $h_k = \sum_{j \leq k} \bar{A}^{k-j}\bar{B}u_j$, 即一次卷积。训练时用卷积走 FFT $O(L \log L)$, 推理时用递推走 $O(L)$ 。

第三步: S4 为何限 LTI。上述方法要求 A, B, C, Δ 与输入无关, 是线性时不变。这限制了「选择性」: 不能根据输入的重要度调整记忆。

第四步: Mamba 怎么打破 LTI。让 Δ_t, B_t, C_t 依赖输入 u_t , 进入 LTV 领域。 $\bar{A}_t = e^{A\Delta_t}$ 随 t 变。代价是不能再走 FFT 卷积, 但能走「并行扫描」: 利用连续乘积的结合律实现 $O(L \log L)$ 并行。

第五步: 选择性为什么重要。 $\Delta_t \rightarrow 0$ 时状态保持不变 (「不记该 token」); $\Delta_t \rightarrow \infty$ 时状态重置 (「重起记忆」)。这为语言建模提供了「选择性记忆」, 与 Transformer 的 attention 选择性遥相呼应。

本节要拿走的一件事: ZOH 是从连续到离散的主流桥梁; Mamba 打破 LTI 后重获选择

性，并行扫描借助结合律为它提供了训练效率。

公式 6 · ZOH 离散化

$$\bar{A} = e^{\Delta A}, \quad \bar{B} = (\Delta A)^{-1}(e^{\Delta A} - I) \cdot \Delta B, \quad \bar{C} = C$$

一句话直觉：零阶保持假设区间内输入为常数，对连续 ODE 精确积分，得到离散递推的「遗忘率」矩阵 $\bar{A} = e^{\Delta A}$ 。

在大模型里的位置：架构（模型结构 / 算子设计 / 表示空间）

本组训练目标：代入 · 证明 · 变形

常见卡点：

- ZOH 是「精确」离散化（对区间内常数输入），不是近似；双线性（Tustin）才是二阶近似
- $\bar{B}$ 的公式来自 $\int_0^\Delta e^{A\tau} d\tau = A^{-1}(e^{A\Delta} - I)$ ，注意 A 在左边
- Mamba 中 Δ_t 依赖输入，所以每步的 $\bar{A}_t, \bar{B}_t$ 不同——这破坏了 LTI 假设

本组在练什么：从连续闭式解推 ZOH 离散化，比较 ZOH 与双线性的差异。做完应能回答：ZOH 和双线性在小步长下精度是否相同？各有什么优势？

T-7.3.1 【易 · 代入 · ZOH 与双线性标量对比】 设 $N = 1$, $A = a$ （标量），步长 Δ 。

- 写出标量 ZOH 的 $\bar{A}_{\text{ZOH}} = e^{\Delta a}$ 和双线性 $\bar{A}_{\text{bilinear}} = \frac{1 + \frac{\Delta}{2}a}{1 - \frac{\Delta}{2}a}$;
- 代入 $a = -2, \Delta = 0.5$ ，计算两种方法的 $\bar{A}$ 值，并计算相对误差（百分比）；
- 对 $\Delta \rightarrow 0$ ，证明双线性变换的一阶展开 $\bar{A}_{\text{bilinear}} \approx 1 + \Delta a$ ，与 ZOH 的一阶展开一致。

解答 T-7.3.1

(a) ZOH: $\bar{A}_{\text{ZOH}} = e^{\Delta a}$; 双线性: $\bar{A}_{\text{bilinear}} = \frac{1 + \frac{\Delta}{2}a}{1 - \frac{\Delta}{2}a}$ 。

(b) 代入 $a = -2, \Delta = 0.5$:

$$\bar{A}_{\text{ZOH}} = e^{-1} \approx 0.3679; \quad \bar{A}_{\text{bilinear}} = \frac{1 + 0.5 \cdot (-1)}{1 - 0.5 \cdot (-1)} = \frac{0.5}{1.5} = \frac{1}{3} \approx 0.3333.$$

相对误差: $\frac{0.3679 - 0.3333}{0.3679} \approx 9.4\%$ （步长 $\Delta = 0.5$ 不算小，差异显著）。

(c) 双线性一阶展开 ($\Delta \rightarrow 0$):

$$\bar{A}_{\text{bilinear}} = \frac{1 + \frac{\Delta}{2}a}{1 - \frac{\Delta}{2}a} \approx \left(1 + \frac{\Delta}{2}a\right) \left(1 + \frac{\Delta}{2}a\right) \approx 1 + \Delta a + O(\Delta^2).$$

ZOH 展开: $e^{\Delta a} \approx 1 + \Delta a + O(\Delta^2)$ 。两者 $O(\Delta)$ 精度相同。□

T-7.3.2 【中 · 证明 · ZOH 推导与矩阵指数积分】 从连续闭式解出发, 在区间 $[k\Delta, (k+1)\Delta]$ 上推导 ZOH 离散化。

- 写出 $h((k+1)\Delta)$ 的闭式解 (利用公式 2);
- 在 ZOH 假设 $x(s) = x_{k+1}$ 为常数时, 令 $\tau = (k+1)\Delta - s$ 换元, 计算 $\int_0^\Delta e^{A\tau} d\tau = A^{-1}(e^{A\Delta} - I)$;
- 得出 $\bar{A} = e^{\Delta A}$, $\bar{B} = A^{-1}(e^{\Delta A} - I)B$, 并对 $A = \text{diag}(-1, -2)$, $B = (1, 1)^\top$, $\Delta = 0.1$ 数值计算 $\bar{A}$ 和 $\bar{B}$ (保留 4 位小数)。

解答 T-7.3.2

$$(a) \quad h((k+1)\Delta) = e^{A\Delta}h(k\Delta) + \int_{k\Delta}^{(k+1)\Delta} e^{A((k+1)\Delta-s)} Bx(s) ds.$$

(b) ZOH 假设 $x(s) = x_{k+1}$ 为常数, 令 $\tau = (k+1)\Delta - s$:

$$\int_{k\Delta}^{(k+1)\Delta} e^{A((k+1)\Delta-s)} B ds = \left(\int_0^\Delta e^{A\tau} d\tau \right) B = A^{-1}(e^{A\Delta} - I)B.$$

故 $\bar{A} = e^{\Delta A}$, $\bar{B} = A^{-1}(e^{\Delta A} - I)B$ 。□

(c) 代入 $A = \text{diag}(-1, -2)$, $B = (1, 1)^\top$, $\Delta = 0.1$:

$$\bar{A} = \text{diag}(e^{-0.1}, e^{-0.2}) \approx \begin{pmatrix} 0.9048 & 0 \\ 0 & 0.8187 \end{pmatrix}.$$

$$A^{-1} = \text{diag}(-1, -1/2), \quad \bar{B} = \begin{pmatrix} -(e^{-0.1} - 1) \\ -\frac{1}{2}(e^{-0.2} - 1) \end{pmatrix} \approx \begin{pmatrix} 0.0952 \\ 0.0907 \end{pmatrix}.$$

T-7.3.3 【难 · 判错 · 离散化误用】 丙同学在实现 Mamba 时, 误将双线性离散化 $\bar{A} = (I - \frac{\Delta}{2}A)^{-1} (I + \frac{\Delta}{2}A)$ 应用到 Mamba 的选择性步长 Δ_t , 并认为「两种离散化精度差不多, 随使用哪个」。

- 指出丙同学说法的一个关键问题: Mamba 选择 ZOH 的理由是什么 (提示: $\bar{A}_t = e^{\Delta_t A}$ 的「遗忘率」语义是什么)?
- 当 $\Delta_t \rightarrow +\infty$, ZOH 给出 $\bar{A}_t \rightarrow 0$ (完全遗忘), 而双线性给出 $\bar{A}_t \rightarrow -1$ (符号震荡)。这对 Mamba 的选择性机制意味着什么问题?
- 写出 ZOH 在 $\Delta_t \rightarrow 0^+$ 和 $\Delta_t \rightarrow +\infty$ 两个极限下 $\bar{A}_t$ 的值, 并说明「记住历史」与「遗忘历史」对应哪个极限。

解答 T-7.3.3

(a) Mamba 选 ZOH 的关键理由： $\bar{A}_t = e^{\Delta_t A}$ 具有清晰的「遗忘率」语义—— Δ_t 控制离散化时间步长，步长越大，相当于积分更长的连续时间，负特征值导致状态衰减越多（遗忘越多）。这种「遗忘率与步长单调对应」的语义在双线性中不成立。

(b) 双线性在 $\Delta_t \rightarrow +\infty$ 时： $\bar{A}_t = \frac{1 + \frac{\Delta_t}{2}a}{1 - \frac{\Delta_t}{2}a} \rightarrow -1$ （对负 a ， $\bar{A}_t \rightarrow -1$ ）。这意味着状态以 $(-1)^k$ 震荡，而非衰减为零——这破坏了「遗忘历史，聚焦当前」的语义，会引起训练不稳定。

(c) ZOH 极限行为：

- $\Delta_t \rightarrow 0^+$: $\bar{A}_t = e^{\Delta_t \lambda} \rightarrow e^0 = 1$ （**记住历史**：状态不变，不注入新输入 $\bar{B}_t \rightarrow 0$ ）；
- $\Delta_t \rightarrow +\infty$ ($\lambda < 0$): $\bar{A}_t = e^{\Delta_t \lambda} \rightarrow 0$ （**遗忘历史**：状态清零，完全聚焦当前输入）。

工程批注：T-7.3.3 的 Mamba vs. Transformer 长序列推理速度对比：Transformer 每生成一个 token 需要用 $O(Ld)$ 的操作访问 KV 缓存（ L 为已生成长度），推理时间随序列增长线性增加；而 Mamba 每步只需 $O(Nd)$ （ N 是固定状态维度，典型值 16-64），不随序列长度增长。在 $L = 65536$ (64K context)、 $N = 16$ 、 $d = 2048$ 的设定下，Mamba 每步推理运算量约是 Transformer 的 1/4096。实测（Mamba 原论文 Figure 8）在序列长 4K 以上，Mamba 推理吞吐量约是同参数量 Transformer 的 4-5 倍；在 128K 以上差距更大。但代价是：Mamba 无法进行精确的 key-value 检索，在 RULER 等长文档 QA 基准上仍显著弱于 Transformer。

公式 7 · Mamba 选择性参数化

$$\Delta_t = \text{softplus}(W_\Delta x_t + b_\Delta), \quad B_t = W_B x_t, \quad C_t = W_C x_t$$

$$\bar{A}_t = e^{\Delta_t A}, \quad h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t, \quad y_t = C_t h_t$$

一句话直觉：让步长 Δ_t 依赖当前 token，使模型能按内容决定「这一步要记多少、忘多少」。

在大模型里的位置：架构（模型结构 / 算子设计 / 表示空间）

本组训练目标：代入 · 变形 · 工程

常见卡点：

- $\Delta_t > 0$ 由 softplus 保证，这是 $\bar{A}_t = e^{\Delta_t A}$ 具有负指数（稳定）的前提
- B_t, C_t 也依赖输入——这使得模型既能选择性记忆（ B_t ），也能选择性读取（ C_t ）
- 选择性机制破坏了 LTI，全局卷积不再有效，必须用并行扫描

本组在练什么：理解选择性机制的极限行为，以及 softplus 保正性为何重要。做完应能回答：Mamba 是如何用 Δ_t 实现「赢者通吃」的记忆控制的？

T-7.3.4 【易 · 代入 · softplus 保正性与极限行为】

- (a) 证明 $\text{softplus}(u) = \ln(1 + e^u) > 0$ 对所有 $u \in \mathbb{R}$ 成立（一行推导）；
 (b) 计算 $\text{softplus}(0)$, $\text{softplus}(2)$, $\text{softplus}(-2)$ 的数值（保留 3 位小数）；
 (c) 设 $\lambda < 0$ 是 A 的特征值, $\bar{A}_t = e^{\Delta_t \lambda}$: 分析 $\Delta_t \rightarrow 0^+$ 和 $\Delta_t \rightarrow +\infty$ 两个极限, 各对应「记忆历史」还是「遗忘历史」?

解答 T-7.3.4

(a) $\forall u \in \mathbb{R}: e^u > 0 \Rightarrow 1 + e^u > 1 > 0 \Rightarrow \ln(1 + e^u) > 0$ 。□

(b) 数值:

$$\text{softplus}(0) = \ln 2 \approx 0.693; \quad \text{softplus}(2) = \ln(1+e^2) \approx \ln 8.389 \approx 2.127; \quad \text{softplus}(-2) = \ln(1+e^{-2})$$

(c) 极限行为（设 $\lambda < 0$ ）:

- $\Delta_t \rightarrow 0^+$: $\bar{A}_t = e^{\Delta_t \lambda} \rightarrow 1$, $\bar{B}_t \rightarrow 0$, 递推 $h_t \approx h_{t-1}$ ——完全**记住历史**, 忽略新输入;
- $\Delta_t \rightarrow +\infty$: $\bar{A}_t = e^{\Delta_t \lambda} \rightarrow 0$, $\bar{B}_t \rightarrow -\lambda^{-1} B_t$ (有界), 递推 $h_t \approx -\lambda^{-1} B_t x_t$ ——完全**遗忘历史**, 聚焦当前输入。

T-7.3.5 【中 · 工程 · Mamba vs. Transformer 长序列推理速度】 Transformer（标准注意力）推理时每步复杂度 $O(Ld)$ （随序列长度线性增长），Mamba 推理时每步复杂度 $O(Nd)$ （状态维度固定）。

- (a) 设 $L = 65536$ (64K context), $N = 16$, $d = 2048$, 计算 Transformer 与 Mamba 每步推理的运算量比值；
 (b) 训练时, Mamba 利用并行扫描实现 $O(L)$ 工作量（深度 $O(\log L)$ ），而 Transformer 训练也是 $O(L^2 d)$ 。对 $L = 4096$ 的训练批次, 两者哪个训练更快?（不是推理, 是训练）
 (c) 指出 Mamba 在什么任务场景上有推理速度优势, 以及它在什么任务上系统性弱于 Transformer（提示: 精确键值检索, 参考 § 7.5 线性注意力分析）。

解答 T-7.3.5

- (a) Transformer 每步运算量 $\sim 2Ld$ (KV 缓存读取), Mamba 每步 $\sim 2Nd$ 。比值: $L/N = 65536/16 = 4096$ 。Transformer 每步运算量是 Mamba 的 4096 倍。
 (b) 训练时比较 ($L = 4096$):
 · Transformer: $O(L^2 d) = O(4096^2 \times 2048) \approx 3.4 \times 10^{10}$;
 · Mamba (并行扫描): $O(LNd) = O(4096 \times 16 \times 2048) \approx 1.3 \times 10^8$;

Mamba 训练也更快(约 256 倍), 因为并行扫描工作量 $O(LNd)$ 远小于注意力的 $O(L^2 d)$ (当 $N \ll L$ 时)。

(c) Mamba 推理速度优势场景：长序列自回归生成（如长文档续写、代码生成），序列越长优势越大。

Mamba 系统性弱于 Transformer 的任务：精确键值检索（如 Passkey Retrieval、复制任务、RULER 基准），因为其状态容量有限（命题 7.8），无法模拟 softmax 注意力的「赢者通吃」机制。

公式 8 · 并行扫描关联算子

$$(a_1, b_1) \otimes (a_2, b_2) = (a_2 a_1, a_2 b_1 + b_2)$$

一句话直觉：把递推 $h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$ 表达为满足结合律的二元运算，从而可以像归并排序一样并行。

在大模型里的位置：架构（模型结构 / 算子设计 / 表示空间）

本组训练目标：证明 · 工程

常见卡点：

- 结合律验证必须手算左右两种结合次序，证明结果相同
- 运算 $\otimes$ 不交换（ $a_2 a_1 \neq a_1 a_2$ 一般），但结合律成立
- Blelloch 算法的工作量 $O(L)$ 、深度 $O(\log L)$ ——工作量不变，深度才是并行化的优势

本组在练什么：验证结合律、理解并行扫描的复杂度分析。做完应能回答：结合律为什么是「可以并行」的充要条件？

T-7.3.6 【中 · 证明 · 关联算子结合律与并行复杂度】

- 手动验证 $(a_1, b_1) \otimes [(a_2, b_2) \otimes (a_3, b_3)] = [(a_1, b_1) \otimes (a_2, b_2)] \otimes (a_3, b_3)$ ，写出每一步计算；
- 设 $h_0 = 0$ ，用 $\otimes$ 运算展开 $h_3 = \bar{A}_3 \bar{A}_2 \bar{B}_1 x_1 + \bar{A}_3 \bar{B}_2 x_2 + \bar{B}_3 x_3$ ，验证与递推定义一致；
- Blelloch 上扫阶段第 d 层执行 $L/2^d$ 次运算（ $d = 1, \dots, \log_2 L$ ），对所有层求和，证明总工作量 $= L - 1 = O(L)$ ；深度（层数）为多少？对 $L = 2^{20}$ ，理论并行加速比约为多少？

解答 T-7.3.6

(a) 左结合： $[(a_1, b_1) \otimes (a_2, b_2)] \otimes (a_3, b_3) = (a_2 a_1, a_2 b_1 + b_2) \otimes (a_3, b_3) = (a_3 a_2 a_1, a_3 a_2 b_1 + a_3 b_2 + b_3)$ 。

右结合： $(a_1, b_1) \otimes [(a_2, b_2) \otimes (a_3, b_3)] = (a_1, b_1) \otimes (a_3 a_2, a_3 b_2 + b_3) = (a_3 a_2 a_1, a_3 a_2 b_1 + a_3 b_2 + b_3)$ 。

两者完全相等。□

(b) 令 $a_t = \bar{A}_t$, $b_t = \bar{B}_t x_t$, 从 $(1, 0)$ (初始态 $h_0 = 0$) 出发:

$$\otimes(a_1, b_1) = (a_1, b_1); \quad \otimes(a_2, b_2) = (a_2 a_1, a_2 b_1 + b_2); \quad \otimes(a_3, b_3) = (a_3 a_2 a_1, a_3 a_2 b_1 + a_3 b_2 + b_3).$$

$$\text{第二分量} = a_3 a_2 b_1 + a_3 b_2 + b_3 = \bar{A}_3 \bar{A}_2 \bar{B}_1 x_1 + \bar{A}_3 \bar{B}_2 x_2 + \bar{B}_3 x_3 = h_3. \quad \square$$

(c) Blelloch 上扫总工作量: $\sum_{d=1}^{\log_2 L} \frac{L}{2^d} = L(1 - \frac{1}{L}) = L - 1 = O(L)$ 。

深度 (层数) = $\log_2 L$ 。对 $L = 2^{20}$, 深度 = 20 层, 理论加速比 (无限处理器) = $L / \log_2 L = 2^{20} / 20 \approx 52428$ 倍。

结合律是并行化前提: 二叉树归并要求「先合并哪两个子树」不影响结果, 即 $(A \otimes B) \otimes C = A \otimes (B \otimes C)$ 。若不满足结合律, 计算树的分割方式会影响结果, 无法自由调整计算顺序, 也就无法并行。

T-7.3.7 【难 · 反例 · LTI 的根本表达能力限制】 考虑「精确复制」任务: 给定输入 $x_1, \dots, x_L$, 要求输出 $y_t = x_{t-k}$ (延迟 k 步)。

- LTI SSM 中 $h_t = \sum_{j=0}^t \bar{A}^j \bar{B} x_{t-j}$, 说明为什么精确复制 x_{t-k} 等价于卷积核在位置 k 为 1、其余为 0 (「Dirac 脉冲结构」) ——而指数衰减的核无法实现此结构;
- Mamba 的 Δ_t 依赖输入: 当某时刻 t_0 的 Δ_{t_0} 突然很大时, $\bar{A}_{t_0} \rightarrow 0$, 状态被「清空」并写入当前 token。解释这如何帮助模型缓解复制任务的限制 (但不能完全解决);
- 给出一个 Mamba 仍然无法处理的任务类型, 并用上述分析解释原因。

解答 T-7.3.7

- 精确复制 x_{t-k} 要求卷积核 $\bar{K}_j = \delta_{j,k}$ (仅第 k 位为 1, 其余为 0)。LTI 中 $\bar{K}_j = \bar{C} \bar{A}^j \bar{B}$, 若 $\bar{A}$ 谱范数 < 1 (稳定性要求), 则 $\bar{K}_j$ 指数衰减, 无法形成 Dirac 脉冲。若强制 $\bar{A}$ 为幺正矩阵 ($|\bar{\lambda}_i| = 1$), 则系统临界稳定 (不衰减), 但会振荡而非形成单 spike。结论: 固定参数 LTI 无法精确实现任意延迟复制。
- 当 Δ_{t_0} 突然变大, $\bar{A}_{t_0} \approx 0$, 状态被「清空」并写入 $\bar{B}_{t_0} x_{t_0}$ ——等效于动态地「重置记忆」并专注于当前 token。这使模型可以在某一时刻选择性地记住某个特定 token, 从而缓解 (但不能完全解决) LTI 的线性叠加限制。根本限制仍在: 状态 $h_t \in \mathbb{R}^N$ 是固定维度的, 同时存储多个精确记忆会产生干扰。
- Mamba 仍然无法可靠处理的任务: 同时精确检索多个相距甚远的 token (如「找出序列中第 3 个、第 57 个、第 203 个特定词」)。原因: 即使选择性机制可以在任一时刻聚焦一个 token, h_t 的有限维度限制了同时存储的精确信息量。当需要同时「记住」多于 N 个精确 token 时, 信息必然被覆盖 (与 T-7.4.6 的容量分析一致)。

【做完自检】

1. ZOH 和双线性离散化在小步长下精度相同，但 Mamba 为何选 ZOH？关键是哪个极限行为？
2. Mamba 的选择性机制如何用 Δ_t 的大小实现「记住」与「遗忘」的控制？
3. Blelloch 并行扫描为什么需要结合律？如果运算不满足结合律，会出现什么问题？

§ 7.4 线性注意力

§ 7.4 的核心：把 softmax 注意力里的 $\exp(Q_i K_j^\top)$ 替换为核函数分解 $\phi(Q_i) \cdot \phi(K_j)^\top$ ，然后利用矩阵乘法结合律把 $O(L^2 d)$ 的注意力矩阵计算，变成 $O(Lrd)$ 的两步矩阵乘法。本节同时要建立「线性注意力的检索能力是有限的」这一重要直觉，这是理解 Mamba 等模型在检索任务上的系统性弱点的關鍵。

小节导读 · 公式从哪里来

为什么能把 $O(L^2)$ 压到 $O(L)$ ？Softmax 注意力 $O_i = \sum_j \text{softmax}(Q_i K_j^\top) V_j$ 是一个三项联合。只要去掉 softmax 的非线性，三项就可以重新结合。

第一步：核函数分解。设 $\phi: \mathbb{R}^d \rightarrow \mathbb{R}^r$ 使 $K(q, k) \approx \phi(q)^\top \phi(k)$ 。原公式变 $O_i \propto \sum_j \phi(Q_i)^\top \phi(K_j) V_j = \phi(Q_i)^\top \sum_j \phi(K_j) V_j^\top$ 。

第二步：结合律变两步乘法。先算 $S = \sum_j \phi(K_j) V_j^\top \in \mathbb{R}^{r \times d}$ （代价 $O(Lrd)$ ），再用 $O_i = \phi(Q_i)^\top S$ （代价 $O(Lrd)$ ）。总代价 $O(Lrd)$ 。在因果场景下变为在线递推 $S_t = S_{t-1} + \phi(K_t) V_t^\top$ ——一个 RNN。

第三步：RNN-attention 对偶。 S_t 本质上是记忆状态，维度 $r \times d$ 是状态容量。线性注意力 $\equiv$ 一个带固定状态维度的 RNN。Mamba 与线性 attention 本是一家亲。

第四步：检索为何崩塌（能力上限）。多个不同的键值对被「压」进同一个 $r \times d$ 矩阵。如果 L 超过 r ，不可避免的信息损失，提取某个特定键时会混入其他键。理论上这是「可区分 capacity 为 r 」的限制。

第五步：为什么 softmax 反而能检索。Softmax 产生锐利的权重，能「只点亮」某一个 K_j 。等价于 $r \rightarrow \infty$ 的核，信息不被压缩，付出的代价是 $O(L^2)$ 。

本节要拿走的一件事：线性 attention = 有限状态 RNN；快不代表全能，检索能力被状态维度 r 硬性限定。

公式 9 · Softmax 注意力复杂度基准

$$O_i = \frac{\sum_j \exp(Q_i \cdot K_j / \sqrt{d}) V_j}{\sum_j \exp(Q_i \cdot K_j / \sqrt{d})}, \quad \text{复杂度 } O(L^2 d)$$

一句话直觉：计算 $L \times L$ 注意力矩阵是性能瓶颈，线性注意力的目标就是绕开这个矩阵。

在大模型里的位置：架构（模型结构 / 算子设计 / 表示空间）

本组训练目标：代入 · 变形

常见卡点：

- $O(L^2d)$ 的瓶颈来自计算所有 i, j 对的內积，不是 softmax 本身
- 分母的归一化 $\sum_j \exp(\cdot)$ 保证权重和为 1；线性版本也必须有归一化分母
- 注意 $Q_i \cdot K_j$ 是 d 维向量的內积，每次 $O(d)$

本组在练什么：建立 $O(L^2d)$ 复杂度的来源直觉，为引入线性注意力做铺垫。做完应能回答：注意力矩阵的哪一步操作导致了二次复杂度？

T-7.4.1 【易 · 代入 · ELU+1 非负性与数值稳定】 ELU+1 特征映射 $\phi(x)_i = \text{elu}(x_i) + 1$ ，其中 $\text{elu}(u) = u \cdot \mathbf{1}_{u \geq 0} + (e^u - 1) \cdot \mathbf{1}_{u < 0}$ 。

- 分 $x_i \geq 0$ 和 $x_i < 0$ 两种情形证明 $\phi(x)_i > 0$ 恒成立；
- 计算 $\phi(x)_i$ 在 $x_i = 2, 0, -1, -5$ 处的数值（保留 3 位小数）；
- 若某个 $\phi(x)_i \leq 0$ ，分母 $\phi(Q_i) \cdot z$ 可能出现什么问题？这为什么会导导致训练崩溃？

解答 T-7.4.1

(a) 非负性验证：

情形 $x_i \geq 0$ ： $\phi(x)_i = x_i + 1 \geq 0 + 1 = 1 > 0$ 。□

情形 $x_i < 0$ ： $\phi(x)_i = e^{x_i}$ ，指数函数恒正。□

(b) 数值：

x_i	$\phi(x)_i$
2	$2 + 1 = 3.000$
0	$0 + 1 = 1.000$
-1	$e^{-1} \approx 0.368$
-5	$e^{-5} \approx 0.007$

- 若 $\phi(Q_i) \cdot z \leq 0$ ，分母为零或负，输出无穷大或符号错误，反向传播时产生 NaN/Inf，导致训练崩溃。ELU+1 保证所有特征值严格正，从而內积 $\phi(Q) \cdot \phi(K) > 0$ ，分母 $= \sum_j \phi(Q) \cdot \phi(K_j) > 0$ 恒成立——这是数值稳定性的必要条件。

T-7.4.2 【中 · 变形 · 线性注意力的 $O(Lrd)$ 推导】 设序列长度 L ，特征维度 r ，值向量维度 d 。

- 朴素计算（不分解）：对每个 i ，计算 L 个內积后加权求和，写出总复杂度；
- 线性分解后：先算 $S = \sum_j \phi(K_j)^\top V_j \in \mathbb{R}^{r \times d}$ （ L 次外积，每次 $O(rd)$ ），再对所有 i 算 $\phi(Q_i)S$ （每次 $O(rd)$ ）。写出两步的总复杂度；
- 对 $r = 64, L = 4096$ ，两种方法的复杂度比值是多少？用一句话解释这里的代数「魔法」（结合律的作用）；

- (d) 在因果（自回归）推理中，每步只需 $O(rd)$ ，而训练时仍需 $O(Lrd)$ ——解释这一推理/训练复杂度的不对称性来自哪里。

解答 T-7.4.2

- (a) 朴素方法：对每个 $i \in \{1, \dots, L\}$ ，计算 L 次内积（每次 $O(d)$ ），总 $O(Ld)$ ； L 个查询，总复杂度 $O(L^2d)$ 。
- (b) 线性分解：
- $S = \sum_j \phi(K_j)^\top V_j$ ： L 次外积 $O(rd)$ ，总 $O(Lrd)$ ；
 - 对 L 个查询 $\phi(Q_i)S$ ：每次 $O(rd)$ ，总 $O(Lrd)$ ；
 - 总复杂度 $O(Lrd)$ 。
- (c) 比值 $= L^2d/(Lrd) = L/r = 4096/64 = 64$ 倍。「代数魔法」：矩阵乘法结合律——先把所有 K_j, V_j 的外积累加成一个 $r \times d$ 的状态矩阵 S ，再用每个查询 $\phi(Q_i)$ 与之相乘，把 $L \times L$ 的注意力矩阵「分解掉」了。
- (d) 推理时（自回归），每一步只有 1 个新 token，利用 $S_t = S_{t-1} + \phi(K_t)^\top V_t$ 在线更新，每步只需 $O(rd)$ ，且 S_t 大小固定为 $r \times d$ ，与序列长度无关。训练时需要对全序列 L 个位置同时计算输出（以利用并行化），因此无法用在线更新，复杂度保持 $O(Lrd)$ 。

公式 10 · 线性注意力核技巧

$$O_i = \frac{\phi(Q_i) \left(\sum_j \phi(K_j)^\top V_j \right)}{\phi(Q_i) \cdot \left(\sum_j \phi(K_j) \right)} = \frac{\phi(Q_i)S}{\phi(Q_i) \cdot z}$$

一句话直觉：矩阵乘法结合律把 $L \times L$ 注意力矩阵「分解掉」，变成固定大小的 $S \in \mathbb{R}^{r \times d}$ 状态。

在大模型里的位置：架构（模型结构 / 算子设计 / 表示空间）

本组训练目标：代入 · 工程 · 判错

常见卡点：

- $S = \sum_j \phi(K_j)^\top V_j$ 是外积 $\phi(K_j)^\top \in \mathbb{R}^{r \times 1}$ 乘 $V_j \in \mathbb{R}^{1 \times d}$ 的累加，结果 $\in \mathbb{R}^{r \times d}$
- 因果设定下 $S_t = S_{t-1} + \phi(K_t)^\top V_t$ ——这就是「快速权重记忆」的在线更新
- Performer (FAVOR+) 的随机特征无偏地近似 softmax 核，但 ELU+1 不是 softmax 的近似

本组在练什么：因果线性注意力的在线递推，以及 Performer 与 ELU+1 的本质区别。做完应能回答：线性注意力的「快速权重记忆」容量是多少 bit？

T-7.4.3 【中 · 代入 · 因果线性注意力在线递推】 设 $r = 2$ ， $d = 1$ ， $S_0 = 0$ ， $z_0 = 0$ 。三个 token 的特征和值：

$$\phi(K_1) = (1, 0), \quad \phi(K_2) = (0, 1), \quad \phi(K_3) = (1, 1), \quad V_1 = 1, V_2 = 2, V_3 = 3$$

$$\phi(Q_3) = (1, 1)$$

- (a) 逐步更新 S_1, S_2, S_3 和 z_1, z_2, z_3 ;
 (b) 计算 $O_3 = \phi(Q_3)S_3 / (\phi(Q_3) \cdot z_3)$;
 (c) 这个 O_3 是 V_1, V_2, V_3 的加权平均, 权重各是多少? 是否是均匀平均?

解答 T-7.4.3

- (a) 逐步更新 $S \in \mathbb{R}^{2 \times 1}$:

$$S_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}; \quad S_2 = \begin{pmatrix} 1 \\ 0 \end{pmatrix} + \begin{pmatrix} 0 \\ 1 \end{pmatrix} \cdot 2 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}; \quad S_3 = \begin{pmatrix} 1 \\ 2 \end{pmatrix} + \begin{pmatrix} 1 \\ 1 \end{pmatrix} \cdot 3 = \begin{pmatrix} 4 \\ 5 \end{pmatrix}.$$

$$z_1 = (1, 0)^\top; \quad z_2 = (1, 1)^\top; \quad z_3 = (2, 2)^\top.$$

- (b)

$$O_3 = \frac{\phi(Q_3)S_3}{\phi(Q_3) \cdot z_3} = \frac{(1, 1) \cdot (4, 5)^\top}{(1, 1) \cdot (2, 2)^\top} = \frac{4 + 5}{2 + 2} = \frac{9}{4} = 2.25.$$

(c) 权重: $w_j = \frac{\phi(Q_3) \cdot \phi(K_j)}{\phi(Q_3) \cdot z_3}.$

$$w_1 = \frac{(1, 1) \cdot (1, 0)}{4} = \frac{1}{4} = 0.25; \quad w_2 = \frac{(1, 1) \cdot (0, 1)}{4} = \frac{1}{4} = 0.25; \quad w_3 = \frac{(1, 1) \cdot (1, 1)}{4} = \frac{2}{4} = 0.5.$$

不是均匀平均 ($w_3 = 0.5 > w_1 = w_2 = 0.25$): $K_3 = (1, 1)$ 与 $Q_3 = (1, 1)$ 完全匹配, 故权重更高; 但对比 softmax, 线性权重差异更「平缓」(没有指数放大)。

T-7.4.4【中·工程·Performer/Linformer/RetNet 实际效果对比】 以下三种线性注意力方案在实践中有不同的取舍:

- ELU+1 (Katharopoulos 2020): 简单特征映射, 不近似 softmax
- FAVOR+ / Performer (Choromanski 2021): 随机特征无偏近似 softmax 核
- RetNet (Sun 2023): 固定指数衰减 γ^{i-j} , 不使用可学习特征映射

- (a) FAVOR+ 使用正值随机特征 ϕ^+ : 解释「无偏估计」的含义(对什么量的无偏估计?); 用 r 个独立随机特征取均值, 方差如何随 r 变化(定性说明);
- (b) RetNet 的固定衰减 $\gamma \in (0, 1)$ 等价于线性注意力核中按位置的衰减因子。这与 LegT 的滑动窗口记忆有何相似之处? RetNet 的多头设定(不同头用不同 γ) 解决了什么问题?
- (c) 在长文档精确检索任务上, 以上三者都弱于标准 softmax 注意力。用一句话指出核心原因(参考命题 7.8)。

解答 T-7.4.4

- (a) FAVOR+ 的 $\phi^+(x) \cdot \phi^+(y)^\top$ 是 $\exp(x \cdot y)$ (softmax 核值) 的无偏估计量, 即 $\mathbb{E}_\omega[\phi^+(x) \cdot \phi^+(y)^\top] = \exp(x \cdot y)$, 无系统性高估或低估。方差 $\propto 1/r$, 随特征数增加, 估计越稳定。
- (b) RetNet 的固定衰减 γ^{i-j} 类似 LegT 的滑动窗口: 都对历史信息施加指数衰减权重, 近期信息权重高。多头设定 (不同 γ 对应不同时间尺度) 解决的问题: 单一 γ 只能捕获一种记忆长度, 多个 γ 让不同注意力头专注于不同时间尺度 (如短期语法 vs. 长期主题), 提升模型的时序建模能力。
- (c) 核心原因: 有限秩的特征映射无法模拟 softmax 的无界尖锐化——正确键的期望权重上界为 $O(r/L)$, 当 $L \gg r$ 时趋向零 (命题 7.8), 无法可靠检索。

公式 11 · 线性注意力检索上界

$$w_{j^*} = \frac{\phi(Q^*) \cdot \phi(K^*)}{\sum_j \phi(Q^*) \cdot \phi(K_j)} \leq O\left(\frac{r}{L}\right) \quad (\text{均匀随机键, 最坏情形})$$

一句话直觉: 有限秩的特征映射无法模拟 softmax 的「无界尖锐化」, 正确键的权重上界随序列变长而趋零。

在大模型里的位置: 架构 (模型结构 / 算子设计 / 表示空间)

本组训练目标: 证明 · 反例

常见卡点:

- 柯西-施瓦茨给出分子上界 $\leq c^2$, 大数定律给出分母量级 $\sim Lc^2/r$
- Softmax 能「无限尖锐化」是因为指数函数没有上界; 线性核 $\phi(Q) \cdot \phi(K)$ 是有界实数
- 此上界是「最坏情形」(均匀随机键), 实际训练中模型会学习让相关键的内积更大, 但根本限制仍然存在

本组在练什么: 用柯西-施瓦茨推导线性注意力的检索能力上界, 理解 softmax 和线性注意力的本质差异。做完应能回答: 为什么 GLA/Mamba 在 RULER 基准上弱于 Transformer?

T-7.4.5 【难 · 证明 · 线性注意力检索权重上界】 设 $\|\phi(K_j)\| = c$ 为常数, L 个键均匀随机分布, 查询 $Q^* = K_1$ (精确匹配)。

- (a) 用柯西-施瓦茨不等式给出分子 $\phi(Q^*) \cdot \phi(K_1)$ 的上界;
- (b) 当键均匀随机时, 估计 $\mathbb{E}[\phi(Q^*) \cdot \phi(K_j)]$ ($j \neq 1$) 的量级, 给出分母期望量级 $\sim Lc^2/r$;
- (c) 综合 (a)(b), 得出 $\mathbb{E}[w_1] \leq O(r/L)$; 对 $L = 4096, r = 64$, 正确键的期望权重上界约为多少? 能否可靠检索?

- (d) Softmax 中, 分子 $e^{\|Q^*\|^2/\sqrt{d}}$ 当 $\|Q^*\| \rightarrow \infty$ 时指数增长, 分母中其他项增长慢。解释为何 $w_{j^*} \rightarrow 1$, 而线性核无法做到。

解答 T-7.4.5

- (a) 柯西-施瓦茨: $\phi(Q^*) \cdot \phi(K_1) \leq \|\phi(Q^*)\| \|\phi(K_1)\| = c \cdot c = c^2$ 。
- (b) 均匀随机键时, $\mathbb{E}[\phi(Q^*) \cdot \phi(K_j)] \sim \|\phi(Q^*)\|^2/r = c^2/r$ (各向同性假设下内积均值量级), L 项求和分母 $\sim Lc^2/r$ 。
- (c) $\mathbb{E}[w_1] \leq \frac{c^2}{Lc^2/r} = \frac{r}{L}$ 。对 $L = 4096, r = 64$: $w_1 \lesssim 1/64 \approx 1.5\%$, 与其他 4095 个键的平均权重 (约 $1/4096 \approx 0.024\%$) 仅差 64 倍, 无法可靠区分正确键 (softmax 可以做到权重接近 100%)。
- (d) Softmax 中, 分子 $e^{\|Q^*\|^2/\sqrt{d}}$ 随 $\|Q^*\| \rightarrow \infty$ 指数增长, 分母中其他项 $e^{Q^* \cdot K_j/\sqrt{d}}$ ($Q^* \cdot K_j < \|Q^*\|^2$) 增长更慢, 故 $w_{j^*} \rightarrow 1$ (「赢者通吃」)。线性核 $\phi(Q^*) \cdot \phi(K^*)$ 是有界常数, 无法通过增大查询范数来无限尖锐化分配。

工程批注: T-7.4.5 解释了为什么 GLA、Mamba、RetNet 等模型在 RULER 长文档检索基准上系统性弱于 Transformer: RULER 的核心任务 (Multi-hop Tracing、Aggregation) 需要精确键值检索, 而线性注意力的 $O(r/L)$ 权重上界在 $L = 128K$ 时几乎意味着「随机猜测」。实践中, 混合架构 (如每 4 层 SSM 插入 1 层标准注意力) 已成为主流折中方案, 如 Jamba (SSM+Transformer 混合) 在 RULER 上表现接近纯 Transformer, 同时保留了 SSM 的推理速度优势。

T-7.4.6 【难 · 工程 · 线性注意力等价快速权重记忆】 Schlag et al. (2021) 指出, 线性注意力的状态更新 $S_t = S_{t-1} + \phi(K_t)^\top V_t$ 等价于「快速权重记忆」: S_t 以外积形式存储键值关联。

- (a) 若 $S_t \in \mathbb{R}^{r \times d}$, 其信息容量约 $O(rd)$ 个实数。当需要精确存储 n 个键值对时, n 超过多少后会出现干扰误差 (容量限制)?
- (b) 与 GRU/LSTM 的门控机制相比, 线性注意力的 S_t 更新 ($S_t = S_{t-1} + \phi(K_t)^\top V_t$, 无遗忘) 与 GLA 的更新 ($S_t = G_t S_{t-1} + \phi(K_t)^\top V_t$, 有门控遗忘) 有何本质区别? 哪个更像 Mamba?
- (c) 判错: 丁同学说「只要增大特征维度 r , 线性注意力的检索能力就能无限逼近 softmax 注意力」。请指出这个说法在什么条件下是合理的近似, 以及它忽略了什么根本差异。

解答 T-7.4.6

- (a) 状态 $S_t \in \mathbb{R}^{r \times d}$ 的信息容量约 $O(rd)$ 个实数。要精确存储 n 个键值对, 每对占 $r+d$ 个自由度, 当 $n > r$ 时 (特征维度 r 已满), 新写入的外积 $\phi(K_t)^\top V_t$ 会与之前的记忆产生干扰 (线性叠加导致串扰, 类似 Hopfield 网络的容量限制 $\sim 0.14N$), 检索精度下降。
- (b) 本质区别: 线性注意力的 $S_t = S_{t-1} + \phi(K_t)^\top V_t$ 是无遗忘的 (所有历史信息累积

写入), 越远的历史信息权重越被新信息「稀释」; GLA 的 $S_t = G_t S_{t-1} + \phi(K_t)^\top V_t$ 有数据依赖的门控遗忘 ($G_t \in (0, 1)$ 按需清除旧信息), 更像 Mamba 的选择性机制 ($A_t = e^{\Delta_t A}$)。Mamba 更接近 GLA 而非无门控的线性注意力。

- (c) 判错: 丁同学的说法部分合理——理论上, 令 $r = L$ (特征维度等于序列长度), 线性注意力确实可以精确表示所有键值对 (Gram 矩阵满秩), 性能逼近 softmax。但这忽略了两点根本差异: ① 计算复杂度退化回 $O(L^2 d)$ (线性注意力的效率优势完全消失); ② softmax 的「指数尖锐化」是通过学习增大 query 范数实现的, 不需要增大 r ——这是非线性的质的差异, 不是 r 足够大就能弥合的近似误差。

【做完自检】

1. 线性注意力如何把 $O(L^2 d)$ 降到 $O(Lrd)$? 用一句话描述矩阵乘法结合律在其中的角色。
2. Performer (FAVOR+) 和 ELU+1 都是线性注意力, 但对 softmax 核的近似方式根本不同——各是什么?
3. 为什么线性注意力无法实现 softmax 的「赢者通吃」精确检索? 从数学上给出核心原因。

§7.5 扩散语言模型

从连续 DDPM 开始, 过渡到离散 token 的吸收态扩散 (MDLM/LLaDA), 重点理解: 闭式边际分布 $q(x_t|x_0)$ 、后验 $q(x_{t-1}|x_t, x_0)$ 、以及为什么训练目标等价于加权 MLM。最后比较扩散语言模型与自回归语言模型的本质数学差异。

小节导读·公式从哪里来

为什么扩散能用于语言? 连续 DDPM 是在高斯噪声中学习反向去噪。语言的输出是 token (离散), 不宜用高斯。MDLM/LLaDA 采取「吸收态扩散」: 随机把 token 替换为 [MASK], 逆转过程是在预测被掩位置。

第一步: 连续 DDPM 边际。 $q(x_t|x_0) = \mathcal{N}(\sqrt{\alpha_t}x_0, (1 - \alpha_t)I)$ 是高斯加噪多步折叠结果; 闭式是高斯乘积仍为高斯的几何后果。后验 $q(x_{t-1}|x_t, x_0)$ 也是高斯, 训练目标是预测噪声。

第二步: 离散吸收态扩散。设每个 token 独立地以概率 α_t 被掩、以 $1 - \alpha_t$ 保留原样。 $q(x_t|x_0) = \prod_i [\alpha_t \delta_{x_t^i, [\text{MASK}]} + (1 - \alpha_t) \delta_{x_t^i, x_0^i}]$ ——闭式边际。

第三步: 训练目标 = 加权 MLM。变分上界 $L_t = \mathbb{E}_{x_0, x_t} [\sum_{i: \text{masked}} -\log p_\theta(x_0^i|x_t)]$ 。上面乘以 $|\alpha'_t|/\alpha_t$ 权重。这是一个「掩码比率可调」的 MLM, 与 BERT 的区别是 t 可变、据此重构一个生成过程。

第四步: 与自回归的本质差异。自回归严格从左到右: chain rule $p(x) = \prod p(x^i|x^{<i})$, 生成顺序不可逆。扩散语言模型一步预测多个掩码位置, 生成顺序可以任意, 适合填空、编辑任务。

第五步: 代价是什么。多步迭代中每步都要调用模型, 推理计算量是自回归的多倍。怎么减少迭代是下一代扩散语言模型的核心课题。

本节要拿走的一件事：扩散语言模型 = 掩码比率可变的加权 MLM；其生成顺序自由、适合不依赖顺序的任务，代价是多步迭代推理。

公式 12 · DDPM 边际分布（闭式）

$$q(x_t|x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I), \quad \bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$$

一句话直觉：不需要逐步 t 次加噪，可以「一步跳到」任意时刻的加噪版本——这是 DDPM 训练效率的关键。

在大模型里的位置：训练（loss 计算 / 梯度回传 / 数据-参数配比）

本组训练目标：代入 · 证明

常见卡点：

- $\bar{\alpha}_t$ 是累积乘积， t 越大 $\bar{\alpha}_t$ 越小，趋向 0 时信号完全淹没
- 重参数化 $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon$ 是一步采样，不需要逐步走 Markov 链
- 分数函数 $\nabla_{x_t} \log q_t(x_t)$ 与 ϵ_θ 的关系： $\nabla_{x_t} \log q(x_t|x_0) = -\epsilon/\sqrt{1 - \bar{\alpha}_t}$

本组在练什么：闭式边际分布的数值计算、重参数化技巧、以及分数函数与噪声预测的等价关系。做完应能回答：为什么 DDPM 训练能用单步采样，而不需要逐步走 T 步马尔可夫链？

T-7.5.1 【易 · 代入 · 噪声调度数值计算】 设线性调度 $\beta_t = 0.02$ （常数）， $\bar{\alpha}_t = 0.98^t$ 。

- 计算 $t = 1, 5, 10, 50, 100$ 时 $\bar{\alpha}_t$ 的数值（保留 4 位小数）；
- 在 $t = 50$ 时，边际分布 $q(x_{50}|x_0)$ 的均值和方差分别是多少（代入数值）？
- 令 $\bar{\alpha}_T < 0.01$ 为「完全噪声化」标准，估算线性调度 $\beta = 0.02$ 下需要多少步 T （用对数公式计算）。

解答 T-7.5.1

(a) 数值表：

t	$\bar{\alpha}_t = 0.98^t$
1	0.9800
5	$0.98^5 \approx 0.9039$
10	$0.98^{10} \approx 0.8171$
50	$0.98^{50} \approx 0.3642$
100	$0.98^{100} \approx 0.1326$

- (b) $t = 50$, $\bar{\alpha}_{50} \approx 0.3642$: 均值 $= \sqrt{0.3642}x_0 \approx 0.6035x_0$; 方差 $= (1 - 0.3642)I = 0.6358I$ （噪声标准差约 0.797）。

(c) 令 $0.98^T < 0.01$:

$$T > \frac{\ln 0.01}{\ln 0.98} = \frac{-4.605}{-0.0202} \approx 228.$$

约需 228 步。

T-7.5.2 【中 · 证明 · 分数函数与 epsilon-theta 等价关系】 设 $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon$, $\epsilon \sim \mathcal{N}(0, I)$ 。

- (a) 写出 $\log q(x_t|x_0)$ 的表达式 (高斯对数密度);
- (b) 对 x_t 求梯度 $\nabla_{x_t} \log q(x_t|x_0)$, 化简到 $-\frac{x_t - \sqrt{\bar{\alpha}_t}x_0}{1 - \bar{\alpha}_t}$;
- (c) 代入 $x_t - \sqrt{\bar{\alpha}_t}x_0 = \sqrt{1 - \bar{\alpha}_t}\epsilon$, 化简为 $-\frac{\epsilon}{\sqrt{1 - \bar{\alpha}_t}}$, 说明 $\epsilon_\theta(x_t, t) \approx \epsilon$ 等价于近似负分数函数;
- (d) 分数函数 $\nabla_{x_t} \log q_t(x_t)$ 的物理含义是什么 (一句话)? 去噪网络沿哪个方向移动?

解答 T-7.5.2

(a) $q(x_t|x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I)$, 故

$$\log q(x_t|x_0) = \text{const} - \frac{\|x_t - \sqrt{\bar{\alpha}_t}x_0\|^2}{2(1 - \bar{\alpha}_t)}.$$

(b)

$$\nabla_{x_t} \log q(x_t|x_0) = -\frac{x_t - \sqrt{\bar{\alpha}_t}x_0}{1 - \bar{\alpha}_t}.$$

(c) 代入 $x_t - \sqrt{\bar{\alpha}_t}x_0 = \sqrt{1 - \bar{\alpha}_t}\epsilon$:

$$\nabla_{x_t} \log q(x_t|x_0) = -\frac{\sqrt{1 - \bar{\alpha}_t}\epsilon}{1 - \bar{\alpha}_t} = -\frac{\epsilon}{\sqrt{1 - \bar{\alpha}_t}}.$$

若 $\epsilon_\theta(x_t, t) \approx \epsilon$, 则 $\frac{\epsilon_\theta}{\sqrt{1 - \bar{\alpha}_t}} \approx -\nabla_{x_t} \log q(x_t|x_0)$, 即网络输出近似了负分数函数。

(d) 分数函数 $\nabla_{x_t} \log q_t(x_t)$ 是在当前噪声状态 x_t 处, 概率密度增大最快的方向。去噪网络沿分数方向 (梯度上升方向) 移动, 等同于从噪声状态「爬坡」向数据流形靠近——每一步去噪都是向高概率区域移动一小步。

T-7.5.3 【难 · 判错 · DDPM 目标与分数匹配】 戊同学说: “DDPM 的训练目标 $\mathcal{L}_{\text{DDPM}} = \mathbb{E}[\|\epsilon - \epsilon_\theta(\cdot)\|^2]$ 是在最小化预测噪声的均方误差, 与分数匹配 (score matching) 没有关系, 只是一个简单的回归目标。”

- (a) 指出这个说法的错误：展示 $\epsilon_\theta(x_t, t)/\sqrt{1-\bar{\alpha}_t}$ 如何近似了 $-\nabla_{x_t} \log q_t(x_t)$ ，说明两者的联系；
- (b) 分数匹配的核心思想是「在每个噪声水平上估计对数密度的梯度」——用一句话解释为什么 DDPM 的噪声预测等价于多尺度的分数估计；
- (c) 若改用 $L_0 = \mathbb{E}[\|x_0 - \hat{x}_0(x_t, t)\|^2]$ （预测原始数据而非噪声）训练扩散模型，理论上可行吗？与 $\mathcal{L}_{\text{DDPM}}$ 相比有何优劣？

解答 T-7.5.3

- (a) 戊同学错误： $\epsilon_\theta(x_t, t)/\sqrt{1-\bar{\alpha}_t}$ 正是对 $-\nabla_{x_t} \log q_t(x_t)$ 的估计（见 T-7.5.2 (c)）。 $\mathcal{L}_{\text{DDPM}} = \mathbb{E}[\|\epsilon - \epsilon_\theta\|^2]$ 等价于最小化：在每个噪声水平 t 上的分数匹配损失 $\mathbb{E} \left[\left\| \nabla \log q_t + \epsilon_\theta / \sqrt{1-\bar{\alpha}_t} \right\|^2 / (1-\bar{\alpha}_t) \right]$ ，两者在最优解处完全等价。
- (b) 「多尺度分数估计」：连续时间分数匹配目标是对所有 $t \in [0, T]$ 和所有噪声水平 q_t 同时训练分数估计器；DDPM 通过离散化的 $t = 1, \dots, T$ 并随机采样实现了同样效果——本质上是在不同信噪比水平（不同 $\bar{\alpha}_t$ ）上同时监督分数估计，只是把「估计梯度」换成了等价的「预测噪声」形式。
- (c) 预测 x_0 (L_0) 理论上可行（等价于 x -prediction 参数化），且在 $\bar{\alpha}_t$ 大（轻度噪声）时数值更稳定（因为 x_0 的量级与 x_t 相近）；但在 $\bar{\alpha}_t$ 小（强噪声）时误差大。 $\mathcal{L}_{\text{DDPM}}$ （预测噪声）反之，在强噪声时更稳定。实践中，现代扩散模型（如 SDXL、Flux）使用 v -prediction（两者的线性组合），兼顾两个极端的数值稳定性。

公式 13 · 离散扩散吸收态边际分布

$$q(x_t|x_0) = \bar{\alpha}_t \delta_{x_t, x_0} + (1 - \bar{\alpha}_t) \delta_{x_t, M}$$

一句话直觉：在时刻 t ，每个 token 要么仍是原始 token（概率 $\bar{\alpha}_t$ ），要么已被 [MASK]（概率 $1 - \bar{\alpha}_t$ ）——没有中间状态。

在大模型里的位置：训练（loss 计算 / 梯度回传 / 数据-参数配比）

本组训练目标：代入 · 证明 · 工程

常见卡点：

- 吸收态不可逆：一旦变成 [MASK] 就永远是 [MASK] ($q(M \rightarrow x_0) = 0$)
- 后验 $q(x_{t-1}|x_t = M, x_0)$ 有两项：token 仍可能从 MASK 回到 x_0 （训练时已知 x_0 ），或仍是 MASK
- MDLM 目标是加权 MLM：仅对被 MASK 的位置求损失，权重 $|\alpha'_t|/\alpha_t$ 对噪声水平重要性加权

本组在练什么：吸收态离散扩散的边际分布归纳、后验推导（贝叶斯公式）、MDLM 目标与 MLM 的对应。做完应能回答：为什么 MDLM 的训练目标本质上是加权 MLM？

T-7.5.4 【中 · 证明 · 吸收态边际分布归纳与后验推导】

- (a) 用归纳法证明边际分布公式：假设 $q(x_{t-1}|x_0) = \bar{\alpha}_{t-1}\delta_{x_{t-1},x_0} + (1 - \bar{\alpha}_{t-1})\delta_{x_{t-1},M}$ ，通过全概率公式推出 $q(x_t|x_0)$ ；
- (b) 在 $x_t = M$ 的情形下，写出贝叶斯公式 $q(x_{t-1}|x_t = M, x_0) \propto q(x_t = M|x_{t-1}) \cdot q(x_{t-1}|x_0)$ ；对 $x_{t-1} \in \{x_0, M\}$ 分别计算各项，得到后验公式（公式 7.38）；
- (c) 在 $x_t \neq M$ 的情形下，说明为什么后验必然是 δ_{x_{t-1},x_0} （利用吸收态不可逆性）。

解答 T-7.5.4

(a) 归纳步：由全概率：

情形 $x_t = x_0$ ：只有 $x_{t-1} = x_0$ 贡献 ($q(x_0|x_0) = 1 - \beta_t$)，概率 = $(1 - \beta_t)\bar{\alpha}_{t-1} = \bar{\alpha}_t$ 。□

情形 $x_t = M$ ：来自 $x_{t-1} = x_0$ （概率 $\beta_t\bar{\alpha}_{t-1}$ ）或 $x_{t-1} = M$ （概率 $1 \cdot (1 - \bar{\alpha}_{t-1})$ ），总概率 = $\beta_t\bar{\alpha}_{t-1} + (1 - \bar{\alpha}_{t-1}) = 1 - (1 - \beta_t)\bar{\alpha}_{t-1} = 1 - \bar{\alpha}_t$ 。□

(b) 贝叶斯公式 ($x_t = M$)： $q(x_{t-1}|x_t = M, x_0) \propto q(x_t = M|x_{t-1}) \cdot q(x_{t-1}|x_0)$ 。

各项计算：

- $x_{t-1} = x_0$ ： $q(x_t = M|x_{t-1} = x_0) = \beta_t = 1 - \bar{\alpha}_t/\bar{\alpha}_{t-1}$ ， $q(x_{t-1} = x_0|x_0) = \bar{\alpha}_{t-1}$ ；未归一化权重 = $\beta_t\bar{\alpha}_{t-1} = \bar{\alpha}_{t-1} - \bar{\alpha}_t$ ；
- $x_{t-1} = M$ ： $q(x_t = M|x_{t-1} = M) = 1$ ， $q(x_{t-1} = M|x_0) = 1 - \bar{\alpha}_{t-1}$ ；未归一化权重 = $1 - \bar{\alpha}_{t-1}$ ；
- 归一化常数 = $(\bar{\alpha}_{t-1} - \bar{\alpha}_t) + (1 - \bar{\alpha}_{t-1}) = 1 - \bar{\alpha}_t$ 。

归一化后即得公式 7.38。□

- (c) 若 $x_t \neq M$ ，该 token 在时刻 t 未被 MASK，则由吸收态不可逆性（一旦 MASK 就永远是 MASK）， $t-1$ 时刻也必然不是 MASK，故 $x_{t-1} = x_0$ （唯一可能），后验为 δ_{x_{t-1},x_0} 。

T-7.5.5 【中·工程·扩散 LLM 最新进展：GLM-Diffusion / SEDD / LLaDA】 离散扩散语言模型在 2024–2025 年有几个重要进展。

- (a) LLaDA (2025) 将 MDLM 框架扩展到 8B 参数规模。从训练目标角度，它的核心是加权 MLM 损失：仅对 x_t 中被 MASK 的位置 i 计算 $\log p_\theta(x_0^{(i)}|x_t)$ ，权重为 $|\alpha'_t|/\alpha_t$ 。说明为什么这个目标与标准 MLM（如 BERT）在本质上的区别在于「多尺度噪声水平加权」；
- (b) 扩散模型在「并行解码」上的优势：自回归生成需 L 步，每步产生 1 个 token；扩散模型用 T 步并行解码全序列。设 $L = 512, T = 128$ ，推理步数比约为多少？这在什么条件下带来实际速度提升（考虑每步的计算量）；
- (c) LLaDA 实验中，扩散模型在「逆向诅咒（Reversal Curse）」任务上优于自回归模型。用一句话解释：扩散模型为什么在结构上没有方向性偏差？

解答 T-7.5.5

- (a) LLaDA 与标准 MLM 的区别：标准 MLM（如 BERT）随机 MASK 15% 位置，用固定权重（或无权重）计算交叉熵；MDLM 对所有可能的噪声水平 t （从轻度 MASK

到全 MASK) 训练, 并用 $|\alpha'_t|/\alpha_t$ (噪声速率/当前保留率) 加权——本质是在不同「信息破坏程度」下的 MLM 目标的加权平均, 更接近最大似然的 ELBO 推导, 有严格的概率意义。

- (b) 设 $L = 512, T = 128$: 推理步数比 $= 512/128 = 4$, 扩散模型快约 4 倍。实际速度提升的条件: 每步的计算量相近 (即扩散模型的去噪网络与 AR 的前向传播计算量相当), 且 $T < L$ 。若扩散模型每步用了更大的模型 (如双向 Transformer, 可比 AR 的因果 Transformer 贵约 2 倍), 实际加速比减半。
- (c) 扩散模型以全序列受损版本为条件, 所有位置同时去噪, 没有左到右的方向性依赖——模型「看到」的是整个序列的 MASK 版本, 对正向和逆向查询一视同仁, 不存在训练时的方向性偏差。

工程批注: T-7.5.5 涉及扩散 LLM 的最新进展。截至 2025 年初, 代表性工作包括: (1) SEDD (Score Entropy Discrete Diffusion, Lou et al. 2024) ——基于分数熵的离散扩散, 理论上比吸收态扩散更一般; (2) GLM-Diffusion (Du et al. 2024) ——将 GLM 的自回归生成与扩散迭代精化结合; (3) LLaDA (Nie et al. 2025) ——8B 参数, 在 MT-Bench 和 GSM8K 上与 LLaMA-3-8B 相当, 是首个「与主流 AR 模型性能可比」的离散扩散 LLM, 证明了离散扩散 LLM 在大规模下的可行性。当前限制: 推理速度 (需 $T = 128-256$ 步)、对 few-shot prompt 的响应不如 AR 流畅, 以及训练数据需求偏高。

公式 14 · MDLM 训练目标 (加权 MLM)

$$\mathcal{L}_{\text{MDLM}} = -\mathbb{E}_{t, x_0} \left[\frac{|\alpha'_t|}{\alpha_t} \sum_{i: x_t^{(i)} = M} \log p_{\theta}(x_0^{(i)} | x_t) \right]$$

一句话直觉: 对不同噪声水平的 MLM 损失做加权平均, 权重正比于该水平的 MASK 速率与当前保留率之比。

在大模型里的位置: 训练 (loss 计算 / 梯度回传 / 数据-参数配比)

本组训练目标: 变形 · 工程 · 反例

常见卡点:

- 求和只对被 MASK 的位置 i ($x_t^{(i)} = M$), 未被 MASK 的位置对应确定性分布, 不贡献损失
- 权重 $|\alpha'_t|/\alpha_t$ 在 MASK 速率快的时刻更大 (重要性更高)
- AR 模型的 CE loss 与此目标的区别: AR 逐 token 左到右, MDLM 对全序列所有时刻并行

本组在练什么: MDLM 目标与 AR 的对比, 以及并行解码 vs. 自回归的速度-质量权衡。做完应能回答: 为什么 $T = 1$ 的单步扩散解码质量很差, 而 $T = 128$ 步接近 AR 质量?

T-7.5.6 【中 · 变形 · DDPM 与 MDLM 目标函数对比】

- (a) 写出 DDPM 目标 $\mathcal{L}_{\text{DDPM}}$ (公式 7.34), 用语言解释: 模型预测什么, 从什么输入预测, 误差如何衡量?
- (b) 写出 MDLM 目标 (公式 7.39), 用语言解释: 求和在哪些位置, 权重 $|\alpha'_t|/\alpha_t$ 的物理含义;
- (c) 用一句话点出两者的深层类比 (高斯加噪 vs. MASK 吸收, 均是「部分破坏 x_0 , 从受损版本学习恢复」);
- (d) 判错: 己同学说” MDLM 与 BERT 的预训练目标完全相同, 都是 MLM”。指出两者的关键区别 (至少一点)。

解答 T-7.5.6

- (a) DDPM 目标:

$$\mathcal{L}_{\text{DDPM}} = \mathbb{E}_{t, x_0, \epsilon} \left[\left\| \epsilon - \epsilon_\theta \left(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t \right) \right\|^2 \right].$$

含义: 从 x_0 和时刻 t 出发, 把 x_0 加噪到 x_t , 让网络 ϵ_θ 从带噪输入 (x_t, t) 预测被加入的高斯噪声 ϵ , 用均方误差训练。

- (b) MDLM 目标 (公式 7.39): 对所有被 MASK 的位置 i ($x_t^{(i)} = M$) 计算预测原始 token 的对数概率, 然后用权重 $|\alpha'_t|/\alpha_t$ 在不同噪声水平 t 上加权平均。权重含义: $|\alpha'_t|$ 是 MASK 速率 (信息变化快的时刻), α_t 是当前保留率; 比值大的时刻 (信息快速丢失) 权重高, 信息平稳的阶段权重低。
- (c) 类比: DDPM 在连续空间「部分破坏」(加高斯噪声), MDLM 在离散 token 空间「部分破坏」(随机 MASK), 两者都是「带噪监督的去噪」, 差别只是噪声空间 (连续 $\mathbb{R}^d$ vs. 离散词表 $\{1, \dots, V\}$)。
- (d) 判错: MDLM 与 BERT-MLM 的关键区别: ① MDLM 有严格的概率推导 (ELBO), BERT 的 MLM 是启发式自监督; ② MDLM 训练时对所有噪声水平 t 采样, 覆盖从轻度到重度 MASK 的全谱, 而 BERT 固定 MASK 率约 15%; ③ MDLM 有噪声水平加权 ($|\alpha'_t|/\alpha_t$), BERT 无; ④ MDLM 在推理时做迭代去噪, BERT 是判别式模型 (不做生成)。

T-7.5.7 【难 · 反例 · 并行解码 vs. AR 的信息论分析】

- (a) 设 $T = 1$ (单步去噪), x_T 几乎全是 [MASK] ($\bar{\alpha}_T \approx 0$)。从信息论角度, x_T 包含多少关于 x_0 的信息? 这对单步生成质量意味着什么?
- (b) 自回归生成 $L = 512$ 步, 每步 $O(L^2)$ (标准注意力), 总时间 $O(L^3)$ 。扩散模型用 $T = 128$ 步并行, 每步 $O(L^2)$, 总时间 $O(TL^2)$ 。当 $T < L$ 时, 扩散推理更快的条件是什么?
- (c) AR 模型训练时只接触 $p(x^i | x^1, \dots, x^{i-1})$ (严格因果), 而扩散模型以全序列受损版本为条件。解释这一区别为什么使得扩散模型在「逆向诅咒」类型任务上具有理论优势 (用训练时「见过的信息对称性」来论证)。

解答 T-7.5.7

- (a) 当 $T = 1$, $\bar{\alpha}_1 \approx 0$ 时, $x_1 \approx \delta_{x_1, M}$ (几乎全是 [MASK])。互信息 $I(x_0; x_1) \approx 0$ —— x_1 对 x_0 几乎无信息 (所有序列的 x_1 都是相同的全 MASK 字符串)。因此 $p_\theta(x_0|x_1) \approx p_\theta(x_0)$ (无条件分布), 单步生成质量极差, 退化为无条件随机采样。
- (b) 扩散模型更快的条件: $O(TL^2) < O(L^3) \Leftrightarrow T < L$ 。当 $T = 128, L = 512, T < L$ 成立, 扩散模型推理步数更少 (128 vs. 512 步), 每步计算量相当, 总时间约快 4 倍。
- (c) AR 训练时, 模型只接触 $p(x^i|x^{<i})$ ——严格从左到右的因果分解, 从未见过「已知右侧内容推左侧」的训练样本, 故对逆向查询系统性失败。扩散模型训练目标是 $p_\theta(x_0|x_t)$, 其中 x_t 是全序列的受损版本, 没有位置顺序约束——模型在训练时对所有位置对称建模, 正向「A 是 B 的父亲」和逆向「B 是谁的儿子」从模型角度是同一类问题 (都是从部分遮蔽的全序列中还原 token), 不存在训练时的方向性偏差。

T-7.5.8 【难 · 工程 · 离散扩散的后验推导完整版】 完整证明吸收态离散扩散的后验公式 (公式 7.38 的 $x_t = M$ 情形):

$$q(x_{t-1}|x_t = M, x_0) = \frac{(1 - \bar{\alpha}_{t-1})\delta_{x_{t-1}, M} + (\bar{\alpha}_{t-1} - \bar{\alpha}_t)\delta_{x_{t-1}, x_0}}{1 - \bar{\alpha}_t}$$

- (a) 写出贝叶斯公式, 分别计算 $q(x_{t-1} = x_0|x_0) = \bar{\alpha}_{t-1}$ 和 $q(x_{t-1} = M|x_0) = 1 - \bar{\alpha}_{t-1}$;
- (b) 计算条件转移: $q(x_t = M|x_{t-1} = x_0) = \beta_t = 1 - \bar{\alpha}_t/\bar{\alpha}_{t-1}$, $q(x_t = M|x_{t-1} = M) = 1$;
- (c) 将 (a)(b) 代入贝叶斯公式, 得到未归一化的分子;
- (d) 验证归一化常数等于 $q(x_t = M|x_0) = 1 - \bar{\alpha}_t$, 完成归一化, 得出公式。

解答 T-7.5.8

- (a) 由边际分布 (公式 7.37):

$$q(x_{t-1} = x_0|x_0) = \bar{\alpha}_{t-1}, \quad q(x_{t-1} = M|x_0) = 1 - \bar{\alpha}_{t-1}.$$

- (b) 条件转移:

$$q(x_t = M|x_{t-1} = x_0) = \beta_t = 1 - \frac{\bar{\alpha}_t}{\bar{\alpha}_{t-1}}, \quad q(x_t = M|x_{t-1} = M) = 1.$$

(吸收态一旦进入不会退出: $q(M \rightarrow M) = 1$ 。)

- (c) 贝叶斯公式 (未归一化分子):

$$\begin{aligned} \cdot x_{t-1} = x_0: & \text{ 权重 } \propto \beta_t \cdot \bar{\alpha}_{t-1} = \left(1 - \frac{\bar{\alpha}_t}{\bar{\alpha}_{t-1}}\right) \bar{\alpha}_{t-1} = \bar{\alpha}_{t-1} - \bar{\alpha}_t; \\ \cdot x_{t-1} = M: & \text{ 权重 } \propto 1 \cdot (1 - \bar{\alpha}_{t-1}) = 1 - \bar{\alpha}_{t-1}. \end{aligned}$$

(d) 归一化常数 $= (\bar{\alpha}_{t-1} - \bar{\alpha}_t) + (1 - \bar{\alpha}_{t-1}) = 1 - \bar{\alpha}_t = q(x_t = M|x_0)$ 。

归一化后：

$$q(x_{t-1} = x_0|x_t = M, x_0) = \frac{\bar{\alpha}_{t-1} - \bar{\alpha}_t}{1 - \bar{\alpha}_t}, \quad q(x_{t-1} = M|x_t = M, x_0) = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}.$$

写成 delta 形式即公式 7.38 ($x_t = M$ 情形)。□

工程批注：T-7.5.8 的后验公式是 MDLM 训练效率的关键。由于吸收态的特殊结构，后验只有两项 ($x_{t-1} = x_0$ 或 $x_{t-1} = M$)，而非对 V 个 token 的全概率分布——这使得 ELBO 的 KL 散度项可以解析计算，无需蒙特卡洛估计，大幅提升训练稳定性。对比连续扩散 (DDPM 后验是高斯，也可解析)，离散扩散能保留这种优雅的解析性，根本原因是吸收态的二值结构 (MASK 或原始 token，没有第三种状态)。LLaDA 正是利用这一性质把训练损失简化为纯 MLM 形式，使得整个训练 pipeline 与标准 LLM 几乎完全兼容。

【做完自检】

- DDPM 闭式边际分布 $q(x_t|x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I)$ 使得训练可以「单步采样」任意 t 时刻，而无需逐步走 Markov 链。为什么？
- 离散扩散 (MDLM) 训练目标与 BERT 的 MLM 预训练目标有何本质区别？权重 $|\alpha'_t|/\alpha_t$ 起什么作用？
- 扩散语言模型如何从理论上消除「逆向诅咒」？与自回归的方向性训练相比，哪个信息对称性更好？

§ 7.6 习题：Mamba、线性注意力与 RNN 的统一视角

导读：本节核心是「广义线性递推统一序列模型」—— $\mathbf{S}_t = \mathbf{G}_t \odot \mathbf{S}_{t-1} + \mathbf{k}_t^\top \mathbf{v}_t$, $\mathbf{o}_t = \mathbf{S}_t \mathbf{q}_t$ ，不同门控机制对应不同架构；Mamba-2 的 SSD 对偶实现了递推计算与矩阵乘法的等价切换。五题分别对应：A (广义递推推导)、B (门控机制辨析)、C (SSD 对偶数值计算)、D (GLA 低秩约束分析)、E (统一视角的边界评判)。

题1【轻·轻推导·广义线性递推的前向展开】 导读：广义线性递推 $\mathbf{S}_t = \mathbf{G}_t \odot \mathbf{S}_{t-1} + \mathbf{k}_t^\top \mathbf{v}_t$ 描述了一个随时间演化的状态矩阵，不同时刻的「贡献」以指数衰减（由 $\mathbf{G}$ 的累积乘积决定）进入当前状态。

- 设 $\mathbf{S}_0 = \mathbf{0}$ ，将 $\mathbf{S}_T = \mathbf{G}_T \odot \mathbf{S}_{T-1} + \mathbf{k}_T^\top \mathbf{v}_T$ 递归展开，写出 $\mathbf{S}_T$ 关于所有历史 $\{\mathbf{k}_t^\top \mathbf{v}_t\}_{t=1}^T$ 的显式求和表达式（用累积门控乘积表示）。
- 在线性注意力 ($\mathbf{G}_t = \mathbf{1}$, 全 1 矩阵) 的特殊情形下，化简 (1) 的结果，并说明输出 $\mathbf{o}_T = \mathbf{S}_T \mathbf{q}_T$ 如何对应标准线性注意力的矩阵形式。
- 在 RetNet ($\mathbf{G}_t = \gamma \mathbf{1}$, $0 < \gamma < 1$) 下，历史时刻 t 对 $\mathbf{S}_T$ 的贡献有什么衰减规律？这与 Transformer 的标准注意力在「长程依赖能力」上的本质差异是什么？

教学注：广义线性递推是 2023–2024 年序列模型研究的核心统一框架，将 RNN、线性

注意力、RetNet、GLA、Mamba 全部纳入同一方程，使「门控机制的差异」成为可比较的设计选择。

陷阱：线性注意力中 $\mathbf{G}_t = \mathbf{1}$ 使历史贡献不衰减，这在理论上意味着无限长上下文，但实践中数值溢出和精度问题使之难以处理非常长的序列。

题2【中·概念辨析·门控机制的设计空间】 导读：不同架构对应广义线性递推中门控矩阵 $\mathbf{G}_t$ 的不同参数化选择，每种选择在「表达能力」、「计算效率」、「长程记忆」三个维度上有不同的权衡。

完成以下对比表，并回答后续问题：

架构	$\mathbf{G}_t$ 形式	参数依赖输入	长程记忆	典型计算模式
线性注意力	$\mathbf{1}$	否	无衰减	?
RetNet	$\gamma \mathbf{1} \ (0 < \gamma < 1)$	否	?	?
GLA	$\alpha_t \beta_t^\top$ (低秩)	是	?	?
Mamba	$e^{\Delta_t A}$ (连续-离散化)	是	?	?

(1) 填写表格中的空白项（「?」位置）。

(2) Mamba 的门控 $\mathbf{G}_t = e^{\Delta_t A}$ 来自连续状态空间方程的离散化， $\Delta_t > 0$ 是输入依赖的时间步长。解释： Δ_t 较大时， $\mathbf{G}_t$ 中各项的量级如何变化，这对序列模型的「选择性记忆」能力有何影响？

(3) GLA (Gated Linear Attention) 的门控 $\mathbf{G}_t = \alpha_t \beta_t^\top$ 是秩-1 矩阵。这一低秩约束的代价和收益分别是什么？

教学注：「参数依赖输入」(input-dependent gates) 是 Mamba 区别于 RetNet 的关键——后者的衰减系数 γ 固定，无法根据内容选择性地保留或遗忘；输入依赖使模型具备了「选择性扫描」(selective scan) 的能力。

陷阱：「无衰减」($\mathbf{G}_t = \mathbf{1}$) 不等于「记忆所有历史」——状态矩阵 $\mathbf{S}_t$ 的维度是有限的，当历史项数量超过状态维度时，仍会发生信息压缩和丢失，只是不是显式的指数衰减。

题3【中·中计算·Mamba-2 SSD 对偶的数值验证】 导读：Mamba-2 的 Structured State Space Duality (SSD) 将序列递推计算等价地重写为半分离矩阵乘法，半分离矩阵的元素由 $M_{ij} = c_i \left(\prod_{t=j+1}^i \alpha_t \right) \beta_j \cdot \mathbf{1}_{i \geq j}$ 给出。这一对偶允许在不同计算条件下选择最优算法。

设序列长度 $T = 4$ ，标量化 (1D 状态) 情形， $\alpha = (\alpha_1, \alpha_2, \alpha_3, \alpha_4) = (0.9, 0.8, 0.7, 0.6)$ ， $\beta = (1, 1, 1, 1)$ ， $c = (1, 1, 1, 1)$ 。

(1) 写出 4×4 半分离矩阵 M 的所有元素（精确到四位小数）。

(2) 设输入向量 $\mathbf{v} = (1, 0, 0, 0)^\top$ （只有第一个位置有值），计算输出 $\mathbf{o} = M\mathbf{v}$ 。

(3) 用递推方式验证 (2) 的结果: 从 $S_0 = 0$ 出发, 递推 $S_t = \alpha_t S_{t-1} + \beta_t v_t$, $o_t = c_t S_t$, 计算 $o = (o_1, o_2, o_3, o_4)^\top$, 与 (2) 的结果对比。

教学注: SSD 对偶的意义在于: 当序列较短时, 矩阵乘法形式 ($O(T^2 d)$) 可用 GPU 的 tensor core 高度并行化; 当序列较长时, 递推形式 ($O(T d^2)$ 每步) 节省内存。Mamba-2 通过分块 (chunking) 动态选择模式, 实现 $2-8\times$ 的实际加速。

陷阱: 半分离矩阵是下三角矩阵 ($\mathbf{1}_{i \geq j}$), 注意 $i = j$ 时 $\prod_{t=j+1}^i \alpha_t$ 是空积 (empty product) $= 1$, 不要误写为 0。

题 4【中·辨析·GLA 的低秩约束与线性注意力的联系】 导读: GLA (Gated Linear Attention) 通过对门控矩阵施加秩-1 约束 $\mathbf{G}_t = \alpha_t \beta_t^\top$, 在线性注意力 ($\mathbf{G} = \mathbf{1}$, 满秩退化) 和 Mamba ($\mathbf{G} = e^{\Delta A}$, 满秩) 之间建立了一个桥梁。

(1) 证明: 当 $\alpha_t = \mathbf{1}$ (全 1 向量) 且 $\beta_t = \mathbf{1}$ (全 1 向量) 时, $\mathbf{G}_t = \alpha_t \beta_t^\top = \mathbf{1}\mathbf{1}^\top$ 是全 1 矩阵 (不是 $\mathbf{1}$ 的单位矩阵), GLA 退化为哪种架构? 说明为什么这不严格等于线性注意力的 $\mathbf{G} = \mathbf{1}$ (单位矩阵 vs 全 1 矩阵)。

(2) GLA 的门控 $\alpha_t, \beta_t \in \mathbb{R}^d$, 低秩约束 $\mathbf{G}_t = \alpha_t \beta_t^\top \in \mathbb{R}^{d \times d}$ 的秩最多为 1。与满秩 $\mathbf{G}_t$ (如 Mamba 的 $e^{\Delta A}$, 一般为满秩) 相比, 秩-1 约束减少了多少参数? (用 d 表示)

(3) 从表达能力角度, 秩-1 门控 $\mathbf{G}_t = \alpha_t \beta_t^\top$ 能捕捉哪类状态-输入交互? 哪类交互无法捕捉 (举一具体例子)?

教学注: GLA 的低秩约束是「效率-表达能力」权衡的典型例子——秩-1 使门控可以分解为两个独立的 d 维向量的外积, 计算复杂度从 $O(d^2)$ 降至 $O(d)$, 但失去了状态维度间的耦合信息。

陷阱: $\mathbf{G}_t = \alpha_t \beta_t^\top$ 是外积 (rank-1 矩阵), $\|\mathbf{G}_t\|_F^2 = \|\alpha_t\|^2 \|\beta_t\|^2$, 不要误解为 Hadamard 乘积或逐元素操作。

题 5【重·重评判·统一视角的解释力与边界】 导读: 「广义线性递推统一框架」将多种架构纳入同一方程, 提供了强大的设计空间分析工具。本题评估这一统一视角的解释力上限和下限。

(1) 「统一框架」的解释力评估: 对以下架构特性, 指出广义线性递推框架能否提供统一的定量分析:

- (A) 不同架构在相同参数量下的语言建模困惑度 (perplexity) 对比
- (B) 不同架构对「长文档理解」任务的能力差异
- (C) 不同架构训练时的数值稳定性差异
- (D) Mamba vs Transformer 在自回归生成时的显存占用

(2) 广义线性递推框架不能统一什么? 列出至少两类在此框架外但对序列模型性能有重要影响因素。

(3) 判断以下论断:

「广义线性递推统一框架证明了 Mamba 和 Transformer 是等价的——既然都

可以写成线性递推，它们的表达能力相同。」

指出该论断的核心谬误所在（不超过4句）。

(4) 从「统一视角」到「选择最优架构」，还需要哪些额外信息？(3-4条)

教学注：统一框架的价值在于提供**分析语言**（用同一套符号比较不同架构的设计选择），而非证明所有架构等价；能在同一框架内表达，不意味着在所有任务上性能相同。

陷阱：(3)的谬误是「形式等价蕴含能力等价」——线性递推是计算**形式**的统一，不是**计算能力**的统一；线性注意力 ($\mathbf{G} = \mathbf{1}$) 和标准 Transformer (softmax 注意力) 在表达能力上有已知的理论差距（后者可以计算任意精度的相似度权重，前者不能）。

解答 §7.6

T-7.6.1 【广义线性递推的前向展开】 (1) 递归展开：

定义累积门控乘积 $\Gamma_{s:t} = \odot_{\tau=s+1}^t \mathbf{G}_\tau$ (从时刻 s 到 t 的逐元素累积乘积), $\Gamma_{t:t} = \mathbf{1}$ (空积)。

递推展开：

$$\mathbf{s}_T = \sum_{t=1}^T \Gamma_{t:T} \odot (\mathbf{k}_t^\top \mathbf{v}_t)$$

其中 $\Gamma_{t:T} = \mathbf{G}_{t+1} \odot \mathbf{G}_{t+2} \odot \cdots \odot \mathbf{G}_T$ ($t = T$ 时为 $\mathbf{1}$)。

(2) 线性注意力特例：

$\mathbf{G}_t = \mathbf{1}$ 时, $\Gamma_{t:T} = \mathbf{1}$ 对所有 t , 故

$$\mathbf{s}_T = \sum_{t=1}^T \mathbf{k}_t^\top \mathbf{v}_t$$

输出 $\mathbf{o}_T = \mathbf{s}_T \mathbf{q}_T = \left(\sum_{t=1}^T \mathbf{k}_t^\top \mathbf{v}_t \right) \mathbf{q}_T = \sum_{t=1}^T \mathbf{k}_t (\mathbf{v}_t \cdot \mathbf{q}_T)$,

对应线性注意力矩阵形式: $\mathbf{O} = (\mathbf{K}^\top \mathbf{V}) \mathbf{Q}$ (将 $\mathbf{K}, \mathbf{V}, \mathbf{Q}$ 按时间步堆叠), 与标准线性注意力完全一致。

(3) RetNet 的衰减规律：

$\mathbf{G}_t = \gamma \mathbf{1}$ 时, $\Gamma_{t:T} = \gamma^{T-t} \mathbf{1}$, 时刻 t 的贡献以 γ^{T-t} 指数衰减。

本质差异: Transformer 标准注意力通过 softmax 计算动态权重, 每个位置的注意力权重由内容相似度决定, 原则上可以对任意远的位置赋予高权重 (无固定衰减); RetNet 的衰减 γ^{T-t} 是固定的、内容无关的, 无法选择性地记住距离较远但重要的内容——这是线性/RetNet 与 Transformer 在长程依赖建模上的本质差距。

Sanity check: (2) 的矩阵形式 $(\mathbf{K}^\top \mathbf{V}) \mathbf{Q}$ 正是线性注意力论文 (Katharopoulos et al., 2020) 中的核心公式, 展开与文献一致。

T-7.6.2 【门控机制的设计空间】 (1) 完整表格：

架构	G_t 形式	参数依赖输入	长程记忆	典型计算模式
线性注意力	$\mathbf{1}$	否	无衰减 ($\gamma = 1$)	递推或矩阵乘法等价
RetNet	$\gamma \mathbf{1}$ ($0 < \gamma < 1$)	否	指数衰减 (固定 γ)	递推 (推理) / 并行 (训练)
GLA	$\alpha_t \beta_t^\top$ (低秩)	是	内容依赖衰减	分块递推
Mamba	$e^{\Delta_t A}$ (连续-离散化)	是	选择性衰减	并行扫描 (CUDA kernel)

(2) Mamba 选择性记忆：

Δ_t 较大时, $e^{\Delta_t A}$ 中各项 (A 负定, 特征值为负实数) 趋向 0 ($e^{\Delta_t \lambda_i} \rightarrow 0$ 当 $\Delta_t |\lambda_i| \gg 1$), 即历史状态被「遗忘」得更快; Δ_t 较小时遗忘慢, 历史保留更多。由于 Δ_t 依赖当前输入, 模型可以对「信息量大的 token」使用小 Δ_t (慢遗忘, 长记忆)、对「无信息 token」使用大 Δ_t (快遗忘), 实现内容驱动的选择性记忆。

(3) 低秩约束的代价与收益：

收益：计算量从 $O(d^2)$ (存储或应用满秩矩阵) 降至 $O(d)$ (存储两个 d 维向量 α_t, β_t); 与线性注意力的递推形式兼容, 保持硬件友好的 IO 模式。

代价：秩-1 门控无法在状态不同维度之间引入耦合—— $(G_t \odot S_{t-1})_{ij} = \alpha_t^{(i)} \beta_t^{(j)} S_{t-1}^{(ij)}$, 每个状态元素的衰减系数可以不同, 但不能让第 i 维的衰减依赖第 j 维的当前值 (无跨维度信息流)。

Sanity check: 表格四行的「参数依赖输入」列中, 线性注意力和 RetNet 为「否」, GLA 和 Mamba 为「是」, 这正是 Mamba 系列架构相对 RetNet 的核心进步。

T-7.6.3 【Mamba-2 SSD 对偶的数值验证】 (1) 半分离矩阵计算：

$$M_{ij} = c_i \left(\prod_{t=j+1}^i \alpha_t \right) \beta_j \cdot \mathbf{1}_{i \geq j}, \quad c = \beta = \mathbf{1}, \quad \alpha = (0.9, 0.8, 0.7, 0.6).$$

$$\text{空积 } (i = j): \prod_{t=j+1}^j = 1.$$

计算各元素：

- $M_{11} = 1 \cdot 1 \cdot 1 = 1.0000$ (空积)
- $M_{21} = 1 \cdot \alpha_2 \cdot 1 = 0.8000$
- $M_{22} = 1 \cdot 1 \cdot 1 = 1.0000$
- $M_{31} = 1 \cdot \alpha_2 \alpha_3 \cdot 1 = 0.8 \times 0.7 = 0.5600$
- $M_{32} = 1 \cdot \alpha_3 \cdot 1 = 0.7000$
- $M_{33} = 1 \cdot 1 \cdot 1 = 1.0000$
- $M_{41} = 1 \cdot \alpha_2 \alpha_3 \alpha_4 \cdot 1 = 0.8 \times 0.7 \times 0.6 = 0.3360$

- $M_{42} = 1 \cdot \alpha_3 \alpha_4 \cdot 1 = 0.7 \times 0.6 = 0.4200$
- $M_{43} = 1 \cdot \alpha_4 \cdot 1 = 0.6000$
- $M_{44} = 1 \cdot 1 \cdot 1 = 1.0000$

$$M = \begin{pmatrix} 1.0000 & 0 & 0 & 0 \\ 0.8000 & 1.0000 & 0 & 0 \\ 0.5600 & 0.7000 & 1.0000 & 0 \\ 0.3360 & 0.4200 & 0.6000 & 1.0000 \end{pmatrix}$$

(2) 矩阵乘法:

$\mathbf{v} = (1, 0, 0, 0)^\top$, $\mathbf{o} = M\mathbf{v} = M$ 的第一列 $= (1.0000, 0.8000, 0.5600, 0.3360)^\top$ 。

(3) 递推验证:

- $t = 1$: $S_1 = \alpha_1 \cdot 0 + \beta_1 v_1 = 0.9 \cdot 0 + 1 \cdot 1 = 1.0000$, $o_1 = c_1 S_1 = 1.0000$
- $t = 2$: $S_2 = \alpha_2 S_1 + \beta_2 v_2 = 0.8 \times 1 + 1 \times 0 = 0.8000$, $o_2 = 0.8000$
- $t = 3$: $S_3 = \alpha_3 S_2 + \beta_3 v_3 = 0.7 \times 0.8 + 0 = 0.5600$, $o_3 = 0.5600$
- $t = 4$: $S_4 = \alpha_4 S_3 + \beta_4 v_4 = 0.6 \times 0.56 + 0 = 0.3360$, $o_4 = 0.3360$

$\mathbf{o} = (1.0000, 0.8000, 0.5600, 0.3360)^\top$, 与 (2) 完全一致。■

Sanity check: 递推与矩阵乘法给出完全相同的结果, 验证了 SSD 对偶的正确性; 注意 M_{i1} 的值正好等于 $\prod_{t=2}^i \alpha_t$ (从 α_2 开始的累积乘积), 数值模式清晰。

T-7.6.4 【GLA 的低秩约束与线性注意力的联系】 (1) 退化分析:

$\mathbf{G}_t = \alpha_t \beta_t^\top$, 当 $\alpha_t = \beta_t = \mathbf{1}$ (d 维全 1 向量) 时, $\mathbf{G}_t = \mathbf{1}\mathbf{1}^\top$, 这是全 1 矩阵 (每个元素均为 1)。

广义线性递推变为 $\mathbf{S}_t = (\mathbf{1}\mathbf{1}^\top) \odot \mathbf{S}_{t-1} + \mathbf{k}_t^\top \mathbf{v}_t = \mathbf{S}_{t-1} + \mathbf{k}_t^\top \mathbf{v}_t$ (因为 $\mathbf{1}\mathbf{1}^\top \odot \mathbf{S}_{t-1} = \mathbf{S}_{t-1}$ 仅当 $\mathbf{S}_{t-1}$ 的所有元素乘以 1, 实际上 $(\mathbf{1}\mathbf{1}^\top)_{ij} = 1$ 对所有 i, j , 所以 Hadamard 积结果是 $\mathbf{S}_{t-1}$ 自身), 退化为线性注意力的无衰减递推。

严格区别: 线性注意力的 $\mathbf{G}_t = \mathbf{I}$ 通常指单位矩阵 (identity, $\mathbf{G}_t = \mathbf{I}$, Hadamard 乘以 $\mathbf{I}$ 等价于不改变), 而 GLA 退化的 $\mathbf{G}_t = \mathbf{1}\mathbf{1}^\top$ 是全 1 矩阵, 两者对角线元素相同 (均为 1) 但非对角元素不同 (全 1 矩阵为 1, 单位矩阵为 0) —— 在 Hadamard 乘法下, 全 1 矩阵与状态的乘积保留所有元素, 而单位矩阵只保留对角元素。

(2) 参数减少量:

满秩 $\mathbf{G}_t \in \mathbb{R}^{d \times d}$ 需要 d^2 个参数 (作为自由参数)。

秩-1 $\mathbf{G}_t = \alpha_t \beta_t^\top$ 只需 $2d$ 个参数 (d 维 α_t 加 d 维 β_t)。

减少量: $d^2 - 2d = d(d - 2)$, 当 $d \gg 2$ 时约减少 $d^2 - 2d \approx d^2$ 个参数, 即参数量降至 $O(d)$ 而非 $O(d^2)$ 。

(3) 表达能力分析:

秩-1 门控能捕捉的: 每个状态维度 i 的衰减率 $\alpha_t^{(i)}$ 可以独立变化 (维度级别的选择性衰减), 同时每个维度接收新信息的权重 $\beta_t^{(j)}$ 也独立可变; 这已经比 RetNet 的固定 γ 灵活很多。

无法捕捉的：跨维度耦合。例如「当第 3 维度的状态值较高时，降低第 7 维度的衰减率」——这需要 G_t 中 (3, 7) 位置的非零非分解元素，秩-1 矩阵无法表达任意的 (i, j) 耦合。

Sanity check：参数减少量 $d^2 - 2d$ 对 $d = 64$ 时约为 $4096 - 128 = 3968$ ，降幅约 97%；这正是 GLA 的高效来源。

T-7.6.5 【统一视角的解释力与边界】 (1) 解释力评估：

- (A) **能**（有限制）：广义线性递推框架通过比较不同 G_t 的表达能力，可以给出困惑度差异的**定性**预测（表达能力更强的架构通常困惑度更低），但精确数值需要实验。
- (B) **部分能**：对长程依赖能力，框架可以定量分析历史衰减率（ G_t 的谱半径），但实际长文档理解还依赖训练数据分布、位置编码等框架外因素。
- (C) **不能**：数值稳定性依赖梯度流的具体性质（梯度消失/爆炸）、激活函数、归一化层等，不在广义线性递推的状态更新方程中体现。
- (D) **能**：Mamba 推理时每步只需 $O(d^2)$ 状态，固定大小；Transformer 需要 KV-cache，随序列长度线性增长——这可以从递推（有界状态）vs 注意力（累积 KV）的框架差异直接推断。

(2) 框架外的重要因素：

① 非线性激活函数和归一化层（LayerNorm、RMSNorm）对最终性能有重要影响，不在线性递推框架内；② 位置编码（RoPE、ALiBi）决定了序列位置信息的引入方式，对长序列泛化至关重要，框架中未体现；③ 训练目标（语言建模 loss 的 token 权重分配、batch 构造）和数据质量对性能的影响是框架外因素。

(3) 论断的核心谬误：

「能写成同一形式」（计算形式的统一）不等于「表达能力相同」（函数类的等价）。广义线性递推统一的是**状态更新的计算图结构**，不是**可以计算的函数集合**；线性注意力（ $G = I$ ）的输出是输入序列的线性函数，而标准 Transformer（softmax 注意力）输出是输入的非线性函数——即使后者在数值精度极高时也无法被前者精确表达。此外，「等价」在理论计算机科学中有精确含义（两个模型对所有输入给出相同输出），而非「用同一套符号描述」。

(4) 选择最优架构还需要：

① 目标任务的序列长度分布（短序列时 Transformer 有硬件优势，长序列时递推架构内存优势显著）；② 任务对长程依赖的依赖程度（固定衰减 vs 输入依赖衰减的选择）；③ 硬件平台特性（不同架构在不同 GPU/TPU 上的实际吞吐量差异）；④ 预训练数据规模（大数据下更复杂的架构收益更大，小数据下简单架构过拟合风险低）。

Sanity check：(3) 的谬误指向「形式 ≠ 能力」，这是计算理论的基本原则；(4) 的四条均属于「架构选择的上下文因素」，与统一框架提供的「架构描述能力」正交。

§ 7.7 将进入扩散语言模型，用同样精准的数学语言处理另一类「统一框架」——ELBO 变分推断如何将 DDPM、分数匹配和离散扩散纳入同一目标函数体系。

§7.7 习题：扩散语言模型的数学

导读：本节核心是「扩散过程的变分推断基础」——ELBO 将生成模型的学习分解为重建项与 KL 正则项，DDPM 通过代数化简将 ELBO 等价转化为去噪分数匹配损失，离散扩散 (MDLM) 将吸收态转移矩阵引入文本域。五题分别对应：A (ELBO 变分推导)、B (DDPM 损失代数化简)、C (前向过程边际计算)、D (离散扩散 MDLM 目标辨析)、E (与自回归模型的评判对比)。

题 1【中·中推导·ELBO 的变分推断基础】 导读：变分自由能 (ELBO) 是扩散模型数学基础的根基，理解它的推导过程比记住公式更重要——ELBO 同时出现在 VAE、扩散模型、Friston 的主动推断中，是生成模型的统一语言。

设生成模型 $p_\theta(x, z) = p_\theta(x|z)p(z)$ ，观测变量 x ，隐变量 z ，变分分布 $q_\phi(z|x)$ 。

(1) 从对数似然 $\log p_\theta(x)$ 出发，引入 $q_\phi(z|x)$ ，推导 ELBO：

$$\log p_\theta(x) = \text{ELBO}(q, \theta, x) + D_{\text{KL}}(q_\phi(z|x) \| p_\theta(z|x))$$

其中 $\text{ELBO} = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)] - D_{\text{KL}}(q_\phi(z|x) \| p(z))$ ，写出详细代数步骤。

(2) 验证：由 $D_{\text{KL}} \geq 0$ ，ELBO 是 $\log p_\theta(x)$ 的下界。等号在什么条件下成立？

(3) 扩散模型中，隐变量 $z = x_{1:T}$ (所有中间噪声状态)，前向过程 $q(x_{1:T}|x_0)$ 扮演变分分布 $q_\phi(z|x)$ 的角色 (无需优化 ϕ ， q 固定)。将 ELBO 的 KL 项和重建项分别对应到扩散模型的「先验匹配损失」和「重建损失」(用 $q(x_{1:T}|x_0)$ 和 p_θ 表示)。

教学注：ELBO 的三种等价表达 (重建项-KL、证据-KL、自由能-对数似然) 在不同上下文中各有便利；扩散模型的 ELBO 推导中，重建项分解为每一步的去噪误差，是 DDPM 损失化简的出发点。

陷阱：(1) 中引入 q 的技巧是「乘以 $q/q = 1$ 」后取对数，等号成立当且仅当 $q_\phi(z|x) = p_\theta(z|x)$ ，即变分分布等于真实后验——这在扩散模型中可以近似实现 (Tweedie 公式)。

题 2【重·重推导·DDPM 损失的代数化简】 导读：Ho et al. (2020) 的关键贡献之一是将复杂的 ELBO 化简为简单的去噪目标——这需要连续三步代数操作：(1) 利用 Markov 性分解 KL 项，(2) 对 $q(x_{t-1}|x_t, x_0)$ 配方，(3) 用重参数化消去 x_0 依赖，最终得到噪声预测损失。

设 DDPM 前向过程 $q(x_t|x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I)$ ， $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$ ，用重参数化表示 $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon$ ， $\epsilon \sim \mathcal{N}(0, I)$ 。

(1) 写出 DDPM 的 ELBO (以 KL 项之和的形式)：

$$-\text{ELBO} = \underbrace{D_{\text{KL}}(q(x_T|x_0) \| p(x_T))}_{L_T} + \sum_{t=2}^T \underbrace{D_{\text{KL}}(q(x_{t-1}|x_t, x_0) \| p_\theta(x_{t-1}|x_t))}_{L_{t-1}} - \underbrace{\log p_\theta(x_0|x_1)}_{L_0}$$

不需要详细推导，但需说明每一项的物理含义。

(2) 关键步骤：证明 $q(x_{t-1}|x_t, x_0)$ 是高斯分布（利用 Bayes 定理和高斯乘积），写出其均值 $\tilde{\mu}_t(x_t, x_0)$ 和方差 $\tilde{\beta}_t$ ：

$$\tilde{\mu}_t(x_t, x_0) = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t}x_0 + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}x_t, \quad \tilde{\beta}_t = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t$$

(3) 代数化简的核心步骤：

将 $x_0 = (x_t - \sqrt{1-\bar{\alpha}_t}\epsilon)/\sqrt{\bar{\alpha}_t}$ 代入 $\tilde{\mu}_t(x_t, x_0)$ ，化简得到 $\tilde{\mu}_t = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon\right)$ 。

设模型预测 $\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon_\theta(x_t, t)\right)$ ，写出 L_{t-1} 中 KL 散度（两个高斯）的显式表达式，并说明为什么最终简化为噪声预测损失 $\mathbb{E}[\|\epsilon - \epsilon_\theta(x_t, t)\|^2]$ （忽略方差相关的常数因子）。

(4) **化简结果**：写出 DDPM 的最终训练目标（简化版）：

$$\mathcal{L}_{\text{DDPM}} = \mathbb{E}_{t \sim \mathcal{U}[1, T], x_0, \epsilon \sim \mathcal{N}(0, I)} [\|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon, t)\|^2]$$

说明该目标与分数匹配（Score Matching）的等价性（ $\epsilon_\theta \propto -\nabla_{x_t} \log q(x_t|x_0)$ 方向）。

教学注：Ho et al. (2020) 在论文中将 (3) 步中的前置权重因子（ $\beta_t^2/(2\sigma_t^2\alpha_t(1-\bar{\alpha}_t))$ ）设为常数 1，这是一个关键的「简化选择」，实验上效果更好，理论上是对 ELBO 的加权（等价于重要性采样的变体）。

陷阱：(3) 的两个高斯 KL 散度公式为 $D_{\text{KL}}(\mathcal{N}(\mu_1, \sigma^2) \parallel \mathcal{N}(\mu_2, \sigma^2)) = (\mu_1 - \mu_2)^2/(2\sigma^2)$ （等方差情形），在此条件下 KL 正比于均值差的平方——这是化简的关键。

题 3【中·中计算·DDPM 前向过程的边际分布】 导读：DDPM 前向过程的最重要数学性质是「任意时刻的边际分布 $q(x_t|x_0)$ 有闭合形式」——这使得训练时可以直接采样任意时刻 t 的噪声版本，无需逐步运行前向链。

设 $\beta_1 = \beta_2 = \dots = \beta_T = \beta$ （等方差噪声调度）， $T = 1000$ ， $\beta = 0.02$ 。

(1) 计算 $\bar{\alpha}_T = \prod_{t=1}^{1000} (1 - 0.02)^{1000} = 0.98^{1000}$ （精确到四位有效数字，用对数辅助）。

(2) 解释 $\bar{\alpha}_T \approx 0$ 的物理含义： $q(x_T|x_0)$ 近似什么分布？为什么这对扩散模型的逆向过程是必要的？

(3) 设在时刻 $t^* = 100$ ， $\bar{\alpha}_{t^*} = 0.98^{100}$ （计算精确值）。此时 $q(x_{t^*}|x_0)$ 中， x_0 的信号权重和噪声权重分别是多少？直观描述这意味着什么。

(4) 等方差噪声调度的缺点是什么？实践中为什么倾向于使用余弦调度（cosine schedule）？（用 $\bar{\alpha}_t$ 的曲率变化解释）

教学注：DDPM 原论文（Ho et al., 2020）使用线性 β 调度，Improved DDPM（Nichol & Dhariwal, 2021）引入余弦调度，将 $\bar{\alpha}_t = \cos^2(\frac{t/T+s}{1+s} \cdot \frac{\pi}{2})$ 使得噪声添加更平滑，训练更稳定。

陷阱： $\bar{\alpha}_t$ 是累积乘积而非算术平均， $\bar{\alpha}_{t+1} = \bar{\alpha}_t \cdot (1 - \beta_{t+1})$ 总是严格小于 $\bar{\alpha}_t$ （单调递减），不要和其他调度参数混淆。

题4【中·概念辨析·离散扩散与 MDLM 目标】 导读：将扩散模型推广到离散文本域需要用「转移矩阵」替代高斯核——吸收态（MASK token）设计是目前最成功的方案，Sahoo et al. (2024) 的 MDLM 进一步将目标简化为加权 MLM 损失。

设词表大小 V ，特殊 MASK token 为 M ，吸收态转移矩阵 $Q_t = (1 - \beta_t)I + \beta_t \mathbf{1}e_M^\top$ （其中 e_M 是 M 的 one-hot 向量）。

(1) 解释转移矩阵 Q_t 的行为：以概率 $1 - \beta_t$ 保持不变，以概率 β_t 变为 M 。证明：边缘分布 $q(x_t|x_0)$ 的闭合形式为

$$q(x_t|x_0) = \bar{\alpha}_t \delta_{x_t, x_0} + (1 - \bar{\alpha}_t) \delta_{x_t, M}$$

（其中 $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$ ， δ 为 Kronecker delta）。

(2) 吸收态设计与连续扩散的「各向同性高斯噪声」相比，有何核心优势？（从文本 token 的离散性角度讨论，2-3 句）

(3) MDLM 的简化训练目标为：

$$\mathcal{L}_{\text{MDLM}} = -\mathbb{E}_{t, x_0} \left[\frac{|\alpha'_t|}{\alpha_t} \sum_{i: x_t^{(i)} = M} \log p_\theta(x_0^{(i)} | x_t) \right]$$

其中 $\alpha'_t = d\alpha_t/dt$ 。解释：(a) 为什么求和只对被 MASK 的位置 i 进行？(b) 权重 $|\alpha'_t|/\alpha_t$ 的直觉含义是什么（类比「时刻 t 的信息增益」）？

教学注：MDLM 的目标本质上是加权的 Masked Language Modeling (MLM) 损失—— t 越小（噪声少），权重越大（对每个 MASK 位置，预测原始 token 更容易，给予更大的损失权重）；这与 BERT 的等权 MLM 的本质区别是理解 MDLM 的关键。

陷阱：(3) 中 $\alpha'_t = d\alpha_t/dt$ 在离散时间版本中需要理解为差分 $(\alpha_{t-1} - \alpha_t)$ ， $|\alpha'_t|/\alpha_t$ 始终为正（ α_t 单调递减， $\alpha'_t < 0$ ），不要误算符号。

题5【重·重评判·扩散语言模型 vs 自回归模型】 导读：扩散语言模型（Diffusion LM）的兴起引发了与自回归（AR）模型的系统性对比，两者在「消除曝光偏差」、「并行解码」、「推理步数」三个维度上各有得失——理解这些权衡是评估实用价值的前提。

(1) 「消除逆向诅咒 (reversal curse)」：AR 模型在训练时只看到「A 导致 B」式的顺序，无法推断「B 导致 A」；扩散模型因为并行生成不依赖固定的生成顺序，理论上应该避免这一问题。

判断：「扩散语言模型在所有需要双向推理的任务上性能必然优于 AR 模型。」这一论断是否成立？指出两处不严谨之处。

(2) 推理效率对比：AR 模型生成 L 个 token 需要 L 步，每步计算量 $O(L \cdot d^2)$ (含 KV-cache)；DDPM 风格的扩散语言模型生成 L 个 token 需要 T_{diff} 步 ($T_{\text{diff}} \in [64, 256]$)，每步计算量 $O(L \cdot d^2)$ (无 KV-cache 优势，但全并行)。

设 $L = 512$, $T_{\text{diff}} = 128$ ，计算两种方案的总计算步数比，并讨论：在什么场景下扩散语言模型的并行性优势能弥补多步推理的劣势？

(3) 「曝光偏差 (exposure bias)」问题：AR 模型训练时以真实 token 为条件 (teacher forcing)，推理时以自身生成的 token 为条件，分布漂移导致错误累积。扩散语言模型如何从结构上消除这一问题？

(4) 综合评判：对以下场景分别给出推荐架构 (AR / 扩散 / 两者皆可) 及理由：

- (A) 实时对话系统 (延迟敏感，需要逐 token 流式输出)
- (B) 创意写作 (要求高多样性，长文本一致性)
- (C) 代码生成 (严格语法约束，填充任务 FIM)
- (D) 机器翻译 (严格对齐，质量优先于延迟)

教学注：扩散语言模型当前 (2024–2025) 的主要瓶颈是多步推理的延迟，但在需要全局一致性 (创意写作) 和填充任务 (FIM) 的场景中展现出结构优势；随着蒸馏技术 (diffusion distillation) 将步数压缩到 4–16 步，延迟差距正在快速缩小。

陷阱：(2) 中「AR 需要 L 步」是在有 KV-cache 且一步生成一个 token 的情形下；批量推理时 AR 同样可以并行 (不同序列之间)，但单条序列的 token 之间必须串行——这是与扩散模型的关键区别。

解答 § 7.7

T-7.7.1 【ELBO 的变分推断基础】 (1) ELBO 推导 (详细步骤)：

$$\log p_{\theta}(x) = \log \int p_{\theta}(x, z) dz = \log \int \frac{p_{\theta}(x, z)}{q_{\phi}(z|x)} q_{\phi}(z|x) dz$$

由 Jensen 不等式 ($\log$ 为凹函数)：

$$\log p_{\theta}(x) \geq \int q_{\phi}(z|x) \log \frac{p_{\theta}(x, z)}{q_{\phi}(z|x)} dz = \mathbb{E}_{q_{\phi}}[\log p_{\theta}(x, z) - \log q_{\phi}(z|x)]$$

展开 $\log p_{\theta}(x, z) = \log p_{\theta}(x|z) + \log p(z)$ ：

$$= \mathbb{E}_{q_{\phi}}[\log p_{\theta}(x|z)] + \mathbb{E}_{q_{\phi}}[\log p(z) - \log q_{\phi}(z|x)]$$

$$= \underbrace{\mathbb{E}_{q_{\phi}}[\log p_{\theta}(x|z)]}_{\text{重建项}} - \underbrace{D_{\text{KL}}(q_{\phi}(z|x) \| p(z))}_{\text{KL 正则项}} = \text{ELBO}$$

等式版本 (无 Jensen 不等式)：

$$\log p_\theta(x) = \text{ELBO} + D_{\text{KL}}(q_\phi(z|x) \| p_\theta(z|x)) \quad \blacksquare$$

(由 $\log p_\theta(x) = \mathbb{E}_q[\log(p_\theta(x, z)/q_\phi(z|x))] + \mathbb{E}_q[\log(q_\phi(z|x)/p_\theta(z|x))]$, 后一项即 D_{KL} 。)

(2) 下界验证: $D_{\text{KL}} \geq 0$ (Gibbs 不等式), 故 $\log p_\theta(x) \geq \text{ELBO}$, 等号成立当且仅当 $q_\phi(z|x) = p_\theta(z|x)$ (变分分布等于真实后验)。■

(3) 扩散模型中的对应:

- KL 正则项 (先验匹配损失 L_T): $D_{\text{KL}}(q(x_T|x_0) \| p(x_T))$, 要求最终噪声分布与先验 $\mathcal{N}(0, I)$ 匹配。
- 重建项 (逐步去噪损失 L_{t-1}): $\sum_{t=2}^T D_{\text{KL}}(q(x_{t-1}|x_t, x_0) \| p_\theta(x_{t-1}|x_t))$, 要求模型学会反转每一步加噪过程。
- L_0 : $-\log p_\theta(x_0|x_1)$, 最后一步的重建损失。

Sanity check: (1) 的推导关键步骤是「乘以 q/q 」后用 Jensen 给出不等式, 再用 $\log p(x, z) = \log p(x|z) + \log p(z)$ 分解——这两步与 VAE 的 ELBO 推导完全相同, 体现了扩散模型是 VAE 的分层推广。

T-7.7.2 【DDPM 损失的代数化简】 (1) ELBO 各项含义:

- L_T : 前向过程终端与先验的匹配损失, 若 β 足够小则近似为常数, 通常忽略。
- L_{t-1} ($t = 2, \dots, T$): 每一步逆向去噪的 KL 散度, 衡量模型对后验 $q(x_{t-1}|x_t, x_0)$ 的逼近质量——这是训练的主要信号。
- L_0 : 从 x_1 恢复 x_0 的对数似然, 通常用离散化的高斯 CDF 建模。

(2) $q(x_{t-1}|x_t, x_0)$ 的均值和方差:

由 Bayes 定理: $q(x_{t-1}|x_t, x_0) \propto q(x_t|x_{t-1})q(x_{t-1}|x_0)$, 两个高斯的乘积仍是高斯。

代入 $q(x_t|x_{t-1}) = \mathcal{N}(\sqrt{\alpha_t}x_{t-1}, \beta_t I)$, $q(x_{t-1}|x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_{t-1}}x_0, (1 - \bar{\alpha}_{t-1})I)$, 配方得:

$$\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t}x_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}x_t, \quad \tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}\beta_t \quad \blacksquare$$

(3) 噪声预测化简:

代入 $x_0 = (x_t - \sqrt{1 - \bar{\alpha}_t}\epsilon)/\sqrt{\bar{\alpha}_t}$:

$$\begin{aligned} \tilde{\mu}_t &= \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t} \cdot \frac{x_t - \sqrt{1 - \bar{\alpha}_t}\epsilon}{\sqrt{\bar{\alpha}_t}} + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}x_t \\ &= \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}}\epsilon \right) \end{aligned}$$

(合并系数后化简, 利用 $\bar{\alpha}_t = \alpha_t \bar{\alpha}_{t-1}$ 和 $\beta_t = 1 - \alpha_t$ 。)

两个方差相同 ($\tilde{\beta}_t$) 的高斯之间的 KL 散度:

$$L_{t-1} = D_{\text{KL}}(\mathcal{N}(\tilde{\mu}_t, \tilde{\beta}_t I) \| \mathcal{N}(\mu_\theta, \tilde{\beta}_t I)) = \frac{1}{2\tilde{\beta}_t} \|\tilde{\mu}_t - \mu_\theta\|^2$$

代入 $\tilde{\mu}_t$ 和 μ_θ 的表达式，两者之差正比于 $(\epsilon - \epsilon_\theta)$ ：

$$L_{t-1} \propto \frac{\beta_t^2}{2\tilde{\beta}_t \alpha_t (1 - \bar{\alpha}_t)} \|\epsilon - \epsilon_\theta(x_t, t)\|^2$$

Ho et al. 将前置系数设为常数 1（经验上效果更好），得到简化损失。

(4) DDPM 最终目标：

$$\mathcal{L}_{\text{DDPM}} = \mathbb{E}_{t, x_0, \epsilon} [\|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t)\|^2]$$

分数匹配等价性： $\nabla_{x_t} \log q(x_t | x_0) = -\epsilon / \sqrt{1 - \bar{\alpha}_t}$ （由 $q(x_t | x_0)$ 对 x_t 求梯度），故 $\epsilon_\theta \approx -\sqrt{1 - \bar{\alpha}_t} \nabla_{x_t} \log q(x_t | x_0)$ ，预测噪声等价于估计分数函数（即对数密度梯度）——这正是 Score Matching 的目标。

Sanity check：化简中「两个等方差高斯的 KL 等于均值差平方除以两倍方差」是关键恒等式；若方差不同（如 DDPM 中 Σ_θ 也参与训练），则 KL 还包含方差项，化简会更复杂。

T-7.7.3 【DDPM 前向过程的边际分布】 (1) $\bar{\alpha}_T$ 计算：

$$\bar{\alpha}_T = 0.98^{1000}$$

$$\ln(0.98^{1000}) = 1000 \ln(0.98) = 1000 \times (-0.020203) = -20.203$$

$$\bar{\alpha}_T = e^{-20.203} \approx 1.675 \times 10^{-9}$$

精确到四位有效数字： $\bar{\alpha}_T \approx 1.675 \times 10^{-9} \approx 0.0000$ （实际接近 0）。

(2) 物理含义：

$\bar{\alpha}_T \approx 0$ 时， $q(x_T | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_T} x_0, (1 - \bar{\alpha}_T)I) \approx \mathcal{N}(0, I)$ ——即 $q(x_T | x_0)$ 近似为标准高斯，与原始数据 x_0 无关。这是必要的：逆向过程从纯高斯噪声 $p(x_T) = \mathcal{N}(0, I)$ 开始，若前向过程的终态与 x_0 仍有关联，则逆向过程无法从纯噪声出发。

(3) $t^* = 100$ 时的信号权重：

$$\bar{\alpha}_{100} = 0.98^{100} = e^{100 \ln 0.98} = e^{100 \times (-0.020203)} = e^{-2.0203} \approx 0.1326$$

$$q(x_{100} | x_0) = \mathcal{N}(\sqrt{0.1326} x_0, (1 - 0.1326)I)。$$

· 信号权重（ x_0 的贡献）： $\sqrt{0.1326} \approx 0.3641$

- 噪声权重 (ϵ 的贡献): $\sqrt{1 - 0.1326} = \sqrt{0.8674} \approx 0.9313$

直观含义: 在 $t = 100$ 时, x_0 的信号只剩约 36%, 噪声已占 93% (信噪比约 0.39: 1) ——模型需要在主要是噪声的 x_{100} 中恢复原始 x_0 , 任务已经相当困难。

(4) 等方差调度的缺点:

等方差调度 $\beta_t = \text{const}$ 使 $\bar{\alpha}_t$ 在 t 接近 0 时下降很慢 (起始段信号损失慢), 在 t 中段急剧下降, 在 t 接近 T 时已接近 0。余弦调度使 $\bar{\alpha}_t = \cos^2(\cdot)$ 随 t 近乎线性地从 1 下降到 0, 噪声添加均匀, 避免了「初始段几乎不加噪 (训练信号弱)、中段急剧加噪 (梯度剧烈变化)」的双重问题, 训练更稳定。

Sanity check: $0.98^{100} \approx 0.1326$, 验证: $\ln(0.1326) = -2.019$, $100 \ln(0.98) = 100 \times (-0.0202) = -2.020$, 误差在舍入范围内。

T-7.7.4 【离散扩散与 MDLM 目标】 (1) 边际分布推导:

$$Q_t = (1 - \beta_t)I + \beta_t \mathbf{1} e_M^\top, \text{ 即 } [Q_t]_{x_t|x_{t-1}} = (1 - \beta_t)\delta_{x_t, x_{t-1}} + \beta_t \delta_{x_t, M}.$$

$x_0 = v$ (非 MASK 的 token) 时, 经 t 步转移的边际:

- 若 $x_t = v$ (从未被 MASK): 需要所有 t 步均「保持」, 概率 $\prod_{s=1}^t (1 - \beta_s) = \bar{\alpha}_t$ 。
- 若 $x_t = M$ (至少被 MASK 一次): 余下概率 $1 - \bar{\alpha}_t$ (一旦变成 M 就是吸收态, 不会再变)。
- 若 $x_t = u \neq v, M$: 概率为 0 (保持只能变成 v 或 M , 不会变成其他 token)。

故 $q(x_t|x_0 = v) = \bar{\alpha}_t \delta_{x_t, v} + (1 - \bar{\alpha}_t) \delta_{x_t, M}$ 。■

(2) 吸收态的核心优势:

文本 token 是离散且无自然距离结构的——「猫」和「狗」之间没有连续插值; 各向同性高斯噪声在连续空间中有意义 (每一步只是稍微「模糊」), 但在离散空间中不存在类比。吸收态 (替换为特殊 MASK token) 有自然的语义解释: MASK 代表「信息未知」, 从 MASK 恢复原 token 等价于「根据上下文填充」, 与 MLM 框架天然对接。

(3) MDLM 目标解释:

- 求和只对 MASK 位置: 只有被 MASK 的位置 $x_t^{(i)} = M$ 才有信息损失, 未被 MASK 的位置已知 $x_t^{(i)} = x_0^{(i)}$, 无需预测 (条件概率为 1, 对数为 0), 求和仅在「信息丢失」的位置上有意义。
- 权重 $|\alpha'_t|/\alpha_t$ 的直觉: $|\alpha'_t|/\alpha_t = |d \ln \alpha_t / dt|$ 是对数 α_t 的变化率——在 α_t 下降快 (大量 token 被 MASK) 的时刻, 权重大 (训练信号强); $\alpha_t \approx 1$ (早期, 几乎没有 MASK) 时权重小; $\alpha_t \approx 0$ (晚期, 几乎全是 MASK) 时 $|\alpha'_t|/\alpha_t$ 也趋于 $|\alpha'_t|/\alpha_t$, 具体取决于调度; 整体上是「每个时刻的信息变化率」的重要性加权, 使模型在「信息正在被移除的临界时刻」受到更多监督。

Sanity check: (1) 的推导利用了吸收态的关键性质——一旦进入 M 就无法离开, 使累积概率有如此简洁的形式。

T-7.7.5 【扩散语言模型 vs 自回归模型】 (1) 论断评判: 不成立。两处不严谨之处:

- 不严谨之处一：「并行生成」并不保证模型内部表示了双向推理——扩散模型的去噪网络通常是双向 Transformer（所有 token 同时可见），但其训练目标（噪声预测/MASK 恢复）不显式要求双向推理；模型可能仍然学习了「顺序先验」。
- 不严谨之处二：「必然优于」是绝对陈述；AR 模型（尤其大规模预训练后）通过提示工程（逆向提问、CoT 推理）可以部分补偿单向训练的局限；「结构上可以并行」不等于「所有双向任务性能更好」。

(2) 推理效率计算：

AR 总步数： $L = 512$ （每步生成 1 个 token）

扩散总步数： $T_{\text{diff}} = 128$ （每步处理全部 $L = 512$ 个 token，但整体需 128 次前向传播）

步数比（AR 相对扩散）： $512/128 = 4.0000$

即 AR 需要的前向传播次数是扩散的 4 倍（但每次扩散步的批处理量是整个序列 L ，AR 每次是单 token）。

扩散优势场景：(a) 高度并行化的批量推理（多条序列同时生成，扩散每步并行度更高）；(b) 对生成延迟（time-to-first-token）不敏感但对总延迟（total latency）有要求的场景（扩散最后一步才输出完整序列）；(c) 需要多轮迭代修改（条件生成、填充）的任务。

(3) 曝光偏差的结构消除：

扩散语言模型训练时的条件是 x_t （加噪后的 token），而非「自己生成的上一步 token」——训练集（ x_t 来自前向过程）和推理集（ x_t 来自逆向过程的当前状态）均处于「含噪 token」的空间；没有「真实 token」和「生成 token」之间的分布漂移，因为每一步的条件变量 x_t 在训练和推理中都是同一类型的噪声状态。AR 模型的曝光偏差根源（训练时条件为真实 token，推理时为自生成 token）从结构上不存在于扩散框架中。

(4) 综合评判：

- 实时对话（延迟敏感）：**AR 模型**。扩散模型需要 64–256 步才能输出完整结果，无法实现逐 token 流式输出；AR 的 KV-cache + streaming 是成熟方案。
- 创意写作（高多样性，长文本一致性）：**扩散模型**（或两者皆可，但扩散有优势）。并行生成全局一致性更强，避免了 AR 末尾部分因误差累积导致的语义漂移；多样性来自扩散过程的随机性，可通过引导（guidance）灵活控制。
- 代码生成（填充任务 FIM）：**扩散模型**（FIM 场景）/ AR（左到右生成）。扩散模型在填充（fill-in-the-middle）任务中有结构优势（自然支持双向上下文），严格语法约束可以通过受约束解码（constrained decoding）在两类模型上实现。
- 机器翻译（质量优先）：**两者皆可**，当前大规模 AR 模型在翻译质量上仍领先；扩散模型在迭代精化（iterative refinement）场景有潜力，但对延迟不敏感时可以用更多步数换取质量。

Sanity check：步数比 $512/128 = 4$ 正是「AR 需要与序列等长的串行步数」和「扩散需要固定步数的并行步数」之比，与两种架构的基本设计一致。

§ 7.8 将进一步延伸变分推断框架，将 ELBO 与 Friston 的变分自由能、JEPa 的能量函数、Kalman 滤波统一到「预测编码 ↔ 世界模型」的更大图景中。

§7.8 习题：世界模型与预测编码的数学

导读：本节核心是「预测编码 = 变分推断 = 反向传播」的三重等价，以及 Kalman 滤波、JEPA、DreamerV3 在同一变分框架下的统一。Friston 的变分自由能是连接神经科学与深度学习的核心桥梁，Mamba 是 Kalman 滤波的非线性数据依赖推广。五题分别对应：A（变分自由能推导）、B（预测编码局部规则 vs 反向传播）、C（JEPA 能量函数与 VICReg 防 collapse）、D（Kalman 滤波与预测编码的对应计算）、E（世界模型框架的评判）。

题1【中·中推导·变分自由能与 Friston 框架】 导读：Karl Friston 的「主动推断」(Active Inference) 框架将感知和行动统一为变分自由能 F 的最小化——感知对应推断隐状态 (E 步)，行动对应最小化关于动作的自由能 ($\partial F / \partial a$)。其数学核心与 VAE 的 ELBO 完全等价。

(1) Friston 定义变分自由能为：

$$F[q, x] = D_{\text{KL}}(q(z) \| p(z|x)) - \log p(x) = -\text{ELBO}(q, x)$$

从 $-\text{ELBO}$ 的定义出发，推导上式中 $D_{\text{KL}}(q(z) \| p(z|x))$ 与 $\log p(x)$ 的关系（即验证 $F = -\text{ELBO}$ ）。

(2) Friston 框架的核心主张：大脑通过最小化 F 来实现感知。

- **感知** (E 步)：最小化 F 关于 $q(z)$ 等价于使 $q(z) \rightarrow p(z|x)$ (后验推断)。用 F 的表达式说明这一等价。
- **行动** (主动推断)：行动 a 影响感觉输入 x ，因此 $\partial F / \partial a$ 给出了最优行动的方向。解释为什么「最小化自由能 = 最小化预测误差 + 最小化对先验的偏离」(2-3 句)。

(3) 与 VAE 的对应：完成以下映射表：

Friston 框架	VAE 框架
变分分布 $q(z)$	?
感觉输入 x (观测)	?
隐状态 z (信念)	?
最小化 F (感知)	?
主动推断 $\partial F / \partial a$	?

教学注：Friston 框架不只是数学上的重新表述——它将「知觉」(perception) 和「行动」(action) 纳入同一优化原则（自由能最小化），为理解大脑和构建具身智能 AI 提供了统一的理论框架。

陷阱： $F = -\text{ELBO}$ 意味着最小化 F 等价于最大化 ELBO；ELBO 是证据 $\log p(x)$ 的下界，最大化 ELBO 不保证 $\log p(x)$ 本身被最大化（除非 $D_{\text{KL}} = 0$ ），两者的差距是近似推断的代价。

题2【中·中推导·预测编码局部规则与反向传播的等价性】 导读：Whittington & Bogacz (2017) 证明了层级预测编码网络中的局部更新规则（每层只需本层的预测误差）在精度加权极限下等价于反向传播，这为大脑如何实现高效学习提供了生物合理的机制。

设层级预测编码网络，第 l 层表示为 x_l ，预测误差 (prediction error) 为 $\varepsilon_l = x_l - f_l(x_{l+1})$ (其中 f_l 为从 $l+1$ 层到 l 层的生成模型)，精度矩阵 Π_l 。

(1) 层级预测编码的自由能为：

$$F = \sum_l \varepsilon_l^\top \Pi_l \varepsilon_l$$

对 x_l 求梯度，推导 x_l 的更新规则：

$$\Delta x_l \propto -\frac{\partial F}{\partial x_l} = \Pi_l \varepsilon_l - \left(\frac{\partial f_l}{\partial x_l} \right)^\top \Pi_{l-1} \varepsilon_{l-1}$$

说明每一项的含义：第一项是「向上修正当前层」，第二项是「向下传递下一层的误差」。

(2) 对模型参数 θ_l (f_l 的参数) 的更新：

$$\Delta \theta_l \propto -\frac{\partial F}{\partial \theta_l} = \left(\frac{\partial f_l}{\partial \theta_l} \right)^\top \Pi_{l-1} \varepsilon_{l-1}$$

说明这如何类比反向传播： ε_{l-1} 扮演「误差信号」， $\partial f_l / \partial \theta_l$ 扮演「局部 Jacobian」，Hebbian 乘积结构是其核心特征。

(3) 精度加权 $\Pi_l = I$ (单位精度)、所有层同时收敛时，验证（定性）为什么预测编码等价于反向传播。(2-3 句即可)

教学注：预测编码与反向传播的等价性在「精度加权等于单位矩阵」的极限下成立；对于非单位精度，预测编码实际上是一种「注意力加权的反向传播」，赋予更可靠（高精度）的感觉通道更大的学习信号。

陷阱：预测编码的「局部性」指每层只需知道上一层的预测误差 ε_{l-1} ，不需要从输出层传递全局梯度——这在生物神经网络中对应局部突触可塑性，是该框架在神经科学上有价值的原因。

题3【中·中计算·JEPA 能量函数与 VICReg 防 collapse】 导读：JEPA (Joint Embedding Predictive Architecture, LeCun, 2022) 和 VICReg (Bardes et al., 2022) 是两种避免表示 collapse (所有输入映射到同一点) 的自监督学习框架，两者在世界模型构建中都是重要组件。

JEPA 部分：

设 JEPA 的能量函数为 $E(x, y) = \|s_\phi(y) - P_\psi(s_\phi(x), z)\|^2$ ，其中 s_ϕ 为编码器， P_ψ 为预测器， z 为额外的隐变量（可选）， x, y 为上下文和目标。

- (1) 解释为什么 JEPA 在**表示空间**（而非像素空间）进行预测可以避免像素级高方差问题。（举一个具体例子：预测「下一帧」在像素空间和表示空间分别需要建模什么）
- (2) 在无 z （确定性预测）时， $E(x, y) = 0$ 的最简单解是什么？（即 collapse 解）JEPA 如何通过「停止梯度」（stop-gradient）或负样本机制避免此 collapse？（2-3 句）

VICReg 部分：

VICReg 损失为 $L = \lambda I + \mu V + \nu C$ ，其中：- 不变性项 $I = \frac{1}{n} \sum_i \|z_i - z'_i\|^2$ （两个视角表示的 ℓ_2 距离之和）- 方差项 $V = \frac{1}{d} \sum_j \max(0, \gamma - \text{std}(z^j))$ （惩罚标准差低于 γ 的维度）- 协方差项 $C = \frac{1}{d} \sum_{i \neq j} \frac{[C(Z)]_{ij}^2}{n-1}$ （惩罚维度间的线性相关）

- (3) 设 $d = 3$ ， $n = 4$ ，表示矩阵 $Z \in \mathbb{R}^{4 \times 3}$ 如下（已中心化）：

$$Z = \begin{pmatrix} 1 & 0 & 0 \\ -1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -1 & 0 \end{pmatrix}$$

计算：(a) 每个维度的标准差（精确到四位小数）；(b) 协方差矩阵 $C(Z)$ 的非对角元素（精确到四位小数）；(c) 方差项 V （设 $\gamma = 1$ ）和协方差项 C 的值。

教学注：VICReg 的三项分别对应三种 collapse 模式： I 防止两视角表示分散（不变性）， V 防止维度退化为常数（维度 collapse）， C 防止维度之间线性相关（冗余 collapse）。

陷阱： V 中标准差是对 n 个样本计算， C 中协方差是对维度对计算（ $j \neq i$ 表示维度对，而非样本对）——注意下标含义不要混淆。

题 4【重·计算题·Kalman 滤波与预测编码的精确对应】 导读：Kalman 滤波是线性高斯系统下的贝叶斯最优滤波器；预测编码的误差修正规则与 Kalman 更新方程在结构上完全对应——Mamba 正是将这一对应推广到非线性、数据依赖的情形。

设线性高斯状态空间模型：

$$x_t = Ax_{t-1} + Bu_t + w_t, \quad w_t \sim \mathcal{N}(0, Q)$$

$$y_t = Cx_t + v_t, \quad v_t \sim \mathcal{N}(0, R)$$

Kalman 增益： $K_t = P_{t|t-1} C^\top (C P_{t|t-1} C^\top + R)^{-1}$

更新方程： $\hat{x}_{t|t} = \hat{x}_{t|t-1} + K_t(y_t - C\hat{x}_{t|t-1})$

(1) 数值计算：

设标量系统（ $x, y \in \mathbb{R}$ ）， $A = 1, C = 1, Q = 0.5, R = 2.0$ ，先验协方差 $P_{t|t-1} = 1.0$ 。

计算：(a) Kalman 增益 K_t （精确到四位小数）；(b) 若预测值 $\hat{x}_{t|t-1} = 3.0$ ，观测值 $y_t = 5.0$ ，计算更新后估计 $\hat{x}_{t|t}$ （精确到四位小数）；(c) 更新后协方差 $P_{t|t} = (1 - K_t C) P_{t|t-1}$ （精确到四位小数）。

(2) 与预测编码的对应：

完成以下对应表（从 Kalman 框架到预测编码框架）：

Kalman 滤波	预测编码
预测残差 $y_t - C\hat{x}_{t t-1}$	?
Kalman 增益 K_t	?
先验协方差 $P_{t t-1}$	?
观测噪声协方差 R	?
更新步 $\hat{x}_{t t} = \hat{x}_{t t-1} + K_t(\cdot)$	?

(3) Mamba 作为 Kalman 的推广:

标准 Kalman 滤波中, A, B, C, Q, R 是固定参数 (不依赖输入)。Mamba 的离散化状态空间方程为:

$$h_t = \bar{A}(x_t)h_{t-1} + \bar{B}(x_t)x_t, \quad y_t = Ch_t$$

其中 $\bar{A}(x_t) = e^{\Delta_t A}$, $\bar{B}(x_t) = (\Delta_t A)^{-1}(e^{\Delta_t A} - I)\Delta_t B$ 。

指出 Mamba 相对于 Kalman 滤波的两个关键推广: (a) 参数的数据依赖性 ($\bar{A}, \bar{B}$ 依赖 x_t), (b) 非线性 (通过门控和激活函数)。解释这两个推广如何使 Mamba 能处理 Kalman 滤波无法处理的问题类型。

教学注: 「Mamba = 数据依赖的非线性 Kalman 滤波」是本节最重要的概念桥梁之一——Kalman 是线性高斯最优的, Mamba 用神经网络替换了固定参数, 保留了递推结构但放弃了最优性保证, 换取了更强的非线性表达能力。

陷阱: Kalman 增益 K_t 只在线性高斯假设下是「最优」的 (最小化均方误差); 非线性系统需要 EKF (扩展 Kalman 滤波) 或粒子滤波, Mamba 不是这些方法的近似, 而是一种独立的神经网络参数化。

题 5【重 · 重评判 · 世界模型框架的能力边界】 导读: 「世界模型」(World Model) 是 AI 研究的重要方向, 其核心主张是「模型应该建立环境的内部表示, 而非直接映射输入到输出」。DreamerV3 是目前最成熟的世界模型系统之一, 但世界模型框架本身有明确的能力边界。

DreamerV3 的 RSSM (Recurrent State Space Model) 损失:

$$\mathcal{L}_{\text{RSSM}} = \mathbb{E}_q \left[\sum_t -\log p_\theta(o_t|h_t, z_t) + \beta D_{\text{KL}}(q_\phi(z_t|h_t, o_t) \| p_\theta(z_t|h_t)) \right]$$

- (1) 识别 $\mathcal{L}_{\text{RSSM}}$ 中的各项, 说明它如何对应 ELBO 框架 (重建项、KL 项、先验、后验)。
- (2) 判断以下关于 DreamerV3 的论断:
 - (A) 「DreamerV3 的 RSSM 可以通过学习世界模型完全替代真实环境交互, 只需少量真实样本即可达到最优策略。」
 - (B) 「RSSM 中的 β 参数类似 β -VAE, 较大的 β 强制更独立的隐表示, 但可能损害重建质量。」

(C)「DreamerV3 中 z_t 是离散 latent（使用直通梯度估计），这比连续 latent 在状态空间结构化方面有本质优势。」

(3) 预测编码框架 (Friston)、JEPA (LeCun)、DreamerV3 (Hafner) 是三种不同的「世界模型」实现路径。对以下维度，比较三者的异同（填写表格）：

维度	预测编码 (Friston)	JEPA	DreamerV3
预测发生在哪个空间	?	?	?
时间建模方式	?	?	?
学习信号来源	?	?	?
行动/规划能力	?	?	?

(4)「世界模型」框架的根本假设是「环境有足够规则的内部结构，使得建立内部表示是有益的」。指出两类世界模型框架失效的场景（即直接策略学习可能更优），并给出直觉解释。

教学注：(3) 的比较表揭示了三种路径的「设计哲学差异」：Friston 强调生物合理性和感知-行动统一；LeCun 强调层级表示和能量框架；Hafner 强调强化学习的样本效率。三者并非竞争关系，而是从不同角度逼近同一问题。

陷阱：(2)(A) 是对世界模型「样本效率优势」的过度推广——世界模型在规则环境（如 Atari）效果显著，但在高度随机或部分可观测的复杂环境（如真实世界机器人）中仍难以完全替代真实交互，模型误差累积会导致策略退化。

解答 §7.8

T-7.8.1 【变分自由能与 Friston 框架】 (1) 推导 $F = -\text{ELBO}$ ：

由 $\log p(x) = \log \int p(x, z) dz$ ，分解：

$$\log p(x) = \mathbb{E}_{q(z)} \left[\log \frac{p(x, z)}{q(z)} \right] + D_{\text{KL}}(q(z) \| p(z|x))$$

即 $\log p(x) = \text{ELBO} + D_{\text{KL}}(q(z) \| p(z|x))$ ，故

$$D_{\text{KL}}(q(z) \| p(z|x)) - \log p(x) = -\text{ELBO}$$

因此 $F[q, x] = D_{\text{KL}}(q(z) \| p(z|x)) - \log p(x) = -\text{ELBO}$ 。■

(2) 感知与行动：

感知 (E 步)： $F = D_{\text{KL}}(q \| p(z|x)) - \log p(x)$ ，其中 $\log p(x)$ 不依赖 q ，故最小化 F 关于 q 等价于最小化 $D_{\text{KL}}(q \| p(z|x))$ ，即使 $q(z) \rightarrow p(z|x)$ （后验推断）。

行动与「最小化预测误差 + 最小化对先验的偏离」： 将 F 展开为 $-\mathbb{E}_q[\log p(x|z)] + D_{\text{KL}}(q \| p(z))$ ——第一项 $-\mathbb{E}_q[\log p(x|z)]$ 是预测误差（ $p(x|z)$ 的负对数似然，即观测 x 与生成模型预测之间的差距），第二项 $D_{\text{KL}}(q \| p(z))$ 是对先验 $p(z)$ 的偏离。最小化 $F =$

最小化预测误差 + 最小化对先验的偏离——行动 a 改变感觉输入 x ，从而影响预测误差项， $\partial F/\partial a$ 给出了「使世界符合预测」的最优行动方向。

(3) 映射表：

Friston 框架	VAE 框架
变分分布 $q(z)$	编码器 $q_\phi(z x)$
感觉输入 x (观测)	训练数据 x
隐状态 z (信念)	隐变量 z
最小化 F (感知)	最大化 ELBO (训练编码器和解码器)
主动推断 $\partial F/\partial a$	(无直接对应；VAE 是被动生成模型，无行动机制)

Sanity check: $F = -\text{ELBO}$ 的等式推导中，关键是 $\log p(x)$ 可以从 q 的期望中分离出来作为常数（对 q 最优化时），这正是 ELBO 推导的核心技巧。

T-7.8.2 【预测编码局部规则与反向传播的等价性】 (1) x_l 更新规则推导：

$$F = \sum_l \varepsilon_l^\top \Pi_l \varepsilon_l, \quad \varepsilon_l = x_l - f_l(x_{l+1})$$

$$\frac{\partial F}{\partial x_l} = \frac{\partial}{\partial x_l} [\varepsilon_l^\top \Pi_l \varepsilon_l + \varepsilon_{l-1}^\top \Pi_{l-1} \varepsilon_{l-1}]$$

第一项 (ε_l 含 x_l): $\partial(\varepsilon_l^\top \Pi_l \varepsilon_l)/\partial x_l = 2\Pi_l \varepsilon_l$ (因为 $\partial \varepsilon_l/\partial x_l = I$)。

第二项 (ε_{l-1} 含 x_l 通过 $f_{l-1}(x_l)$): $\partial(\varepsilon_{l-1}^\top \Pi_{l-1} \varepsilon_{l-1})/\partial x_l = -2(\partial f_{l-1}/\partial x_l)^\top \Pi_{l-1} \varepsilon_{l-1}$ 。

故 (忽略常数 2):

$$\Delta x_l \propto -\frac{\partial F}{\partial x_l} = \Pi_l \varepsilon_l - \left(\frac{\partial f_{l-1}}{\partial x_l}\right)^\top \Pi_{l-1} \varepsilon_{l-1}$$

注：以 l 层预测 $l-1$ 层 ($f_l: x_l \rightarrow \hat{x}_{l-1}$)，第二项中的 Jacobian 应为 $(\partial f_l/\partial x_l)^\top$ (上层对本层的 Jacobian)。

含义：- 第一项 $\Pi_l \varepsilon_l$ ：向上修正——本层的预测误差 ε_l (本层表示与更高层预测的偏差) 推动本层表示向预测的方向调整。- 第二项 $-(\partial f_l/\partial x_l)^\top \Pi_{l-1} \varepsilon_{l-1}$ ：向下传递——本层通过 f_l 预测了下层，若下层有预测误差 ε_{l-1} ，则将误差沿 Jacobian 转置传回本层，驱动本层表示做出能减少下层误差的调整。

(2) 参数更新的 Hebbian 结构：

$$\Delta \theta_l \propto (\partial f_l/\partial \theta_l)^\top \Pi_{l-1} \varepsilon_{l-1}:$$

- ε_{l-1} ：下一层的预测误差，扮演反向传播中「误差信号 δ_{l-1} 」的角色。
- $\partial f_l/\partial \theta_l$ ：生成模型的局部 Jacobian，对应反向传播中的「输入激活」。

- 两者的内积（外积类型）形成 Hebbian 型学习规则：「当下层有较大预测误差时，沿当前激活的方向调整参数以减小该误差」——只用本层信息，无需从输出层显式传递全局梯度。

(3) 等价性（精度 $\Pi_l = I$ ）：

精度矩阵为单位矩阵时， $\Delta\theta_l \propto (\partial f_l / \partial \theta_l)^\top \varepsilon_{l-1}$ ， ε_{l-1} 精确等于下层的预测误差；当所有层同时收敛（不再是迭代推断而是一步解析）， x_l 取极值时 $\partial F / \partial x_l = 0$ ，意味着预测编码在「均衡态」下的参数更新等价于反向传播（误差信号通过 Jacobian 转置从下一层反向传播到参数）——Whittington & Bogacz（2017）的定理正式证明了此等价。

Sanity check：(1) 的推导涉及两项，分别来自 l 层的自身误差和对 $l-1$ 层的预测误差，这对应「误差从两个方向汇入当前层」的双路修正机制。

T-7.8.3 【JEPA 能量函数与 VICReg 防 collapse】（1）表示空间预测的优势：

像素空间中预测「下一帧」需要精确建模每个像素的颜色值，而自然视频中像素变化高度随机（光照、运动模糊、背景纹理），高方差导致模型倾向于学习「平均值」（模糊帧）而非有意义的动态；表示空间中预测「下一帧的表示」只需捕捉高层语义变化（「物体向右移动了」），可以忽略像素级的随机变化，预测任务的方差大幅降低，模型可以专注于学习结构化的世界动态。

(2) collapse 解： $s_\phi(y) = s_\phi(x) = c$ （常数）时 $E = 0$ ——所有输入映射到同一表示，能量为 0 但表示失去区分能力。

JEPA 通过对目标分支使用**停止梯度**（只更新上下文分支 $s_\phi(x)$ ，目标分支用动量更新，如 BYOL/I-JEPA）来避免：若两个分支同步更新，梯度会找到 collapse 捷径；异步更新（目标分支缓慢移动）使 collapse 的「速度」被抑制，同时不变性通过在线预测目标被间接强制。

(3) VICReg 数值计算：

Z 已中心化， $n = 4$ ， $d = 3$ 。

(a) 每维标准差：

- 维度 1： $z^1 = (1, -1, 0, 0)$ ， $\text{std}(z^1) = \sqrt{\frac{1^2 + (-1)^2 + 0^2 + 0^2}{4-1}} = \sqrt{2/3} \approx 0.8165$
- 维度 2： $z^2 = (0, 0, 1, -1)$ ， $\text{std}(z^2) = \sqrt{2/3} \approx 0.8165$
- 维度 3： $z^3 = (0, 0, 0, 0)$ ， $\text{std}(z^3) = 0.0000$

(b) 协方差矩阵非对角元素（ $[C(Z)]_{ij} = \frac{1}{n-1} \sum_k Z_{k,i} Z_{k,j}$ ，已中心化）：

- $[C(Z)]_{12} = \frac{1}{3}(1 \cdot 0 + (-1) \cdot 0 + 0 \cdot 1 + 0 \cdot (-1)) = 0.0000$
- $[C(Z)]_{13} = \frac{1}{3}(1 \cdot 0 + (-1) \cdot 0 + 0 \cdot 0 + 0 \cdot 0) = 0.0000$
- $[C(Z)]_{23} = \frac{1}{3}(0 \cdot 0 + 0 \cdot 0 + 1 \cdot 0 + (-1) \cdot 0) = 0.0000$

(c) 方差项 V （ $\gamma = 1$ ）：

$$\begin{aligned} V &= \frac{1}{3} [\max(0, 1 - 0.8165) + \max(0, 1 - 0.8165) + \max(0, 1 - 0)] \\ &= \frac{1}{3} (0.1835 + 0.1835 + 1.0000) = \frac{1.3670}{3} \approx 0.4557 \end{aligned}$$

协方差项 C ($d = 3$, $d(d-1) = 6$ 个非对角元素对):

$$C = \frac{1}{3} \cdot \frac{0^2 + 0^2 + 0^2 + 0^2 + 0^2 + 0^2}{n-1} = 0.0000$$

(所有非对角协方差为 0, 无维度线性相关惩罚。)

Sanity check: 维度 3 全零导致 V 中有一项 $\max(0, 1-0) = 1.0$, 显示 VICReg 的方差项会强烈惩罚退化维度; 协方差项为 0 说明维度 1 和维度 2 已经正交 (无冗余), 这是 VICReg 期望的状态。

T-7.8.4 【Kalman 滤波与预测编码的精确对应】 (1) 数值计算:

(a) Kalman 增益:

$$K_t = \frac{P_{t|t-1}C^\top}{CP_{t|t-1}C^\top + R} = \frac{1.0 \times 1}{1 \times 1.0 \times 1 + 2.0} = \frac{1.0}{3.0} \approx 0.3333$$

(b) 更新后估计:

$$\begin{aligned}\hat{x}_{t|t} &= \hat{x}_{t|t-1} + K_t(y_t - C\hat{x}_{t|t-1}) = 3.0 + 0.3333 \times (5.0 - 1 \times 3.0) \\ &= 3.0 + 0.3333 \times 2.0 = 3.0 + 0.6667 = 3.6667\end{aligned}$$

(c) 更新后协方差:

$$P_{t|t} = (1 - K_tC)P_{t|t-1} = (1 - 0.3333 \times 1) \times 1.0 = 0.6667 \times 1.0 = 0.6667$$

(2) 对应表:

Kalman 滤波	预测编码
预测残差 $y_t - C\hat{x}_{t t-1}$	预测误差 $\varepsilon = x_{\text{obs}} - \hat{x}_{\text{pred}}$
Kalman 增益 K_t	精度加权的误差传播系数 (Π_t 的函数)
先验协方差 $P_{t t-1}$	模型不确定性 $\sim 1/\Pi_t$ (精度的倒数)
观测噪声协方差 R	感觉精度 ($1/\Pi_{l=0}$, 感觉层的不确定性)
更新步 $\hat{x}_{t t} = \hat{x}_{t t-1} + K_t(\cdot)$	表示更新 $\Delta x_l \propto \Pi_l \varepsilon_l - \dots$ (加权误差修正)

(3) Mamba 相对于 Kalman 的两个推广:

- (a) **数据依赖性:** Kalman 的 A, B, C 是固定矩阵, 对所有输入和时刻使用相同的转移和观测关系; Mamba 的 $\bar{A}(x_t), \bar{B}(x_t)$ 随输入 x_t 动态变化, 相当于「根据当前内容选择不同的状态转移规则」。这使 Mamba 能处理**非平稳序列** (如语言中不同话题需要不同的记忆策略), 而固定参数的 Kalman 只能处理平稳线性系统。

- (b) **非线性**：Kalman 的最优性建立在线性高斯假设上；Mamba 通过门控激活（SiLU）引入非线性，可以建模状态空间中的非线性动力学（如语言的复杂语义组合），代价是失去了 Kalman 的数学最优性保证，但获得了更强的表达能力。

Sanity check： $K_t = 1/(1 + R/P_{t|t-1}) = 1/(1 + 2) = 1/3$ ，当观测噪声 R 大（不可信观测）时 K_t 小（权重低），当先验协方差 $P_{t|t-1}$ 大（不确定先验）时 K_t 大（更相信观测）——这正是贝叶斯加权的直觉。

T-7.8.5 【世界模型框架的能力边界】 (1) RSSM 各项识别：

$$\mathcal{L}_{\text{RSSM}} = \mathbb{E}_q \left[\underbrace{\sum_t -\log p_\theta(o_t|h_t, z_t)}_{\text{重建项 (观测似然)}} + \beta \underbrace{D_{\text{KL}}(q_\phi(z_t|h_t, o_t) \| p_\theta(z_t|h_t))}_{\text{KL 项 (后验 vs 先验)}} \right]$$

对应 ELBO 框架：- $-\log p_\theta(o_t|h_t, z_t)$ ：重建项——给定隐状态 (h_t, z_t) 时，观测 o_t 的负对数似然，对应 VAE 的解码器重建损失。- $D_{\text{KL}}(q_\phi(z_t|h_t, o_t) \| p_\theta(z_t|h_t))$ ：KL 项——后验（给定观测的隐状态推断）与先验（仅由递推隐状态 h_t 给出的预测）的散度，对应 VAE 的 KL 正则项。- 先验 $p_\theta(z_t|h_t)$ ：由 RNN 隐状态预测的隐变量先验（模型的「预期」）。- 后验 $q_\phi(z_t|h_t, o_t)$ ：结合当前观测后的推断分布（「实际感知」）。

(2) 论断判断：

- (A) **不成立**。世界模型通过在想象中的虚拟轨迹上训练策略来提高样本效率，但在高度随机或高维感知（如真实世界图像）的环境中，模型误差会随规划步数指数累积（「梦境发散」），无法完全替代真实交互。「少量样本达到最优策略」在结构化低维环境中近似成立，在复杂环境中过于乐观。
- (B) **基本正确**。 β 项确实类似 β -VAE 中的 KL 权重，较大的 β 强化 KL 正则化，倾向于使后验更接近先验（更独立、更结构化的隐表示），但同时限制了后验对观测的自由拟合，可能降低重建质量。这是 DreamerV3 中 β 调参的核心权衡。
- (C) **部分正确**。DreamerV3 确实使用直通估计器（straight-through estimator）的离散 latent；离散 latent 在捕捉「开关式」的状态（如游戏中的生死状态）时有结构优势；但「本质优势」的说法过强——连续 latent 在平滑动力学（如物理模拟）中表现更好，没有哪一种在所有情况下都优。

(3) 三框架比较表：

维度	预测编码 (Friston)	JEPA	DreamerV3
预测发生在哪个空间	表示空间（每层预测下层）	表示空间（避免像素预测）	表示空间（ z_t 隐空间）
时间建模方式	层级递推（空间层级隐含时间）	框架不强制时间顺序	显式 RNN 递推（ $h_t = f(h_{t-1}, z_{t-1}, a_{t-1})$ ）
学习信号来源	预测误差（无监督，自由能）	能量最小化（自监督对比）	ELBO（重建 + KL）+ 奖励

维度	预测编码（Friston）	JEPA	DreamerV3
行动/规划能力	主动推断（ $\partial F/\partial a$ ）	无内置规划（需外部规划器）	Actor-Critic 在想象中规划

(4) 世界模型框架失效的场景：

- ① **高度随机环境**（如随机奖励、无规律扰动）：环境的内部结构随机性强，任何紧凑的内部模型都会有较大的模型误差；在想象中规划会因误差累积而偏离真实轨迹；直接使用无模型方法（如 PPO）的样本效率反而可能更高，因为避免了模型误差的引入。直觉：建模随机性本身代价高于直接学习策略。
- ② **极低维、高度结构化的即时反应任务**（如 Pong、简单 bandit）：状态转移极简单，不需要多步预测——策略可以直接从观测映射到动作（无需内部模型作为中间层）；世界模型引入的额外参数和推断开销不带来性能收益，反而增加训练复杂度。直觉：当环境简单到直接学习策略毫不费力时，世界模型是过度设计。

Sanity check： (1) 中 RSSM 损失的两项与 ELBO 的重建项和 KL 项严格对应， β 系数出现在 KL 项前与 β -VAE 形式完全一致。(3) 表中「学习信号来源」一列清晰区分了三者：纯无监督（Friston）、自监督（JEPA）、有监督（DreamerV3 含奖励）——这是理解三框架适用场景的核心维度。