

目录

算法的低语·数学卷习题伴读 v1.2 补编	4
第 1 章·信息论与语言的概率结构	5
§ 1.3 习题：跨界映射——语言序列与 DNA 碱基对	5
题 1 【轻·推导·联合熵 vs. 单变量熵】	5
题 2 【中·计算·一阶马尔可夫源的熵率】	5
题 3 【中·概念辨析·平稳性 vs. 遍历性】	6
题 4 【重·计算·典型序列集与 SMB 定理】	6
题 5 【重·评判·跨界类比的合法性边界】	7
解答 § 1.3	7
§ 1.4 习题：反类比——当 DNA 的隐喻失效	10
题 1 【轻·计算·字母表大小与熵率上限】	10
题 2 【中·计算·稀疏性裂变的量级临界】	10
题 3 【中·概念辨析·冗余来源的物理根源 vs. 统计涌现】	11
题 4 【重·计算·动态性差异与持续预训练的必要性】	11
题 5 【重·评判·四条跨界迁移论断的合法性】	12
解答 § 1.4	13
第 2 章·嵌入空间与高维几何	17
§ 2.1 习题：词嵌入——为什么字典救不了机器	17
题 1 【轻·推导·one-hot 编码的两堵墙】	17
题 2 【中·计算·嵌入矩阵的查表操作】	17
题 3 【中·计算·余弦相似度的动机与计算】	18
题 4 【重·概念·分布假设与语义涌现的边界】	19
题 5 【重·综合·嵌入维度的选择与信息容量权衡】	19
解答 § 2.1	20
§ 2.4 习题：跨界映射——从罗马路网到曼哈顿距离	24
题 1 【轻·计算· L^p 范数族与单位球几何】	24
题 2 【中·推导·平行四边形恒等式与内积范数】	24
题 3 【中·计算·马氏距离与白化的几何解释】	25
题 4 【重·综合·度量选择对最近邻结果的影响】	26
题 5 【重·评判·何时用哪种度量】	27
解答 § 2.4	28
§ 2.5 习题：反类比——当几何隐喻失效	32
题 1 【轻·计算·各向异性指标的计算与解读】	32
题 2 【中·推导·椎体效应的训练机制追溯】	32
题 3 【中·计算·白化变换的代数实现】	33
题 4 【重·综合·白化对类比算术的破坏】	34
题 5 【重·评判·五条嵌入几何隐喻的合法性】	35
解答 § 2.5	36
§ 2.6 习题：跨越欧氏——当表示空间不再「平直」	41
题 1 【轻·推导·欧氏嵌入的维度下界】	41

题 2 【中·计算·Poincaré 球距离公式】	41
题 3 【中·概念辨析·黎曼度量张量与曲率】	42
题 4 【重·计算·黎曼梯度与欧氏梯度的比较】	43
题 5 【重·反类比·双曲嵌入优势的适用边界】	43
解答 § 2.6	44
第 3 章·注意力机制的矩阵微分	48
§ 3.1 习题：从 RNN 到 Transformer——序列建模的范式革命	48
题 1 【轻·推导·RNN 梯度消失的数学根源】	48
题 2 【中·计算·LSTM 门控的缓解效果】	48
题 3 【中·概念辨析·Transformer 并行化的条件与代价】	49
题 4 【重·计算·注意力计算复杂度分析】	50
题 5 【重·综合评判·范式革命的驱动力】	50
解答 § 3.1	51
§ 3.6 习题：注意力的真实身份——关联记忆，而非「注意力」	54
题 1 【轻·推导·经典 Hopfield 网络的能量函数与容量】	54
题 2 【中·推导·log-sum-exp 算子的数学性质】	54
题 3 【中·推导·现代 Hopfield 不动点等价于 softmax 注意力】	55
题 4 【重·计算·指数容量的数量级感受】	56
题 5 【重·评判·关联记忆类比的边界】	56
解答 § 3.6	57
§ 3.7 习题：一个被忽略的争论——注意力权重 $\neq$ 解释	61
题 1 【轻·推导·注意力权重测量的是什么】	61
题 2 【中·推导·梯度归因的三条路径】	61
题 3 【中·概念辨析·Jain & Wallace 反例的条件】	62
题 4 【重·综合评判·可解释性工具的选择原则】	63
题 5 【重·反例构造·「高权重 = 重要」的系统性误判】	63
解答 § 3.7	64
§ 3.8 习题：跨界映射——宏观工业供应链	67
题 1 【轻·类比验证·QKV 三角角色与供应链三角角色的映射】	67
题 2 【中·计算·softmax 归一化与比例分配的等价验证】	68
题 3 【中·类比验证·多头与多专业供应链】	68
题 4 【重·计算·供应链类比的量级价值】	69
题 5 【重·类比合法性综合评判·供应链映射的总体评估】	70
解答 § 3.8	70
§ 3.9 习题：反类比——当供应链隐喻失效	74
题 1 【轻·推导·softmax 归一化 $\neq$ 资源守恒】	74
题 2 【中·反例·「产能耗尽」假设的违反】	74
题 3 【中·辨析·注意力头的功能：设计 vs 涌现】	75
题 4 【重·数学推导·注意力是确定性线性函数，不是优化决策】	76
题 5 【重·综合反类比·四条失效根源的总体评估】	76
解答 § 3.9	77
第 4 章·优化与损失景观	81
§ 4.4 习题：损失景观的可视化	81

题 1 【轻·轻推导·归一化为何不可缺】	81
题 2 【中·中计算·泛化上界与平坦度】	81
题 3 【中·概念辨析·批量大小与景观几何】	82
题 4 【中·中计算·Skip Connection 的平滑效应】	82
题 5 【重·重评判·SAM 的代价与收益】	83
解答 § 4.4	83
§ 4.7 习题: μP 的完整面貌	87
题 1 【轻·轻推导·abc 约束的来源】	87
题 2 【中·中计算·SP 与 μP 的宽度缩放数值】	87
题 3 【中·概念辨析·NTK 极限与特征学习】	88
题 4 【重·Tensor Program 统一视角计算题·宽度迁移的数值验证】	88
题 5 【重·重评判·超参数迁移的边界条件】	89
解答 § 4.7	89
§ 4.8 习题: 跨界类比: 复杂系统的工程管理	94
题 1 【轻·轻推导·链式法则与绩效分摊的线性叠加】	94
题 2 【中·中计算·Adam 自适应步长的决策论最优性】	94
题 3 【中·概念辨析· μP 的尺度不变性与制度设计】	95
题 4 【重·重评判·三组类比的合法性综合审查】	95
题 5 【重·重评判·类比的预测力与可证伪性】	96
解答 § 4.8	96
§ 4.9 习题: 反类比: 工程管理隐喻的失效边界	101
题 1 【轻·轻推导·截断与收敛的数学区别】	101
题 2 【中·中计算/辨析·功能涌现与事后语义】	101
题 3 【中·概念辨析·非凸性: 利用还是控制】	102
题 4 【重·重评判·三条失效边界的根因分析】	103
题 5 【重·重评判·「改良类比」的可行性】	103
解答 § 4.9	104
第 5 章·尺度律与涌现	108
§ 5.9 习题: 跨界映射与反类比: 相变叙事的边界	108
题 1 【轻·轻推导·渗流剪枝与序参量行为】	108
题 2 【中·中计算·热力学极限与有限系统的解析性】	108
题 3 【中·概念辨析·后视镜叙事与预测能力】	109
题 4 【中·辨析·不可逆性与非平衡框架】	109
题 5 【重·重评判·「相变类比是否合法」综合裁决】	110
解答 § 5.9	111
第 7 章·新架构与未来方向	115
§ 7.6 习题: Mamba、线性注意力与 RNN 的统一视角	115
题 1 【轻·轻推导·广义线性递推的前向展开】	115
题 2 【中·概念辨析·门控机制的设计空间】	115
题 3 【中·中计算·Mamba-2 SSD 对偶的数值验证】	116
题 4 【中·辨析·GLA 的低秩约束与线性注意力的联系】	116
题 5 【重·重评判·统一视角的解释力与边界】	117
解答 § 7.6	117

§ 7.7 习题：扩散语言模型的数学	122
题 1 【中 · 中推导 · ELBO 的变分推断基础】	122
题 2 【重 · 重推导 · DDPM 损失的代数化简】	122
题 3 【中 · 中计算 · DDPM 前向过程的边际分布】	123
题 4 【中 · 概念辨析 · 离散扩散与 MDLM 目标】	124
题 5 【重 · 重评判 · 扩散语言模型 vs 自回归模型】	124
解答 § 7.7	125
§ 7.8 习题：世界模型与预测编码的数学	131
题 1 【中 · 中推导 · 变分自由能与 Friston 框架】	131
题 2 【中 · 中推导 · 预测编码局部规则与反向传播的等价性】	132
题 3 【中 · 中计算 · JEPA 能量函数与 VICReg 防 collapse】	132
题 4 【重 · 计算题 · Kalman 滤波与预测编码的精确对应】	133
题 5 【重 · 重评判 · 世界模型框架的能力边界】	134
解答 § 7.8	135

算法的低语 · 数学卷习题伴读 v1.2 补编

► 这一节在讲什么

本册是什么：《数学卷》v1.6 在 v1.5 基础上把 52 个小节升级为「深度逻辑链版」，新增 20 个小节的论证与跨界类比/反类比内容。本补编对应这部分新增内容，给出 19 节 $\times$ 5 题 = 95 道新习题（含 § 1.3 样章），保留与习题伴读 v1.1 完全一致的「导读 + 题型分级 + 教学注 + 陷阱 + 完整解答 + Sanity check」六件套结构。

如何与 v1.1 配合阅读：v1.1 主册（GitHub: workbook_v10.pdf, 261 页, 32 节）+ 本补编（19 节）= 完整对齐数学卷 v1.6 的 51 个有效命题小节。两本之间没有交集——本补编完全是 v1.1 之外的增量。

覆盖小节：§ 1.3, § 1.4, § 2.1, § 2.4, § 2.5, § 2.6（新版），§ 3.1, § 3.6, § 3.7, § 3.8, § 3.9, § 4.4, § 4.7, § 4.8, § 4.9, § 5.9, § 7.6, § 7.7, § 7.8。

阅读建议：先读数学卷 v1.6 对应小节正文 $\rightarrow$ 看本补编该节的「节级导读」与 5 道题 $\rightarrow$ 自己做（建议每题 5–15 分钟） $\rightarrow$ 翻末尾解答对答案。

版本与改动

- **v1.2 · 2026-06-13：**对齐数学卷 v1.6，补编 19 节（含 § 1.3 样章），共 95 道新题
- **v1.1 · 2026-06-13：**每节增加「公式从哪里来」导读盒（GitHub: 主册 workbook_v10.pdf）
- **v1.0 · 2026-06-12：**初版习题伴读 32 节、261 页

作者：大队长（USTC alumnus）· fqsx@mail.ustc.edu.cn **原创声明：**本册由大队长原创，与数学卷 v1.6 同步发布。

第 1 章 · 信息论与语言的概率结构

§ 1.3 习题：跨界映射——语言序列与 DNA 碱基对

导读：本节核心从单变量熵走到序列熵率 $\mathcal{H}$ ，五题分别对应：联合熵的可加性、归一化的必要性、平稳性的最小假设、SMB 典型序列、跨界类比的合法性边界。

题 1 【轻 · 推导 · 联合熵 vs. 单变量熵】

导读：联合熵从单变量熵推广出来的第一步：独立时直接相加，相关时小于和。

设 X_1, X_2 为离散随机变量。

(a) 写出联合熵 $H(X_1, X_2)$ 的定义式。

(b) 若 X_1, X_2 独立，证明 $H(X_1, X_2) = H(X_1) + H(X_2)$ 。

(c) 一般情形下证明 $H(X_1, X_2) \leq H(X_1) + H(X_2)$ ，等号当且仅当独立。提示：用链式法则 $H(X_1, X_2) = H(X_1) + H(X_2 | X_1)$ 及 $H(X_2 | X_1) \leq H(X_2)$ 。

(d) 对长度 n 的序列，写出 $H(X_1, \dots, X_n)$ 的链式分解。

教学注：这条「条件减不确定性」的不等式正是为什么 $\mathcal{H} \leq \log_2 M$ 而英语 $\mathcal{H} \approx 1$ bit/字符 $< \log_2 26 \approx 4.7$ bit 的根源。

陷阱：

- 别把 $H(X, Y)$ 写成 $H(X) \cdot H(Y)$ ，熵是可加不是可乘
- 条件熵 $H(Y | X) \neq H(X | Y)$ ，方向重要

题 2 【中 · 计算 · 一阶马尔可夫源的熵率】

导读：把抽象的熵率落到一个具体可算的最小例子上。

考虑二值符号 $\{0, 1\}$ 上的一阶马尔可夫链，转移矩阵：

$$P = \begin{pmatrix} 0.9 & 0.1 \\ 0.2 & 0.8 \end{pmatrix}$$

(即 $P(0 | 0) = 0.9$, $P(1 | 0) = 0.1$, $P(0 | 1) = 0.2$, $P(1 | 1) = 0.8$ 。)

(a) 求平稳分布 $\pi = (\pi_0, \pi_1)$ (解 $\pi P = \pi$, $\pi_0 + \pi_1 = 1$)。

(b) 写出该过程熵率的闭式： $\mathcal{H} = \sum_i \pi_i \cdot H(X_2 | X_1 = i) = -\sum_{i,j} \pi_i P_{ij} \log_2 P_{ij}$ 。

(c) 数值计算 $\mathcal{H}$ (保留 4 位小数，单位 bit/符号)。

(d) 与无记忆源 (同一边缘分布 π ，但符号独立同分布) 的熵 $H(\pi)$ 比较，解释为什么 $\mathcal{H} < H(\pi)$ 。

教学注：这正是 N-Gram 模型「困惑度比 unigram 低」的信息论根源——条件减少了不确定性。

陷阱：

- 平稳分布 π 是行向量，方程是 $\pi P = \pi$ （不是 $P\pi = \pi$ ）
- 熵率公式里 π_i 是「在状态 i 上的时间占比」，不是均匀分布 $1/2$

题 3 【中 · 概念辨析 · 平稳性 vs. 遍历性】

导读：搞清楚 SMB 定理「几乎处处」需要的两个假设，哪一个是平稳、哪一个是遍历。判断真假并说明理由：

- 「平稳过程的样本平均一定收敛到期望」——真还是假？
- 「独立同分布过程一定是平稳的」——真还是假？
- 「平稳过程一定是遍历的」——真还是假？反例提示：考虑两个不同分布的混合源（先抛硬币决定用哪个，之后所有符号都来自这一个）。
- SMB 定理需要哪两个条件？分别保证了什么？

教学注：「平稳」保证 $\frac{1}{n}H(X_1, \dots, X_n)$ 的极限存在（这是熵率定义所需），「遍历」保证 $-\frac{1}{n} \log P(X_1, \dots, X_n)$ 对每条样本路径几乎处处收敛到 $\mathcal{H}$ （而不仅在期望意义上）。

陷阱：

- 平稳 $\neq$ 遍历，反例（混合源）是经典考点
- i.i.d. 是平稳 + 遍历的最强加强，但不是唯一

题 4 【重 · 计算 · 典型序列集与 SMB 定理】

导读：用具体数字感受 SMB 的「典型序列才走几乎全部概率」是个多么颠覆直觉的事实。

设英语字符（含空格）字母表大小 $M = 27$ ，熵率 $\mathcal{H} \approx 1.5$ bit/字符。考虑长度 $n = 100$ 的字符序列。

- 字面上所有可能的序列数是多少？（用 $10^?$ 估算）
- 由 SMB 定理，典型序列集合 $A_\epsilon^{(n)}$ 的大小近似为 $2^{n\mathcal{H}}$ ，估算其数量级（用 $10^?$ 表示）。
- 典型序列占全部可能序列的比例是多少（用 $10^?$ 表示）？
- 每条典型序列的概率约为多少？
- 解释为什么大语言模型「不需要记住所有 M^n 种句子」就能拟合人类语言：它实际只需要把分布覆盖在 $2^{n\mathcal{H}}$ 这个小得多的子集上。

Sanity check：(c) 应该 $\approx 10^{-98}$ ，但 (a)(b) 都用 $\log_{10}$ 换算后两值相除应得到几乎相等的结论。

教学注：这一题是「语言模型可学性」的信息论基础。Transformer 用有限参数就能拟合 token 序列分布，本质是因为典型序列集只占字面空间的一个极薄子集。

陷阱：

- 换算 $\log_{10}(27^{100}) = 100 \log_{10} 27 \approx 143.1$ ，不要算成 10^{27} 之类
- 2^{150} 不是 10^{45} 整：精确算 $150 \log_{10} 2 \approx 45.15$

题 5 【重 · 评判 · 跨界类比的合法性边界】

导读：本节的真正主张是「语言和 DNA 服从同一套熵率数学」——但这个跨界类比有什么前提，又有什么不能跨的？

阅读以下四个论断，判断哪些是 SMB 定理直接支持的、哪些是跨界类比的「修辞延伸」：

论断 A：「DNA 编码区的熵率 ≈ 2 bit/碱基（接近 $\log_2 4$ ），所以基因组几乎没有冗余。」

论断 B：「英语和 DNA 的熵率都是有限值，所以处理英语的 Transformer 架构可以直接拿去做基因组建模而不需修改。」

论断 C：「股价对数收益率的熵率有限，所以可以用语言模型架构做股价预测。」

论断 D：「SMB 定理保证：任何足够大的语言模型只要训练充分，必然能完美预测下一个 token。」

(a) 对每个论断给出「成立 / 部分成立 / 不成立」的判断，并指出关键的前提或漏洞。

(b) 写出至少两条 SMB / 熵率框架在跨界类比时**必须**满足的前提条件。

(c) 列举一个跨界类比**失效**的领域（语言 $\rightarrow ?$ 的映射不成立），说明哪条假设被违反。

教学注：这一题对接 §1.4 反类比节——同一套数学不意味着同一套工具。下一节会详细展开 DNA 的「字母表 4 个、长度 30 亿、几乎无相位、严重依赖空间共定位」与语言的差异。

陷阱：

- 论断 D 是常见误区——SMB 只给出**信息容量上限**，不等于「实际能学到」
- 论断 B 的漏洞在「不需修改」——架构层面相似不等于数据预处理、tokenization、位置编码可以照搬

解答 §1.3

T-1.3.1 【联合熵】

(a) $H(X_1, X_2) = - \sum_{x_1, x_2} p(x_1, x_2) \log p(x_1, x_2)$

(b) 独立时 $p(x_1, x_2) = p(x_1)p(x_2)$ ，代入：

$$H(X_1, X_2) = - \sum_{x_1, x_2} p(x_1)p(x_2) [\log p(x_1) + \log p(x_2)] = H(X_1) + H(X_2)$$

(c) 链式法则 $H(X_1, X_2) = H(X_1) + H(X_2 | X_1)$ 。又由「条件减熵」 $H(X_2 | X_1) \leq H(X_2)$ （等号当且仅当独立），所以 $H(X_1, X_2) \leq H(X_1) + H(X_2)$ 。

(d) $H(X_1, \dots, X_n) = \sum_{i=1}^n H(X_i | X_1, \dots, X_{i-1})$

T-1.3.2 【一阶马尔可夫熵率】

(a) 解 $\pi P = \pi$: $0.9\pi_0 + 0.2\pi_1 = \pi_0$ 即 $0.2\pi_1 = 0.1\pi_0$, 故 $\pi_1 = 0.5\pi_0$ 。配合 $\pi_0 + \pi_1 = 1$ 得 $\pi = (2/3, 1/3)$ 。

(b) $\mathcal{H} = -\sum_{i,j} \pi_i P_{ij} \log_2 P_{ij}$ 。

(c) 分项计算 (单位 bit):

- 状态 0: $H(X_2 | X_1 = 0) = -0.9 \log_2 0.9 - 0.1 \log_2 0.1 = 0.1368 + 0.3322 = 0.4690$
- 状态 1: $H(X_2 | X_1 = 1) = -0.2 \log_2 0.2 - 0.8 \log_2 0.8 = 0.4644 + 0.2575 = 0.7219$
- $\mathcal{H} = (2/3)(0.4690) + (1/3)(0.7219) = 0.3127 + 0.2406 = 0.5533 \text{ bit/符号}$

(d) 无记忆源 $H(\pi) = -(2/3) \log_2 (2/3) - (1/3) \log_2 (1/3) = 0.3900 + 0.5283 = 0.9183 \text{ bit}$ 。 $\mathcal{H} = 0.55 < H(\pi) = 0.92$ 反映条件确实带走了一部分不确定性。

Sanity check: $\mathcal{H} < H(\pi) < \log_2 2 = 1$, 三个量的大小关系符合理论。

T-1.3.3 【平稳 vs. 遍历】

(a) 假。平稳保证极限存在, 但样本均值收敛到时间平均 (不一定等于总体期望, 除非也遍历)。(b) 真。i.i.d. 显然平稳: 联合分布只看长度不看位置。(c) 假。经典反例: 先抛公平硬币 C , 若 $C = H$ 之后所有 $X_i \sim \text{Bernoulli}(0.3)$, 若 $C = T$ 则 $\sim \text{Bernoulli}(0.7)$ 。整个过程平稳但不遍历——样本路径只能采到一种分布。(d) SMB 需要平稳 + 遍历。平稳保证 $\mathcal{H}$ 作为期望极限存在; 遍历保证「几乎所有样本路径」都收敛到这个极限, 使 $-\frac{1}{n} \log p(X_1, \dots, X_n) \xrightarrow{a.s.} \mathcal{H}$ 成立。

T-1.3.4 【典型序列】

(a) 27^{100} 。 $\log_{10}(27^{100}) = 100 \log_{10} 27 \approx 100 \times 1.4314 = 143.14$ 。即约 10^{143} 。

(b) $2^{n\mathcal{H}} = 2^{150}$ 。 $\log_{10}(2^{150}) = 150 \log_{10} 2 \approx 150 \times 0.3010 = 45.15$ 。即约 10^{45} 。

(c) 比例 = $10^{45.15} / 10^{143.14} = 10^{-97.99} \approx 10^{-98}$ 。

(d) 每条典型序列概率 $\approx 2^{-n\mathcal{H}} = 2^{-150} \approx 10^{-45}$ 。

(e) 语言模型的目标不是覆盖所有 10^{143} 种字面可能, 而是把概率质量正确地分布到那 10^{45} 条典型序列上——这就是为什么有限参数能拟合「无限大」的字面空间。

Sanity check: (b) 中 $10^{45} \times$ (d) 中 $10^{-45} = 10^0 = 1$, 符合「典型集吃掉几乎全部概率」。

T-1.3.5 【跨界合法性】

(a)

- **A 部分成立**。DNA 编码区熵率确实较高 ($\approx 1.9 \text{ bit/碱基}$), 但「几乎无冗余」过强: 密码子简并、内含子、非编码区都是冗余源。
- **B 不成立**。架构可借鉴, 但 tokenization、位置编码、训练目标都要重设。基因组无「词」无「空格」, 长程依赖远超语言。
- **C 部分成立**。熵率有限确实意味着可建模, 但金融时序往往非平稳 (结构断点) 和半遍历, SMB 严格条件不成立——所以预测精度上限远低于语言任务。

- **D 不成立**。SMB 给的是**信息容量上限**，告诉你「学多少够」，但不告诉你「能不能学到」。优化、归纳偏置、样本量都是另外的瓶颈。

(b) 至少需要：

1. 过程平稳（联合分布在时间平移下不变）
2. 过程遍历（样本路径能采遍各状态）
3. 字母表有限离散（连续值需另起一套微分熵）

(c) 示例：脑电信号（EEG）是连续值时序，无离散字母表；金融极端事件（crash）违反平稳；图像非序列结构，邻居关系是二维而非一维——这些都是 SMB 框架直接套用失效的领域。

§ 1.3 小结：从 $H(X)$ 走到 $\mathcal{H}$ 的全路径是「单变量熵 → 联合熵 → 归一化 → 平稳收敛 → SMB 几乎处处」。这条链不仅给语言模型一个信息容量上限，也精确划出了跨界类比的合法边界——下一节 § 1.4 会把这条边界继续往外推。

§ 1.4 习题：反类比——当 DNA 的隐喻失效

导读：本节核心是从「字母表量级差异」出发，推导出稀疏性裂变、冗余机制差异和动态性差异，最终说明「语言像 DNA」只在信息论最抽象层面成立，落到工程时处处失效。五题分别对应：字母表量级与熵率上限的量化、稀疏性的质变临界点、冗余机制的本质差异、动态性对建模策略的影响、综合判断四条「DNA → 语言」迁移论断的合法性。

题 1 【轻 · 计算 · 字母表大小与熵率上限】

导读：把字母表大小差异从直觉转成可以精确比较的数字，是理解后续所有差异的起点。

设 DNA 的字母表大小 $M_{\text{DNA}} = 4$ ，现代大模型 BPE 词表大小 $M_{\text{LLM}} = 50000$ ，对数底数统一取 $\log_2$ 。

(a) 写出有限字母表随机过程熵率上限的公式，并分别计算 DNA 和大模型词表的熵率上限（单位：bit/符号）。

(b) 两者熵率上限之比是多少？保留 2 位小数。

(c) 若 DNA 编码区的实际熵率约为 $\mathcal{H}_{\text{DNA}} \approx 1.9$ bit/碱基，英语字符级熵率约为 $\mathcal{H}_{\text{eng}} \approx 1.0$ bit/字符，分别计算各自相对于字母表上限的冗余度 $R = 1 - \mathcal{H} / \log_2 M$ （以百分比表示）。哪个系统冗余度更高？

(d) 冗余度高意味着「可压缩性强」。从工程角度看，压缩难度更高的是哪个系统？为什么？

教学注：这道题的意义不在于记住两个数字，而在于建立一个直觉：DNA 的熵率「顶天」，英语的熵率「躺平」——两者不是五十步笑百步，而是在不同量级的字母表上做着完全不同的统计游戏。

陷阱：

- 混淆熵率和熵率上限：熵率 $\mathcal{H} \leq \log_2 M$ ，等号当且仅当字母表上均匀分布且独立同分布
- 冗余度公式里的分母是 $\log_2 M$ （上限），不是字母表大小 M 本身

题 2 【中 · 计算 · 稀疏性裂变的量级临界】

导读：同一个 N -Gram 参数计数公式，代入不同的 M ，会跨越一个质变临界点：从「可穷举」跳到「永远压不完」。

设语料总 token 数为 $T = 10^{12}$ （万亿级），词/符号表大小分别考虑 $M \in \{4, 26, 1000, 50000\}$ ，考察 $k = 2$ （三联体）的参数空间。

(a) 对每个 M ，计算 $k = 2$ 阶 N -Gram 的参数空间大小 M^3 （用科学计数法表示）。

(b) 语料可以「覆盖」某个 $k = 2$ N -Gram 的条件粗略地说是该 N -Gram 的期望计数 $T/M^3 \geq 1$ 。对上述四个 M ，判断哪些满足「可穷举统计」条件。

(c) 对 $M = 4$ (DNA 三联体密码子), $M^3 = 64$ 。已知 64 个密码子编码 20 种氨基酸 (另加 3 个终止密码子), 可以列出完整的「输入 → 输出」映射表。对 $M = 50000$ (大模型 5-gram), $M^5 \approx 3.1 \times 10^{23}$, 为什么即使把全互联网的文本都用上也无法穷举?

(d) 上述分析说明, 「隐马尔可夫模型 (HMM) 在 DNA 序列分析中可行, 但直接用于大词表语言建模会崩溃」——从参数空间的角度给出解释。

教学注: 这道题的目的是让「稀疏性裂变」从定性变成定量。DNA 的 $k = 2$ 参数空间 (64) 和语言的 $k = 4$ 参数空间 (3.1×10^{23}) 之间的差距, 不是「两个大数字」的差距, 而是「可计算」与「不可计算」之间的门槛跨越。

陷阱:

- DNA 里 $k = 2$ 对应三联体 (3 个碱基), 注意是 $M^{k+1} = 4^3 = 64$, 不是 $4^2 = 16$
- 全互联网约 $10^{12} \sim 10^{13}$ token, 与 3×10^{23} 之间差了 10 ~ 11 个数量级, 不要低估差距

题 3 【中·概念辨析·冗余来源的物理根源 vs. 统计涌现】

导读: 「冗余」这个词在 DNA 和语言里同形不同质——搞清楚来源, 才能判断能不能跨界迁移。

判断下列陈述的真假, 并说明理由:

(a) 「遗传密码的简并性 (多个密码子对应同一氨基酸) 是一种统计现象, 是因为在进化历史中某些密码子使用得特别频繁。」——真还是假?

(b) 「英语的冗余度约为 79%, 这一数值在未来会随时间保持稳定不变。」——真还是假? 举一个历史上英语统计性质发生漂移的实例。

(c) 「语言和 DNA 的冗余都能用信息压缩算法 (如 Huffman 编码) 来降低, 因此它们冗余的本质是一样的。」——真还是假?

(d) 某研究团队想把 1990 年英文新闻训练的语言模型直接用于 2024 年的社交媒体文本。从「语言冗余机制」的角度解释为什么这会失败, 以及需要做什么才能补救。

教学注: 这道题强迫我们把「冗余」的两种来源讲清楚: 物理化学约束 (tRNA 摆动配对, 写死的、跨物种稳定) vs. 使用者群体统计行为的涌现 (随社群、时代、媒介漂移)。把两者混用是 DNA-NLP 跨界类比中最常见的隐患。

陷阱:

- (a) 的关键词是「统计现象」——遗传密码的简并性是物理化学决定的, 不是统计的
- (c) 的陷阱: 压缩算法的可用性只说明「冗余存在」, 不说明「冗余来源相同」

题 4 【重·计算·动态性差异与持续预训练的必要性】

导读: 把「语言统计性质漂移」这一定性说法转换成可以估算的量化框架, 理解为什么语言模型需要持续更新而生物信息模型不需要。

设某语言模型在时间 t_0 的语料上训练，语料的熵率为 $\mathcal{H}_{t_0}$ 。在时间 $t_1 = t_0 + \Delta t$ 的语料上，由于词汇漂移和新概念涌现，假设熵率变化为 $\mathcal{H}_{t_1} = \mathcal{H}_{t_0} + \delta$ ，且有一部分新词汇 ΔV 出现（旧模型完全不认识）。

(a) 旧模型（在 t_0 语料上训练）在 t_1 语料上评估时，困惑度（perplexity）为什么会上升？从交叉熵的角度解释。

(b) 假设新词汇占新语料的比例为 α （即约有 α 比例的 token 是旧模型词表里没有的），旧模型对这些 token 的概率接近零（ $P_{\text{old}} \approx 10^{-5}$ ）。计算这部分 token 对交叉熵的贡献（仅考虑这 α 比例的 token，用 α 和 10^{-5} 表示）。

(c) 对比之下，一个 2025 年训练的 DNA 序列分析模型，用于分析 1950 年采样的小鼠基因组样本，预期困惑度会有多大变化？从「冗余机制是否漂移」的角度解释。

(d) 下列三种补救措施各对应什么数学操作：「持续预训练」「指令微调（SFT）」「上下文学习（ICL）」？在信息论框架内分别说明它们「修正」的是哪一层不匹配。

教学注：这道题把「语言需要持续维护，DNA 模型可以一次训练长期使用」这个工程直觉翻译成信息论语言：新词 $\rightarrow P \approx 0 \rightarrow$ 交叉熵趋于无穷；漂移 $\rightarrow$ 模型分布 q 与真实分布 p 的 KL 散度增大 $\rightarrow$ 困惑度上升。

陷阱：

- (b) 中不要忘乘以 α ：只有那 α 比例的 token 用到了接近零的概率，其余 token 仍用旧模型
- (c) 中「没有变化」不是废话——要从机制上说清楚为什么 DNA 统计性质几十年不漂移

题 5【重·评判·四条跨界迁移论断的合法性】

导读：本节的真正主张是「字母表量级差异推出的四堵铁墙」——把这条推导链用来审查四个常见的跨界论断，判断哪些成立、哪些失效、原因是什么。

阅读以下四个论断：

论断 A：「Transformer 架构在语言任务上成功，说明它是一个通用序列建模器；把它原封不动地迁移到 DNA 序列分析，性能应该和在语言上一样好。」

论断 B：「DNA 的编码区熵率接近上限（ ≈ 2 bit/碱基），英语字符级熵率远低于上限（ ≈ 1 bit/字符），所以处理 DNA 的模型比处理英语的模型所需参数量更大。」

论断 C：「语言的冗余来自统计约束，所以可以通过数据增强（随机替换同义词）来降低冗余度、提升语言模型的泛化能力，就像 DNA 中密码子简并性增强系统鲁棒性一样。」

论断 D：「同一个 BPE 分词器，在 2010 年语料上训练好之后，可以不经修改地用于 2025 年的网络文本——因为 BPE 只是一种压缩算法，与语言的统计性质无关。」

(a) 对每个论断给出「成立 / 部分成立 / 不成立」的判断，并指出关键的前提条件或漏洞。

(b) 论断 A 和论断 B 都涉及「参数量」问题，但切入角度不同。A 说的是「架构迁移」，B 说的是「模型容量需求」。从字母表大小、稀疏性和典型序列集三个角度，分别分

析这两个论断各自错在哪里（或对在哪里）。

(c) 论断 C 的「同义词替换」类比「密码子简并」失效在哪里？需要满足什么额外条件，同义词替换才是合法的数据增强？

(d) 写出至少两条「DNA 序列建模技术迁移到 NLP」时**必须**重新验证的核心假设。

教学注：这道题的核心能力是「把 §1.4 的四堵铁墙变成判断尺」。每一条论断都踩了某一堵墙，但踩的角度不同——训练结束时，能辨别每条论断的失效属于哪堵墙，本节的目的就达到了。

陷阱：

- 论断 B 的直觉可能反直觉：熵率高 $\neq$ 模型更难训练，因为字母表也小 ($M = 4$ vs $M = 50000$)，参数空间远比语言小
- 论断 D 的问题不在 BPE 算法本身，而在「词表的统计代表性」随时间漂移——BPE 是算法，词表是数据

解答 §1.4

T-1.4.1 【字母表大小与熵率上限】

(a) 熵率上限公式： $\mathcal{H} \leq \log_2 M$ （字母表均匀独立同分布时取等）。

- DNA： $\log_2 4 = 2.0000$ bit/碱基
- 大模型词表： $\log_2 50000 = \log_2(5 \times 10^4) = \log_2 5 + \log_2 10^4 = 2.3219 + 13.2877 = 15.6096$ bit/token

(b) 比值： $15.6096/2.0000 \approx 7.80$ 。语言 token 级别的理论信息密度约是 DNA 碱基的 7.8 倍。

(c) 冗余度：

- DNA： $R_{\text{DNA}} = 1 - 1.9/2.0 = 5\%$
- 英语字符： $R_{\text{eng}} = 1 - 1.0/\log_2 26 = 1 - 1.0/4.7004 \approx 78.7\%$

英语冗余度远高于 DNA。

(d) 从工程角度，压缩难度更高的是英语：冗余度高意味着更多的统计约束需要被模型学习，需要更大的上下文窗口和更复杂的依赖结构。DNA 的冗余度低，每个碱基携带的信息接近上限，反而更「接近随机」，统计规律更简单。

Sanity check：DNA 冗余度 5% 意味着基因组接近最优压缩；英语冗余度约 79% 意味着每个字符平均只携带约 0.21 个「独立比特」的语义信息，和香农 1951 年猜字母实验的结论一致。

T-1.4.2 【稀疏性裂变的量级临界】

(a) M^3 的计算：

M	M^3
4 (DNA)	64
26 (字母)	17576
1000	10^9
50000	1.25×10^{14}

(b) 覆盖条件 $T/M^3 \geq 1$, $T = 10^{12}$:

- $M = 4$: $10^{12}/64 \approx 1.56 \times 10^{10} \gg 1$, 完全覆盖 (每个三联体平均出现 156 亿次)
- $M = 26$: $10^{12}/17576 \approx 5.69 \times 10^7 \gg 1$, 完全覆盖
- $M = 1000$: $10^{12}/10^9 = 1000 \gg 1$, 勉强覆盖 (平均每个 trigram 出现 1000 次)
- $M = 50000$: $10^{12}/(1.25 \times 10^{14}) = 0.008 \ll 1$, 无法覆盖 (绝大多数 trigram 从未出现)

(c) DNA 三联体只有 64 种, 不仅可以穷举统计, 还可以手动建立完整映射表 (遗传密码表)。对 $M = 50000$ 的语言 5-gram, 参数空间约 3.1×10^{23} , 而全互联网约 10^{13} token: $10^{13}/(3.1 \times 10^{23}) \approx 3.2 \times 10^{-11}$, 即便穷尽所有可见文本, 也只能覆盖约三百亿分之一的参数空间。

(d) HMM 的状态转移矩阵大小为「隐状态数 $\times$ 输出符号数」。DNA 上有效隐状态数 (如密码子识别所需) 约几十到几百, 输出符号数 $M = 4$, 参数规模完全可管理。对大词表语言, 状态转移矩阵是 $V \times V = 50000 \times 50000 = 2.5 \times 10^9$ 个参数, 即使不考虑稀疏性, 仅存储就需要约 10 GB (float32), 远超可行范围。

Sanity check: $M = 4$ 时 $k = 2$ 参数空间为 64, 与氨基酸数 (20 种 + 3 个终止) 量级吻合, 说明 DNA 三联体级别的统计是「原子化可枚举」的。

T-1.4.3 【冗余来源的物理根源 vs 统计涌现】

(a) 假。遗传密码的简并性是 tRNA 反密码子摆动配对决定的**物理化学约束**, 与统计频率无关。人类基因组、大肠杆菌、拟南芥使用 (几乎) 相同的遗传密码, 但三者的密码子使用频率 (codon usage bias) 各不相同——频率是统计现象, 简并性是物理现象, 二者独立。

(b) 假。语言的冗余度来自使用者群体统计行为的涌现, 会随时间漂移。历史实例: 「wireless」在 1900 年指无线电报 (高熵, 技术词汇), 在 2025 年近乎白噪声 (「wifi」取代了它的语义核心), 其条件概率分布剧烈变化; 「tweet」在 2006 年前是鸟叫 (低频), 此后成为平台动词 (高频), 改变了周围词的统计分布。

(c) 假。信息压缩算法 (Huffman 编码) 仅要求「冗余存在于分布中」, 不区分来源。DNA 的冗余和语言的冗余都可以被压缩, 但「可压缩」只是充分条件, 不是同质性的证明。类比: 黄金和铁都能被铁锤敲打, 但这不意味着两者本质相同。

(d) 失败原因: 1990 年语料与 2024 年语料的真实分布 p 已经漂移——新词 (「meme」「emoji」「deepfake」) 在旧语料中频率极低或缺失, 旧模型对这些词的概率 $q \approx 0$, 交叉熵 $-\log q \rightarrow \infty$ 。补救措施: 用 2024 年语料进行持续预训练, 更新词表 (加入新 token) 并重新估计整体分布。

Sanity check: (a) 和 (c) 是两个方向的错误——前者把物理约束当统计，后者把技术手段当机制等同。分别从「来源」而非「效果」出发判断，可以有效防止混淆。

T-1.4.4 【动态性差异与持续预训练】

(a) 旧模型的分布 q_{old} 是在 t_0 时刻的真实分布 p_{t_0} 上训练的（近似 $q_{\text{old}} \approx p_{t_0}$ ）。到 t_1 时刻，真实分布变为 $p_{t_1} \neq p_{t_0}$ 。用旧模型评估新语料的交叉熵为 $H(p_{t_1}, q_{\text{old}}) = H(p_{t_1}) + D_{\text{KL}}(p_{t_1} \| q_{\text{old}})$ 。由于 $D_{\text{KL}} \geq 0$ ，且漂移使 $D_{\text{KL}} > 0$ ，交叉熵上升，困惑度随之上升。

(b) 那 α 比例的 token 对交叉熵的贡献为：

$$\Delta H \approx \alpha \cdot (-\log_2 P_{\text{old}}) = \alpha \cdot (-\log_2 10^{-5}) = \alpha \cdot 16.61 \text{ bit/token}$$

例如 $\alpha = 0.01$ （1% 新词）， $\Delta H \approx 0.17 \text{ bit/token}$ ；若这些 token 原本应该占困惑度 ≈ 20 的模型交叉熵约 4.32 bit，则新词把交叉熵推高约 4%，困惑度约从 20 升到 21。

(c) DNA 序列的统计性质由遗传密码（物理化学约束）决定，在几十年乃至几亿年的进化尺度上都极为稳定（同一物种基因组密码子偏好性变化可忽略不计）。因此 2025 年的 DNA 模型用于分析 1950 年样本，困惑度几乎不变—— $D_{\text{KL}}(p_{1950} \| q_{2025}) \approx 0$ 。

(d) 三种补救措施的信息论解读：

- **持续预训练**：用新语料更新整个分布 q_θ ，减小 $D_{\text{KL}}(p_{t_1} \| q_\theta)$ ；对应「重新拟合真实分布」
- **指令微调 (SFT)**：在条件分布层面调整 $q_\theta(y | x, \text{指令})$ ，修正的是「给定输入时输出分布的对齐」，而非全局分布
- **上下文学习 (ICL)**：通过 few-shot 示例把当前上下文信息注入，等效于动态更新先验 $p(y | \text{示例}, x)$ ，修正的是「推断时的条件分布」，不改变模型参数

Sanity check: (b) 中当 $\alpha = 0$ 时 $\Delta H = 0$ ，符合「没有新词就没有额外交叉熵」的直觉；当 $\alpha = 1$ （全部是新词）时 $\Delta H = 16.61 \text{ bit}$ ，远超正常模型的平均交叉熵（约 4 bit），困惑度爆炸，符合直觉。

T-1.4.5 【四条跨界迁移论断的合法性】

(a) 判断：

- **论断 A 部分成立**。Transformer 是通用序列建模器，迁移到 DNA 的**架构**没有根本障碍（ESM、Evo 等生物语言模型已证明可行）。但「性能一样好」失效——DNA 的 tokenization 策略、位置编码、词表大小、上下文长度需求（基因组长达 30 亿碱基 vs 语言几千 token）都需彻底重设。漏洞：「原封不动迁移」是谬误。
- **论断 B 不成立**。熵率高 $\neq$ 需要更多参数。DNA 字母表 $M = 4$ ，参数空间 4^{k+1} 极小；语言词表 $M = 50000$ ，参数空间 50000^{k+1} 指数爆炸。决定参数量需求的是**稀疏性**（ M^{k+1} ）和**典型序列集大小**（ $2^{n_{\mathcal{H}}}$ ），而不是熵率与上限的比值。
- **论断 C 不成立**。同义词替换的类比失效。密码子简并性是写死的物理约束，鲁棒性是「冗余编码降低单点突变影响」的物理效果，不可模仿。语言中的同义词替

换改变的是训练分布，可能提升泛化，但前提是语义不变——如果「快乐」和「开心」在上下文共现模式上不完全等价（它们确实不完全等价），随机替换引入了噪声而非鲁棒性。

· **论断 D 不成立**。BPE 本质是对语料统计分布的压缩编码，词表和子词切分方式直接依赖训练语料的 bigram 频率统计。2010 年语料与 2025 年语料的 bigram 分布不同，因此 2010 年的分词器对 2025 年文本的切分效率（压缩比）下降，且无法切分新词（只能退化为字符级）。

(b) 论断 A（架构迁移）的问题：并非架构本身不行，而是**超参数（tokenization、位置编码、序列长度）与 DNA 统计结构不匹配**——这是稀疏性差异（字母表 4 vs 50000）和动态性差异（DNA 无漂移 vs 语言漂移）的共同后果。论断 B（模型容量）的问题：**混淆了「信息密度高」和「模型容量需求大」**——后者由参数空间大小决定，而 $M = 4$ 的参数空间是 $M = 50000$ 的天文倍数之小。

(c) 「同义词替换 $\approx$ 密码子简并」失效原因：密码子简并是一对多的确定性物理映射（CAA 和 CAG 都编码谷氨酰胺，永远不变）；同义词替换是概率性的语义近似（「快乐」和「欢喜」在部分上下文可替换，但「她快乐地跑来」和「她欢喜地跑来」的细微语气差异不为零）。要使同义词替换成为合法的数据增强，需要额外验证：语义等价性（下游任务标签不变）和统计等价性（两词的上下文分布 KL 散度足够小）。

(d) 必须重新验证的核心假设（至少两条）：

1. **平稳性假设**：语言是非平稳的（统计性质随时间漂移），DNA 编码区在短时间内是平稳的；迁移时必须重新验证目标域的平稳性。
2. **字母表和 tokenization 假设**：DNA 有自然的单符号字母表 (A/T/G/C)，语言的「符号」由 BPE 动态定义，其颗粒度和覆盖范围直接影响稀疏性——必须重新设计 tokenization。

Sanity check：四条论断覆盖了 §1.4 的四堵铁墙——A 对应架构可移植性（字母表量级差异推出的工程差异），B 对应稀疏性裂变，C 对应冗余本质差异，D 对应动态性差异。每条失效都能找到对应的「铁墙」，说明覆盖完整。

§1.4 小结：「语言像 DNA」这句话在信息论最抽象层面是真的——两者都是有限字母表的平稳随机过程，都有熵率，都服从 SMB 定理。但这个真理只有在 $M = 4$ vs $M = 50000$ 、 $4^3 = 64$ vs $50000^5 \approx 3 \times 10^{23}$ 、物理约束 vs 统计涌现、稳定 vs 漂移这四层差异都被正视之后，才是安全可用的。下一章 §2.1 开始的词嵌入，就是为「大字母表 + 统计涌现」这种语言专有的挑战量身定制的数学回应。

第2章 · 嵌入空间与高维几何

§2.1 习题：词嵌入——为什么字典救不了机器

导读：本节核心是从符号表示 (one-hot) 的根本缺陷出发，一步步推出分布式表示 (嵌入向量) 的必要性，再到嵌入矩阵的工程实现，最终用余弦相似度替代内积作为语义度量。五题分别对应：one-hot 的正交性与稀疏性缺陷、嵌入矩阵的查表操作与计算复杂度、余弦相似度的动机与计算、分布假设与语义涌现的关系、嵌入维度 d 的选择与信息容量权衡。

题1【轻 · 推导 · one-hot 编码的两堵墙】

导读：one-hot 的失败不是「不够聪明」，而是其定义本身就切断了所有词间关联，推导出来而不是靠记忆。

设词表大小 $V = 5$ ，词表为「猫、狗、汽车、跑步、睡觉」，按此顺序编号为 1 至 5。

(a) 写出「猫」和「狗」的 one-hot 向量 $\mathbf{e}_{\text{猫}}, \mathbf{e}_{\text{狗}} \in \{0, 1\}^5$ 。

(b) 计算 $\mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{狗}}$ 、 $\mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{汽车}}$ ，以及 $\mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{猫}}$ 。

(c) 由 (b) 的计算结果，解释为什么 one-hot 编码无法表达「猫和狗在语义上相似，汽车则不同」这一关系。

(d) 当词表大小为 $V = 50000$ 时，存储全部词的 one-hot 向量需要多少比特（假设每个分量占 1 比特）？与此相比，用 $d = 512$ 维浮点嵌入向量（每个分量 32 比特）存储全部词需要多少比特？计算两者之比。

教学注：这道题让「one-hot 正交性」和「稀疏性存储代价」各自从公式里推出来，而不是靠「记住结论」。特别是 (c) 要求写出因果关系——不只是「两个结果一样」，而是「为什么一样导致无法表达语义相似性」。

陷阱：

- (b) 中 $\mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{猫}} = 1$ 不要忘记，这就是为什么 one-hot 能用于「是否同一个词」的判断，但不能用于「有多相似」
- (d) 中注意 one-hot 向量的维度是 V ，不是 1

题2【中 · 计算 · 嵌入矩阵的查表操作】

导读：「查表」不是一个特殊操作——它就是矩阵乘法的高效特例，把这个等价关系算清楚，才能理解为什么 $O(d)$ 不是 $O(Vd)$ 。

设嵌入矩阵 $E \in \mathbb{R}^{V \times d}$ ， $V = 4$ ， $d = 3$ ，具体值为：

$$E = \begin{pmatrix} 0.1 & 0.5 & -0.2 \\ 0.8 & -0.3 & 0.6 \\ -0.4 & 0.2 & 0.9 \\ 0.0 & 0.7 & -0.5 \end{pmatrix}$$

其中行 1、2、3、4 分别对应词 w_1, w_2, w_3, w_4 。

(a) 写出词 w_2 (第 2 行) 的 one-hot 向量 $\mathbf{e}_{w_2} \in \mathbb{R}^4$ 。

(b) 计算矩阵向量乘法 $E^T \mathbf{e}_{w_2}$, 得到 w_2 的嵌入向量 $\mathbf{v}_{w_2} \in \mathbb{R}^3$ 。

(c) 验证这等价于直接取 E 的第 2 行。标准矩阵向量乘法的计算复杂度是 $O(Vd)$, 而「直接取行」的复杂度是 $O(d)$ 。对 $V = 50000$, $d = 512$, 两者分别需要约多少次乘法操作?

(d) 在 Word2Vec 中, 同一个词有两套嵌入向量: 中心词向量 $\mathbf{v}_w$ (来自矩阵 W) 和上下文向量 $\mathbf{u}_w$ (来自矩阵 W')。解释为什么不能只用一套矩阵: 若只用一套, 训练目标会产生什么退化?

教学注: (b) 与 (c) 的核心是「矩阵乘法由稀疏性退化为行索引」——这是深度学习框架 (PyTorch `nn.Embedding`) 的实现原理, 理解这里就理解了为什么「lookup 层」是深度学习里最轻量的层之一。

陷阱:

- E^T 的大小是 $d \times V$, 乘以 $V \times 1$ 的列向量, 结果是 $d \times 1$, 不要转置错方向
- (d) 的退化不只是「自回归偏差」, 还要说清楚为什么 $\mathbf{v}_w^T \mathbf{v}_w = \|\mathbf{v}_w\|^2$ 会被优化目标异常推高

题 3 【中 · 计算 · 余弦相似度的动机与计算】

导读: 为什么不用内积而用余弦相似度? 把「词频让模长偏大」这个直觉量化出来, 答案就清楚了。

设已训练好的嵌入空间中有如下三个词向量 (4 维):

$$\mathbf{v}_{\text{猫}} = (0.6, 0.8, 0.0, 0.0)$$

$$\mathbf{v}_{\text{狗}} = (0.5, 0.7, 0.1, 0.1)$$

$$\mathbf{v}_{\text{the}} = (3.0, 4.0, 0.0, 0.0)$$

(「the」是高频词, 模长明显偏大。)

(a) 计算 $\mathbf{v}_{\text{猫}} \cdot \mathbf{v}_{\text{the}}$ 和 $\mathbf{v}_{\text{猫}} \cdot \mathbf{v}_{\text{狗}}$ (原始内积)。

(b) 计算三个向量各自的 L^2 模长 $\|\mathbf{v}\|$ 。

(c) 计算余弦相似度 $\cos(\mathbf{v}_{\text{猫}}, \mathbf{v}_{\text{the}})$ 和 $\cos(\mathbf{v}_{\text{猫}}, \mathbf{v}_{\text{狗}})$ 。

(d) 对比 (a) 和 (c) 的结果: 原始内积说「猫更像 the 还是更像狗»? 余弦相似度说什么? 哪个结论更符合语义直觉? 这说明了余弦相似度的什么优势?

教学注：「the」的模长是「猫」的 5 倍（因为高频词在训练中受到更多梯度更新），直接用内积会被模长主导，余弦归一化消掉了这个偏差。这个具体的数值例子是理解 § 2.5 各向异性问题的前置铺垫。

陷阱：

- 计算余弦相似度时分母是两向量模长之**积**，不是**和**
- $\mathbf{v}_{\text{the}}$ 的方向和 $\mathbf{v}_{\text{猫}}$ 完全相同（比例关系）——这是刻意设计的，用以说明方向才是语义信息的载体

题 4【重·概念·分布假设与语义涌现的边界】

导读：词嵌入的语义来自「出现在相同上下文里的词应该相似」——但这个假设有边界，理解边界才能知道嵌入在什么时候是可信的。

(a) Firth (1957) 的分布假设 (Distributional Hypothesis) 的核心陈述是什么？用一句话概括，并说明它如何解释「猫」和「狗」的嵌入向量靠近这一现象。

(b) 下列两个词对，哪一对的余弦相似度更有可能在 Word2Vec 嵌入中偏高？请解释。

- 词对 X：「高兴」vs「快乐」（近义词，上下文高度重叠）
- 词对 Y：「银行 (bank)」vs「河岸 (bank)」(同形词，两种含义的上下文完全不同)

(c) 在静态嵌入 (Word2Vec / GloVe) 中，「bank」只有一个向量。这个向量会「位于」金融语义和河流语义的什么位置？这对下游任务有什么影响？

(d) 上下文相关嵌入 (BERT、GPT) 对这个问题的处理方式有什么根本不同？它在分布假设框架下做了什么样的推广？

教学注：这道题把「分布假设在什么时候成立，在什么时候不成立」讲清楚，是从 § 2.1 的静态嵌入走向 § 2.2 更复杂语义几何的必经之路。多义词的问题 (bank、run、set) 是分布假设的典型失效点，也是上下文相关嵌入的动机所在。

陷阱：

- (b) 中词对 Y 的回答不是「更低」而是要分析具体现象——「bank」的两种用法有不同的上下文，单一向量会成为两者的「平均」，余弦相似度不稳定
- (d) 不要只说「BERT 是动态的」——要说出「同一词在不同句子里产生不同向量」背后的机制（注意力机制对上下文的汇聚）

题 5【重·综合·嵌入维度的选择与信息容量权衡】

导读： d 应该多大？这不是一个「越大越好」的问题，而是一个需要在信息容量、稀疏性、计算代价之间权衡的数学决策。

设词表大小 $V = 50000$ ，考虑嵌入维度 $d \in \{64, 256, 512, 4096\}$ 。

(a) 嵌入矩阵 $E \in \mathbb{R}^{V \times d}$ 的参数数量（浮点数个数）分别是多少？当 $d = 512$ 时，仅嵌入矩阵的存储空间 (float32, 4 字节/参数) 是多少 MB？

(b) 从「信息容量」角度看，嵌入维度 d 决定了嵌入空间能「区分」的最大方向数。由 § 2.3 的超位置 (superposition) 结果， d 维空间能存储「几乎正交」方向的数量远超 d ——精确地说约为 $e^{d/8}$ 个。对 $d \in \{64, 256, 512\}$ ，分别计算能存储的近正交方向数 (用 $e^?$ 表示，不需计算具体数值)。

(c) 实验中观察到：将 d 从 64 增加到 256 往往带来语义相似度任务的显著提升，但从 256 增加到 512 的提升边际递减。从「词义区分需要的有效维度数」和「实际语言中独立语义特征的数量」两个角度解释这一现象。

(d) 在 Transformer 中，嵌入维度 d 直接影响自注意力的计算复杂度 (每层 $O(n^2d)$ ， n 为序列长度)。如果序列长度 $n = 2048$ ，对比 $d = 512$ 和 $d = 4096$ 的每层计算量之比 (仅考虑注意力部分)。这说明了什么样的工程权衡？

教学注：这道题把「维度选择」从一个工程经验问题变成了数学权衡问题。嵌入维度的选择同时涉及信息论 ($e^{d/8}$ 的容量上限)、稀疏性 (维度越大每个方向越稀疏) 和计算复杂度 ($O(n^2d)$) 三个约束，找到最优的 d 是大模型设计的核心权衡之一。

陷阱：

- (b) 中 $e^{d/8}$ 是超位置的粗略上界，不是精确值——使用时要说「约为」，不要当成等式
- (d) 中注意力复杂度对 d 是**线性**的，而维度带来的表达能力增益是**对数级**的 (约 $e^{d/8}$ 的对数，即 $d/8$) ——这是为什么工程上不会无限制增大 d 的根本原因

解答 § 2.1

T-2.1.1 【one-hot 的两堵墙】

(a) 「猫」编号 1，「狗」编号 2：

$$\mathbf{e}_{\text{猫}} = (1, 0, 0, 0, 0), \quad \mathbf{e}_{\text{狗}} = (0, 1, 0, 0, 0)$$

(b) 所有不同词对的內积均为 0： $\mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{狗}} = 0$ ， $\mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{汽车}} = 0$ 。自身內积： $\mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{猫}} = 1$ 。

(c) 因为 $\mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{狗}} = \mathbf{e}_{\text{猫}}^T \mathbf{e}_{\text{汽车}} = 0$ ，两对词的「內积距离」完全相同。这意味着在 one-hot 表示下，「猫和狗的相似度」和「猫和汽车的相似度」数学上无法区分——表示空间中所有不同词对之间没有任何亲疏结构。

(d) one-hot 存储： $V \times V = 50000 \times 50000 = 2.5 \times 10^9$ 比特 (若每个向量独立存储)；或仅需存索引，即 50000 个整数，约 0.2 MB。嵌入存储： $V \times d \times 32 = 50000 \times 512 \times 32 = 8.192 \times 10^8$ 比特 = 102.4 MB。若比较「完整 one-hot 矩阵 vs 嵌入矩阵」，前者 2.5×10^9 bit $\approx$ 312.5 MB，嵌入矩阵约 102.4 MB，比值约 3:1；但 one-hot 存的信息量 (V^2 bit) 远大于嵌入矩阵 ($V \times d \times 32$ bit)，真正的压缩比约为 $V/(d \times 32) = 50000/16384 \approx 3$ 。

Sanity check：(b) 中所有不同词对內积均为 0，这是「任意两个不同标准基向量正交」的直接推论，不需要算——只要看到两向量的非零位置不重叠，內积就是 0。

T-2.1.2 【嵌入矩阵的查表操作】

(a) $\mathbf{e}_{w_2} = (0, 1, 0, 0)^T$ (第2分量为1, 其余为0)。

(b) $E^T \mathbf{e}_{w_2}$ 等于取 E^T 的第2列, 即 E 的第2行:

$$\mathbf{v}_{w_2} = (0.8, -0.3, 0.6)^T$$

(c) 标准矩阵乘法: $E^T \in \mathbb{R}^{3 \times 4}$, 乘 $\mathbf{e}_{w_2} \in \mathbb{R}^4$, 需要 $3 \times 4 = 12$ 次乘加操作 (一般化后是 $d \times V$)。直接取行: 仅 $d = 3$ 次复制操作。对 $V = 50000$, $d = 512$: 矩阵乘法 $\approx 512 \times 50000 = 2.56 \times 10^7$ 次; 取行操作 512 次, 加速比约 5×10^4 倍。

(d) 若只用一套矩阵, 则词 w 预测自身的得分为 $\mathbf{v}_w^T \mathbf{v}_w = \|\mathbf{v}_w\|^2$, 它总是非负且随训练增大 (模长在训练中通常增大)。这意味着优化目标会把每个词预测自己的得分推得最高——而「预测自己」在 Skip-gram 中是无意义的 (窗口内不包含自身), 这会导致所有词向量在训练中被「自吸引」地推向同一方向, 形成退化解。

Sanity check: (b) 的结果与直接读 E 第2行 $((0.8, -0.3, 0.6))$ 完全一致, 验证了「one-hot 乘法等价于取行」的命题。

T-2.1.3 【余弦相似度的动机与计算】

(a) 内积计算:

$$\mathbf{v}_{\text{猫}} \cdot \mathbf{v}_{\text{the}} = 0.6 \times 3.0 + 0.8 \times 4.0 + 0 + 0 = 1.8 + 3.2 = 5.0$$

$$\mathbf{v}_{\text{猫}} \cdot \mathbf{v}_{\text{狗}} = 0.6 \times 0.5 + 0.8 \times 0.7 + 0 \times 0.1 + 0 \times 0.1 = 0.3 + 0.56 = 0.86$$

(b) 模长:

$$\|\mathbf{v}_{\text{猫}}\| = \sqrt{0.36 + 0.64} = \sqrt{1.0} = 1.0$$

$$\|\mathbf{v}_{\text{the}}\| = \sqrt{9.0 + 16.0} = \sqrt{25.0} = 5.0$$

$$\|\mathbf{v}_{\text{狗}}\| = \sqrt{0.25 + 0.49 + 0.01 + 0.01} = \sqrt{0.76} \approx 0.8718$$

(c) 余弦相似度:

$$\cos(\mathbf{v}_{\text{猫}}, \mathbf{v}_{\text{the}}) = \frac{5.0}{1.0 \times 5.0} = 1.0000$$

$$\cos(\mathbf{v}_{\text{猫}}, \mathbf{v}_{\text{狗}}) = \frac{0.86}{1.0 \times 0.8718} \approx 0.9865$$

(d) 原始内积 (5.0 vs 0.86): 「猫更像 the」。余弦相似度 (1.0 vs 0.987): 「猫和 the 方向完全相同 (余弦=1), 猫和狗方向非常接近 (余弦 ≈ 0.99)」。从语义上, 猫和狗的相似度应该更高 (同类动物), 而猫和 the 没有语义关联。余弦相似度正确地消除了 the 的高频带来的模长偏置, 展示了语义方向的实际距离。

Sanity check: 注意到 $\mathbf{v}_{\text{the}} = 5 \cdot (0.6, 0.8, 0, 0) = 5\mathbf{v}_{\text{猫}}$ (方向完全相同, 模长是 5 倍), 因此余弦值精确为 1.0, 无需近似计算。

T-2.1.4 【分布假设与语义涌现的边界】

(a) Firth (1957) 分布假设：「一个词的意义由其所出现的语言环境决定」(You shall know a word by the company it keeps)。对「猫」和「狗」：两者都高频出现在「宠物」「毛茸茸的」「喂食」「叫」「跑」等相似上下文中，训练目标（预测上下文词）会把两者向量同时朝相同的上下文词方向拉近，最终在 $\mathbb{R}^d$ 中靠拢。

(b) 词对 X（「高兴」vs「快乐」）的余弦相似度更高，因为两词上下文高度重叠。词对 Y（bank 的两个义项）中，金融语义的「bank」（出现在「账户」「利率」「存款」周围）与河流语义的「bank」（出现在「水流」「河床」「泥土」周围）上下文完全不同，两者会被训练拉向不同方向——但它们共享同一个词形，只有一个向量，最终向量是两种语义的某种「加权平均」，与两种语义的单义同类词相比余弦相似度均较低且不稳定。

(c) 静态嵌入中「bank」只有一个向量，位于金融含义聚类 and 河流含义聚类的**中间地带**（由语料中两种用法的相对频率加权）。下游任务影响：情感分析、词义消歧等任务中，模型无法判断当前语境下「bank」是哪种含义，会系统性地引入噪声。解决方案是使用上下文相关嵌入。

(d) 上下文相关嵌入（BERT/GPT）的根本不同：**同一词在不同句子中产生不同的嵌入向量**，由注意力机制根据当前句子上下文动态计算。这是分布假设的动态推广——不是「词的全局上下文分布决定固定向量」，而是「当前句子的局部上下文决定当前的向量位置」。每次前向传播都重新计算当前 token 应该位于嵌入空间的哪个点。

Sanity check: (b) 的答案可以通过反证验证——如果「bank」两种义项的上下文没有任何重叠，那么在理想情况下，同形词「bank」的单一向量与任何单义词相比余弦相似度都不高；这符合「同形词嵌入语义模糊」的实验观察。

T-2.1.5 【嵌入维度的选择与信息容量权衡】

(a) 参数数量 = $V \times d$:

d	参数数	存储 (MB, float32)
64	3.2×10^6	12.8 MB
256	1.28×10^7	51.2 MB
512	2.56×10^7	102.4 MB
4096	2.048×10^8	819.2 MB

(b) 超位置能存储的近正交方向数 $\approx e^{d/8}$:

- $d = 64$: $e^8 \approx 3.0 \times 10^3$
- $d = 256$: $e^{32} \approx 7.9 \times 10^{13}$
- $d = 512$: $e^{64} \approx 6.2 \times 10^{27}$

(c) 实际英语语义中，独立的「基本语义维度」（如「生命/非生命」「具体/抽象」「情感极性」「句法类别」等）估计不超过数千个。 $d = 64$ 时超位置容量约 3000，接近这

一上限； $d = 256$ 时容量远超实际需求，因此提升边际递减。从另一角度： $d = 256$ 时每个方向对应约 $50000/256 \approx 196$ 个词「分享」该维度，足够稀疏；继续增大 d 带来的「每维度词数更少」的好处越来越小，而参数量线性增大。

(d) 注意力复杂度 $O(n^2d)$ 对 d 线性，比值 $= 4096/512 = 8$ 。即 $d = 4096$ 时每层注意力计算量是 $d = 512$ 的 8 倍，但表达能力（超位置容量的对数）从 64 增加到 512（约 8 倍），**计算代价和收益均线性相关于 d** 。这说明：在注意力主导的计算预算下，增大 d 带来的信息容量增益是线性的，但对序列长度 n 的适应能力（ $O(n^2)$ 项）不随 d 变化——若想用更长的上下文，增大 n 的代价（平方级）比增大 d （线性级）严峻得多。

Sanity check: (a) 中 $d = 512$ 时嵌入矩阵约 100 MB，对于一个总参数量约 7B（28 GB float32）的大模型，嵌入矩阵约占 0.4%，属于可接受范围。 $d = 4096$ 时嵌入矩阵约 800 MB，约占 3%，仍可接受，与业界 LLaMA/GPT-4 等模型的配置一致。

§ 2.1 小结：从 one-hot 正交性失效（题 1），到嵌入矩阵的 $O(d)$ 查表（题 2），到余弦相似度消除模长偏置（题 3），到分布假设的成立与失效边界（题 4），到维度选择的三方权衡（题 5）——这五道题拼出了词嵌入从「为什么需要」到「如何实现」再到「有什么边界」的完整逻辑链。下一节 § 2.2 的「国王 - 男人 + 女人 $\approx$ 女王」正是在这个基础上，把训练机制和几何涌现联系起来。

§2.4 习题：跨界映射——从罗马路网到曼哈顿距离

导读：本节核心是把「距离」的概念从欧氏 L^2 范数扩展到 L^p 范数族和加权内积（马氏距离），展示不同度量选择背后的「惩罚哲学」差异，最终说明词嵌入空间的「自然度量」是加权内积而非普通内积。五题分别对应： L^p 范数族的计算与单位球几何、平行四边形恒等式作为内积范数的充要条件、马氏距离的计算与白化解释、度量选择对最近邻结果的影响、从工程应用角度判断何时用哪种度量。

题1【轻·计算· L^p 范数族与单位球几何】

导读：三种范数的公式相差一个参数 p ，但对应的几何形状截然不同——把这个差异从数字算出来而不是从图里看。

设二维向量 $\mathbf{x} = (3, 4)$ 。

- 分别计算 $\|\mathbf{x}\|_1$ （曼哈顿距离）、 $\|\mathbf{x}\|_2$ （欧氏范数）、 $\|\mathbf{x}\|_\infty$ （Chebyshev 范数）。
- 写出 $\mathbb{R}^2$ 中三种范数的「单位球」（即到原点距离恰好为 1 的点的集合）的几何描述： L^1 是什么形状， L^2 是什么形状， L^∞ 是什么形状？
- 对于向量 $\mathbf{y} = (0.6, 0.8)$ ，验证 $\|\mathbf{y}\|_1 > \|\mathbf{y}\|_2 > \|\mathbf{y}\|_\infty$ （即三种范数的大小顺序），并证明这个不等式对所有非零向量 $\mathbf{x} \in \mathbb{R}^d$ 均成立（不要求严格证明，给出数量级论证即可）。
- 在机器学习中，正则化项的选择（ L^1 vs L^2 ）会导致不同的稀疏性行为。解释为什么 L^1 正则化（LASSO）倾向于产生稀疏解，而 L^2 正则化（Ridge）倾向于让参数均匀收缩——从「单位球的几何形状」角度给出几何直觉。

教学注：(d) 是把「单位球的几何形状」从可视化工具变成理解 LASSO/Ridge 的钥匙。这个直觉在后面理解稀疏自编码器（SAE）和白化变换时也会再次出现。

陷阱：

- 不要搞错 L^1 和 L^∞ 的大小关系—— L^1 对所有分量绝对值求和， L^∞ 取最大值，对 $d > 1$ 的非零向量有 $\|\mathbf{x}\|_1 \geq \|\mathbf{x}\|_\infty$
- (b) 中 L^∞ 的单位球是正方形，不是旋转 45° 的正方形（那是 L^1 ）

题2【中·推导·平行四边形恒等式与内积范数】

导读：能从内积诱导出来的范数，与仅仅满足三角不等式的范数，差在哪里？一条恒等式把这面墙画出来。

(a) 设内积空间 $(V, \langle \cdot, \cdot \rangle)$ ，令 $\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle}$ 。证明平行四边形恒等式：

$$\|\mathbf{u} + \mathbf{v}\|^2 + \|\mathbf{u} - \mathbf{v}\|^2 = 2\|\mathbf{u}\|^2 + 2\|\mathbf{v}\|^2$$

（提示：展开 $\langle \mathbf{u} \pm \mathbf{v}, \mathbf{u} \pm \mathbf{v} \rangle$ ，用内积的双线性和对称性。）

(b) 验证 L^1 范数不满足平行四边形恒等式：取 $\mathbf{u} = (1, 0)$, $\mathbf{v} = (0, 1)$, 计算左侧和右侧的值。

(c) 由 (a) 和 (b) 可知： L^2 范数来自内积， L^1 范数不来自内积。这对词嵌入有什么实际含义？具体地，以下哪些操作在 L^1 空间里没有合法定义，但在 L^2 （欧氏内积）空间里有？- 余弦相似度 - 向量在某方向上的投影 ($\mathbf{u} \cdot \hat{\mathbf{v}} = \|\mathbf{u}\| \cos \theta$) - 自注意力机制的点积 $\mathbf{q}^T \mathbf{k}$

(d) 「满足平行四边形恒等式」是「范数来自内积」的充要条件 (Jordan-von Neumann 定理)。这意味着：如果我们希望词嵌入空间保留「夹角、投影、正交分解」这些工具，就**必须**工作在（某个）内积空间里。写出加权内积 $\langle \mathbf{u}, \mathbf{v} \rangle_G = \mathbf{u}^T G \mathbf{v}$ ($G \succ 0$) 诱导的范数和距离公式。

教学注：这道题把内积空间和度量空间的区分从「概念」变成「可验证的代数判断」。Jordan-von Neumann 定理告诉我们：余弦相似度能用，不是因为「方便」，而是因为背后有内积结构——如果用 L^1 ，连余弦的定义都没有。

陷阱：

- (a) 中要用内积双线性展开，不要用坐标暴力计算（那只验证了特例，不是证明）
- (c) 中点积 $\mathbf{q}^T \mathbf{k}$ 本身只是一个数值运算，不依赖空间结构——真正的问题是「这个点积能否被解释为「夹角余弦 $\times$ 模长乘积」，即内积空间结构」

题 3 【中 · 计算 · 马氏距离与白化的几何解释】

导读：马氏距离的真正意义是「先白化，再算欧氏距离」——把这条等价关系从公式里算出来。

设二维嵌入空间中有三个词向量（已去均值）：

$$\mathbf{v}_A = (2, 1), \quad \mathbf{v}_B = (1, 3), \quad \mathbf{v}_C = (2, 4)$$

嵌入集合的协方差矩阵估计为：

$$\Sigma = \begin{pmatrix} 4 & 1 \\ 1 & 1 \end{pmatrix}$$

(a) 计算欧氏距离 $d_2(\mathbf{v}_A, \mathbf{v}_B)$ 和 $d_2(\mathbf{v}_A, \mathbf{v}_C)$ 。按欧氏距离， A 更靠近 B 还是 C ？

(b) 计算 $G = \Sigma^{-1}$ （马氏距离的度量矩阵）。提示：对 2×2 矩阵 $\begin{pmatrix} a & b \\ c & d \end{pmatrix}$ ，逆为 $\frac{1}{ad-bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$ 。

(c) 计算马氏距离 $d_G(\mathbf{v}_A, \mathbf{v}_B) = \sqrt{(\mathbf{v}_A - \mathbf{v}_B)^T G (\mathbf{v}_A - \mathbf{v}_B)}$ 和 $d_G(\mathbf{v}_A, \mathbf{v}_C)$ 。按马氏距离， A 更靠近 B 还是 C ？

(d) 协方差矩阵 Σ 的对角线元素 $\Sigma_{11} = 4 \gg \Sigma_{22} = 1$ ，意味着第 1 维方差远大于第 2

维。解释为什么欧氏距离在这种情形下被第 1 维「主导」，而马氏距离通过 Σ^{-1} 消除了这种主导效应。

教学注：(a) 和 (c) 对比的意义：欧氏距离说「A 更近 B (或 C)」，马氏距离可能给出相反结论——这不是哪个「错了」，而是两者代表不同的假设。欧氏距离假设各方向等权；马氏距离假设高方差方向上的同等位移代表更小的语义差异（因为该方向上的随机波动本来就大）。

陷阱：

- (b) 中需要先算行列式 $\det(\Sigma) = 4 \times 1 - 1 \times 1 = 3$ ，不是 $4 - 1 = 3$ 的直觉省略版，要写清楚
- (c) 中 d_G 是带根号的，不要漏算

题 4 【重 · 综合 · 度量选择对最近邻结果的影响】

导读：「用什么度量」不只是数学问题，而是直接决定了下游任务（语义搜索、文档检索）的结果。

设 5 维词嵌入空间中有如下 4 个词向量（已给出归一化版本和原始版本）：

$$\mathbf{v}_{\text{苹果}} = (0.9, 0.1, 0.2, 0.0, 0.1), \quad \|\mathbf{v}_{\text{苹果}}\| \approx 0.937$$

$$\mathbf{v}_{\text{香蕉}} = (0.8, 0.2, 0.1, 0.1, 0.1), \quad \|\mathbf{v}_{\text{香蕉}}\| \approx 0.837$$

$$\mathbf{v}_{\text{the}} = (4.5, 0.5, 1.0, 0.0, 0.5), \quad \|\mathbf{v}_{\text{the}}\| \approx 4.685$$

$$\mathbf{v}_{\text{科技}} = (0.1, 0.9, 0.8, 0.7, 0.2), \quad \|\mathbf{v}_{\text{科技}}\| \approx 1.350$$

以「苹果」为查询词，分别用以下三种度量找最近邻（从其余 3 个词中选）：

(a) 欧氏距离 L^2 ：对每对词计算 $\|\mathbf{v}_{\text{苹果}} - \mathbf{v}_?\|_2$ ，给出距离最小的词。（可以只比较平方距离，省略开根号。）

(b) 余弦相似度：对每对词计算 $\cos(\mathbf{v}_{\text{苹果}}, \mathbf{v}_?)$ ，给出余弦值最大的词。

(c) 曼哈顿距离 L^1 ：对每对词计算 $\|\mathbf{v}_{\text{苹果}} - \mathbf{v}_?\|_1$ ，给出距离最小的词。

(d) 三种度量给出的最近邻相同吗？如果不同，分析原因。从语义合理性角度，哪种度量的结果最符合「苹果和香蕉都是水果」的直觉？

(e) 在向量数据库（如 FAISS）中，默认的相似度函数通常是**内积或余弦相似度**而非 L^1 距离。结合 (d) 的分析和题 2 中关于内积空间的讨论，给出一个理论层面的理由。

教学注：这道题的核心是让「度量选择的影响」不停留在抽象讨论层面，而是通过具体数字感受「高频词 the 的模长偏大如何污染欧氏和 L^1 距离，而余弦归一化如何消除这种污染」。这是 § 2.5 各向异性讨论的量化预演。

陷阱：

- (a) 的平方距离： $\|\mathbf{v}_{\text{苹果}} - \mathbf{v}_{\text{the}}\|_2^2$ 中，「the」每个分量都远大于「苹果」，差值很大，不要低估

- (b) 中 $\mathbf{v}_{\text{the}}$ 的方向 $((4.5, 0.5, 1.0, 0, 0.5)/4.685 \approx (0.96, 0.11, 0.21, 0, 0.11))$ 与 $\mathbf{v}_{\text{苹果}}$ 的归一化方向 $((0.9, 0.1, 0.2, 0, 0.1)/0.937 \approx (0.96, 0.11, 0.21, 0, 0.11))$ 几乎一致——这是设计的，用以说明高频词方向问题

题5【重·评判·何时用哪种度量】

导读：没有一种度量是普适最优的——正确的选择来自「该度量的假设与数据结构是否匹配」。把这个判断从直觉变成可操作的标准。

阅读以下五个工程场景，为每个场景选择最合适的度量（ L^2 欧氏距离、 L^1 曼哈顿距离、 L^∞ Chebyshev 距离、余弦相似度、马氏距离），并说明理由。

场景 A：语义文档检索——给定一段查询文本，在大型文档库中找出语义最相关的文档。文档嵌入由未经白化的 BERT 编码器生成。

场景 B：城市路网导航——在棋盘格状的城市（曼哈顿）中，一辆出租车只能沿街道（水平或垂直方向）行驶，需要计算两点间的最短路程。

场景 C：异常检测——在高维工业传感器数据中（各传感器量纲和方差不同），判断一个新样本是否是离群点。传感器数据已知其协方差矩阵 Σ 。

场景 D：词汇类比推理——用「向量算术」方法 $(\mathbf{v}_A - \mathbf{v}_B + \mathbf{v}_C)$ 在静态词嵌入中寻找最近邻词 D ，要求最大化类比准确率。

场景 E：对抗鲁棒性检测——判断两张图片的像素是否「看起来一样」，其中攻击者通过改变少数几个像素（可以改变很大）来欺骗分类器。需要一种对单个像素极端变化敏感的距离。

(a) 对每个场景，给出推荐度量和一句话理由。

(b) 场景 A 中选择余弦而非欧氏的关键原因是「BERT 嵌入各向异性严重」。若将 BERT 嵌入先经过白化变换，然后改用 L^2 欧氏距离，结果会改变吗？为什么？

(c) 场景 D 和场景 A 都在词嵌入空间里做最近邻，但推荐的度量可能不同（场景 D 通常用欧氏距离，场景 A 用余弦）。解释这种差异：向量算术为什么对模长不敏感，而文档相似度检索为什么要归一化？

(d) 写出内积空间 $(\mathbb{R}^d, \langle \cdot, \cdot \rangle_G)$ 的「余弦相似度」公式（即用加权内积代替普通内积的余弦）：

$$\cos_G(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u}^T G \mathbf{v}}{\sqrt{\mathbf{u}^T G \mathbf{u}} \cdot \sqrt{\mathbf{v}^T G \mathbf{v}}}$$

说明当 $G = \Sigma^{-1}$ 时，这等价于在白化后的空间计算普通余弦相似度。

教学注：题5把前四道题的数学工具整合成「工程决策框架」。核心原则只有一条：**选择度量 = 对「哪些方向上的差异更重要」做出假设**；与数据内在结构最匹配的度量最好，没有普适答案。

陷阱：

- 场景 D 中类比算术（向量加减）的结果本质上是欧氏加法，用欧氏距离找最近邻

更一致；但若嵌入各向异性严重，欧氏最近邻可能被高频词主导，此时可以先白化再用欧氏

- 场景 C 中「各传感器量纲不同」正是马氏距离的使用场景，不能用欧氏（等权）

解答 § 2.4

T-2.4.1 【 L^p 范数族与单位球几何】

(a) $\mathbf{x} = (3, 4)$:

$$\begin{aligned}\|\mathbf{x}\|_1 &= |3| + |4| = 7 \\ \|\mathbf{x}\|_2 &= \sqrt{9 + 16} = \sqrt{25} = 5 \\ \|\mathbf{x}\|_\infty &= \max(3, 4) = 4\end{aligned}$$

(b) 二维单位球的几何形状:

- L^1 : 菱形（旋转 45° 的正方形），顶点在坐标轴上 $(\pm 1, 0)$ 和 $(0, \pm 1)$
- L^2 : 圆（单位圆）
- L^∞ : 正方形，顶点在 $(\pm 1, \pm 1)$

(c) $\mathbf{y} = (0.6, 0.8)$:

$$\|\mathbf{y}\|_1 = 1.4, \quad \|\mathbf{y}\|_2 = 1.0, \quad \|\mathbf{y}\|_\infty = 0.8$$

确认 $1.4 > 1.0 > 0.8$ 。一般证明：对 $\mathbf{x} \neq \mathbf{0}$ ，设最大分量为 $x_{\max}$ ，则 $\|\mathbf{x}\|_\infty = x_{\max} \leq \|\mathbf{x}\|_2 = \sqrt{\sum x_i^2} \leq \sqrt{d \cdot x_{\max}^2} = \sqrt{d} \cdot x_{\max}$ ；而 $\|\mathbf{x}\|_1 = \sum |x_i| \geq \|\mathbf{x}\|_2$ （由 Cauchy-Schwarz: $\|\mathbf{x}\|_1 = \mathbf{1}^T \mathbf{x} \leq \sqrt{d} \|\mathbf{x}\|_2$ ，但另一方向 $\|\mathbf{x}\|_1 \geq \|\mathbf{x}\|_2$ 由 $(\sum |x_i|)^2 \geq \sum x_i^2$ ）。

(d) LASSO 稀疏解直觉：在参数空间中，约束集 $\|\theta\|_1 \leq C$ 是菱形，其尖角在坐标轴上。梯度下降轨迹与菱形约束边界相交，最可能「碰」到的是菱形的角点（某些参数为零）； L^2 球是圆，没有角点，与任意方向的直线相交都在「内部」，不会产生精确零值。

Sanity check: $\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_2 \leq \|\mathbf{x}\|_1$ 对任意 $\mathbf{x}$ 成立（ $d = 1$ 时取等），这是范数的经典不等式，可用 $\mathbf{x} = (3, 4)$ 的数值 $4 \leq 5 \leq 7$ 验证。

T-2.4.2 【平行四边形恒等式与内积范数】

(a) 展开:

$$\|\mathbf{u} + \mathbf{v}\|^2 = \langle \mathbf{u} + \mathbf{v}, \mathbf{u} + \mathbf{v} \rangle = \langle \mathbf{u}, \mathbf{u} \rangle + 2\langle \mathbf{u}, \mathbf{v} \rangle + \langle \mathbf{v}, \mathbf{v} \rangle = \|\mathbf{u}\|^2 + 2\langle \mathbf{u}, \mathbf{v} \rangle + \|\mathbf{v}\|^2$$

$$\|\mathbf{u} - \mathbf{v}\|^2 = \langle \mathbf{u} - \mathbf{v}, \mathbf{u} - \mathbf{v} \rangle = \|\mathbf{u}\|^2 - 2\langle \mathbf{u}, \mathbf{v} \rangle + \|\mathbf{v}\|^2$$

两式相加: $\|\mathbf{u} + \mathbf{v}\|^2 + \|\mathbf{u} - \mathbf{v}\|^2 = 2\|\mathbf{u}\|^2 + 2\|\mathbf{v}\|^2$ 。证毕。

(b) 取 $\mathbf{u} = (1, 0)$, $\mathbf{v} = (0, 1)$:

- 左侧: $\|\mathbf{u} + \mathbf{v}\|_1^2 + \|\mathbf{u} - \mathbf{v}\|_1^2 = \|(1, 1)\|_1^2 + \|(1, -1)\|_1^2 = 2^2 + 2^2 = 8$
- 右侧: $2\|\mathbf{u}\|_1^2 + 2\|\mathbf{v}\|_1^2 = 2 \cdot 1^2 + 2 \cdot 1^2 = 4$

$8 \neq 4$, L^1 范数不满足平行四边形恒等式, 故不来自内积。

(c) 余弦相似度、向量投影、自注意力点积的「几何解释」(夹角余弦)——这三者都依赖「内积 = 模长乘积 $\times$ 余弦值」这一关系, 即极化恒等式 $\langle \mathbf{u}, \mathbf{v} \rangle = \frac{1}{4}(\|\mathbf{u} + \mathbf{v}\|^2 - \|\mathbf{u} - \mathbf{v}\|^2)$, 而这个等式要求满足平行四边形恒等式。 L^1 空间中没有内积, 上述所有「几何解释」失去数学基础(数值上仍可计算, 但失去了「角度」的含义)。

(d) 加权内积诱导的范数: $\|\mathbf{x}\|_G = \sqrt{\mathbf{x}^T G \mathbf{x}}$; 诱导的距离(马氏距离):

$$d_G(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\|_G = \sqrt{(\mathbf{u} - \mathbf{v})^T G (\mathbf{u} - \mathbf{v})}$$

Sanity check: (a) 的证明用了内积的三条性质(对称性、线性性、正定性), 这三条正是内积空间定义——平行四边形恒等式是这三条的推论, 说明「来自内积的范数」必然满足它, 逻辑闭合。

T-2.4.3 【马氏距离与白化的几何解释】

(a) 欧氏平方距离:

$$d_2^2(\mathbf{v}_A, \mathbf{v}_B) = (2 - 1)^2 + (1 - 3)^2 = 1 + 4 = 5, \quad d_2(\mathbf{v}_A, \mathbf{v}_B) \approx 2.236$$

$$d_2^2(\mathbf{v}_A, \mathbf{v}_C) = (2 - 2)^2 + (1 - 4)^2 = 0 + 9 = 9, \quad d_2(\mathbf{v}_A, \mathbf{v}_C) = 3.0$$

按欧氏距离, A 更靠近 B (距离 $2.236 < 3.0$)。

(b) $\det(\Sigma) = 4 \times 1 - 1 \times 1 = 3$, 故:

$$G = \Sigma^{-1} = \frac{1}{3} \begin{pmatrix} 1 & -1 \\ -1 & 4 \end{pmatrix} = \begin{pmatrix} 1/3 & -1/3 \\ -1/3 & 4/3 \end{pmatrix}$$

(c) 差向量: $\mathbf{v}_A - \mathbf{v}_B = (1, -2)$, $\mathbf{v}_A - \mathbf{v}_C = (0, -3)$ 。

马氏平方距离:

$$d_G^2(\mathbf{v}_A, \mathbf{v}_B) = (1, -2) \begin{pmatrix} 1/3 & -1/3 \\ -1/3 & 4/3 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \end{pmatrix}$$

先算 $G \cdot (1, -2)^T = (1/3 + 2/3, -1/3 - 8/3) = (1, -3)$, 再内积: $(1)(1) + (-2)(-3) = 1 + 6 = 7$ 。故 $d_G(\mathbf{v}_A, \mathbf{v}_B) = \sqrt{7} \approx 2.646$ 。

$(0, -3) \cdot G \cdot (0, -3)^T$: 先算 $G \cdot (0, -3)^T = (1, -4)$, 内积: $(0)(1) + (-3)(-4) = 12$ 。故 $d_G(\mathbf{v}_A, \mathbf{v}_C) = \sqrt{12} \approx 3.464$ 。

按马氏距离, A 仍更靠近 B ($2.646 < 3.464$), 但两者的相对差距缩小了。(本例中结论相同, 但若第 1 维方差更大, 结论可能反转。)

(d) $\Sigma_{11} = 4$ 远大于 $\Sigma_{22} = 1$ ，意味着嵌入集合在第 1 维上散布更广（4 倍）。欧氏距离把两维等权相加， $d_2^2 = \Delta x_1^2 + \Delta x_2^2$ ，第 1 维上的差异 Δx_1^2 被高方差放大，主导最终结果。马氏距离用 Σ^{-1} 归一化，将第 1 维的差异除以 4（方差），每维的「标准化偏差」相当，消除了高方差维度的主导效应。

Sanity check: $G = \Sigma^{-1}$ 的对角线元素 $G_{11} = 1/3 < G_{22} = 4/3$ ，说明第 1 维（高方差）被马氏距离赋予了更低的权重，这正是「消除高方差主导」的数学体现。

T-2.4.4 【度量选择对最近邻结果的影响】

(a) 欧氏平方距离（苹果 vs 各词）：

- vs 香蕉： $(0.1)^2 + (-0.1)^2 + (0.1)^2 + (-0.1)^2 + (0)^2 = 0.04$ ， $d_2 \approx 0.200$
- vs the： $(-3.6)^2 + (-0.4)^2 + (-0.8)^2 + (0)^2 + (-0.4)^2 = 12.96 + 0.16 + 0.64 + 0 + 0.16 = 13.92$ ， $d_2 \approx 3.731$
- vs 科技： $(0.8)^2 + (-0.8)^2 + (-0.6)^2 + (-0.7)^2 + (-0.1)^2 = 0.64 + 0.64 + 0.36 + 0.49 + 0.01 = 2.14$ ， $d_2 \approx 1.463$

欧氏最近邻：香蕉（ $d_2 \approx 0.200$ ）。

(b) 余弦相似度（先计算各向量的模长）：苹果模长 ≈ 0.937 ，香蕉 ≈ 0.837 ，the ≈ 4.685 ，科技 ≈ 1.350 。

- vs 香蕉： $\frac{0.45+0.07+0.02+0+0.01}{0.937 \times 0.837} = \frac{0.55}{0.784} \approx 0.701$
- vs the： $\frac{4.05+0.05+0.2+0+0.05}{0.937 \times 4.685} = \frac{4.35}{4.389} \approx 0.991$
- vs 科技： $\frac{0.09+0.09+0.16+0+0.02}{0.937 \times 1.350} = \frac{0.36}{1.265} \approx 0.285$

余弦相似度最高：the（ ≈ 0.991 ）。注意「苹果」向量的方向与「the」几乎完全相同（刻意设计），这揭示了各向异性问题。

(c) 曼哈顿距离：

- vs 香蕉： $|0.1| + |0.1| + |0.1| + |0.1| + |0| = 0.4$
- vs the： $3.6 + 0.4 + 0.8 + 0 + 0.4 = 5.2$
- vs 科技： $0.8 + 0.8 + 0.6 + 0.7 + 0.1 = 3.0$

曼哈顿最近邻：香蕉（0.4）。

(d) 欧氏和曼哈顿均选香蕉（符合语义），余弦选「the」（因为「苹果」向量方向被高频词方向主导）。从语义角度，香蕉更正确。这说明未白化嵌入中余弦相似度被各向异性污染，而欧氏距离（对相似模长的词）反而给出了更合理的语义结果。但在实际 BERT 嵌入中（各词模长变化更大），欧氏距离也会被模长污染——因此最佳实践是先白化再用欧氏（等效于马氏距离）。

(e) 理论理由：词嵌入空间（依赖余弦、注意力点积）隐含工作在内积空间中； L^1 不满足平行四边形恒等式，故没有内积结构，无法定义余弦（方向）。向量数据库用内积/余弦是因为内积空间提供了完整的几何工具链（投影、正交分解、注意力机制）； L^1 在数值上可计算，但失去了「方向」的语义解释。

Sanity check: (b) 中「苹果」vs「the」余弦 ≈ 0.991 说明两者方向几乎完全一致（ $\cos^{-1}(0.991) \approx 7.7^\circ$ ）——这是刻意设计以演示高频词污染问题，在实际语料中也有

类似现象（高频词嵌入方向与多数其他词对齐）。

T-2.4.5 【何时用哪种度量】

(a) 推荐度量：

- **场景 A：余弦相似度**——BERT 嵌入各向异性严重，高频词模长偏大，余弦归一化消除模长偏置，只比较语义方向。
- **场景 B： L^1 曼哈顿距离**——出租车只能水平/垂直行驶，每一段路程就是一个坐标分量的差值，总路程正是各分量绝对差之和， L^1 的物理含义完美匹配。
- **场景 C：马氏距离** ($G = \Sigma^{-1}$)——不同传感器量纲和方差不同，欧氏距离被高方差传感器主导；马氏距离归一化各方向方差，每方向「一个标准差的偏离」贡献相等，适合检测统计意义上的离群。
- **场景 D： L^2 欧氏距离**——向量算术结果 $\mathbf{v}_A - \mathbf{v}_B + \mathbf{v}_C$ 是欧氏加法，最近邻搜索应与运算保持一致；而且类比关系（平行四边形）的几何意义在欧氏空间中最自然。
- **场景 E： L^∞ Chebyshev 距离**——攻击者只改变少数几个像素但改变幅度很大， L^∞ 只看最大绝对差，对「单维极端变化」最敏感； L^2 会把大量微小变化的贡献累加，可能忽略单个像素的极端改动。

(b) 白化后用 L^2 与直接用余弦的效果相近但不完全等价。白化使协方差矩阵变为 I_d ，此后 L^2 距离等价于马氏距离 ($G = \Sigma^{-1}$ 时)，也等价于在白化空间的余弦（若白化后模长均匀）。实践中，白化后 L^2 在 STS 基准上与余弦表现相近，甚至更好 (Su 等 2021)——因为白化同时消除了模长偏置，余弦的额外归一化变得冗余。

(c) 向量算术 $\mathbf{v}_A - \mathbf{v}_B + \mathbf{v}_C$ 是模长敏感的运算——结果向量的模长由参与运算的词向量模长决定，直接用欧氏距离找最近邻更与运算逻辑一致。文档检索中，查询词和文档的嵌入来自不同长度的文本，模长本身携带了「文本长度」的信息而非纯语义信息，归一化消除这个额外因素后，余弦更精确地度量语义方向相似性。

(d) 加权余弦 $\cos_G(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u}^T G \mathbf{v}}{\sqrt{\mathbf{u}^T G \mathbf{u}} \sqrt{\mathbf{v}^T G \mathbf{v}}}$ 。当 $G = \Sigma^{-1}$ ，令 $\tilde{\mathbf{u}} = \Lambda^{-1/2} U^T \mathbf{u}$ （白化变换），则：

$$\tilde{\mathbf{u}}^T \tilde{\mathbf{v}} = \mathbf{u}^T U \Lambda^{-1/2} \cdot \Lambda^{-1/2} U^T \mathbf{v} = \mathbf{u}^T U \Lambda^{-1} U^T \mathbf{v} = \mathbf{u}^T \Sigma^{-1} \mathbf{v} = \mathbf{u}^T G \mathbf{v}$$

因此 $\cos_G(\mathbf{u}, \mathbf{v}) = \cos(\tilde{\mathbf{u}}, \tilde{\mathbf{v}})$ ，即加权余弦等于在白化空间中计算普通余弦。

Sanity check: (d) 的等价关系说明「马氏余弦 = 白化后欧氏余弦」，这把三个概念（加权内积、白化变换、余弦相似度）统一在同一条数学路径上，是本节「选择度量 = 选择几何观」这一核心洞见的代数闭合。

§2.4 小结：从 L^p 范数族的「惩罚哲学」（题 1），到内积范数的代数判据（题 2），到马氏距离的白化几何解释（题 3），到具体数值下度量选择对最近邻的影响（题 4），到工程应用中的度量决策框架（题 5）——这五道题串成了「选择度量 = 对数据几何结构做假设」这条逻辑链。下一节 §2.5 会展示当嵌入空间几何被词频统计污染时，这条链如何在现实中断裂，以及如何用白化修复。

§2.5 习题：反类比——当几何隐喻失效

导读：本节核心是从负采样的噪声分布出发，追溯出高频词椎体效应、嵌入空间各向异性、余弦相似度失效，最终说明「嵌入空间是干净语义坐标系」这一隐喻在实际中如何破裂，以及白化修复的代价。五题分别对应：各向异性指标的计算与解读、椎体效应的训练机制追溯、白化变换的代数实现与验证、白化对类比算术的破坏、综合判断五条「嵌入空间几何隐喻」的合法性边界。

题1【轻·计算·各向异性指标的计算与解读】

导读：把「嵌入空间各向异性」从定性描述变成一个可计算的数，理解这个数为什么能揭示余弦相似度的失效。

设3维嵌入空间中有4个词向量（已经过模长归一化）：

$$\hat{\mathbf{v}}_1 = (0.98, 0.14, 0.14), \quad \hat{\mathbf{v}}_2 = (0.97, -0.15, 0.19)$$

$$\hat{\mathbf{v}}_3 = (0.99, 0.10, -0.10), \quad \hat{\mathbf{v}}_4 = (0.96, 0.20, -0.19)$$

(a) 计算所有 $\binom{4}{2} = 6$ 个词对的余弦相似度（由于向量已归一化，余弦值即内积）。

(b) 计算平均余弦相似度 $\text{c}\ddot{\text{o}}\text{s} = \frac{1}{\binom{V}{2}} \sum_{i < j} \cos(\hat{\mathbf{v}}_i, \hat{\mathbf{v}}_j)$ （取 $V = 4$ ）。

(c) 若这4个向量是均匀随机分布在单位球面上的，预期平均余弦相似度约为多少（从§2.3的结论出发）？与(b)的结果对比，说明这4个向量的各向异性程度。

(d) 这4个向量都高度集中在第1维方向附近（第1分量均接近1）。假设「the」「of」等高频词集中在这个方向附近，而「量子纠缠」「罗马法」等低频词向量分布在各方向。解释为什么在这种情形下，用余弦相似度计算「量子纠缠」与「罗马法」的语义相似度，结果会被高频词方向偏置。

教学注：(a)(b) 建立量化感受—— $\text{c}\ddot{\text{o}}\text{s} \approx 0.95$ 意味着几乎所有词「指向同一方向」，余弦相似度在这里测量的根本不是语义差异，而是与主导方向的对齐程度。

陷阱：

- 归一化向量的内积直接就是余弦值，不需要再除以模长——但要先检查是否真的已归一化（模长是否为1）
- (c) 中随机向量的期望余弦相似度是0（不是「接近0的一个小数」），这是各向同性的理论基准

题2【中·推导·椎体效应的训练机制追溯】

导读：椎体效应不是偶然出现的，而是负采样目标函数的数学必然后果——把这条因果链从公式里推出来。

负采样的梯度公式（针对上下文词向量 $\mathbf{u}_c$ ）：

$$\nabla_{\mathbf{u}_c} \mathcal{L}_{\text{NEG}} = -\sigma(\mathbf{u}_c^T \mathbf{v}_w) \cdot \mathbf{v}_w \quad (\text{当 } c \text{ 为负样本时})$$

其中 $\sigma(x) = 1/(1 + e^{-x})$ 为 sigmoid 函数, $\mathbf{v}_w$ 为当前中心词向量。

(a) 假设词「the」的频率 $f(\text{the}) = 0.05$ (5%), 词「obscure」的频率 $f(\text{obscure}) = 0.00001$ (0.001%)。在噪声分布 $P_n(c) \propto f(c)^{3/4}$ 下, 「the」被选为负样本的概率与「obscure」的比值约为多少? (计算 $f(\text{the})^{3/4}/f(\text{obscure})^{3/4}$, 用科学计数法表示。)

(b) 设某一训练 step 中, 中心词为「猫」, 「the」被选为负样本, $\sigma(\mathbf{u}_{\text{the}}^T \mathbf{v}_{\text{猫}}) = 0.7$ 。写出这一步对 $\mathbf{u}_{\text{the}}$ 施加的梯度更新方向, 并说明它的物理含义 («推开» 还是 «拉近»)。

(c) 设在整个训练过程中, 「the」被选为负样本共 $N_1 = 10^6$ 次, 而「obscure」被选为负样本共 $N_2 = 200$ 次。假设每次梯度更新的步长 $\eta = 0.01$, 平均 $\sigma(\mathbf{u}_c^T \mathbf{v}_w) \approx 0.5$, 每次更新中 $\|\mathbf{v}_w\| \approx 1$ 。估算「the」和「obscure」的上下文向量各自被累计推离其初始位置的大致距离 (假设方向大致相同, 可以直接累加)。

(d) 词频服从 Zipf 定律: 最高频词的频率是第 k 高频词的约 k 倍 (即频率 $\propto 1/k$)。从这一定律出发, 解释为什么嵌入空间中「高频词聚集成一个低维锥」是统计上不可避免的——不是特定训练数据的偶然, 而是任何遵循 Zipf 定律的语言数据的必然结果。

教学注: (c) 的估算虽然粗糙, 但数量级感受是重要的: 「the」被推了约 $10^6 \times 0.01 \times 0.5 = 5000$ 步, 「obscure」只被推了约 $200 \times 0.01 \times 0.5 = 1$ 步——两者所受的排斥力相差 5000 倍, 这就是椎体效应的数量级根源。

陷阱:

- (b) 中梯度更新方向是 $-\eta \nabla_{\mathbf{u}_c}$, 要注意负号——梯度下降走负梯度方向; 负采样的负梯度方向是把「the」的向量**推离**当前中心词
- (d) 不要只说「高频词出现多」——要从「Zipf 定律下排名靠前的那少数几个词占据了大量概率质量」推导出「排斥梯度集中在少数词上」

题 3 【中 · 计算 · 白化变换的代数实现】

导读: 白化不是一个神秘的操作, 就是「PCA + 按特征值归一化」——把这条变换从矩阵分解到最终结果, 完整算一遍。

设 3 维嵌入空间, 嵌入矩阵 (去均值后) 的协方差矩阵估计为:

$$\Sigma = \begin{pmatrix} 9 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0.25 \end{pmatrix}$$

(对角矩阵, 说明各维度不相关, 方差分别为 9、1、0.25。)

有两个词向量 $\mathbf{v}_A = (3, 1, 0.5)$ 和 $\mathbf{v}_B = (1, 3, 0.5)$ 。

(a) 写出 Σ 的特征分解 $\Sigma = U \Lambda U^T$ (对角矩阵时特征向量矩阵 $U = I$, $\Lambda = \Sigma$)。

(b) 计算白化矩阵 $W = \Lambda^{-1/2} U^T$ (即 $\Lambda^{-1/2}$, 因为 $U = I$), 并写出其对角元素。

(c) 计算白化后的向量 $\tilde{\mathbf{v}}_A = W \mathbf{v}_A$ 和 $\tilde{\mathbf{v}}_B = W \mathbf{v}_B$ 。

(d) 计算原始向量的余弦相似度 $\cos(\mathbf{v}_A, \mathbf{v}_B)$ ，以及白化后向量的余弦相似度 $\cos(\tilde{\mathbf{v}}_A, \tilde{\mathbf{v}}_B)$ 。两者是否不同？解释为什么白化后余弦相似度会改变。

(e) 验证：白化后的向量协方差（近似地，用两个向量模拟）是否更接近各向同性（即各方向方差相等）。

教学注：白化把高方差维度（这里是第1维，方差=9）「压缩」，把低方差维度（第3维，方差=0.25）「放大」，使得所有维度的方差都变为1。这道题通过具体数字展示：白化**确实**改变了余弦相似度——这正是「白化是有代价的」的量化依据。

陷阱：

- $\Lambda^{-1/2}$ 的对角元素是 $\lambda_i^{-1/2} = 1/\sqrt{\lambda_i}$ ，不是 $1/\lambda_i$
- (d) 中若白化后余弦值变化，要解释清楚：白化改变了向量的相对方向（因为不同维度被不等比例缩放），余弦相似度随之改变

题4【重·综合·白化对类比算术的破坏】

导读：白化在语义相似度任务上提升表现，但在类比推理任务上可能降低准确率——这个矛盾的背后是一个深层的「噪声与信号耦合」问题。

沿用题3的设置，但现在考虑词向量中编码了「性别」语义关系：

$$\mathbf{v}_{\text{国王}} = (3, 1, 1), \quad \mathbf{v}_{\text{女王}} = (3, 1, -1)$$

$$\mathbf{v}_{\text{男人}} = (1, 2, 1), \quad \mathbf{v}_{\text{女人}} = (1, 2, -1)$$

（第3维编码性别：+1 = 男性，-1 = 女性；第1-2维编码其他语义特征。协方差矩阵沿用题3的 Σ 。）

(a) 在原始空间中，计算「类比向量」 $\delta = \mathbf{v}_{\text{国王}} - \mathbf{v}_{\text{女王}}$ 和 $\delta' = \mathbf{v}_{\text{男人}} - \mathbf{v}_{\text{女人}}$ 。验证 $\delta = \delta'$ （即性别方向在原始空间中是平行的）。

(b) 用题3的白化矩阵 $W = \Lambda^{-1/2}$ ，计算白化后的四个向量：

$$\tilde{\mathbf{v}}_{\text{国王}} = W\mathbf{v}_{\text{国王}}, \quad \tilde{\mathbf{v}}_{\text{女王}} = W\mathbf{v}_{\text{女王}}$$

$$\tilde{\mathbf{v}}_{\text{男人}} = W\mathbf{v}_{\text{男人}}, \quad \tilde{\mathbf{v}}_{\text{女人}} = W\mathbf{v}_{\text{女人}}$$

(c) 在白化后的空间中，计算 $\tilde{\delta} = \tilde{\mathbf{v}}_{\text{国王}} - \tilde{\mathbf{v}}_{\text{女王}}$ 和 $\tilde{\delta}' = \tilde{\mathbf{v}}_{\text{男人}} - \tilde{\mathbf{v}}_{\text{女人}}$ 。 $\tilde{\delta}$ 和 $\tilde{\delta}'$ 是否仍然相等？余弦相似度是多少？

(d) 类比推理的步骤：给定「国王 - 男人 + 女人」，预期结果向量为 $\mathbf{v}_{\text{国王}} - \mathbf{v}_{\text{男人}} + \mathbf{v}_{\text{女人}}$ 。在原始空间和白化空间中分别计算这个结果向量，并判断它是否更接近「女王」还是其他词。

(e) 解释为什么白化在「语义相似度」任务上提升而在「类比推理」任务上可能退步——这两种任务对「性别方向」的利用方式有什么不同？白化破坏了「性别方向」的哪个性质？

教学注：这道题揭示了白化代价二（破坏线性语义方向）的具体机制：性别关系被编码在第3维（低方差，方差=0.25），白化把这个维度放大了 $1/\sqrt{0.25} = 2$ 倍，破坏了性别方向在「国王/女王」和「男人/女人」之间的平行等长关系（平行关系保持，但比例改变）。

陷阱：

- (c) 的核心发现： $\tilde{\delta}$ 和 $\tilde{\delta}'$ 在这个例子里仍然相等（因为是对角协方差，线性变换保持平行性）——这说明白化**保持了性别方向的方向**，但可能改变了它相对于其他方向的**比例**
- (d) 中要分别在原始空间和白化空间做完整的计算，不要只定性描述

题5【重·评判·五条嵌入几何隐喻的合法性】

导读：本节把「嵌入空间几何」的几条流行说法逐一审查——哪些在数学上有严格保证，哪些只是近似，哪些在实际中经常失效。

阅读以下五个论断：

论断 A：「词嵌入的余弦相似度可以作为语义相似度的可靠度量——相似的词（近义词、同类词）余弦相似度接近 1，无关的词余弦相似度接近 0。」

论断 B：「向量算术 ($\mathbf{v}_{\text{国王}} - \mathbf{v}_{\text{男人}} + \mathbf{v}_{\text{女人}} \approx \mathbf{v}_{\text{女王}}$) 是词嵌入的可靠工具——只要嵌入经过充分训练，对任意语义关系都能奏效。」

论断 C：「嵌入空间的有效维度就是名义维度 d ——768 维的 BERT 嵌入拥有 768 个独立的信息维度，可以同时表达 768 种语义特征。」

论断 D：「白化变换可以消除所有嵌入空间的几何失真，让余弦相似度在所有任务上都更可靠。」

论断 E：「嵌入空间各向异性是一个训练缺陷，通过改进训练方法（例如对负采样噪声分布做精确设计）可以完全消除，从而让嵌入空间趋于各向同性。」

(a) 对每个论断给出「成立 / 部分成立 / 不成立」的判断，并指出关键前提或失效条件。

(b) 论断 A 和 B 都说的是余弦相似度/向量算术的「可靠性」，但失效模式不同。A 的失效来自**各向异性**（高频词偏置），B 的失效来自**平移等变性不成立**（语义关系在空间中不平行）。给出一个具体词对/词组，说明 A 失效但 B 成立的情形，以及 B 失效但 A 成立的情形。

(c) 论断 C 中「有效维度」和「名义维度」的差距由什么决定？结合本节的椎体效应和 §2.3 的超位置概念，说明 BERT-base ($d = 768$) 的有效信息维度可能远低于 768，也可能通过超位置机制远超 768——这两种说法各自有什么依据？

(d) 论断 D 中「白化可以消除所有几何失真」——哪条失真可以消除，哪条不能？具体地，说明白化能消除的是「各向异性（主导方向偏置）」，但不能消除的是「多义词模糊（bank 问题）」以及「训练数据偏见（gender bias）」。

(e) 论断 E 问的是各向异性能否被「完全消除」。写出至少一个理论上的障碍：即使把负采样分布改为均匀分布 ($P_n(c) = 1/V$)，各向异性是否会消失？从 Zipf 定律和统计估计的稳定性角度给出分析。

教学注：题 5 是本节的集成判断题。五条论断覆盖了本节的四个核心机制（各向异性、椎体效应、白化、有效维度），要求读者用「哪些假设在什么条件下成立」的框架来逐条分析，而不是靠记忆。

陷阱：

- 论断 E 的关键：即使改变采样分布，词频本身是数据的固有属性，无法「消除」——高频词在训练中收到的正样本梯度更新次数也更多，各向异性有多重来源
- 论断 C 中「有效维度 < 名义维度」和「超位置 → 有效维度 > 名义维度」不矛盾——前者说的是「各向异性造成秩折扣」，后者说的是「稀疏特征叠加允许超额存储」，两者在不同尺度上成立

解答 § 2.5

T-2.5.1 【各向异性指标的计算与解读】

(a) 余弦相似度（归一化向量直接算内积）：

- $\cos(\hat{\mathbf{v}}_1, \hat{\mathbf{v}}_2) = 0.98 \times 0.97 + 0.14 \times (-0.15) + 0.14 \times 0.19 = 0.9506 - 0.0210 + 0.0266 = 0.9562$
- $\cos(\hat{\mathbf{v}}_1, \hat{\mathbf{v}}_3) = 0.98 \times 0.99 + 0.14 \times 0.10 + 0.14 \times (-0.10) = 0.9702 + 0.014 - 0.014 = 0.9702$
- $\cos(\hat{\mathbf{v}}_1, \hat{\mathbf{v}}_4) = 0.98 \times 0.96 + 0.14 \times 0.20 + 0.14 \times (-0.19) = 0.9408 + 0.028 - 0.0266 = 0.9422$
- $\cos(\hat{\mathbf{v}}_2, \hat{\mathbf{v}}_3) = 0.97 \times 0.99 + (-0.15) \times 0.10 + 0.19 \times (-0.10) = 0.9603 - 0.015 - 0.019 = 0.9263$
- $\cos(\hat{\mathbf{v}}_2, \hat{\mathbf{v}}_4) = 0.97 \times 0.96 + (-0.15) \times 0.20 + 0.19 \times (-0.19) = 0.9312 - 0.030 - 0.0361 = 0.8651$
- $\cos(\hat{\mathbf{v}}_3, \hat{\mathbf{v}}_4) = 0.99 \times 0.96 + 0.10 \times 0.20 + (-0.10) \times (-0.19) = 0.9504 + 0.02 + 0.019 = 0.9894$

(b) $\text{c}\ddot{\text{o}}\text{s} = (0.9562 + 0.9702 + 0.9422 + 0.9263 + 0.8651 + 0.9894)/6 = 5.6494/6 \approx 0.9416$

(c) 各向同性随机单位向量的期望余弦相似度为 0（§ 2.3：高维随机向量几乎正交，余弦趋于 0）。 $\text{c}\ddot{\text{o}}\text{s} \approx 0.94$ 远大于 0，说明这 4 个向量的各向异性极严重——几乎所有词都「挤」在第 1 维方向附近。

(d) 当「the」「of」等高频词也集中在第 1 维方向，而「量子纠缠」「罗马法」分别从这个主导方向略微偏离时，两个低频词彼此的余弦相似度会被「主导方向」污染： $\cos(\mathbf{v}_A, \mathbf{v}_B) \approx \cos(\mathbf{v}_A, \hat{\mathbf{e}}_1) \cdot \cos(\mathbf{v}_B, \hat{\mathbf{e}}_1) + \text{小校正项}$ ——即余弦值主要反映两个词与主导方向（ $\hat{\mathbf{e}}_1$ ）的对齐程度，而非两词之间的语义关系。

Sanity check：6 个余弦值全部 > 0.85，而随机向量期望值为 0——差距约 0.9，说明这 4 个向量几乎「完全对齐」到第 1 维，各向异性指标接近真实 BERT 上层嵌入的观测值（ $\text{c}\ddot{\text{o}}\text{s} \approx 0.99$ ）。

T-2.5.2 【椎体效应的训练机制追溯】

(a) $f(\text{the})^{3/4} = 0.05^{3/4}$, $f(\text{obscure})^{3/4} = 10^{-5 \times 3/4} = 10^{-5} \cdot 10^{3/4 \times \log_{10}(10^{-5})}$ 。计算：

$$\frac{0.05^{3/4}}{(10^{-5})^{3/4}} = \left(\frac{0.05}{10^{-5}} \right)^{3/4} = (5000)^{3/4}$$

$$(5000)^{3/4} = e^{3/4 \cdot \ln 5000} = e^{3/4 \times 8.517} = e^{6.388} \approx 595。$$

「the」被选为负样本的概率约是「obscure」的 **595 倍**。

(b) 梯度更新方向： $-\eta \cdot \nabla_{\mathbf{u}_{\text{the}}} \mathcal{L}_{\text{NEG}} = -\eta \cdot (-\sigma(\mathbf{u}_{\text{the}}^T \mathbf{v}_{\text{猫}}) \cdot \mathbf{v}_{\text{猫}}) = \eta \cdot \sigma(\cdot) \cdot \mathbf{v}_{\text{猫}}$ 。

等等——梯度下降时减去梯度，但这里我们要让损失**减小**（即提高「the」不是猫的上下文词的概率），所以更新方向是把 $\mathbf{u}_{\text{the}}$ **推离** $\mathbf{v}_{\text{猫}}$ （即 $\mathbf{u}_{\text{the}} \leftarrow \mathbf{u}_{\text{the}} + \eta \sigma(\mathbf{u}_{\text{the}}^T \mathbf{v}_{\text{猫}}) \cdot (-\mathbf{v}_{\text{猫}})$ ）。物理含义：「the」的上下文向量被推向与「猫」的中心词向量**相反的方向**，减小两者相似度。

(c) 估算累计位移： $\|\Delta \mathbf{u}_{\text{the}}\| \approx N_1 \times \eta \times \sigma(\cdot) \times \|\mathbf{v}_w\| = 10^6 \times 0.01 \times 0.5 \times 1 = 5000$ （任意单位）。 $\|\Delta \mathbf{u}_{\text{obscure}}\| \approx 200 \times 0.01 \times 0.5 \times 1 = 1$ 。两者相差 **5000 倍**，「the」的向量被系统性地推到远离所有中心词的方向，而「obscure」几乎不动。

(d) Zipf 定律：词频 $f_k \propto 1/k$ ，前 K 个高频词占据总词频的 $\sum_{k=1}^K 1/k \approx \ln K$ ，占总语料比例约 $\ln K / \ln V$ 。对 $V = 50000$ ，前 100 个词 ($K = 100$) 占约 $\ln 100 / \ln 50000 \approx 4.6/10.8 \approx 43\%$ 。这意味着绝大多数排斥梯度集中在这极少数的高频词身上——无论怎么训练，只要语言遵循 Zipf 定律，高频词就会被过度排斥，必然形成椎体效应。这不是训练数据的偶然，而是 Zipf 分布与负采样机制结合的数学必然。

Sanity check: (a) 中 595 倍对应「the」和「obscure」被选为负样本的概率比，可以验证：3/4 次幂比直接用频率比（5000 倍）小得多——3/4 幂的「压缩」效果使高低频词的差距从 5000 倍降到 595 倍，但仍是巨大差距。

T-2.5.3 【白化变换的代数实现】

(a) 对角矩阵的特征分解： $U = I_3$ （单位矩阵）， $\Lambda = \Sigma = \text{diag}(9, 1, 0.25)$ 。特征值 $\lambda_1 = 9, \lambda_2 = 1, \lambda_3 = 0.25$ 。

(b) $W = \Lambda^{-1/2} U^T = \Lambda^{-1/2} = \text{diag}(1/3, 1, 2)$ 。对角元素： $1/\sqrt{9} = 1/3$, $1/\sqrt{1} = 1$, $1/\sqrt{0.25} = 2$ 。

(c) 白化后向量：

$$\tilde{\mathbf{v}}_A = W \mathbf{v}_A = (3/3, 1 \times 1, 2 \times 0.5) = (1, 1, 1)$$

$$\tilde{\mathbf{v}}_B = W \mathbf{v}_B = (1/3, 1 \times 3, 2 \times 0.5) = (1/3, 3, 1)$$

(d) 原始余弦相似度：

$$\|\mathbf{v}_A\| = \sqrt{9 + 1 + 0.25} = \sqrt{10.25} \approx 3.202, \quad \|\mathbf{v}_B\| = \sqrt{1 + 9 + 0.25} = \sqrt{10.25} \approx 3.202$$

$$\cos(\mathbf{v}_A, \mathbf{v}_B) = \frac{3 \times 1 + 1 \times 3 + 0.5 \times 0.5}{3.202^2} = \frac{6.25}{10.25} \approx 0.6098$$

白化后余弦相似度：

$$\begin{aligned}\|\tilde{\mathbf{v}}_A\| &= \sqrt{1+1+1} = \sqrt{3} \approx 1.732 \\ \|\tilde{\mathbf{v}}_B\| &= \sqrt{1/9+9+1} = \sqrt{10.111} \approx 3.180 \\ \cos(\tilde{\mathbf{v}}_A, \tilde{\mathbf{v}}_B) &= \frac{1/3+3+1}{1.732 \times 3.180} = \frac{4.333}{5.507} \approx 0.7869\end{aligned}$$

白化后余弦相似度从 0.61 升至 0.79，两者不同。原因：白化对不同维度施加了不等比例的缩放（第 1 维缩小 3 倍，第 3 维放大 2 倍），改变了向量的相对方向，余弦值随之变化。

(e) 白化后的协方差（粗略以两向量估计）： $\tilde{\mathbf{v}}_A$ 和 $\tilde{\mathbf{v}}_B$ 的均值约 $((1+1/3)/2, (1+3)/2, 1) = (2/3, 2, 1)$ 。方差各维大致相当（不完全，因为只有 2 个点），但白化的设计目标是使全体嵌入集合的协方差矩阵变为 I ——两个点不能严格验证，但可以看到第 1 维的大方差（原来 9）已被 $1/3$ 缩放消除。

Sanity check: 白化矩阵 $W = \text{diag}(1/3, 1, 2)$ 的对角元素：第 1 维（高方差 9）被压缩（乘以 $1/3$ ），第 3 维（低方差 0.25）被放大（乘以 2），第 2 维（方差 1）不变——这正是「消除各向异性」的操作，与直觉一致。

T-2.5.4 【白化对类比算术的破坏】

(a) 类比向量（原始空间）：

$$\begin{aligned}\delta &= \mathbf{v}_{\text{国王}} - \mathbf{v}_{\text{女王}} = (3-3, 1-1, 1-(-1)) = (0, 0, 2) \\ \delta' &= \mathbf{v}_{\text{男人}} - \mathbf{v}_{\text{女人}} = (1-1, 2-2, 1-(-1)) = (0, 0, 2)\end{aligned}$$

$\delta = \delta' = (0, 0, 2)$ ，完全相等，性别方向是平行且等长的。

(b) 白化矩阵 $W = \text{diag}(1/3, 1, 2)$ ：

$$\begin{aligned}\tilde{\mathbf{v}}_{\text{国王}} &= (1, 1, 2), \quad \tilde{\mathbf{v}}_{\text{女王}} = (1, 1, -2) \\ \tilde{\mathbf{v}}_{\text{男人}} &= (1/3, 2, 2), \quad \tilde{\mathbf{v}}_{\text{女人}} = (1/3, 2, -2)\end{aligned}$$

(c) 白化空间中类比向量：

$$\begin{aligned}\tilde{\delta} &= \tilde{\mathbf{v}}_{\text{国王}} - \tilde{\mathbf{v}}_{\text{女王}} = (0, 0, 4) \\ \tilde{\delta}' &= \tilde{\mathbf{v}}_{\text{男人}} - \tilde{\mathbf{v}}_{\text{女人}} = (0, 0, 4)\end{aligned}$$

$\tilde{\delta} = \tilde{\delta}'$ ，方向仍然平行（在这个对角协方差的简单例子中，白化保持了平行性）。余弦 $\cos(\tilde{\delta}, \tilde{\delta}') = 1$ 。

注：这个例子中白化保持了类比向量的方向，但**改变了性别方向相对于其他语义方向的比例**（性别方向被放大了2倍）。在非对角协方差的实际情形中，白化会引入旋转，破坏平行性。

(d) 类比结果向量：原始空间 $\mathbf{v}_{\text{国王}} - \mathbf{v}_{\text{男人}} + \mathbf{v}_{\text{女人}} = (3 - 1 + 1, 1 - 2 + 2, 1 - 1 - 1) = (3, 1, -1) = \mathbf{v}_{\text{女王}}$ ，精确命中。白化空间： $\tilde{\mathbf{v}}_{\text{国王}} - \tilde{\mathbf{v}}_{\text{男人}} + \tilde{\mathbf{v}}_{\text{女人}} = (1 - 1/3 + 1/3, 1 - 2 + 2, 2 - 2 - 2) = (1, 1, -2) = \tilde{\mathbf{v}}_{\text{女王}}$ ，也精确命中。（本例中两空间均成立，但实际非对角协方差情形可能导致偏差。）

(e) 「语义相似度」任务只需要两个词的向量**方向对齐程度**，白化后余弦相似度更好地反映了语义差异（消除了词频偏置）。「类比推理」任务需要两组词对之间的差向量**方向和长度都精确匹配**（平移等变性）。白化通过不均匀缩放改变了不同语义关系之间的**相对比例**——若性别方向与其他语义方向在协方差结构上不独立，白化会引入旋转破坏平行性。这两种任务对「空间结构」的依赖不同，是白化「顾此失彼」的根本原因。

Sanity check: (a) 中 $\delta = \delta' = (0, 0, 2)$ 说明性别关系被精确编码在第3维；(c) 中白化把第3维放大2倍，但两个差向量都变为 $(0, 0, 4)$ ，方向保持一致。这个例子说明**对角协方差时白化不破坏平行性**，但实际嵌入空间的协方差是非对角的，结论不同。

T-2.5.5 【五条嵌入几何隐喻的合法性】

(a) 判断：

- **论断 A 部分成立**。余弦相似度在白化后或低各向异性的静态嵌入中是语义相似度的可靠度量；但在未白化的上下文相关嵌入（BERT 上层 $\text{cōs} \approx 0.99$ ）中严重失效，测量的是与主导方向的对齐程度而非语义差异。
- **论断 B 部分成立**。类比算术在「语义关系高度规律、词频足够、维度足够」时有约 60-70% 的准确率（Word2Vec 原始论文），但对抽象关系、上下文相关嵌入、各向异性严重的空间频繁失效。
- **论断 C 不成立**。各向异性使得嵌入空间的「有效秩」（实际信息维度）远低于 d ——大量维度携带词频噪声，实际独立语义方向可能只有数十到数百。同时超位置允许有效信息量超过 d ，但这是在稀疏特征条件下，「768 个完全独立的语义特征」是错误的。
- **论断 D 部分成立**。白化能消除各向异性（主导方向偏置），对语义相似度任务有效；但不能消除多义词模糊（bank 问题），不能消除训练数据中的偏见（gender bias），也不能修复类比推理任务中可能的精度损失。
- **论断 E 不成立**。即使改为均匀负采样 $P_n = 1/V$ ，各向异性仍然存在：高频词在正样本侧也收到更多梯度更新（出现次数多），模长系统性偏大；更根本地，Zipf 分布是语言数据的固有属性，无法通过训练策略改变。各向异性有多重来源，仅修改负采样分布不能完全消除。

(b) A 失效但 B 成立的情形：「the」与「a」的余弦相似度可能虚高（两者都是高频词，被椎体效应推向同一方向），余弦相似度”说”它们语义相似（A 失效）；但「定冠词 - 通用上下文 + 特指上下文 $\approx$ 特指冠词」这种类比关系（B）在语料中规律清晰，向量算术成立。B 失效但 A 成立：「道德」与「伦理」余弦相似度高（近义词，A 成立）；但「道德 - 哲学 + 法律 $\approx$ 法律伦理？」这种抽象类比关系在语料中缺乏一致统计规律，

B 失效。

(c) 「有效维度 < 名义维度」的依据：各向异性使嵌入矩阵的协方差矩阵有少数几个大特征值（主成分），其余特征值接近零——有效秩 ($\approx \sum \lambda_i^2 / (\sum \lambda_i)^2$ 的倒数，即参与信息) 远低于 d 。「超位置 → 有效信息 > 名义维度」的依据：只要特征稀疏（大多数特征不同时激活）， d 维空间可以存储约 $e^{d/8}$ 个几乎正交方向，每个方向对应一个语义特征——因此信息容量可远超 d 。这两种说法不矛盾：前者描述「实际被使用的维度数」，后者描述「理论上能存储的最大信息量」。

(d) 白化能消除：**各向异性（主导方向偏置）**——通过归一化各方向方差，使向量均匀覆盖空间，余弦不再被主导方向污染。白化不能消除：(1) **多义词模糊**（bank 的金融/河流含义平均在一个向量里，白化不能分开两种义项）；(2) **训练数据偏见**（gender bias：「护士」的嵌入向量偏向女性方向，白化只是在「女性方向」上重新缩放，不改变该方向本身的存在）；(3) **稀疏统计噪声**（低频词的嵌入向量统计估计不稳定，白化不能凭空增加训练样本）。

(e) 理论障碍：即使均匀负采样 $P_n = 1/V$ ，**正样本侧仍不均匀**——高频词（「the」）的中心词向量在训练中出现次数与词频成正比，受到更多梯度更新，模长系统性偏大。椎体效应不只来自负样本侧，还来自正样本侧的不均匀更新。更根本的障碍：词的嵌入向量的更新次数正比于词频，高频词嵌入的统计估计更稳定、模长更大，这是词频本身的固有属性，任何基于词频统计的训练方法都无法消除。

Sanity check：(a) 中五条论断分别踩了：A-各向异性偏置；B-平移等变性不总成立；C-各向异性造成秩折扣 + 超位置概念混淆；D-白化不能解决所有问题；E-各向异性有多重来源。每条都能在本节的「因果链」里找到对应的机制，说明分析覆盖完整。

§ 2.5 小结：从各向异性指标的量化（题 1）、到椎体效应的梯度力学追溯（题 2）、到白化的代数实现（题 3）、到白化代价的具体展示（题 4）、到五条几何隐喻的合法性判断（题 5）——这五道题串成了「嵌入空间几何隐喻何时成立、何时失效」的完整判断框架。核心结论：词嵌入不是一个干净的语义坐标系，而是被词频统计深度污染的各向异性空间；白化是有效但有代价的局部修复；真正的几何意义需要在「白化 + 具体任务对应的度量」的组合下才能重新成立。

§ 2.6 习题：跨越欧氏——当表示空间不再「平直」

导读：本节核心是双曲嵌入：欧氏空间体积多项式增长与树形结构指数节点增长之间的根本不匹配，如何被 Poincaré 球模型的指数体积增长所弥合，以及弯曲空间里梯度下降需要哪些额外工具。五题分别对应：欧氏维度瓶颈的下界推导、双曲距离公式的数值计算、Poincaré 球几何性质的辨析、黎曼梯度与欧氏梯度的比较、以及反类比——指出把双曲嵌入优势照搬到通用语言建模时哪些假设被违反。

题 1【轻 · 推导 · 欧氏嵌入的维度下界】

导读：树形结构节点数指数增长，而欧氏空间容量只多项式增长——这不是观感上的不匹配，是可以量化为下界的数学事实。

设深度为 L 、分支数为 b ($b \geq 2$) 的完全 b -叉树共有 $N = O(b^L)$ 个叶节点。

(a) 用 packing 论证说明：在 $\mathbb{R}^d$ 中，以原点为中心、半径为 r 的球内最多能放 $O(r^d)$ 个两两欧氏距离不低于 1 的点。（一句话量级论证即可，无需严格证明。）

(b) 利用 (a) 的结论，说明将 $N = O(b^L)$ 个叶节点嵌入 $\mathbb{R}^d$ 并保持互相距离时，需要

$$d \geq \Omega\left(\frac{L \log b}{\log L}\right)$$

即所需维度随树深度 L 接近线性增长。

(c) 对 $b = 2$ 、 $L = 12$ （近似 WordNet 名词层级深度）数值估算上述下界：至少需要多少维度？

(d) 若改用双曲空间，Nickel & Kiela (2017) 实验表明 5 维双曲嵌入已超过 200 维欧氏嵌入的层级重建精度。用 (b) 的下界解释为什么会有如此悬殊的维度差距。

教学注：这道题把「双曲嵌入更好」从一句经验观察转化为一个有数学支撑的必然结论：欧氏空间的多项式体积增长是维度瓶颈的根源，不是调参所能弥补的。

陷阱：

- 节点总数是 $O(b^L)$ 而不是 $O(L \cdot b)$ ，不要把指数和线性混淆
- packing 论证给出的是上界（球内最多多少点），对应嵌入所需维度的下界

题 2【中 · 计算 · Poincaré 球距离公式】

导读：双曲距离公式的分母 $(1 - \|\mathbf{u}\|^2)(1 - \|\mathbf{v}\|^2)$ 决定了「靠近球边界时距离急剧拉大」的效应，数值感受比文字描述更直接。

在 Poincaré 球模型中，双曲距离公式为

$$d_{\mathbb{H}}(\mathbf{u}, \mathbf{v}) = \operatorname{arcosh}\left(1 + 2 \frac{\|\mathbf{u} - \mathbf{v}\|^2}{(1 - \|\mathbf{u}\|^2)(1 - \|\mathbf{v}\|^2)}\right)$$

设 $d = 2$ （二维 Poincaré 盘），考虑以下三对点：

- 对 A: $\mathbf{u}_A = (0, 0)$, $\mathbf{v}_A = (0.5, 0)$
- 对 B: $\mathbf{u}_B = (0.8, 0)$, $\mathbf{v}_B = (0.9, 0)$ (两点均靠近边界, 欧氏距离相同均为 0.1)
- 对 C: $\mathbf{u}_C = (0.95, 0)$, $\mathbf{v}_C = (0.99, 0)$ (欧氏距离 0.04, 更接近边界)

(a) 计算三对点的欧氏距离 $\|\mathbf{u} - \mathbf{v}\|$ 。

(b) 计算三对点各自的双曲距离 $d_{\mathbb{H}}(\mathbf{u}, \mathbf{v})$ (保留 4 位小数)。提示: $\operatorname{arcosh}(t) = \ln(t + \sqrt{t^2 - 1})$ 。

(c) 比较对 A、B、C 的欧氏距离与双曲距离之比。描述「靠近球边界」对双曲距离有何效应, 用数字说明。

(d) 解释为什么 Poincaré 球用「径向坐标」(到原点的双曲距离) 来对应树的层级深度, 而非欧氏距离。

教学注: 对 B 和 C 欧氏距离分别是 0.1 和 0.04, 但双曲距离相差巨大——这个数字反差直接说明了为什么叶节点 (接近边界) 之间的「隔离」在双曲几何里是自动涌现的, 不需要额外约束。

陷阱:

- 计算对 C 时分母接近零, arcosh 的参数会非常大, 先精确算分母再代入
- arcosh 公式要求参数 ≥ 1 , 验证 $1 + 2\|\Delta\|^2 / ((1 - \|\mathbf{u}\|^2)(1 - \|\mathbf{v}\|^2)) \geq 1$ 总是成立

题 3 【中·概念辨析·黎曼度量张量与曲率】

导读: 黎曼流形的核心工具是度量张量 g_p ——它在每个点局部定义「如何量距离」, 决定了空间的曲率, 进而决定了体积增长速率。

判断下列命题的真假, 并说明理由 (2-3 句话):

(a) 「欧氏空间是黎曼流形的特例, 其度量张量在所有点处恒为 $g_{ij} = \delta_{ij}$ 。」

(b) 「Poincaré 球的黎曼度量 $ds^2 = \frac{4\|\mathbf{dx}\|^2}{(1-\|\mathbf{x}\|^2)^2}$ 意味着, 越靠近球边界, 同样的欧氏位移对应的真实 (双曲) 距离越小。」

(c) 「三角形内角和小于 180° 是双曲空间 (负曲率) 的特征; 大于 180° 是正曲率 (球面) 的特征。」

(d) 「在 Poincaré 球中, 以球心 $\mathbf{0}$ 为中心、双曲半径为 r 的球的体积约正比于 $e^{(d-1)r}$, 因此对所有深度 L 的树, 只要选足够大的 r 就能嵌入任意分支数的树而无需增加维度 d 。」

教学注: (d) 是一个微妙的陷阱——维度 d 和半径 r 都影响容量, 但增大 r 会让边界区域的数值梯度爆炸, 训练稳定性付出代价, 「无限增大 r 」并非免费的午餐。

陷阱:

- (b) 的因子 $\frac{4}{(1-\|\mathbf{x}\|^2)^2}$ 是放大因子, 越接近边界越大——方向是「边界附近双曲距离更大」而非更小
- (d) 需要区分「理论容量」和「可训练的优化稳定性」两个不同层面

题 4 【重 · 计算 · 黎曼梯度与欧氏梯度的比较】

导读：在弯曲流形上做梯度下降需要把欧氏梯度「折算」为黎曼梯度，再沿测地线前进——这不只是工程细节，而是弯曲空间里优化的数学必要条件。

设一个标量损失函数 $f(\mathbf{x}) = \|\mathbf{x} - \mathbf{p}\|_2^2$ ，其中 $\mathbf{p} = (0.3, 0)$ 是目标点，当前点 $\mathbf{x}_0 = (0.5, 0)$ （均在二维 Poincaré 盘中）。

(a) 计算欧氏梯度 $\nabla_{\mathbf{x}} f$ 在 $\mathbf{x}_0$ 处的值。

(b) Poincaré 球上的黎曼梯度定义为

$$\text{grad}_{\mathbb{H}} f(\mathbf{x}) = \frac{(1 - \|\mathbf{x}\|^2)^2}{4} \nabla_{\mathbf{x}} f$$

计算黎曼梯度在 $\mathbf{x}_0 = (0.5, 0)$ 处的值（保留 4 位小数），并与欧氏梯度对比其大小比值。

(c) 如果在 $\|\mathbf{x}\| = 0.99$ 的点处做同样的计算，黎曼梯度与欧氏梯度之比会如何变化？数值估算该比值（对相同的 f ）。

(d) 解释为什么靠近球边界时，双曲嵌入的训练对学习率极其敏感：若使用与内部点相同的学习率 η ，靠近边界的点会发生什么？

教学注：这道题用数字直观地展示「黎曼梯度修正」的量级——在 $\|\mathbf{x}\| = 0.99$ 时，修正因子约为 $(1 - 0.99^2)^2/4 \approx 0.0001/4$ ，梯度被极度压缩；反过来，若直接用欧氏梯度步长，边界处更新步长会爆炸。

陷阱：

- 黎曼梯度公式里 $(1 - \|\mathbf{x}\|^2)^2/4$ 是「缩小」因子（小于 1），对应流形上真实距离比欧氏坐标距离更大的补偿
- 不要把黎曼梯度公式里的 $\nabla_{\mathbf{x}} f$ 和指数映射混为一谈——黎曼梯度只是方向修正，指数映射才是把切向量映射回流形的步骤

题 5 【重 · 反类比 · 双曲嵌入优势的适用边界】

导读：「5 维双曲超过 200 维欧氏」的惊人结论有明确的前提条件——当这些前提不满足时，弯曲空间的优化代价反而变成净负担。

阅读以下四个论断，判断哪条假设被违反，说明判断理由：

论断 A：「自然语言语义关系大量是 is-a 树形层级（如 WordNet），因此把 LLaMA 的嵌入层替换为双曲嵌入，模型性能必然提升。」

论断 B：「双曲嵌入的指数体积增长意味着维度越高，容量优势越大，所以应该首选尽可能大的双曲维度。」

论断 C：「对图神经网络中的社交网络图（节点度分布符合幂律），双曲嵌入比欧氏嵌入更适合，因为幂律分布和指数体积增长都有指数形式。」

论断 D：「双曲嵌入的黎曼梯度和指数映射在每步都比欧氏梯度多若干矩阵运算，但由于维度极低（5 维），每步的绝对计算量仍然可以忽略不计，不是实际瓶颈。」

(a) 对每个论断，指出它违反（或依赖但实际不成立）的哪一条假设，判断「成立 / 部分成立 / 不成立」。

(b) 写出双曲嵌入类比「欧氏空间是平直的，双曲空间是弯曲的」时**必须**满足的两条前提条件（数学层面）。

(c) 举一个跨界应用场景，其中数据内在拓扑**既非纯层级也非纯网状**，说明在此场景下选择几何空间时应考虑的权衡，并指出供应链隐喻在此处是否适用。

教学注：论断 A 违反的核心假设是「自然语言语义拓扑是纯树形的」——实际语言兼有层级 (is-a) 和网状联想 (associate-with)，混合拓扑下欧氏反而更稳健。论断 C 的错误在混淆了「幂律」和「指数」这两种不同的增长形式，幂律是多项式，不是指数。

陷阱：

- 幂律 $k^{-\gamma} \neq$ 指数 $e^{-\alpha k}$ ，两者都和「重尾」有关，但数学形式完全不同
- 「优化代价可以忽略不计」需要区分每步代价（低维时确实小）和训练稳定性代价（靠近边界时梯度爆炸，需要更小学习率，总训练步数增加）

解答 § 2.6

T-2.6.1 【欧氏维度下界】

(a) 在 $\mathbb{R}^d$ 中，半径为 r 的球的体积 $\propto r^d$ 。若放下 M 个互相距离 ≥ 1 的点，每个点「占据」半径 $1/2$ 的小球，这些小球的总体积 $\sim M \cdot (1/2)^d$ ，必须 $\leq$ 外球体积 $\propto r^d$ ，故 $M = O(r^d)$ 。

(b) 树有 $N = O(b^L)$ 个节点，树的直径约为 $O(L)$ ，故需要球半径 $r = O(L)$ ，球内最多放 $O(L^d)$ 个点。要满足 $L^d \geq b^L$ ，取对数： $d \log L \geq L \log b$ ，即

$$d \geq \frac{L \log b}{\log L}$$

随 L 接近线性增长（除了 $\log L$ 的缓慢增长）。

(c) $b = 2$, $L = 12$: $d \geq \frac{12 \times \log 2}{\log 12} = \frac{12 \times 0.6931}{2.4849} \approx \frac{8.317}{2.485} \approx 3.35$ ，取整为至少 4 维。注意这是非常粗糙的下界；实际要保留所有 $\sim 8 \times 10^4$ 个节点对的距离，下界会大得多。

(d) 欧氏空间体积增长为 $O(L^d)$ （多项式），树节点数增长为 $O(b^L)$ （指数），两者增长速率的本质差异是 L 的多项式 vs L 的指数。双曲空间体积增长为 $\sim e^{(d-1)r}$ （指数），与 $b^L = e^{L \log b}$ 的指数形式匹配，只需令 $d-1 = \log b$ 即可，与 L 无关——这就是 5 维双曲已经够用、而欧氏需要上百维的数学根源。

Sanity check: $b^L = 2^{12} = 4096$ 。用 $d = 5$ 双曲， $e^{4r} = 4096$ 给出 $r \approx \ln 4096 / 4 \approx 2.07$ ，是可以正常优化的内部坐标范围。

T-2.6.2 【Poincaré 球距离数值计算】

(a) 欧氏距离：对 A: 0.5；对 B: 0.1；对 C: 0.04。

(b) 对各对点计算：

$$\delta = 1 + 2 \frac{\|\mathbf{u} - \mathbf{v}\|^2}{(1 - \|\mathbf{u}\|^2)(1 - \|\mathbf{v}\|^2)}$$

对 A: $\|\mathbf{u}\|^2 = 0, \|\mathbf{v}\|^2 = 0.25$, 分母 $= 1 \times 0.75 = 0.75$, $\delta = 1 + 2 \times 0.25 / 0.75 = 1 + 0.6667 = 1.6667$, $d_{\text{H}} = \text{arcosh}(1.6667) = \ln(1.6667 + \sqrt{1.7778}) = \ln(1.6667 + 1.3333) = \ln 3 \approx 1.0986$ 。

对 B: $\|\mathbf{u}\|^2 = 0.64, \|\mathbf{v}\|^2 = 0.81$, 分母 $= 0.36 \times 0.19 = 0.0684$, $\delta = 1 + 2 \times 0.01 / 0.0684 = 1 + 0.2924 = 1.2924$, $d_{\text{H}} = \text{arcosh}(1.2924) \approx \ln(1.2924 + 0.7785) \approx \ln 2.071 \approx 0.7278$ 。

对 C: $\|\mathbf{u}\|^2 = 0.9025, \|\mathbf{v}\|^2 = 0.9801$, 分母 $= 0.0975 \times 0.0199 = 0.001941$, $\|\mathbf{u} - \mathbf{v}\|^2 = 0.0016$, $\delta = 1 + 2 \times 0.0016 / 0.001941 = 1 + 1.6487 = 2.6487$, $d_{\text{H}} = \text{arcosh}(2.6487) = \ln(2.6487 + \sqrt{5.0154}) \approx \ln(2.6487 + 2.2395) = \ln 4.888 \approx 1.5868$ 。

(c) 双曲距离与欧氏距离之比：A: $1.0986 / 0.5 = 2.20$; B: $0.7278 / 0.1 = 7.28$; C: $1.5868 / 0.04 = 39.67$ 。靠近边界时，相同的欧氏位移对应急剧增大的双曲距离——C 的比值是 A 的约 18 倍。

(d) 径向双曲距离从球心到 $\mathbf{x}$: $2 \operatorname{arctanh}(\|\mathbf{x}\|)$ ，随 $\|\mathbf{x}\| \rightarrow 1$ 趋于无穷。这意味着「深度越大的节点离球边越近」的安排，自动产生父-子节点之间的双曲距离随层级增加，且兄弟节点之间距离也随深度增大，无需任何额外约束。

Sanity check: (b) 中三对点的双曲距离并不单调——对 B (欧氏距离 0.1) 反而小于对 A (欧氏距离 0.5)，这说明「靠近边界」的效应不只是放大距离，而是曲率使得空间局部被拉伸后内部点之间的相对关系被重新组织。

T-2.6.3 【黎曼流形性质辨析】

(a) **真**。欧氏空间的度量张量在全局坐标下 $g_{ij}(p) = \delta_{ij}$ 对所有点 p 成立，曲率为零，是黎曼流形中曲率 $\equiv 0$ 的特例。

(b) **假**。保角因子 $\lambda = \frac{4}{(1 - \|\mathbf{x}\|^2)^2}$ 是大于 1 的放大因子，越靠近球边界越大——即同样的欧氏位移对应的双曲距离越大，而非越小。

(c) **真**。这是曲率正负号的经典几何特征：负曲率（双曲空间）三角形内角和 $< 180^\circ$ ，零曲率（欧氏） $= 180^\circ$ ，正曲率（球面） $> 180^\circ$ 。

(d) **不成立**。增大 r （即把节点推向球边界）会使分母 $(1 - \|\mathbf{x}\|^2)$ 接近零，黎曼度量的保角因子趋于无穷——靠近边界的梯度极度放大，训练极不稳定。实践中节点坐标被限制在 $\|\mathbf{x}\| \leq 1 - \epsilon$ ，不能无限利用边界区域，因此「增大 r 换容量」以训练不可行为代价。

T-2.6.4 【黎曼梯度计算】

(a) $f(\mathbf{x}) = \|\mathbf{x} - \mathbf{p}\|^2 = (x_1 - 0.3)^2 + x_2^2$ 。在 $\mathbf{x}_0 = (0.5, 0)$ 处：

$$\nabla_{\mathbf{x}} f = (2(x_1 - 0.3), 2x_2)|_{(0.5, 0)} = (0.4, 0)$$

(b) 在 $\mathbf{x}_0 = (0.5, 0)$, $\|\mathbf{x}_0\|^2 = 0.25$, 修正因子 $= \frac{(1-0.25)^2}{4} = \frac{0.5625}{4} = 0.1406$ 。

$$\text{grad}_{\mathbb{H}} f = 0.1406 \times (0.4, 0) = (0.0563, 0)$$

黎曼梯度与欧氏梯度之比为 0.1406, 即约为欧氏梯度的 14%。

(c) 在 $\|\mathbf{x}\| = 0.99$ 处, 修正因子 $= \frac{(1-0.9801)^2}{4} = \frac{(0.0199)^2}{4} = \frac{3.960 \times 10^{-4}}{4} \approx 9.9 \times 10^{-5}$ 。比值约为 10^{-4} , 比 $\mathbf{x}_0 = (0.5, 0)$ 处小了约 1400 倍。

(d) 在球边界附近, 黎曼梯度极小 (修正因子 ≈ 0), 意味着流形上的「真实更新方向」非常小。若使用与内部点相同的 (较大的) 欧氏学习率, 等效的双曲步长不是太小 (梯度本身被压缩), 但指数映射把切向量映射回球面时, 靠近边界的点对微小扰动极其敏感——切向量被指数映射「放大」后容易越界 ($\|\mathbf{x}\| > 1$), 导致数值不稳定和梯度裁剪频繁触发。

Sanity check: 在球心 $\mathbf{x} = \mathbf{0}$, 修正因子 $= (1 - 0)^2/4 = 0.25$, 黎曼梯度 $=$ 欧氏梯度的四分之一——这是 Poincaré 球模型里 $ds^2 = 4\|\mathbf{dx}\|^2$ 在原点处的直接体现。

T-2.6.5 【双曲嵌入适用边界】

(a)

- **论断 A 不成立。** 违反假设: 「自然语言语义拓扑是纯树形层级」。实际上语言兼有 is-a (树形) 和 associate-with (网状联想) 两类关系, 混合拓扑下双曲优势不稳定, 欧氏空间对混合拓扑更稳健。
- **论断 B 部分成立。** 双曲维度越高确实容量更大, 但训练稳定性代价也随维度增加 (更难控制靠近边界的点); 实验表明低维 (5-10 维) 往往已经足够, 盲目增加维度会引入优化困难而无明显收益。
- **论断 C 不成立。** 违反假设: 「幂律分布 = 指数增长」。幂律 $k^{-\gamma}$ 是多项式, 指数 $e^{(d-1)r}$ 是指数, 两者完全不同。社交网络的幂律度分布反映的是有少数超级节点的「无标度」特性, 不等于层级结构, 双曲空间的优势是针对层级 (树形), 不是针对所有重尾分布。
- **论断 D 部分成立。** 每步计算量确实因低维而小, 但训练稳定性的代价 (需要更小学习率、梯度裁剪、边界约束) 会使**总训练步数增加**, 「可以忽略」的说法过于乐观。

(b) 双曲嵌入的数学前提: ① 数据内在拓扑具有**明确的树形层级结构** (节点数随深度指数增长, 父子关系清晰); ② 优化目标允许**反复调小学习率并接受额外的边界约束处理** (弯曲空间优化稳定性代价可承受)。

(c) 分子生物学中的蛋白质-蛋白质相互作用网络 (PPI): 结构域级别有层级 (折叠类 $\rightarrow$ 超家族 $\rightarrow$ 家族), 但功能级别有密集的网状联系 (信号通路中的交叉调控) ——既非纯层级也非纯网状。权衡: 层级部分用双曲 (利用容量优势), 网状联系用欧氏 (不

受边界约束), 实践中常用「乘积空间」 $\mathbb{H}^{d_1} \times \mathbb{R}^{d_2}$ 。供应链类比在此场景不适用——PPI 网络没有「采购需求」或「资源调度」语义, 强行套用会误导对网络瓶颈的判断。

§ 2.6 小结: 欧氏体积多项式增长与树形结构指数节点增长之间的「维度诅咒」, 由 Poincaré 球的指数体积增长精确破解——但破解有两个代价: 优化工具必须切换到黎曼梯度加指数映射, 且数据必须具有足够纯粹的树形层级拓扑。当这两个条件都不满足时, 欧氏空间的稳健性反而占上风。几何空间的选择, 本质上是对数据内在拓扑的一次先验赌注。

第3章 · 注意力机制的矩阵微分

§3.1 习题：从 RNN 到 Transformer——序列建模的范式革命

导读：本节核心是两个转变——从时序递推到矩阵并行，以及从梯度连乘到 $O(1)$ 路径。五题分别对应：RNN 梯度连乘的谱半径分析、LSTM 门控的定量效果、Transformer 并行化条件的辨析、注意力计算复杂度的量化、以及「范式革命」背后硬件驱动力与数学结构的综合评判。

题1【轻 · 推导 · RNN 梯度消失的数学根源】

导读：梯度消失不是调参问题，而是连乘结构在线性代数上的必然——把谱范数的上界写清楚，就把「为什么」说清楚了。

设 RNN 隐状态递推公式为 $h_t = \sigma(W h_{t-1} + U x_t + b)$ ，其中 $\sigma = \tanh$ ， $|\sigma'| \leq 1$ 。

(a) 写出从时刻 T 反传到时刻 t 的梯度连乘公式 $\frac{\partial \mathcal{L}}{\partial h_t}$ ，展开每步雅可比矩阵。

(b) 设 $\rho = \|W\|_2 \cdot \max |\sigma'|$ （有效谱半径上界）。证明梯度范数满足

$$\left\| \frac{\partial \mathcal{L}}{\partial h_t} \right\|_2 \leq \left\| \frac{\partial \mathcal{L}}{\partial h_T} \right\|_2 \cdot \rho^{T-t}$$

(c) 当 $\rho = 0.9$ 、 $T - t = 50$ 时，梯度范数衰减到原始值的多少比例（保留 4 位有效数字）？当 $T - t = 100$ 时呢？

(d) 梯度爆炸 ($\rho > 1$) 和梯度消失 ($\rho < 1$) 是否可以同时避免？说明「恰好 $\rho = 1$ 」在实践中是否可以精确控制，并解释原因。

教学注：(c) 的数字直接说明为什么 RNN 在 100 步以上的序列上几乎无法学习长距离依赖——梯度已经缩小了 7×10^{-5} 倍，优化信号近乎消失。

陷阱：

- 矩阵范数不等式是 $\|AB\|_2 \leq \|A\|_2 \|B\|_2$ ，连乘时上界累乘，这只是上界不是等号
- $\sigma = \tanh$ 时 $\max |\sigma'| = 1$ （在 0 处），故 $\rho = \|W\|_2$ ；但 $\sigma' < 1$ 在大多数时间步，实际衰减比 $\|W\|_2^{T-t}$ 更快

题2【中 · 计算 · LSTM 门控的缓解效果】

导读：LSTM 是工程防护栏而非数学根治——量化它的有效谱半径上限，才能精确理解它把 RNN 的天花板从哪里提高到哪里。

LSTM 的记忆单元（cell state）更新公式为

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

其中 $f_t \in [0, 1]^{d_h}$ 是遗忘门输出, $i_t \in [0, 1]^{d_h}$ 是输入门, $\tilde{c}_t$ 是候选更新量, $\odot$ 是逐元素乘。

(a) 写出 c_t 对 c_{t-1} 的偏导 $\partial c_t / \partial c_{t-1}$ (矩阵形式)。

(b) 若遗忘门在所有时刻都为 $f_t = \mathbf{1}$ (全开), 则记忆单元的梯度路径等效谱半径是多少? 这意味着什么?

(c) 若遗忘门在所有时刻都为 $f_t = 0.8 \cdot \mathbf{1}$, 且 $T - t = 200$, 记忆单元梯度的衰减比例是多少 (保留 4 位小数)? 与 (d) 相同情形下普通 RNN ($\rho = 0.9$, $T - t = 200$) 相比如何?

(d) 解释为什么 LSTM 门控「缓解但不根治」梯度消失问题, 以及它无法根治的数学原因。

教学注: (b) 的「全开等于恒等映射」是理解 LSTM 为什么能处理比 RNN 长得多的序列的核心直觉: 梯度可以无衰减地从 T 传回 t , 有效跨越整段序列。

陷阱:

- LSTM 的遗忘门 f_t 本身依赖输入, 是学习出来的, 实践中很少真正稳定为全开
- 「缓解但不根治」的「不根治」体现在: 门控参数也是通过梯度学习的, 训练初期门控设置错误, 真正重要的远距离信息仍然无法有效传播

题 3 【中 · 概念辨析 · Transformer 并行化的条件与代价】

导读: Transformer 的可并行性不是「注意力更聪明」, 而是计算图上没有时间依赖——把这个条件精确化, 才能判断哪些变体失去了并行性。

判断下列说法的真假, 并说明理由:

(a) 「Transformer 编码器 (非自回归模式) 的所有层都可以完全并行——不仅同一层内的所有位置并行, 不同层之间也可以并行。」

(b) 「自回归解码 (推理阶段逐 token 生成) 时, Transformer 和 RNN 同样无法并行, 所以两者在推理速度上没有本质区别。」

(c) 「在 Transformer 中, 位置 i 的输出和位置 j 的输出之间的梯度传播路径长度为 $O(1)$ (与序列长度无关), 而 RNN 中为 $O(n)$ 。」

(d) 「去掉位置编码的 Transformer 对输入序列的任意排列具有完全的置换不变性, 因此所有语序信息都丢失了, 模型性能会降至随机。」

教学注: (b) 是一个微妙的真假题——推理时 Transformer 确实逐 token 生成 (无法并行生成不同位置), 但它保有对已有历史 token 的并行注意力 (KV Cache), 计算模式与 RNN 不同。

陷阱:

- (a) 中不同层之间必须等前一层结果完成, 有层间依赖, 不能跨层并行
- (d) 中「性能降至随机」过强——没有位置编码的模型仍然能利用词义信息, 只是无法利用顺序信息, 在对序列顺序不敏感的任务上 (如词袋分类) 影响有限

题 4 【重 · 计算 · 注意力计算复杂度分析】

导读： $O(n^2d)$ 的复杂度不只是一个渐近符号，具体数字告诉你为什么长上下文是实际痛点。

设单头注意力，序列长度 n ，键/查询维度 d_k ，值维度 d_v ，精度 BF16（2 字节/元素）。

(a) 逐步写出注意力计算的三个步骤 ($S = QK^T$, softmax, $O = PV$)，各自的 FLOPs 表达式。

(b) 对 $n = 4096$, $d_k = d_v = 128$ （单头，典型 GPT-3 配置），计算总 FLOPs（精确表达式，单位 GFLOPs）。

(c) 若序列长度从 $n = 4096$ 翻倍到 $n = 8192$ ，FLOPs 变为多少倍？若翻四倍到 $n = 16384$ ，变为多少倍？

(d) 标准实现中，注意力矩阵 $S \in \mathbb{R}^{n \times n}$ 需要存储在显存中。对 $n = 8192$ (BF16)，计算此矩阵的显存占用（单位 MB）。若将 n 翻倍，显存需求如何变化？

教学注：(c) 揭示了为什么「长上下文」是当前大模型的核心工程瓶颈：FLOPs 和显存都以 n^2 增长，不是线性可扩展的。FlashAttention 解决的正是 (d) 的显存问题，而不改变 (c) 的 FLOPs。

陷阱：

- $S = QK^T$ 的 FLOPs 是 $2n^2d_k$ （每个输出元素做 d_k 次乘加），不要漏掉系数 2
- 显存计算： $n \times n$ 矩阵，每个元素 2 字节 (BF16)， $8192^2 \times 2 = 134,217,728$ 字节 ≈ 128 MB

题 5 【重 · 综合评判 · 范式革命的驱动力】

导读：「Transformer 崛起因为注意力更聪明」vs「Transformer 崛起因为矩阵乘法更适合 GPU」——这两种叙事的数学含义和推论截然不同。

阅读以下四个关于 Transformer 范式革命的论断，评估其准确性：

论断 A：「LSTM 在处理 200 步以内的序列时性能与 Transformer 相当，Transformer 的优势主要体现在超长序列 ($n > 1000$) 上。」

论断 B：「Transformer 消除了梯度消失问题——在任意深度的 Transformer 中，任意两个位置之间的梯度传播都是 $O(1)$ 的，不随层数或序列长度变化。」

论断 C：「注意力机制之所以能替代 RNN，根本原因是注意力在数学上等价于无参数的动态池化——它不需要递推，因此并行；它对全局加权，因此梯度路径短。」

论断 D：「RNN 的串行结构导致 GPU 利用率低，而 Transformer 的矩阵并行导致 GPU 利用率高——这是硬件驱动的范式替换，而非算法层面的突破。」

(a) 对每个论断给出「成立 / 部分成立 / 不成立」，指出关键的准确点或漏洞。

(b) 从数学角度，写出 Transformer 能替代 RNN 的两个必要条件（分别对应「并行性」和「长依赖可学性」）。

(c) Transformer 的位置编码 (RoPE) 的存在, 是否意味着 Transformer 重新引入了某种形式的「时序依赖」? 说明为什么 RoPE 不影响并行性。

教学注: 论断 B 有个重要漏洞——「任意深度」的 Transformer 在层数方向仍然存在梯度消失问题 (L 层时有 L 次矩阵乘法叠加), 只是在「序列方向」(不同位置之间) 梯度路径缩短为 $O(1)$, 这两个维度必须分开讨论。

陷阱:

- 「梯度路径 $O(1)$ 」只针对自注意力层内的序列方向, 不包括跨层传播 (残差连接解决的是跨层梯度问题, 不是注意力解决的)
- 论断 C 的「无参数」不准确——注意力有 W^Q, W^K, W^V 三套投影参数, 是有参数的

解答 § 3.1

T-3.1.1 【RNN 梯度消失推导】

(a) 链式法则展开:

$$\frac{\partial \mathcal{L}}{\partial h_t} = \frac{\partial \mathcal{L}}{\partial h_T} \prod_{k=t}^{T-1} \frac{\partial h_{k+1}}{\partial h_k}$$

每步雅可比矩阵 $\frac{\partial h_{k+1}}{\partial h_k} = \text{diag}(\sigma'(Wh_k + Ux_{k+1})) \cdot W$ 。

(b) 由矩阵范数次乘性 $\|AB\|_2 \leq \|A\|_2 \|B\|_2$:

$$\left\| \prod_{k=t}^{T-1} \frac{\partial h_{k+1}}{\partial h_k} \right\|_2 \leq \prod_{k=t}^{T-1} \|\text{diag}(\sigma')\|_2 \cdot \|W\|_2 \leq (\max |\sigma'| \cdot \|W\|_2)^{T-t} = \rho^{T-t}$$

故 $\|\partial \mathcal{L} / \partial h_t\|_2 \leq \|\partial \mathcal{L} / \partial h_T\|_2 \cdot \rho^{T-t}$ 。

(c) $\rho = 0.9$, $T-t = 50$: $0.9^{50} = e^{50 \ln 0.9} = e^{-5.268} \approx 0.0052$, 即约 0.52%。 $T-t = 100$: $0.9^{100} \approx 2.66 \times 10^{-5}$, 约 0.003%。

(d) $\rho = 1$ 在实践中几乎不可精确控制: 权重矩阵 W 的谱范数随训练动态变化, σ' 也随激活值变化; 即使初始化时 $\|W\|_2 = 1$, 一次梯度更新后谱范数即发生偏移。梯度消失 ($\rho < 1$) 和梯度爆炸 ($\rho > 1$) 两端都不稳定, 不存在一个稳定的「恰好 $\rho = 1$ 」的操作点。

Sanity check: $0.9^{50} \approx 0.005$, $0.9^{100} \approx 0.9^{50} \times 0.9^{50} \approx 0.005^2 = 2.5 \times 10^{-5}$, 与精确值 2.66×10^{-5} 量级一致。

T-3.1.2 【LSTM 门控效果】

(a) $\partial c_t / \partial c_{t-1} = \text{diag}(f_t)$ (逐元素遗忘门, 视作对角矩阵)。

(b) 若 $f_t = 1$ (全开), $\partial c_t / \partial c_{t-1} = I$, 等效谱半径为 1。梯度可无衰减地从任意远的时刻传回, 理论上能学习无限长的依赖关系。

(c) $f_t = 0.8 \cdot 1$, $T - t = 200$: 衰减比例 $0.8^{200} = e^{200 \ln 0.8} = e^{-44.63} \approx 5.2 \times 10^{-20}$, 几乎为零。

普通 RNN ($\rho = 0.9$, $T - t = 200$): $0.9^{200} = e^{200 \times (-0.1054)} = e^{-21.07} \approx 7.1 \times 10^{-10}$ 。

尽管 $0.8 < 0.9$, LSTM 在遗忘门全开时能做到谱半径 = 1; 而门若关小 ($f < 1$), 实际衰减可以比普通 RNN 更快。LSTM 的优势在于「门可以被学习为接近 1」, 而不是单纯地固定一个值。

(d) 不根治的数学原因: 遗忘门 f_t 本身是通过 $\sigma(W_f h_{t-1} + U_f x_t + b_f)$ 计算的, 这是一个递推函数。要让门在正确的时间步打开/关闭, 门的参数也需要通过反向传播学习——而这个学习过程本身仍然通过时间轴的链式法则传播, 在训练初期门控不准确时, 真正重要的长距离信号仍然可能被遗忘门「意外关闭」而丢失。

T-3.1.3 【并行化条件辨析】

(a) 假。不同层之间有顺序依赖: 第 ℓ 层必须等第 $\ell - 1$ 层所有位置的输出完成后才能开始。同一层内的不同位置可以完全并行, 但层间不行。

(b) 假 (对推理) / 真 (对训练)。推理时确实是逐 token 自回归 (无法并行生成), 但有 KV Cache 机制——对已生成的历史 token, Key 和 Value 只计算一次并缓存, 每步只需对新 token 做增量计算, 而不是像 RNN 那样整个隐状态串行更新。训练时 (教师强制), Transformer 的 n 个位置可以完全并行, RNN 不可以。

(c) 真。在自注意力层内, 位置 i 的输出 $O_i = \sum_j \alpha_{ij} v_j$ 通过一次矩阵运算直接与位置 j 连接, 梯度传播路径 $O(1)$ (一次矩阵乘法相隔); RNN 中位置 i 和 j 之间需要 $|i - j|$ 步递推, 路径长 $O(n)$ 。

(d) 假。去掉位置编码后, 模型仍然能利用词义信息 (通过嵌入向量), 只是所有序列排列都产生相同的注意力权重 (注意力对排列不变)。对词袋级别的任务 (情感分类等) 性能影响有限; 对需要顺序的任务 (语言建模、翻译) 性能大幅下降, 但不降至随机。

T-3.1.4 【复杂度数值计算】

(a)

- 步骤 1: $S = QK^T \in \mathbb{R}^{n \times n}$, FLOPs = $2n^2 d_k$
- 步骤 2: softmax (逐行), FLOPs = $\Theta(n^2)$ (较小, 约 $5n^2$)
- 步骤 3: $O = PV \in \mathbb{R}^{n \times d_v}$, FLOPs = $2n^2 d_v$

总 FLOPs $\approx 2n^2(d_k + d_v) = 4n^2 d$ (取 $d_k = d_v = d$)。

(b) $n = 4096$, $d = 128$: FLOPs = $4 \times 4096^2 \times 128 = 4 \times 1.678 \times 10^7 \times 128 = 8.590 \times 10^9 \approx 8.59$ GFLOPs。

(c) FLOPs $\propto n^2$: n 翻倍时 FLOPs 变为 4 倍; n 翻四倍时变为 16 倍。

(d) $n = 8192$: 矩阵大小 $8192^2 = 6.711 \times 10^7$ 元素, BF16 各 2 字节, $= 1.342 \times 10^8$ 字节 ≈ 128 MB。若 n 翻倍到 16384: $16384^2 \times 2 = 5.369 \times 10^8$ 字节 ≈ 512 MB, 即 n 翻倍、显存需求变为 4 倍。

Sanity check: FLOPs 和显存都正比于 n^2 , 验证: $512/128 = 4 = (16384/8192)^2 \checkmark$ 。

T-3.1.5 【范式革命驱动力评判】

(a)

- **论断 A 部分成立**。LSTM 在中等长度序列上确实接近 Transformer, 但 Transformer 优势不只来自长度——训练并行度允许更大数据量, 更大模型, 这是性能差距的主要来源, 而非仅仅序列长度。
- **论断 B 部分成立**。「序列方向梯度路径 $O(1)$ 」成立 (自注意力层内), 但层间传播仍是 $O(L)$ (L 为层数), 残差连接缓解但不消除跨层梯度消失。
- **论断 C 部分成立**。注意力确实无递推、梯度路径短, 但「无参数」不准确——投影矩阵 W^Q, W^K, W^V 是可学习参数; 「动态池化」的类比有一定直觉价值但不够精确。
- **论断 D 成立**。这是最核心的叙事: 矩阵乘法对 SIMD 硬件的高算术强度匹配, 使 GPU 能充分利用; 时序递推在 GPU 上浪费并行潜力。Transformer 的数学设计恰好与 2010 年代 GPU 的发展形成完美共振。

(b) 两个必要条件: ① **计算图无时间轴依赖**: n 个位置的输出可同时计算, 不需要等待前序隐状态 (并行性); ② **任意两位置梯度传播路径为 $O(1)$** : 自注意力在序列方向上只有一层矩阵运算相隔, 不需要连乘 (长依赖可学性)。

(c) RoPE 不影响并行性。RoPE 的作用是在计算 Q, K 时对每个位置施加一个旋转变换 $\mathcal{R}_m$, 这个变换是**每个位置独立**的 (位置 m 的 query 只依赖 m 本身的位置信息, 不依赖其他位置), 可与其他位置同时计算。RoPE 注入了相对位置信息 (通过旋转矩阵使内积只依赖位置差 $n - m$), 但这是通过函数变换实现的, 不引入任何时序递推依赖。

§ 3.1 小结: RNN 到 Transformer 的跨越有两条并行的逻辑链——数学上: 把梯度连乘 (ρ^{T-t}) 替换为 $O(1)$ 路径; 工程上: 把时序串行 (GPU 空等) 替换为矩阵并行 (GPU 满载)。LSTM 改善了前者 (防护栏, 上限 ~ 200 步), 但不改变后者; Transformer 同时解决了两个问题, 代价是位置编码和 $O(n^2)$ 复杂度两个新挑战。

§ 3.6 习题：注意力的真实身份——关联记忆，而非「注意力」

导读：本节核心是现代 Hopfield 网络与 softmax 注意力的数学等价：log-sum-exp 能量函数的不动点迭代，精确对应一次注意力前向传播，同时带来存储容量从线性跃升至指数级。五题分别对应：经典 Hopfield 网络能量函数与容量、log-sum-exp 算子的数学性质、不动点推导、等价性的代入验证、以及容量指数化的工程意义与类比边界。

题 1 【轻 · 推导 · 经典 Hopfield 网络的能量函数与容量】

导读：理解经典版本的线性容量限制，是明白「为什么需要换能量函数」的前提。

设经典 Hopfield 网络存储 N 个 d 维二值模式 $\xi^1, \dots, \xi^N \in \{-1, +1\}^d$ ，权重矩阵为 $W = X^T X - NI$ ($X \in \mathbb{R}^{N \times d}$ 为模式矩阵， I 为 $d \times d$ 单位矩阵)，能量函数为

$$E_{\text{classic}} = -\frac{1}{2} \xi^T W \xi$$

(a) 将 $W = X^T X - NI$ 代入能量函数，化简得到 E_{classic} 关于 ξ 和 X 的表达式，说明其含义：能量极小值对应什么几何关系？

(b) 经典 Hopfield 网络的检索更新规则是 $\xi_i^{\text{new}} = \text{sgn}((W\xi)_i)$ ，这等价于沿能量梯度下降的哪个步骤？

(c) 经典版本的存储容量约为 $0.14d$ （随机模式情形）。对 $d = 512$ ，该网络最多可靠存储多少个模式？若 WordNet 名词层级有约 8×10^4 个节点，用经典 Hopfield 网络以 $d = 512$ 嵌入所有节点是否可行？

(d) 解释为什么二次能量函数 $-\xi^T W \xi$ 的容量受到「串扰 (crosstalk)」的限制，直觉上串扰是如何产生的？

教学注：(a) 的化简揭示了经典 Hopfield 本质上在做 ℓ^2 范数最大化，即找最接近某个存储模式的方向——这是线性近似，只有不太密集的模式集才能正常检索。

陷阱：

- W 里减去 NI 是为了消除「自强化」效应（一个模式预测自己总是能量极小）
- 存储容量 $0.14d$ 是随机模式的概率保证，对结构化数据（如词嵌入这样高度相关的向量集）实际容量更低

题 2 【中 · 推导 · log-sum-exp 算子的数学性质】

导读：log-sum-exp 是连接能量函数和 softmax 的数学桥梁——搞清楚它的微分性质，不动点推导就会水到渠成。

定义 log-sum-exp 算子 $\text{lse}(\beta, z) = \beta^{-1} \log \sum_{i=1}^N \exp(\beta z_i)$ ，其中 $z \in \mathbb{R}^N$ ， $\beta > 0$ 。

(a) 证明 $\frac{\partial}{\partial z_j} \text{lse}(\beta, z) = \text{softmax}(\beta z)_j = \frac{\exp(\beta z_j)}{\sum_i \exp(\beta z_i)}$ 。

(b) 设 $z = X\xi$ ($X \in \mathbb{R}^{N \times d}$, $\xi \in \mathbb{R}^d$)，利用链式法则计算 $\frac{\partial}{\partial \xi} \text{lse}(\beta, X\xi)$ ，用 X 和 $\text{softmax}(\beta X\xi)$ 表示结果。

(c) 当 $\beta \rightarrow \infty$ 时， $\text{lse}(\beta, z)$ 趋向于 $\max_i z_i$ (即 ℓ^∞ 范数的光滑近似)；当 $\beta \rightarrow 0$ 时，趋向于什么？说明 β 的「逆温度」解释：大 β 对应「低温」，为什么「低温」让检索更锐利？

(d) 注意力公式中 $\beta = 1/\sqrt{d_k}$ ：当 d_k 增大时， β 变小 (温度升高)， softmax 更「平滑」。这与 §3.2 中为什么要除以 $\sqrt{d_k}$ 的论述有何关联？

教学注：(c) 揭示了 log-sum-exp 与 softmax 的「温度」解释： $\beta \rightarrow \infty$ 时 softmax 退化为 one-hot (硬选择)， $\beta \rightarrow 0$ 时趋于均匀分布——Hopfield 网络的「低温」等价于注意力的「大 $\sqrt{d_k}$ 缩放比例」时的锐利检索。

陷阱：

- (b) 的链式法则： $\frac{\partial}{\partial \xi} \text{lse}(\beta, X\xi) = X^T \cdot \text{softmax}(\beta X\xi)$ ，注意转置的位置
- (d) 中注意力 $\beta = 1/\sqrt{d_k}$ 是为了防止 softmax 退化，这与 Hopfield 「适当温度让检索成功」方向一致

题 3 【中 · 推导 · 现代 Hopfield 不动点等价于 softmax 注意力】

导读：这是本节最核心的推导——一步一步从能量函数偏导为零推出 softmax attention，不要跳步。

现代 Hopfield 网络的能量函数为

$$E = -\text{lse}(\beta, X\xi) + \frac{1}{2}\xi^T \xi + \frac{1}{2\beta} \log N + C$$

其中 $X \in \mathbb{R}^{N \times d}$ ， $\xi \in \mathbb{R}^d$ ， C 与 ξ 无关。

(a) 计算 $\partial E / \partial \xi$ ，利用题 2(b) 的结论写出完整表达式。

(b) 令 $\partial E / \partial \xi = 0$ ，得到不动点条件，写出对应的不动点更新规则

$$\xi^{\text{new}} = F(\xi)$$

(c) 令 $\xi \leftarrow Q_i$ (某查询向量)， $X \leftarrow K$ (键矩阵，行为键向量)， $\beta = 1/\sqrt{d_k}$ ，将不动点更新规则代入，与单头注意力输出

$$\text{Attention}_i = K^T \text{softmax}\left(\frac{KQ_i}{\sqrt{d_k}}\right)$$

对比，说明两者的等价关系及所需的额外条件。

(d) 完整的注意力公式 $O = \text{softmax}(QK^T/\sqrt{d_k})V$ 中有 $V \neq K$ ，这与 Hopfield 等价中 $K = V$ 的条件不符。解释这个差异的工程含义：分开 Key 和 Value 带来了什么额外灵活性？

教学注：(c) 中「等价」的精确表述是：softmax attention 是现代 Hopfield 网络以逆温度 $\beta = 1/\sqrt{d_k}$ 做一步不动点迭代——注意是一步，而非收敛到不动点。一步迭代在实践中已经足够，因为 Transformer 叠加多层注意力，可以理解为多步迭代的近似。

陷阱：

- (c) 中 KQ_i 是 $N \times 1$ 向量 (K 是 $N \times d_k$ 矩阵, Q_i 是 $d_k \times 1$ 向量), softmax 是对这个 $N \times 1$ 向量操作, 结果再乘 K^T ($d_k \times N$) 得到 d_k 维输出
- 「Key 与 Value 相同」只是 Hopfield 的特殊情形, 实际注意力中 $V = XW^V \neq K = XW^K$

题 4【重·计算·指数容量的数量级感受】

导读：从 $O(d)$ 到 $O(\exp(\alpha^2 d/2))$ 不只是渐近符号的变化——具体数字能让你感受「指数容量」的震撼。

现代 Hopfield 网络的存储容量约为 $C_{\text{modern}} = O\left(\exp\left(\frac{\alpha^2 d}{2}\right)\right)$, 经典版本约为 $C_{\text{classic}} = 0.14d$ 。

(a) 对 $d = 64$ (注意力头的典型键维度), $\alpha = 1/\sqrt{d}$ (即 $\alpha^2 = 1/d$), 计算现代版本的理论容量 C_{modern} (精确到数量级, 用 $10^?$ 表示)。

(b) 对同样的 $d = 64$, 经典版本容量约为多少? 两者相差多少个数量级?

(c) 若 GPT-3 的一个注意力头 $d_k = 128$, $\alpha = 1/\sqrt{d_k}$ (即 $\alpha^2 d/2 = 1/2$), 计算 C_{modern} 。这个数字相比于 GPT-3 的训练数据量 (约 5×10^{11} 个 token) 意味着什么?

(d) 解释为什么更大的模型 (更大的 d) 不仅是「更多参数」, 而是在关联记忆意义上具有指数倍更强的知识存储能力。这是否意味着「足够大的模型可以记住所有训练数据」?

教学注：(c) 中 $\alpha^2 d/2 = (1/d_k) \times d_k/2 = 1/2$, 故 $C_{\text{modern}} \sim e^{0.5} \approx 1.65$ ——这提醒我们: 理论容量是假设模式充分分离 (α 取固定值时 $\alpha^2 d$ 随 d 增长), 一旦实际 α 与 d 的比值固定, 容量就固定了。真正的指数增益需要 $\alpha^2 d$ 随 d 增大。

陷阱：

- C_{modern} 中的 α 不是固定常数, 而是与模式分离度和维度相关的量——如果 α 随 d 缩放, 才会得到指数增益
- 「记住所有训练数据」需要区分「存储容量」(关联记忆意义) 和「泛化能力」(统计学习意义), 前者是理论上界, 不等于后者

题 5【重·评判·关联记忆类比的边界】

导读：「softmax attention = 关联记忆检索」是比「softmax attention = 心理学注意力」更精确的类比, 但它也有边界——找到边界, 类比才能真正发挥作用。

阅读以下四个论断, 评估其准确性:

论断 A:「现代 Hopfield 网络证明了 softmax attention 每次前向传播相当于做一次完整的关联记忆检索，收敛到最近的存储模式。」

论断 B:「Transformer 模型中参数矩阵 W^K 的行向量就是「存储模式」，推理时的每次注意力计算是一次模式检索，这解释了为什么更大的模型能记住更多事实。」

论断 C:「指数容量意味着一个 $d = 512$ 的注意力头可以精确存储和检索约 $e^{128} \approx 10^{55}$ 个模式，这就是 Transformer 知识容量无穷大的原因。」

论断 D:「关联记忆类比比「注意力」类比更准确，因此可以直接用 Hopfield 网络的分析工具（如存储容量、串扰分析）来预测 Transformer 的记忆能力和错误率。」

(a) 对每个论断，指出「成立 / 部分成立 / 不成立」并说明关键准确点或漏洞。

(b) softmax attention 与现代 Hopfield 网络等价关系的两个重要「前提条件」是什么？（一个与 $K = V$ 有关，一个与迭代次数有关。）

(c) 「关联记忆」类比在解释 Transformer 的哪些现象时最有力？在解释哪些现象时会失效？各举一个例子。

教学注：论断 A 的「收敛到最近存储模式」是错误的——注意力只做了一步迭代，不保证收敛。多层 Transformer 可以理解为多步迭代，但每层之间还有 FFN 等其他非线性变换，不是纯 Hopfield 迭代。

陷阱：

- 论断 C 的 e^{128} 是理论上界，需要模式两两充分分离（分离度 $\geq \Delta$ ）——在实际 token 嵌入中，许多模式高度相关，有效容量远低于理论值
- 「更大模型记更多事实」与指数容量的关联是间接的：更大 d 提升容量，但训练的优化动态、数据分布等因素同样关键

解答 §3.6

T-3.6.1 【经典 Hopfield 能量与容量】

(a) 代入 $W = X^T X - NI$:

$$E_{\text{classic}} = -\frac{1}{2}\xi^T(X^T X - NI)\xi = -\frac{1}{2}\|X\xi\|^2 + \frac{N}{2}\|\xi\|^2$$

对 $\|\xi\|^2 = d$ (二值模式), $\frac{N}{2}\|\xi\|^2 = \frac{Nd}{2}$ 是常数项。能量函数极小化等价于最大化 $\|X\xi\|^2$, 即找最大化「存储模式矩阵与查询向量内积范数」的方向——几何上即 ξ 与某个存储模式最对齐的方向。

(b) 能量梯度下降: $-\nabla_{\xi} E = W\xi$, 符号步 (sgn) 取梯度方向的二值化, 等价于在负梯度方向上做一步 $\{-1, +1\}$ 投影。

(c) $d = 512$: $C_{\text{classic}} \approx 0.14 \times 512 = 71.68$, 约 71 个模式。 $8 \times 10^4 \gg 71$, 不可行——经典 Hopfield 以 $d = 512$ 存储 WordNet 全部节点会严重串扰, 检索失效。

(d) 串扰来自权重矩阵 $W = X^T X - NI$ 的叠加: 存储第 μ 个模式时, W 中有 $N - 1$ 个其他模式的贡献 $\xi^{\nu T} \xi^{\nu}$, 当模式数 N 超过 $0.14d$ 时, 这些「其他模式」的分量在检

索引时相互叠加，让能量极小值偏离目标模式，检索失败。

T-3.6.2 【log-sum-exp 微分】

(a) 令 $s_j = \exp(\beta z_j) / \sum_i \exp(\beta z_i)$ (softmax), 则:

$$\frac{\partial}{\partial z_j} \text{lse}(\beta, z) = \frac{\partial}{\partial z_j} \left[\frac{1}{\beta} \log \sum_i e^{\beta z_i} \right] = \frac{1}{\beta} \cdot \frac{\beta e^{\beta z_j}}{\sum_i e^{\beta z_i}} = s_j = \text{softmax}(\beta z)_j$$

(b) 链式法则: $\frac{\partial}{\partial \xi} \text{lse}(\beta, X\xi) = X^T \frac{\partial \text{lse}(\beta, z)}{\partial z} \Big|_{z=X\xi} = X^T \text{softmax}(\beta X\xi)$ 。

(c) $\beta \rightarrow 0$ 时, $\text{lse}(\beta, z) \rightarrow \frac{1}{\beta} \log N + \bar{z}$ (对数 N 加平均值), 实质趋向均匀平均。「逆温度」类比: 大 β (低温) 时 softmax 趋向 one-hot, 检索更锐利 (只取最相似的模式); 小 β (高温) 时 softmax 趋向均匀, 检索更「模糊」(各模式均等贡献)。

(d) 注意力 $\beta = 1/\sqrt{d_k}$, d_k 增大则 β 减小 (温度升高)。若不除以 $\sqrt{d_k}$, 内积方差为 d_k , 进入 softmax 时放大效应相当于 β 随 d_k 增大——softmax 退化为 one-hot, 梯度消失。除以 $\sqrt{d_k}$ 将方差归一化为 1, 等价于保持 β 对不同 d_k 在同一数量级, 使 softmax 保持「适温」的软检索。

T-3.6.3 【不动点推导】

(a) $\partial E / \partial \xi = -X^T \text{softmax}(\beta X\xi) + \xi$ (利用题 2(b) 和 $\partial(\xi^T \xi / 2) / \partial \xi = \xi$, 常数 C 、 $\log N / (2\beta)$ 不贡献)。

(b) 令 $\partial E / \partial \xi = 0$: $\xi = X^T \text{softmax}(\beta X\xi)$, 即不动点更新规则:

$$\xi^{\text{new}} = X^T \text{softmax}(\beta X\xi)$$

(c) 令 $\xi \leftarrow Q_i$, $X \leftarrow K$, $\beta = 1/\sqrt{d_k}$:

$$\xi^{\text{new}} = K^T \text{softmax}\left(\frac{KQ_i}{\sqrt{d_k}}\right)$$

这与 $\text{Attention}_i = K^T \text{softmax}(KQ_i / \sqrt{d_k})$ 完全相同 (写法上注意 KQ_i 是 $N \times 1$ 向量)。等价的额外条件: 此处 $K = V$ (键向量集合即为值向量集合), 即检索返回的内容与索引相同。

(d) 分开 K 和 V 的工程意义: K 负责「我能回答什么类型的问题」(打分索引), V 负责「我实际传递什么内容」(被检索后输出的信息)。即使匹配分数 (K) 相同, 传递的内容 (V) 可以完全不同——例如某个 token 的语法标签 (K , 用于被语法相关 Query 检索到) 与它的语义特征 (V , 真正混合到输出的内容) 可以由两套投影矩阵独立学习。这是注意力表达能力比纯 Hopfield 更强的原因。

T-3.6.4 【指数容量数量级】

(a) $d = 64$, $\alpha = 1/\sqrt{d} = 1/8$, $\alpha^2 = 1/64$:

$$C_{\text{modern}} \sim \exp\left(\frac{\alpha^2 d}{2}\right) = \exp\left(\frac{(1/64) \times 64}{2}\right) = \exp(0.5) \approx 1.65$$

注意这里 $\alpha^2 d = 1$ 为常数，与 d 无关——没有指数增益。真正的指数增益需要固定 α (不随 d 缩放)，此时 $\alpha^2 d \propto d$ 。若 $\alpha = 0.5$ (固定)， $C_{\text{modern}} \sim e^{d/8} = e^8 \approx 2981 \approx 10^{3.47}$ 。

(b) $C_{\text{classic}} = 0.14 \times 64 = 8.96 \approx 9$ 个。若 $\alpha = 0.5$ 固定时现代版本约 $10^{3.5}$ ，相差约 $10^{3.5}/9 \approx 350$ 倍，约 2.5 个数量级。

(c) $d_k = 128$, $\alpha = 1/\sqrt{128}$, $\alpha^2 d/2 = (1/128) \times 128/2 = 0.5$: $C_{\text{modern}} \sim e^{0.5} \approx 1.65$ 。这仅是每个头在「固定 $\alpha = 1/\sqrt{d}$ 」假设下的值，远小于训练数据量——说明单个头的关联记忆容量不是大模型记忆海量事实的唯一来源，参数在各层各头的分布式存储才是真正的机制。

(d) 更大的 d 在 α 固定时带来指数容量增长，但「记住所有训练数据」需要区分：关联记忆容量是理论上界（需要模式充分分离），实际训练目标（交叉熵最小化）是统计近似，不保证每个训练样本都被精确「存入」某个头的关联记忆。泛化能力来自参数化对数据分布的学习，而非对所有样本的精确记忆。

Sanity check: $e^{0.5} \approx 1.65$, $e^8 \approx 2981$ ——在 $\alpha^2 d$ 固定为 1 时和 d 无关，在 $\alpha^2 d \propto d$ 时指数级增长，两种情形结论截然不同，必须注意 α 的缩放方式。

T-3.6.5 【关联记忆类比边界】

(a)

- **论断 A 不成立。** 注意力只做一步不动点迭代，不保证收敛到存储模式。「完整检索 = 完全收敛」需要多次迭代，单层注意力只做一步近似。
- **论断 B 部分成立。** W^K 的行向量确实类似存储模式，推理时注意力做近似检索，这是合理的解释框架。但「更大的模型能记住更多事实」的原因是多因素的（更多参数、更多层、更大 FFN 的隐式记忆），单纯用 Hopfield 容量解释是过度简化。
- **论断 C 不成立。** e^{128} 是 $\alpha^2 d/2 = 64$ 时的值，但这需要 $\alpha = \sqrt{2}$ (固定)，远大于实际模式间的平均分离度。实际 token 嵌入高度相关，有效分离度小，有效容量远低于理论上界。「知识容量无穷大」是不正确的表述。
- **论断 D 部分成立。** 关联记忆类比确实比心理学类比更准确，但「直接用 Hopfield 分析工具预测 Transformer」有限制：(1) Transformer 中 $K \neq V$ ；(2) 每层还有 FFN、残差、层归一化等非 Hopfield 的组件；(3) 真实 token 嵌入不满足随机模式假设。分析工具可作参考，不能直接套用。

(b) 两个前提：① $K = V$ （键向量集合同时作为值向量集合，即「被检索的内容就是索引本身」）；② **一步迭代近似**（等价关系成立的是一次前向传播 = 一步不动点更新，而非完整收敛）。

(c) 最有力的解释：Transformer 为什么随参数量增加能存储更多世界知识（指数容量

提供了理论支撑)，以及为什么注意力能做「软检索」（关联记忆的内容寻址语义）。失效场景：解释 in-context learning 为何只需少量示例即能泛化——关联记忆框架只处理静态存储模式，无法解释 Transformer 在推理时「动态更新」和组合泛化的能力，这需要更复杂的机制分析（如 induction head 电路）。

§ 3.6 小结：softmax attention 的「真实身份」是现代 Hopfield 网络一步不动点迭代——能量函数从二次改为 log-sum-exp，把吸引子从「线性容量」升级为「指数容量」，这解释了为什么 Transformer 能以有限参数存储海量知识模式。理解这条链路，还能精确划定类比的边界：等价需要 $K = V$ 且只做一步迭代，超出这两个条件，关联记忆的分析工具就需要谨慎外推。

§3.7 习题：一个被忽略的争论——注意力权重 ≠ 解释

导读：本节核心是三条论证链——注意力权重只反映 Value 路径、梯度归因走更复杂的多路径、Jain & Wallace 证明权重对输出不具唯一决定性。五题分别对应：注意力权重的数学含义辨析、梯度归因三路径的推导、Jain & Wallace 反例的构造条件、可解释性工具的选择原则、以及综合评判「注意力权重作为解释工具」的合法边界。

题1【轻·推导·注意力权重测量的是什么】

导读： α_j 大的直觉含义是「模型更关注 token j 」——但在数学上，它只是 v_j 在输出线性组合中的系数，与 x_j 的重要性并非同一件事。

设单层单头注意力：

$$y = \sum_{j=1}^n \alpha_j v_j, \quad v_j = x_j W^V, \quad \alpha_j = \frac{\exp(q \cdot k_j / \sqrt{d_k})}{\sum_l \exp(q \cdot k_l / \sqrt{d_k})}$$

- 写出 y 对 v_j 的偏导 $\partial y / \partial v_j$ （视 α_j 为常数）。
- 写出 y 对 x_j 的偏导——仅考虑 Value 路径（假设 q 和 k_j 不依赖 x_j ），结果用 α_j 和 W^V 表示。
- 设 W^V 是一个将 $\mathbb{R}^d$ 投影到某个低维子空间的矩阵（秩为 $r < d$ ）。在这种情况下， α_j 大是否意味着 x_j 对 y 的贡献大？说明理由。
- 一个极端情形：设 $W^V = 0$ （零矩阵，所有 Value 向量为零），此时注意力权重 α_j 的值会如何变化？ y 的值是多少？这说明注意力权重与输出质量之间的关系是什么？

教学注：(d) 是一个刻意构造的极端反例，揭示了注意力权重和 W^V 是相互独立的——权重由 Q, K 决定，输出由 α 和 V 共同决定，只看权重一侧是信息不完整的。

陷阱：

- $v_j = x_j W^V$ 中 x_j 是行向量， $W^V \in \mathbb{R}^{d \times d_v}$ ，偏导结果是矩阵
- (c) 中「秩低」不等于「信息为零」，只是说 v_j 在某些方向上没有分量， α_j 的贡献被限制在那个子空间内

题2【中·推导·梯度归因的三条路径】

导读： $\partial \mathcal{L} / \partial x_j$ 比 α_j 复杂得多——把三条路径分开写出来，就能精确看到注意力权重只覆盖了哪一条。

在自注意力中（ $Q = XW^Q$ ， $K = XW^K$ ， $V = XW^V$ ）， x_j 影响输出 y_i （位置 i 的注意力输出）有三条路径。

- 路径一（Value 路径）：** $x_j \xrightarrow{W^V} v_j \xrightarrow{\alpha_{ij}} y_i$ 。写出 $\partial y_i / \partial x_j$ 经由路径一的贡献（用 α_{ij} 和 W^V 表示）。

(b) 路径二 (Key 路径): $x_j \xrightarrow{W^K} k_j \rightarrow \alpha_{ij} \rightarrow y_i$ 。写出 $\partial \alpha_{ij} / \partial k_j$ (提示: softmax 的 Jacobian), 再链接到 $\partial y_i / \partial x_j$ 的路径二贡献 (不需要完整展开, 写出结构形式即可)。

(c) 注意力权重 α_{ij} 只反映了哪条路径的强度? 路径二对 y_i 的贡献包含在 α_{ij} 里面吗?

(d) 若 x_j 对应的 $\alpha_{ij} = 0$ (位置 i 完全不关注位置 j), 路径二是否仍然可能对 y_i 有贡献? 说明理由, 并给出一个直觉上的语言学场景。

教学注: (d) 揭示了一个反直觉的现象: 即使位置 i 的注意力权重 $\alpha_{ij} = 0$, x_j 仍然可以通过影响 k_j 来间接改变其他位置的注意力分配, 进而影响 y_i 。这是注意力权重作为「解释」的一个根本漏洞。

陷阱:

- 路径二的贡献来自 x_j 改变 k_j , 进而改变 α_{ij} (位置 i 对 j 的权重), 进而改变 $y_i = \sum_l \alpha_{il} v_l$ ——即使最终 α_{ij} 较小, 通过它的变化对 y_i 的影响可以不为零
- softmax 的 Jacobian: $\partial \alpha_{ij} / \partial A_{ij} = \alpha_{ij}(1 - \alpha_{ij})$, $\partial \alpha_{ij} / \partial A_{il} = -\alpha_{ij}\alpha_{il}$ ($l \neq j$)

题 3 【中 · 概念辨析 · Jain & Wallace 反例的条件】

导读: Jain & Wallace 的结论不是「注意力权重永远无用」, 而是在特定条件 (Value 矩阵低秩相关) 下注意力权重对输出不具唯一决定性——搞清楚这个条件, 才能精确判断什么时候可以信任权重。

设注意力输出 $y = \alpha^T V$, 其中 $V \in \mathbb{R}^{n \times d_v}$ 是 Value 矩阵 (行为 Value 向量), $\alpha \in \Delta^{n-1}$ (概率单纯形)。

(a) 若 V 的行向量两两正交且模长相等, 设 α 和 α' 是两个不同的注意力分布 ($\|\alpha - \alpha'\|_1 > 0$), 证明 $y = \alpha^T V \neq \alpha'^T V = y'$ (除非 $\alpha = \alpha'$)。这说明在什么条件下注意力权重对输出唯一决定?

(b) 若 V 的所有行向量完全相同 ($v_1 = v_2 = \dots = v_n = v_0$), 则不管 α 如何选取, y 的值是多少? 这说明注意力权重在什么极端情形下完全「失效」(完全不决定输出)?

(c) 实际中 $V = XW^V$, 而 X 是 n 个 token 的嵌入矩阵。解释为什么「语义相似的 token 会有相似的 Value 向量」, 以及这如何导致 V 在实践中接近低秩矩阵。

(d) 一个长文档中, 90% 的 token 语义相似 (正文内容词), 10% 的 token 极具特异性 (专有名词)。你期望注意力权重在这个场景中对可解释性更可靠还是更不可靠? 结合 (a)(b) 的分析说明。

教学注: (a) 的正交情形说明, 当 Value 矩阵的行向量「最不相关」时, 注意力权重才对输出有最强的唯一决定性; (b) 则揭示了相反极端。实际情形总是在中间。

陷阱:

- (a) 中「正交且模长相等」是最有利于注意力权重作为解释的情形, 因为此时 V 是「最全秩」的
- (b) 中 $\sum_j \alpha_j v_0 = v_0$ 与 α 无关, 这是极端低秩 (秩为 1) 的情形

题4【重·综合评判·可解释性工具的选择原则】

导读：什么时候用注意力权重、什么时候用梯度方法、什么时候用激活修补——不同工具回答的是不同层次的问题，搞清楚问题类型才能选对工具。

对以下四个可解释性问题，判断注意力权重是否是合适的工具，并说明理由：

问题 A：「这个 token 的 Value 特征在输出混合中占了多大比重？」

问题 B：「删掉输入中的哪个 token 对预测结果影响最大？」

问题 C：「模型为什么在这个位置预测了 token X 而不是 token Y？」

问题 D：「哪些位置的 Value 向量的线性组合权重最不均匀（最集中）」

(a) 对每个问题，判断注意力权重是「直接回答 / 部分回答 / 不能回答」，并说明正确工具应该是什么。

(b) 写出「梯度归因」（如 Integrated Gradients）与「注意力权重可视化」在回答类型上的本质区别（各一句话）。

(c) 电路分析（Circuit Analysis）和激活修补（Activation Patching）能回答注意力权重无法回答的哪类问题？举一个具体场景。

教学注：问题 D 是一个微妙的情形——它问的确实是注意力权重可以直接测量的量（权重分布的熵或集中度），但这与「重要性」不同。「权重集中」只是说「softmax 的输出接近 one-hot」，不说明那个位置的输入是否真的「重要」。

陷阱：

- 「删掉某个 token」（问题 B）是一个因果干预操作，需要实际修改输入并重新推理，不是注意力权重能直接回答的
- 问题 A 和问题 D 是注意力权重能合法回答的，但它们的答案只反映当前前向传播中的线性组合关系，不涉及因果

题5【重·反例构造·「高权重 = 重要」的系统性误判】

导读：这道题让读者自己构造一个「高权重但不重要」的反例场景，以及一个「低权重但重要」的场景——亲手构造比被动阅读更能固化直觉。

(a) 构造一个具体的文本理解场景，使得 token j （如介词「of」）的注意力权重 α_{ij} 很大，但将「of」替换为另一个介词（如「for」）时预测几乎不变。指出这里违反了哪条注意力权重作为解释的前提条件（Value 路径的唯一性，或 V 的行向量独立性）。

(b) 构造另一个场景：token j （如一个否定词「not」）的注意力权重 α_{ij} 很小（接近 0），但将「not」删除会导致预测结果完全反转。这里是路径一还是路径二/三在起关键作用？

(c) 在 (b) 的场景中，什么可解释性方法能正确识别「not」的重要性？给出方法名称并描述其数学原理（一句话）。

(d) Jain & Wallace (2019) 的结论被后续工作（如 Wiegrefe & Pinter, 2019）部分质疑——他们指出在某些设置下注意力权重与人类判断相关。结合本节的三条论证链，写出「注意力权重何时可以作为辅助解释参考」的最小充分条件（两条）。

教学注：(b) 中「not」的低权重可能源于「not」的 Value 向量经过 W^V 投影后信息量较小（路径一弱），但「not」通过改变 k_{not} 来影响其他位置的注意力分配（路径二强），从而间接影响整个输出。这是注意力权重热力图中最常见的系统性误导来源。

陷阱：

- (a) 中的介词场景：介词的嵌入向量 (x_j) 经 W^V 投影后，Value 向量可能在语义子空间中与其他停用词的 Value 向量高度对齐，导致 α_j 大但替换后输出不变
- (d) 的「最小充分条件」不是「永远可用」的条件，而是「不会系统性误导」的条件，不同场景仍需验证

解答 § 3.7

T-3.7.1 【注意力权重的含义】

(a) $\partial y / \partial v_j = \alpha_j \cdot I_{d_v}$ （标量乘单位矩阵，因为 $y = \sum_j \alpha_j v_j$ 对 v_j 是线性的，系数为 α_j ）。

(b) 路径一： $y = \sum_j \alpha_j v_j = \sum_j \alpha_j (x_j W^V)$ ，固定 α_j ， $\partial y / \partial x_j = \alpha_j W^{V\top}$ （视 x_j 为行向量时，输出关于 x_j 的梯度为 $\alpha_j W^{V\top} \in \mathbb{R}^d$ ）。

(c) 若 W^V 是低秩投影（秩 $r < d$ ），则 $v_j = x_j W^V$ 只保留 x_j 在 r 维子空间里的分量。 α_j 大只意味着该 r 维投影在输出中权重高；若 x_j 在被 W^V 投影掉的 $(d-r)$ 维上有重要信息， α_j 大也反映不了这部分贡献。

(d) $W^V = 0$ ：所有 $v_j = 0$ ， $y = \sum_j \alpha_j \cdot 0 = 0$ ，与 α_j 无关。注意力权重仍然通过 Q, K 的内积被正常计算（可以任意分布），但输出永远为零。这说明注意力权重与输出质量完全解耦——权重由 W^Q, W^K 决定，输出由 W^V 和权重共同决定，仅凭权重无法推断输出信息量。

T-3.7.2 【梯度归因三路径】

(a) 路径一贡献： $\left. \frac{\partial y_i}{\partial x_j} \right|_{\text{path 1}} = \alpha_{ij} \cdot W^{V\top}$ （仅 x_j 对 v_j 的影响，权重为 α_{ij} ）。

(b) 路径二结构： $x_j \rightarrow k_j = x_j W^K \rightarrow A_{ij} = q_i \cdot k_j / \sqrt{d_k} \rightarrow \alpha_{ij} \rightarrow y_i = \sum_l \alpha_{il} v_l$ 。
 $\partial \alpha_{il} / \partial A_{ij}$ ：对 $l = j$ 为 $\alpha_{ij}(1 - \alpha_{ij})$ ，对 $l \neq j$ 为 $-\alpha_{ij}\alpha_{il}$ 。路径二对 y_i 的贡献：

$$\left. \frac{\partial y_i}{\partial x_j} \right|_{\text{path 2}} = \sum_l \frac{\partial y_i}{\partial \alpha_{il}} \frac{\partial \alpha_{il}}{\partial A_{ij}} \frac{\partial A_{ij}}{\partial k_j} \frac{\partial k_j}{\partial x_j}$$

结构形式上是 $(V^T \partial_{\alpha_{i \cdot}} \text{softmax})$ 乘 $q_i / \sqrt{d_k}$ 乘 $W^{K\top}$ ，比路径一更复杂，且与 q_i 、 V 矩阵行向量均有关。

(c) 注意力权重 α_{ij} 只反映路径一（Value 路径）中 v_j 的线性组合系数。路径二对 y_i 的贡献完全不在 α_{ij} 里——路径二的贡献来自 x_j 通过改变 k_j 来调整 α_{ij} 的大小，这是

一个导数关系，不等于 α_{ij} 本身。

(d) 即使 $\alpha_{ij} = 0$ ，路径二仍然可能有贡献： $\partial\alpha_{ij}/\partial A_{ij} = \alpha_{ij}(1 - \alpha_{ij}) = 0$ （当 $\alpha_{ij} = 0$ ，该项消失），但 $\partial\alpha_{il}/\partial A_{ij} = -\alpha_{ij}\alpha_{il} = 0$ 也消失——实际上当 $\alpha_{ij} = 0$ 时路径二的直接贡献也为零。但注意： α_{ij} 是在训练好的参数下的值，在训练过程中 α_{ij} 不为零，梯度通过路径二传播影响了参数学习，即使推理时 $\alpha_{ij} \approx 0$ ，模型参数已经被路径二的历史梯度「塑造」过了。语言学场景：主句中的从句引导词「that」注意力权重极低，但它的存在通过路径二影响了整个句子的结构解析（谓语归属）。

T-3.7.3 【Jain & Wallace 反例条件】

(a) 若 V 的行向量两两正交且模长相等 ($v_i \cdot v_j = 0, i \neq j, \|v_i\| = c$)，则 $y = \alpha^T V = \sum_j \alpha_j v_j$ ， $y' = \alpha'^T V = \sum_j \alpha'_j v_j$ 。若 $\alpha \neq \alpha'$ ，存在某个 j 使 $\alpha_j \neq \alpha'_j$ ，由正交性： $\|y - y'\|^2 = \sum_j (\alpha_j - \alpha'_j)^2 \|v_j\|^2 = c^2 \sum_j (\alpha_j - \alpha'_j)^2 > 0$ ，故 $y \neq y'$ 。唯一决定条件：Value 矩阵 V 的行向量两两正交（满秩、无相关性）时，注意力权重对输出唯一决定。

(b) $v_1 = \dots = v_n = v_0$ ： $y = \sum_j \alpha_j v_0 = v_0$ ，与 α 完全无关。在所有 Value 向量相同（ V 秩为 1）的极端情形下，注意力权重对输出零决定性。

(c) 语义相似的 token 的嵌入 x_j 聚集在嵌入空间的相近区域，经过 W^V 的线性投影后，相似 token 的 Value 向量仍然相近（线性变换保持相似关系）。在一段语义连贯的文本中，大多数 token 的 Value 向量在高维空间中分布在一个低维流形上， V 的有效秩远低于 n ，Jain & Wallace 的条件成立。

(d) 正文内容词（90%）语义相似 $\rightarrow$ Value 向量高度相关 $\rightarrow V$ 低秩（主要由少数方向张成）。专有名词（10%）高度特异 $\rightarrow$ Value 向量方向独特 $\rightarrow$ 这 10% 的 token 的注意力权重有更强的唯一决定性。因此：对正文内容词，注意力权重可解释性较低（高相关导致权重可替换）；对专有名词，注意力权重更可靠（Value 向量独特，权重对输出影响更直接）。

T-3.7.4 【可解释性工具选择】

(a)

- **问题 A（直接回答）**：注意力权重 α_j 就是 Value 向量的线性组合系数，这是权重的字面定义，可以直接回答。
- **问题 B（不能回答）**：「删掉 token 对预测的影响」是因果干预操作，需要重新推理；正确工具是输入扰动法（如 LIME 的遮掩实验）或 Integrated Gradients。
- **问题 C（不能回答）**：「为什么预测 X 而非 Y」需要追溯完整计算电路（哪些特征激活了 X 对应的输出分布），正确工具是激活修补（Activation Patching）或电路分析。
- **问题 D（直接回答）**：注意力权重的集中度（如熵 $-\sum_j \alpha_j \log \alpha_j$ 或最大权重值）可以直接计算，注意这只反映注意力分布形状，不等于重要性。

(b) **梯度归因**回答「输入的微小变化如何影响输出」（微分敏感度，因果性强）；**注意力权重**回答「当前前向传播中哪些 Value 向量被最多线性组合进输出」（相关性，非因

果)。

(c) 激活修补能回答「某层某位置的激活值是否是产生特定预测的必要条件」：将模型在干净输入上的激活值替换到被污染输入的对应位置，观察预测变化——能精确定位「预测由哪个模块产生」。具体场景：识别「人名从主语移动到宾语位置」的「name mover head」——激活修补可以证明这个头的激活是预测正确实体名的充分条件，而注意力权重热力图只能显示这个头「关注」了主语位置，无法证明因果性。

T-3.7.5 【反例构造与边界】

(a) 场景：句子「The cost of living in this city is high」中，「of」的注意力权重可能因高频词的稳定性而较大。将「of」替换为「for」，句法结构相似，预测影响极小。违反的条件：「of」和其他高频虚词的 Value 向量高度相关（经过 W^V 后在语义空间中聚集）， V 的行向量不独立， α_j 大但输出在「of」和「for」之间几乎不变（它们的 Value 向量差异被 W^V 压平）。

(b) 场景：「The result is not valid」中，「not」的注意力权重 $\alpha_{i,\text{not}}$ 可能接近 0（许多位置不需要直接从「not」的 Value 取内容），但删除「not」后预测从「negative」反转为「positive」。路径二/三起主要作用：「not」的 k_{not} （Key 向量）在训练中被塑造成一个「语义翻转信号」，影响了其他位置（如「valid」所在位置）的注意力权重，从而改变了那些位置的 Value 混合；路径三（Query 路径）：「not」同时影响了自身位置的 q_{not} ，对其他位置的关注分配也产生了全局影响。

(c) Integrated Gradients（积分梯度）：沿从基线（如全零输入）到实际输入的插值路径，对输入特征求梯度的积分 $\int_0^1 \frac{\partial F(x_0 + t(x - x_0))}{\partial x} dt \cdot (x - x_0)$ ，满足完整性公理（所有特征的归因之和等于预测值之差），能正确识别「not」的否定作用。

(d) 注意力权重可以作为辅助解释参考的最小充分条件：① **Value 矩阵 V 的行向量足够独立**（如通过条件数或有效秩验证，使得不同 α 产生明显不同的输出）；② **解释目标是「哪些 token 的 Value 特征被直接混合进输出」**而非「哪些输入 token 对预测起决定性作用」（前者是注意力权重的字面含义，后者需要梯度归因）。

§ 3.7 小结：注意力权重的三层困境——它只覆盖 Value 路径（路径一）；梯度归因需要三条路径之和；即使在路径一上，Value 矩阵的相关性也让「高权重 $\Leftrightarrow$ 高重要性」的等式失效。正确的可解释性策略是：注意力权重用于「Value 分配的描述性统计」，梯度方法用于「输入敏感性归因」，激活修补用于「因果机制定位」。三种工具回答不同层次的问题，不存在万能的可解释性工具。

§ 3.8 习题：跨界映射——宏观工业供应链

导读：本节核心是供应链类比的「合法边界」——哪些注意力的数学特征能被供应链逻辑精确对应，哪些对应是量级直觉、哪些是修辞。五题重点偏向「类比是否合法」：Q/K/V 三角角色与采购三角角色的映射、softmax 与比例分配的等价验证、多头与多专业供应链的数学对应、量级估算的实践价值、以及类比合法性的总结评判。

题 1 【轻·类比验证·QKV 三角角色与供应链三角角色的映射】

导读：最好的类比是在数学结构上有精确对应的类比——把 Q、K、V 的数学定义与供应链角色的定义逐条配对，找到对应的边界。

供应链采购中：**需求方**发出采购请求（详细说明「需要什么类型的物料」），**供应商标签**是供应商公布的规格书（描述「能提供什么」），**实际物料**是真正交货的零件。

注意力机制中： $Q = XW^Q$ （查询向量）， $K = XW^K$ （键向量）， $V = XW^V$ （值向量）。

(a) 对应关系是： $Q \leftrightarrow$ 需求方， $K \leftrightarrow$ 供应商标签， $V \leftrightarrow$ 实际物料。验证：「需求方和供应商标签之间做匹配打分」在数学上对应注意力的哪一步计算？写出对应公式。

(b) 在供应链中，规格书（Key）和实际物料（Value）可以不同：规格书描述型号和参数，实际物料是物理实体。在注意力中， $W^K \neq W^V$ 也意味着键和值由不同投影产生。请问：如果强制 $W^K = W^V$ ，注意力机制等价于「规格书就是实物」的供应链，这有什么问题？（从 § 3.2 的角度回答。）

(c) 供应链中一个关键特性：采购方同时扮演「需求方」（向上游发出需求）和「供应商」（向下游提供产品）。在自注意力中，同一个 token 同时生成 Q、K、V，对应这个特性吗？说明理由。

(d) 供应链中，需求方发出的采购请求通常非常具体（型号、数量、规格），而注意力的 Query 向量是连续实数向量，「模糊匹配」而非「精确匹配」。这个差异对类比的「精确度」有什么影响？类比是「数学等价」还是「量级类比」？

教学注：(b) 揭示了 $W^K \neq W^V$ 的设计意图——「能回答什么类型的问题」（Key）和「真正传递什么内容」（Value）解耦，这与供应链中规格书和实物分离的管理逻辑高度对应，但在数学上有更强的表达能力保证（§ 3.2 的非对称性论证）。

陷阱：

- (c) 中「同一 token 生成 Q、K、V」是自注意力的特性，交叉注意力（cross-attention）中 Q 来自一个序列，K/V 来自另一个序列，此时「需求方」和「供应商」不再是同一个实体
- (d) 中「模糊匹配」通过 softmax 实现，而不是通过 argmax——这是注意力比「数据库查询」更灵活的核心，也是类比边界之一

题2【中·计算·softmax 归一化与比例分配的等价验证】

导读：供应链的「比例分配订单」和 softmax 归一化在数学结构上高度吻合，但有一个关键差异——这道题通过具体数字揭示差异所在。

设有 3 个供应商，采购部门对其打分 $s = (3, 1, 0)$ （分数越高匹配度越好）。

(a) 供应链的「比例分配」方案：按打分归一化， $\alpha_j = s_j / \sum_l s_l$ 。计算 $\alpha_1, \alpha_2, \alpha_3$ 。

(b) 注意力的 softmax 方案： $\alpha_j = \exp(s_j) / \sum_l \exp(s_l)$ ($\beta = 1$ 时)。计算 $\alpha_1, \alpha_2, \alpha_3$ （保留 4 位小数）。

(c) 比较两种分配方案的差异。softmax 相比「按打分比例分配」对高分供应商给出了更多还是更少的份额？这种差异在数学上由什么决定？

(d) 在供应链中，「评分为 0 的供应商」通常被完全排除出采购名单（份额为 0）。在 softmax 方案中，评分为 0 的供应商对应的权重是多少？这对「软检索 vs 硬检索」的区别有何启示？

教学注：(c) 揭示了 softmax 的「放大效应」：exp 函数对打分差异的放大比线性比例更激进，高分供应商在 softmax 方案中获得的份额比例高于其得分占比。这对应注意力的「高相似度键得到指数级更高权重」的性质。

陷阱：

- (b) 中 $\exp(3) = 20.0855$, $\exp(1) = 2.7183$, $\exp(0) = 1$, 分母 = 23.8038
- (d) 中 $\exp(0) = 1 \neq 0$, softmax 永远不会输出精确的 0（只在 $s \rightarrow -\infty$ 时趋向 0）——这是「软检索」的数学来源

题3【中·类比验证·多头与多专业供应链】

导读：多头注意力「并行在不同子空间做注意力」的结构，与「多条专业供应链并行运作」的直觉高度吻合——这道题验证这个对应的数学精确度，并指出涌现与设计之间的区别。

设有 $h = 4$ 个注意力头，每头的键/查询维度 $d_k = d/h$ ($d = 256$, 故 $d_k = 64$)。

(a) 在参数量上，单头注意力 ($d_k = d = 256$) 和 4 头注意力 ($h = 4$, $d_k = 64$) 的 Q, K, V 总参数量是否相同？计算两种方案各自的 $W^Q + W^K + W^V$ 的参数总数。

(b) 供应链的「多专业化分工」是事先设计好的（例如「第 1 条链负责标准件，第 2 条链负责精密件」），而多头注意力中各头的专业化是通过训练涌现的（不是预先规定的）。这个差异对「以供应链类比注意力」的合法性有什么影响？

(c) 假设你是工程师，想在训练前「规定」第 1 个头专注于句法依存关系，第 2 个头专注于语义关联。可以通过以下哪种操作实现？判断每种操作是否可行，说明理由：- 方案 A：初始化 W_1^Q, W_1^K 为句法分析器提取的特征矩阵 - 方案 B：在损失函数中加入「第 1 头的注意力分布应与句法分析树对齐」的正则项 - 方案 C：只有第 1 头的 W^Q, W^K 参与梯度更新，其他头固定

(d) 实验研究（如 Clark et al., 2019）发现，有些头确实捕捉到了句法依存关系（如主语-谓语头），有些头追踪指代关系。这是「设计」还是「涌现」？这个现象是否支持供

应链的「专业化供应链」类比？

教学注：(b) 是类比最重要的边界之一——供应链的专业化是人设计的，注意力头的专业化是梯度发现的。用「多专业供应链」类比时，要明确这是对「已训练结果」的事后描述，而不是对「训练机制」的精确类比。

陷阱：

- (a) 中 4 头注意力：每头 $W_i^Q \in \mathbb{R}^{256 \times 64}$ ，4 头共 $4 \times 256 \times 64 \times 3 = 196608$ ；单头 $W^Q \in \mathbb{R}^{256 \times 256}$ ， $256^2 \times 3 = 196608$ ——两者完全相同，这是设计要求
- (c) 的三种方案难度依次增加：A 较为可行（初始化不影响最终优化方向但可能加速收敛），B 较为可行（常见的辅助损失方法），C 存在梯度不均衡问题

题 4【重·计算·供应链类比的量级价值】

导读：供应链类比最大的贡献是帮助建立规模直觉——这道题把「全球询价」的量级从比喻变成精确数字，让读者感受注意力计算的规模为什么在人类供应链管理中完全不可想象。

设 GPT-4 的某个版本：序列长度 $n = 8192$ ，注意力头数 $h = 128$ ，层数 $L = 120$ ，键/查询维度 $d_k = 128$ ，每次前向传播处理一个序列。

(a) 在单层单头的注意力中，每个 token 对所有 n 个 token 做一次内积打分，相当于供应链中「一次全球询价」。单层 128 头对整个序列完成一次前向传播，等价于多少次「全球询价」（询价次数 = 每个 Query 对应的 Key 比较次数之和）？

(b) 全部 120 层完成一次完整的前向传播，等价于多少次「全球询价」？用科学计数法表示。

(c) 一个现实世界的供应链管理系统，假设每天管理 1000 个供应商，每次采购决策需要与 50 个候选供应商做比较，每年进行 10^6 次采购决策。计算年询价次数，与 (b) 比较，差距多少个数量级？

(d) 量级差距说明了什么？在什么意义上「GPU 实现了人类供应链系统完全无法实现的规模」？这是否意味着注意力机制比供应链更「高效」？

教学注：量级计算揭示了类比的價值局限——供应链类比帮助理解逻辑结构（三角色分离、比例分配、专业化分工），但在规模上两者差距超过 10 个数量级，「以规模感受到差异」才是类比的量级价值所在。

陷阱：

- (a) 中「全球询价次数」= $n \times n \times h = 8192 \times 8192 \times 128$ （每个 Query 与每个 Key 做内积， n 个 Query， n 个 Key， h 个头）
- (d) 中「更高效」需要明确单位——注意力的高效体现在「可并行的矩阵运算」，而非单次决策的复杂度更低

题 5 【重 · 类比合法性综合评判 · 供应链映射的总体评估】

导读：经过前四题对供应链类比的细节检验，这道题要求读者从整体上评估这个类比的合法性——哪些维度「精确对应」，哪些只是「量级类比」，哪些是「修辞延伸」。

对以下五个关于供应链类比的论断，判断其「类比是否合法」：

论断 A：「softmax 归一化对应供应链中比例分配订单的操作，这是一个精确的数学等价——两者在数学上是同一回事。」

论断 B：「注意力机制中某个位置被「多个 Query」同时高度关注，类似于一个供应商被多家客户抢购，会导致该供应商「产能耗尽」，进而影响其他客户的供应。」

论断 C：「多头注意力中各头自发专业化（有的头关注句法，有的头关注语义），与供应链中多条专业供应链的分工类似，这是一个结构上的有效类比。」

论断 D：「供应链通过「询价-报价-成交」的流程做最优决策，注意力机制也通过 softmax 做「最优」的 Value 混合，两者在优化逻辑上等价。」

论断 E：「增加注意力头数 h 类似于增加供应链的专业化分工条数，能增加系统的「采购精度」——这是一个在量级上可以预测头数效果的类比。」

(a) 对每个论断，分类为「精确等价 / 量级类比 / 修辞延伸 / 误导性类比」，并一句话说明理由。

(b) 供应链类比在解释注意力时最准确的一句话总结是什么？（不超过 30 字）

(c) 写出供应链类比在「预测注意力计算瓶颈」时最容易产生的一种误判，以及这种误判的正确纠正。

教学注：论断 B 是本题最关键的反例——它引入了「产能耗尽」这个供应链核心概念，但注意力中 Value 向量没有产能约束，这个映射是根本性的失效，详见 § 3.9。

陷阱：

- 论断 A 的「精确等价」需要验证：softmax 是 exp 归一化，比例分配是线性归一化，两者数学形式不同，因此不是「同一回事」，而是「结构相似但函数形式不同」
- 论断 E 中「增加头数增加精度」：实验上增加头数到一定程度后效果不再提升，甚至略降（注意力头过多会导致信息分散），用供应链类比预测「头数越多越好」是误导

解答 § 3.8

T-3.8.1 【QKV 与供应链三角色映射】

(a) 「需求方和供应商标签之间做匹配打分」对应： $A = QK^T / \sqrt{d_k} \in \mathbb{R}^{n \times n}$ ，其中 $A_{ij} = q_i \cdot k_j / \sqrt{d_k}$ 是第 i 个需求方（Query）和第 j 个供应商标签（Key）之间的匹配分数。

(b) 若强制 $W^K = W^V$ ($K = V$)，则注意力打分用于「谁被关注」和「传递什么」由同一套投影决定。问题：注意力矩阵 $A = QK^T / \sqrt{d_k}$ 中 K 的方向既要优化「打分匹配」又要优化「传递内容」，这两个目标可能冲突（§ 3.2：Value 需要传递语义内容，

Key 需要易于被正确的 Query 匹配到，两者对 W^K/W^V 的优化方向可能不同)。分开设计使「规格书」和「实物」各自独立优化。

(c) 是，自注意力中同一 token j 的嵌入 x_j 同时乘以 W^Q (作为需求方)、 W^K (作为供应商标签)、 W^V (作为实际物料)，对应供应链中企业同时扮演三个角色的现实。

(d) 类比是「结构类比」而非「数学等价」：采购请求是离散规格 (型号、数量)，Query 向量是连续实数，匹配方式 (内积 vs 精确匹配) 根本不同。供应链类比提供的是逻辑结构直觉 (三角色的功能分工)，不是计算公式的等价，属于「量级/逻辑类比」而非「数学等价」。

T-3.8.2 【softmax 与比例分配的差异】

(a) 线性比例分配： $\alpha_1 = 3/4 = 0.7500$, $\alpha_2 = 1/4 = 0.2500$, $\alpha_3 = 0/4 = 0.0000$ 。

(b) softmax: $\exp(3) = 20.0855$, $\exp(1) = 2.7183$, $\exp(0) = 1.0000$, 分母 = 23.8038。

$\alpha_1 = 20.0855/23.8038 = 0.8438$, $\alpha_2 = 2.7183/23.8038 = 0.1142$, $\alpha_3 = 1.0000/23.8038 = 0.0420$ 。

(c) softmax 给高分供应商更多份额 (0.8438 vs 0.7500)，给低分供应商更少份额 (0.0420 vs 0)。数学上，exp 是凸函数，对打分差异的「放大比例」超过线性——分数越高，被 exp 放大后在分母中占比越大，份额越集中于高分项。

(d) 评分为 0 的供应商：softmax 权重 = $\exp(0)/Z = 1/Z > 0$ (永远非零)。这就是「软检索」——softmax 永远不会完全排除某个 token (除非分数趋于 $-\infty$)。对应供应链语义：评分 0 的供应商仍然分得约 4% 的订单，保留了「一定的容错性」——这在供应链中有时是合理的 (避免单一供应商风险)，但在注意力中，这是 exp 函数的数学性质，不是设计决策。

Sanity check: $0.8438 + 0.1142 + 0.0420 = 1.0000 \checkmark$ 。

T-3.8.3 【多头与多专业供应链】

(a) 单头: $W^Q \in \mathbb{R}^{256 \times 256}$, $256^2 = 65536$, $W^Q + W^K + W^V$ 共 $3 \times 65536 = 196608$ 个参数。4 头: 每头 $W_i^Q \in \mathbb{R}^{256 \times 64}$, $256 \times 64 = 16384$, 4 头 $\times 3$ 套 $\times 16384 = 196608$ ——完全相同，这是多头设计「参数量不变而扩展表达能力」的工程保证。

(b) 供应链分工是事前设计 (合同规定职责)，注意力头的专业化是事后涌现 (梯度塑造)，这个差异使类比在「解释训练机制」时失效：不能用「设计专业供应链」的逻辑来理解「如何训练各头分工」。类比只在描述「已训练好的模型各头功能」时有启发价值。

(c) 方案 A (较可行)：初始化提供了有利的起点，但梯度更新会改变权重，不保证最终专业化符合设计；方案 B (较可行)：辅助损失是常见的约束训练的手段，但句法分析树的获取和对齐代价高；方案 C (不太可行)：固定其他头的参数会导致多头之间梯度不均衡，模型容量被浪费。

(d) 涌现，不是设计。Clark et al. (2019) 的实验是事后分析——训练时没有任何「让

第 k 头负责句法」的显式约束，头的分工是损失函数在高维参数空间中自然找到的最优解。支持类比：结果上确实有专业化分工，与「多专业供应链」的最终状态吻合。但不支持类比在「过程」层面的推广——不能用「供应链管理设计分工」来类比「Transformer 如何学会分工」。

T-3.8.4 【量级估算】

(a) 单层询价次数：每个头，每个 Query ($n = 8192$) 与每个 Key ($n = 8192$) 做一次内积，共 $n^2 = 8192^2 = 6.711 \times 10^7$ 次； $h = 128$ 头，单层询价总次数 $= 128 \times 6.711 \times 10^7 = 8.590 \times 10^9$ (约 86 亿次)。

(b) $L = 120$ 层：总询价次数 $= 120 \times 8.590 \times 10^9 = 1.031 \times 10^{12}$ (约 1 万亿次)。

(c) 现实供应链： $1000 \times 50 \times 10^6 = 5 \times 10^{10}$ 次 (约 500 亿次/年)。差距： $10^{12} / 5 \times 10^{10} = 20$ ，约 **1 个数量级**。这里参数选取使两者接近——如果用更实际的「全球最大供应链系统」(采购次数更少)，差距可达 3 ~ 5 个数量级。

(d) 量级差距说明：一次 Transformer 前向传播 (约毫秒级完成) 完成的「匹配评分」次数，与人类供应链系统全年运营量相当甚至更多。这不意味着注意力「更高效」(单次决策，注意力内积和人类判断的代价量级不同)，而是说明矩阵运算在硬件上可以极度并行化，而人类供应链受物理和组织约束不能并行。类比的值在于：把抽象的矩阵乘法规模还原为可感知的操作量级。

T-3.8.5 【类比合法性评判】

(a)

- **论断 A 修辞延伸**。softmax (exp 归一化) 和线性比例分配 (权重 $\propto s_j$) 在数学形式上不同——exp 对差异有放大效应，线性比例没有。两者是「类似的归一化目标」，但不是「同一回事」。
- **论断 B 误导性类比**。注意力没有产能约束 (Value 向量可以无限次被不同 Query「调用」，不存在资源耗尽)，这是供应链类比最根本的失效点 (详见 §3.9)。
- **论断 C 量级类比**。结果上多头确实有分工 (正确)，但分工是涌现的而非设计的 (与供应链「设计专业链」不同)——是描述训练结果的有效类比，不是对训练机制的精确类比。
- **论断 D 误导性类比**。供应链调度是带约束的优化问题 (有决策者、有目标函数)；注意力是一个确定性线性函数 (矩阵乘加 softmax)，没有任何「决策」或「权衡过程」，结果唯一确定。两者在优化逻辑上根本不同。
- **论断 E 量级类比 (部分)**。增加头数确实增加了「并行检索不同语义维度」的能力 (有一定直觉价值)，但实验上效果饱和，且总参数量不变 (每头维度缩小)——用「供应链专业化条数越多越好」来预测头数效果会过度乐观。

(b) 供应链类比最准确的一句话：注意力的「查询-打分-加权混合」逻辑，在三角色分离和比例分配的结构层面与供应链的「需求-匹配-调度」高度对应，但没有产能约束、没有优化决策。

(c) 最容易产生的误判：「序列中某个位置被多个 Query 高度关注时，该位置会成为「瓶颈」（被过度使用），影响系统整体性能」。纠正：注意力没有产能约束，同一 Value 向量可以无限次以最高权重响应所有 Query——不存在「过度使用」的概念；注意力的真正计算瓶颈是 $O(n^2)$ 的内存和 FLOPs，与某个具体位置被关注多少次完全无关。

§ 3.8 小结：供应链类比在三个层面有价值：三角色分离（Q/K/V 解耦的直觉）、比例分配（softmax 的软检索直觉）、多专业链并行（多头分工的量级直觉）。它在两个层面系统性失效：产能约束（Value 无守恒）和优化决策（注意力是确定性线性函数，不是带约束的优化过程）。下一节（§ 3.9）将逐一拆解这些失效的数学根源。

§ 3.9 习题：反类比——当供应链隐喻失效

导读：本节核心是从数学层面逐一解析供应链隐喻失效的四个根源：无产能约束（softmax 归一化不是资源守恒）、无先验语义目标（头的功能由训练涌现）、无优化决策（注意力是确定性线性变换）、权重不等于解释（不可审计性）。五题重点偏向「指出哪条假设被违反」——每道题都从一个看似合理的供应链推论出发，要求精确定位违反了注意力的哪条数学性质。

题 1【轻·推导·softmax 归一化 ≠ 资源守恒】

导读：供应链的「订单分配」满足资源守恒（产能总量固定），但 softmax 归一化满足的是「每个 Query 的权重之和为 1」，这是统计归一化而非物理守恒——两者的数学形式截然不同。

设注意力输出为 $y_i = \sum_j \alpha_{ij} v_j$ ，其中 $\alpha_{ij} = \exp(q_i \cdot k_j / \sqrt{d_k}) / \sum_l \exp(q_i \cdot k_l / \sqrt{d_k})$ 。

(a) 验证「行归一化」：对固定的 i ，证明 $\sum_j \alpha_{ij} = 1$ 。这对应供应链中哪个守恒律？

(b) 验证「列无约束」：对固定的 j ， $\sum_i \alpha_{ij}$ 是否有固定值？写出 $\sum_i \alpha_{ij}$ 的表达式，说明其是否等于 1。

(c) 供应链中，产能守恒意味着「同一供应商向客户 A 分配了 p 的产能，则向其他所有客户合计只能分配 $1 - p$ 的产能」，即 $\sum_i (\text{客户 } i \text{ 对供应商 } j \text{ 的采购量}) = (\text{供应商 } j \text{ 的总产能})$ 。在注意力中，与此对应的「列守恒」是否成立？用 (b) 的结论给出明确答案。

(d) 指出注意力中 Value 向量无产能约束的直接推论：同一个 v_j 能否同时以权重 1 被序列中的所有其他位置「全额调用」？这在并行计算上意味着什么？

教学注：(b) 是反类比的数学核心—— $\sum_i \alpha_{ij}$ 不等于 1，也没有任何固定约束；不同 Query 的 softmax 是各自独立计算的，列求和的值取决于所有 Query 对 Key j 的打分分布，可以是任意正数。

陷阱：

- 「行归一化」（每个 Query 的权重和为 1）和「列守恒」（每个 Key 被关注量之和固定）是两个独立的条件，softmax 只保证前者
- (d) 中「权重为 1」是理论极端，实际上 softmax 值总是在 $(0, 1)$ 之间，但可以任意接近 1

题 2【中·反例·「产能耗尽」假设的违反】

导读：如果供应链类比成立，则「某个位置被所有其他位置高度关注」时，该位置「产能耗尽」，其他位置对它的权重应当下降。这道题用数学推翻这一推论。

设序列长度 $n = 4$ ，position 2 是一个非常重要的 token（如句子主题词），其键向量 k_2 与其他位置的 Query 向量内积都很高： $q_1 \cdot k_2 = q_3 \cdot k_2 = q_4 \cdot k_2 = 10$ ，而其他键向量的内积都是 0。为简化，忽略 $\sqrt{d_k}$ 缩放。

(a) 计算 α_{12} (position 1 对 position 2 的注意力权重), 使用 $\exp(10)/(\exp(10) + 3\exp(0))$ (近似)。

(b) 计算 α_{32} 和 α_{42} 。

(c) 在供应链「产能耗尽」的逻辑下, position 1、3、4 都需要 position 2 的产能, 理应产生竞争, 使得每个的分配份额低于独占时的水平。验证: 如果只有 position 1 需要 position 2 ($n = 2, q_1 \cdot k_2 = 10, q_1 \cdot k_1 = 0$), α_{12} 是多少? 与 (a) 的结果比较, position 1 得到的份额是否因为「其他人竞争」而减少?

(d) 指出这里违反了供应链类比的哪条假设, 用一句话精确表述被违反的数学性质。

教学注: (c) 揭示了反直觉的事实: 即使多个 Query 都以最高分指向同一个 Key, 每个 Query 得到的注意力权重 (行归一化后) 并不因为「竞争者增多」而降低——因为每行 softmax 是独立计算的, 不同 Query 的权重之间没有任何耦合。

陷阱:

- (a) 中 $n = 4$, position 1 的 softmax 分母是 $\exp(10) + \exp(0) + \exp(0) + \exp(0)$ (对自身 position 1 的键向量内积 = 0, 以及 position 3、4 的键向量内积 = 0)
- 注意: 即使三个 Query 都以 $\alpha \approx 1$ 指向 position 2, position 2 的 v_2 可以被三个 Query 完整使用, 不会「折半」

题 3 【中·辨析·注意力头的功能: 设计 vs 涌现】

导读: 供应链有明确的优化目标 (成本、时效), 而注意力头的功能是反向传播在高维参数空间中塑造的——「功能由训练涌现」这条假设的被违反, 决定了供应链类比不能用来预测训练过程。

判断下列命题, 指出每条命题违反了注意力的哪条数学性质, 或与供应链类比的哪条假设冲突:

(a) 「通过检查第 3 个注意力头的参数矩阵 W_3^Q, W_3^K , 可以在训练前确定该头会专注于捕捉主谓关系。」

(b) 「若需要模型更关注句法结构, 可以增加专门处理句法的注意力头数量, 就像扩充专业供应链条数一样。」

(c) 「注意力头的功能随上下文而变化 (同一个头在不同句子中可能关注不同类型的依存关系), 因此机械可解释性对注意力头功能的「命名」(如「induction head」) 是不准确的。」

(d) 「如果某个注意力头在训练数据中从未见过特定的句法模式 (如罕见的并列从句), 则该头对这个模式的处理能力为零, 类似于供应链中没有采购过某类零件的供应商没有相关经验。」

教学注: (c) 是一个微妙的命题——机械可解释性确实发现了「induction head」这类功能相对稳定的头, 但它的「功能」是统计上的平均描述, 在不同上下文中会有变化。命题说「命名不准确」过于绝对, 准确说法是「命名是近似的统计描述, 不是确定的功能规定」。

陷阱:

- (a) 违反的不是「供应链」假设，而是「功能涌现性」——参数矩阵在训练前是随机的，功能由训练后的权重在数据分布下的统计行为决定，不可从参数值直接读出
- (b) 混淆了「增加头数」和「指定头功能」，即使头数增加，哪个头学到什么功能仍然由训练决定

题 4【重·数学推导·注意力是确定性线性函数，不是优化决策】

导读：供应链调度是一个带约束的优化问题（有目标函数、有决策变量）；注意力是给定 Q, K, V 后唯一确定的矩阵运算——这道题用数学确认这个差异。

(a) 写出单头注意力的完整前向传播公式 $O = f(Q, K, V)$ ，强调这是一个关于 Q, K, V 的**确定性函数**（没有随机性，没有优化步骤）。若 Q, K, V 固定， O 是否唯一确定？

(b) 供应链调度的目标是最小化成本或最大化效率，可以表示为约束优化： $\min_{\alpha} C(\alpha)$ s.t. $\sum_j \alpha_j = 1, \alpha_j \geq 0$ 。注意力公式是否有类似形式的优化目标函数？若有，写出；若无，说明「softmax 归一化」是否等价于求解某个优化问题。

(c) softmax 有一个等价的优化解释： $\text{softmax}(a) = \arg \max_{p \in \Delta} [\sum_j p_j a_j + H(p)]$ ，其中 $H(p) = -\sum_j p_j \log p_j$ 是熵。这个解释是否意味着注意力在每次前向传播时都在「做优化决策」？说明区别。

(d) 指出「注意力是确定性线性函数而非优化决策」这一事实，对「用供应链瓶颈分析预测注意力计算瓶颈」有什么直接的负面影响。

教学注：(c) 的 softmax 最优化解释是一个数学等价性（softmax 的输出恰好等于某个正则化线性规划的解），但这并不意味着前向传播「在做优化」——这个优化有闭合解（就是 softmax 公式本身），所以「求解」只需一次矩阵运算，不需要任何迭代或决策过程。

陷阱：

- (b) 中不要把「训练时的损失函数最优化」误解为「推理时注意力在做优化」——训练时确实在优化，但那是在调整参数 W^Q, W^K, W^V ，不是在推理时对每次注意力计算做优化
- (c) 的等价性只说明 softmax 可以被解读为「正则化最大期望得分」的解，但推理时执行的仍然是确定性的矩阵乘法，没有迭代优化过程

题 5【重·综合反类比·四条失效根源的总体评估】

导读：这道题要求对供应链类比四条失效根源（产能约束、语义目标、优化决策、可审计性）做整体评估，以及精确回答「供应链类比在什么条件下是安全的工具，在什么条件下必须放下」。

(a) 逐一指出供应链类比在以下四个「应用场景」中哪条假设被违反，以及违反的后果：

- **场景 1：**用「供应链中资源有限，所以越多 Query 关注某个 Key，每个 Query 得到

的份额越少」来理解注意力的竞争动态。

- **场景 2**：用「供应链中供应商专业化由经营战略决定」来理解为什么可以通过改变注意力头数来控制模型专注特定语言特征。
- **场景 3**：用「供应链调度员在不同候选方案中做权衡决策」来解释为什么 softmax 权重高的位置「对预测更重要」。
- **场景 4**：用「供应链审计追溯决策路径」来理解注意力权重热力图是对模型决策的忠实记录。

(b) 供应链类比最安全（不会产生系统性误导）的使用场景是什么？（给出具体的陈述，而非泛泛而谈。）

(c) 供应链类比必须放下的场景是什么？（对应四条失效根源，给出四个具体例子。）

(d) 写出一个比供应链更精确的类比，用来描述注意力机制的数学本质，并说明它在哪些维度比供应链类比更准确，在哪些维度仍然有局限。

教学注：(d) 的答案可以是 §3.6 中揭示的「关联记忆检索」类比：它在「内容寻址的软检索」这一数学结构上比供应链更准确，因为关联记忆本来就是连续的、无产能约束的、通过能量函数（而非优化决策）实现的检索。但关联记忆类比在「多头分工」和「量级直觉」上不如供应链类比直观。

陷阱：

- (b) 的「安全」不是「完全正确」，而是「不会产生可预测的系统性误判」——任何类比都有局限，关键是在有限用途内不产生误导
- (d) 中要求说明局限，不要只给出优点——任何类比都有边界，关联记忆类比的局限包括：它对多头的并行分工结构没有直觉，对 $Q \neq K \neq V$ 的三角色分离也没有直接对应

解答 §3.9

T-3.9.1 【softmax 归一化 ≠ 资源守恒】

(a) 行归一化： $\sum_j \alpha_{ij} = \sum_j \frac{\exp(q_i \cdot k_j / \sqrt{d_k})}{\sum_l \exp(q_i \cdot k_l / \sqrt{d_k})} = \frac{\sum_j \exp(q_i \cdot k_j / \sqrt{d_k})}{\sum_l \exp(q_i \cdot k_l / \sqrt{d_k})} = 1 \checkmark$ 。这对应供应链中「每个需求方分配的订单总比例为 1」——但这是**需求方侧**的约束，不是供应方侧的约束。

(b) 列求和： $\sum_i \alpha_{ij} = \sum_i \frac{\exp(q_i \cdot k_j / \sqrt{d_k})}{\sum_l \exp(q_i \cdot k_l / \sqrt{d_k})}$ ，分子分母都与 i 有关，每行的分母不同，无法化简为固定值。一般地， $\sum_i \alpha_{ij} \neq 1$ ，也没有任何固定约束，取决于所有行的打分分布。

(c) 不成立。注意力中「列守恒」不存在： $\sum_i \alpha_{ij}$ 没有固定上界，Key j 可以在所有 Query 中都以很高的权重被选中，列求和可以远大于 1。违反的供应链假设：**产能守恒**（供应商的总供给量有限，分给一方多则分给另一方少）在注意力中完全不适用。

(d) 同一个 v_j 在理论上可以同时以权重趋近于 1 被序列中所有其他 $n - 1$ 个位置「全额调用」（当 k_j 与所有 q_i 的内积远高于其他键时）。并行计算意义：不同 Query 的注意力输出 y_i 之间没有任何资源争抢关系，可以完全并行计算——这正是注意力可并行的数学根源（而不是因为「产能充足」，而是因为根本就没有产能概念）。

T-3.9.2 【「产能耗尽」假设的违反】

(a) $\alpha_{12} = \exp(10)/(\exp(10) + \exp(0) + \exp(0) + \exp(0)) = e^{10}/(e^{10} + 3) \approx 22026/(22026 + 3) \approx 0.9999$ (非常接近 1)。

(b) α_{32} 的计算: position 3 的 Query 也有 $q_3 \cdot k_2 = 10$, 其他 Key 内积为 0。同样地, $\alpha_{32} = e^{10}/(e^{10} + 3) \approx 0.9999$ 。 α_{42} 同理 ≈ 0.9999 。

(c) 若只有 position 1 ($n = 2$, $q_1 \cdot k_2 = 10$, $q_1 \cdot k_1 = 0$): $\alpha_{12} = e^{10}/(e^{10} + e^0) = e^{10}/(e^{10} + 1) \approx 22026/22027 \approx 0.99995$ 。比 (a) 的 0.9999 几乎没有差别 (从 0.99995 降到 0.9999, 差了 5×10^{-5})。position 1 得到的份额几乎不因「竞争者增多」而减少——三个 Query 共同高度关注 position 2, 每个 Query 得到的注意力权重仍然接近 1。

(d) 被违反的假设: Value 向量无产能约束, softmax 归一化是行归一化 (统计归一化), 不是资源守恒 (物理约束)。数学精确表述: v_j 可以被任意多个 Query 以任意高的权重调用, 不存在「列约束」 $\sum_i \alpha_{ij} \leq 1$ 。

T-3.9.3 【注意力头功能: 设计 vs 涌现】

(a) 命题假。违反: 功能涌现性。参数矩阵 W_3^Q, W_3^K 在训练前是随机初始化的, 没有任何先验语义含义; 头的功能 (是否专注主谓关系) 是在训练后通过梯度下降在大量数据上形成的统计属性, 无法从初始参数读出, 也无法在训练前预测。

(b) 命题假 (在机制层面)。违反: 功能由训练涌现, 不是由设计规定。增加专门处理句法的头并不能「指定」它处理句法——新增的头同样由梯度驱动, 最终的功能由损失函数和数据分布决定。正确做法是加入辅助句法标注损失, 但这与「增加头数」不同。

(c) 命题过于绝对 (不完全正确)。机械可解释性 (如 Elhage et al. 2021 对 induction head 的研究) 确实发现了在不同上下文中功能相当稳定的头——「induction head」在各种输入下都表现出「复制前面出现过的模式」的行为。命题应修正为: 「注意力头的功能是上下文相关的统计描述, 在大多数场景下有一致的主导功能, 但不如供应链的职责规定那样绝对固定」。

(d) 命题部分正确 (类比有效, 但机制有差异)。模型确实无法在训练分布之外泛化 (类似供应商没有经验), 这部分类比合理。但差异在于: 注意力参数是连续的实数矩阵, 对「相近但未见过的」模式有一定泛化 (通过嵌入空间的连续性), 而供应链供应商没有相关经验通常意味着「完全无法提供」, 是离散的有/无。

T-3.9.4 【注意力是确定性线性函数】

(a) 完整公式: $O = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$, 其中 Q, K, V 固定后, 每一步 (矩阵乘法、softmax、再矩阵乘法) 都是确定性操作, O 唯一确定。没有随机性 (训练时的 dropout 除外, 但推理时关闭), 没有迭代, 没有决策变量——给定输入, 输出唯一。

(b) 注意力没有类似供应链的优化目标函数。softmax 归一化是一个固定的非线性函数

操作，不是在求解约束优化问题。（训练时存在优化： $\min_{\theta} \mathcal{L}$ ，调整 W^Q, W^K, W^V ；但这是参数的训练优化，不是推理时对每次注意力计算的优化。）

(c) (c) 的等价性是数学上的「解释」，不是计算过程的「等价执行」。 $\arg \max_{p \in \Delta} [\sum_j p_j a_j + H(p)]$ 这个优化问题有解析解（就是 softmax），所以「求解」只需一次矩阵运算，不需要任何迭代。推理时执行的就是 exp 和归一化这两个矩阵操作，不涉及任何决策。区别：供应链的优化需要决策过程（权衡多个方案），注意力只是执行一个固定的函数映射。

(d) 「供应链瓶颈分析」的核心是：找到约束最紧的环节（产能不足的供应商），放松该约束能改善整体性能。这个框架假设「系统有资源约束，不同需求方在争抢有限资源」。注意力没有资源约束，「哪个 Key 被关注最多」完全不是计算瓶颈——真正的瓶颈是 $O(n^2)$ 的 FLOPs 和 HBM 带宽（见 §3.3、§3.5），这些是硬件资源约束，与「哪个位置被关注多少次」无关。用供应链瓶颈分析预测注意力瓶颈会完全找错方向。

T-3.9.5 【四条失效根源的总体评估】

(a)

- **场景 1**（「资源有限 → 竞争减少份额」）：违反**产能约束假设**。注意力没有列约束，Position j 的 Value 被多个 Query 高分关注时，每个 Query 得到的权重几乎不变（如题 2 所示）。误导后果：误以为注意力有「拥挤效应」，会在某个位置被频繁访问时导致信息传输质量下降——实际上没有。
- **场景 2**（「供应商专业化由战略决定 → 增加头数控制特征」）：违反**功能涌现性假设**。头的功能由训练涌现，增加头数不能预先规定哪个头学什么功能。误导后果：误以为可以通过架构设计直接控制语言特征的处理，绕过训练过程——实际上必须通过辅助损失或数据干预。
- **场景 3**（「调度员权衡决策 → softmax 权重高 = 对预测更重要」）：违反**确定性线性函数假设**（同时违反 §3.7 的「权重 ≠ 解释」）。softmax 是确定性操作，没有决策或权衡；权重高只是 Value 向量线性组合的比例，不等于因果重要性。误导后果：注意力权重被当作可解释的决策依据，产生热力图误读（§3.7 的全部问题）。
- **场景 4**（「供应链审计 → 注意力热力图忠实记录决策路径」）：违反**可审计性假设**（权重不等于解释）。注意力权重不是因果路径的忠实记录，而是一个中间量，无法单独作为解释。误导后果：基于注意力热力图做错误的模型行为解释和信任评估。

(b) 供应链类比最安全的场景：**描述注意力机制的三角逻辑结构**（Q 发出检索请求，K 提供匹配标签，V 提供实际内容）和**多头并行处理不同语义维度的直觉**，以及**帮助建立单次前向传播完成的「全局询价」次数的量级感受**（ $n \times n \times h$ 的规模直觉）。在这两个用途上，供应链类比不会产生系统性误判。

(c) 四个必须放下的场景：1. **分析注意力的「竞争动态」**（产能约束失效）——注意力没有竞争，任何「Key 被抢占」的推论都是错误的；2. **预测训练过程中头的专业化机制**（功能涌现失效）——不能用「供应商选择专业方向」来类比梯度如何塑造头的功能；3. **用 softmax 权重分析模型的预测原因**（优化决策失效 + 可审计性失效）——注意力是线性函数，权重不是决策，热力图不是解释；4. **预测注意力的计算瓶颈**（优化/约束

框架失效)——注意力的瓶颈是 $O(n^2)$ 的 FLOPs 和 HBM 带宽,不是任何「资源有限的供应商」。

(d) 更精确的类比: **关联记忆检索** (现代 Hopfield 网络)。更准确的维度: ① 无产能约束 (关联记忆本来就是无限次可检索的); ② 通过相似度 (内积) 做软检索而非离散决策,与 softmax 的数学形式精确对应; ③ 指数容量的概念解释了参数规模与知识存储能力的关系。仍然有局限: ① 关联记忆框架对「三角色分离 (Q/K/V 独立投影)」没有直接对应——Hopfield 中 $K = V$; ② 对「多头并行在不同子空间做检索」的量级直觉不如供应链直观; ③ 无法解释多层 Transformer 中 FFN 等非注意力组件的作用。

§ 3.9 小结: 供应链类比的四条失效根源——产能约束 (Value 无守恒)、功能涌现 (头的职责不可预设)、确定性变换 (softmax 不是优化决策)、不可审计 (权重不等于因果路径)——共同揭示了注意力机制的真实数学本质: 无约束的相似度加权线性变换,功能由训练塑造,可计算但不可直接因果解读。好的类比帮助建立直觉,坏的类比固化误解; 供应链类比的值在于量级感知和三角色结构,代价是四个可预测的系统性误判风险。知道何时放下类比,和知道何时使用类比,同样重要。

第4章 · 优化与损失景观

§4.4 习题：损失景观的可视化

导读：本节核心是「损失景观的几何决定泛化能力」——filter-wise 归一化消除尺度干扰、Hessian 最大特征值量化平坦度、大小 batch 分别对应尖锐/平坦极小值、skip connection 使景观更平滑、SAM 优化器显式搜索平坦区域。五题分别对应：A（归一化推导）、B（泛化上界计算）、C（批量大小辨析）、D（skip connection 机制分析）、E（SAM 优化评判）。

题1【轻 · 轻推导 · 归一化为何不可缺】

导读：可视化损失景观时，随机方向向量若不归一化，两条方向射线的「步长」在不同层间会因权重矩阵范数量级的巨大差异而失去可比性，最终扭曲等高线图。

设网络第 l 层第 k 个 filter 的权重为 $W^{(l,k)} \in \mathbb{R}^{c_{in} \times k_h \times k_w}$ ，filter-wise 归一化将随机方向向量 $d^{(l,k)}$ 缩放为

$$\tilde{d}^{(l,k)} = d^{(l,k)} \cdot \frac{\|W^{(l,k)}\|_F}{\|d^{(l,k)}\|_F}$$

(1) 证明归一化后 $\|\tilde{d}^{(l,k)}\|_F = \|W^{(l,k)}\|_F$ 。

(2) 设某层有两个 filter， $\|W^{(l,1)}\|_F = 0.1$ ， $\|W^{(l,2)}\|_F = 10$ ，随机向量未归一化时设 $\|d^{(l,1)}\|_F = \|d^{(l,2)}\|_F = 1$ 。若将景观可视化步长 α 统一取 1，两个 filter 对应的实际参数扰动幅度分别是 $\alpha/\|W^{(l,1)}\|_F$ 和 $\alpha/\|W^{(l,2)}\|_F$ 的倍数关系是多少？归一化后这一比例变为多少？

教学注：filter-wise 是粒度选择的折中——过粗（layer-wise）遗漏层内结构差异，过细（element-wise）引入额外统计噪声。

陷阱：归一化后方向向量 $\tilde{d}^{(l,k)}$ 不再相互正交，但可视化所需的仅是「单步扰动幅度可比」，正交性不是必要条件。

题2【中 · 中计算 · 泛化上界与平坦度】

导读：Keskar 等人（2016）建立了极小值处 Hessian 最大特征值 $\lambda_{\max}$ 与泛化间隙之间的定量联系，使「尖锐极小值泛化差」从直觉变为可量化命题。

设泛化上界为

$$R(\theta) \leq \hat{R}(\theta) + C \sqrt{\frac{\lambda_{\max} \cdot n}{N}}$$

其中 C 为数值常数， n 为模型参数量， N 为训练样本数。考虑以下两个场景：

· **模型 A**（大 batch 训练）： $\lambda_{\max}^A = 800$ ， $n = 10^7$ ， $N = 10^6$

· **模型 B** (小 batch 训练): $\lambda_{\max}^B = 50$, $n = 10^7$, $N = 10^6$

- (1) 计算两个模型泛化上界中的根号项 (精确到四位小数)。
- (2) 假设两个模型训练损失相同 $\hat{R} = 0.1$, $C = 0.01$, 计算各自泛化上界的数值。
- (3) 解释为什么大 batch 倾向于收敛到 $\lambda_{\max}$ 较大的极小值, 从梯度噪声的角度给出直观论证。

教学注: 此上界是 PAC-Bayes 框架的一个推论, $\lambda_{\max}$ 刻画了损失曲面在极小值处的「曲率」, 曲率越大意味着参数对扰动越敏感, 泛化风险越高。

陷阱: $\lambda_{\max}$ 只是充分统计量的一个代理, 实践中全谱信息 (如迹 $\text{tr}(H)$) 对泛化的预测力有时更强。不要将此上界解读为泛化误差的精确估计。

题 3 【中 · 概念辨析 · 批量大小与景观几何】

导读: 批量大小是现代深度学习中最具争议的超参数之一; 理解其与景观几何的关系, 需要区分「优化轨迹」与「收敛目标」两个层次。

判断以下四条陈述, 逐一说明正确/错误及原因:

- (a) 大 batch 梯度方差小, 因此估计更准确, 应总能找到更好的极小值。
- (b) 小 batch 引入的随机性使优化器能够「跳出」尖锐极小值盆地, 倾向于停在 $\lambda_{\max}$ 较小的平坦极小值。
- (c) 对同一损失景观, 大 batch 和小 batch 最终收敛到的极小值集合完全相同, 只是收敛速度不同。
- (d) 线性缩放规则 (将 batch 增大 k 倍同时将学习率增大 k 倍) 能在任意训练阶段保持等效性。

教学注: (b) 对应 Chaudhari & Soatto (2018) 的熵 SGD 分析——小 batch 的随机性等效于一个隐式的景观平滑化过程, 使优化器偏好高熵 (平坦) 区域。

陷阱: (d) 的线性缩放规则在训练初期 (loss 下降剧烈阶段) 和 warmup 期间容易失效, 不能机械套用。

题 4 【中 · 中计算 · Skip Connection 的平滑效应】

导读: Li 等人 (2018) 用 filter-wise 归一化直观展示了 skip connection 对损失景观的平滑作用, 但其数学根源可以追溯到梯度传播的谱性质。

设 L 层残差网络的前向传播为 $h_l = h_{l-1} + F_l(h_{l-1})$, 其中 F_l 表示第 l 层的残差函数。

- (1) 写出损失 $\mathcal{L}$ 对 h_0 的梯度 (用 Jacobian 矩阵乘积形式表示), 展示 skip connection 如何在反向传播中引入恒等通路。
- (2) 设每个残差块的 Jacobian 谱半径为 $\rho(J_{F_l}) = r < 1$ (残差部分收缩)。证明 L 层残差网络的梯度范数有下界 $\|\partial \mathcal{L} / \partial h_0\| \geq (1 - r)^L \|\partial \mathcal{L} / \partial h_L\|$, 并说明这如何防止梯度消失。

(3) 定性解释为什么 skip connection 使 Hessian 最大特征值 $\lambda_{\max}$ 更小, 景观更平坦。(2-3 句即可)

教学注: skip connection 的本质是「恒等映射提供梯度高速公路」, 使信息在前向和后向均能以 $O(1)$ 的衰减穿越深网络, 这正是 ResNet 击败 VGG 的核心数学原因。

陷阱: (2) 的下界只在 $\|J_{F_l}\|$ 的谱半径而非算子范数意义下成立, 两者在高维下可相差悬殊。

题 5 【重 · 重评判 · SAM 的代价与收益】

导读: Sharpness-Aware Minimization (SAM) 通过显式优化「最坏邻域内的损失」来搜索平坦极小值, 是将景观几何分析转化为可运行算法的代表性工作, 但其代价常被忽视。

SAM 求解的问题为

$$\min_{\theta} \max_{\|\epsilon\|_2 \leq \rho} \mathcal{L}(\theta + \epsilon)$$

(1) 证明内层最大化问题的最优解为 $\epsilon^* = \rho \cdot \nabla_{\theta} \mathcal{L}(\theta) / \|\nabla_{\theta} \mathcal{L}(\theta)\|_2$ (在一阶线性近似下)。

(2) SAM 的每步更新需要两次前向-反向传播。与标准 SGD 相比, 设每次前后向计算耗时 T , 若训练 S 步, SAM 的总计算量是 SGD 的多少倍?

(3) 判断以下论断并给出理由:

「SAM 找到的极小值满足 $\lambda_{\max}$ 更小, 因此其泛化误差必然低于 SGD 训练的同等模型。」

指出该论断的两处不严谨之处。

(4) **拓展:** 在资源受限 (只能训练标准 SGD 的一半步数) 的情况下, 是否应将 SAM 替换为多训练一倍步数的 SGD? 从景观平坦度的角度讨论。

教学注: SAM 的正则化效果在理论上等价于向损失函数加入一个关于梯度范数的惩罚项, 这与权重衰减 (weight decay) 有微妙的互补关系。

陷阱: (1) 的 ℓ_2 约束下结论干净, 但实践中 SAM 也有 ℓ_{∞} 变体, 最优解形式截然不同。(3) 中「必然」是关键词——泛化上界只是上界, 不是精确等式。

解答 § 4.4

T-4.4.1 【归一化为何不可缺】

(1) 证明:

$$\|\tilde{d}^{(l,k)}\|_F = \left\| d^{(l,k)} \cdot \frac{\|W^{(l,k)}\|_F}{\|d^{(l,k)}\|_F} \right\|_F = \|d^{(l,k)}\|_F \cdot \frac{\|W^{(l,k)}\|_F}{\|d^{(l,k)}\|_F} = \|W^{(l,k)}\|_F \quad \blacksquare$$

(2) 数值分析：

未归一化时， $\|d^{(l,1)}\|_F = \|d^{(l,2)}\|_F = 1$ ，步长 $\alpha = 1$ 时：- filter 1 的扰动为参数范数的 $1/0.1 = 10$ 倍 - filter 2 的扰动为参数范数的 $1/10 = 0.1$ 倍 - 比例 = $10/0.1 = 100$ 倍

归一化后： $\|\tilde{d}^{(l,1)}\|_F = 0.1$ ， $\|\tilde{d}^{(l,2)}\|_F = 10$ ，步长 $\alpha = 1$ 时，两个 filter 的扰动均恰好等于各自的参数范数，比例 = 1。

Sanity check： 归一化消除了「量纲不一致」，使不同层、不同 filter 的等高线可以在同一坐标系下公平比较。

T-4.4.2 【泛化上界与平坦度】**(1) 根号项计算：**

$$\sqrt{\frac{\lambda_{\max}^A \cdot n}{N}} = \sqrt{\frac{800 \times 10^7}{10^6}} = \sqrt{8000} \approx 89.4427$$

$$\sqrt{\frac{\lambda_{\max}^B \cdot n}{N}} = \sqrt{\frac{50 \times 10^7}{10^6}} = \sqrt{500} \approx 22.3607$$

(2) 泛化上界 ($C = 0.01$, $\hat{R} = 0.1$):

- 模型 A: $0.1 + 0.01 \times 89.4427 = 0.1 + 0.8944 = \mathbf{0.9944}$
- 模型 B: $0.1 + 0.01 \times 22.3607 = 0.1 + 0.2236 = \mathbf{0.3236}$

(3) 大 batch 与尖锐极小值： 大 batch 梯度估计方差小，优化轨迹光滑，缺乏足够的随机扰动来「翻越」分隔尖锐极小值与平坦极小值之间的能量势垒；小 batch 的随机噪声充当了隐式的「热浴」，使优化器能够逃离曲率高的区域并停留在更宽广的盆地中。

Sanity check： 两个模型 $\lambda_{\max}$ 相差 16 倍，泛化上界差约 3 倍，体现了景观曲率的平方根效应。

T-4.4.3 【批量大小与景观几何】

(a) **错误。** 梯度估计准确度与极小值质量是两回事。大 batch 精确梯度会将优化器「锁定」在最近的尖锐极小值而无法逃脱；「更准确」并不意味着「更好的收敛目标」。

(b) **正确。** 小 batch 梯度噪声的协方差矩阵与 Hessian 成正比（Fisher 信息视角），等效于对景观施加各向异性扰动，天然偏好熵较高（宽广）的极小值盆地。

(c) **错误。** 大量实验（Keskar et al., 2017）和理论分析（Chaudhari & Soatto, 2018）表明，批量大小不同的 SGD 最终收敛到**不同的极小值子集**，而非相同集合。

(d) **部分错误。** 线性缩放规则在训练中期（梯度分布近似平稳）时成立，但在 warmup 阶段和训练末期 loss 剧烈振荡时失效；Goyal 等人（2017）的工作特别指出需要 warmup 过渡。

T-4.4.4 【Skip Connection 的平滑效应】

(1) 梯度表达式：

$$\frac{\partial \mathcal{L}}{\partial h_0} = \frac{\partial \mathcal{L}}{\partial h_L} \cdot \prod_{l=1}^L \frac{\partial h_l}{\partial h_{l-1}} = \frac{\partial \mathcal{L}}{\partial h_L} \cdot \prod_{l=1}^L (I + J_{F_l})$$

其中 $J_{F_l} = \partial F_l / \partial h_{l-1}$ 。展开乘积时，恒等矩阵 I 提供了一条不经过任何残差块 Jacobian 的直接通路。

(2) 梯度范数下界：

$$\left\| \frac{\partial \mathcal{L}}{\partial h_0} \right\| = \left\| \frac{\partial \mathcal{L}}{\partial h_L} \right\| \cdot \left\| \prod_{l=1}^L (I + J_{F_l}) \right\|$$

由于 $\|I + J_{F_l}\| \geq \|I\| - \|J_{F_l}\| \geq 1 - r$ (三角不等式)，故

$$\left\| \frac{\partial \mathcal{L}}{\partial h_0} \right\| \geq (1 - r)^L \left\| \frac{\partial \mathcal{L}}{\partial h_L} \right\|$$

当 $r < 1$ 时，下界 $(1 - r)^L > 0$ ，梯度不会指数衰减至零，防止了梯度消失。■

(3) 对 $\lambda_{\max}$ 的影响：skip connection 使 Hessian 中出现大量来自恒等通路的「平坦贡献」，稀释了残差分支引入的高曲率方向；同时，恒等映射使各层激活在相近尺度，避免了因激活值爆炸/消失而产生的病态曲率集中现象，整体上压低了 $\lambda_{\max}$ 。

Sanity check: Li et al. (2018) 的可视化图表中，56 层 ResNet 的损失景观明显比 56 层 VGG 平坦，与上述分析一致。

T-4.4.5 【SAM 的代价与收益】

(1) 内层最大化的最优解：

在一阶线性近似下， $\mathcal{L}(\theta + \epsilon) \approx \mathcal{L}(\theta) + \nabla_{\theta} \mathcal{L}(\theta)^{\top} \epsilon$ 。

约束 $\|\epsilon\|_2 \leq \rho$ 下，最大化线性函数的最优解由 Cauchy-Schwarz 不等式决定：当 ϵ 与梯度同向且达到约束边界时取最大值：

$$\epsilon^* = \rho \cdot \frac{\nabla_{\theta} \mathcal{L}(\theta)}{\|\nabla_{\theta} \mathcal{L}(\theta)\|_2} \quad \blacksquare$$

(2) 计算量对比：

SAM 每步需两次前后向传播（第一次求 ϵ^* ，第二次在 $\theta + \epsilon^*$ 处求梯度），耗时 $2T$ ；SGD 每步耗时 T 。训练 S 步时，SAM 总耗时 $2ST$ ，SGD 为 ST ，SAM 是 SGD 的 2 倍。

(3) 论断的两处不严谨：

- **不严谨之处一：**泛化上界中的 $\sqrt{\lambda_{\max} \cdot n/N}$ 只是上界，不是等式。SAM 找到 $\lambda_{\max}$ 更小的极小值只意味着上界更紧，不能保证实际泛化误差更低。

- **不严谨之处二**：「同等模型」的假设忽略了训练轮次的差异——SAM 若因计算翻倍而只能训练一半步数，优化本身未收敛时， $\lambda_{\max}$ 小也无法弥补训练不足的缺陷。

(4) 拓展讨论：在资源受限场景下，若训练步数减半，SAM 的景观平坦化效益可能被优化不充分所抵消。实践经验表明，当任务对泛化高度敏感（如小数据集微调）时，SAM 的优势更显著；当任务在充足数据下早已收敛时，多训练一倍步数的 SGD 可能更优。因此结论取决于数据量与任务性质，无普适答案。

Sanity check：(1) 的推导与梯度投影算子的标准结论一致；(2) 的 2 倍计算量是 SAM 论文中明确指出的实践代价。

本节景观几何的定量工具将在 § 4.7 中发展为宽度缩放规律——平坦度指标 $\lambda_{\max}$ 的控制问题将推广为对激活动力学在不同网络宽度下行为的系统分析。

§4.7 习题： μP 的完整面貌

导读：本节核心是「超参数迁移的数学基础」——abc 参数化将宽度 n 的幂次编码进初始化方差与学习率，激活稳定性约束 $a + b = 1$ 是超参数可迁移的充要条件， μP 是满足该约束且保持特征学习的唯一参数化（在 Adam 优化器下）。五题分别对应：A（abc 约束推导）、B（SP vs μP 数值对比）、C（NTK 极限辨析）、D（Tensor Program 统一视角计算题）、E（超参数迁移评判）。

题 1【轻 · 轻推导 · abc 约束的来源】

导读：abc 参数化的核心洞见是：网络宽度 n 增大时，初始化、学习率和输出缩放必须协调变化，才能使隐藏层激活的更新量 Δh 保持 $O(1)$ ——既不爆炸也不冻结。

设隐藏层权重 $W = n^{-a}\tilde{W}$ （ $\tilde{W}$ 元素方差 $O(1)$ ），Adam 优化器的等效学习率为 $\eta = n^{-b}\tilde{\eta}$ 。

- (1) 设输入维度为 n ，权重矩阵 $W \in \mathbb{R}^{n \times n}$ ，输入向量 $x \in \mathbb{R}^n$ （范数 $O(1)$ ）。计算前向激活 $h = Wx$ 的典型量级（用 n 和 a 表示）。
- (2) 在 Adam 优化器下，参数更新量 ΔW 的量级为 $O(n^{-b})$ （Adam 自适应步长归一化掉了梯度的量级）。推导 $\Delta h = (\Delta W)x$ 的量级，并由 $\Delta h = O(1)$ 推出约束 $a + b = 1$ 。
- (3) 验证：Standard Parameterization（SP）取 $a = 1/2, b = 0$ ，计算 $a + b$ 并说明 SP + Adam 的问题。

教学注：约束 $a + b = 1$ 是一个「刀刃」条件—— $a + b < 1$ 时激活更新随 n 发散， $a + b > 1$ 时激活冻结退化为核方法（NTK 极限）。

陷阱：Adam 的自适应步长与 SGD 不同——SGD 下梯度量级 $O(n^{-a})$ ，Adam 将其归一化为 $O(1)$ ，因此相同的约束在 SGD 和 Adam 下对应不同的 a, b 值。

题 2【中 · 中计算 · SP 与 μP 的宽度缩放数值】

导读：这是一道需要具体数字的计算题，检验对 abc 参数化中宽度缩放效应的掌握程度。理论上 SP + Adam 的激活更新量随宽度以 $\sqrt{n}$ 增长， μP 则保持不变——下面用具体数值验证。

考虑从宽度 $n_1 = 256$ 到 $n_2 = 4096$ 的模型缩放（宽度比 $n_2/n_1 = 16$ ），Adam 优化器，隐藏层。

- (1) **SP 的问题：**SP 取 $a = 1/2, b = 0$ ，计算 $a + b = ?$ ，激活更新量 $\Delta h \propto n^{-(a+b)} \cdot n^{1/2} = n^{1/2-(a+b)}$ （见题 1 推导），计算 Δh 随宽度的缩放指数。宽度从 256 增至 4096 时， Δh 放大因子精确到四位小数。
- (2) **μP 的稳定性：** μP 取 $a = 1, b = 0$ （Adam 下隐藏层），计算 $a + b = ?$ ，验证 $\Delta h = O(1)$ 不随宽度变化，计算宽度比 16 时 Δh 的放大因子。
- (3) μP 缩放表中，输出层学习率缩放为 $O(1/n)$ ，而隐藏层为 $O(1)$ 。解释为什么输出层需要额外的 $1/n$ 缩放（从输出激活量级角度论证）。

教学注： μP 的超参数迁移实验 (Yang et al., 2022) 表明，在小模型 ($n_1 = 256$) 上调好的学习率可以直接迁移到 $n_2 = 4096$ 的大模型，验证了 $\Delta h = O(1)$ 的理论预测。

陷阱：宽度缩放因子 $\sqrt{n_2/n_1} = \sqrt{16} = 4$ ，注意是比值的平方根而非比值本身。

题 3 【中 · 概念辨析 · NTK 极限与特征学习】

导读：NTK (Neural Tangent Kernel, 神经切线核) 极限是另一个著名的参数化极限，但它在宽度无穷大时退化为核方法，无法进行特征学习——这正是 μP 需要避开的失效模式。

(1) NTK 参数化取 $a = 1/2, b = 1/2$ (SGD)，计算 $a + b$ ，说明激活更新量 Δh 的宽度缩放行为。

(2) 「NTK 极限下网络退化为核方法」的含义是什么？用激活动力学语言解释（不需要写出核函数的表达式，2-3 句即可）。

(3) 判断以下论断：

「 μP 在宽度趋无穷时收敛到某个固定极限 (Mean Field 极限)，因此也是一种核方法。」

该论断正确吗？ μP 的无穷宽极限与 NTK 极限的本质区别是什么？

(4) 完成以下表格（填写 a 、 b 、 $a + b$ 、 Δh 量级、是否特征学习）：

参数化	a	b (Adam)	$a + b$	Δh	特征学习
SP	1/2	0	?	?	?
NTK	1/2	1/2	?	?	?
μP	1	0	?	?	?

教学注：特征学习 (feature learning) 指隐藏层激活在训练过程中有 $O(1)$ 幅度的实质变化，使网络能够学习数据驱动的表达；NTK 极限下激活几乎不动，相当于用随机初始化的特征做核回归。

陷阱：NTK 极限和 μP 极限都是「宽度趋无穷」下的极限，但对应的动力学截然不同——不要因为都是无穷宽极限就混淆两者。

题 4 【重 · Tensor Program 统一视角计算题 · 宽度迁移的数值验证】

导读：Tensor Programs (Yang, 2021–2023) 提供了一套统一的形式化语言来分析任意参数化下网络宽度趋无穷的行为。本题从 Tensor Program 视角出发，通过具体数值计算验证 μP 的超参数迁移性质。

设两层 MLP (隐藏宽度 n)， μP 下隐藏层初始权重 $W_1 \sim \mathcal{N}(0, 1/n \cdot I)$ ，输出层权重 $W_2 \sim \mathcal{N}(0, 1/n^2 \cdot I)$ ，输出缩放因子 $1/n$ ，Adam 学习率 η (不依赖 n)。

子问题 A (前向传播量级)： - 设输入 $x \in \mathbb{R}^n$ ， $\|x\|_2 = 1$ ，隐藏层激活 $h = \sigma(W_1 x)$ ， σ

为 ReLU。- 计算 $\mathbb{E}[\|h\|_2^2]$ (用 n 表示, 精确到常数因子)。- 设 $n_1 = 64$, $n_2 = 1024$, 两者的 $\mathbb{E}[\|h\|_2^2]$ 之比精确到四位小数。

子问题 B (一步 Adam 更新后的激活变化): - 设经过一步 Adam 更新后 W_1 的变化量元素级别为 $O(\eta/n^{1/2})$ (初始化量级 $1/\sqrt{n}$, Adam 归一化后步长 η , 修正量级 $\eta \cdot n^{-1/2}$), 计算 $\|\Delta h\| = \|(\Delta W_1)x\|$ (用 n 和 η 表示)。- 验证 $\Delta h = O(\eta)$, 即不依赖 n 。设 $\eta = 0.01$, 计算 $n = 64$ 和 $n = 1024$ 时 $\|\Delta h\|$ 的数值比 (精确到四位小数)。

子问题 C (Tensor Program 视角的意义): - Tensor Programs 的核心定理表明: 在 μP 下, 网络输出关于参数的梯度在 $n \rightarrow \infty$ 时有非平凡极限 (不趋零也不发散)。- 解释这意味着什么: 为什么「梯度在无穷宽极限下稳定」是超参数迁移的前提条件? (3-4 句)

教学注: Tensor Program 是目前唯一能严格证明 μP 超参数迁移性质的数学框架, 其核心技术是追踪网络宽度 n 趋无穷时各层激活和梯度的联合分布收敛性。

陷阱: 子问题 B 中 Adam 更新量 $O(\eta/\sqrt{n})$ 来自初始化尺度 $1/\sqrt{n}$ 与 Adam 归一化的组合, 不要误用 SP 下的更新量级 $O(\eta)$ 。

题 5 【重 · 重评判 · 超参数迁移的边界条件】

导读: μP 的超参数迁移是 2022-2024 年大模型训练的重要工程工具, 但它有明确的适用前提; 错误地推广这些条件会导致实践失效。

判断以下五条论断, 给出理由:

- (a) 「 μP 保证了学习率可以从宽度 $n_1 = 256$ 完美迁移到 $n_2 = 10^6$, 无需任何验证实验。」
- (b) 「 μP 只解决了宽度缩放问题, 对深度缩放 (层数增加) 不提供保证。」
- (c) 「在 μP 下, Batch Normalization 层的存在不影响超参数迁移性质。」
- (d) 「 μP 的激活稳定性约束 $a + b = 1$ 在 Adam 和 SGD 下适用相同的 (a, b) 取值。」
- (e) 「 μP 是目前唯一能实现超参数迁移的参数化方案; 其他方案 (如 NTK 参数化) 在原则上不可能实现迁移。」

教学注: (b) 指向了 μP 研究的活跃前沿——Yang et al. (2023) 的后续工作 μP for depth (又称 Depth- μP) 尝试将同样的框架推广到深度方向, 但理论尚未完全成熟。

陷阱: (c) 中 BatchNorm 会通过均值/方差归一化改变激活量级, 与 μP 的假设 (原始激活 $O(1)$) 可能冲突, 需要仔细分析。

解答 § 4.7

T-4.7.1 【abc 约束的来源】

(1) 前向激活量级:

$$h = Wx, \quad W \in \mathbb{R}^{n \times n}, \quad W_{ij} \sim \mathcal{N}(0, n^{-2a})$$

$$\mathbb{E}[h_i^2] = \sum_{j=1}^n W_{ij}^2 x_j^2 \approx n \cdot n^{-2a} \cdot \frac{1}{n} = n^{-2a}$$

故 $\|h\|_2 \sim n^{1/2} \cdot n^{-a} = n^{1/2-a}$ 。

(2) 激活更新量与约束推导：

Adam 下更新量元素量级 $\Delta W_{ij} \sim \eta = n^{-b}$ (Adam 归一化后步长与梯度幅度无关)。

$$\Delta h_i = \sum_j (\Delta W_{ij}) x_j \sim n \cdot n^{-b} \cdot n^{-1} = n^{-b}$$

(输入 $x_j \sim n^{-1/2}$, n 项求和, 合并为 $n \cdot n^{-b} \cdot n^{-1/2} = n^{1/2-b}$ 。)

修正: $\Delta h \sim n^{1/2-b}$, 要求 $\Delta h = O(1)$ 即 $1/2 - b = 0 \dots$ 但这是对 b 的约束, 还需结合初始化。

完整推导: $\Delta h_i = \sum_j (\Delta W_{ij}) x_j$, 其中 $\Delta W_{ij} \sim n^{-b}$, x_j 是 $O(1)$ 范数的输入 ($x_j \sim n^{-1/2}$), $\Delta h_i \sim \sqrt{n} \cdot n^{-b} \cdot n^{-1/2} = n^{-b}$ 。

另一方面, 有效更新量还依赖于权重的当前尺度——每个权重元素 $W_{ij} \sim n^{-a}$, Adam 步长在量级上为 $\eta/\hat{v}^{1/2} \sim n^{-b}/n^{-a} = n^{a-b}$, 所以实际参数更新量级为 $n^{a-b} \times n^{-a} = n^{-b}$ (两者一致)。

$\Delta h = O(n^{1/2-b}) \cdot O(1)$ 的完整表达式在 Tensor Programs 框架中给出为 $\Delta h = O(n^{1-a-b})$ (详细推导见题 4)。由 $\Delta h = O(1)$ 得

$$\boxed{a + b = 1} \quad \blacksquare$$

(3) SP 验证: $a = 1/2, b = 0, a + b = 1/2 \neq 1$ 。

SP + Adam 下 $\Delta h = O(n^{1-1/2}) = O(n^{1/2})$, 随宽度 n 增大而发散, 超参数 (如学习率) 需要随网络宽度重新调整, 无法迁移。

Sanity check: $a + b = 1$ 是边界条件, SP 的 $a + b = 1/2$ 位于「发散」一侧, NTK 的 $a + b = 1$ (SGD 等效点) 在刀刃上但无特征学习, μP 的 $a + b = 1$ 同时满足稳定性与特征学习。

T-4.7.2 【SP 与 μP 的宽度缩放数值】

(1) SP 数值计算:

$a + b = 1/2$, $\Delta h \sim O(n^{1-a-b}) = O(n^{1/2})$, 缩放指数为 $1/2$ 。

宽度比 $n_2/n_1 = 4096/256 = 16$, Δh 放大因子:

$$\left(\frac{n_2}{n_1}\right)^{1/2} = \sqrt{16} = 4.0000$$

即 SP + Adam 在宽度增大 16 倍时, 激活更新幅度放大 4.0000 倍, 导致训练不稳定或需重新调参。

(2) μP 数值计算:

$$a = 1, b = 0, a + b = 1, \Delta h \sim O(n^{1-1}) = O(n^0) = O(1)。$$

放大因子:

$$\left(\frac{n_2}{n_1}\right)^{1-a-b} = \left(\frac{n_2}{n_1}\right)^0 = 1.0000$$

Δh 完全不随宽度变化, 学习率可直接从小模型迁移到大模型。

(3) 输出层学习率 $O(1/n)$ 的论证:

μP 下输出层初始化 $W_2 \sim \mathcal{N}(0, 1/n^2)$, 输出激活 $f = W_2 h/n$ (另有 $1/n$ 输出缩放)。为保持输出激活 $f = O(1)$ (与隐藏层等量级), Adam 更新后输出层参数变化 ΔW_2 需满足 $\Delta f = (\Delta W_2)h/n = O(1)$ 。由于 $\|h\|_2 = O(1)$ (μP 隐藏层激活稳定), 需要 $\Delta W_2 = O(n)$, 而 Adam 步长 η_2 下更新量为 $O(\eta_2)$, 故 $\eta_2 \cdot O(n) = O(1)$ 得 $\eta_2 = O(1/n)$ 。

Sanity check: 宽度从 256 到 4096, SP 的激活放大 $4\times$, μP 保持 $1\times$ ——与 Yang et al. (2022) 的实验图表完全吻合。

T-4.7.3 【NTK 极限与特征学习】

(1) **NTK 量级:** $a = 1/2, b = 1/2$ (SGD), $a + b = 1, \Delta h = O(n^{1-1}) = O(1)$ 。

但 SGD 下 $b = 1/2$ 意味着学习率 $\eta \sim n^{-1/2} \rightarrow 0$, 激活更新虽然形式上 $O(1)$, 实际上权重变化 $\rightarrow 0$ (退化)。

(2) **NTK 退化的激活语言:** NTK 极限下, 每步梯度下降的权重更新 $\Delta W \rightarrow 0$ (按 $n^{-1/2}$ 衰减), 隐藏层激活 h 在整个训练过程中几乎保持初始化时的随机值; 网络等效于用初始化确定的固定特征做线性回归 (核方法), 无法从数据中学习新的表示。

(3) **论断评判: 错误。** μP 的无穷宽极限 (Mean Field 极限) 与 NTK 极限本质不同: μP 下权重在整个训练中有 $O(1)$ 幅度的变化 ($\Delta W \sim O(n^{-a}) = O(n^{-1})$ 对元素级别, 但 $\Delta h = O(1)$ 整体上有效), 隐藏层激活实质改变, 网络在进行真正的特征学习; NTK 极限下权重变化趋零, 只有网络输出的切线 (线性化) 在变化。

(4) 表格填写:

参数化	a	b (Adam)	$a + b$	Δh	特征学习
SP	1/2	0	1/2	$O(n^{1/2})$, 发散	否 (不稳定)
NTK	1/2	1/2	1	$O(1)$, 但 $\eta \rightarrow 0$	否 (冻结)
μP	1	0	1	$O(1)$, 稳定	是

Sanity check: 三者 $a + b$ 分别为 1/2、1、1, 与「发散/冻结/稳定」一一对应。

T-4.7.4 【Tensor Program 统一视角计算题】

子问题 A:

$W_1 \in \mathbb{R}^{n \times n}$, $(W_1)_{ij} \sim \mathcal{N}(0, 1/n)$, $\|x\|_2 = 1$, $x_j = 1/\sqrt{n}$ 量级。

$$\mathbb{E}[h_i^2] = \mathbb{E} \left[\left(\sum_j (W_1)_{ij} x_j \right)^2 \right] = \sum_j \frac{1}{n} \cdot x_j^2 = \frac{1}{n} \cdot \|x\|_2^2 = \frac{1}{n}$$

(ReLU 引入系数 1/2, 但量级不变。) 故 $\mathbb{E}[\|h\|_2^2] = n \cdot (1/n) = 1$, 与 n 无关。

$n_1 = 64$: $\mathbb{E}[\|h\|_2^2] = 1$; $n_2 = 1024$: $\mathbb{E}[\|h\|_2^2] = 1$ 。比值 = **1.0000** (μP 隐藏层激活范数与宽度无关)。

子问题 B:

$(\Delta W_1)_{ij} \sim O(\eta/\sqrt{n})$ (Adam 步长 η 乘以初始化尺度 $1/\sqrt{n}$ 给出更新量级)。

$$\|\Delta h\|_2^2 = \mathbb{E} \left[\left(\sum_j (\Delta W_1)_{ij} x_j \right)^2 \right] \approx n \cdot \frac{\eta^2}{n} \cdot \frac{1}{n} \cdot n = \eta^2$$

故 $\|\Delta h\|_2 = O(\eta)$, 与 n 无关。 $\eta = 0.01$: $n = 64$ 时 $\|\Delta h\| \approx 0.01$, $n = 1024$ 时 $\|\Delta h\| \approx 0.01$, 比值 = **1.0000**。

子问题 C:

Tensor Programs 定理保证 μP 下梯度在 $n \rightarrow \infty$ 时收敛到非平凡极限, 意味着: (1) 学习率 η 在大网络与小网络中对梯度下降步的「实际效果」等价; (2) 损失曲面的局部几何 (梯度、Hessian 谱) 随 n 收敛, 因此在小 n 上调好的学习率能预测大 n 上的行为; (3) 若梯度趋零 (NTK 冻结) 或发散 (SP 不稳定), 则小网络与大网络的优化动力学根本不同, 迁移失去意义。

Sanity check: 子问题 A、B 两处比值均为 1.0000, 正是 μP 「宽度无关」的量化证明。

T-4.7.5 【超参数迁移的边界条件】

(a) **部分错误**。 μP 提供理论保证, 但实践中有限宽度效应 (有限 n 的高阶修正)、数值精度、硬件实现等因素仍可能引入偏差; 「完美迁移无需验证」过于绝对, 工程上仍需小规模验证实验。

(b) **基本正确**。 μP 原始理论 (Yang et al., 2022) 针对宽度缩放, 对深度缩放不提供同等严格的保证; 深度方向的协调缩放是独立的开放问题, Depth- μP (2023) 是初步探索但尚未完善。

(c) **错误**。Batch Normalization 通过对激活进行归一化, 使激活的实际量级与初始化方差解耦, 打破了 μP 假设中「激活量级由初始化控制」的前提; 在实践中 $\mu\text{P} + \text{BatchNorm}$ 需要额外分析, 不能直接套用 μP 的迁移结论。

(d) **错误**。SGD 和 Adam 的梯度量级不同: SGD 下更新量 $\propto \eta \|\nabla \mathcal{L}\|$, Adam 下更新量 $\propto \eta$ (梯度被自适应归一化)。因此满足 $a + b = 1$ 的 (a, b) 在两者下不同: Adam 下 μP

取 $(a = 1, b = 0)$, SGD 等效点取 $(a = 1/2, b = 1/2)$ (即 NTK 参数化)。

(e) **错误**。(e) 夸大了 μP 的排他性。NTK 参数化在 SGD 下同样满足 $a + b = 1$ (刀刃条件), 但由于 $b = 1/2 > 0$, $\eta \rightarrow 0$, 退化为特征冻结; 从「迁移」的宽泛定义看, NTK 极限下的核函数也与宽度无关 (收敛到固定核), 也是一种「迁移」。 μP 的独特性在于同时满足稳定性和特征学习, 而非「唯一能迁移」。

Sanity check: (a)–(e) 五条涵盖了理论局限、工程边界和概念辨析, 与 Yang et al. (2022、2023) 原始论文的讨论一致。

本节 μP 的「宽度均匀动力学」在 § 4.8 中将被类比到组织扩张时的「制度设计不变性」——两者的数学结构 (尺度不变的递推关系) 是类比成立的根本原因, 同时也为理解 § 4.9 类比的失效边界埋下伏笔。

§4.8 习题：跨界类比：复杂系统的工程管理

导读：本节核心是「反向传播 $\leftrightarrow$ 绩效分摊、Adam $\leftrightarrow$ 不确定性管理、 $\mu P \leftrightarrow$ 规模不变制度」三组类比的数学根源——每组类比均有严格的结构对应，不是比喻，是同构。五题分别对应：A（链式法则类比推导）、B（Adam 自适应步长的决策论基础）、C（ μP 尺度不变性辨析）、D（「类比合法性」综合评判）、E（类比的预测力评估）。

题1【轻·轻推导·链式法则与绩效分摊的线性叠加】

导读：反向传播中每个参数的梯度等于所有通过该参数传递的误差信号之和，这与组织管理中「每个员工的绩效贡献等于其参与的所有项目产出之加权和」具有完全相同的数学结构。

设两层网络，隐藏层神经元 j 的输出为 $z_j = \sigma(\sum_i w_{ij}x_i)$ ，损失对隐藏层的误差信号为 $\delta_j = \partial \mathcal{L} / \partial z_j$ ，输入为 x_i 。

- (1) 写出 $\partial \mathcal{L} / \partial w_{ij}$ 的表达式，展示它如何分解为「上游误差 δ_j 」与「输入激活 x_i 」的乘积。
- (2) 设某神经元 i 连接到多个上游神经元 $j = 1, \dots, m$ ，写出 $\partial \mathcal{L} / \partial x_i$ ，说明它是所有下游误差信号的**线性叠加**。
- (3) 用两句话说明：为什么「边际贡献线性可分」是此类比成立的关键假设，如果损失函数对参数是非线性的（二阶以上），类比在哪里出现裂缝？

教学注：链式法则的「线性叠加」性质使误差信号能够无歧义地「归因」到每个参数——这正是「绩效分摊」类比的数学支柱。任何绕开链式法则的二阶方法（如 K-FAC）都会打破这种干净的线性归因。

陷阱：梯度是一阶近似，只在参数空间的局部邻域内刻画了参数的「边际贡献」；全局范围内由于非凸性，同一参数的「真实贡献」无法通过任何单一数值表征。

题2【中·中计算·Adam 自适应步长的决策论最优性】

导读：Adam 的自适应步长 $\eta_t^{(i)} = \eta / (\sqrt{\hat{v}_t^{(i)}} + \epsilon)$ 可以从贝叶斯决策理论重新推导：在「参数更新量的不确定性正比于历史梯度方差」的假设下，最优步长恰好与方差平方根成反比——这与风险管理中「不确定性越大越保守」的直觉完全吻合。

- (1) 设参数 $\theta^{(i)}$ 的梯度观测服从 $g_t^{(i)} \sim \mathcal{N}(\mu_i, \sigma_i^2)$ ，在贝叶斯框架下，最小化后悔 (regret) 的最优步长为 $\eta^* \propto 1/\sigma_i$ 。设 $\hat{v}_t^{(i)} \approx \sigma_i^2$ (Adam 的二阶矩估计)，写出 Adam 步长与最优步长的对应关系。
- (2) 考虑两个参数： $-\theta^{(1)}$ ：历史梯度方差 $\hat{v}^{(1)} = 0.0025$ - $\theta^{(2)}$ ：历史梯度方差 $\hat{v}^{(2)} = 0.25$ 设 $\eta = 0.001$ ， $\epsilon = 10^{-8}$ ，计算两者的实际步长（精确到四位有效数字）及其比值。
- (3) 在组织管理类比中， $\hat{v}_t^{(i)}$ 对应「员工绩效的历史波动性」，步长对应「管理者给予的自主权」。解释为什么「波动性大的员工应给予更少自主权」在决策论层面有最优性保证，而非仅仅是经验直觉。

教学注：Adam 的动量项 $\hat{m}_t^{(i)}$ 对应「对长期趋势的追踪」，这在组织管理类比中对应「基于历史绩效趋势的期望设定」——两个分量都有清晰的决策论解释。

陷阱：贝叶斯最优步长的推导需要假设梯度为高斯分布且独立同分布；实际梯度有相关性和非平稳性，Adam 是近似而非精确最优。

题 3 【中·概念辨析· μP 的尺度不变性与制度设计】

导读： μP 的激活稳定性约束 $a + b = 1$ 在数学上意味着激活动力学对网络宽度 n 均匀 (uniform)：无论 n 取 256 还是 40960，隐藏层激活更新量 Δh 都是 $O(1)$ 。这被类比为「组织扩张不改变制度核心」。

(1)「 μP 激活动力学 n -均匀」与「制度扩张不变性」的类比，其数学同构点是什么？完成以下对应表：

深度学习侧	组织管理侧
网络宽度 n	?
激活更新量 $\Delta h = O(1)$	?
abc 约束 $a + b = 1$	?
超参数迁移：小 n 调好的 η 直接用于大 n	?

(2)「尺度不变性」在数学物理中对应「重整化群不动点」。简要解释：为什么 μP 可以被视为参数化空间中的一个重整化群不动点？（不需要写出完整的重整化群方程，2-3 句即可）

(3) 判断：「 μP 的 n -均匀性类比到组织管理时，预测了『制度设计存在唯一最优解』。」这一论断是否从类比中合法推出？

教学注：类比的「转移能力」有严格限制——数学同构只保证结构映射，不保证语义扩展；在对应表填好之后，每一条「新推论」都需要回到原系统中独立验证。

陷阱：「重整化群不动点」的类比在文学意义上成立（都是某种尺度变换下的不动结构），但不要据此推断深度学习与统计物理的相变有定量关联——这需要额外的理论桥梁。

题 4 【重·重评判·三组类比的合法性综合审查】

导读：类比是科学思维的利器，但「类比合法性」需要明确核查其依赖的假设——每一个假设一旦在目标域（这里是工程管理）失效，类比就从严格同构退化为松散隐喻。

对以下三组类比，分别：(i) 给出类比成立的核心数学假设；(ii) 指出该假设在工程管理语境下何时成立、何时不成立；(iii) 评级：严格同构 / 结构类比 / 松散隐喻。

类比 A：反向传播中的梯度 $\leftrightarrow$ 组织中的绩效归因（「每个员工的边际贡献可精确量化并线性叠加」）

类比 B: Adam 自适应步长 $\leftrightarrow$ 波动性越大给予越少自主权 (「过去波动性是未来风险的充分统计量」)

类比 C: μP 的 n -均匀 $\leftrightarrow$ 「规模不变的制度设计」 (「激活动力学的尺度不变类比到组织文化的规模不变」)

教学注: 评判一个类比的「合法性」不是要求类比完美,而是要能明确说出类比的「有效域」——在什么条件下它是有信息量的,在什么条件下它只是装饰性的。

陷阱: 「严格同构」是最高评级,意味着两个系统的所有定理在转换下双向对应;现实中绝大多数跨学科类比最多是「结构类比」,千万不要因为数学公式相似就误判为「严格同构」。

题 5 【重·重评判·类比的预测力与可证伪性】

导读: 一个「有价值的类比」不仅能解释已知现象,还应该能做出可检验的预测。这是区分「富有洞见的类比」与「事后诸葛」的关键标准。

(1) 反向传播 $\leftrightarrow$ 绩效分摊类比提示:「优化收敛速度取决于误差信号的传播效率」。这在深度学习中对应什么可量化的预测?(例如层数、skip connection 对收敛的影响)写出一个具体的可检验命题。

(2) Adam $\leftrightarrow$ 不确定性管理类比提示:「对高波动性参数保守更新应提升整体稳定性」。请构造一个反例:在什么情况下,对高 $\hat{v}$ 参数更保守的更新反而损害性能?

(3) $\mu P \leftrightarrow$ 规模不变制度类比的「预测」是:「按 μP 方式设计制度的组织,扩张时性能(人均产出等)保持稳定」。请评估:

(a) 这个预测在数学上是否从类比中严格推出?

(b) 用什么样的组织管理数据可以检验这个预测?

(c) 该预测的「可证伪性」(falsifiability) 如何?

教学注: Popper 的可证伪性标准在跨学科类比中尤为重要——如果一个类比的「预测」可以被任意解释成与证据相容,它就失去了科学价值,变成了无法检验的叙事。

陷阱: 题 (2) 要求构造反例,不是说 Adam 不好——而是说任何基于历史方差的保守策略在非平稳环境下都有其局限,「反例」的意义在于界定有效域,而非否定整体框架。

解答 § 4.8

T-4.8.1 【链式法则与绩效分摊的线性叠加】

(1) 单参数梯度:

$$\frac{\partial \mathcal{L}}{\partial w_{ij}} = \frac{\partial \mathcal{L}}{\partial z_j} \cdot \frac{\partial z_j}{\partial w_{ij}} = \delta_j \cdot x_i$$

这是「上游误差信号 δ_j 」乘以「输入激活 x_i 」，两个量分别对应「该参数所在节点的边际输出对损失的影响」和「该参数实际接收的输入强度」。

(2) 多连接的线性叠加：

$$\frac{\partial \mathcal{L}}{\partial x_i} = \sum_{j=1}^m \frac{\partial \mathcal{L}}{\partial z_j} \cdot w_{ij} = \sum_{j=1}^m \delta_j w_{ij}$$

即 x_i 的梯度是所有下游节点的误差信号 δ_j 按连接权重 w_{ij} 的线性加权和——每条连接路径独立贡献，互不干扰。

(3) 线性叠加假设的边界：

「边际贡献线性可分」的关键假设是链式法则的**乘积可分性**——损失对参数的一阶导数可以分解为「局部激活」与「上游误差」的乘积。若损失函数对参数是二阶以上非线性的（如需要考虑参数之间的交叉二阶导数），则单个参数的「真实贡献」无法通过一阶梯度完全刻画，需要 Hessian 信息，类比在此处出现裂缝：「绩效归因」不能再通过简单叠加完成，而需要考虑参数间的「协同效应」（对应组织中的团队协作溢出效应）。

Sanity check：反向传播的计算复杂度 $O(n_{\text{params}})$ 正是线性叠加的直接结果——每个参数恰好需要一次乘加运算。

T-4.8.2 【Adam 自适应步长的决策论最优性】

(1) 对应关系：

贝叶斯最优步长 $\eta^* \propto 1/\sigma_i$ ，Adam 步长 $\eta_t^{(i)} = \eta / (\sqrt{\hat{v}_t^{(i)}} + \epsilon) \approx \eta / \sqrt{\hat{v}_t^{(i)}}$ （忽略 ϵ ）。

两者精确对应： $\hat{v}_t^{(i)} \approx \sigma_i^2$ 时， $\eta_t^{(i)} \approx \eta / \sigma_i \propto 1/\sigma_i$ 。

(2) 数值计算：

$$\eta_t^{(1)} = \frac{0.001}{\sqrt{0.0025} + 10^{-8}} = \frac{0.001}{0.05 + 10^{-8}} \approx \frac{0.001}{0.05} = 0.02000$$

$$\eta_t^{(2)} = \frac{0.001}{\sqrt{0.25} + 10^{-8}} = \frac{0.001}{0.5 + 10^{-8}} \approx \frac{0.001}{0.5} = 0.00200$$

比值 $\eta_t^{(1)} / \eta_t^{(2)} = 0.02 / 0.002 = 10.0000$ 。

方差相差 100 倍 ($0.25 / 0.0025 = 100$)，步长相差 10 倍 ($\sqrt{100} = 10$)，与 Adam 公式的平方根关系一致。

(3) 决策论最优性解释：

在贝叶斯均值-方差框架下，最小化「期望后悔」（expected regret）等价于在每次更新中步长与梯度不确定性成反比——方差大意味着当前梯度方向的估计噪声大，大步长会随机游走放大噪声的不良影响；方差小意味着梯度方向可信，可以放心采用更

大步长加速收敛。这不是经验直觉，而是在高斯噪声假设下严格可证明的最优性结果（对应 Bayesian online learning 的最优预测器）。

Sanity check: 两个参数步长之比为 10，恰好等于标准差之比 $0.5/0.05 = 10$ ，而非方差之比 100——Adam 的平方根归一化保证了步长比方差更「温和」地反映不确定性差异。

T-4.8.3 【μP 的尺度不变性与制度设计】

(1) 对应表：

深度学习侧	组织管理侧
网络宽度 n	组织规模（员工/团队数量）
激活更新量 $\Delta h = O(1)$	个体/团队的实际行为变化幅度保持稳定
abc 约束 $a + b = 1$	制度设计参数（激励强度、汇报层级）满足某个协调约束
超参数迁移：小 n 调好的 η 直接用于大 n	小团队验证的管理规则可直接应用于大组织

(2) 重整化群不动点：

重整化群变换描述系统在「粗粒化」（整合更多微观自由度）后的动力学变化，不动点是变换下保持不变的系统。μP 可类比为：当宽度 n 增大（类似粗粒化），激活动力学的统计量（ Δh 的方差、均值）保持不变——即初始化和学习率的调整方案是宽度变换的不动点。这意味着 μP 刻画了深度学习参数化空间中对宽度缩放「临界稳定」的唯一流形。

(3) 论断评判：不合法。μP 的 n -均匀性只保证「对特定宽度比例，激活动力学等价」，并不蕴含「制度设计空间中存在唯一最优解」。「唯一最优」需要额外的凸性或全局最优性假设，而 μP 框架对此没有任何主张；类比从「结构等价」跳到「唯一性」超越了类比的数学支撑范围。

Sanity check: 对应表的四行均有严格的数学对应（不是隐喻），但第 (3) 题的推论超出了对应表所能承载的信息量。

T-4.8.4 【三组类比的合法性综合审查】

类比 A（反向传播 ↔ 绩效归因）：

- (i) 核心假设：损失对参数是可微的，梯度（一阶导数）充分描述了参数的边际贡献，且贡献可线性叠加。
- (ii) 在组织管理中：当工作流程是线性管道（每个员工输出直接进入下一环节）且绩效函数光滑可微时成立；当存在团队协同效应、非线性激励（奖金跳跃）、或「涌现」型产出（ $1+1>2$ ）时失效。
- (iii) 评级：结构类比（数学形式一致，但语义目标域的假设需独立验证）。

类比 B (Adam ↔ 不确定性管理):

- (i) 核心假设：过去梯度的二阶矩 ($\hat{v}_t$) 是未来梯度方差的充分统计量 (平稳性假设)；高斯噪声下贝叶斯最优步长 $\propto 1/\sigma$ 。
- (ii) 在组织管理中：当员工绩效波动是平稳过程 (历史方差预测未来) 且波动是独立的高斯噪声时成立；当绩效波动有结构性原因 (学习曲线、外部冲击) 时失效——历史高波动性可能恰好预示未来低波动 (学成后趋于稳定)，应给予更大自主权。
- (iii) 评级：**结构类比** (贝叶斯基础成立，但平稳性假设在复杂组织中经常不满足)。

类比 C (μP 尺度不变 ↔ 规模不变制度):

- (i) 核心假设：激活动力学在宽度变换下不变，这在数学上等价于「制度效果在规模变换下不变」。
- (ii) 在组织管理中：当组织增长是同质扩张 (新员工和团队与旧有完全同质) 时近似成立；现实中组织扩张通常引入异质性 (新职能、新地区、文化摩擦)，打破了「同质扩张」假设。
- (iii) 评级：**松散隐喻** (数学结构对应最弱，因为「组织同质扩张」是极强假设)。

Sanity check: 三组类比的评级梯度 (结构类比 → 结构类比 → 松散隐喻) 反映了假设可信度的递减，这与本节内容「部分类比成立，需分层审视」的论点吻合。

T-4.8.5 【类比的预测力与可证伪性】

(1) **可检验命题**：「反向传播 ↔ 绩效分摊」类比预测：引入 skip connection (类比于「绩效信号直连高层」) 应显著加速收敛——可量化为「达到相同训练损失所需 epoch 数的减少比例」，ResNet vs VGG 在 ImageNet 上提供了定量检验 (ResNet 在相同参数量下收敛快约 2–3 倍)。

(2) **反例构造**：当模型中某些参数是「关键转折点」(如 gating 参数，小变化导致输出大幅改变) 时，这些参数的梯度方差 $\hat{v}$ 会很大，Adam 给予极小步长；但恰恰是这些参数需要大更新才能使模型跳出当前模式，过度保守反而导致模型「卡住」——实践中 Transformer 中的 attention 温度参数有时出现此类现象，需要手动覆盖 Adam 的自适应步长。

(3) 预测评估:

- (a) **否**。 n -均匀性严格保证的是激活动力学等价，而非组织「性能」的任何定量量度 (人均产出是多维的复杂指标，与激活更新量没有数学映射)。
- (b) 可用数据：对不同规模的初创公司 (种子期 → A 轮 → C 轮)，在制度设计固定不变的条件下，追踪人均产出增长率的变化；若人均产出随规模稳定 (斜率接近 0)，则与预测相符。
- (c) **可证伪性较弱**：因为「制度设计固定」在实践中几乎不可能实现 (任何扩张都伴随制度调整)，且「人均产出」有太多混淆因素，难以分离「规模效应」与「制度效应」。这使该预测倾向于成为无法有效检验的叙事。

Sanity check: (3)(c) 指出了类比预测的核心局限——数学域 (深度学习) 的可控实验

无法复制到目标域（组织管理），这是所有「社会科学借鉴物理/数学」类比的普遍困境。

§ 4.9 将系统梳理上述类比中隐藏的三条「失效边界」，说明工程管理隐喻在哪些根本假设处与深度学习的实际数学结构不符。

§4.9 习题：反类比：工程管理隐喻的失效边界

导读：本节核心是「工程管理隐喻在三条根本假设处失效」——(1) 无「完成」状态（截断非收敛）、(2) 功能涌现非预先设计（事后语义 vs 事前规范）、(3) 非凸性不可消除（利用 vs 控制）。五题分别对应：A（截断 vs 收敛推导）、B（功能涌现的可解释性含义）、C（非凸性的不可消除性）、D（三条失效边界综合评判）、E（「改良类比」可行性评估）。

题1【轻·轻推导·截断与收敛的数学区别】

导读：工程项目有明确的「完成」状态（需求全部通过验收），而神经网络训练的「停止」是一个截断决策（基于计算预算、验证集指标等），而非理论上的收敛——后者在一般非凸问题中无法保证。

(1) 对于强凸光滑目标函数 $f(\theta)$ （强凸参数 $\mu > 0$ ，梯度 Lipschitz 常数 L ），梯度下降可以证明 $f(\theta_T) - f(\theta^*) \leq (1 - \mu/L)^T (f(\theta_0) - f(\theta^*))$ 。计算：当 $\mu/L = 0.01$ 时，需要多少步 T 使误差降低到初始值的 10^{-4} （精确到整数步）？

(2) 对于深度学习中的非凸损失函数，梯度下降的「收敛性」结论是什么？（选择最准确的描述）

- (A) 梯度下降收敛到全局最小值
- (B) 梯度下降收敛到某个驻点 ($\|\nabla f\| = 0$)，但不保证是全局最小值
- (C) 梯度下降在一般非凸问题中连局部最小值都无法保证找到
- (D) 梯度下降收敛到最近的局部最小值

(3) 用一句话说明：从数学角度，「训练停止」为什么只能被称为「截断」而非「收敛」。

教学注：「驻点」包括极大值点、鞍点和极小值点；高维非凸函数中，梯度消失的鞍点数量指数多于极小值点，梯度下降在实践中通常卡在鞍点附近区域，而非真正收敛。

陷阱：实践中经常混用「训练收敛了」（意指 loss 曲线趋于平稳）和「数学收敛」（有严格的极限保证）——两者的区别正是此题要点。

题2【中·中计算/辨析·功能涌现与事后语义】

导读：工程模块的功能由工程师在设计阶段预先规范（「这个函数负责日志记录」），但神经网络神经元的语义由训练动力学在事后决定（「这个神经元响应猫耳朵特征」）——两者的根本差异使「功能模块化」的类比在可解释性问题上失效。

(1) 设网络的某个中间层神经元 z 在训练前和训练后的激活函数形式完全相同（均为 ReLU），但其响应的输入特征从随机噪声变为某个有语义的概念。解释：工程管理隐喻如何处理这一现象？类比为什么在此处失效？

(2) 「多神经元多义性」(polysemanticity) 现象：单个神经元在不同输入下对应不同的高层语义概念（如 Anthropic 的研究发现某神经元同时响应「香蕉」和「弧形物体」）。

判断：「polysemanticity 的存在意味着神经网络的功能模块化假设是错的，因此反向传播 $\leftrightarrow$ 绩效归因的类比完全失效。」

这一推断的逻辑跳跃在哪里？

(3) 构造一个思想实验：设计一个「事后发现功能」的工程场景，使之在结构上与神经网络语义涌现尽可能相似。指出该场景与真实工程管理的本质差异。

教学注：polysemanticity 是「叠加假设」(superposition hypothesis) 的核心现象——神经网络通过让单个神经元编码多个概念来突破激活维度限制，这从根本上打破了「神经元 = 功能模块」的工程类比。

陷阱：功能涌现是「非预先设计」，不等于「无规律可循」——可解释性研究（如 mechanistic interpretability）正在发现这些事后规律，但这不恢复类比，只是提供了新的（非工程的）理解框架。

题 3【中·概念辨析·非凸性：利用还是控制】

导读：工程优化问题通常被设计为（或转化为）凸问题，具有全局最优解的唯一性保证；深度学习「利用」高维非凸景观的良性性质（如宽平坦极小值泛化好），而非「消除」非凸性——这是一个根本性的范式差异。

(1) 「线性规划」和「二次规划（正定）」是两类经典的凸优化问题。解释为什么工程设计中将问题「转化为凸规划」是有价值的（从唯一性、算法保证角度）。

(2) 深度学习的非凸损失景观具有以下已知的良性性质（选择正确的描述）：

- (A) 所有局部最小值的函数值都相等（等能极小值假设）
- (B) 局部最小值的质量（泛化性能）随网络宽度增大而趋向全局最优
- (C) 梯度下降会以概率 1 找到全局最优解
- (D) 非凸性是深度学习成功不可缺少的组成部分，而非需要消除的障碍

(3) 判断以下论断是否成立：

「随着神经网络技术的发展，未来的训练算法将能够消除损失景观的非凸性，从而给出全局最优保证——就像工程优化那样。」

给出理由，并指出该论断混淆了哪两个不同层次的概念。

教学注：深度学习「利用」非凸性的方式包括：(1) 过参数化使极小值流形连通（Gauss-Newton 矩阵秩亏）；(2) 大量极小值质量相近，找到哪个都可以；(3) 隐式正则化（如小批量 SGD 的平坦极小值偏好）将泛化能力内嵌到优化过程中。

陷阱：「等能极小值假设」(A) 仅在过参数化网络和特定数据分布下近似成立，不是普遍事实；不要将「宽度趋无穷时极小值质量趋于全局最优」的渐近结论误用于有限宽度网络。

题4【重·重评判·三条失效边界的根因分析】

导读：本节三条失效边界——(1) 截断非收敛、(2) 功能涌现非预先设计、(3) 非凸性利用非控制——并非孤立的「例外列表」，而是反映了深度学习与工程系统在**本体论层面**的根本差异。

(1) 指出三条失效边界分别对应工程管理中的哪个核心假设，并说明该假设在深度学习中「不成立」还是「以弱化形式成立」：

失效边界	对应工程假设	深度学习中的状态
截断 $\neq$ 收敛	?	?
功能涌现非预先设计	?	?
非凸性不可消除	?	?

(2) 有观点认为：「三条失效边界都是『当前』技术的局限，随着 AI 的进步，它们会逐步被解决。」

对每条失效边界，分析它是「技术局限」(可通过技术进步解决)还是「原理性限制」(由数学结构决定，技术进步无法消除)。

(3) 「类比有用但有边界」——从认识论角度，为什么指出类比的失效边界比建立类比本身更重要？(4-5 句)

教学注：此题的「认识论」问题没有唯一答案，但评分关键在于：是否能用具体论据(而非泛泛而谈)支持「失效边界的认识论价值」。

陷阱：(2) 中「原理性限制」不意味着「完全无法改善」，而是「无法通过工程优化完全消除其本质特征」——例如非凸性可以局部正则化，但全局凸化会改变深度学习的本质(退化为核方法)。

题5【重·重评判·「改良类比」的可行性】

导读：既然工程管理类比在三处失效，一个自然的反应是「修补类比」——用更精确的工程隐喻替代失效部分。本题评估若干「改良方案」的可行性。

考虑以下三种「改良类比」方案：

方案 X：将「工程项目」替换为「生态系统管理」——生态系统没有明确「完成」状态，功能由进化动力学而非设计决定，非线性不可消除；三条失效边界或许在这个类比中同时成立。

方案 Y：将「绩效归因」精确化为「Shapley 值分配」——博弈论的 Shapley 值给出了联盟博弈中每个参与者的公平贡献，数学上更严格，可能比梯度类比更准确。

方案 Z：放弃「管理」隐喻，转向「进化」隐喻——训练 = 选择压力，神经元 = 物种，涌现功能 = 自然选择结果；这一类比天然包含「无预设目标」和「非凸搜索」。

对每个方案：(i) 指出该方案解决了原类比的哪条失效边界；(ii) 指出该方案引入了什么新的假设或问题；(iii) 总体评价：是「有效改良」还是「引入了等量或更多的新问题」。

教学注：改良类比是科学进步的常规路径——牛顿力学类比失效之处引出量子力学，热力学类比失效之处引出统计力学。评估改良方案需要同时看「它解决了什么」和「它引入了什么」。

陷阱：方案 X 引入了「生态系统」的所有复杂性（食物链、共进化、外部冲击），使类比变得更难操作而非更清晰；类比的值在于简化，过于复杂的类比失去了教学/启发功能。

解答 §4.9

T-4.9.1 【截断与收敛的数学区别】

(1) 收敛步数计算：

需要 $(1 - 0.01)^T \leq 10^{-4}$ ，即 $0.99^T \leq 10^{-4}$ 。

两边取对数： $T \ln(0.99) \leq \ln(10^{-4}) = -4 \ln 10$ 。

$$T \geq \frac{-4 \ln 10}{\ln 0.99} = \frac{4 \times 2.3026}{0.01005} \approx \frac{9.2103}{0.01005} \approx 916$$

即需要 $T = 916$ 步（精确值： $T = \lceil 916.0 \rceil = 916$ ）。

注： $\ln(0.99) \approx -0.01005$ ， $-4 \ln 10 \approx -9.2103$ ， $T \geq 9.2103/0.01005 \approx 916.4$ ，取整为 917 步。

精确计算： $T = \lceil \ln(10^{-4}) / \ln(0.99) \rceil = \lceil -9.2103 / (-0.010050) \rceil = \lceil 916.5 \rceil = 917$ 。

(2) 正确选项：(B)。对一般非凸函数，梯度下降（在合适步长下）收敛到驻点（梯度消失点），但不保证是全局甚至局部最小值。

(3) 一句话总结：训练停止是基于「验证损失不再下降」或「计算预算耗尽」的截断判断，而数学收敛要求存在极限 $\lim_{t \rightarrow \infty} \theta_t = \theta^*$ 且 θ^* 满足最优性条件——前者是工程决策，后者是数学事实，两者在非凸问题中一般不等价。

Sanity check：917 步对应条件数 $L/\mu = 100$ 的强凸问题——这已经是相当温和的情况；深度学习的有效「条件数」远大于 100，实际需要的步数是此量级的若干数量级倍。

T-4.9.2 【功能涌现与事后语义】

(1) 工程类比的失效：工程管理隐喻将神经元类比为「功能模块」，预设了每个模块在设计时就有固定功能定义；但神经元 z 的语义由训练动力学事后决定，在设计阶段无从规范。类比在此处失效：「该神经元负责 X 功能」这样的陈述在训练前无意义，训练后又因 polysemanticity 变得模糊——无法套用「功能模块的职责清晰」这一工程假设。

(2) 逻辑跳跃分析：该论断犯了两处逻辑跳跃：- 跳跃一：从「polysemanticity 存在」跳到「功能模块化假设全面失效」——polysemanticity 只说明单个神经元不是干净的功

能模块，但网络层级、电路 (circuit) 级别的功能模块化仍可能部分成立 (mechanistic interpretability 的研究发现确实存在功能电路)。- 跳跃二：从「功能模块化假设有问题」跳到「反向传播 $\leftrightarrow$ 绩效归因类比完全失效」——链式法则的线性叠加性质独立于功能模块化假设，两者是不同层次的主张；即使功能模块化失效，梯度的线性分解仍然精确成立。

(3) **思想实验**：设想一个咨询公司，完全没有事先分配职责，员工自由协作完成项目，事后回顾时发现某员工「实际上承担了法律风险识别功能」但这从未被设计或规定——这与神经元语义涌现结构相似。本质差异：真实工程管理中，「事后归因」后会立即将其转化为「事前规范」(写入职位说明书)，而神经网络无法通过修改「职位说明书」改变神经元的动力学行为——涌现功能不能被锁定或精确复制。

Sanity check：(2) 的两处逻辑跳跃是独立的，指出其中一处不足以完整回答，需两处均指出。

T-4.9.3 【非凸性：利用还是控制】

(1) **凸规划的价值**：凸优化保证了 (a) 唯一全局最优解 (严格凸时) 或连通的最优解集；(b) 多项式时间算法 (如内点法) 有严格的收敛率保证；(c) 对偶理论提供最优性的必要充分条件 (KKT 条件)，使验证「已到达最优」成为可能——这是工程设计能给出「完成」保证的数学基础。

(2) **正确选项**：(D)。深度学习的成功依赖非凸景观的良性几何性质 (过参数化下极小值流形的连通性、宽平坦极小值的泛化性)，而非消除非凸性。(A) 是近似成立的渐近命题，不是精确事实；(B) 和 (C) 都是错误的。

(3) **论断分析**：不成立。该论断混淆了两个层次：

- 层次一：「找到损失函数的全局最小值」——对于固定的非凸损失函数，这是 NP-hard 问题，任何确定性算法在最坏情况下无法多项式时间内解决，与技术进步无关。
- 层次二：「修改损失函数使其成为凸函数」——这在原则上可行，但会根本改变深度学习的本质：凸化通常意味着放弃非线性激活函数或深层结构，退化为核方法或广义线性模型；代价是失去特征学习能力，得不偿失。

论断混淆了「在既有非凸框架内改善优化」和「改变框架使其变成凸框架」——后者不是技术进步，而是放弃了深度学习的核心优势。

Sanity check：(2) 选 (D) 是本节核心论点的直接体现；(3) 的两个层次区分是此题的评分关键。

T-4.9.4 【三条失效边界的根因分析】

(1) **对应工程假设**：

失效边界	对应工程假设	深度学习中的状态
截断 $\neq$ 收敛	任务有明确的「完成」验收标准	不成立 ：损失函数在非凸景观上没有普遍可达的全局最优，停止是工程决策
功能涌现非预先设计	模块功能由设计者事前规范	不成立 ：神经元语义由训练动力学事后决定，无法事前精确规范
非凸性不可消除	优化问题可转化为凸规划，具有全局保证	以弱化形式成立 ：过参数化下极小值质量趋同，但非凸性本身无法消除，只能「利用」

(2) 技术局限 vs 原理性限制：

- **截断 $\neq$ 收敛：原理性限制。**非凸优化的 NP 难度是计算复杂度理论的结论，不随算法改进而改变；何时「足够好」是语境依赖的价值判断，无法被技术客观解决。
- **功能涌现非预先设计：原理性限制（但可部分缓解）。**训练动力学决定语义是梯度下降的数学结构决定的；可解释性技术可以事后理解语义，但无法使网络在训练前就具有设计者预设的神经元功能。
- **非凸性不可消除：原理性限制。**深层非线性网络的非凸性来自网络结构本身（多层权重乘积），消除非凸性意味着消除非线性或深层结构——这是深度学习的本质特征，不是可绕过的实现细节。

(3) 失效边界的认识论价值：

类比是认识新领域的脚手架，其价值在于借用熟悉域的直觉在陌生域中快速建立框架；但脚手架的本质是临时的——如果不拆除类比中不成立的部分，错误的直觉会比没有类比更危险，因为它会以「合理」的外表掩盖根本性错误。指出失效边界不是否定类比的价值，而是将类比从「直觉来源」升级为「受控工具」：在有效域内使用，在失效边界处停止，不做越界推论。从认识论角度，每一条清晰的失效边界都给出了「下一层理解所需的新概念」，是知识进步的路标——截断 $\neq$ 收敛指向「优化理论」，功能涌现指向「可解释性科学」，非凸性利用指向「景观几何学」。

Sanity check：三条失效边界中两条是「原理性限制」，一条是「部分原理性」，这与 §4.8 中类比评级（两个「结构类比」、一个「松散隐喻」）的梯度一致。

T-4.9.5 【「改良类比」的可行性】

方案 X（生态系统管理）：

- 解决了三条失效边界：生态系统无明确「完成」，物种功能由进化决定（事后），生态动力学高度非凸/非线性。
- 引入的新问题：生态系统管理包含「人为干预 vs 自然演替」的二元性，与神经网络训练的「全程梯度控制」不符；「适应度」概念的测量争议（类比「损失函数选择」问题，但引入了额外的模糊性）；生态系统的多稳态（bistability）机制与神经网络极小值流形的拓扑性质不同。
- 评价：引入了等量新问题。生态系统类比更自然地包含三条失效边界，但同时引

入了新的不对应点，且比工程管理类比更难操作（生态学概念对大多数读者更陌生，降低了类比的教學价值）。

方案 Y (Shapley 值分配):

- (i) 改善了失效边界 2 (功能涌现): Shapley 值是博弈论中定义的严格归因框架，可以处理「参与者联合贡献不可分」的情况；相比梯度，Shapley 值对特征交互的处理更准确。
- (ii) 引入的新问题: Shapley 值计算复杂度指数增长 ($O(2^n)$)，实践中只能近似；更重要的是，Shapley 值是针对输入特征的归因 (解释性工具)，而非针对优化过程的动力学描述——它改变了类比的**层次**，不再是「优化 $\leftrightarrow$ 管理」而是「决策归因 $\leftrightarrow$ 绩效归因」。
- (iii) 评价: **有效改良 (局部)**。在「可解释性归因」这一子问题上更严格的类比，但不能替代整个优化过程的工程管理类比，是补充而非替换。

方案 Z (进化隐喻):

- (i) 解决了失效边界 1 (无「完成」状态) 和 2 (功能涌现非预先设计); 对失效边界 3 (非凸性) 也有自然类比 (进化景观中的多峰适应度地形)。
- (ii) 引入的新问题: 进化是无梯度的随机搜索，而训练是基于梯度的确定性 (或随机梯度) 过程; 进化的选择单元是个体，神经网络的「更新单元」是梯度步——单元不对应; 进化没有「反向传播」的信息传递机制，无法类比信用分配 (credit assignment)。
- (iii) 评价: **有效改良 (整体框架) 但引入新的核心不对应**。进化隐喻更自然地处理三条失效边界，但丢失了梯度信息传播的结构 (这是深度学习最核心的计算特征之一)，相当于用更合适的宏观图像替代了不合适的微观图像——宏观改善但微观失真，取决于教学目标如何选择。

Sanity check: 三个方案分别对应「整体替换」「局部精化」「框架替换」三种改良策略，覆盖了类比改良的主要方向，体现了系统性思考。

§ 5.9 将把类似的「类比成立与失效边界」分析方法应用到「相变」叙事，处理一个从物理学借鉴而来的完全不同的跨界映射。

第5章·尺度律与涌现

§5.9 习题：跨界映射与反类比：相变叙事的边界

导读：本节核心是「相变叙事的双重性」——渗流剪枝实验为「AI 涌现类相变」提供了形式相似的定量支撑，但热力学极限的缺失、后视镜叙事、以及不可逆性三条边界严格限制了这一类比的合法范围。五题分别对应：A（渗流剪枝的幂律推导）、B（热力学极限的有限系统修正）、C（后视镜叙事的方法论批判）、D（不可逆性与非平衡框架）、E（「类比是否合法」综合评判）。

题1【轻·轻推导·渗流剪枝与序参量行为】

导读：Frankle & Carlin (2019) 的彩票假设实验和 Goldt et al. 的渗流剪枝实验共同表明，神经网络中存在一个临界剪枝阈值 $\bar{q}_c$ ，低于此阈值时网络性能快速恶化，其行为形式上类似物理渗流相变中的序参量幂律。

设渗流剪枝实验中，保留参数比例为 $\bar{q}$ ，性能指标（如准确率）在 $\bar{q} \geq \bar{q}_c$ 附近满足幂律关系：

$$F(\bar{q}) \sim (\bar{q} - \bar{q}_c)^\beta, \quad \bar{q} \geq \bar{q}_c, \quad \bar{q}_c \approx 0.98$$

- 设 $\beta = 0.5$ （类比二维渗流的临界指数），计算：当 $\bar{q} = 0.99$ 时， $F(0.99)/F(0.999)$ 的比值（精确到四位小数）。
- 物理渗流相变中， $\bar{q} < \bar{q}_c$ 时序参量严格为零（不渗透）。在神经网络剪枝实验中， $\bar{q} < \bar{q}_c$ 时网络性能是否严格为零？这一差异揭示了什么类比局限？
- 写出「序参量急剧但连续过渡」（crossover）与「真正相变」（phase transition）的数学区别（用导数的存在性表述）。

教学注：渗流剪枝为「涌现类相变」提供的是**形式相似性**（幂律行为），而非**机制同一性**——物理渗流的幂律来自无标度关联长度发散，神经网络的幂律来自参数冗余结构，两者的微观机制完全不同。

陷阱： $\bar{q}_c \approx 0.98$ 意味着只需保留 2% 的参数网络性能就开始大幅下降——这与直觉「保留 98% 的参数应该差不多」相反，正是「稀疏彩票子网络」的反直觉核心。

题2【中·中计算·热力学极限与有限系统的解析性】

导读：物理相变（严格意义上的非解析性）只在热力学极限（ $N \rightarrow \infty$ ）下存在；有限系统的自由能 $f(N, T)$ 在任何温度 T 下都是解析函数。神经网络是有限系统，因此只有 crossover（连续渐变）而非相变。

- 有限体积 N 的 Ising 模型，配分函数为 $Z_N = \sum_{\{s_i\}} e^{-\beta H}$ （有限项的有限求和）。解释为什么 Z_N 对任意 β 都是解析的（不需要具体计算，用有限项指数函数之和的性质论证）。

(2) 设某神经网络的「等效系统大小」为参数量 $n = 10^{10}$ (典型大语言模型量级)。在有限系统中, 相变点附近的「伪临界区域」宽度正比于 $N^{-1/\nu}$ (ν 为临界指数, $\nu \approx 1$ 对三维 Ising)。当 $N = 10^{10}$ 时, 伪临界区域宽度的量级是多少? 这意味着什么?

(3) 判断:「GPT-3 到 GPT-4 之间某些能力的『突然』出现, 在技术上构成相变 (phase transition)。」这一论断在热力学极限的标准下是否成立?

教学注:「有限系统的自由能永远解析」是统计力学的严格定理 (Lee-Yang 定理的推论), 这使神经网络中的「相变」叙事在最严格意义上站不住脚——有限系统只有 crossover, crossover 的导数存在, 没有真正的奇异性。

陷阱:「解析」不等于「平滑」(在实践意义上)——有限系统的 crossover 可以非常陡峭, 在有限分辨率的测量下与真正的相变不可区分; 这不否定 crossover 现象的存在, 只是说它没有普适临界指数。

题 3【中·概念辨析·后视镜叙事与预测能力】

导读:「相变叙事」的第二条失效边界是方法论层面的——序参量是在观察到涌现之后才被识别出来的 (事后确认), 因此无法从相变理论推断「下一次涌现何时发生」。

(1) 物理相变理论 (如朗道理论) 在临界点之前可以预测: 温度降至 T_c 时磁化率发散, $T < T_c$ 时自发磁化出现。这一预测能力的数学基础是什么? (序参量、Landau 展开的先验知识角度)

(2) 对于 AI 能力涌现, 以下哪些要素是「后视镜叙事」所缺乏的, 因而无法做出类似预测?

逐条分析: - (A) 普适临界指数 β, ν, γ - (B) 序参量的先验定义 - (C) 控制参数 (类比温度) 的精确量化 - (D) 热力学极限的存在

(3) 构造一个「有预测能力的涌现叙事」的最低要求列表 (4 条), 说明目前 AI 能力预测研究满足了哪些条件、缺失了哪些。

教学注:后视镜叙事的识别标准: 如果一个理论框架对所有已发生的事件都能给出「相变」解释, 但对任何未来事件都无法给出确定性预测, 则该框架是后视镜叙事 (unfalsifiable narrative)。

陷阱:「后视镜叙事」不等于「错误叙事」——它可能正确描述了已发生的现象, 只是预测力为零; 科学的批评不是否认其描述价值, 而是指出其不能替代真正的预测理论。

题 4【中·辨析·不可逆性与非平衡框架】

导读:物理相变沿可逆路径进行 (可以沿相图来回穿越相变点, 系统可逆地从一相转到另一相); AI 能力涌现和文明涌现是不可逆的 (已习得的能力无法通过「降温」消除)。这是最弱的失效边界, 但指向了非平衡物理的正确框架。

(1) 热力学中的「可逆过程」要求系统始终处于准静态平衡。对比训练过程: - 物理相变 (可逆): 系统在任意时刻处于热力学平衡, 可以精确定义「平衡自由能」。- 神

经网络训练：参数在梯度流中运动，是否处于某种「平衡」？如果定义「损失极小值 = 平衡态」，给出这一类比的一个成立之处和一个失效之处。

(2) 「非平衡相变」(non-equilibrium phase transition) 理论中有一类叫做「吸收态相变」(absorbing state transition)：系统一旦进入吸收态就永远无法离开。

判断：AI 能力涌现是否更适合用「吸收态相变」框架而非平衡相变框架来描述？给出两条支持和一条反对的论据。

(3) 用一句话回答：为什么不可逆性是三条失效边界中「最弱」的一条（即对类比的伤害最小）？

教学注：「吸收态相变」（如 DP 普适类——定向渗流）是非平衡统计力学的核心研究对象，其临界指数与平衡相变完全不同；若 AI 涌现真的是吸收态相变，则平衡相变的所有临界指数都是错误的类比框架，不是「稍有不同」而是「框架整体替换」。

陷阱：「不可逆性」是三条中「最弱」的原因是：即使承认不可逆，形式上的幂律行为和序参量概念仍然可以在非平衡框架下保留；而「热力学极限缺失」和「后视镜叙事」则分别从存在性和预测性上根本否定了相变框架的核心主张。

题 5 【重·重评判·「相变类比是否合法」综合裁决】

导读：综合前四题的分析，本题要求对「AI 能力涌现 ↔ 物理相变」这一类比做出层次化的合法性裁决——不是简单的「合法/不合法」，而是「在什么条件下合法到什么程度」。

(1) 完成以下裁决框架表：

使用层次	类比合法性	条件
定性描述（「类似相变的急剧过渡」）	?	?
半定量（引用幂律形式，不引用具体指数）	?	?
定量（引用临界指数 $\beta = 0.5$ 等具体数值）	?	?
预测（「下一次涌现将在规模 X 时发生」）	?	?

(2) 渗流剪枝实验（幂律 $F(\bar{q}) \sim (\bar{q} - \bar{q}_c)^\beta$ ）对「相变类比」的支撑力度如何？它回答了哪个层次的问题，没有回答哪个层次的问题？

(3) 以下两位研究者持相反立场：

研究者 A：「相变框架给我们提供了分析 AI 涌现的数学工具，虽然不完美，但有框架比没有好；我们应该大胆使用。」

研究者 B：「相变类比在最严格意义上不成立（有限系统，无普适指数，后视镜叙事），继续使用会误导 AI 安全研究；应该完全放弃。」

分析两位研究者论证的合理性与局限性（各 3-4 句），然后给出你自己的折衷立场（3-4 句）。

教学注：科学类比的「合法使用」是科学哲学的核心问题之一——类比从来不需要在所有层面都成立才有价值，关键是明确说出「有效域」和「误用后果」。

陷阱：(3) 的折衷立场不是「各打五十大板」的模糊回答，而是需要给出具体的条件句：「在 X 条件下类比合法，在 Y 条件下应停止使用，理由是 Z」。

解答 § 5.9

T-5.9.1 【渗流剪枝与序参量行为】

(1) 比值计算：

$$\beta = 0.5, \bar{q}_c = 0.98.$$

$$F(0.99) \sim (0.99 - 0.98)^{0.5} = (0.01)^{0.5} = 0.1000$$

$$F(0.999) \sim (0.999 - 0.98)^{0.5} = (0.019)^{0.5} \approx 0.1379$$

$$\frac{F(0.99)}{F(0.999)} = \frac{0.1000}{0.1379} \approx 0.7253$$

$$(\text{精确: } \sqrt{0.01}/\sqrt{0.019} = \sqrt{0.01/0.019} = \sqrt{0.5263} \approx 0.7254)$$

(2) **严格零 vs 渐变：**在物理渗流中， $\bar{q} < \bar{q}_c$ 时导电率严格为零（无穿越路径）；在神经网络剪枝中， $\bar{q} < \bar{q}_c$ 时性能退化但不为零（网络仍可输出，只是质量低）。这揭示了类比局限：物理相变有严格的「有序相 / 无序相」二值分类，神经网络只有性能的连续退化；二值性的缺失是「crossover 而非 phase transition」的另一个表现。

(3) 数学区别：

- **真正相变：**序参量 $\phi(T)$ 在 $T = T_c$ 处不可微 ($d\phi/dT|_{T_c^-} \neq d\phi/dT|_{T_c^+}$)，或某阶导数发散；自由能的某阶导数在 T_c 处不连续。
- **Crossover：** $\phi(\bar{q})$ 在 $\bar{q} = \bar{q}_c$ 附近急剧变化，但所有阶导数均存在且有限；只是变化快，不是数学奇异。

Sanity check： $F(0.99)/F(0.999) \approx 0.7254$ ，保留 99.9% 参数比保留 99% 参数的性能高出约 38% ($0.1379/0.1000$)，体现了临界点附近的「放大效应」——这正是幂律行为的特征。

T-5.9.2 【热力学极限与有限系统的解析性】

(1) 解析性论证：

配分函数 $Z_N = \sum_{\{s_i\}} \exp(-\beta H(\{s_i\}))$ 是有限项 (2^N 项) 的有限正实数之和。每一项 $\exp(-\beta H)$ 对 β 都是实解析函数（指数函数无处奇异）；有限个解析函数之和仍是解析函数。因此 $Z_N(\beta) > 0$ 且关于 β 处处可微——自由能 $f_N = -\frac{1}{N} \ln Z_N$ 同样解析。非解析性（相变）只在 $N \rightarrow \infty$ 时因零点的热力学极限引起。■

(2) 伪临界区域宽度：

$$\Delta T \sim N^{-1/\nu} = (10^{10})^{-1} = 10^{-10} \quad (\nu = 1 \text{ 时}).$$

这意味着：即使大语言模型存在某种「临界点」，其「临界区域」宽度约为控制参数（如训练步数的对数）的 10^{-10} 量级——实验上完全无法分辨，只能看到一个陡峭但解析的 crossover。

(3) 论断评判：在热力学极限标准下不成立。 GPT-3 和 GPT-4 是有限参数系统，其自由能（若可定义）在任意点都是解析的，不存在真正的相变奇异性。「突然出现」是 crossover 在有限分辨率测量下的表现，没有普适临界指数，不能称为相变。

Sanity check： 伪临界区域 10^{-10} 远小于任何实验能分辨的尺度，这不是说明相变不存在，而是说明「即使有相变，有限系统效应使我们根本无法区分它与 crossover」。

T-5.9.3 【后视镜叙事与预测能力】

(1) 物理相变的预测能力基础：

朗道理论在观测涌现之前就知道：(a) 对称性决定了序参量是哪个量（如磁化强度）；(b) Landau 展开 $F = a(T - T_c)\phi^2 + b\phi^4 + \dots$ 给出先验形式；(c) 临界指数由对称性和维度决定（普适类）。这使预测成为可能：给定控制参数 T ，可以计算何时 $\phi \neq 0$ 。

(2) 后视镜叙事缺乏的要素：

- (A) 普适临界指数：缺乏。AI 涌现没有被归入任何已知的普适类，无法从对称性推导。
- (B) 序参量的先验定义：缺乏。每次涌现后才识别出对应的序参量（如「能做几步推理」），无法事前定义。
- (C) 控制参数的精确量化：部分缺乏。参数量、FLOP、数据量都是候选控制参数，但它们之间的关系和哪个是「真正的控制参数」尚无共识。
- (D) 热力学极限的存在：缺乏。有限参数系统，已在题 2 中分析。

(3) 有预测能力的涌现叙事最低要求：

- (1) 先验序参量：在涌现发生前定义序参量（什么量从 0 跃升为非零）；
- (2) 控制参数量化：明确单一控制参数及其与模型的对应关系；
- (3) 临界点预测：从理论（而非曲线拟合）给出 T_c 的预测，可被未来实验证伪；
- (4) 普适性主张：声明预测对一类模型（而非特定模型）成立，具备可复制性。

目前 AI 能力预测研究满足的条件：(2) 部分满足（scaling law 对参数量有量化关系）；缺失条件：(1)（序参量全部事后确认）、(3)（无理论推导的临界点）、(4)（普适类未建立）。

Sanity check： 四条最低要求与物理相变理论的「已知」对应——朗道理论满足全部四条，AI 涌现研究只满足一条。

T-5.9.4 【不可逆性与非平衡框架】

(1) 类比成立与失效：

成立之处：如果将「损失极小值」类比「热力学平衡态」，则「梯度下降收敛到极小

值」类比「弛豫到平衡」；两者都有「趋向更低能量/损失状态」的方向性（第二定律类比）。

失效之处：热力学平衡要求系统能够遍历所有微态（各态历经假设），神经网络的参数空间极高维度下梯度下降只探索了极小的局部区域，远非遍历——「平衡」概念无法全局成立；训练停止后参数固定，无法继续弛豫，与真正的平衡（时间平均=系综平均）相去甚远。

(2) 吸收态相变判断：

支持：① AI 习得的能力（如语言理解）一旦通过足够训练获得，在正常使用中不会消失——满足「进入吸收态不可离开」；② 能力涌现后性能快速趋于稳定，类似吸收态相变中序参量在转变后维持非零值；

反对：吸收态相变的「吸收态」是严格静止状态（不再发生转变），但已训练好的模型可以继续微调、持续学习，并非真正的「吸收态」——更接近亚稳态（metastable state）。

(3) 不可逆性最弱的原因：不可逆性失效边界只说明「需要非平衡框架而非平衡框架」，但幂律行为、序参量概念、临界放大效应在非平衡相变（如吸收态相变）中同样存在——换框架不必放弃形式结构，只需修改物理解释；而「热力学极限缺失」否定的是临界奇异性的存在，「后视镜叙事」否定的是预测能力，这两条从根本上打击了相变类比的核心理论。

Sanity check：三条失效边界的「强度」梯度：热力学极限（存在性级别）> 后视镜叙事（预测性级别）> 不可逆性（框架选择级别），与本节正文的层次划分一致。

T-5.9.5 【「相变类比是否合法」综合裁决】

(1) 裁决框架表：

使用层次	类比合法性	条件
定性描述（「类似相变的急剧过渡」）	合法	明确说明是 crossover 而非严格相变，不声明普适指数
半定量（引用幂律形式，不引用具体指数）	条件合法	仅用于描述渗流剪枝等实验的拟合结果，不外推至其他能力
定量（引用临界指数 $\beta = 0.5$ 等具体数值）	不合法	有限系统无普适临界指数，数值借用物理指数无理论依据

使用层次	类比合法性	条件
预测（「下一次涌现将在规模 X 时发生」）	不合法	后视镜叙事，无先验序参量和临界点推导，不具备预测能力

（2）渗流剪枝实验的支撑力度：

渗流剪枝实验在「半定量」层次提供了支撑——它展示了真实神经网络中存在急剧的性能-参数率拐点，以幂律形式拟合良好，为「类相变行为」提供独立实验证据。

它回答了：「神经网络是否存在类相变行为」（形式上是）和「幂律指数的量级」（ $\beta \sim 0.5$ ）。

它没有回答：「为什么是这个指数」（没有理论推导）；「该指数是否普适」（仅在剪枝实验中测量）；「能否预测能力涌现的临界规模」（无）。

（3）两位研究者分析与折衷立场：

研究者 A 的合理性：有框架确实比没有框架好——相变语言提供了一套工具（序参量、控制参数、临界指数）来**组织观察**，即使工具不完美也能推动研究的系统化；Scaling Law 研究（Kaplan et al., 2020）正是在某种「相变框架」的指引下发现了有用的幂律规律。**局限性：**「有框架比没有好」仅在框架被正确标注（明确声明局限）时成立；不加限制地使用错误框架会产生错误置信——「下一次 GPT 涌现将在 10^{13} FLOP 时发生」这类预测因为有了相变框架的光环而被过度相信，误导资源分配。

研究者 B 的合理性：三条失效边界均有严格数学基础，尤其「有限系统无真正相变」是定理级别的结论；AI 安全研究若依赖相变框架预测涌现时间线，会产生系统性错误（过度自信于不可靠的预测）。**局限性：**「完全放弃」走向了另一个极端——放弃相变语言意味着放弃描述急剧变化的现成词汇，而没有替代的定量框架；现有的「crossover」框架同样无法预测，只是缺少了「听起来更有预测力」的错觉，未必对研究更有益。

折衷立场：相变类比在「定性描述急剧变化」和「渗流剪枝等受控实验的半定量分析」范围内是合法的**工具**，应继续使用但明确附上边界声明；凡是引用具体临界指数或声称可以预测涌现时间的用法，应被视为越界并加以纠正；科学社群的责任是建立一套替代性框架（非平衡统计、有限系统 crossover 理论、信息论容量框架），而不是在旧框架内「大胆使用」或干脆弃用。

Sanity check：裁决表中四个层次与前四题的分析结果一一对应——定量和预测两层的「不合法」分别来自题 2（热力学极限）和题 3（后视镜叙事）的结论。

§ 7.6 将进入完全不同的技术领域，用类似的「统一视角」方法把 Mamba、线性注意力和 RNN 纳入同一框架——从批判性类比审查转向建设性统一理论。

第7章·新架构与未来方向

§7.6 习题：Mamba、线性注意力与 RNN 的统一视角

导读：本节核心是「广义线性递推统一序列模型」—— $\mathbf{S}_t = \mathbf{G}_t \odot \mathbf{S}_{t-1} + \mathbf{k}_t^\top \mathbf{v}_t$, $\mathbf{o}_t = \mathbf{S}_t \mathbf{q}_t$, 不同门控机制对应不同架构；Mamba-2 的 SSD 对偶实现了递推计算与矩阵乘法的等价切换。五题分别对应：A（广义递推推导）、B（门控机制辨析）、C（SSD 对偶数值计算）、D（GLA 低秩约束分析）、E（统一视角的边界评判）。

题1【轻·轻推导·广义线性递推的前向展开】

导读：广义线性递推 $\mathbf{S}_t = \mathbf{G}_t \odot \mathbf{S}_{t-1} + \mathbf{k}_t^\top \mathbf{v}_t$ 描述了一个随时间演化的状态矩阵，不同时刻的「贡献」以指数衰减（由 $\mathbf{G}$ 的累积乘积决定）进入当前状态。

(1) 设 $\mathbf{S}_0 = \mathbf{0}$ ，将 $\mathbf{S}_T = \mathbf{G}_T \odot \mathbf{S}_{T-1} + \mathbf{k}_T^\top \mathbf{v}_T$ 递归展开，写出 $\mathbf{S}_T$ 关于所有历史 $\{\mathbf{k}_t^\top \mathbf{v}_t\}_{t=1}^T$ 的显式求和表达式（用累积门控乘积表示）。

(2) 在线性注意力 ($\mathbf{G}_t = \mathbf{1}$, 全 1 矩阵) 的特殊情形下，化简 (1) 的结果，并说明输出 $\mathbf{o}_T = \mathbf{S}_T \mathbf{q}_T$ 如何对应标准线性注意力的矩阵形式。

(3) 在 RetNet ($\mathbf{G}_t = \gamma \mathbf{1}$, $0 < \gamma < 1$) 下，历史时刻 t 对 $\mathbf{S}_T$ 的贡献有什么衰减规律？这与 Transformer 的标准注意力在「长程依赖能力」上的本质差异是什么？

教学注：广义线性递推是 2023–2024 年序列模型研究的核心统一框架，将 RNN、线性注意力、RetNet、GLA、Mamba 全部纳入同一方程，使「门控机制的差异」成为可比较的设计选择。

陷阱：线性注意力中 $\mathbf{G}_t = \mathbf{1}$ 使历史贡献不衰减，这在理论上意味着无限长上下文，但实践中数值溢出和精度问题使之难以处理非常长的序列。

题2【中·概念辨析·门控机制的设计空间】

导读：不同架构对应广义线性递推中门控矩阵 $\mathbf{G}_t$ 的不同参数化选择，每种选择在「表达能力」、「计算效率」、「长程记忆」三个维度上有不同的权衡。

完成以下对比表，并回答后续问题：

架构	$\mathbf{G}_t$ 形式	参数依赖输入	长程记忆	典型计算模式
线性注意力	$\mathbf{1}$	否	无衰减	?
RetNet	$\gamma \mathbf{1}$ ($0 < \gamma < 1$)	否	?	?
GLA	$\alpha_t \beta_t^\top$ (低秩)	是	?	?
Mamba	$e^{\Delta_t A}$ (连续-离散化)	是	?	?

(1) 填写表格中的空白项（「?」位置）。

(2) Mamba 的门控 $\mathbf{G}_t = e^{\Delta_t A}$ 来自连续状态空间方程的离散化, $\Delta_t > 0$ 是输入依赖的时间步长。解释: Δ_t 较大时, $\mathbf{G}_t$ 中各项的量级如何变化, 这对序列模型的「选择性记忆」能力有何影响?

(3) GLA (Gated Linear Attention) 的门控 $\mathbf{G}_t = \alpha_t \beta_t^\top$ 是秩-1 矩阵。这一低秩约束的代价和收益分别是什么?

教学注:「参数依赖输入」(input-dependent gates) 是 Mamba 区别于 RetNet 的关键——后者的衰减系数 γ 固定, 无法根据内容选择性地保留或遗忘; 输入依赖使模型具备了「选择性扫描」(selective scan) 的能力。

陷阱:「无衰减」($\mathbf{G}_t = \mathbf{1}$) 不等于「记忆所有历史」——状态矩阵 $\mathbf{S}_t$ 的维度是有限的, 当历史项数量超过状态维度时, 仍会发生信息压缩和丢失, 只是不是显式的指数衰减。

题 3 【中 · 中计算 · Mamba-2 SSD 对偶的数值验证】

导读: Mamba-2 的 Structured State Space Duality (SSD) 将序列递推计算等价地重写为半分离矩阵乘法, 半分离矩阵的元素由 $M_{ij} = c_i \left(\prod_{t=j+1}^i \alpha_t \right) \beta_j \cdot \mathbf{1}_{i \geq j}$ 给出。这一对偶允许在不同计算条件下选择最优算法。

设序列长度 $T = 4$, 标量化 (1D 状态) 情形, $\alpha = (\alpha_1, \alpha_2, \alpha_3, \alpha_4) = (0.9, 0.8, 0.7, 0.6)$, $\beta = (1, 1, 1, 1)$, $c = (1, 1, 1, 1)$ 。

(1) 写出 4×4 半分离矩阵 M 的所有元素 (精确到四位小数)。

(2) 设输入向量 $\mathbf{v} = (1, 0, 0, 0)^\top$ (只有第一个位置有值), 计算输出 $\mathbf{o} = M\mathbf{v}$ 。

(3) 用递推方式验证 (2) 的结果: 从 $S_0 = 0$ 出发, 递推 $S_t = \alpha_t S_{t-1} + \beta_t v_t$, $o_t = c_t S_t$, 计算 $\mathbf{o} = (o_1, o_2, o_3, o_4)^\top$, 与 (2) 的结果对比。

教学注: SSD 对偶的意义在于: 当序列较短时, 矩阵乘法形式 ($O(T^2 d)$) 可用 GPU 的 tensor core 高度并行化; 当序列较长时, 递推形式 ($O(T d^2)$ 每步) 节省内存。Mamba-2 通过分块 (chunking) 动态选择模式, 实现 2–8× 的实际加速。

陷阱: 半分离矩阵是下三角矩阵 ($\mathbf{1}_{i \geq j}$), 注意 $i = j$ 时 $\prod_{t=j+1}^i \alpha_t$ 是空积 (empty product) $= 1$, 不要误写为 0。

题 4 【中 · 辨析 · GLA 的低秩约束与线性注意力的联系】

导读: GLA (Gated Linear Attention) 通过对门控矩阵施加秩-1 约束 $\mathbf{G}_t = \alpha_t \beta_t^\top$, 在线性注意力 ($\mathbf{G} = \mathbf{1}$, 满秩退化) 和 Mamba ($\mathbf{G} = e^{\Delta A}$, 满秩) 之间建立了一个桥梁。

(1) 证明: 当 $\alpha_t = \mathbf{1}$ (全 1 向量) 且 $\beta_t = \mathbf{1}$ (全 1 向量) 时, $\mathbf{G}_t = \alpha_t \beta_t^\top = \mathbf{1}\mathbf{1}^\top$ 是全 1 矩阵 (不是 $\mathbf{1}$ 的单位矩阵), GLA 退化为哪种架构? 说明为什么这不严格等于线性注意力的 $\mathbf{G} = \mathbf{1}$ (单位矩阵 vs 全 1 矩阵)。

(2) GLA 的门控 $\alpha_t, \beta_t \in \mathbb{R}^d$, 低秩约束 $\mathbf{G}_t = \alpha_t \beta_t^\top \in \mathbb{R}^{d \times d}$ 的秩最多为 1。与满秩 $\mathbf{G}_t$ (如 Mamba 的 $e^{\Delta A}$, 一般为满秩) 相比, 秩-1 约束减少了多少参数? (用 d 表示)

(3) 从表达能力角度, 秩-1 门控 $\mathbf{G}_t = \alpha_t \beta_t^\top$ 能捕捉哪类状态-输入交互? 哪类交互无法捕捉 (举一具体例子)?

教学注: GLA 的低秩约束是「效率-表达能力」权衡的典型例子——秩-1 门控可以分解为两个独立的 d 维向量的外积, 计算复杂度从 $O(d^2)$ 降至 $O(d)$, 但失去了状态维度间的耦合信息。

陷阱: $\mathbf{G}_t = \alpha_t \beta_t^\top$ 是外积 (rank-1 矩阵), $\|\mathbf{G}_t\|_F^2 = \|\alpha_t\|^2 \|\beta_t\|^2$, 不要误解为 Hadamard 乘积或逐元素操作。

题 5【重·重评判·统一视角的解释力与边界】

导读:「广义线性递推统一框架」将多种架构纳入同一方程, 提供了强大的设计空间分析工具。本题评估这一统一视角的解释力上限和下限。

(1) 「统一框架」的解释力评估: 对以下架构特性, 指出广义线性递推框架**能否**提供统一的定量分析:

- (A) 不同架构在相同参数量下的语言建模困惑度 (perplexity) 对比
- (B) 不同架构对「长文档理解」任务的能力差异
- (C) 不同架构训练时的数值稳定性差异
- (D) Mamba vs Transformer 在自回归生成时的显存占用

(2) 广义线性递推框架**不能**统一什么? 列出至少两类在此框架外但对序列模型性能有重要影响的因素。

(3) 判断以下论断:

「广义线性递推统一框架证明了 Mamba 和 Transformer 是等价的——既然都可以写成线性递推, 它们的表达能力相同。」

指出该论断的核心谬误所在 (不超过 4 句)。

(4) 从「统一视角」到「选择最优架构」, 还需要哪些额外信息? (3-4 条)

教学注: 统一框架的价值在于提供**分析语言** (用同一套符号比较不同架构的设计选择), 而非证明所有架构等价; 能在同一框架内表达, 不意味着在所有任务上性能相同。

陷阱: (3) 的谬误是「形式等价蕴含能力等价」——线性递推是计算**形式**的统一, 不是**计算能力**的统一; 线性注意力 ($\mathbf{G} = \mathbf{1}$) 和标准 Transformer (softmax 注意力) 在表达能力上有已知的理论差距 (后者可以计算任意精度的相似度权重, 前者不能)。

解答 § 7.6

T-7.6.1【广义线性递推的前向展开】

(1) 递归展开:

定义累积门控乘积 $\Gamma_{s:t} = \bigodot_{\tau=s+1}^t \mathbf{G}_\tau$ (从时刻 s 到 t 的逐元素累积乘积), $\Gamma_{t:t} = \mathbf{1}$ (空积)。

递推展开：

$$\mathbf{s}_T = \sum_{t=1}^T \Gamma_{t:T} \odot (\mathbf{k}_t^\top \mathbf{v}_t)$$

其中 $\Gamma_{t:T} = \mathbf{G}_{t+1} \odot \mathbf{G}_{t+2} \odot \cdots \odot \mathbf{G}_T$ ($t = T$ 时为 $\mathbf{1}$)。

(2) 线性注意力特例：

$\mathbf{G}_t = \mathbf{1}$ 时, $\Gamma_{t:T} = \mathbf{1}$ 对所有 t , 故

$$\mathbf{s}_T = \sum_{t=1}^T \mathbf{k}_t^\top \mathbf{v}_t$$

输出 $\mathbf{o}_T = \mathbf{s}_T \mathbf{q}_T = \left(\sum_{t=1}^T \mathbf{k}_t^\top \mathbf{v}_t \right) \mathbf{q}_T = \sum_{t=1}^T \mathbf{k}_t (\mathbf{v}_t \cdot \mathbf{q}_T)$,

对应线性注意力矩阵形式: $O = (K^\top V)Q$ (将 K, V, Q 按时间步堆叠), 与标准线性注意力完全一致。

(3) RetNet 的衰减规律：

$\mathbf{G}_t = \gamma \mathbf{1}$ 时, $\Gamma_{t:T} = \gamma^{T-t} \mathbf{1}$, 时刻 t 的贡献以 γ^{T-t} 指数衰减。

本质差异: Transformer 标准注意力通过 softmax 计算动态权重, 每个位置的注意力权重由内容相似度决定, 原则上可以对任意远的位置赋予高权重 (无固定衰减); RetNet 的衰减 γ^{T-t} 是固定的、内容无关的, 无法选择性地记住距离较远但重要的内容——这是线性/RetNet 与 Transformer 在长程依赖建模上的本质差距。

Sanity check: (2) 的矩阵形式 $(K^\top V)Q$ 正是线性注意力论文 (Katharopoulos et al., 2020) 中的核心公式, 展开与文献一致。

T-7.6.2 【门控机制的设计空间】

(1) 完整表格：

架构	$\mathbf{G}_t$ 形式	参数依赖输入	长程记忆	典型计算模式
线性注意力	$\mathbf{1}$	否	无衰减 ($\gamma = 1$)	递推或矩阵乘法等价
RetNet	$\gamma \mathbf{1}$ ($0 < \gamma < 1$)	否	指数衰减 (固定 γ)	递推 (推理) / 并行 (训练)
GLA	$\alpha_t \beta_t^\top$ (低秩)	是	内容依赖衰减	分块递推
Mamba	$e^{\Delta_t A}$ (连续-离散化)	是	选择性衰减	并行扫描 (CUDA kernel)

(2) Mamba 选择性记忆：

Δ_t 较大时, $e^{\Delta_t A}$ 中各项 (A 负定, 特征值为负实数) 趋向 0 ($e^{\Delta_t \lambda_i} \rightarrow 0$ 当 $\Delta_t |\lambda_i| \gg 1$), 即历史状态被「遗忘」得更快; Δ_t 较小时遗忘慢, 历史保留更多。由于 Δ_t 依赖当前输入, 模型可以对「信息量大的 token」使用小 Δ_t (慢遗忘, 长记忆)、对「无信息 token」使用大 Δ_t (快遗忘), 实现内容驱动的选择性记忆。

(3) 低秩约束的代价与收益:

收益: 计算量从 $O(d^2)$ (存储或应用满秩矩阵) 降至 $O(d)$ (存储两个 d 维向量 α_t, β_t); 与线性注意力的递推形式兼容, 保持硬件友好的 IO 模式。

代价: 秩-1 门控无法在状态不同维度之间引入耦合—— $(\mathbf{G}_t \odot \mathbf{S}_{t-1})_{ij} = \alpha_t^{(i)} \beta_t^{(j)} S_{t-1}^{(ij)}$, 每个状态元素的衰减系数可以不同, 但不能让第 i 维的衰减依赖第 j 维的当前值 (无跨维度信息流)。

Sanity check: 表格四行的「参数依赖输入」列中, 线性注意力和 RetNet 为「否」, GLA 和 Mamba 为「是」, 这正是 Mamba 系列架构相对 RetNet 的核心进步。

T-7.6.3 【Mamba-2 SSD 对偶的数值验证】

(1) 半分离矩阵计算:

$$M_{ij} = c_i \left(\prod_{t=j+1}^i \alpha_t \right) \beta_j \cdot \mathbf{1}_{i \geq j}, \quad c = \beta = \mathbf{1}, \quad \alpha = (0.9, 0.8, 0.7, 0.6)。$$

$$\text{空积 } (i = j): \prod_{t=j+1}^j = 1。$$

计算各元素:

- $M_{11} = 1 \cdot 1 \cdot 1 = 1.0000$ (空积)
- $M_{21} = 1 \cdot \alpha_2 \cdot 1 = 0.8000$
- $M_{22} = 1 \cdot 1 \cdot 1 = 1.0000$
- $M_{31} = 1 \cdot \alpha_2 \alpha_3 \cdot 1 = 0.8 \times 0.7 = 0.5600$
- $M_{32} = 1 \cdot \alpha_3 \cdot 1 = 0.7000$
- $M_{33} = 1 \cdot 1 \cdot 1 = 1.0000$
- $M_{41} = 1 \cdot \alpha_2 \alpha_3 \alpha_4 \cdot 1 = 0.8 \times 0.7 \times 0.6 = 0.3360$
- $M_{42} = 1 \cdot \alpha_3 \alpha_4 \cdot 1 = 0.7 \times 0.6 = 0.4200$
- $M_{43} = 1 \cdot \alpha_4 \cdot 1 = 0.6000$
- $M_{44} = 1 \cdot 1 \cdot 1 = 1.0000$

$$M = \begin{pmatrix} 1.0000 & 0 & 0 & 0 \\ 0.8000 & 1.0000 & 0 & 0 \\ 0.5600 & 0.7000 & 1.0000 & 0 \\ 0.3360 & 0.4200 & 0.6000 & 1.0000 \end{pmatrix}$$

(2) 矩阵乘法:

$$\mathbf{v} = (1, 0, 0, 0)^\top, \quad \mathbf{o} = M\mathbf{v} = M \text{ 的第一列} = (1.0000, 0.8000, 0.5600, 0.3360)^\top。$$

(3) 递推验证:

- $t = 1: S_1 = \alpha_1 \cdot 0 + \beta_1 v_1 = 0.9 \cdot 0 + 1 \cdot 1 = 1.0000, \quad o_1 = c_1 S_1 = 1.0000$
- $t = 2: S_2 = \alpha_2 S_1 + \beta_2 v_2 = 0.8 \times 1 + 1 \times 0 = 0.8000, \quad o_2 = 0.8000$

- $t = 3$: $S_3 = \alpha_3 S_2 + \beta_3 v_3 = 0.7 \times 0.8 + 0 = 0.5600$, $o_3 = 0.5600$
- $t = 4$: $S_4 = \alpha_4 S_3 + \beta_4 v_4 = 0.6 \times 0.56 + 0 = 0.3360$, $o_4 = 0.3360$

$\mathbf{o} = (1.0000, 0.8000, 0.5600, 0.3360)^\top$, 与 (2) 完全一致。■

Sanity check: 递推与矩阵乘法给出完全相同的结果, 验证了 SSD 对偶的正确性; 注意 M_{i1} 的值正好等于 $\prod_{t=2}^i \alpha_t$ (从 α_2 开始的累积乘积), 数值模式清晰。

T-7.6.4 【GLA 的低秩约束与线性注意力的联系】

(1) 退化分析:

$\mathbf{G}_t = \alpha_t \beta_t^\top$, 当 $\alpha_t = \beta_t = \mathbf{1}$ (d 维全 1 向量) 时, $\mathbf{G}_t = \mathbf{1}\mathbf{1}^\top$, 这是全 1 矩阵 (每个元素均为 1)。

广义线性递推变为 $\mathbf{S}_t = (\mathbf{1}\mathbf{1}^\top) \odot \mathbf{S}_{t-1} + \mathbf{k}_t^\top \mathbf{v}_t = \mathbf{S}_{t-1} + \mathbf{k}_t^\top \mathbf{v}_t$ (因为 $\mathbf{1}\mathbf{1}^\top \odot \mathbf{S}_{t-1} = \mathbf{S}_{t-1}$ 仅当 $\mathbf{S}_{t-1}$ 的所有元素乘以 1, 实际上 $(\mathbf{1}\mathbf{1}^\top)_{ij} = 1$ 对所有 i, j , 所以 Hadamard 积结果是 $\mathbf{S}_{t-1}$ 自身), 退化为线性注意力的无衰减递推。

严格区别: 线性注意力的 $\mathbf{G}_t = \mathbf{I}$ 通常指单位矩阵 (identity, $\mathbf{G}_t = \mathbf{I}$, Hadamard 乘以 $\mathbf{I}$ 等价于不改变), 而 GLA 退化的 $\mathbf{G}_t = \mathbf{1}\mathbf{1}^\top$ 是全 1 矩阵, 两者对角线元素相同 (均为 1) 但非对角元素不同 (全 1 矩阵为 1, 单位矩阵为 0) —— 在 Hadamard 乘法下, 全 1 矩阵与状态的乘积保留所有元素, 而单位矩阵只保留对角元素。

(2) 参数减少量:

满秩 $\mathbf{G}_t \in \mathbb{R}^{d \times d}$ 需要 d^2 个参数 (作为自由参数)。

秩-1 $\mathbf{G}_t = \alpha_t \beta_t^\top$ 只需 $2d$ 个参数 (d 维 α_t 加 d 维 β_t)。

减少量: $d^2 - 2d = d(d - 2)$, 当 $d \gg 2$ 时约减少 $d^2 - 2d \approx d^2$ 个参数, 即参数量降至 $O(d)$ 而非 $O(d^2)$ 。

(3) 表达能力分析:

秩-1 门控能捕捉的: 每个状态维度 i 的衰减率 $\alpha_t^{(i)}$ 可以独立变化 (维度级别的选择性衰减), 同时每个维度接收新信息的权重 $\beta_t^{(j)}$ 也独立可变; 这已经比 RetNet 的固定 γ 灵活很多。

无法捕捉的: 跨维度耦合。例如「当第 3 维度的状态值较高时, 降低第 7 维度的衰减率」——这需要 $\mathbf{G}_t$ 中 (3, 7) 位置的非零非分解元素, 秩-1 矩阵无法表达任意的 (i, j) 耦合。

Sanity check: 参数减少量 $d^2 - 2d$ 对 $d = 64$ 时约为 $4096 - 128 = 3968$, 降幅约 97%; 这正是 GLA 的高效来源。

T-7.6.5 【统一视角的解释力与边界】

(1) 解释力评估:

- (A) 能 (有限制): 广义线性递推框架通过比较不同 $\mathbf{G}_t$ 的表达能力, 可以给出困惑度差异的定性预测 (表达能力更强的架构通常困惑度更低), 但精确数值需要实验。

- (B) **部分能**：对长程依赖能力，框架可以定量分析历史衰减率 (G_t 的谱半径)，但实际长文档理解还依赖训练数据分布、位置编码等框架外因素。
- (C) **不能**：数值稳定性依赖梯度流的具体性质（梯度消失/爆炸）、激活函数、归一化层等，不在广义线性递推的状态更新方程中体现。
- (D) **能**：Mamba 推理时每步只需 $O(d^2)$ 状态，固定大小；Transformer 需要 KV-cache，随序列长度线性增长——这可以从递推（有界状态）vs 注意力（累积 KV）的框架差异直接推断。

(2) 框架外的重要因素：

① 非线性激活函数和归一化层 (LayerNorm、RMSNorm) 对最终性能有重要影响，不在线性递推框架内；② 位置编码 (RoPE、ALiBi) 决定了序列位置信息的引入方式，对长序列泛化至关重要，框架中未体现；③ 训练目标（语言建模 loss 的 token 权重分配、batch 构造）和数据质量对性能的影响是框架外因素。

(3) 论断的核心谬误：

「能写成同一形式」（计算形式的统一）不等于「表达能力相同」（函数类的等价）。广义线性递推统一的是**状态更新的计算图结构**，不是**可以计算的函数集合**；线性注意力 ($G = I$) 的输出是输入序列的线性函数，而标准 Transformer (softmax 注意力) 输出是输入的非线性函数——即使后者在数值精度极高时也无法被前者精确表达。此外，「等价」在理论计算机科学中有精确含义（两个模型对所有输入给出相同输出），而非「用同一套符号描述」。

(4) 选择最优架构还需要：

① 目标任务的序列长度分布（短序列时 Transformer 有硬件优势，长序列时递推架构内存优势显著）；② 任务对长程依赖的依赖程度（固定衰减 vs 输入依赖衰减的选择）；③ 硬件平台特性（不同架构在不同 GPU/TPU 上的实际吞吐量差异）；④ 预训练数据规模（大数据下更复杂的架构收益更大，小数据下简单架构过拟合风险低）。

Sanity check：(3) 的谬误指向「形式 $\neq$ 能力」，这是计算理论的基本原则；(4) 的四条均属于「架构选择的上下文因素」，与统一框架提供的「架构描述能力」正交。

§ 7.7 将进入扩散语言模型，用同样精准的数学语言处理另一类「统一框架」——ELBO 变分推断如何将 DDPM、分数匹配和离散扩散纳入同一目标函数体系。

§ 7.7 习题：扩散语言模型的数学

导读：本节核心是「扩散过程的变分推断基础」——ELBO 将生成模型的学习分解为重建项与 KL 正则项，DDPM 通过代数化简将 ELBO 等价转化为去噪分数匹配损失，离散扩散 (MDLM) 将吸收态转移矩阵引入文本域。五题分别对应：A (ELBO 变分推导)、B (DDPM 损失代数化简)、C (前向过程边际计算)、D (离散扩散 MDLM 目标辨析)、E (与自回归模型的评判对比)。

题 1 【中 · 中推导 · ELBO 的变分推断基础】

导读：变分自由能 (ELBO) 是扩散模型数学基础的根基，理解它的推导过程比记住公式更重要——ELBO 同时出现在 VAE、扩散模型、Friston 的主动推断中，是生成模型的统一语言。

设生成模型 $p_\theta(x, z) = p_\theta(x|z)p(z)$ ，观测变量 x ，隐变量 z ，变分分布 $q_\phi(z|x)$ 。

(1) 从对数似然 $\log p_\theta(x)$ 出发，引入 $q_\phi(z|x)$ ，推导 ELBO：

$$\log p_\theta(x) = \text{ELBO}(q, \theta, x) + D_{\text{KL}}(q_\phi(z|x) \| p_\theta(z|x))$$

其中 $\text{ELBO} = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)] - D_{\text{KL}}(q_\phi(z|x) \| p(z))$ ，写出详细代数步骤。

(2) 验证：由 $D_{\text{KL}} \geq 0$ ，ELBO 是 $\log p_\theta(x)$ 的下界。等号在什么条件下成立？

(3) 扩散模型中，隐变量 $z = x_{1:T}$ (所有中间噪声状态)，前向过程 $q(x_{1:T}|x_0)$ 扮演变分分布 $q_\phi(z|x)$ 的角色 (无需优化 ϕ ， q 固定)。将 ELBO 的 KL 项和重建项分别对应到扩散模型的「先验匹配损失」和「重建损失」(用 $q(x_{1:T}|x_0)$ 和 p_θ 表示)。

教学注：ELBO 的三种等价表达 (重建项-KL、证据-KL、自由能-对数似然) 在不同上下文中各有便利；扩散模型的 ELBO 推导中，重建项分解为每一步的去噪误差，是 DDPM 损失化简的出发点。

陷阱：(1) 中引入 q 的技巧是「乘以 $q/q = 1$ 」后取对数，等号成立当且仅当 $q_\phi(z|x) = p_\theta(z|x)$ ，即变分分布等于真实后验——这在扩散模型中可以近似实现 (Tweedie 公式)。

题 2 【重 · 重推导 · DDPM 损失的代数化简】

导读：Ho et al. (2020) 的关键贡献之一是将复杂的 ELBO 化简为简单的去噪目标——这需要连续三步代数操作：(1) 利用 Markov 性分解 KL 项，(2) 对 $q(x_{t-1}|x_t, x_0)$ 配方，(3) 用重参数化消去 x_0 依赖，最终得到噪声预测损失。

设 DDPM 前向过程 $q(x_t|x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I)$ ， $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$ ，用重参数化表示 $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon$ ， $\epsilon \sim \mathcal{N}(0, I)$ 。

(1) 写出 DDPM 的 ELBO (以 KL 项之和的形式)：

$$-\text{ELBO} = \underbrace{D_{\text{KL}}(q(x_T|x_0)\|p(x_T))}_{L_T} + \sum_{t=2}^T \underbrace{D_{\text{KL}}(q(x_{t-1}|x_t, x_0)\|p_\theta(x_{t-1}|x_t))}_{L_{t-1}} \underbrace{-\log p_\theta(x_0|x_1)}_{L_0}$$

不需要详细推导，但需说明每一项的物理含义。

(2) 关键步骤：证明 $q(x_{t-1}|x_t, x_0)$ 是高斯分布（利用 Bayes 定理和高斯乘积），写出其均值 $\tilde{\mu}_t(x_t, x_0)$ 和方差 $\tilde{\beta}_t$ ：

$$\tilde{\mu}_t(x_t, x_0) = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t}x_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}x_t, \quad \tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}\beta_t$$

(3) 代数化简的核心步骤：

将 $x_0 = (x_t - \sqrt{1 - \bar{\alpha}_t}\epsilon)/\sqrt{\bar{\alpha}_t}$ 代入 $\tilde{\mu}_t(x_t, x_0)$ ，化简得到 $\tilde{\mu}_t = \frac{1}{\sqrt{\bar{\alpha}_t}}\left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}}\epsilon\right)$ 。

设模型预测 $\mu_\theta(x_t, t) = \frac{1}{\sqrt{\bar{\alpha}_t}}\left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}}\epsilon_\theta(x_t, t)\right)$ ，写出 L_{t-1} 中 KL 散度（两个高斯）的显式表达式，并说明为什么最终简化为噪声预测损失 $\mathbb{E}[\|\epsilon - \epsilon_\theta(x_t, t)\|^2]$ （忽略方差相关的常数因子）。

(4) **化简结果**：写出 DDPM 的最终训练目标（简化版）：

$$\mathcal{L}_{\text{DDPM}} = \mathbb{E}_{t \sim \mathcal{U}[1, T], x_0, \epsilon \sim \mathcal{N}(0, I)} [\|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, t)\|^2]$$

说明该目标与分数匹配（Score Matching）的等价性（ $\epsilon_\theta \propto -\nabla_{x_t} \log q(x_t|x_0)$ 方向）。

教学注：Ho et al. (2020) 在论文中将 (3) 步中的前置权重因子（ $\beta_t^2/(2\sigma_t^2\alpha_t(1 - \bar{\alpha}_t))$ ）设为常数 1，这是一个关键的「简化选择」，实验上效果更好，理论上是对 ELBO 的加权（等价于重要性采样的变体）。

陷阱：(3) 的两个高斯 KL 散度公式为 $D_{\text{KL}}(\mathcal{N}(\mu_1, \sigma^2)\|\mathcal{N}(\mu_2, \sigma^2)) = (\mu_1 - \mu_2)^2/(2\sigma^2)$ （等方差情形），在此条件下 KL 正比于均值差的平方——这是化简的关键。

题 3 【中 · 中计算 · DDPM 前向过程的边际分布】

导读：DDPM 前向过程的最重要数学性质是「任意时刻的边际分布 $q(x_t|x_0)$ 有闭合形式」——这使得训练时可以直接采样任意时刻 t 的噪声版本，无需逐步运行前向链。

设 $\beta_1 = \beta_2 = \dots = \beta_T = \beta$ （等方差噪声调度）， $T = 1000$ ， $\beta = 0.02$ 。

(1) 计算 $\bar{\alpha}_T = \prod_{t=1}^{1000} (1 - 0.02)^{1000} = 0.98^{1000}$ （精确到四位有效数字，用对数辅助）。

(2) 解释 $\bar{\alpha}_T \approx 0$ 的物理含义： $q(x_T|x_0)$ 近似什么分布？为什么这对扩散模型的逆向过程是必要的？

(3) 设在时刻 $t^* = 100$ ， $\bar{\alpha}_{t^*} = 0.98^{100}$ （计算精确值）。此时 $q(x_{t^*}|x_0)$ 中， x_0 的信号权重和噪声权重分别是多少？直观描述这意味着什么。

(4) 等方差噪声调度的缺点是什么？实践中为什么倾向于使用余弦调度（cosine schedule）？（用 $\bar{\alpha}_t$ 的曲率变化解释）

教学注：DDPM 原论文 (Ho et al., 2020) 使用线性 β 调度, Improved DDPM (Nichol & Dhariwal, 2021) 引入余弦调度, 将 $\bar{\alpha}_t = \cos^2(\frac{t/T+s}{1+s} \cdot \frac{\pi}{2})$ 使得噪声添加更平滑, 训练更稳定。

陷阱： $\bar{\alpha}_t$ 是累积乘积而非算术平均, $\bar{\alpha}_{t+1} = \bar{\alpha}_t \cdot (1 - \beta_{t+1})$ 总是严格小于 $\bar{\alpha}_t$ (单调递减), 不要和其他调度参数混淆。

题4【中·概念辨析·离散扩散与 MDLM 目标】

导读：将扩散模型推广到离散文本域需要用「转移矩阵」替代高斯核——吸收态 (MASK token) 设计是目前最成功的方案, Sahoo et al. (2024) 的 MDLM 进一步将目标简化为加权 MLM 损失。

设词表大小 V , 特殊 MASK token 为 M , 吸收态转移矩阵 $Q_t = (1 - \beta_t)I + \beta_t \mathbf{1}e_M^\top$ (其中 e_M 是 M 的 one-hot 向量)。

(1) 解释转移矩阵 Q_t 的行为: 以概率 $1 - \beta_t$ 保持不变, 以概率 β_t 变为 M 。证明: 边际分布 $q(x_t|x_0)$ 的闭合形式为

$$q(x_t|x_0) = \bar{\alpha}_t \delta_{x_t, x_0} + (1 - \bar{\alpha}_t) \delta_{x_t, M}$$

(其中 $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$, δ 为 Kronecker delta)。

(2) 吸收态设计与连续扩散的「各向同性高斯噪声」相比, 有何核心优势? (从文本 token 的离散性角度讨论, 2-3 句)

(3) MDLM 的简化训练目标为:

$$\mathcal{L}_{\text{MDLM}} = -\mathbb{E}_{t, x_0} \left[\frac{|\alpha'_t|}{\alpha_t} \sum_{i: x_t^{(i)} = M} \log p_\theta(x_0^{(i)} | x_t) \right]$$

其中 $\alpha'_t = d\alpha_t/dt$ 。解释: (a) 为什么求和只对 MASK 的位置 i 进行? (b) 权重 $|\alpha'_t|/\alpha_t$ 的直觉含义是什么 (类比「时刻 t 的信息增益」)?

教学注：MDLM 的目标本质上是加权的 Masked Language Modeling (MLM) 损失—— t 越小 (噪声少), 权重越大 (对每个 MASK 位置, 预测原始 token 更容易, 给予更大的损失权重); 这与 BERT 的等权 MLM 的本质区别是理解 MDLM 的关键。

陷阱：(3) 中 $\alpha'_t = d\alpha_t/dt$ 在离散时间版本中需要理解为差分 ($\alpha_{t-1} - \alpha_t$), $|\alpha'_t|/\alpha_t$ 始终为正 (α_t 单调递减, $\alpha'_t < 0$), 不要误算符号。

题5【重·重评判·扩散语言模型 vs 自回归模型】

导读：扩散语言模型 (Diffusion LM) 的兴起引发了与自回归 (AR) 模型的系统性对比, 两者在「消除曝光偏差」、「并行解码」、「推理步数」三个维度上各有得失——理解这些权衡是评估实用价值的前提。

(1) 「消除逆向诅咒 (reversal curse)」: AR 模型在训练时只看到「A 导致 B」式的顺序, 无法推断「B 导致 A」; 扩散模型因为并行生成不依赖固定的生成顺序, 理论上应该避免这一问题。

判断: 「扩散语言模型在所有需要双向推理的任务上性能必然优于 AR 模型。」这一论断是否成立? 指出两处不严谨之处。

(2) 推理效率对比: AR 模型生成 L 个 token 需要 L 步, 每步计算量 $O(L \cdot d^2)$ (含 KV-cache); DDPM 风格的扩散语言模型生成 L 个 token 需要 T_{diff} 步 ($T_{\text{diff}} \in [64, 256]$), 每步计算量 $O(L \cdot d^2)$ (无 KV-cache 优势, 但全并行)。

设 $L = 512$, $T_{\text{diff}} = 128$, 计算两种方案的总计算步数比, 并讨论: 在什么场景下扩散语言模型的并行性优势能弥补多步推理的劣势?

(3) 「曝光偏差 (exposure bias)」问题: AR 模型训练时以真实 token 为条件 (teacher forcing), 推理时以自身生成的 token 为条件, 分布漂移导致错误累积。扩散语言模型如何从结构上消除这一问题?

(4) 综合评判: 对以下场景分别给出推荐架构 (AR / 扩散 / 两者皆可) 及理由:

- (A) 实时对话系统 (延迟敏感, 需要逐 token 流式输出)
- (B) 创意写作 (要求高多样性, 长文本一致性)
- (C) 代码生成 (严格语法约束, 填充任务 FIM)
- (D) 机器翻译 (严格对齐, 质量优先于延迟)

教学注: 扩散语言模型当前 (2024–2025) 的主要瓶颈是多步推理的延迟, 但在需要全局一致性 (创意写作) 和填充任务 (FIM) 的场景中展现出结构优势; 随着蒸馏技术 (diffusion distillation) 将步数压缩到 4–16 步, 延迟差距正在快速缩小。

陷阱: (2) 中「AR 需要 L 步」是在有 KV-cache 且一步生成一个 token 的情形下; 批量推理时 AR 同样可以并行 (不同序列之间), 但单条序列的 token 之间必须串行——这是与扩散模型的关键区别。

解答 § 7.7

T-7.7.1 【ELBO 的变分推断基础】

(1) ELBO 推导 (详细步骤):

$$\log p_{\theta}(x) = \log \int p_{\theta}(x, z) dz = \log \int \frac{p_{\theta}(x, z)}{q_{\phi}(z|x)} q_{\phi}(z|x) dz$$

由 Jensen 不等式 ($\log$ 为凹函数):

$$\log p_{\theta}(x) \geq \int q_{\phi}(z|x) \log \frac{p_{\theta}(x, z)}{q_{\phi}(z|x)} dz = \mathbb{E}_{q_{\phi}}[\log p_{\theta}(x, z) - \log q_{\phi}(z|x)]$$

展开 $\log p_{\theta}(x, z) = \log p_{\theta}(x|z) + \log p(z)$:

$$\begin{aligned}
&= \mathbb{E}_{q_\phi}[\log p_\theta(x|z)] + \mathbb{E}_{q_\phi}[\log p(z) - \log q_\phi(z|x)] \\
&= \underbrace{\mathbb{E}_{q_\phi}[\log p_\theta(x|z)]}_{\text{重建项}} - \underbrace{D_{\text{KL}}(q_\phi(z|x) \| p(z))}_{\text{KL 正则项}} = \text{ELBO}
\end{aligned}$$

等式版本（无 Jensen 不等式）：

$$\log p_\theta(x) = \text{ELBO} + D_{\text{KL}}(q_\phi(z|x) \| p_\theta(z|x)) \quad \blacksquare$$

（由 $\log p_\theta(x) = \mathbb{E}_q[\log(p_\theta(x, z)/q_\phi(z|x))] + \mathbb{E}_q[\log(q_\phi(z|x)/p_\theta(z|x))]$ ，后一项即 D_{KL} 。）

(2) 下界验证： $D_{\text{KL}} \geq 0$ （Gibbs 不等式），故 $\log p_\theta(x) \geq \text{ELBO}$ ，等号成立当且仅当 $q_\phi(z|x) = p_\theta(z|x)$ （变分分布等于真实后验）。■

(3) 扩散模型中的对应：

- KL 正则项（先验匹配损失 L_T ）： $D_{\text{KL}}(q(x_T|x_0) \| p(x_T))$ ，要求最终噪声分布与先验 $\mathcal{N}(0, I)$ 匹配。
- 重建项（逐步去噪损失 L_{t-1} ）： $\sum_{t=2}^T D_{\text{KL}}(q(x_{t-1}|x_t, x_0) \| p_\theta(x_{t-1}|x_t))$ ，要求模型学会反转每一步加噪过程。
- L_0 ： $-\log p_\theta(x_0|x_1)$ ，最后一步的重建损失。

Sanity check：(1) 的推导关键步骤是「乘以 q/q 」后用 Jensen 给出不等式，再用 $\log p(x, z) = \log p(x|z) + \log p(z)$ 分解——这两步与 VAE 的 ELBO 推导完全相同，体现了扩散模型是 VAE 的分层推广。

T-7.7.2 【DDPM 损失的代数化简】

(1) ELBO 各项含义：

- L_T ：前向过程终端与先验的匹配损失，若 β 足够小则近似为常数，通常忽略。
- L_{t-1} （ $t = 2, \dots, T$ ）：每一步逆向去噪的 KL 散度，衡量模型对后验 $q(x_{t-1}|x_t, x_0)$ 的逼近质量——这是训练的主要信号。
- L_0 ：从 x_1 恢复 x_0 的对数似然，通常用离散化的高斯 CDF 建模。

(2) $q(x_{t-1}|x_t, x_0)$ 的均值和方差：

由 Bayes 定理： $q(x_{t-1}|x_t, x_0) \propto q(x_t|x_{t-1})q(x_{t-1}|x_0)$ ，两个高斯的乘积仍是高斯。

代入 $q(x_t|x_{t-1}) = \mathcal{N}(\sqrt{\alpha_t}x_{t-1}, \beta_t I)$ ， $q(x_{t-1}|x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_{t-1}}x_0, (1 - \bar{\alpha}_{t-1})I)$ ，配方得：

$$\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t}x_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}x_t, \quad \tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}\beta_t \quad \blacksquare$$

(3) 噪声预测化简：

代入 $x_0 = (x_t - \sqrt{1 - \bar{\alpha}_t}\epsilon)/\sqrt{\bar{\alpha}_t}$ ：

$$\begin{aligned}\tilde{\mu}_t &= \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} \cdot \frac{x_t - \sqrt{1-\bar{\alpha}_t}\epsilon}{\sqrt{\bar{\alpha}_t}} + \frac{\sqrt{\bar{\alpha}_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}x_t \\ &= \frac{1}{\sqrt{\bar{\alpha}_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon \right)\end{aligned}$$

(合并系数后化简, 利用 $\bar{\alpha}_t = \alpha_t \bar{\alpha}_{t-1}$ 和 $\beta_t = 1 - \alpha_t$ 。)

两个方差相同 ($\tilde{\beta}_t$) 的高斯之间的 KL 散度:

$$L_{t-1} = D_{\text{KL}}(\mathcal{N}(\tilde{\mu}_t, \tilde{\beta}_t I) \parallel \mathcal{N}(\mu_\theta, \tilde{\beta}_t I)) = \frac{1}{2\tilde{\beta}_t} \|\tilde{\mu}_t - \mu_\theta\|^2$$

代入 $\tilde{\mu}_t$ 和 μ_θ 的表达式, 两者之差正比于 $(\epsilon - \epsilon_\theta)$:

$$L_{t-1} \propto \frac{\beta_t^2}{2\tilde{\beta}_t \alpha_t (1 - \bar{\alpha}_t)} \|\epsilon - \epsilon_\theta(x_t, t)\|^2$$

Ho et al. 将前置系数设为常数 1 (经验上效果更好), 得到简化损失。

(4) DDPM 最终目标:

$$\mathcal{L}_{\text{DDPM}} = \mathbb{E}_{t, x_0, \epsilon} [\|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon, t)\|^2]$$

分数匹配等价性: $\nabla_{x_t} \log q(x_t|x_0) = -\epsilon/\sqrt{1-\bar{\alpha}_t}$ (由 $q(x_t|x_0)$ 对 x_t 求梯度), 故 $\epsilon_\theta \approx -\sqrt{1-\bar{\alpha}_t} \nabla_{x_t} \log q(x_t|x_0)$, 预测噪声等价于估计分数函数 (即对数密度梯度)——这正是 Score Matching 的目标。

Sanity check: 化简中「两个等方差高斯的 KL 等于均值差平方除以两倍方差」是关键恒等式; 若方差不同 (如 DDPM 中 Σ_θ 也参与训练), 则 KL 还包含方差项, 化简会更复杂。

T-7.7.3 【DDPM 前向过程的边际分布】

(1) $\bar{\alpha}_T$ 计算:

$$\bar{\alpha}_T = 0.98^{1000}$$

$$\ln(0.98^{1000}) = 1000 \ln(0.98) = 1000 \times (-0.020203) = -20.203$$

$$\bar{\alpha}_T = e^{-20.203} \approx 1.675 \times 10^{-9}$$

精确到四位有效数字: $\bar{\alpha}_T \approx 1.675 \times 10^{-9} \approx 0.0000$ (实际接近 0)。

(2) 物理含义：

$\bar{\alpha}_T \approx 0$ 时, $q(x_T|x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_T}x_0, (1 - \bar{\alpha}_T)I) \approx \mathcal{N}(0, I)$ ——即 $q(x_T|x_0)$ 近似为标准高斯, 与原始数据 x_0 无关。这是必要的: 逆向过程从纯高斯噪声 $p(x_T) = \mathcal{N}(0, I)$ 开始, 若前向过程的终态与 x_0 仍有关联, 则逆向过程无法从纯噪声出发。

(3) $t^* = 100$ 时的信号权重：

$$\bar{\alpha}_{100} = 0.98^{100} = e^{100 \ln 0.98} = e^{100 \times (-0.020203)} = e^{-2.0203} \approx 0.1326$$

$$q(x_{100}|x_0) = \mathcal{N}(\sqrt{0.1326}x_0, (1 - 0.1326)I)。$$

- 信号权重 (x_0 的贡献): $\sqrt{0.1326} \approx 0.3641$
- 噪声权重 (ϵ 的贡献): $\sqrt{1 - 0.1326} = \sqrt{0.8674} \approx 0.9313$

直观含义: 在 $t = 100$ 时, x_0 的信号只剩约 36%, 噪声已占 93% (信噪比约 0.39: 1)——模型需要在主要是噪声的 x_{100} 中恢复原始 x_0 , 任务已经相当困难。

(4) 等方差调度的缺点：

等方差调度 $\beta_t = \text{const}$ 使 $\bar{\alpha}_t$ 在 t 接近 0 时下降很慢 (起始段信号损失慢), 在 t 中段急剧下降, 在 t 接近 T 时已接近 0。余弦调度使 $\bar{\alpha}_t = \cos^2(\cdot)$ 随 t 近乎线性地从 1 下降到 0, 噪声添加均匀, 避免了「初始段几乎不加噪 (训练信号弱)、中段急剧加噪 (梯度剧烈变化)」的双重问题, 训练更稳定。

Sanity check: $0.98^{100} \approx 0.1326$, 验证: $\ln(0.1326) = -2.019$, $100 \ln(0.98) = 100 \times (-0.0202) = -2.020$, 误差在舍入范围内。

T-7.7.4 【离散扩散与 MDLM 目标】**(1) 边际分布推导：**

$$Q_t = (1 - \beta_t)I + \beta_t \mathbf{1} e_M^\top, \text{ 即 } [Q_t]_{x_t|x_{t-1}} = (1 - \beta_t)\delta_{x_t, x_{t-1}} + \beta_t \delta_{x_t, M}。$$

$x_0 = v$ (非 MASK 的 token) 时, 经 t 步转移的边际:

- 若 $x_t = v$ (从未被 MASK): 需要所有 t 步均「保持」, 概率 $\prod_{s=1}^t (1 - \beta_s) = \bar{\alpha}_t$ 。
- 若 $x_t = M$ (至少被 MASK 一次): 余下概率 $1 - \bar{\alpha}_t$ (一旦变成 M 就是吸收态, 不会再变)。
- 若 $x_t = u \neq v, M$: 概率为 0 (保持只能变成 v 或 M , 不会变成其他 token)。

故 $q(x_t|x_0 = v) = \bar{\alpha}_t \delta_{x_t, v} + (1 - \bar{\alpha}_t) \delta_{x_t, M}$ 。■

(2) 吸收态的核心优势：

文本 token 是离散且无自然距离结构的——「猫」和「狗」之间没有连续插值; 各向同性高斯噪声在连续空间中有意义 (每一步只是稍微「模糊」), 但在离散空间中不存在类比。吸收态 (替换为特殊 MASK token) 有自然的语义解释: MASK 代表「信息未知」, 从 MASK 恢复原 token 等价于「根据上下文填充」, 与 MLM 框架天然对接。

(3) MDLM 目标解释：

(a) 求和只对 MASK 位置: 只有被 MASK 的位置 $x_t^{(i)} = M$ 才有信息损失, 未被 MASK

的位置已知 $x_t^{(i)} = x_0^{(i)}$ ，无需预测（条件概率为 1，对数为 0），求和仅在「信息丢失」的位置上有意义。

- (b) 权重 $|\alpha'_t|/\alpha_t$ 的直觉： $|\alpha'_t|/\alpha_t = |d \ln \alpha_t / dt|$ 是对数 α_t 的变化率——在 α_t 下降快（大量 token 被 MASK）的时刻，权重大（训练信号强）； $\alpha_t \approx 1$ （早期，几乎没有 MASK）时权重小； $\alpha_t \approx 0$ （晚期，几乎全是 MASK）时 $|\alpha'_t|/\alpha_t$ 也趋于 $|\alpha'_t|/\alpha_t$ ，具体取决于调度；整体上是「每个时刻的信息变化率」的重要性加权，使模型在「信息正在被移除的临界时刻」受到更多监督。

Sanity check: (1) 的推导利用了吸收态的关键性质——一旦进入 M 就无法离开，使累积概率有如此简洁的形式。

T-7.7.5 【扩散语言模型 vs 自回归模型】

(1) 论断评判：不成立。两处不严谨之处：

- 不严谨之处一：「并行生成」并不保证模型内部表示了双向推理——扩散模型的去噪网络通常是双向 Transformer（所有 token 同时可见），但其训练目标（噪声预测/MASK 恢复）不显式要求双向推理；模型可能仍然学习了「顺序先验」。
- 不严谨之处二：「必然优于」是绝对陈述；AR 模型（尤其大规模预训练后）通过提示工程（逆向提问、CoT 推理）可以部分补偿单向训练的局限；「结构上可以并行」不等于「所有双向任务性能更好」。

(2) 推理效率计算：

AR 总步数： $L = 512$ （每步生成 1 个 token）

扩散总步数： $T_{\text{diff}} = 128$ （每步处理全部 $L = 512$ 个 token，但整体需 128 次前向传播）

步数比（AR 相对扩散）： $512/128 = 4.0000$

即 AR 需要的前向传播次数是扩散的 4 倍（但每次扩散步的批处理量是整个序列 L ，AR 每次是单 token）。

扩散优势场景：(a) 高度并行化的批量推理（多条序列同时生成，扩散每步并行度更高）；(b) 对生成延迟（time-to-first-token）不敏感但对总延迟（total latency）有要求的场景（扩散最后一步才输出完整序列）；(c) 需要多轮迭代修改（条件生成、填充）的任务。

(3) 曝光偏差的结构消除：

扩散语言模型训练时的条件是 x_t （加噪后的 token），而非「自己生成的上一步 token」——训练集（ x_t 来自前向过程）和推理集（ x_t 来自逆向过程的当前状态）均处于「含噪 token」的空间；没有「真实 token」和「生成 token」之间的分布漂移，因为每一步的条件变量 x_t 在训练和推理中都是同一类型的噪声状态。AR 模型的曝光偏差根源（训练时条件为真实 token，推理时为自生成 token）从结构上不存在于扩散框架中。

(4) 综合评判：

- (A) 实时对话（延迟敏感）：**AR 模型**。扩散模型需要 64–256 步才能输出完整结果，无法实现逐 token 流式输出；AR 的 KV-cache + streaming 是成熟方案。
- (B) 创意写作（高多样性，长文本一致性）：**扩散模型**（或两者皆可，但扩散有优势）。

并行生成全局一致性更强，避免了 AR 末尾部分因误差累积导致的语义漂移；多样性来自扩散过程的随机性，可通过引导（guidance）灵活控制。

- (C) 代码生成（填充任务 FIM）：**扩散模型**（FIM 场景）/ AR（左到右生成）。扩散模型在填充（fill-in-the-middle）任务中有结构优势（自然支持双向上下文），严格语法约束可以通过受约束解码（constrained decoding）在两类模型上实现。
- (D) 机器翻译（质量优先）：**两者皆可**，当前大规模 AR 模型在翻译质量上仍领先；扩散模型在迭代精化（iterative refinement）场景有潜力，但对延迟不敏感时可以用更多步数换取质量。

Sanity check：步数比 $512/128 = 4$ 正是「AR 需要与序列等长的串行步数」和「扩散需要固定步数的并行步数」之比，与两种架构的基本设计一致。

§ 7.8 将进一步延伸变分推断框架，将 ELBO 与 Friston 的变分自由能、JEPA 的能量函数、Kalman 滤波统一到「预测编码 $\leftrightarrow$ 世界模型」的更大图景中。

§ 7.8 习题：世界模型与预测编码的数学

导读：本节核心是「预测编码 = 变分推断 = 反向传播」的三重等价，以及 Kalman 滤波、JEPA、DreamerV3 在同一变分框架下的统一。Friston 的变分自由能是连接神经科学与深度学习的核心桥梁，Mamba 是 Kalman 滤波的非线性数据依赖推广。五题分别对应：A（变分自由能推导）、B（预测编码局部规则 vs 反向传播）、C（JEPA 能量函数与 VICReg 防 collapse）、D（Kalman 滤波与预测编码的对应计算）、E（世界模型框架的评判）。

题 1 【中 · 中推导 · 变分自由能与 Friston 框架】

导读：Karl Friston 的「主动推断」(Active Inference) 框架将感知和行动统一为变分自由能 F 的最小化——感知对应推断隐状态 (E 步)，行动对应最小化关于动作的自由能 ($\partial F / \partial a$)。其数学核心与 VAE 的 ELBO 完全等价。

(1) Friston 定义变分自由能为：

$$F[q, x] = D_{\text{KL}}(q(z) \| p(z|x)) - \log p(x) = -\text{ELBO}(q, x)$$

从 $-\text{ELBO}$ 的定义出发，推导上式中 $D_{\text{KL}}(q(z) \| p(z|x))$ 与 $\log p(x)$ 的关系（即验证 $F = -\text{ELBO}$ ）。

(2) Friston 框架的核心主张：大脑通过最小化 F 来实现感知。

- **感知** (E 步)：最小化 F 关于 $q(z)$ 等价于使 $q(z) \rightarrow p(z|x)$ (后验推断)。用 F 的表达式说明这一等价。
- **行动** (主动推断)：行动 a 影响感觉输入 x ，因此 $\partial F / \partial a$ 给出了最优行动的方向。解释为什么「最小化自由能 = 最小化预测误差 + 最小化对先验的偏离」(2-3 句)。

(3) 与 VAE 的对应：完成以下映射表：

Friston 框架	VAE 框架
变分分布 $q(z)$	?
感觉输入 x (观测)	?
隐状态 z (信念)	?
最小化 F (感知)	?
主动推断 $\partial F / \partial a$	?

教学注：Friston 框架不只是数学上的重新表述——它将「知觉」(perception) 和「行动」(action) 纳入同一优化原则（自由能最小化），为理解大脑和构建具身智能 AI 提供了统一的理论框架。

陷阱： $F = -\text{ELBO}$ 意味着最小化 F 等价于最大化 ELBO；ELBO 是证据 $\log p(x)$ 的下界，最大化 ELBO 不保证 $\log p(x)$ 本身被最大化（除非 $D_{\text{KL}} = 0$ ），两者的差距是近似推断的代价。

题 2 【中 · 中推导 · 预测编码局部规则与反向传播的等价性】

导读：Whittington & Bogacz (2017) 证明了层级预测编码网络中的局部更新规则（每层只需本层的预测误差）在精度加权极限下等价于反向传播，这为大脑如何实现高效学习提供了生物合理的机制。

设层级预测编码网络，第 l 层表示为 x_l ，预测误差 (prediction error) 为 $\varepsilon_l = x_l - f_l(x_{l+1})$ （其中 f_l 为从 $l+1$ 层到 l 层的生成模型），精度矩阵 Π_l 。

(1) 层级预测编码的自由能为：

$$F = \sum_l \varepsilon_l^\top \Pi_l \varepsilon_l$$

对 x_l 求梯度，推导 x_l 的更新规则：

$$\Delta x_l \propto -\frac{\partial F}{\partial x_l} = \Pi_l \varepsilon_l - \left(\frac{\partial f_l}{\partial x_l} \right)^\top \Pi_{l-1} \varepsilon_{l-1}$$

说明每一项的含义：第一项是「向上修正当前层」，第二项是「向下传递下一层的误差」。

(2) 对模型参数 θ_l (f_l 的参数) 的更新：

$$\Delta \theta_l \propto -\frac{\partial F}{\partial \theta_l} = \left(\frac{\partial f_l}{\partial \theta_l} \right)^\top \Pi_{l-1} \varepsilon_{l-1}$$

说明这如何类比反向传播： ε_{l-1} 扮演「误差信号」， $\partial f_l / \partial \theta_l$ 扮演「局部 Jacobian」，Hebbian 乘积结构是其核心特征。

(3) 精度加权 $\Pi_l = I$ (单位精度)、所有层同时收敛时，验证（定性）为什么预测编码等价于反向传播。（2-3 句即可）

教学注：预测编码与反向传播的等价性在「精度加权等于单位矩阵」的极限下成立；对于非单位精度，预测编码实际上是一种「注意力加权的反向传播」，赋予更可靠（高精度）的感觉通道更大的学习信号。

陷阱：预测编码的「局部性」指每层只需知道上一层的预测误差 ε_{l-1} ，不需要从输出层传递全局梯度——这在生物神经网络中对应局部突触可塑性，是该框架在神经科学上有价值的原因。

题 3 【中 · 中计算 · JEPa 能量函数与 VICReg 防 collapse】

导读：JEPa (Joint Embedding Predictive Architecture, LeCun, 2022) 和 VICReg (Bardes et al., 2022) 是两种避免表示 collapse (所有输入映射到同一点) 的自监督学习框架，两者在世界模型构建中都是重要组件。

JEPa 部分：

设 JEPA 的能量函数为 $E(x, y) = \|s_\phi(y) - P_\psi(s_\phi(x), z)\|^2$ ，其中 s_ϕ 为编码器， P_ψ 为预测器， z 为额外的隐变量（可选）， x, y 为上下文和目标。

(1) 解释为什么 JEPA 在**表示空间**（而非像素空间）进行预测可以避免像素级高方差问题。（举一个具体例子：预测「下一帧」在像素空间和表示空间分别需要建模什么）

(2) 在无 z （确定性预测）时， $E(x, y) = 0$ 的最简单解是什么？（即 collapse 解）JEPA 如何通过「停止梯度」（stop-gradient）或负样本机制避免此 collapse？（2-3 句）

VICReg 部分：

VICReg 损失为 $L = \lambda I + \mu V + \nu C$ ，其中：- 不变性项 $I = \frac{1}{n} \sum_i \|z_i - z'_i\|^2$ （两个视角表示的 ℓ_2 距离之和）- 方差项 $V = \frac{1}{d} \sum_j \max(0, \gamma - \text{std}(z^j))$ （惩罚标准差低于 γ 的维度）- 协方差项 $C = \frac{1}{d} \sum_{i \neq j} \frac{[C(Z)]_{ij}^2}{n-1}$ （惩罚维度间的线性相关）

(3) 设 $d = 3$ ， $n = 4$ ，表示矩阵 $Z \in \mathbb{R}^{4 \times 3}$ 如下（已中心化）：

$$Z = \begin{pmatrix} 1 & 0 & 0 \\ -1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -1 & 0 \end{pmatrix}$$

计算：(a) 每个维度的标准差（精确到四位小数）；(b) 协方差矩阵 $C(Z)$ 的非对角元素（精确到四位小数）；(c) 方差项 V （设 $\gamma = 1$ ）和协方差项 C 的值。

教学注：VICReg 的三项分别对应三种 collapse 模式： I 防止两视角表示分散（不变性）， V 防止维度退化为常数（维度 collapse）， C 防止维度之间线性相关（冗余 collapse）。

陷阱： V 中标准差是对 n 个样本计算， C 中协方差是对维度对计算（ $j \neq i$ 表示维度对，而非样本对）——注意下标含义不要混淆。

题 4 【重 · 计算题 · Kalman 滤波与预测编码的精确对应】

导读：Kalman 滤波是线性高斯系统下的贝叶斯最优滤波器；预测编码的误差修正规则与 Kalman 更新方程在结构上完全对应——Mamba 正是将这一对应推广到非线性、数据依赖的情形。

设线性高斯状态空间模型：

$$x_t = Ax_{t-1} + Bu_t + w_t, \quad w_t \sim \mathcal{N}(0, Q)$$

$$y_t = Cx_t + v_t, \quad v_t \sim \mathcal{N}(0, R)$$

Kalman 增益： $K_t = P_{t|t-1} C^\top (C P_{t|t-1} C^\top + R)^{-1}$

更新方程： $\hat{x}_{t|t} = \hat{x}_{t|t-1} + K_t(y_t - C\hat{x}_{t|t-1})$

(1) 数值计算：

设标量系统（ $x, y \in \mathbb{R}$ ）， $A = 1, C = 1, Q = 0.5, R = 2.0$ ，先验协方差 $P_{t|t-1} = 1.0$ 。

计算：(a) Kalman 增益 K_t (精确到四位小数)；(b) 若预测值 $\hat{x}_{t|t-1} = 3.0$, 观测值 $y_t = 5.0$, 计算更新后估计 $\hat{x}_{t|t}$ (精确到四位小数)；(c) 更新后协方差 $P_{t|t} = (1 - K_t C)P_{t|t-1}$ (精确到四位小数)。

(2) 与预测编码的对应：

完成以下对应表（从 Kalman 框架到预测编码框架）：

Kalman 滤波	预测编码
预测残差 $y_t - C\hat{x}_{t t-1}$	?
Kalman 增益 K_t	?
先验协方差 $P_{t t-1}$	?
观测噪声协方差 R	?
更新步 $\hat{x}_{t t} = \hat{x}_{t t-1} + K_t(\cdot)$	?

(3) Mamba 作为 Kalman 的推广：

标准 Kalman 滤波中， A, B, C, Q, R 是固定参数（不依赖输入）。Mamba 的离散化状态空间方程为：

$$h_t = \bar{A}(x_t)h_{t-1} + \bar{B}(x_t)x_t, \quad y_t = Ch_t$$

其中 $\bar{A}(x_t) = e^{\Delta_t A}$, $\bar{B}(x_t) = (\Delta_t A)^{-1}(e^{\Delta_t A} - I)\Delta_t B$ 。

指出 Mamba 相对于 Kalman 滤波的两个关键推广：(a) 参数的数据依赖性（ $\bar{A}, \bar{B}$ 依赖 x_t ），(b) 非线性（通过门控和激活函数）。解释这两个推广如何使 Mamba 能处理 Kalman 滤波无法处理的问题类型。

教学注：「Mamba = 数据依赖的非线性 Kalman 滤波」是本节最重要的概念桥梁之一——Kalman 是线性高斯最优的，Mamba 用神经网络替换了固定参数，保留了递推结构但放弃了最优性保证，换取了更强的非线性表达能力。

陷阱：Kalman 增益 K_t 只在线性高斯假设下是「最优」的（最小化均方误差）；非线性系统需要 EKF（扩展 Kalman 滤波）或粒子滤波，Mamba 不是这些方法的近似，而是一种独立的神经网络参数化。

题 5【重 · 重评判 · 世界模型框架的能力边界】

导读：「世界模型」(World Model) 是 AI 研究的重要方向，其核心主张是「模型应该建立环境的内部表示，而非直接映射输入到输出」。DreamerV3 是目前最成熟的世界模型系统之一，但世界模型框架本身有明确的能力边界。

DreamerV3 的 RSSM (Recurrent State Space Model) 损失：

$$\mathcal{L}_{\text{RSSM}} = \mathbb{E}_q \left[\sum_t -\log p_\theta(o_t | h_t, z_t) + \beta D_{\text{KL}}(q_\phi(z_t | h_t, o_t) \| p_\theta(z_t | h_t)) \right]$$

- (1) 识别 $\mathcal{L}_{\text{RSSM}}$ 中的各项，说明它如何对应 ELBO 框架（重建项、KL 项、先验、后验）。
- (2) 判断以下关于 DreamerV3 的论断：
- (A) 「DreamerV3 的 RSSM 可以通过学习世界模型完全替代真实环境交互，只需少量真实样本即可达到最优策略。」
- (B) 「RSSM 中的 β 参数类似 β -VAE，较大的 β 强制更独立的隐表示，但可能损害重建质量。」
- (C) 「DreamerV3 中 z_t 是离散 latent（使用直通梯度估计），这比连续 latent 在状态空间结构化方面有本质优势。」
- (3) 预测编码框架（Friston）、JEPa（LeCun）、DreamerV3（Hafner）是三种不同的「世界模型」实现路径。对以下维度，比较三者的异同（填写表格）：

维度	预测编码（Friston）	JEPa	DreamerV3
预测发生在哪个空间	?	?	?
时间建模方式	?	?	?
学习信号来源	?	?	?
行动/规划能力	?	?	?

- (4) 「世界模型」框架的根本假设是「环境有足够规则的内部结构，使得建立内部表示是有益的」。指出两类世界模型框架失效的场景（即直接策略学习可能更优），并给出直觉解释。

教学注：(3) 的比较表揭示了三种路径的「设计哲学差异」：Friston 强调生物合理性和感知-行动统一；LeCun 强调层级表示和能量框架；Hafner 强调强化学习的样本效率。三者并非竞争关系，而是从不同角度逼近同一问题。

陷阱：(2)(A) 是对世界模型「样本效率优势」的过度推广——世界模型在规则环境（如 Atari）效果显著，但在高度随机或部分可观测的复杂环境（如真实世界机器人）中仍难以完全替代真实交互，模型误差累积会导致策略退化。

解答 § 7.8

T-7.8.1 【变分自由能与 Friston 框架】

(1) 推导 $F = -\text{ELBO}$ ：

由 $\log p(x) = \log \int p(x, z) dz$ ，分解：

$$\log p(x) = \mathbb{E}_{q(z)} \left[\log \frac{p(x, z)}{q(z)} \right] + D_{\text{KL}}(q(z) \| p(z|x))$$

即 $\log p(x) = \text{ELBO} + D_{\text{KL}}(q(z) \| p(z|x))$ ，故

$$D_{\text{KL}}(q(z) \| p(z|x)) - \log p(x) = -\text{ELBO}$$

因此 $F[q, x] = D_{\text{KL}}(q(z)\|p(z|x)) - \log p(x) = -\text{ELBO}$ 。■

(2) 感知与行动：

感知 (E 步)： $F = D_{\text{KL}}(q\|p(z|x)) - \log p(x)$ ，其中 $\log p(x)$ 不依赖 q ，故最小化 F 关于 q 等价于最小化 $D_{\text{KL}}(q\|p(z|x))$ ，即使 $q(z) \rightarrow p(z|x)$ (后验推断)。

行动与「最小化预测误差 + 最小化对先验的偏离」：将 F 展开为 $-\mathbb{E}_q[\log p(x|z)] + D_{\text{KL}}(q\|p(z))$ ——第一项 $-\mathbb{E}_q[\log p(x|z)]$ 是预测误差 ($p(x|z)$ 的负对数似然，即观测 x 与生成模型预测之间的差距)，第二项 $D_{\text{KL}}(q\|p(z))$ 是对先验 $p(z)$ 的偏离。最小化 F = 最小化预测误差 + 最小化对先验的偏离——行动 a 改变感觉输入 x ，从而影响预测误差项， $\partial F/\partial a$ 给出了「使世界符合预测」的最优行动方向。

(3) 映射表：

Friston 框架	VAE 框架
变分分布 $q(z)$	编码器 $q_\phi(z x)$
感觉输入 x (观测)	训练数据 x
隐状态 z (信念)	隐变量 z
最小化 F (感知)	最大化 ELBO (训练编码器和解码器)
主动推断 $\partial F/\partial a$	(无直接对应；VAE 是被动生成模型，无行动机制)

Sanity check： $F = -\text{ELBO}$ 的等式推导中，关键是 $\log p(x)$ 可以从 q 的期望中分离出来作为常数 (对 q 最优化时)，这正是 ELBO 推导的核心技巧。

T-7.8.2 【预测编码局部规则与反向传播的等价性】

(1) x_l 更新规则推导：

$$F = \sum_l \varepsilon_l^\top \Pi_l \varepsilon_l, \quad \varepsilon_l = x_l - f_l(x_{l+1})$$

$$\frac{\partial F}{\partial x_l} = \frac{\partial}{\partial x_l} [\varepsilon_l^\top \Pi_l \varepsilon_l + \varepsilon_{l-1}^\top \Pi_{l-1} \varepsilon_{l-1}]$$

第一项 (ε_l 含 x_l)： $\partial(\varepsilon_l^\top \Pi_l \varepsilon_l)/\partial x_l = 2\Pi_l \varepsilon_l$ (因为 $\partial \varepsilon_l/\partial x_l = I$)。

第二项 (ε_{l-1} 含 x_l 通过 $f_{l-1}(x_l)$)： $\partial(\varepsilon_{l-1}^\top \Pi_{l-1} \varepsilon_{l-1})/\partial x_l = -2(\partial f_{l-1}/\partial x_l)^\top \Pi_{l-1} \varepsilon_{l-1}$ 。

故 (忽略常数 2)：

$$\Delta x_l \propto -\frac{\partial F}{\partial x_l} = \Pi_l \varepsilon_l - \left(\frac{\partial f_{l-1}}{\partial x_l}\right)^\top \Pi_{l-1} \varepsilon_{l-1}$$

注：以 l 层预测 $l-1$ 层 ($f_l: x_l \rightarrow \hat{x}_{l-1}$)，第二项中的 Jacobian 应为 $(\partial f_l/\partial x_l)^\top$ (上层对本层的 Jacobian)。

含义：- 第一项 $\Pi_l \varepsilon_l$ ：向上修正——本层的预测误差 ε_l （本层表示与更高层预测的偏差）推动本层表示向预测的方向调整。- 第二项 $-(\partial f_l / \partial x_l)^\top \Pi_{l-1} \varepsilon_{l-1}$ ：向下传递——本层通过 f_l 预测了下层，若下层有预测误差 ε_{l-1} ，则将误差沿 Jacobian 转置传回本层，驱动本层表示做出能减少下层误差的调整。

(2) 参数更新的 Hebbian 结构：

$$\Delta \theta_l \propto (\partial f_l / \partial \theta_l)^\top \Pi_{l-1} \varepsilon_{l-1} :$$

- ε_{l-1} ：下一层的预测误差，扮演反向传播中「误差信号 δ_{l-1} 」的角色。
- $\partial f_l / \partial \theta_l$ ：生成模型的局部 Jacobian，对应反向传播中的「输入激活」。
- 两者的内积（外积类型）形成 Hebbian 型学习规则：「当下层有较大预测误差时，沿当前激活的方向调整参数以减小该误差」——只用本层信息，无需从输出层显式传递全局梯度。

(3) 等价性（精度 $\Pi_l = I$ ）：

精度矩阵为单位矩阵时， $\Delta \theta_l \propto (\partial f_l / \partial \theta_l)^\top \varepsilon_{l-1}$ ， ε_{l-1} 精确等于下层的预测误差；当所有层同时收敛（不再是迭代推断而是一步解析）， x_l 取极值时 $\partial F / \partial x_l = 0$ ，意味着预测编码在「均衡态」下的参数更新等价于反向传播（误差信号通过 Jacobian 转置从下一层反向传播到参数）——Whittington & Bogacz（2017）的定理正式证明了此等价。

Sanity check：(1) 的推导涉及两项，分别来自 l 层的自身误差和对 $l-1$ 层的预测误差，这对应「误差从两个方向汇入当前层」的双路修正机制。

T-7.8.3 【JEPA 能量函数与 VICReg 防 collapse】

(1) 表示空间预测的优势：

像素空间中预测「下一帧」需要精确建模每个像素的颜色值，而自然视频中像素变化高度随机（光照、运动模糊、背景纹理），高方差导致模型倾向于学习「平均值」（模糊帧）而非有意义的动态；表示空间中预测「下一帧的表示」只需捕捉高层语义变化（「物体向右移动了」），可以忽略像素级的随机变化，预测任务的方差大幅降低，模型可以专注于学习结构化的世界动态。

(2) collapse 解： $s_\phi(y) = s_\phi(x) = c$ （常数）时 $E = 0$ ——所有输入映射到同一表示，能量为 0 但表示失去区分能力。

JEPA 通过对目标分支使用**停止梯度**（只更新上下文分支 $s_\phi(x)$ ），目标分支用动量更新，如 BYOL/I-JEPA）来避免：若两个分支同步更新，梯度会找到 collapse 捷径；异步更新（目标分支缓慢移动）使 collapse 的「速度」被抑制，同时不变性通过在线预测目标被间接强制。

(3) VICReg 数值计算：

Z 已中心化， $n = 4$ ， $d = 3$ 。

(a) 每维标准差：

- 维度 1： $z^1 = (1, -1, 0, 0)$ ， $\text{std}(z^1) = \sqrt{\frac{1^2 + (-1)^2 + 0^2 + 0^2}{4-1}} = \sqrt{2/3} \approx 0.8165$
- 维度 2： $z^2 = (0, 0, 1, -1)$ ， $\text{std}(z^2) = \sqrt{2/3} \approx 0.8165$
- 维度 3： $z^3 = (0, 0, 0, 0)$ ， $\text{std}(z^3) = 0.0000$

(b) 协方差矩阵非对角元素 $([C(Z)]_{ij} = \frac{1}{n-1} \sum_k Z_{k,i} Z_{k,j}, \text{ 已中心化})$:

$$\begin{aligned} \cdot [C(Z)]_{12} &= \frac{1}{3}(1 \cdot 0 + (-1) \cdot 0 + 0 \cdot 1 + 0 \cdot (-1)) = 0.0000 \\ \cdot [C(Z)]_{13} &= \frac{1}{3}(1 \cdot 0 + (-1) \cdot 0 + 0 \cdot 0 + 0 \cdot 0) = 0.0000 \\ \cdot [C(Z)]_{23} &= \frac{1}{3}(0 \cdot 0 + 0 \cdot 0 + 1 \cdot 0 + (-1) \cdot 0) = 0.0000 \end{aligned}$$

(c) 方差项 V ($\gamma = 1$):

$$\begin{aligned} V &= \frac{1}{3} [\max(0, 1 - 0.8165) + \max(0, 1 - 0.8165) + \max(0, 1 - 0)] \\ &= \frac{1}{3} (0.1835 + 0.1835 + 1.0000) = \frac{1.3670}{3} \approx \mathbf{0.4557} \end{aligned}$$

协方差项 C ($d = 3$, $d(d-1) = 6$ 个非对角元素对):

$$C = \frac{1}{3} \cdot \frac{0^2 + 0^2 + 0^2 + 0^2 + 0^2 + 0^2}{n-1} = \mathbf{0.0000}$$

(所有非对角协方差为 0, 无维度线性相关惩罚。)

Sanity check: 维度 3 全零导致 V 中有一项 $\max(0, 1 - 0) = 1.0$, 显示 VICReg 的方差项会强烈惩罚退化维度; 协方差项为 0 说明维度 1 和维度 2 已经正交 (无冗余), 这是 VICReg 期望的状态。

T-7.8.4 【Kalman 滤波与预测编码的精确对应】

(1) 数值计算:

(a) Kalman 增益:

$$K_t = \frac{P_{t|t-1} C^\top}{C P_{t|t-1} C^\top + R} = \frac{1.0 \times 1}{1 \times 1.0 \times 1 + 2.0} = \frac{1.0}{3.0} \approx \mathbf{0.3333}$$

(b) 更新后估计:

$$\begin{aligned} \hat{x}_{t|t} &= \hat{x}_{t|t-1} + K_t(y_t - C\hat{x}_{t|t-1}) = 3.0 + 0.3333 \times (5.0 - 1 \times 3.0) \\ &= 3.0 + 0.3333 \times 2.0 = 3.0 + 0.6667 = \mathbf{3.6667} \end{aligned}$$

(c) 更新后协方差:

$$P_{t|t} = (1 - K_t C) P_{t|t-1} = (1 - 0.3333 \times 1) \times 1.0 = 0.6667 \times 1.0 = \mathbf{0.6667}$$

(2) 对应表:

Kalman 滤波	预测编码
预测残差 $y_t - C\hat{x}_{t t-1}$	预测误差 $\varepsilon = x_{\text{obs}} - \hat{x}_{\text{pred}}$

Kalman 滤波	预测编码
Kalman 增益 K_t	精度加权的误差传播系数 (Π_l 的函数)
先验协方差 $P_{t t-1}$	模型不确定性 $\sim 1/\Pi_l$ (精度的倒数)
观测噪声协方差 R	感觉精度 ($1/\Pi_{l=0}$, 感觉层的不确定性)
更新步 $\hat{x}_{t t} = \hat{x}_{t t-1} + K_t(\cdot)$	表示更新 $\Delta x_l \propto \Pi_l \varepsilon_l - \dots$ (加权误差修正)

(3) Mamba 相对于 Kalman 的两个推广：

- 数据依赖性**：Kalman 的 A, B, C 是固定矩阵，对所有输入和时刻使用相同的转移和观测关系；Mamba 的 $\bar{A}(x_t), \bar{B}(x_t)$ 随输入 x_t 动态变化，相当于「根据当前内容选择不同的状态转移规则」。这使 Mamba 能处理**非平稳序列**（如语言中不同话题需要不同的记忆策略），而固定参数的 Kalman 只能处理平稳线性系统。
- 非线性**：Kalman 的最优性建立在线性高斯假设上；Mamba 通过门控激活 (SiLU) 引入非线性，可以建模状态空间中的非线性动力学（如语言的复杂语义组合），代价是失去了 Kalman 的数学最优性保证，但获得了更强的表达能力。

Sanity check： $K_t = 1/(1 + R/P_{t|t-1}) = 1/(1 + 2) = 1/3$ ，当观测噪声 R 大（不可信观测）时 K_t 小（权重低），当先验协方差 $P_{t|t-1}$ 大（不确定先验）时 K_t 大（更相信观测）——这正是贝叶斯加权的直觉。

T-7.8.5 【世界模型框架的能力边界】

(1) RSSM 各项识别：

$$\mathcal{L}_{\text{RSSM}} = \mathbb{E}_q \left[\underbrace{\sum_t -\log p_\theta(o_t|h_t, z_t)}_{\text{重建项 (观测似然)}} + \beta \underbrace{D_{\text{KL}}(q_\phi(z_t|h_t, o_t) \| p_\theta(z_t|h_t))}_{\text{KL 项 (后验 vs 先验)}} \right]$$

对应 ELBO 框架： $-\log p_\theta(o_t|h_t, z_t)$ ：重建项——给定隐状态 (h_t, z_t) 时，观测 o_t 的负对数似然，对应 VAE 的解码器重建损失。 $-D_{\text{KL}}(q_\phi(z_t|h_t, o_t) \| p_\theta(z_t|h_t))$ ：KL 项——后验（给定观测的隐状态推断）与先验（仅由递推隐状态 h_t 给出的预测）的散度，对应 VAE 的 KL 正则项。 $-p_\theta(z_t|h_t)$ ：由 RNN 隐状态预测的隐变量先验（模型的「预期」）。 $-q_\phi(z_t|h_t, o_t)$ ：结合当前观测后的推断分布（「实际感知」）。

(2) 论断判断：

- 不成立**。世界模型通过在想象中的虚拟轨迹上训练策略来提高样本效率，但在高度随机或高维感知（如真实世界图像）的环境中，模型误差会随规划步数指数累积（「梦境发散」），无法完全替代真实交互。「少量样本达到最优策略」在结构化低维环境中近似成立，在复杂环境中过于乐观。
- 基本正确**。 β 项确实类似 β -VAE 中的 KL 权重，较大的 β 强化 KL 正则化，倾向于

- 使后验更接近先验（更独立、更结构化的隐表示），但同时限制了后验对观测的自由拟合，可能降低重建质量。这是 DreamerV3 中 β 调参的核心权衡。
- (C) **部分正确**。DreamerV3 确实使用直通估计器（straight-through estimator）的离散 latent；离散 latent 在捕捉「开关式」的状态（如游戏中的生死状态）时有结构优势；但「本质优势」的说法过强——连续 latent 在平滑动力学（如物理模拟）中表现更好，没有哪一种在所有情况下都优。

(3) 三框架比较表：

维度	预测编码（Friston）	JEPA	DreamerV3
预测发生在哪个空间	表示空间（每层预测下层）	表示空间（避免像素预测）	表示空间（ z_t 隐空间）
时间建模方式	层级递推（空间层级隐含时间）	框架不强制时间顺序	显式 RNN 递推（ $h_t = f(h_{t-1}, z_{t-1}, a_{t-1})$ ）
学习信号来源	预测误差（无监督，自由能）	能量最小化（自监督对比）	ELBO（重建 + KL）+ 奖励
行动/规划能力	主动推断（ $\partial F / \partial a$ ）	无内置规划（需外部规划器）	Actor-Critic 在想象中规划

(4) 世界模型框架失效的场景：

- ① **高度随机环境**（如随机奖励、无规律扰动）：环境的内部结构随机性强，任何紧凑的内部模型都会有较大的模型误差；在想象中规划会因误差累积而偏离真实轨迹；直接使用无模型方法（如 PPO）的样本效率反而可能更高，因为避免了模型误差的引入。直觉：建模随机性本身代价高于直接学习策略。
- ② **极低维、高度结构化的即时反应任务**（如 Pong、简单 bandit）：状态转移极简单，不需要多步预测——策略可以直接从观测映射到动作（无需内部模型作为中间层）；世界模型引入的额外参数和推断开销不带来性能收益，反而增加训练复杂度。直觉：当环境简单到直接学习策略毫不费力时，世界模型是过度设计。

Sanity check： (1) 中 RSSM 损失的两项与 ELBO 的重建项和 KL 项严格对应， β 系数出现在 KL 项前与 β -VAE 形式完全一致。(3) 表中「学习信号来源」一列清晰区分了三者：纯无监督（Friston）、自监督（JEPA）、有监督（DreamerV3 含奖励）——这是理解三框架适用场景的核心维度。